

Entwicklung Effizienter Multivariater Lebensdauertests

Development of Efficient Multivariate Life Tests

Der Fakultät Konstruktions-, Produktions- und Fahrzeugtechnik
der Universität Stuttgart
zur Erlangung der Würde eines Doktor-Ingenieurs (Dr.-Ing.) vorgelegte
Abhandlung

von
Marco Arndt, M.Sc.
aus Ravensburg

Hauptberichter: PD Dr.-Ing. habil. Martin Dazer
Mitberichter: tbd.

Tag der mündlichen Prüfung:

Institut für Maschinenelemente der Universität Stuttgart

2026

Vorwort

Die vorliegende Arbeit entstand während meiner Tätigkeit als akademischer Mitarbeiter am Institut für Maschinenelemente (IMA) der Universität Stuttgart.

Mein tiefster Dank gilt meinem Doktorvater und Mentor Herrn PD Dr.-Ing. habil. Martin Dazer. Als sein Stellvertreter im Fachbereich Zuverlässigkeitstechnik durfte ich neben seinem herausragenden Fachwissen eine außergewöhnliche Förderung erfahren. Seine stetige Unterstützung, die unzähligen Diskussionen und sein uneingeschränktes Vertrauen legten das absolute Fundament für diese Arbeit. Für dieses freundschaftliche Miteinander bin ich zutiefst dankbar.

Besonderer Dank gebührt Herrn Prof. Dr.-Ing. Bernd Bertsche, dem ehemaligen Leiter des Instituts für Maschinenelemente. Er prägte zu meinem Beginn am IMA eine einzigartige Institutskultur, die mir den kreativen und methodischen Freiraum für diese Forschungsarbeit überhaupt erst eröffnete.

Herzlich danke ich Herrn Prof. Dr. Name für die Übernahme des Mitberichts und die kritische Durchsicht meiner Arbeit, sowie Herrn Prof. Dr. Name für die Übernahme des Prüfungsvorsitzes.

Für die hervorragende Zusammenarbeit im Industrieprojekt danke ich Herrn Dr. sc. ETH Wolfram Raither. Unser freundschaftlicher Austausch und die fruchtbaren Gespräche waren stets eine wertvolle Inspirationsquelle.

Mein Dank gilt ebenso allen Mitarbeiterinnen und Mitarbeitern des IMA für das einzigartige Arbeitsklima. Allen voran danke ich Philipp Mell für den stets fachlich bereichernden und befruchtenden Austausch sowie für das akribische Korrekturlesen dieser Arbeit. Giuseppe Mannone, Kim Hintz, Dr.-Ing. Alexander Grundler und Erich Rittmaier danke ich für die wertvollen Diskussionen und die großartige gemeinsame Zeit am Institut. Ein besonderer Dank gilt Dr.-Ing. Kevin Lucan für das von ihm initiierte vertrauensvolle Umfeld und die gelebte unternehmerische Freiheit, die meinen Weg und den vieler ehemaliger Kollegen nachhaltig und mit

großer Freude prägen. Gleichmaßen danke ich allen studentischen Hilfskräften und Verfassern von Abschlussarbeiten für ihre tatkräftige Unterstützung.

Der wichtigste Dank gebührt meiner Familie. Meiner Ehefrau Marei und meiner Tochter Karla danke ich von ganzem Herzen für den unermüdlichen Rückhalt und die grenzenlose Geduld in all den Phasen, in denen diese Arbeit meine Zeit beansprucht hat.

Ravensburg, im September 2026

Marco Arndt

Kurzfassung

Die funktionale Absicherung technischer Produkte und Systeme über deren gesamten Lebenszyklus stellt eine zentrale Säule des industriellen Produktentwicklungsprozesses dar. Zur Vermeidung von Felddausfällen innerhalb des Gewährleistungszeitraums bei simultaner Reduktion der Entwicklungszyklen bedient sich die Zuverlässigkeitstechnik beschleunigter Lebensdauerprüfungen (*Accelerated Life Testing*). Da die Degradationskinematik technischer Systeme zumeist von mehreren interagierenden Lastgrößen determiniert wird, erfordert die empirische Modellierung zwingend den Einsatz der multivariaten statistischen Versuchsplanung (*Design of Experiments*). Als methodische für ingenieurs-wissenschaftliche Anwendungen adäquat hat sich hierbei die *Response Surface Methodology* auf Basis des *Central Composite Design* (CCD) etabliert.

Die ungeprüfte Übertragung klassischer Design of Experiments - Prinzipien auf die Zuverlässigkeitstechnik offenbart jedoch fundamentale methodische Diskrepanzen. Während konventionelle Versuchspläne auf geometrische Orthogonalität, Symmetrie und eine maximale Schätzpräzision im Zentrum des Versuchsraums (Interpolation) ausgelegt sind, erfordert die Lebensdauererprobung prinzipbedingt die Extrapolation: Um Ausfälle während (*End of Life Testing*) in wirtschaftlich vertretbarer Zeit zu induzieren, müssen Versuche unter signifikant erhöhten Lasten (*typischerweise im nordöstlichen Parameterraum*) durchgeführt werden. Die primäre Zielsetzung der Modellbildung ist indes die Generierung verlässlicher Prognosen unter moderaten Feldbedingungen (*im südwestlichen Parameterraum*). Erschwerend verletzen Lebensdauerdaten durch ihre inhärente Asymmetrie (i.d.R. *Weibull-Verteilung*) und das Auftreten von Zensierungen die klassischen Prämissen normalverteilter Residuen.

Die vorliegende Dissertation adressiert diesen methodischen Konflikt und entwickelt ein holistisches Framework zur Auslegung hocheffizienter, multivariater Lebensdauertests. Als Fundament dient die Einführung eines heuristischen Screening-

Verfahrens. Da die Komplexität multivariater Versuchspläne exponentiell mit der Anzahl der Faktoren skaliert, fungiert dieser Ansatz als deterministischer Filter zwischen qualitativer Systemanalyse und quantitativer Testplanung. Durch die methodische Fokussierung auf zeitabhängige Degradationsmechanismen wird die Dimensionalität des Parameterraums im Vorfeld rational auf die vitalen Einflussgrößen reduziert, ohne zunächst aufwendige experimentelle Vorversuche zu erfordern.

Im informationstheoretischen Kern der Arbeit wird das CCD systematisch auf seine Robustheit gegenüber praxisinduzierten Restriktionen evaluiert. Umfangreiche Monte-Carlo-Simulationen auf Basis pseudo-physikalischer *Ground-Truth*-Modelle belegen eine ausgeprägte topologische Resilienz des Designs. Es wird quantitativ nachgewiesen, dass moderate Orthogonalitätsabweichungen - wie der Entfall redundanter Zentralpunkte oder stochastische Varianzen in der Lastansteuerung - die statistische Trennschärfe (*power*) und die Schätzpräzision lediglich marginal kompromittieren. Der resultierende methodische Informationsverlust (*Design-Penalty*) wird in der Erprobungspraxis zumeist durch das inhärente System- und Messrauschen dominiert.

Diese nachgewiesene Fehlertoleranz legitimiert den Übergang zur adaptiven Versuchsplanung. Der bewusste Verzicht auf strikte geometrische Symmetrie zugunsten reduzierter Prüfumfänge erschließt ein wertvolles geometrisches Gestaltungsbudget. Anstatt Versuchspunkte ausschließlich zur passiven Kostensenkung zu eliminieren, werden freigewordene Stützstellen proaktiv modifiziert und während dem bereits etablierten Augmentierungs-Vorgang bei der Versuchsumsetzung als Extrapolations-Ankerpunkte in Richtung des anvisierten Feldbereichs verlagert. Dieser strategische Brückenbau im Parameterraum - formalisiert im neu entwickelten **Extrapolationvariance minimized Accelerated Lifetime Testing Design (EmALT)** - stützt das Regressionsmodell entlang des maßgeblichen Extrapolationspfads empirisch ab. Um den stochastischen Leistungsgewinn dieser gerichteten Asymmetrie objektiv bewerten zu können, wird die *Scaled Prediction Variance* als formale Metrik für die Vorhersageunsicherheit herangezogen. Da klassische Bewertungswerkzeuge wie der *Variance Dispersion Graph* infolge ihrer Rotationssymmetrie sicherheitskritische blinde Flecken (*Blind Spots*) bei gerichteten Extrapolationen aufweisen, wird der *Extrapolation Variance Graph* eingeführt. Dieser ermöglicht die richtungsabhängige Quantifizierung der Prognosevarianz und belegt formal, dass die Allokation von Ankerpunkten die Unsicherheit am Feld-Betriebspunkt massiv reduziert.

Um den methodischen Transfer dieses adaptiven Konzepts in die industrielle Zuverlässigkeitspraxis zu gewährleisten, erfolgt die Übertragung der Methodik von der idealisierten *Ordinary Least Squares*-Regression auf multivariate Lebensdauermodelle. Anhand Weibull-verteilter Daten und iterativer Parameteridentifikation mittels *Maximum-Likelihood-Estimation* wird validiert, dass die Extrapolationsabsicherung auch unter den Bedingungen realer Prüfstandsrestriktionen ihre überlegene Prognosefähigkeit bewahrt, was durch signifikant schmalere Konfidenzintervalle im Feldbereich belegt wird.

Den Abschluss bildet die Synthese mit einem entwickelten ökonomischen Effizienz- und Kostenmodell, welches den Zielkonflikt der Lebensdauererprobung quantifiziert: Ein in den Feldbereich verschobener Ankerpunkt steigert die statistische Prognosegüte, verursacht jedoch durch die reduzierte Stressbeschleunigung exponentiell längere Laufzeiten und folglich höhere Prüfstandskosten. Durch die Translation der Versuchszeit in monetäre Aufwände und deren algorithmische Verknüpfung mit dem Informationsgewinn etabliert die Arbeit den *Economic Extrapolation Power Index* als holistische Bewertungsmetrik. Eine empirische Fallstudie verifiziert abschließend die industrielle Praxistauglichkeit der entwickelten Systematik, indem das ungestützte Basismodell mittels prädiktiver *Confirmation Experiments* einem statistischen Härte-test unterzogen wird, was das Zuverlässigkeitsmodell zwingend vor sicherheitskritischen Überschätzungen im Feldbetrieb bewahrt.

Die Dissertation etabliert somit einen **allgemeingültigen Analyse-Leitpfad** und erbringt den Nachweis, dass sich Effizienz in der Versuchsplanung nicht über die bedingungslose Minimierung von Prüfläufen definiert, sondern durch das ökonomische Optimum zwischen minimalem Ressourceneinsatz und der zwingenden Absicherung der statistischen Vorhersagegüte im Einsatzbereich.

Abstract

The functional assurance of technical products and systems throughout their entire life cycle constitutes a central pillar of the industrial product development process. To prevent field failures within the warranty period whilst simultaneously reducing development cycles, reliability engineering employs *Accelerated Life Testing*. Since the degradation kinematics of technical systems are predominantly governed by multiple interacting stress factors, empirical modelling necessitates the application of multivariate statistical experimental design (*Design of Experiments*). In this context, the *Response Surface Methodology* based on the *Central Composite Design* (CCD) has established itself as the methodological standard.

However, the unverified transfer of classical *Design of Experiments* principles to reliability engineering reveals fundamental methodological discrepancies. Whilst conventional experimental designs are configured for geometric orthogonality, symmetry, and maximal estimation precision at the centre of the design space (interpolation), life testing inherently demands extrapolation: to induce failures within an economically viable timeframe, tests must be conducted under significantly elevated loads (typically in the north-eastern parameter space). The primary objective of the modelling, however, is the generation of reliable prognoses under moderate field conditions (in the south-western parameter space). Exacerbating this issue, lifetime data intrinsically violates the classical premises of normally distributed residuals due to its inherent asymmetry (Weibull distribution) and the occurrence of censored observations.

The present dissertation addresses this methodological conflict and develops a holistic framework for the configuration of highly efficient, multivariate life tests. The foundation is laid by the introduction of a heuristic screening procedure. As the complexity of multivariate experimental designs scales exponentially with the number of factors, this approach serves as a deterministic filter between qualitative system analysis and quantitative test planning. Through a methodological focus

on time-dependent degradation mechanisms, the dimensionality of the parameter space is rationally reduced to the vital influential variables in advance, without necessitating laborious preliminary experiments.

Within the information-theoretical core of the work, the CCD is systematically evaluated regarding its robustness against practice-induced restrictions. Extensive Monte Carlo simulations based on pseudo-physical *ground-truth* models demonstrate a pronounced topological resilience of the design. It is quantitatively proven that moderate deviations from orthogonality - such as the omission of redundant centre points or stochastic variances in load control - compromise the statistical power (*power*) and estimation precision only marginally. The resulting methodological loss of information (*design penalty*) is, in testing practice, predominantly overshadowed by the inherent system and measurement noise.

This substantiated fault tolerance legitimises the transition towards adaptive experimental design. The deliberate abandonment of strict geometric symmetry in favour of reduced test scopes unlocks a valuable geometric design budget. Instead of eliminating design points exclusively for passive cost reduction, freed support points are proactively modified and relocated towards the targeted field domain as extrapolation anchor points. This strategic bridge-building within the parameter space - formalised in the newly developed **Extrapolation-variance minimised Accelerated Lifetime Testing Design (EmALT)** - empirically supports the regression model along the crucial extrapolation path. To objectively evaluate the stochastic performance gain of this directed asymmetry, the *Scaled Prediction Variance* is utilised as a formal metric for prediction uncertainty. Since classical evaluation tools such as the *Variance Dispersion Graph* exhibit safety-critical blind spots during directed extrapolations due to their rotational symmetry, the *Extrapolation Variance Graph* is introduced. This enables the direction-dependent quantification of prediction variance and formally proves that the allocation of anchor points substantially mitigates the uncertainty at the field operating point.

To guarantee the methodological transfer of this adaptive concept into industrial reliability practice, the methodology is transitioned from idealised *Ordinary Least Squares* regression to multivariate lifetime models. Utilising Weibull-distributed data and iterative parameter identification via *Maximum-Likelihood-Estimation*, it is validated that the safeguarding of extrapolation retains its superior predictive capability

even under the conditions of real test bench restrictions, early failures, and censoring, as evidenced by significantly narrower confidence intervals in the field domain.

The synthesis is concluded by integrating a newly developed economic efficiency and cost model, which quantifies the inherent trade-off of life testing: an anchor point shifted into the field domain enhances the statistical prediction quality, yet causes exponentially longer test durations and consequently higher test bench costs due to the reduced stress acceleration. By translating the test duration into monetary expenditures and algorithmically linking them with the information gain, the work establishes the *Economic Extrapolation Power Index* as a holistic evaluation metric. Finally, an empirical case study verifies the industrial applicability of the developed systematics by subjecting the unsupported baseline model to a rigorous statistical test via predictive *Confirmation Experiments*, thus imperatively protecting the reliability model from safety-critical overestimations in field operation.

Consequently, the dissertation establishes a **universally applicable analytical framework** and demonstrates that efficiency in experimental design is not defined by the unconditional minimisation of test runs, but rather by the economic optimum between minimal resource deployment and the imperative safeguarding of statistical prediction quality within the application domain.

Inhaltsverzeichnis

Vorwort	iii
Kurzfassung	v
Abstract	ix
Nomenklatur	xvii
Abkürzungen	xvii
Indizes	xix
Formelzeichen	xxi
Abbildungsverzeichnis	xxvii
Tabellenverzeichnis	xxxiii
1 Einleitung	1
1.1 Forschungsperspektive und Problembeschreibung	2
1.2 Beitrag dieser Arbeit	3
1.3 Aufbau der Arbeit	4
2 Stand der Technik und Forschung	7
2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie	7
2.1.1 Begriffe und Definitionen	8
2.1.2 Deskriptive Statistik für Lebensdauerdaten	9
2.1.3 Parametrische Lebensdauermodelle	10
2.1.4 Parameterschätzverfahren	12
2.2 Statistische Versuchsplanung und Modellbildung	17
2.2.1 Grundlagen zur statistischen Versuchsplanung	19
2.2.2 Parameter-Screening	22
2.2.3 Statistische Versuchsplanung zur Lebensdauererprobung	23

2.2.4	Strategische Vorgehensweisen	29
2.2.5	Bewertung und Optimierung von Versuchsplanung	31
2.2.6	Statistische Modellbildung	44
3	Effiziente Testplanung für die multivariate Lebensdauererprobung .	53
3.1	Bewertung des Standes der Forschung und Technik	53
3.1.1	Das methodische Paradoxon moderner Versuchsplanung . .	54
3.1.2	Schlussfolgerung für die Testplanung	55
3.2	Forschungsfragen und wissenschaftliche Zielsetzung	56
3.3	Methodische Forschungsarchitektur	58
4	Parameter-Screening für multifaktorielle Lebensdauertests	61
4.1	Identifikation der latenten Einflussgrößen	62
4.2	Methodische Strukturierung und analytische Priorisierung	63
4.2.1	Erfassung von Interdependenzen	64
4.2.2	Matrixbasierte Bewertungsmethodik (Decision Making) . .	64
4.2.3	Physikalische und versuchsökonomische Randbedingungen	68
4.3	Methodische Synthese des Screening-Prozesses	69
4.4	Fazit: Heuristisches Screening als Gatekeeper der Modellvalidität .	70
5	Statistische Effektivität als Fundament effizienter Lebensdauertests	73
5.1	Methodische Simulationsarchitektur und pseudo-physikalisches Modell	74
5.2	Effektivität von Versuchsplänen mit Orthogonalitätsabweichungen	76
5.2.1	Sensitivitätsanalyse geometrischer und stochastischer Einflussgrößen	78
5.2.2	Ergebnisse der Sensitivitätsanalyse und Quantifizierung der Trennschärfe	80
5.2.3	Generische Auswirkungen relevanter Orthogonalitätsabweichungen	84
5.2.4	Fazit: Statistische Effektivität als Basis der explorativen Versuchsplanung	98
5.3	Adaptive Versuchsplanung zur Extrapolationsabsicherung	99
5.3.1	Die Scaled Prediction Variance als Prognosemetrik	100

5.3.2	Richtungsabhängige Bewertung: Der Extrapolation Variance Graph (EVG)	103
5.4	Kostenstruktur der Lebensdauererprobung	108
5.5	Übertragung auf multivariate Lebensdauermodelle	113
5.5.1	Signal-Rausch-Kalibrierung unter dem Sparsity of Effects Principle	116
5.5.2	Generische Auswirkungen asymmetrischer Versuchsplanung	119
5.5.3	Effizientes Lifetime Design of Experiments (L-DoE) und der Economic Extrapolation Power Index	123
5.6	Methodische Synthese und Transfer	132
6	Empirische Validierung der Extrapolationsabsicherung	135
6.1	Modellschätzung und Anpassungsgüte	138
6.1.1	Residuenanalyse und Verifikationsdiagnostik	140
6.2	Konsequenzen für die Zuverlässigkeitsmodellierung	141
6.2.1	Confirmation Experiments: Der statistische Härtetest	143
6.2.2	Ökonomische Schlussfolgerung und industrieller Business Case	144
7	Zusammenfassung und Ausblick	147
7.1	Diskussion	149
7.2	Ausblick	150
	Literatur	153
	Anhang	169
A	Sensitivitätsanalyse	169
B	Orthogonalitäts-Analysen der Design-Modifikationen	178
B.1	Szenarien bei Arbeitspunkt Signal-zu-Rausch Verhältnis, engl. Signal-to-Noise Ratio (SNR)= 1	183
B.2	Effizienzanalysen	183

Nomenklatur

Abkürzungen

<i>cdf</i>	Cumulative Distribution Function
<i>pdf</i>	Probability Density Function
AFT	Accelerated Failure Time
ALT	Accelerated Lifetime Testing
ANOVA	Varianzanalyse, engl. Analysis of Variance
AP	Ankerpunkt
BEV	Battery Electric Vehicle
CapEx	Capital Expenditure, Investitionskosten
CCD	Central Composite Design
CI	Confidence Interval
CP	Center Point
DfR	Design for Reliability
DoE	Design of Experiments
DSD	Definitive Screening Design
DSM	Design-Structure-Matrix
ECU	Electronic Control Unit
EmALT	Extrapolationvariance minimized Accelerated Lifetime Testing
EoL	End-of-Life
EPI	Economic Extrapolation Power Index
EVG	Extrapolation Variance Graph

FBD	Function Block Diagram
FC	Face Centered
FDS	Fraction of Design Space
FEA	Finite-Elemente-Analyse
FTA	Fault-Tree-Analysis
GLL	Generalized Log-Linear
GLM	Generalized Linear Model
ILP	Integer Linear Programming
IMA	Institut für Maschinenelemente
KPI	Leistungsindikator, engl. Key Performance Indicator
L-DoE	Lifetime Design of Experiments
LR-Test	Likelihood-Ratio Test
M7	Seven Management and Planning Tools
MCS	Monte-Carlo-Simulation
MLE	Maximum-Likelihood-Estimation
MMR	Median-Rank-Regression-Methode
MSE	Mean Squared Error
OFAT	One Factor At Time
OLS	Ordinary Least Squares
OMARS	Orthogonal Minimally Aliased Response Surface
PH	Proportional Hazard
PI	Prediction Interval
Q7	Seven Quality Tools
RSD	Response Surface Design
RSM	Response Surface Methodology
SNR	Signal-zu-Rausch Verhältnis, engl. Signal-to-Noise Ratio
SP	Sternpunkt

SPV	Scaled Prediction Variance
UPV	Unscaled Prediction Variance
VDG	Variance Dispersion Graph
VIF	Varianz-Inflations-Faktor
ZP	Zentralpunkt

Indizes

0	Zeitpunkt $t = 0$ Regressionskonstante Position im Versuchsraum
Σ	Gesamtkosten
AP	Ankerpunkt
A	Umgebungskosten (Ambient Conditions)
BC	Box-Cox-Transformation
B	Basis-Prüfstandshardware
C	Steuerungstechnik (Control)
D	Sternpunktabstand CCD
E	Energiekosten
F	Faktorieller Punkt
H	Hilfs- und Betriebsstoffe
I	Messtechnik (Instrumentation)
L	Labor- und Infrastrukturkosten
MC	Monte-Carlo-Simulation
M	Instandhaltungskosten (Maintenance)
O	Personalkosten (Operator)
SP	Sternpunkt
S	Laufende Durchführungskosten (Size of Testing)

T	Prüfstandskosten (Test Equipment)
V	Transformation
ZP	Zentralpunkt
a	Simulationsfaktor: Sternpunkt-Abstand
b	Simulationsfaktor: Sternpunkt-Shift
c	Simulationsfaktor: Zentralpunkte
d	Simulationsfaktor: Sternpunkte
error	Fehler 2. Art (Wahrscheinlichkeit für ein falsch-negatives Ergebnis)
e	Simulationsfaktor: System-Rauschen
f	Simulationsfaktor: Effekt-Verhältnis
g	Simulationsfaktor: Mess-Rauschen
h	Simulationsfaktor: Signifikanzniveau
m	Modellbezogen
nc	Nichtzentral (non-central)
nom	Nominale Werte
ob	Beobachtet (Observed)
sim	Simulationsergebnisse
<i>i</i>	Laufvariable
<i>j</i>	Laufvariable
<i>k</i>	Laufvariable (für Faktor-Indizierung)
<i>l</i>	Laufvariable
<i>o</i>	Obere Grenze des Vertrauensbereichs
<i>q</i>	Quantilwert
<i>u</i>	Untere Grenze des Vertrauensbereichs
<i>z</i>	Zensierungsindikator

Formelzeichen

A_2	Nicht-Orthogonalitätsindikator (A_2 -Kriterium)
A_{opt}	A-Optimalitätskriterium (Spur-Minimierung)
α	Signifikanzniveau
b	Abstand der Sternpunkte (Axial Points)
β	Weibull-Formparameter (Weibull-Modul)
β	Koeffizientenmatrix
β	Regressionskoeffizient, Modellparameter
C	Fehler 2. Art
Ω	Kandidatenmenge (Menge aller möglichen Faktorstufenkombinationen)
$\chi^2(\cdot)$	Chi-Quadrat-Verteilung
$\text{Cov}[\cdot]$	Covarianz-Operator
COVRATIO	Einflussstatistik auf Schätzwerte (Covariance Ratio)
D	Cook's Distanz
d_f	Anzahl der Freiheitsgrade
D_{opt}	D-Optimalitätskriterium (Determinanten-Maximierung)
γ	Binäre Entscheidungsvariable für die Design-Optimierung (1 = Versuchspunkt ausgewählt)
δ	Statusindikator (1=Ausfall, 0=Zensiert)
δ_{nc}	Nichtzentralitätsparameter der Prüfverteilung
DFBETAS	Einflussstatistik auf Koeffizienten (Difference in Betas)
DFFITS	Einflussstatistik auf Prädiktionen (Difference in Fits)
$E(\cdot)$	Erwartungswert
$\vec{e}$	Richtungsvektor zur extrapolierten Prognose
E	Effekt
A_{eff}	A-Effizienz

D_{eff}	D-Effizienz (Normierte Determinante)
G_{eff}	G-Effizienz (Verhältnis Modellparameter zu max. Varianz)
I_{eff}	I-Effizienz
V_{eff}	V-Effizienz
λ	Eigenwert (einer Matrix)
	Transformationsparameter (Box-Cox)
η_{eco}	Economic Extrapolation Power Index
ϵ	Fehlerterm-Matrix
ϵ	Fehlerterm
$E(\cdot)$	Erwartungswert
$F(\cdot)$	Ausfallwahrscheinlichkeit, Verteilungsfunktion
$f(\cdot)$	Dichtefunktion
$\mathbf{F}$	Fisher-Informationsmatrix
$G(\cdot)$	Verteilungsfunktion der kleinsten Extremwerte
$g(\cdot)$	Abgeleitete Funktion (für Delta-Methode)
$\mathbf{g}'$	Gradientenvektor der Funktion g
G_{opt}	G-Optimalitätskriterium (Minimierung max. Prädiktionsvarianz)
$\Gamma(\cdot)$	Gamma-Funktion
$\mathbf{H}_{\mathbf{f}}$	Hessian-Matrix (der Log-Likelihood-Funktion)
h	Eintrag von $\mathbf{H}$, Hebelwert
H_0	Nullhypothese
H_1	Alternativhypothese
$\mathbf{H}$	Orthogonale Projektionsmatrix, Prädiktionsmatrix, Hat-Matrix
I_{opt}	I-Optimalitätskriterium (Minimierung durchschn. Prädiktionsvarianz)
k	Anzahl der Modellparameter
$\mathcal{L}(\cdot)$	Likelihood-Funktion

$\Lambda(\cdot)$	Log-Likelihood-Funktion
$\lambda(t)$	Ausfallrate (zeitabhängig)
LR	Likelihood-Ratio
M	Informationsmatrix $\mathbf{X}'\mathbf{X}$
m	Replikation
MSE	Mittlerer quadratischer Fehler (Mean Squared Error)
μ	Lageparameter
N	Versuchsanzahl
n	Stichprobenumfang Anzahlvariable
k_f	Anzahl der Faktoren (Dimension)
p	Anzahl der Regressionskoeffizienten
p -Wert	Überschreitungs-, Rest-Irrtumswahrscheinlichkeit
p_f	Fraktionsgrad
$power$	Trennschärfe, Power
Pr	Wahrscheinlichkeit
$v(\mathbf{x}_0)$	Prädiktionsvarianz an der Stelle $\mathbf{x}_0$ (skaliert)
q	Quantilwert
R	Zuverlässigkeit
r	Paarweiser (Pearson-)Korrelationskoeffizient Radius im Versuchsraum (Euklidische Distanz) Studentisiertes Residuum
R^2	Bestimmtheitsmaß (Determinationskoeffizient)
r_{CS}	Cox-Snell-Residuum
r_{Dev}	Standardisiertes Devianz-Residuum
r	Standardisiertes Residuum (bezogen auf die SEV-Verteilung)
$\mathbb{R}$	Menge der reellen Zahlen
s	Empirische Standardabweichung (von $\mathbf{x}$)

s^2	Empirische Varianz (von x)
$SEV(\cdot, \cdot)$	Verteilung der kleinsten Extremwerte, engl. Smallest Extreme Value
σ	Standardabweichung (theoretisch) Skalenparameter
σ^2	Varianz der Lebensdauer (theoretisch)
SNR	Signal-zu-Rausch Verhältnis (engl. Signal-to-Noise Ratio)
T	Charakteristische Lebensdauer (Skalenparameter)
t	Zeit, Lebensdauermerkmal Teststatistik in Bezug zur Signal-to-Noise Ratio
$\mathbf{t}$	Vektor der Ausfallzeiten
τ	kontinuierliche Zufallsvariable
θ	Modellparameter, Schätzung
$\boldsymbol{\theta}$	Vektor der Modellparameter
v	Integrationsvariable (Gamma-Funktion)
$\mathbf{V}$	Varianz-Kovarianz-Matrix
V_{opt}	V-Optimalitätskriterium (Punktuelle Varianz-Minimierung)
$\text{Var}[\cdot]$	Varianz-Operator
$\mathcal{W}(\cdot, \cdot)$	Weibull-Verteilung
w	Hilfsgröße zur Berechnung von Vertrauensbereichen (standardisierte Log-Lebensdauer)
$\mathbf{X}$	Versuchsplan-Matrix oder Modellmatrix
x	Messwert, Variable, Parameter
$\bar{x}$	Arithmetischer Mittelwert (empirisch)
$\mathcal{X}$	Anker-Exposition (zulässiges Toleranzfeld für Extrapolationsankerpunkte)
$\mathbf{x}$	Position im Parameterraum
ζ	Einflussfaktor im Meta-Design der Sensitivitätsanalyse

ξ	Vektor der Einflussfaktoren im Meta-Design der Sensitivitätsanalyse
$\mathbf{y}$	Antwortmatrix
y	Systemantwort, -variable
z	Quantil der Standardnormalverteilung
z_e	Standardisierte Variable der Kleinstwertverteilung (SEV); Hilfsgröße für Wald-Konfidenzintervalle (äquivalent zu w)

Abbildungsverzeichnis

1.1	Aufbau der Arbeit.	6
2.1	Weibull $f(t)$ für ausgewählte Werte von T und b	13
2.2	Design of Experiments (DoE) Prozess-Schritte gemäß [40]	19
2.3	Parameter-Diagramm (P-Diagramm)	20
2.4	Schematische Darstellung der Effekte: (a) positiver Haupteffekt von Faktor x_1 , (b) Wechselwirkungseffekte zwischen x_1 und x_2	21
2.5	Standard voll-faktorieller Versuchsplan	24
2.6	Einfluss der Schrittweite auf die Approximation des Effekts E	25
2.7	Zentral zusammengesetzter Versuchsplan (CCD) mit $k = 2$	28
2.8	Strategischer Ansatz zu augmentierter Versuchsplanung für die Lebensdauererprobung nach [51, 52]	30
2.9	Fraction of Design Space (FDS) und Variance Dispersion Graph (VDG) für einen Central Composite Design (CCD) mit $k = 2$ Faktoren.	33
4.1	Function Block Diagram (FBD) mit Haupt-, Neben- und Teilfunktionen zur lückenlosen Identifikation funktionskritischer Einflussgrößen (in Anlehnung an [97] nach [99]).	63
4.2	Erweitertes Ishikawa-Diagramm zur expliziten Visualisierung zwingender Interaktionen zwischen Einflussfaktoren (adaptiert nach [81]). . .	65
4.3	Numerische Design-Structure-Matrix (DSM) mit Konfidenzangabe für die Abschätzung einflussreicher Parameter auf die Lebensdauer als Zielgröße, in Anlehnung an [42, 45, 97]	66
4.4	Grid-Analyse zur algorithmischen Ableitung der Faktor-Rollen (Aktiv, Kritisch, Passiv, Träge) für das nachfolgende DoE (entsprechend [97]). <i>Koordinaten:</i> Definiert durch Aktiv- und Passivsumme. <i>Konfidenzvektoren:</i> Visualisieren den Informationsstand und verweisen von unsicheren/intuitiven Werten „(!)“ auf fundierte Werte „!“	67

4.5	Dreistufiger, kondensierender Ablauf des heuristischen Screenings als obligatorische Vorstufe zur multivariaten L-DoE -Planung und -Modellierung - in Anlehnung an [97].	69
4.6	Die Volumenreduktion des Parameterraums: Überführung der qualitativen Komplexität in eine finanzierbare, statistisch valide Dimension für das quantitative L-DoE (adaptiert nach [97]).	71
5.1	Methodische Architektur der Monte-Carlo-Simulationsumgebung zur ganzheitlichen stochastisch-ökonomischen Bewertung multivariater Lebensdauertests für sämtliche Abschnitte in Kapitel 5.	77
5.2	Güte der Schätzer (Mean Squared Error (MSE)) am Arbeitspunkt SNR = 1,20. Geometrische Verzerrungen entladen sich primär in der Schätzvarianz, insbesondere beim Wegfall von Rand-Freiheitsgraden durch asymmetrische Ausfälle (Fall IV: Sternpunkt (SP)).	91
5.3	Absolute Schätzwerte der Modellkoeffizienten für den Arbeitspunkt SNR = 1,20. Der Bias bleibt marginal; die Ordinary Least Squares (OLS) -Schätzung ist fundamental erwartungstreu.	92
5.4	Numerische Konvergenz am Beispiel des Schätzwertes zu $\hat{\beta}_2$ über die Monte-Carlo-Simulation (MCS) -Iterationen.	93
5.5	Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der simulierten Störszenarien (SNR = 1,20).	95
5.6	Numerische Konvergenz der Trennschärfe über die Simulationsläufe am Beispiel von β_2	95
5.7	p-Wert Histogramm für den Signifikanztest am Beispiel von β_2 . Die kumulierte Häufigkeit links der α = 0,05-Schranke entspricht der berechneten power	96
5.8	Korrelation zwischen a priori Design-Metriken und dem resultierenden Trennschärfe-Verlust in den Störszenarien: Der MSE übersetzt den geometrischen Fehler am direktesten in die probabilistische Trennschärfe.	97
5.9	Vorhersagegüte bei Variation der Zentralpunkt (ZP) -Anzahl n_{ZP} für einen CCD mit k = 2 Faktoren.	101

5.10	Vorhersagegüte bei Variation der SP-Anzahl n_{SP} für einen CCD mit $k = 2$ Faktoren. Scaled Prediction Variance (SPV)-Werte für verschiedene Varianten entfallener Sternpunkte. Abbildung 5.10b zeigt den Fall des vollständigen Entfalls der Sternpunkte $(\alpha_D; 0)$ und $(0; \alpha_D)$ im Hochlastbereich.	102
5.11	Dreidimensionale Darstellung der SPV und zugehöriger Konturverlauf für ein beispielhaft asymmetrisch manipuliertes Versuchsdesign: es entfallen $(0; \alpha_D)$ und $(\alpha_D; 0)$ eines CCD mit $k = 2$ Faktoren.	103
5.12	Versuchsraum-Topologie: Das Basis-Design (CCD) wird durch strategische Extrapolations-Ankerpunkte (APs) (innerhalb der Exposure-Area) in Richtung des fernen Feld-Betriebspunktes (Ziel-Vektor) erweitert.	106
5.13	Dreidimensionale Darstellung der SPV und zugehöriger Konturverlauf für ein asymmetrisch manipuliertes Versuchsdesign: Das modifizierte CCD ($k = 2$) beinhaltet drei APs zur Stützung des südwestlichen Quadranten.	107
5.14	Der klassische VDG verschleiert den lokalen Design-Nutzen des um APs modifizierten CCD durch radiale Mittelung. Der Extrapolation Variance Graph (EVG) belegt hingegen die signifikante SPV-Reduktion zielgerichtet entlang des Extrapolationsvektors zum Prognosepunkt.	108
5.15	Struktur des Kostenmodells zur Berechnung der Gesamtkosten C_Σ als Funktion der Versuchsplan-Implementierung, identifizierter Kostenfaktoren sowie zufallsbehafteter Versuchslaufzeiten t_i (in Anlehnung an [95]).	111
5.16	Antwortfläche der charakteristischen Systemlebensdauer T in Abhängigkeit der Faktoren x_1 und x_2 . Die Projektion verdeutlicht die massive Extrapolationsdistanz zwischen dem DoE-Zentrum und den geforderten Feld-Bedingungen.	118
5.17	Absolute Schätzwerte der Modellkoeffizienten für die asymmetrischen Designvarianten am Arbeitspunkt $SNR = 1,20$. Der Bias bleibt marginal; die Erwartungstreue des OLS-Schätzers ist gewahrt.	121
5.18	Aggregierte p -Wert Histogramme der verglichenen Designvarianten. Der konforme Verlauf belegt die Abwesenheit systematischer Verzerrungen in der Signifikanzprüfung.	121

5.19	Vergleichende Analyse der absoluten statistischen Trennschärfe. Die asymmetrische Extrapolationsabsicherung (Extrapolationvariance minimized Accelerated Lifetime Testing (EmALT)) stellt die Detektionsrate im Vergleich zur reinen Ausdünnung nahezu vollständig wieder her.	123
5.20	Absolute Schätzwerte der Maximum-Likelihood-Estimation (MLE) -Koeffizienten im Weibull-Modell ($\text{SNR} = 1,20$). Der Schätzwert der Basislebensdauer $\hat{\beta}_0$ bleibt exakt; die Terme höherer Ordnung spiegeln die durch die Multikollinearität induzierte Varianzumverteilung wider.	126
5.21	Aggregierte p-Wert Histogramme der MLE -Signifikanztests. Die stochastische Auswertung liefert artefaktfreie Verteilungen.	127
5.22	Vergleichende Analyse der MLE-power . Das EmALT -Design rettet die für die Modellierung essenziellen Terme vor dem vollständigen Zusammenbruch.	128
5.23	Links: Exponentieller Zielkonflikt aus Prädiktionsvarianz und Erwartungskosten mit dem EmALT -Design als ökonomischem Optimum. Rechts: Inverse Kausalität zwischen klassischer <i>D</i> -Effizienz und Economic Extrapolation Power Index (EPI) am Beispiel von β_{22} (vollständige Evaluation in Anhang B.2).	130
5.24	Vergleich der prognostizierten Überlebenswahrscheinlichkeit $R(t)$ am Feldbetriebpunkt inklusive 90 %- Confidence Interval (CI) . Aufgrund der Distanz weisen beide Designs hohe Prognoseunschärfen auf, das EmALT -Design (schwarz) reproduziert das wahre Zuverlässigkeitsmodell jedoch mit stellenweise geringerer Varianz als das Basis- CCD (grau).	132
6.1	Vergleich der MLE -Parameterschätzungen für das klassische Basis- CCD und das EmALT -Design am realen Datensatz. Die Integration der Ankerpunkte führt zu einer elementaren Neukalibrierung ausgewählter Haupteffekte, Wechselwirkungen und der Streuung (Formparameter $\hat{b}$).	138
6.2	Modellanpassung im Parameterraum (logarithmische Darstellung): Beide Regressionsflächen im direkten visuellen Vergleich. Das Basis- CCD extrapoliert starr aus dem Hochlastzentrum. Das EmALT -Design wird durch die APs im südwestlichen Parameterbereich gestützt und erfährt eine merkliche Dämpfung der prognostizierten Lebensdauer.	139

6.3	Residuenanalyse der Modellpassung für das Basis- CCD und das EmALT -Design am realen Prüfstandsdatensatz ($N = 26$): Standardisierte Devianz-Residuen über $\ln(\hat{T})$ (links) sowie Cox-Snell-Residuen (rechts).	141
6.4	Empirische Lebensdauerprognose am Feldpunkt. Das EmALT -Design liefert eine radikal verkleinerte Prädiktionsvarianz (schmales Konfidenzband). Sein Median verbleibt kohärent innerhalb des weiten Vertrauensbereichs des Basis- CCD , zeichnet jedoch ein realitätsnäheres und konservativeres Ausfallverhalten.	142
B1	Laufende Konvergenz der Trennschärfe für alle Modellparameter. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar. . . .	179
B2	Konvergenz der OLS -Parameterschätzwerte ($\hat{\beta}_i$). Alle Modelle erweisen sich unabhängig von der geometrischen Verzerrung als erwartungstreu. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar. . .	180
B3	Relative Häufigkeiten der in der Simulation ermittelten p-Werte der Signifikanztests.	181
B4	Korrelierende Metriken zur prozentualen Trennschärfe-Änderung (Δ^{power} [%]) über alle Koeffizienten und Szenarien ergänzend zu Abbildung 5.8.	182
B5	Güte der Schätzer (MSE) für SNR = 1.	183
B6	Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der Störszenarien für SNR = 1.	183
B7	Leistungsindikator , engl. Key Performance Indicator (KPI) ggü. <i>D</i> -Effizienz aller Koeffizienten.	184

Tabellenverzeichnis

2.1	Mathematische Definitionen der Zuverlässigkeitsfunktionen	8
2.2	Deskriptive Kennzahlen im Kontext der Lebensdaueranalyse	10
2.3	Funktionen und Kennzahlen der Weibull-Verteilung	12
2.4	Übersicht, Zielsetzung und mathematische Definition verschiedener Optimalitätskriterien für Versuchspläne	37
2.5	Übersicht, Zielsetzung und mathematische Definition verschiedener Effizienzkriterien für Versuchspläne	39
2.6	Übersicht gängiger Transformationen der Belastungsgrößen zur Abbildung physikalischer Lebensdauermodelle	47
5.1	Nominale Startwerte und Streuparameter des pseudo-physikalischen Simulationsmodells	79
5.2	Definition und Parametrisierung der Untersuchungsfaktoren für die Sensitivitätsanalyse	81
5.3	Zusammenfassende Statistik der Trennschärfe und Identifikation der zugehörigen, jeweils dominierenden Einflussfaktoren. Die Ergebnisse demonstrieren, dass die Power maßgeblich durch unveränderliche Systemgrößen (Rauschen) und nur im Ausnahmefall durch modifizierbare Designgrößen limitiert wird.	82
5.4	Systematischer Trennschärfe-Verlust (Δ_{power}) bei Reduktion der Versuchsstützpunkte. Während lineare Haupteffekte relativ robust gegenüber einer Design-Ausdünnung bleiben, zeigt sich der primäre <i>Design-Penalty</i> in der Schätzung der quadratischen Terme.	83
5.5	Kalibrierte Startwerte und statistische Eigenschaften des additiven Normalverteilungs-Basismodells	88

5.6	Matrizeigenschaften und Effizienzen zu Optimalitätskriterien der simulierten Störszenarien. Der Varianz-Inflations-Faktor (VIF) wird für alle Haupt- und quadratischen Terme dargestellt ($\hat{\beta}_0$ entfällt theoriekonform).	90
5.7	Simulationsergebnisse: Relativer systematischer Schätzfehler (Bias) der einzelnen Koeffizienten in Prozent bezogen auf ihren Nominalwert bei SNR = 1,20.	92
5.8	Simulationsergebnisse: Durchschnittliche Trennschärfe-Änderung (Δ power) der Koeffizienten. Ein negatives Vorzeichen indiziert einen Verlust, ein positives Vorzeichen einen Gewinn an power verglichen zur Referenz (Basis CCD)	94
5.9	Indikative Relationen der Kostenpositionen in Bezug auf die Gesamtinvestition C_T für beispielhafte, typische Komponentenprüfstände im Maschinenbau.	113
5.10	Kalibrierte Startwerte und statistische Eigenschaften des log-linearen Weibull-Basismodells (Accelerated Failure Time (AFT) -Ansatz)	118
5.11	Matrizeigenschaften und Effizienzen. Der VIF wird für alle Terme dargestellt ($\hat{\beta}_0$ entfällt).	119
5.12	Relativer systematischer Schätzfehler (Bias) in Prozent bei OLS-Baseline (SNR = 1,2).	120
5.13	Schätzvarianz (MSE) der einzelnen Koeffizienten bei OLS-Baseline (SNR = 1,2).	122
5.14	Durchschnittlicher Trennschärfe-Verlust (Δ power) bei OLS-Baseline (SNR = 1,2).	122
5.15	Relativer systematischer Schätzfehler (Bias) in Prozent bei GLLW-Schätzung (Weibull-Modell).	125
5.16	Ganzheitliche ökonomisch-statistische Gegenüberstellung aller Modellkoeffizienten. Der Index η_{eco} quantifiziert die prädiktive Effizienz unter Berücksichtigung der Erwartungskosten $E(C_{\Sigma})$	130
6.1	Gegenüberstellung der Versuchspläne und realisierten Ausfallzeiten t_i für das Basis- CCD und das EmALT -Design ($N = 26$) auf Basis der Datenlage aus [125] und begleitenden Prüfläufen (APs).	137

A1	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = +1$	169
A2	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = 0$	170
A3	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = -1$	171
A4	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = +1$	172
A5	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = 0$	173
A6	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = -1$	174
A7	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = +1$	175
A8	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = 0$	176
A9	Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = -1$	177
B1	Simulationsergebnisse: Schätzvarianz (MSE) der einzelnen Koeffizienten bei $\text{SNR} = 2,4$	178

1 Einleitung

Die funktionale Absicherung technischer Produkte und Systeme über ihren gesamten Lebenszyklus bildet das Fundament einer beherrschten industriellen Produktentwicklung. Motiviert durch zugesicherte Systemeigenschaften, die Wahrung der Markenintegrität sowie zunehmend restriktive normative und regulatorische Rahmenbedingungen ist ein proaktives Zuverlässigkeitsmanagement unerlässlich. Aus der Marktperspektive manifestiert sich dies in der Anforderung, dass komplexe technische Systeme - von automatisierten Fahrzeugarchitekturen über vernetzte mechatronische Subsysteme bis hin zu energie- und antriebstechnischen Anlagen - ihre spezifizierte Funktionalität über den definierten Einsatz- und Gewährleistungszeitraum ausfallfrei erfüllen.

Die Zuverlässigkeitstechnik stellt das methodische Instrumentarium bereit, um dieses Ausfallverhalten über den Produktlebenszyklus hinweg quantitativ zu beherrschen. Das Spektrum reicht von deterministischen Methoden der funktionalen Sicherheit (*Safety*) über die stochastische Analyse von Felddaten bis hin zu Verfahren der statistischen Versuchsplanung für die beschleunigte Lebensdauererprobung (engl. [Accelerated Lifetime Testing \(ALT\)](#)). Das zentrale Ergebnis dieser probabilistischen Modellierung ist die Bestimmung der zeitabhängigen Überlebenswahrscheinlichkeit (Zuverlässigkeit $R(t)$), welche die Wahrscheinlichkeit quantifiziert, dass ein System unter definierten Betriebs- und Umgebungsbedingungen bis zu einem Zeitpunkt t funktionsfähig bleibt [1]. Ungenügende Zuverlässigkeitsprognosen in der industriellen Praxis resultieren selten aus einem rein quantitativen Mangel an Prüfstandskapazitäten. Vielmehr begründen sich Fehleinschätzungen primär darin, dass im Betrieb simultan *mehrere* heterogene Stressoren auf das System einwirken. Die resultierenden Schädigungsmechanismen werden maßgeblich durch latente Wechselwirkungen getrieben, welche durch isolierte, univariate Versuchsstrategien methodisch nicht erfasst werden können [2, 3].

Die Beherrschung dieser multivariaten Beanspruchungskollektive erfordert folglich den Einsatz statistischer Versuchsmethoden. Mit der fortschreitenden mechatronischen Integration und Funktionsverdichtung gewinnt die multivariate Lebensdauererprobung eine existenzielle Bedeutung für die ressourceneffiziente Produktabsicherung.

1.1 Forschungsperspektive und Problembeschreibung

Werden multivariate Interdependenzen bei der Lebensdauerabsicherung nicht methodisch aufgelöst, weicht die industrielle Praxis häufig auf kostenintensive Kompensationsstrategien aus: Restrisiken werden durch pauschale Sicherheitsfaktoren abgefangen, präventive Wartungs- und Austauschintervalle konservativ verkürzt oder Produkte vor Erreichen ihrer physikalischen Verschleißgrenze vorsorglich substituiert. Führen derartige Unschärfen dennoch zu unerwarteten Feldausfällen, resultieren daraus erhebliche Gewährleistungsaufwände, Rückrufaktionen und nachhaltige Reputationsverluste.

Um diesen Risiken bereits in frühen Entwicklungsphasen präventiv zu begegnen, muss die Zuverlässigkeitstechnik zunehmend komplexeren Randbedingungen genügen. Die Transformation hin zur Elektromobilität, der Trend zum extremen Leichtbau sowie verkürzte Entwicklungszyklen verschieben die operativen Belastungsgrenzen kontinuierlich. In modernen Fahrzeugarchitekturen hängt die Gesamtzuverlässigkeit beispielsweise von der Interaktion einer dreistelligen Anzahl vernetzter elektronischer Steuergeräte ([Electronic Control Units \(ECUs\)](#)) [4] sowie der Dauerhaltbarkeit mechatronischer Komponenten unter kombinierten Vibrations-, Temperatur- und Feuchte-Lastkollektiven ab. Gleichzeitig erfordert die Dimensionierung von Traktionsbatterien in [Battery Electric Vehicles \(BEVs\)](#) ein präzises Verständnis der elektrochemischen Alterungskinetik unter simultan wirkenden thermischen, mechanischen und zyklischen elektrischen Stressoren.

Während Produktdesigns im Zuge fortlaufender Effizienzsteigerungen bis an ihre physikalischen Belastungsgrenzen ausgereizt werden, verliert die Kausalitätskette zwischen Einzelbelastung und Systemversagen an analytischer Eindeutigkeit. Daraus folgt zwingend, dass die Fähigkeit zur präzisen, empirisch gestützten Lebens-

dauer- und Zuverlässigkeitsprognose unter multivariaten Belastungen eine zentrale Schlüsselkompetenz moderner Entwicklungsprozesse darstellt. Dies erfordert die methodische Integration der statistischen Versuchsplanung (DoE) in die beschleunigte Lebensdauererprobung (ALT).

Hierbei offenbart sich jedoch die fundamentale methodische Diskrepanz der vorliegenden Problemstellung: Klassische Konzepte der Versuchsplanung und der *Response Surface Methodology* (RSM) sind mathematisch auf geometrische Symmetrie, Orthogonalität und eine minimale Schätzvarianz im *Zentrum* des Versuchsraums (Interpolation) ausgelegt. Die Lebensdauererprobung erzwingt hingegen aus ökonomischen und zeitlichen Restriktionen die Prüfung unter signifikant erhöhten Beanspruchungsniveaus (ALT), um Ausfälle in vertretbaren Testdauern zu provozieren. Das eigentliche Ziel der Zuverlässigkeitsmodellierung liegt jedoch in der präzisen Vorhersage der Systemlebensdauer im fernen, moderaten Feldbereich (*Extrapolation*). Dieser strukturelle Widerspruch zwischen dem auf Interpolation optimierten Standard-DoE und den asymmetrischen, extrapolationsorientierten Anforderungen der Lebensdauererprobung führt bei Verwendung konventioneller Standardpläne zu signifikanten, unkontrollierten Prognoseunsicherheiten im Feldbetrieb.

1.2 Beitrag dieser Arbeit

Ausgehend von diesem methodischen Konflikt formuliert die vorliegende Dissertation eine neuartige Systematik zur Auslegung hocheffizienter, multivariater Lebensdauertests. Liegt ein System vor, dessen Zuverlässigkeit unter Einwirkung mehrerer interagierender Stressfaktoren experimentell abzusichern ist, stellt diese Arbeit das theoretische, simulative und empirische Instrumentarium bereit, um den Zielkonflikt zwischen stochastischer Extrapolationsgüte und exponentiell skalierenden Prüfkosten aufzulösen. Der wissenschaftliche Beitrag gliedert sich in vier zentrale methodische Kernelemente:

- **Deterministische Parameterselektion (Heuristisches Screening):** Etablierung eines formalisierten Screening-Verfahrens, welches qualitative Ingenieurmethoden in matrixbasierte Bewertungsalgorithmen überführt. Der Ansatz isoliert lebensdauer-kritische Stressoren und deren latente Wechselwirkun-

gen deterministisch, wodurch der Versuchsraum vor einer kombinatorischen Explosion geschützt wird, ohne aufwendige experimentelle Vorversuche zu erfordern.

- **Quantifizierung topologischer Resilienz:** Systematischer simulativer Nachweis mittels Monte-Carlo-Methoden, dass klassische Response Surface Designs eine signifikante Robustheit der Schätzpräzision und Test-Power gegenüber praxisinduzierten Orthogonalitätsabweichungen aufweisen. Hieraus wird die methodische Existenz eines nutzbaren geometrischen *Gestaltungsbudgets* abgeleitet.
- **Adaptive Versuchsplanung und richtungs-sensitive Varianzbewertung:** Proaktive Umwidmung des identifizierten Gestaltungsbudgets in strategisch allokierte Extrapolations-Ankerpunkte zur empirischen Absicherung des Prognosepfads. Flankierend wird eine richtungs-sensitive Bewertungsmethodik eingeführt, welche die Entwicklung der Prädiktionsvarianz gezielt entlang des physikalischen Extrapolationsvektors quantifiziert und optimiert.
- **Ökonomische Synthese und empirische Falsifikation:** Etablierung einer ganzheitlichen Bewertungsmetrik zur simultanen Bilanzierung von statistischer Test-Power, Extrapolationsunsicherheit und realen Prüfstandskosten. Anhand einer industriellen Fallstudie und prädiktionsintervall-basierter *Confirmation Experiments* wird empirisch nachgewiesen, dass die entwickelte Methodik Zuverlässigkeitsmodelle im Feldbetrieb nachweislich vor sicherheitskritischen Überschätzungen bewahrt.

1.3 Aufbau der Arbeit

Der strukturelle Aufbau der vorliegenden Arbeit orientiert sich an der methodischen Sequenz einer effizienten multivariaten Versuchskampagne (vgl. Abbildung 1.1).

Nach der in diesem Kapitel dargelegten Problemstellung widmet sich **Kapitel 2** dem aktuellen Stand der Forschung und Technik. Dort werden die mathematisch-statistischen Grundlagen der Zuverlässigkeitsdatenanalyse, der Maximum-Likelihood-Schätzung, der statistischen Versuchsplanung (DoE) sowie der multivariaten Modellbildung im Rahmen von [Generalized Linear Models \(GLMs\)](#) systematisch

aufbereitet. **Kapitel 3** synthetisiert diese Grundlagen, identifiziert die inhärenten Schwachstellen klassischer Optimalitätskriterien bei Lebensdauerprüfungen und leitet hieraus die zentralen Forschungsfragen der Dissertation ab.

Kapitel 4 behandelt die Dimensionierung des Versuchsraums und stellt das entwickelte heuristische Screening-Framework zur Isolierung relevanter Einflussgrößen und Interaktionspfade vor. Darauf aufbauend vollzieht **Kapitel 5** den methodischen Schritt zur quantitativen Versuchsplanung: Ausgehend von der quantifizierten topologischen Resilienz klassischer Designs werden die Methodik der richtungs-sensitive Varianzanalyse, das Konzept der asymmetrischen Extrapolationsabsicherung sowie die ökonomisch-statistische Effizienzbilanzierung hergeleitet und im Weibull-Kontext simulativ validiert.

In **Kapitel 6** erfolgt der Transfer in die industrielle Praxis. Anhand eines realen Datensatzes zur Lebensdauerprüfung von Lenksystem-Zahnriemen wird die Leistungsfähigkeit der entwickelten Methodik durch statistische Bestätigungsversuche empirisch verifiziert und der resultierende ökonomische Business Case dargelegt. Die Arbeit schließt in **Kapitel 7** mit einer Zusammenfassung der Kernergebnisse, einer kritischen Diskussion methodischer Anwendungsgrenzen sowie einem Ausblick auf weiterführende Forschungsfelder ab.




Abbildung 1.1: Aufbau der Arbeit.

2 Stand der Technik und Forschung

Dieses Kapitel stellt die für diese Arbeit erforderlichen technischen und methodischen Grundlagen bereit. Zunächst werden in Abschnitt 2.1 zentrale Begriffe und Konzepte der Zuverlässigkeitstechnik sowie das grundlegende statistische Verfahren zur Lebensdauer-Datenanalyse in Kombination mit Versuchsplänen erläutert. Darauf aufbauend folgen in Abschnitt 2.2 die Einführung und die Einordnung von DoE für Lebensdaueruntersuchungen sowie der multivariaten Lebensdauermodellierung aus dem Stand der Technik und der Wissenschaft, die beide für die Entwicklung effizienter Lebensdauerversuchspläne maßgeblich sind. Im Kontext der Lebensdauererprobung umfasst dies insbesondere typische, statistische Versuchspläne sowie Metriken und Indikatoren zur allgemeinen Bewertung der Versuchspläne.

2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie

Die Zuverlässigkeitstechnik befasst sich mit der probabilistischen Beschreibung der Lebensdauer technischer Produkte und Systeme sowie der strategischen und statistischen Planung von Lebensdauertests. Ziel ist die statistische Modellierung des Ausfallverhaltens unter Berücksichtigung der Funktionalität des Produkts bei relevanten Randbedingungen. Eine zentrale Aufgabe besteht somit in der statistischen Charakterisierung des Ausfallbegriffs mithilfe deskriptiver Statistik sowie in der Parametrisierung geeigneter Verteilungen zur Abbildung des Lebensdauerverhaltens. Die Modellierung kann - abhängig von den Randbedingungen - auf Basis *einer* einzelnen Belastungsgröße oder *mehrerer* Beanspruchungsparameter erfolgen, die gemeinsam den Produktausfall determinieren. Ein grundlegendes Verständnis des Umgangs mit zufallsverteilten Lebensdauerereignissen ist daher eine elementare Voraussetzung für die statistische Versuchsplanung im Rahmen der Zuverlässig-

keitstechnik. Weiterführende Konzepte und vertiefte methodische Ansätze zur Zuverlässigkeitstechnik sowie zur statistischen Testplanung sind allen voran in der Standardliteratur von Bertsche und Dazer [1] dargelegt, an deren Vorgehensweise sich die nachfolgende Übersicht orientiert.

2.1.1 Begriffe und Definitionen

Der **Ausfall**, engl. **End-of-Life (EoL)**, eines Produkts bezeichnet das Ende der Lebensdauer durch Verlust der geforderten Funktionalität. Maßgeblich hierfür sind von außen einwirkende **Belastungen** (*einzelne* oder zeitgleich *mehrere* Einflussparameter - Kräfte und Momente im mechanischen Kontext) sowie die daraus resultierenden inneren **Beanspruchungen** (innere Kräfte, Momente und lokale Spannungen). Die Ausfallzeit wird als kontinuierliche Zufallsvariable $\tau > 0$ verstanden. Die fundamentalen Funktionen zur probabilistischen Beschreibung des Lebensdauerverhaltens sind gemeinsam mit deskriptiven Statistiken in Tabelle 2.1 zusammengefasst [1, 2, 5].

Tabelle 2.1: Mathematische Definitionen der Zuverlässigkeitsfunktionen

Ausfallwahrscheinlichkeit (engl. **Cumulative Distribution Function (cdf)**):

Wahrscheinlichkeit eines Ausfalls bis zum Zeitpunkt t .

$$F(t) = \Pr(\tau \leq t) = \int_0^t f(t) dt \quad (2.1)$$

Zuverlässigkeit (engl. Reliability):

Überlebenswahrscheinlichkeit über den Zeitpunkt t hinaus.

$$R(t) = 1 - F(t) = \int_t^\infty f(t) dt \quad (2.2)$$

Tabelle 2.1 (Fortsetzung): Mathematische Definitionen

Wahrscheinlichkeitsdichte (engl. **Probability Density Function (pdf)**):

Änderungsrate der Ausfallwahrscheinlichkeit (Ausfallintensität).

$$f(t) = \frac{d}{dt}F(t) = \frac{d}{dt}\Pr(\tau \leq t), \quad t \geq 0. \quad (2.3)$$

Ausfallrate (engl. Hazard-Function):

Momentanes Ausfallrisiko, bedingt auf das Überleben bis t .

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t < \tau \leq t + \Delta t | \tau > t)}{\Delta t} = \frac{f(t)}{R(t)} \quad (2.4)$$

2.1.2 Deskriptive Statistik für Lebensdauerdaten

Um die theoretischen Parameter der Grundgesamtheit in der Praxis nutzbar zu machen, müssen diese auf Basis empirisch ermittelter Lebensdauerdaten (Stichprobe vom Umfang n mit Werten $x_1, \dots, x_n$) approximiert werden. Die deskriptive Statistik liefert hierfür Methoden zur Berechnung von **Lageparametern** (Zentrum) und **Streuungsmaßen** (Breite). Tabelle 2.2 fasst die theoretischen Definitionen der Zufallsvariable τ sowie die grundlegenden Zuverlässigkeitsfunktionen und ihre korrespondierenden empirischen Schätzer kompakt zusammen.

Tabelle 2.2: Deskriptive Kennzahlen im Kontext der Lebensdaueranalyse

Erwartungswert und Mittelwert:

Erwartungswert μ des theoretischen Lageparameters der Grundgesamtheit. Der arithmetische Mittelwert $\bar{x}$ dient als üblicher, **empirischer Schätzer** für eine endliche Stichprobe.

$$\mu = E[\tau] = \int_0^{\infty} t \cdot f(t) dt \quad \text{geschätzt durch} \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2.5)$$

Quantile und Median:

Das Quantil t_q definiert den Zeitpunkt, an dem die Verteilung $F(t)$ den Anteil $q \in [0, 1]$ erreicht. Der Median $t_{0.5}$ teilt die Fläche unter der pdf in zwei Hälften [6, 7].

$$F(t_q) = q \quad \text{bzw. für Median:} \quad F(t_{0.5}) = 0.5 \quad (2.6)$$

Varianz und Standardabweichung:

Die theoretische Varianz σ^2 (mittlere quadratische Abweichung) wird durch die erwartungstreue empirische Varianz s^2 geschätzt. Die empirische Standardabweichung folgt daraus zu $s = \sqrt{s^2}$.

$$\sigma^2 = E[(\tau - \mu)^2] \quad \approx \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2.7)$$

2.1.3 Parametrische Lebensdauermodelle

Während die deskriptiven Statistiken $\bar{x}$ und s^2 die zentrale Tendenz und die Streuung der vorliegenden Stichprobe quantifizieren, erlauben sie keine Extrapolation oder die Modellierung der zugrundeliegenden Funktionen $F(t)$ und $f(t)$ der Grundgesamtheit. Um eine prädiktive, mathematische Beschreibung des stochastischen

Ausfallverhaltens zu erhalten, müssen die in Abschnitt 2.1.1 definierten Lebensdauerfunktionen durch geeignete parametrische Verteilungsmodelle approximiert werden. Andernfalls können nur nichtparametrische Modellierungsansätze zur Schätzung der kumulierten Wahrscheinlichkeit in Überlebensfunktionen wie beispielsweise nach Kaplan und Meier [8] genutzt werden [2, 3]. Die Verteilungsmodelle hingegen bieten eine geschlossene mathematische Form für *cdf* und *pdf* und ermöglichen es, das komplexe Ausfallverhalten durch eine geringe Anzahl von Parametern zu charakterisieren.

Weibull-Verteilung

In der Zuverlässigkeitstechnik hat sich die **Weibull-Verteilung** aufgrund ihrer hohen Flexibilität als das am häufigsten verwendete Modell etabliert. Je nach zugrundeliegendem physikalischen Ausfallmechanismus finden jedoch auch andere statistische Verteilungen Anwendung, wie beispielsweise die **Lognormal-Verteilung** (häufig bei Ermüdungs-, Korrosions- oder Diffusionsprozessen), die **Exponentialverteilung** (zur Modellierung von Zufallsausfällen ohne Alterungseffekte) oder die **Beta-Verteilung** (allgemein zur formenreichen Modellierung von R über dem festen Intervall $[0, 1]$). Für weitere Ausführungen dazu sei an dieser Stelle jedoch auf bereits ausreichend diskutierte Aufbereitungen von Bertsche und Dazer [1], Rigdon et al. [3], Birolini [5], Yang [6] und Hedderich und Sachs [9] verwiesen.

Die (zweiparametrische) Weibull-Verteilung ist das Standardmodell zur Beschreibung der Lebensdauer von technischen Produkten ohne die Berücksichtigung eines möglichen dritten Parameters - der ausfallfreien Zeit t_0 . Sie wird durch den **Formparameter** $b > 0$ (Weibull-Modul) und die **charakteristische Lebensdauer** $T > 0$ (Skalenparameter), welche dem 63,2-ten Perzentil $t_{0,632}$ entspricht, beschrieben. Unabhängig von b gilt hier somit: $F(T) = 1 - e^{-1} \approx 63,2\%$. Folgt die Lebensdauer-Zufallsvariable τ dieser Verteilung, wird dies mathematisch als $\tau \sim \mathcal{W}(T, b)$ notiert. Damit ist sie in der Lage, alle drei Phasen der "Badewannenkurve" (Frühausfälle mit $b < 1$, Zufallsausfälle $b \approx 1$, Verschleißausfälle mit $b > 1$) durch die Wahl ihrer Parametrisierung abzubilden, vgl. Bertsche und Dazer [1]. Die Einheit des Skalenparameters T entspricht der des Messwertes. Die charakteristischen Funktionen und statistischen Momente der Weibull-Verteilung sind in Tabelle 2.3 zusammengefasst.

Tabelle 2.3: Funktionen und Kennzahlen der Weibull-Verteilung

Dichte- und Verteilungsfunktion (*pdf* & *cdf*)

$$f(t) = \frac{b}{T^b} t^{b-1} \exp \left[- \left(\frac{t}{T} \right)^b \right], \quad t > 0 \quad (2.8)$$

$$F(t) = 1 - \exp \left[- \left(\frac{t}{T} \right)^b \right], \quad t > 0 \quad (2.9)$$

Ausfallrate (Hazard-Funktion)

$$\lambda(t) = \frac{b}{T} \left(\frac{t}{T} \right)^{b-1}, \quad t > 0 \quad (2.10)$$

Momente und Gamma-Funktion

Mit der Gamma-Funktion (2.11) $\Gamma(x) = \int_0^\infty v^{x-1} e^{-v} dv$ ergeben sich Erwartungswert μ (vgl. Gleichung (2.5)) und Varianz σ^2 (vgl. Gleichung (2.7)) der Weibull-verteilten Lebensdauer τ :


$$\mu = T \cdot \Gamma \left(1 + \frac{1}{b} \right) \quad (2.12)$$

$$\sigma^2 = T^2 \left[\Gamma \left(1 + \frac{2}{b} \right) - \Gamma^2 \left(1 + \frac{1}{b} \right) \right] \quad (2.13)$$

Die Flexibilität der Verteilung zeigt sich in den Spezialfällen des Formparameters: Für $b = 1$ geht sie in die Exponentialverteilung über ($\lambda(t) = \text{konst.}$), während sie sich für $b \approx 3,6$ einer Normalverteilung annähert (vgl. Abb. 2.1) [10, 11].

2.1.4 Parameterschätzverfahren

Soll eine geschlossene mathematische Beschreibung des stochastischen Ausfallverhaltens eines Produktes gefunden werden, ist das in Abschnitt 2.1.3 definierte parametrische Verteilungsmodell $\tau \sim \mathcal{W}(T, b)$ zu schätzen. Die Modellparameter

Abbildung 2.1: Weibull $f(t)$ für ausgewählte Werte von T und b .

der Grundgesamtheit sind in der praktischen Anwendung jedoch unbekannt. Die zentrale Problemstellung der **Parameterschätzung** besteht somit darin, aus der empirischen Stichprobe bestehend aus n Realisierungen $t_1, \dots, t_n$ der Zufallsvariable τ statistisch fundierte Schätzwerte $\hat{T}$ und $\hat{b}$ zu gewinnen. Diese sind Voraussetzung, um das Lebensdauermodell (z.B. Gleichung (2.9)) zu quantifizieren und prädiktive Aussagen zu Quantilen oder der Zuverlässigkeit $R(t)$ zu ermöglichen. Eine wesentliche Komplikation hierbei sind jedoch das mögliche Auftreten von unvollständigen bzw. **zensierten** Daten sowie *multivariate* Abhängigkeiten der Belastungen zur Messgröße. Während für die Schätzung von Verteilungsparametern einfache Verfahren, wie die **Momentenmethode** oder die **Methode der kleinsten Fehlerquadrate** - engl. **OLS**, die beispielsweise bei der **Median-Rank-Regression-Methode (MMR)** im Wahrscheinlichkeitsnetz Anwendung findet, existieren, sind diese für die umfassende Analyse vielschichtiger Lebensdauerdaten in der Regel unzureichend und hier nur der Vollständigkeit wegen erwähnt - vgl. [1, 12]. Das universell anwendbare und robuste Verfahren, das Herausforderungen wie zensierte Daten und multivariate Modelle inhärent behandelt, ist die **MLE** [2, 13].

Maximum-Likelihood-Estimation

Das Grundprinzip der MLE besteht darin, diejenigen Parameterwerte (z.B. $\hat{T}, \hat{b}$) als Schätzwerte auszuwählen, welche die Wahrscheinlichkeit (engl. Likelihood) maximieren, die empirisch beobachtete Stichprobe (bestehend aus unabhängigen Ausfällen und Zensierungen) zu erhalten. Mathematisch wird die Wahrscheinlichkeit der Realisierung von $\mathbf{t} = (t_1, \dots, t_n)$ einer Stichprobe durch die **Likelihood-Funktion** $\mathcal{L}$ bestimmt. Diese ist eine Funktion des unbekannten Parametervektors $\boldsymbol{\theta}$, der k zu schätzende Parameter enthält (z.B. $\boldsymbol{\theta} = (T, b)$ mit $k = 2$).

Für den vereinfachten Fall, dass die Stichprobe ausschließlich aus n exakten Ausfallereignissen (vollständige Daten) besteht, ist die Likelihood-Funktion $\mathcal{L}$ das Produkt der einzelnen Wahrscheinlichkeitsdichten $f(\cdot)$:

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^n f(t_i|\boldsymbol{\theta}). \quad (2.14)$$

Zur Vereinfachung der numerischen Berechnung wird in der Anwendung die **Log-Likelihood-Funktion** Λ verwendet. Durch die Logarithmierung wird das Produkt (Gleichung (2.14)) in eine äquivalente, leichter zu maximierende Summe überführt:

$$\Lambda := \ln(\mathcal{L}(\boldsymbol{\theta})) \propto \sum_{i=1}^n \ln[f(t_i|\boldsymbol{\theta})]. \quad (2.15)$$

Wie zuvor dargelegt, ist dieser vereinfachte Ansatz für Lebensdauerdaten jedoch oft unzureichend, da er das Auftreten von zensierten Daten vernachlässigt. Für die praktische Anwendung existiert jedoch die entsprechende Erweiterung der Likelihood-Funktion um die Differenzierung etwaiger Testausgänge als *Durchläufer*. Dazu wird die Stichprobe als Paarung von t_i, δ_i für $\mathbf{t}$ definiert, wobei t_i der beobachteten Zeit und δ_i einem Statusindikator ($\delta_i = 1$ für einen exakten Ausfall; $\delta_i = 0$ für eine Rechts-Zensierung) entspricht [2, 14]. $\mathcal{L}$ für rechts-zensierte Lebensdauerdaten lautet somit:

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^n \left[f(t_i|\boldsymbol{\theta})^{\delta_i} \cdot R(t_i|\boldsymbol{\theta})^{1-\delta_i} \right] \quad (2.16)$$

und definiert die Log-Likelihood Funktion als:

$$\Lambda := \ln(\mathcal{L}(\mathbf{t}|\boldsymbol{\theta})) \propto \sum_{i=1}^n [\delta_i \cdot \ln f(t_i|\boldsymbol{\theta}) + (1 - \delta_i) \cdot \ln R(t_i|\boldsymbol{\theta})]. \quad (2.17)$$

Der Parametervektor $\hat{\boldsymbol{\theta}}$, der den Wert von $\Lambda(\boldsymbol{\theta})$ maximiert, liefert die MLE-Werte. Die Schätzwerte repräsentieren die (asymptotisch) effizientesten Schätzwerte für die Parameter der Grundgesamtheit. Dies erfolgt mathematisch durch Nullsetzen k partieller Ableitungen von Λ , sofern mathematisch entsprechende Schätzwerte in geschlossener Form durch $\partial\Lambda/\partial\boldsymbol{\theta} \stackrel{!}{=} 0$ identifiziert werden können [10, 15]. Andernfalls werden numerische Optimierungsalgorithmen, vgl. Newton-Raphson-Verfahren, Patternsearch und vergleichbare, dafür herangezogen - siehe weiterführend [15, 16] sowie detaillierte Untersuchungen von Kremer und Bertsche [17]. An dieser Stelle sei erwähnt, dass systematische Verzerrungen (engl. **Bias**) in $\hat{\boldsymbol{\theta}}$ aufgrund kleiner Stichprobenumfänge auftreten können [18] - jedoch auch korrigierbar sind, vgl. Arbeiten von Hirose [19] und Ross [20].

Die Qualität der Parameterschätzung beeinflusst daraus nicht nur die Prädiktionsgüte zur Schätzung der Lebensdauer oder Zuverlässigkeit - sie bedingt schließlich auch die Effizienz des Schätzverfahrens. Wird im Sinne eines effizienten Verfahrens zur multivariaten Lebensdauermodellbildung eine Methodik gesucht, ist auch die Qualität der Parameterschätzung damit entscheidend. Vertrauensbereiche, oder engl. **CI**s, können eine Metrik für die Qualität der Modellierung einnehmen, da sie die Unsicherheit oder *Unschärfe* in der Prädiktion bemessen.

Die MLE liefert nicht nur die Punktschätzer $\hat{\boldsymbol{\theta}}$, sondern auch die Quantifizierung von deren statistischer Unsicherheit (Präzision). Obwohl verschiedene Ansätze, wie die numerisch anspruchsvolleren Berechnungen nach Likelihood-Ratio-Methode, Bootstrap-Perzentil-Methode oder Monte-Carlo-Approximation existieren, ist das gängigste Verfahren zur Berechnung von **CI**s die Approximation mittels asymptotischer Normalverteilung der MLE-Schätzer $\hat{\boldsymbol{\theta}}$ [1, 13]. Dies erfolgt über die **Fisher-Informationsmatrix** $\mathbf{F}$, welche die Information der Stichprobe über die Parameter $\boldsymbol{\theta}$ gemäß Kremer und Bertsche [21] bezüglich des Rechenaufwands und resultierender Modellqualität vergleichsweise effizient quantifiziert. So wird diese Methodik auch in gängiger Applikationen als Standard angewandt, vgl. [6, 13, 15]. In der praktischen Anwendung wird die Fisher-Informationsmatrix auf Basis der resultierenden

Schätzwerte $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}$ so als Schätzung zur Beobachtung nach $\mathbf{F}_{\text{ob}}$ verwendet [13, 22]. Diese ist definiert als die negative **Hesse-Matrix** $\mathbf{H}_{\mathbf{f}}$ der Log-Likelihood-Funktion, ausgewertet an der Stelle der MLE-Schätzwerte $\hat{\boldsymbol{\theta}}$:

$$\mathbf{F}_{\text{ob}} := -\mathbf{H}_{\mathbf{f}}(\hat{\boldsymbol{\theta}}) = - \left[\frac{\partial^2 \Lambda(\boldsymbol{\theta})}{\partial \theta_j \partial \theta_l} \right]_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}} . \quad (2.18)$$

Die Matrix $\mathbf{H}_{\mathbf{f}}$ entspricht der $(k \times k)$ -Matrix der k zweiten partiellen Ableitungen von Λ (vgl. Gl. (2.17)). Eine Invertierung $\hat{\mathbf{F}}_{\text{ob}}^{-1}$ ergibt die geschätzte **Varianz-Kovarianz-Matrix** $\hat{\mathbf{V}}$:

$$\hat{\mathbf{V}} \approx \hat{\mathbf{F}}_{\text{ob}}^{-1}. \quad (2.19)$$

Die Diagonalelemente dieser Matrix $\hat{\mathbf{V}}_{jj}$ entsprechen den Varianzen $\text{Var}(\hat{\theta}_j)$ der einzelnen Parameterschätzwerte [13]. Die Nicht-Diagonalelemente $\hat{\mathbf{V}}_{jl}$ (für $j \neq l$) repräsentieren die **Kovarianzen** $\text{Cov}(\hat{\theta}_j, \hat{\theta}_l)$ [6, 13]. Diese Kovarianzen sind von entscheidender Bedeutung, da sie die statistische Abhängigkeit zwischen den Schätzwerten (z.B. zwischen $\hat{T}$ und $\hat{b}$) quantifizieren, welche für die Berechnung der CIs von abgeleiteten Funktionen wie $\hat{R}(t)$ erforderlich sind [2]. Basierend auf der Annahme der asymptotischen Normalität der Schätzer wird ein zweiseitiges $(1 - \alpha)$ -CI für einen einzelnen Parameter $\hat{\theta}_j$ direkt aus dessen Varianz approximiert durch:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\mathbf{V}}_{jj}}, \quad (2.20)$$

wobei $z_{1-\alpha/2}$ dem $(1 - \alpha/2)$ -Quantil der Standardnormalverteilung entspricht. Da Lebensdauerparameter (z.B. T, b) üblicherweise auf $\mathbb{R}_{>0}$ beschränkt sind, werden CIs robust über eine Log-Transformation der Parameter berechnet, um physikalisch unmögliche (negative) Intervallgrenzen zu vermeiden [2, 6, 13]:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \exp \left(\pm z_{1-\alpha/2} \cdot \frac{\sqrt{\hat{\mathbf{V}}_{jj}}}{\hat{\theta}_j} \right). \quad (2.21)$$

Die Berechnung dieser CIs für Schätzwerte $g(\hat{\boldsymbol{\theta}})$ zu Größen wie $\hat{R}(t)$ oder $\hat{t}_q$ erfolgt mittels **Delta-Methode** [2, 13]. Dieses auf einer Taylor-Reihenentwicklung basierende Verfahren (Gauß'sche Fehlerfortpflanzung) approximiert die Varianz der Funktion $\hat{g} = g(\hat{\boldsymbol{\theta}})$ unter Einbeziehung der gesamten Varianz-Kovarianz-Matrix.

Dazu wird der **Gradientenvektor** $\mathbf{g}'$ der Funktion g (z.B. $g = R(t)$) bezüglich des k -dimensionalen Parametervektors $\boldsymbol{\theta}$ gebildet:

$$\mathbf{g}' := \left[\frac{\partial g(\boldsymbol{\theta})}{\partial \theta_1}, \dots, \frac{\partial g(\boldsymbol{\theta})}{\partial \theta_k} \right]_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}}^T. \quad (2.22)$$

Die approximierte Varianz $\text{Var}(\hat{g})$ der Funktion ergibt sich dann aus:

$$\text{Var}(\hat{g}) \approx \mathbf{g}'^T \hat{\mathbf{V}} \mathbf{g}'. \quad (2.23)$$

Das Vertrauensintervall für die Funktion $\hat{g}$ wird anschließend unter Verwendung dieser Varianz (bzw. des Standardfehlers $\sqrt{\text{Var}(\hat{g})}$) analog zu Gleichung (2.20) berechnet [6, 13, 23]:

$$[g_u, g_o] = \hat{g} \pm z_{1-\alpha/2} \sqrt{\text{Var}(\hat{g})}. \quad (2.24)$$

Sollen auch hier nur positive Werte für g berücksichtigt werden, kann eine Logarithmierung in der Berechnung der Vertrauensbereiche analog zu Gl. 2.21 erfolgen [6].

2.2 Statistische Versuchsplanung und Modellbildung

Multivariate Lebensdauertests erfordern definitionsgemäß die Betrachtung mehrerer $k \geq 2$ Einflussfaktoren als Versuchsparameter. Dementsprechend entscheidend ist das Verständnis der wesentlichen Grundlagen im Umgang mit statistischer Versuchsplanung (DoE) für Lebensdauerdaten - auch unter dem Begriff **L-DoE** zusammengefasst - sowie der darauffolgenden Lebensdauermodellbildung. Während detaillierte Übersichten zur Historie von DoE von anfänglichen einschlägigen Beschreibungen durch Fisher [24], außerdem maßgebliche Weiterentwicklungen durch Box et al. [25] oder evolutionäre Schritte durch Taguchi [26] ausgiebig in Werken von Rigdon et al. [3], Kleppmann [27] und Montgomery [28] beschrieben sind, wird im Folgenden auf die wesentlichen Inhalte für die Forschungsschwerpunkte eingegangen.

Der primäre Anspruch von DoE besteht in der effizienten Planung empirischer Datenerhebungen, um Zielgrößen in Abhängigkeit erklärender Variablen zunächst robust zu modellieren und schließlich zu optimieren. Dieses Paradigma lässt sich

auch unter der Begrifflichkeit **Design for Reliability (DfR)** unmittelbar wiedererkennen und so auf die Analyse von Lebensdauer und Zuverlässigkeit übertragen [6, 29]. Da das lokale oder globale Optimum der Lebensdauer- bzw. Zuverlässigkeitsfunktion eines Produktes a priori meist unbekannt ist, erfordert dessen Identifikation eine systematische Exploration des Parameterraumes. Eine besondere Herausforderung stellt hierbei zusätzlich die Integration von **ALT** dar: Die Diskrepanz zwischen dem hochbelasteten Testraum (engl. **Design Space**) und dem regulären **Prädiktionsraum** (engl. Use Space oder **Field Space**) kann eine **Extrapolation** erforderlich machen, welche die Anforderungen an die Daten- und somit auch an die Designqualität deutlich verschärft. Für umfassendere Ausführungen zu Forschungserkenntnissen in **ALT** sei hierbei insbesondere auf Arbeiten von Meeker et al. [2], Nelson [13], Meeker und Escobar [30] und Elsayed und Zhang [31] verwiesen. Das Unwissen zur tatsächlichen Lage optimaler Antwortwerte und die Möglichkeit, per se einen systematischen Offset zwischen Design- und Field-Space durch **ALT** vorzufinden, stellen Teststrategien nach Best-Guess Ansätzen nachteilig. Hier wird in der industriellen Praxis häufig fälschlicherweise ein **One Factor At Time (OFAT)**-Testing Ansatz gewählt - unabhängig, ob vom Vorhandensein von Lebensdauer- oder anderen Daten, welcher schlichtweg die Wahrscheinlichkeit, Optimalstellen im Parameterraum systematisch zu treffen, senkt und somit gegenüber **L-DoE** nachteilig ist, vgl. [28, 32]. Da nun die geometrische Struktur eines Versuchsplans die erreichbare Modellierungsqualität deterministisch begrenzt, ist eine präzise Bewertung der Plangüte anhand genau dieser Eigenschaft im Vorfeld unerlässlich. Hierfür können objektive **Performance-Indikatoren** sowie mathematische **Optimalitätskriterien** dienen, vgl. [28, 33]. Ergänzend zu rationalen Metriken wie der statistischen **Trennschärfe** (engl. **Power**) und dem Schätzergebnis einer **Koeffizienten**- bzw. Parameterschätzung sind diese Größen damit bestimmend für effiziente multivariate Lebensdauertests.

Vor diesem Hintergrund fokussiert sich dieser Abschnitt auf eine gezielte Auswahl an Grundbegriffen und Metriken für multivariate Testpläne im Kontext von **L-DoE** sowie auf eine Übersicht der für Lebensdauertests geeigneten Versuchspläne, bevor abschließend die statistische Modellbildung beleuchtet wird.

Für eine grundsätzlichere Auseinandersetzung mit konventionellen Methoden und Werkzeugen von **DoE** sei, mit Blick auf den Fokus der vorliegenden Arbeit, hingegen auf die einschlägige Literatur von Kleppmann [27], Siebertz et al. [32], Hinkelmann [34] sowie vornehmlich Montgomery [28] und Myers et al. [35] ver-

wiesen. Diese Werke behandeln intensiv die Inhalte grundsätzlicher statistischer Versuchsplanung, welche um Perspektiven zu L-DoE bereits durch am [Institut für Maschinenelemente \(IMA\)](#) entstandene Dissertationen von Dazer [36], Herzig [37], Grundler [38] und maßgeblich durch Kremer [39] fortschreitend ergänzt wurden. Konsequenterweise werden Hintergründe zum Umgang mit normalverteilten Daten oder Abweichungen davon im Rahmen des DoE, die Diskussion zu einschlägigen Vor- und Nachteilen auch unter Abgrenzung zu Alternativen wie OFAT, die Regressionsmodellierung auf Basis der **Varianzanalyse, engl. Analysis of Variance (ANOVA)**, konventionelle Hypothesentests sowie fundamentale Ausführungen zu ALT in den nachfolgenden Ausführungen nicht explizit betrachtet, sondern als bekannt vorausgesetzt.

2.2.1 Grundlagen zur statistischen Versuchsplanung

Die Anwendung von DoE versteht sich grundsätzlich als Verfahrenskette entlang mehrerer Prozessschritte [28, 40], die beginnend von einer spezifischen Aufgabendeinition in einer statistisch abgesicherten Testentscheidung und Datenmodellierung mündet, vgl. Abbildung 2.2. Das erklärte Ziel ist es, den kausalen Zusammenhang


- 
- ① Definition des Untersuchungsziels
 - ② Identifizierung von Einflussparametern und Systemantwort
 - ③ Auswahl von Faktoren, Stufen und Parameterbereich
 - ④ Auswahl des Versuchsplans
 - ⑤ Durchführung der Versuchsreihe gemäß Versuchsplan
 - ⑥ Statistische Datenanalyse
 - ⑦ Schlussfolgerungen und Empfehlungen/Optimierung

Abbildung 2.2: DoE Prozess-Schritte gemäß [40]

zwischen Einflussfaktoren und Systemantwort funktional abzubilden. Darin abgebildete Einflussfaktoren sollen also per se **statistisch signifikant** und somit relevant für das Systemverhalten sein. So kann beispielsweise die zufallsverteilte Lebensdauer τ in Abhängigkeit von $k \geq 2$ technischen Beanspruchungen zunächst empirisch untersucht und anschließend modelliert sowie optimiert werden (*Schritt 1* in Abbildung 2.2).

Im Zentrum der Betrachtung steht damit generell ein technisches **System**, welches abstrakt als Produkt oder Prozess verstanden wird und den Zustand der Ausgangsgröße in Abhängigkeit der einwirkenden Eingangsgrößen definiert. Die zu untersuchende oder zu optimierende Ausgangsgröße wird als **Systemantwort** y (engl. **Response**) bezeichnet. Die gezielt kontrollierbaren und variierten Eingangsgrößen sind **Faktoren** (**Steuergrößen**), während nicht kontrollierbare oder unbekannte Einflüsse als **Störgrößen** (engl. **Noise**) klassifiziert werden (*Schritt 2*, vgl. [27]). Eine visuelle Aufstellung des genannten Zusammenspiels der Parameter kann dem Parameterdiagramm, kurz **P-Diagramm**, in Abbildung 2.3 entnommen werden [28]. Um das Systemverhalten zu charakterisieren, werden die Faktoren als kategoriale




Abbildung 2.3: Parameter-Diagramm (P-Diagramm)

oder kontinuierliche Parameter im Versuch auf diskreten Werten, den sogenannten **Faktorstufen** (engl. **Level**), variiert (*Schritt 3*). Dies erfolgt in aller Regel in kodierter Darstellung, so entsprechen gemäß der gängigsten Konvention die Stufe -1 der niedrigen und +1 der hohen Einstellstufe. Die planerische Kombination verschiedener Faktorstufen äußert sich in spezifischen **Versuchspunkten** innerhalb des Parameter-raums und entspricht der Versuchsplan-Matrix [27, 32]. Der **Versuchsraum** (engl. **Design Space**) wird hierbei durch die Gesamtheit der technisch realisierbaren und im Versuch einstellbaren Parameterkombinationen aufgespannt. Die Auswahl geeig-

neter statistischer Versuchspläne (Schritt 4) für die Durchführung (Schritt 5) wird in Abschnitt 2.2.3 detailliert behandelt.

Die aus der Variation resultierende Änderung der Systemantwort quantifiziert den Einfluss des Faktors, der statistisch als **Effekt** E bezeichnet wird und den Mittelwertunterschiede zweier Faktorstufen beschreibt (Schritte 6-7). Mittels **Kontrastmethode** wird also die Änderung der Systemantwort über alle durchgeführten Versuche mit jeweiligen Faktorstufen registriert [27, 28]:

$$E = \frac{1}{n|_{+1}} \sum y|_{+1} - \frac{1}{n|_{-1}} \sum y|_{-1} \quad (2.25)$$

So können mittels DoE strukturiert, effizient und verbindlich Informationen gewonnen werden, die über die direkten Effekte hinausgehen und differenziert Aufschluss über **Haupteffekte** sowie etwaige **Wechselwirkungen** der Faktoren auf die Antwort des Systems geben - vergleiche Abb. 2.4 sowie Kleppmann [27], Montgomery [28], Siebertz et al. [32] und Kremer [39]. Abbildung 2.4 visualisiert derartige Effekte. So gibt die Darstellung eines Haupteffekts in Abhängigkeit des Vorzeichens und der Steigung (**positiver** oder **negativer** Haupteffekt) sozusagen die Einflusstärke und -richtung wieder, während bei Wechselwirkung der Effekt in Abhängigkeit der Einstellung eines **Co-Faktors** dargestellt wird. Diese Zusammenhänge können




Abbildung 2.4: Schematische Darstellung der Effekte: (a) positiver Haupteffekt von Faktor x_1 , (b) Wechselwirkungseffekte zwischen x_1 und x_2 .

mathematisch positiv oder negativ beschrieben sowie durch Polynomfunktionen höherer Ordnung approximiert werden, um zusätzlich beispielsweise **quadratische**

Effekte oder **Mehrfachwechselwirkungen** abzubilden. In einem einfachen Fall wird für die lineare Beschreibung des Einflusses von Faktoren auf eine Antwortvariable ein durchschnittlicher Effekt durch eine Regressionskonstante β_0 sowie Haupteffekte durch die Regressionskoeffizienten $\beta_j, j = 0, 1, \dots, k$ zu einem Regressionsmodell erster Ordnung geschätzt. Falls relevant, erfolgt die Ergänzung um die jeweilige Wechselwirkung und einen Fehlerterm ϵ als Zufallsvariable für Abweichungen durch Mess- und Streufehler [3, 28, 35]. Beispielhaft $k = 2$ Faktoren resultiert daraus:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \epsilon. \quad (2.26)$$

Ein Modell zweiter Ordnung enthält zudem quadratische Terme, welche üblicherweise in Optimierungsaufgaben - so auch in der Lebensdauer- und Zuverlässigkeitsanalyse - relevant werden können:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \quad (2.27)$$

Die Gleichung der Modellierung kann so zur einfacheren Handhabung auch in Matrixnotation notiert werden und resultiert in:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad (2.28)$$

wobei $\boldsymbol{\beta}$ als $p \times 1$ Vektor der Regressionskoeffizienten ($p = k + 1$) durch den $n \times 1$ Vektor $\mathbf{y}$ aller Beobachtungen sowie durch die Versuchsplan-Matrix $\mathbf{X}$ ($n \times p$ Einträge) unter Zuhilfenahme eines geeigneten Schätzverfahrens (vgl. Abschnitt 2.1.4) zu ermitteln ist [6, 15]. Sollen zunächst perspektivisch relevante Faktoren für eine versuchstechnische Untersuchung identifiziert werden, kann ein **Parameter-Screening** durchgeführt werden. Dessen Durchführung kann sowohl heuristisch als auch versuchstechnisch erfolgen.

2.2.2 Parameter-Screening

Angesichts der potenziell hohen Komplexität durch Wechselwirkungen und Nicht-linearitäten sind die in Abbildung 2.2 beschriebenen Schritte 2-3 als propädeutische Arbeiten für ein effizientes Testdesign zu interpretieren. Methodisch lassen sich diese unter dem Terminus **Screening** subsumieren. Screening-Schritte sind

zwischen der Definition des Untersuchungsziels und der Durchführung der physischen Screening-Experimente angeordnet (vgl. *Schritt 3* in Abbildung 2.2 sowie Abschnitt 2.2.3). Daraus folgend dienen Screening-Methoden und -Versuchspläne dem Ziel, Informationsverluste bei einer minimalen Anzahl an Versuchsläufen zu begrenzen und die vitalen (*Steuergrößen*) von den trivialen (*Störgrößen*) Faktoren zu separieren, vgl. Abbildung 2.3.

Im Hinblick auf die Realisierung eines unter Zeit- und Kostenrestriktionen hochgradig effizienten DoE ist die effiziente Ausgestaltung der Screening-Strategie selbst schon von primärem Interesse. In traditionellen DoE-Ansätzen impliziert dies den Einsatz von **Kreativmethoden**, wie sie Standardliteratur von Montgomery [28] aufführen oder exemplarisch durch Kremer [39] und Gundlach [41] zusammengefasst werden. Hierbei ist ein Rückgriff auf Ergebnisse aus Experimenten, die explizit für das Forschungsziel ausgelegt wären, in dieser Phase unter Umständen noch nicht möglich. Es gilt damit zunächst, qualitativ eine rein rational erlesene Sammlung an potenziellen Einflussparameter zu erstellen, um diese dann anhand ihrer geschätzten Einflüsse auf die Systemantwort zu priorisieren. Ansätze aus der Kreativmethodik können dazu genutzt werden und fundieren auf der technischen **Systemanalyse**, die sowohl mit als auch ohne spezifisches Vorwissen über das System erfolgen kann [1]. Hilfsmittel zur Priorisierung einer hier erstellten Parametersammlung können beispielsweise Entscheidungsfindungsprotokolle, wie die **DSM**, und Methoden aus dem Komplexitätsmanagement, z.B. **Ishikawa-Diagramm**, sein - siehe hierzu auch weiterführende Werke von Mayers [42], Pahl et al. [43], Wu und Hamada [29] und Daenzer und Haberfellner [44] sowie Lindemann et al. [45]. Das Screening liefert somit eine rational festgestellte Auswahl an möglichst wenigen Einflussparametern, die mutmaßlich den entscheidenden Anteil an statistisch begründeter Manipulation der Systemantwort tragen und sich daher für eine Untersuchung in Versuchsplänen qualifizieren. Entsprechend ist daraufhin ein geeigneter Versuchsplan für die physischen Datenerhebungen zu wählen.


2.2.3 Statistische Versuchsplanung zur Lebensdauererprobung

Standardprotokolle aus dem DoE wie der 2^k **voll-faktorielle Versuchsplan** eignen sich grundsätzlich auch für Lebensdaueruntersuchungen, da sich hier analog zu vergleichbar statistisch verteilter Datenlage Effekte stets als (Mittelwert-) Unterschiede

in der Beobachtung der Systemantwort aus dem Vergleich zweier Einstellstufen eines oder mehrerer Faktoren ergeben [27].

2^k Faktorielle Versuchspläne

Demzufolge kann auch ein Lebensdauer-beeinflussendes Parameterset - beispielhaft (x_1, x_2) - voll-faktoriell auf zwei Stufen variiert und vollständig kombiniert werden, vgl. Abbildung 2.5. Ein derartiges Setup erlaubt es, die perspektivische



(a) Versuchsplan

Faktorstufen-Kombination #	Faktoren und Wechselwirkung		
	x_1	x_2	$x_1 x_2$
1	-1	-1	+1
2	+1	-1	-1
3	-1	+1	-1
4	+1	+1	+1

(b) Versuchsplanmatrix zu Abb. 2.5a

Abbildung 2.5: Standard voll-faktorieller Versuchsplan

Differenz erreichbarer **EoL**-Werte durch niedrige und hohe Beanspruchungswerte der Faktoren zu beobachten [2, 6]. Der voll-faktorielle Versuchsplan bildet somit den Standard-Versuchsplan im **DoE** und fordert bei einmaliger Durchführung (**Replikation** $m = 1$)

$$n = 2^k \quad (2.29)$$

Versuche. Dieser Stichprobenumfang stellt sicher, dass das resultierende Gleichungssystem **gesättigt** ist: Mit n Versuchen lassen sich $n - 1$ Effekte für Hauptfaktoren und Wechselwirkungen eindeutig bestimmen. Von entscheidender Bedeutung für die Aussagekraft des Versuchsplans ist die Wahl der Faktorstufen (vgl. Abbildung 2.6). Die Differenz der gewählten Level muss bereits im Vorfeld definiert werden, sodass signifikante Effekte sicher detektiert werden - vgl. **SNR** [12] - wobei gleichzeitig zu

geringe Abstände (Rauschen) sowie zu große Intervalle (Gefahr unerkannter Nichtlinearitäten) zu vermeiden sind, siehe auch Abbildung 2.6 sowie Kleppmann [27], Wu und Hamada [29] und Siebertz et al. [32]. Auf Basis eines solchen zweistufigen




Abbildung 2.6: Einfluss der Schrittweite auf die Approximation des Effekts E

Setups lässt sich der Zusammenhang zwischen Einflussgrößen und Lebensdauer interpolieren und in einem linearen Modell abbilden, welches zudem die Schätzung von Wechselwirkungen erlaubt. Werden davon abweichende Modellterme zur Abbildung der Systemantwort erwartet, berücksichtigen alternative Versuchspläne typischerweise drei bis fünf Faktorstufen. Der voll-faktorielle Versuchsplan nimmt dabei eine entscheidende Schlüsselrolle in der strategischen Modellbildung ein - insbesondere im Hinblick auf Lebensdauerdaten und Zuverlässigkeitstechnik. Darin aufgeführte Versuchspunkte können auf Basis der Struktur ihrer Zuordnung üblicherweise ideal aus Voruntersuchungen übernommen oder durch weiterführende Untersuchungen nachfolgend erweitert werden. Ausgehend vom qualitativen Parameter-Screening (vgl. Abschnitt 2.2.1) ist ohne initiale Experimente oft unklar, welche Faktoren die Antwortvariable, also beispielsweise die Lebensdauer eines Systems, nun tatsächlich signifikant beeinflussen. Folglich ist es essenziell, diese Fragestellung vor der eigentlichen Versuchsplanumsetzung effizient zu klären.

2^{k-p_f} Fraktionell Faktorielle Versuchspläne

Sind nach Anwendung der Kreativmethoden (qualitatives Screening) weiterhin so viele Einflussfaktoren als relevant eingestuft, dass ein voll-faktorieller Ansatz gemäß Gleichung 2.29 zu einem wirtschaftlich nicht vertretbaren Versuchsumfang führen würde, muss die Strategie hin zu physikalischen Screening-Tests verschärft werden.

Dies empfiehlt sich insbesondere für Systeme mit $k > 5$ Faktoren, um die experimentelle Effizienz zu gewährleisten. Zur Veranschaulichung der Notwendigkeit: Bereits eine einzelne Replikation eines voll-faktoriellen Experiments mit $k = 8$ Faktoren würde $2^8 = 256$ Versuchsdurchläufe erfordern, was in der Lebensdauererprobung meist illusorisch ist.

Für derartige Selektionsaufgaben eignen sich daher **Screening-Versuchspläne**, wie der **teil-faktorielle Versuchsplan** (Fractional Factorial Design) oder alternativ der **Plackett-Burman-Plan** [27, 28, 32]. Bei diesem Ansatz wird lediglich eine selektive Teilmenge (Fraktion) der voll-faktoriellen Versuchsagenda umgesetzt, um mit minimalem Informationsverlust die für den Anwendungsfall signifikanten Effekte zu beschreiben. Mathematisch wird die Anzahl der Versuche dabei auf

$$n = 2^{k-p_f} \quad (2.30)$$

reduziert, wobei p_f den Grad der Fraktionierung (die Anzahl der Generatoren) angibt. Die Validität dieses Vorgehens stützt sich auf zwei fundamentale empirische Postulate [3, 12]:

- Die **Effekthierarchie** besagt, dass Effekte niedrigerer Ordnung - primär Haupteffekte - in der Regel eine größere Amplitude aufweisen und mit höherer Wahrscheinlichkeit signifikant sind als Effekte höherer Ordnung.
- Die **Effektvererbung** impliziert, dass das Auftreten signifikanter Wechselwirkungen oder quadratischer Terme strukturell an die Signifikanz ihrer korrespondierenden Haupteffekte gekoppelt ist.

Eine direkte Konsequenz dieser Reduktion („Der Preis der Einsparung“) ist jedoch, dass sich in teil-faktoriellen Versuchsplänen bestimmte Effekte nicht mehr isoliert betrachten lassen (vgl. Abbildung 2.5a für den Fall einer Fraktionierung). So sind beispielsweise Haupteffekte unter Umständen nicht mehr zweifelsfrei von Wechselwirkungen höherer Ordnung zu unterscheiden. Da sich diese Effekte statistisch überlagern, spricht man von einer **Vermengung** (engl. **Aliasing**). Die Schwere dieser Vermengung wird dabei über die **Auflösung** (engl. Resolution) des Versuchsplans klassifiziert (z. B. Auflösung III, IV oder V). Wird dieser Informationsverlust jedoch bewusst in Kauf genommen und ingenieurwissenschaftlich bewertet, ermöglicht dies eine signifikante Reduktion des Versuchsumfangs, um effizient die dominanten

Faktoren aus der initialen Parametermenge zu isolieren. Diese Vorgehensweise ist von hoher Relevanz, da Lebensdauertests - ob als beschleunigte Prüfung mittels **ALT** oder unter Feldbedingungen - durch die inhärente Zeitabhängigkeit der Systemantwort erhebliche Kapazitäten binden und Ergebnisse nicht ad hoc verfügbar sind. Im Sinne einer ressourceneffizienten Gesamtstrategie sollten die Screening-Versuche daher idealerweise so konzipiert sein, dass sie nahtlos in einen nachfolgenden, höher aufgelösten Versuchsplan integriert (**augmentiert**) werden können.

Wirkungsflächenversuchspläne


Die bisher diskutierten Versuchspläne beschränken sich auf die Untersuchung von Faktoren auf jeweils zwei Stufen (± 1). Dies ermöglicht zwar eine effiziente Darstellung linearer Beziehungen und Interaktionen, jedoch ist die Modellierung komplexerer, nicht-linearer Effekte aufgrund fehlender Stützstellen im Versuchsraum damit physikalisch nicht möglich. Perspektivisch ist daher entscheidend, wie die bestehende Datenbasis weitergenutzt und augmentiert werden kann, falls die Systemantwort signifikante **Krümmungen** (engl. **Curvature**) aufweist und die quantitativen Beziehungen zwischen Faktoren und Zielgröße für eine Optimierung detaillierter beschrieben werden müssen.

Die **RSM** behandelt als Teildisziplin des **DoE** derartige Herangehensweisen und bietet hierfür spezielle **Wirkungsflächenversuchspläne** - engl. **Response Surface Designs (RSDs)** - an. Der erste Schritt zur Detektion von Nichtlinearitäten besteht in der Integration von n_{ZP} sogenannten **ZPs**, engl. **Center Points (CPs)**, in den faktoriellen Basisplan. Hierbei werden alle Faktoren auf die kodierte Stufe 0 (die Mitte des Versuchsraums) gesetzt. Weicht der Mittelwert der Systemantwort in den **ZPs** signifikant vom Mittelwert über die faktoriellen Eckpunkte ab, deutet dies auf eine Krümmung der Antwortfläche hin [28].

Um diese quadratischen Zusammenhänge explizit zu bestimmen, gilt der **Zentral-Zusammengesetzte-Versuchsplan**, engl. **CCD**, als etablierter Standard. Ein **CCD** entsteht durch die Augmentierung des ursprünglichen voll- (oder teil-)faktoriellen Plans (den n_{F} Eckpunkten), vgl. Abbildung 2.7, um:

- eine definierte Anzahl n_{ZP} an wiederholten **ZPs** (üblicherweise $3 \leq n_{\text{ZP}} \leq 5$ zur Abschätzung des reinen Fehlers) sowie

- $n_{SP} = 2 \cdot k$ zusätzliche **SPs** (engl. **Axial Points** oder **Star Points**), die auf den Achsen des Koordinatensystems im Abstand $\pm\alpha_D$ vom Zentrum liegen.



(a) Versuchsplan (CCD)

Versuchs- #	Faktorstufen	
	x_1	x_2
1	-1	-1
2	+1	-1
3	-1	+1
4	+1	+1
5	$-\alpha_D$	0
6	$+\alpha_D$	0
7	0	$-\alpha_D$
8	0	$+\alpha_D$
9	0	0
10	0	0
11	0	0
12	0	0
13	0	0

(b) Versuchsplanmatrix (Stufen) zu Abb. 2.7a

Abbildung 2.7: Zentral zusammengesetzter Versuchsplan (CCD) mit $k = 2$

Während die **ZPs** das Vorhandensein quadratischer Effekte validieren, ermöglichen die **SPs** deren Wertbestimmung. Die Wahl des Abstands α_D wird primär durch die Geometrie des interessierenden Versuchsraums (**Region of Interest**) diktiert. Betrachtet man diesen Raum als Kugel (**sphärisch**), ist die **Drehbarkeit** (**Rotierbarkeit**, engl. **Rotatability**) ein wesentliches Qualitätsmerkmal. Sie stellt sicher, dass die Varianz der Vorhersage nur vom Abstand zum Zentrum abhängt und invariant gegenüber einer Rotation des Koordinatensystems ist. Um diese Eigenschaft zu gewährleisten, berechnet sich der Abstand α_D in Abhängigkeit der faktoriellen Versuchspunkte n_F zu [28, 46]:

$$\alpha_D = (n_F)^{1/4}. \quad (2.31)$$

Alternativ kann für sphärische Räume auch $\alpha_D = \sqrt{k}$ gewählt werden (**Sphärisches CCD**), wodurch alle Versuchs- und **SPs** auf einer Kugeloberfläche liegen [35]. Ist der Versuchsraum hingegen durch harte physikalische Grenzen (z.B. maximale Temperatur) kubisch beschränkt, bietet sich der **flächenzentrierte CCD** (**Face Centered**

CCD) an. Hierbei wird $\alpha_D = 1$ gesetzt, sodass die **SPs** direkt auf den Flächenmitten des Würfels liegen. Dies vereinfacht die Durchführung, da nur drei Faktorstufen $(-1, 0, +1)$ benötigt werden, opfert jedoch die Eigenschaft der Rotierbarkeit. Eine effiziente Alternative zum **CCD** stellt das **Box-Behnken-Design** dar [47]. Dieses Design kombiniert 2^k -Faktorielle mit unvollständigen Blockplänen und platziert Versuchspunkte auf den Kantenmitten des Versuchsraums, vermeidet jedoch die extremen faktoriellen Versuchspunkte. Dies kann vorteilhaft für Lebensdauertests sein, bei denen extreme Ecken oft zu verfrühten Ausfällen führen können. Zudem ist es bei korrekter Wahl der **ZPs** alias-optimal gegenüber kubischen Modellen [48]. Stoßen Standard-Designs (**CCD**, **Box-Behnken**) aufgrund von Restriktionen im Versuchsraum (**Constraints**), nicht-standardmäßigen Modellierungszielen oder ungewöhnlichen Stichprobenumfängen an ihre Grenzen, empfiehlt sich der Einsatz von **Optimalen Versuchsplänen**, vergleiche übernächsten Abschnitt. Diese computer-generierten Designs minimieren algorithmisch die durchschnittliche Vorhersagevarianz über den gesamten Designraum und können Standard-Designs in ihrer Prädiktionsgüte oft übertreffen [28, 33].

2.2.4 Strategische Vorgehensweisen

In der Praxis entsteht ein **CCD** häufig im Rahmen einer **sequenziellen Versuchsstrategie**: Zeigt das initiale lineare Modell Anpassungsmängel (**Lack-of-Fit**), wird der bestehende faktorielle Plan um die **SPs** augmentiert, um ein Modell zweiter Ordnung zu fitten [35]. Modelle zweiter Ordnung sind insbesondere in der Lebensdauer- und Zuverlässigkeitstechnik vermehrt von Bedeutung, da sie die Existenz von lokalen Extrema (Minima oder Maxima) der Systemantwort im Versuchsraum detaillierter abbilden können [3, 49]. Prinzipielle Vorgehensweisen, die ein erfolgreiches Umsetzen von **DoE** bzw. **L-DoE** begünstigen sollten, wie **Blockbildung** oder **Randomisierung** (vgl. [27, 32]), seien hier bereits vorausgesetzt. Abbildung 2.8 fasst eine derartige strategische Vorgehensweise zur Realisierung eines **CCD** zusammen, wie sie beispielsweise Box und Wilson [50], Box et al. [51] und Bisgaard [52] vorschlagen.

Um effizient Versuchspunkte zu allokalieren und für sequentiell fortlaufende Versuche weiterverwendet zu werden, wird in Abgleich mit Abbildung 2.2 zunächst ein **teil-faktorieller Versuchsplan** zur Identifikation signifikanter Faktoren durch-




Abbildung 2.8: Strategischer Ansatz zu augmentierter Versuchsplanung für die Lebensdauererprobung nach [51, 52]

geführt. Anschließend wird der Plan zu einem **voll-faktoriellen Versuchsplan** erweitert, um alle Haupteffekte und Wechselwirkungen erster Ordnung zu schätzen. Daraufhin werden **ZPs** ergänzt, um das Vorhandensein von Krümmungen zu validieren. Abschließend werden bei Bedarf die **SPs** hinzugefügt, um ein vollständiges **CCD** zu realisieren. Insbesondere in der Lebensdauererprobung ist eine derartige schrittweise Vorgehensweise sinnvoll, um den Versuchsumfang zu minimieren und dennoch eine fundierte Modellierung der Systemantwort zu gewährleisten. Hierbei kann sequenziell ausgewertet und entschieden werden, inwiefern ein reduziertes Modell mit ausgewählten Termen gegenüber einem vollen Modell quadratischer Ordnung überlegen ist, um die Systemantwort präzise abzuschätzen [53]. Gleichzeitig erlaubt diese Strategie eine flexible Anpassung an unerwartete Ergebnisse in den einzelnen Phasen der Untersuchung, während lokale Optima von Zuverlässigkeiten im Sinne von **DfR** im Vorfeld ohnehin nicht bekannt sind. In Abhängigkeit der Anpassung zur Wahl eines geeigneten Modells, linear oder quadratisch, kann die Versuchsplanung so stets an die aktuellen Erkenntnisse angepasst werden. Dies folgt im Wesentlichen einer übergeordneten Logik der Modellkomplexität: Gemäß Russell [54] korrespondiert die minimale Anzahl notwendiger Versuchspunkte direkt mit der Anzahl der zu schätzenden Modellparameter p . Intuitiv erfordert bereits die Bestimmung der Parameter einer einfachen Geraden (β_0, β_1) mindestens $N = 2$ unterschiedliche Stützstellen. Soll hingegen ein quadratischer Zusammenhang $(\beta_0, \beta_1, \beta_{11})$ abgebildet werden, sind zwingend mindestens drei Stützstellen erforderlich, um das Gleichungssystem zu lösen. Im Kontext optimaler Versuchspläne definiert nach Pukelsheim [55] der Maßerweiterungssatz von Carathéodory dabei eine theoretische Obergrenze für die notwendigen Stützstellen von

$N = p(p + 1)/2 + 1$, beziehungsweise $N = p(p + 1)/2$, sofern das Interesse der Schätzung aller Elemente des Parametervektors β gilt [54]. Es kann beispielsweise auf Basis der Ergebnisse des teil-faktoriellen Plans entschieden werden, ob eine Erweiterung zum voll-faktoriellen Plan überhaupt notwendig ist. Genauso kann die Anzahl der ZPs an die beobachtete Streuung der Lebensdauerdaten angepasst werden, um eine robuste Schätzung des Fehlers zu gewährleisten. Ist dann eine Extrapolation in Richtung a-priori unbekannter Beanspruchungsniveaus geplant, verfügt der CCD über die notwendigen Stützstellen, um eine adäquate Exploration des Versuchsraums zu ermöglichen. Zuletzt kann selbst bei Extrapolation über die Grenzen des Versuchsraums hinaus auf Basis der modellierten Krümmungen eine fundierte Abschätzung der Systemantwort erfolgen [28, 35] und sogar mit Validierungsversuchen unter realen Einsatzbedingungen hinterlegt werden [49]. So wird eine effiziente und zugleich robuste Lebensdauererprobung ermöglicht, die den Anforderungen der DfR gerecht wird und wirtschaftlich abbildbar bleibt [56].

2.2.5 Bewertung und Optimierung von Versuchsplanung

Wird maximale Flexibilität jenseits starrer Standard-Designs wie dem voll-faktoriellen Setup oder dem CCD verlangt, können **optimale Versuchspläne** einen leistungsfähigen, *effizienten* Lösungsansatz für *multivariate* Versuchsplanung bieten [28, 35, 57]. Diese verfolgen das Ziel, die Versuchspunkte algorithmisch so im Versuchsraum zu positionieren, dass spezifische Qualitätskriterien - allen voran die Verteilung der (um die Versuchsanzahl N skalierten) **Prädiktionsvarianz**, engl. **SPV**,

$$v(\mathbf{x}_0) = \frac{N \text{Var}[\hat{y}(\mathbf{x}_0)]}{\sigma^2} = \mathbf{x}_0' \left(\frac{\mathbf{M}}{N} \right)^{-1} \mathbf{x}_0 = N \mathbf{x}_0' \mathbf{M}^{-1} \mathbf{x}_0 \quad (2.32)$$

optimiert werden [28, 35]. Die Prädiktionsvarianz ist ein dimensionsloses Maß, das ausschließlich über die geometrische Anordnung der N Versuchspunkte (der Matrix $\mathbf{X}$) in der **Informationsmatrix** (auch **Momentenmatrix**)

$$\mathbf{M} \stackrel{m=1}{=} \mathbf{X}'\mathbf{X} \quad (2.33)$$

definiert und damit positionsabhängig von einer Referenz $\mathbf{x}_0' = [1, x_{01}, \dots, x_{0k}]$ im Parameterraum ist [35]. Sie ist damit unabhängig von der tatsächlichen Streuung

der Messdaten (σ^2). Weiter wird sie über die Anzahl der Versuchspunkte N skaliert, um zwischen Versuchsplänen mit unterschiedlicher Stichprobengröße hinsichtlich des Gestaltungsbudgets und der geometrischen Effizienz zu vergleichen [33, 35]. Im Sinne der absoluten Schätzpräzision und direkt über die Breite der resultierenden Konfidenzintervalle kann sie im ingenieurwissenschaftlichen Blickwinkel aber auch unskaliert betrachtet werden: als **Unscaled Prediction Variance (UPV)**

$$v(\mathbf{x}_0)/N = \text{Var}[\hat{y}(\mathbf{x}_0)]/\sigma^2 = \mathbf{x}_0' \mathbf{M}^{-1} \mathbf{x}_0, \quad (2.34)$$

vgl. Montgomery [28] und Myers et al. [58]. Die strikte methodische Differenzierung dieser beiden Metriken ist für die Auslegung von Lebensdauertests essenziell: Während die **UPV** die *absolute, physikalische Schätzpräzision* repräsentiert - welche sich nach informationstheoretischen Grundsätzen mit jedem zusätzlichen Versuchspunkt zwingend verbessert oder zumindest stagniert -, fungiert die **SPV** als reines Maß der *geometrischen Design-Effizienz*. Sie bewertet den Informationsgewinn pro investiertem Versuchsaufwand N . Ein geometrisch ineffizient platzierter Versuchspunkt (etwa ein redundanter Zentralpunkt für eine fernen Extrapolation) kann zwar die absolute **UPV** marginal senken, jedoch die **SPV** verschlechtern, da die Aufwandserhöhung (Steigerung von N) den minimalen Informationsgewinn überkompensiert. Somit dient die **SPV** folglich dem topologischen Strukturvergleich und der Budget-Allokation, während die **UPV** die Basis zur Berechnung realer Konfidenzintervalle für die tatsächliche Lebensdauerprognose im Feld bildet. Zusammen mit der Varianz des Versuchsfehlers σ^2 (vgl. Gleichung 2.37) erlaubt die Prädiktionsvarianz somit eine direkte Quantifizierung der **Unsicherheit in der Modellvorhersage** $\text{Var}[\hat{y}(\mathbf{x}_0)]$ an einer beliebigen Stelle $\mathbf{x}_0$ im Versuchsraum. Um sie über verschiedene Stellen im Parameterraum zu bewerten, konnten allen voran Zahran et al. [59] und Giovannitti-Jensen und Myers [60] mit dem **VDG** oder **FDS-Plot** Visualisierungsstrategien entwickeln. Diverse Anwendungen folgten daraufhin und festigten durch Arbeiten von Goldfarb et al. [61] und Ozol-Godfrey et al. [62] deren Relevanz bei der Untersuchung von Designtypen durch beispielsweise Borkowski et al. [63], Myers et al. [64] und Schoonees et al. [65] für verschiedenste Designmodifikationen oder -Störungen. Der **FDS** stellt dabei die kumulative Verteilung der Prädiktionsvarianz über den jeweiligen Anteil des Design-Space' entsprechend Abbildung 2.9a dar, während der **VDG** (neben den Extremwerten) die durchschnittliche, sphärische

Prädiktionsvarianz als Funktion des Abstands r zum Zentrum des Versuchsraums visualisiert - vgl. Abbildung 2.9b. Eine effiziente Versuchsplanung für multivariate




Abbildung 2.9: FDS und VDG für einen CCD mit $k = 2$ Faktoren.

Lebensdaueruntersuchungen muss sich neben pragmatischen Beweggründen maßgeblich an der Prädiktionsvarianz orientieren, weshalb im Folgenden eine Übersicht der darauf basierenden, gängigen Metriken und Qualitätsmerkmale gegeben wird.

Orthogonalität, Ausgewogenheit und Multikollinearität

Der Einsatz optimaler Versuchspläne ist zunächst prädestiniert für Szenarien, in denen klassische Pläne an ihre Grenzen stoßen - sei es durch physikalische Randbedingungen welche bestimmte Faktorstufenkombinationen ausschließen, oder durch strikte Limitierungen der verfügbaren Versuchskapazität [27, 33]. Derart klassische Versuchspläne wie der voll-faktorielle Versuchsplan sind aufgrund ihrer Versuchspunktanordnung stets **orthogonal** [3, 28]. Ein Versuchsplan wird als orthogonal bezeichnet, wenn keine Korrelation zwischen jeweils zwei Spalten der Versuchsplan-Matrix vorliegt - deren Skalarprodukte also jeweils null ergeben:

$$\langle x_i, x_j \rangle = 0 \quad \text{für alle } i \neq j. \quad (2.35)$$

Oder in anderen Worten: entspricht die Informationsmatrix $\mathbf{M}$ einer reinen Diagonalmatrix, ist der Versuchsplan orthogonal [3, 12]. So können Effekte eindeutig

identifiziert werden - die Vektoren der Faktorstufenkombinationen sind linear unabhängig und Effekte lassen sich unverzerrt schätzen. Dies stellt einen Versuchsplan also zunächst einmal qualitativ günstig dar.

Um den Grad der Abweichung von diesem Idealzustand - etwa bei asymmetrisch ausgedünnten Designs oder durch praxisbedingte Modifikationen der Versuchsraumgeometrie - quantitativ bewerten zu können, hat sich in der Literatur der **A_2 -Indikator** als globales Maß für Nicht-Orthogonalität etabliert [66, 67]. Er berechnet sich als Summe der quadrierten Elemente abseits der Hauptdiagonalen der normierten Informationsmatrix **M**:

$$A_2 = \sum_{i=1}^p \sum_{\substack{j=1 \\ j \neq i}}^p r_{ij}^2 \quad \text{mit} \quad r_{ij} = \frac{\mathbf{M}_{ij}}{\sqrt{\mathbf{M}_{ii}\mathbf{M}_{jj}}}, \quad (2.36)$$

wobei r_{ij} den paarweisen Korrelationskoeffizienten zwischen der i -ten und j -ten Spalte der Versuchsplan-Matrix repräsentiert. Folglich gilt für einen streng orthogonalen Plan $A_2 = 0$. Jeder Anstieg dieses Wertes signalisiert zunehmende Multikollinearität im Design, was das Risiko von Fehlschlüssen bei der Identifikation kausaler Haupteffekte und Interaktionen erhöht [29].

Zudem liegt **Ausgewogenheit** vor, sofern für einen jeweiligen Faktor alle anderen Faktoreinstellungen gleichmäßig aufgeteilt sind [32]. Damit wird Varianzhomogenität und Gleichbehandlung der Faktoren gewährleistet, sodass die Schätzung der Effekte unverzerrt erfolgt.

Mathematisch fundiert die Bewertung der Schätzgenauigkeit auf der Inversen der Informationsmatrix, welche als **Varianz-Kovarianz-Matrix** (oder **Dispersionsmatrix**) $(\mathbf{X}'\mathbf{X})^{-1}$ der Regressionskoeffizienten definiert ist:

$$\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}, \quad (2.37)$$

wobei wie gehabt σ^2 die Varianz des Versuchsfehlers darstellt.

Ein universelles Maß zur Beurteilung der Schätzgüte einzelner Parameter ist der **MSE**. Er vereint die Varianz des Schätzers und dessen systematische Verzerrung (**Bias**) generell über alle Beobachtungen durch $1/n \sum_i^n (y_i - \hat{y}_i)^2$ in einer Metrik

und beschreibt für einen geschätzten Parameter $\hat{\beta}_j$ die erwartete quadratische Abweichung von dessen wahren Wert β_j :

$$\text{MSE}(\hat{\beta}_j) = E \left[(\hat{\beta}_j - \beta_j)^2 \right] = \text{Var}(\hat{\beta}_j) + \left(\text{Bias}(\hat{\beta}_j) \right)^2. \quad (2.38)$$

Da klassische Schätzverfahren (wie OLS oder MLE) unter regulären Bedingungen erwartungstreu sind (Bias = 0), entspricht der MSE in diesen Fällen exakt der Schätzvarianz $\text{Var}(\hat{\beta}_j)$ und skaliert folglich direkt mit den Diagonalelementen der inversen Informationsmatrix [9].

Während der A_2 -Indikator die Gesamtmatrix bewertet, stehen genau diese Diagonalelemente in direktem Zusammenhang mit dem VIF für die Evaluation einzelner Modellterme [27, 32]. Der VIF dient als Maßzahl für Multikollinearität und quantifiziert den Faktor, um den sich die Varianz (und damit der MSE) eines geschätzten Koeffizienten im Vergleich zu einem vollständig orthogonalen Design aufgrund von Korrelationen zwischen den Faktoren erhöht (vergleiche auch **Konditionszahl**) [9]. Während bei orthogonalen Plänen (Idealfall) ein $\text{VIF} = 1$ vorliegt, deuten hohe Werte (typischerweise > 5 oder > 10) auf eine instabile Modellschätzung hin [12, 27].

Zur lokalen Diagnose von Versuchspunkten und deren Auswirkung auf die Regressionsparameter existieren in der Fachliteratur etablierte Maßzahlen wie die Hebelwerte h_{ii} der Prädiktionsmatrix (engl. auch **Hat-Matrix**) $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, die Cook-Distanz (D_i) sowie detaillierte Einflusststatistiken wie DFBETAS, DFFITS und COVRATIO - vergleiche Werke von Montgomery et al. [12], Siebertz et al. [32], Belsley [68] und Fahrmeir et al. [69]. Da es sich hierbei jedoch um rein retrospektive Diagnostikwerkzeuge handelt, die bereits vorliegende Versuchsergebnisse zwingend voraussetzen, finden sie im Rahmen der a priori Testplanung dieser Arbeit keine weitere Anwendung.

Optimalitätskriterien

Da in restriktiven Versuchsräumen Orthogonalität oft nicht erreichbar ist, zielen optimale Versuchspläne darauf ab, durch Minimierung spezifischer Eigenschaften der Dispersionsmatrix $(\mathbf{X}'\mathbf{X})^{-1}$ den Informationsgehalt trotz Korrelationen zu maximieren. Die Generierung solcher maßgeschneiderten Pläne erfolgt algorithmisch unter

Maximierung spezifischer statistischer Gütekriterien. Eine Übersicht der einschlägigen **Optimalitätskriterien** - oder einfach **Optimalitäten** - welche den quantitativen Vergleich zur Standard-Methodik ermöglichen, ist in Tabelle 2.4 zusammengefasst [28, 33]. Sie bilden mitunter die Grundlage für diverse weitere Optimalitäten und hybride Ansätze und lassen sich prinzipiell in Modellierungskriterien (*A*-, *D*-Optimalität) und Prädiktionskriterien (*G*-, *I*-, *U*-, *V*- **Optimalität**) unterteilen [3, 35]. Während konventionelle Ansätze stets die Optimierung eines einzelnen Kriteriums anstreben, können in der Praxis auch mehrere Kriterien gleichzeitig berücksichtigt werden, um eine ausgewogene Optimierung zu erreichen [33, 70].

Jenseits praktischer Kriterien sind hier der Vollständigkeit halber auch eine Teilmenge eher theoretischerer Optimalitäten zu nennen. Die **E-Optimalität**, führt zur Minimierung des maximalen Eigenwerts der Dispersionsmatrix, was eine Worst-Case-Absicherung zur Varianzschätzung begünstigt - vergleiche Russell [54] und Boyd und Vandenberghe [71]. Für explorative Zielsetzungen ohne starre Modellannahmen kann nach Atkinson [72] die **S-Optimalität** relevant sein, da hier durch die Maximierung der euklidischen Abstände benachbarter Punkte eine gleichmäßige Raumfüllung (*Space-Filling*) sichergestellt werden kann. So können für sich ändernde Modelle entlang einzelner Parameter wie beispielsweise $\hat{T} \in \hat{\theta}$ Sensitivitätsanalysen effizient durchgeführt werden. Eine Verallgemeinerung der prädiktionsorientierten Kriterien stellt die **Q-Optimalität** dar, welche analog zur *I*-Optimalität die integrierte Prädiktionsvarianz minimiert, jedoch mittels Gewichtsfunktionen eine differenzierte Priorisierung spezifischer Regionen im Versuchsraum erlaubt, vgl. Goos und Jones [33]. Liegt der Fokus hingegen isoliert auf einer Teilmenge der Modellparameter - etwa zur Trennung von Haupteffekten und Blockeffekten oder von Termen erster und zweiter Ordnung - ermöglicht die **D_S-Optimalität** als Derivat der *D*-Optimalität eine gezielte Maximierung der Schätzgüte für genau dieses jeweilige Subset der Parametergruppe - siehe auch Werke von Goos und Jones [33], Myers et al. [35] und Atkinson et al. [73].

Tabelle 2.4: Übersicht, Zielsetzung und mathematische Definition verschiedener Optimalitätskriterien für Versuchspläne

Kriterium	Zielgröße, Beschreibung und Definition
A-Optimalität	Minimierung der Spur der inversen Informationsmatrix [3, 27, 28]. <i>Ziel: Maximale Präzision der einzelnen Parameter im Durchschnitt.</i> $A_{\text{opt}} = \min \left(\text{spur} \left(\mathbf{M}^{-1} \right) \right) = \min \left(\sum_{j=1}^k \text{Var} \left(\hat{\beta}_j \right) \right) \quad (2.39)$
D-Optimalität	Maximierung der Determinante der Informationsmatrix $\mathbf{M}$. Da das Volumen des Vertrauensellipsoids der Koeffizientenschätzwerte umgekehrt proportional zur Quadratwurzel der Determinante ($\sqrt{\det(\mathbf{M})}$) ist, minimiert dieses Kriterium das Unsicherheitsvolumen im Parameterraum [27, 28, 35, 73]. <i>Ziel: Minimierung des Volumens des gemeinsamen Vertrauensbereichs aller Modellparameter.</i> $D_{\text{opt}} = \max \left(\det(\mathbf{M}) \right) = \min \left(\det \left(\mathbf{M}^{-1} \right) \right) \quad (2.40)$
G-Optimalität	Minimierung der maximalen skalierten Prädiktionsvarianz $v(\mathbf{x}_0)$ im relevanten Parameterraum [28, 35, 54]. <i>Ziel: Qualität der Vorhersage an der ungünstigsten Stelle sichern.</i> $G_{\text{opt}} = \min \left(\max_{\mathbf{x}_0 \in \mathbb{R}^k} v(\mathbf{x}_0) \right) \quad (2.41)$

Fortsetzung auf der nächsten Seite...

Tabelle 2.4 (Fortsetzung): Übersicht der Optimalitätskriterien

Kriterium	Zielgröße, Beschreibung und Definition
I-Optimalität	Minimierung der durchschnittlichen (<i>integrierten</i>) Prädiktionsvarianz über den Parameterraum - auch als U-Optimalität im ingenieurwissenschaftlich-statistischen Sinn bekannt: Optimierung bzgl. einer <i>uniformen</i> Prädiktionsvarianz [3, 73, 74]. <i>Ziel: Optimale Vorhersagegüte (SPV) im Mittel über den gesamten Raum - z.B. bei initialer Parametrisierung eines multivariaten Lebensdauermodells.</i> $I_{\text{opt}} = \min \left(\frac{N}{\int_{\mathbb{R}^k} dx} \int_{\mathbb{R}^k} v(\mathbf{x}_0) dx \right) \quad (2.42)$
V-Optimalität	Minimierung der durchschnittlichen Prädiktionsvarianz über ein diskretes Set von N Punkten [28, 33, 58]. <i>Ziel: Optimale Vorhersagegüte (SPV) an spezifischen i Stellen - z.B. bei L-DoE-Versuchspunkten oder spezifischen Nennlasten.</i> $V_{\text{opt}} = \min \left(\frac{1}{N} \sum_{i=1}^N v(x_i) \right) \quad (2.43)$

Zur vergleichbaren Bewertung unterschiedlicher Designs unabhängig von der Skalierung werden normierte **Effizienzen** herangezogen [28]. Aus Tabelle 2.4 lassen sich die **A-Effizienz** A_{eff} , **D-Effizienz** D_{eff} , **G-Effizienz** G_{eff} , **I-Effizienz** I_{eff} und **V-Effizienz** V_{eff} ableiten, welche jeweils die Güte $[0, 1]$ eines Versuchsplans quantifizieren - vergleiche Tabelle 2.5.

Tabelle 2.5: Übersicht, Zielsetzung und mathematische Definition verschiedener Effizienzkriterien für Versuchspläne

Kriterium	Zielgröße, Beschreibung und Definition
A-Effizienz	Maß für die durchschnittliche Präzision der Regressionskoeffizienten. [33, 35]. $A_{\text{eff}} = 100 \cdot \frac{p}{\text{spur}(\mathbf{N} \cdot \mathbf{M}^{-1})} \quad (2.44)$
D-Effizienz	Maß für den Informationsgehalt der Informationsmatrix $\mathbf{M}$, definiert über die Determinante, umgekehrt proportional zum Volumen des Vertrauensellipsoids der Parameterschätzwerte und durch die Potenzierung mit $1/p$ pro Schätzparameter normiert. [33, 35]. $D_{\text{eff}} = 100 \cdot \frac{\det(\mathbf{M})^{1/p}}{N} \quad (2.45)$
G-Effizienz	Maß für die Vorhersagegüte im ungünstigsten Fall innerhalb des Versuchsraums. Da für die maximale SPV die theoretische Untergrenze $v(\mathbf{x}_0)_{\max} \geq p$ gilt, beschreibt dieses Kriterium das Verhältnis zwischen idealer und realisierter maximaler Varianz [35]. $G_{\text{eff}} = 100 \cdot \frac{p}{v(\mathbf{x}_0)_{\max}} \quad (2.46)$
I-Effizienz	Maß für die durchschnittliche Vorhersagegüte über den gesamten Versuchsraum [35]. $I_{\text{eff}} = 100 \cdot \frac{p}{\frac{1}{\int_R d\mathbf{x}} \int_R v(\mathbf{x}_0) d\mathbf{x}} \quad (2.47)$

Fortsetzung auf der nächsten Seite...

Tabelle 2.5 (Fortsetzung): Übersicht der Effizienzkriterien

Kriterium	Zielgröße, Beschreibung und Definition
V-Effizienz	Maß für die durchschnittliche Vorhersagegüte über ein diskretes Set von N Punkten analog zu Gleichung 2.47 [35].
$V_{\text{eff}} = 100 \cdot \frac{1}{N} \sum_{i=1}^N \frac{p}{v(\mathbf{x}_0)(x_i)} \quad (2.48)$	

Forschungsschwerpunkte in der RSM

Während die klassische sequentielle Strategie (Screening gefolgt von Augmentierung zum CCD oder Anpassung von Parameterräumen mit optimalen Versuchsplänen) die methodischen Risiken minimiert, erfordert sie oft einen hohen administrativen und zeitlichen Aufwand durch mehrere Versuchsphasen - insbesondere bei technischen Versuchsanlagen mit hohem Rüst-Aufwand. Als Antwort darauf entwickelten Jones und Nachtsheim [48] zunächst die Klasse der **Definitive Screening Designs (DSDs)**, um auch bei größeren Faktorenzahlen (typisch $k \geq 4$) Haupteffekte von nicht-linearen Effekten in einem Schritt zu trennen. Da DSDs jedoch eine starre Struktur aufweisen und oft nur eine geringe statistische Power zur Schätzung quadratischer Effekte bieten, etablierte sich in jüngster Forschung die umfassendere Klasse der **Orthogonal Minimally Aliased Response Surface (OMARS)-Designs** (*Orthogonal Minimally Aliased Response Surface Designs*), zu der Goos [75] zuletzt eine detaillierte Übersichtsarbeit vorlegten. Núñez Ares und Goos [76] erarbeiteten hierfür einen Katalog verschiedener OMARS-Designs, die im Gegensatz zu klassischen Plänen eine flexible Wahl der Versuchsanzahl n ermöglichen. Diese Designs zielen spezifisch auf den fließenden Übergang von Screening zu RSD in einem einzigen experimentellen Schritt ab (*One-Step Approach*). Dazu basieren sie auf der Variation aller quantitativen Faktoren auf drei Stufen $(-1, 0, +1)$, um quadratische Zusammenhänge prinzipiell abzubilden. Die statistische Konstruktion garantiert dabei zwei fundamentale Orthogonalitätseigenschaften, die sie von klassischen Optimal-Designs abgrenzen: Erstens sind alle Haupteffekte orthogonal zueinander, was eine

unabhängige Schätzung der linearen Einflüsse sichert. Zweitens sind die Haupteffekte vollständig unkorreliert mit sämtlichen Effekten zweiter Ordnung (sowohl Zweifach-Wechselwirkungen als auch quadratische Terme). Das verbleibende Aliasing (Vermengung) beschränkt sich somit ausschließlich auf die Gruppe der Effekte zweiter Ordnung untereinander und wird algorithmisch minimiert (engl. *Minimally Aliased*). Dies erlaubt eine signifikante Flexibilisierung der Stichprobengröße im Vergleich zu starr definierten Plänen wie dem CCD, bei gleichzeitigem Erhalt der robusten Schätzbarkeit der primären Haupteffekte. Die Generierung eines solchen OMARS-Designs erfolgt dabei nicht über geometrische Konstruktionsvorschriften (wie beim CCD), sondern algorithmisch durch die Lösung eines ganzzahligen linearen Optimierungsproblems (engl. **Integer Linear Programming (ILP)**). Basierend auf der Kandidatenmenge Ω (üblicherweise entsprechend einem voll-faktoriellen 3^{k_f} Plan) wird ein Vektor binärer Entscheidungsvariablen $\gamma \in \{0, 1\}^{|\Omega|}$ gesucht, der folgende mathematische Restriktionen simultan erfüllt:

- **Einhaltung des Stichprobenumfangs:** Die Summe der ausgewählten Versuchspunkte muss exakt der gewünschten Anzahl n entsprechen:

$$\sum_{i=1}^{|\Omega|} \gamma_i = n. \quad (2.49)$$

- **Orthogonalität der Haupteffekte:** Jedes Paar von Haupteffekt-Spalten j und l muss unkorreliert sein. Für die kodierten Faktorstufen $x_{ij} \in \{-1, 0, +1\}$ des i -ten Kandidaten gilt:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot x_{il} = 0 \quad \forall 1 \leq j < l \leq k_f. \quad (2.50)$$

- **OMARS-Eigenschaft (Orthogonalität Haupteffekt zu Effekten zweiter Ordnung):** Dies ist das definierende Merkmal. Jeder Haupteffekt j muss orthogonal zu jedem Effekt zweiter Ordnung (Interaktion $x_l x_k$ oder quadratischer Term x_l^2) sein:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot (x_{il} \cdot x_{ik}) = 0 \quad \forall j, l, k \in \{1, \dots, k_f\}. \quad (2.51)$$

Unter Einhaltung dieser harten Nebenbedingungen wird anschließend jene Design-Variante ausgewählt, welche die Aliasing-Struktur der Effekte zweiter Ordnung untereinander minimiert (z. B. durch Maximierung von D_{opt} , vgl. Gleichung 2.40).

Signifikanz und Trennschärfe

Zuletzt muss sichergestellt werden, dass der Versuchsplan über eine ausreichende **Trennschärfe** (engl. *power*) verfügt. Die Trennschärfe beschreibt als Metrik diejenige Wahrscheinlichkeit, mit der ein existierender Einfluss durch Faktoren vor dem Hintergrund des experimentellen Rauschens (vergleiche *t*-Statistik, **SNR**, **Signifikanztests** nach Kleppmann [27], Montgomery [28] und Goos und Jones [33]) korrekt als **signifikanter** Effekt E identifiziert wird [27, 32]. Insofern ist ein Effekt in praktischem Umfeld natürlich problemabhängig (Streuungscharakteristik der Lebensdauer, realisierbare Stichprobengröße, etc.) und meist von Bedeutung für $E \geq 2\sigma$, wobei Trennschärfewerte $\geq 80\%$ als befriedigend gelten [3, 28]. Insbesondere bei reduzierten Versuchsplänen und unter dem Einfluss stochastischer Lebensdauerstreuung ist die Power-Analyse jedoch essenziell, um das Risiko von falsch-negativen Schlussfolgerungen zu minimieren. Letztendlich kann die Trennschärfe somit als Garantimetrik verstanden werden, die sicherstellt, dass ein geplanter Versuchsaufbau in der Lage ist, Effekte von praktischer Relevanz zu detektieren [35, 77] - was vornehmlich in Bezug auf Lebensdauertests aufgrund genannter wirtschaftlicher Randbedingungen von hoher Bedeutung ist.

Formalisiert wird dies im Rahmen **statistischer Hypothesentests** [27, 28]. Die Zielsetzung besteht darin, den Nachweis zu erbringen, ob ein bestimmter Faktor x_j einen signifikanten Einfluss auf die Systemantwort y ausübt. Dazu werden zwei konkurrierende Hypothesen formuliert: Die **Nullhypothese** H_0 unterstellt, dass kein Zusammenhang besteht, der korrespondierende Regressionskoeffizient β_j (vgl. Abschnitt 2.2.6) also den Wert Null annimmt:

$$H_0 : \beta_j = 0 \quad \text{gegen} \quad H_1 : \beta_j \neq 0. \quad (2.52)$$

Die **Alternativhypothese** H_1 postuliert hingegen einen signifikanten Effekt ($\beta_j \neq 0$). Die Entscheidung über die Annahme oder Ablehnung von H_0 basiert auf dem *p*-Wert. Dieser quantifiziert die Wahrscheinlichkeit, unter der Annahme der Gültigkeit von H_0 die beobachteten Daten (oder extremere Ergebnisse) zu erhalten.

Unterschreitet der p -Wert das a priori definierte **Signifikanzniveau** α (üblicherweise $\alpha = 0,05$), wird H_0 zugunsten der Alternativhypothese H_1 verworfen. Der Fehler, H_0 fälschlicherweise abzulehnen, obwohl kein Effekt vorliegt, wird als Fehler 1. Art bezeichnet; seine Wahrscheinlichkeit ist durch α begrenzt. Die **Trennschärfe** fokussiert hingegen auf den Fehler 2. Art (oft mit β_{error} notiert), welcher das Risiko beschreibt, einen tatsächlich vorhandenen Effekt nicht zu erkennen (falsch-negative Entscheidung). Die Power folglich ist definiert als das Komplement dieses Fehlers ($1 - \beta_{\text{error}}$) und entspricht somit der Wahrscheinlichkeit, H_0 korrekterweise abzulehnen, wenn H_1 wahr ist:

$$\text{power} = \Pr(H_0 \text{ ablehnen} \mid H_1 \text{ ist wahr}) = 1 - \beta_{\text{error}}. \quad (2.53)$$

In idealisierten, orthogonalen Standard-Versuchsplänen unter der Annahme normalverteilter Residuen $\epsilon \sim \mathcal{N}(0, \sigma^2)$ lässt sich die Trennschärfe für klassische OLS-Regressionsmodelle exakt analytisch bestimmen. Die power für den Signifikanztest eines einzelnen Regressionskoeffizienten β_j berechnet sich aus der Wahrscheinlichkeit, dass die Teststatistik den kritischen Wert der zentralen Prüfverteilung überschreitet. Unter der Gültigkeit der Alternativhypothese H_1 folgt die Teststatistik jedoch einer verschobenen, *nicht-zentralen* Verteilung (z.B. der nicht-zentralen t -Verteilung). Der Grad dieser Verschiebung wird durch den sogenannten **Nichtzentralitätsparameter** δ_{nc} quantifiziert [28, 78]. Für die Überprüfung eines individuellen Modellparameters ist dieser definiert als:

$$\delta_{\text{nc}} = \frac{|\beta_j|}{\sigma \sqrt{(\mathbf{X}'\mathbf{X})_{jj}^{-1}}} \quad (2.54)$$

wobei $|\beta_j|$ die zu detektierende wahre Effektstärke, σ die Standardabweichung des experimentellen Rauschens und $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ das j -te Diagonalelement der inversen Informationsmatrix $\mathbf{M}^{-1}$ (vgl. Abschnitt 2.2.5) darstellt [35, 77]. Anhand von Gleichung 2.54 wird der mathematische Zusammenhang der Effektivität deutlich: Die Trennschärfe, welche monoton mit δ_{nc} wächst, steigt bei größeren Effekten und sinkt bei stärkerem Rauschen.

Die entscheidende Rolle des Versuchsplans manifestiert sich im Term $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$. In einem vollständig orthogonalen Versuchsplan ist die Informationsmatrix $\mathbf{M} = \mathbf{X}'\mathbf{X}$

eine reine Diagonalmatrix. Die Schätzer der Koeffizienten sind somit linear unabhängig und das Diagonalelement der Inversen minimiert sich. Sobald jedoch geometrische Verzerrungen auftreten und die Orthogonalität verloren geht, entstehen signifikante Kovarianzen (Werte abseits der Hauptdiagonalen in **M**). Bei der Invertierung der Matrix führt dies zu einer Inflation der Varianzen, wodurch der Wert $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ anwächst. Dies vergrößert den Nenner in Gleichung 2.54, reduziert den Nichtzentralitätsparameter δ_{nc} und mindert somit unmittelbar die analytische Trennschärfe.

Solche analytischen Berechnungen, die auf der exakten Bestimmung von δ_{nc} beruhen, verkomplizieren sich erheblich, sobald asymmetrische Design-Modifikationen und Mehrfach-Korrelationen greifen. Im Kontext der Lebensdauerdatenanalyse, bei der zudem nicht-normalverteilte und zensierte Daten vorliegen, lassen sich diese Wahrscheinlichkeiten folglich ohnehin nicht mehr über klassische **t-Tests** ableiten. Aus der Arbeit von Nelder und Wedderburn [79] kommen hier **Verallgemeinerte Lineare Modelle**, engl. **GLMs** zum Einsatz, bei denen die Signifikanz der Koeffizienten β_j vorzugsweise über den **Likelihood-Ratio Test (LR-Test)** (oder approximativ über **Wald-Tests** - vergleiche hierzu Arbeiten von Meeker et al. [2], Rigdon et al. [3], Montgomery [28] und McCulloch und Searle [80]) ermittelt wird. Da für diese komplexen Verteilungsmodelle - insbesondere unter dem Einfluss von Orthogonalitätsabweichungen und bei kleinen Stichprobenumfängen n - keine geschlossenen analytischen Lösungen zur Berechnung der Trennschärfe existieren, erfolgt die Untersuchung in der modernen Praxis numerisch mittels **MCS** [39, 81, 82]. Hierbei wird der geplante Versuchsplan virtuell vielfach durchlaufen (z.B. $n_{MC} = 10^4$ Simulationsläufe). Für jeden Lauf werden basierend auf einem angenommenen Modell Ausfallzeiten generiert, verrauscht bzw. mit Streuung überlagert und/oder zensiert. Anschließend erfolgt die Modellbildung und Hypothesenprüfung. Der Anteil der Simulationsläufe, in denen der definierte Effekt korrekt als signifikant ($p\text{-Wert} < \alpha$) erkannt wird, entspricht der geschätzten *power* des Designs.

2.2.6 Statistische Modellbildung

Die statistische Modellbildung transformiert die durch den Versuchsplan generierte Datenbasis in einen funktionalen, empirisch basierten Zusammenhang zwischen den Einflussfaktoren x_i und der Lebensdauerantwort. Aufgrund der in Abschnitt 2.1 dargelegten Eigenschaften von Lebensdauerdaten (Nicht-Normalverteilung, Zen-

sierung) sind klassische Regressionsverfahren (OLS) hier nicht zulässig. Stattdessen kommt i.d.R. das Framework der GLM zur Anwendung, welches die lineare Prädiktion mit der zugrundeliegenden Verteilung verknüpft [2, 3, 6]. Hinsichtlich der Modellauswahl können in klassischen Ansätzen der Versuchsplanung dabei oft auf Potenztransformationen der Antwortvariablen in Form $y^{(\lambda_{BC})}$ oder $\ln(y)$ (für $\lambda_{BC} = 0$ mit geometrischem Mittelwert der Beobachtung $\hat{y} = \exp\left[\frac{1}{n} \sum_{i=1}^n \ln(y_i)\right]$) zurückgegriffen werden - wie die **Box-Cox-Transformation** nach Montgomery et al. [12] und Box und Cox [83]. So wird Varianzhomogenität und Normalverteilung approximiert zu:

$$y_i^{(\lambda_{BC})} = \begin{cases} \frac{y_i^{\lambda_{BC}} - 1}{\lambda_{BC} \hat{y}^{\lambda_{BC} - 1}}, & \text{für } \lambda_{BC} \neq 0, \\ \hat{y} \ln(y_i), & \text{für } \lambda_{BC} = 0. \end{cases} \quad (2.55)$$

Im Kontext der expliziten Lebensdaueranalyse ist dieser generische Ansatz jedoch weniger gebräuchlich, da die physikalisch motivierte Verteilungsannahme (z.B. Weibull) bereits eine inhärente Transformation der Lebensdauerzeit impliziert - vgl. Abschnitt 2.1.3, Gleichung 2.8 sowie Yang [6] und Wu und Hamada [29]. Wird also für die Lebensdauerverteilung die Weibull-Verteilung (Abschnitt 2.1.3) angenommen, so ergibt sich für $j = 0, \dots, k$ betrachtete Parameter aus beispielsweise Gleichung 2.27 und n Beobachtungen analog zu Gleichung 2.8 der Erwartungswert der charakteristischen Lebensdauer als **Link-Funktion** der Einflussfaktoren x_j und des unbekannten Koeffizientenvektors $\hat{\beta}$ [6, 29, 84] zum AFT-Modell:

$$E_{\theta_x}(\ln(T)) = y = \beta_0 + \sum_{j=1}^k \beta_j x_j + \dots + \epsilon. \quad (2.56)$$

In der Lebensdauer-Datenanalyse werden insbesondere zwei weitere Modellierungsansätze verwendet: neben den GLM-Ansätzen insbesondere der **Proportional Hazard (PH)-Modell**-Ansatz. Jedoch werden PH-Modelle vornehmlich in der Biostatistik verwendet und spielen hier ihre Stärke bei der Abbildung zeitabhängiger Kovariate aus [85, 86]:

$$f(t, \mathbf{X}) = \lambda(t)(t, \mathbf{X}) \cdot R(t, \mathbf{X}) = b \cdot t^{b-1} \cdot e^{[y - t^b e^y]}. \quad (2.57)$$

Weibull-GLM

Im ingenieurwissenschaftlichen Kontext - maßgeblich gestützt durch Ausführungen in Meeker et al. [2], Yang [6], Wu und Hamada [29], Myers et al. [58], Kremer et al. [86], Dobson und Barnett [87] und Stufken und Yang [88] - finden hingegen **Log-Location-Scale-Modelle**, also **GLMs**, überwiegend Anwendung. Obwohl für die Weibull-Verteilung eine mathematische Äquivalenz zwischen beiden Ansätzen besteht, sprechen drei fundamentale Gründe für deren Verwendung. **Physikalischer Bezug:** Gängige physikalische Beschleunigungsmodelle (Arrhenius, Inverses Potenzgesetz) beschreiben die Änderung der *Zeit* bis zum Ausfall ($\ln(\hat{T})$) und nicht der Ausfallrate. Die Log-Linearisierung dieser Gesetze führt direkt auf die Regressionsgleichung der Location-Scale-Modelle. **Universalität der Auswertung:** Das Modell bietet einen einheitlichen mathematischen Rahmen, der nicht nur für die Weibull-Verteilung, sondern identisch auch für die Lognormal-Verteilung und Normalverteilung gültig ist. Das **PH-Modell** hingegen ist für Lognormal-Verteilungen mathematisch nicht geschlossen anwendbar. **Fokus auf Lebensdauer-Quantile:** Im Engineering und **DfR** liegt das Interesse primär auf der Prädiktion von Ausfallzeiten für geringe Ausfallanteile (z.,B. t_{10}). Diese Größen sind direkte Ergebnisse der Location-Scale-Gleichung, während sie im **PH-Modell** nur indirekt über die Invertierung der Hazard-Funktion zugänglich sind. Folglich wird eine zufallsverteilte Lebensdauer τ für ein Weibull-GLM mit der Dichtefunktion

$$f(t, \mathbf{X}) = b \cdot t^{b-1} e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_j)} \cdot e^{-t^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_j)}}, \quad t > 0. \quad (2.58)$$

beschrieben und analog zu Gleichungen 2.14 - 2.17 in die **Generalized Log-Linear (GLL)-Funktion** überführt [6, 54, 89]:

$$\begin{aligned} \Lambda &= \ln(\mathcal{L}(t_i; b, \beta_0, \dots, \beta_k)) \\ &\propto \sum_{i=1}^n \left[\ln(b) - b \left(\beta_0 + \sum_{j=1}^k \beta_j x_{ij} \right) + (b-1) \ln(t_i) - t_i^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})} \right]. \end{aligned} \quad (2.59)$$

Werden außerdem (rechts-) zensierte Daten berücksichtigt, so ergibt sich analog zu Gleichung 2.17 über Gleichung 2.59 die erweiterte GLL-Funktion [2, 6]:

$$\Lambda_z \propto \Lambda - (1 - \delta_i) \cdot t_i^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})}. \quad (2.60)$$

Sollen über die rein empirische Datenauswertung hinaus bekannte physikalische Gesetzmäßigkeiten im Modell berücksichtigt werden, ist die lineare Struktur des Prädiktors entsprechend anzupassen. Dies erfolgt durch eine Transformation der physikalischen Beanspruchungsgrößen x in den Modellraum. Anstelle der direkten Verwendung des Einflussfaktors in der GLL-Beziehung (Gleichung 2.58) wird eine transformierte Größe x_V eingesetzt, welche die physikalische Natur des Schädigungsmechanismus abbildet. Gängige Transformationen umfassen hierbei die reziproke Anpassung für thermische Lasten oder logarithmische Ansätze für elektrische Potenzmodelle, vgl. Tabelle 2.6. Eine Übersicht verschiedener Modellierungsansätze

Tabelle 2.6: Übersicht gängiger Transformationen der Belastungsgrößen zur Abbildung physikalischer Lebensdauermodelle

Art	Transformation	Lebensdauermodell	Anwendungsfall
Keine	$x_V = x$	Exponential / Wöhler	mechanisch
Reziprok	$x_V = 1/x$	Arrhenius	thermisch
Logarithmisch	$x_V = e^x$	Potenzmodell	elektrisch

(z.B. **Arrhenius-Modell**, **Inverses Potenzgesetz**, **Eyring**, **Coffin-Manson-Modell**, etc.) und deren Einbindung in die GLM-Struktur findet sich in den Arbeiten von Meeker et al. [2], Rigdon et al. [3] und Modarres et al. [85]. Die Schätzung der unbekannten Parameter $\hat{\beta}$ und $\hat{b}$ erfolgt anschließend mittels MLE durch Maximierung der Log-Likelihood-Funktion (Gleichung 2.60) mittels beispielsweise **Newton-Raphson-Verfahren** bzw. **Pattern-Search-Algorithmen** oder **Gradientenverfahren**, [6, 16]. Geeignete numerische Optimierungsverfahren wurden in Abschnitt 2.1.4 erwähnt und unter anderem durch Vorarbeiten von Kremer und Bertsche [17] evaluiert.

Signifikanzanalyse

Liegen die Parameterschätzungen $\hat{\theta}_i$ vor, erfolgt die Bewertung ihrer statistischen Relevanz mittels **LR-Test**. Dieses Verfahren stellt das methodische Äquivalent zur **ANOVA** bei normalverteilten Daten dar und prüft, ob die Aufnahme eines Parameters die Modellanpassung signifikant verbessert. Der Test basiert auf dem Vergleich der maximalen Likelihoods des vollständigen Modells $\mathcal{L}(\hat{\theta}_i)$ gegenüber einem reduzierten Modell $\mathcal{L}(\hat{\theta}_{-i})$, aus dem der zu untersuchende Parameter eliminiert wurde [21, 39]. Die Teststatistik **LR** quantifiziert den Informationsverlust durch die Modellreduktion und ist definiert als **Devianz-Funktion** [2, 90]:

$$LR = -2 \ln \left(\frac{\mathcal{L}(\hat{\theta}_{-i})}{\mathcal{L}(\hat{\theta}_i)} \right) = 2 \cdot [\ln(\mathcal{L}(\hat{\theta}_i)) - \ln(\mathcal{L}(\hat{\theta}_{-i}))]. \quad (2.61)$$

Unter der Nullhypothese H_0 , dass der ausgeschlossene Parameter keinen Einfluss hat, folgt **LR** asymptotisch einer χ^2 -Verteilung mit d_f Freiheitsgraden (Anzahl der ausgeschlossenen Parameter, hier meist $d_f = 1$). Die Signifikanzentscheidung erfolgt über den **p-Wert**, der die Wahrscheinlichkeit angibt, einen Testwert $\geq LR$ zu beobachten:

$$p\text{-Wert} = \Pr(\chi^2(d_f) \geq LR). \quad (2.62)$$

Ist dieser **p-Wert** kleiner als das definierte Signifikanzniveau $p\text{-Wert} < \alpha$, wird der Parameter als signifikant in das Modell aufgenommen.

Erwartungswerte und Konfidenzintervalle

Nach der Ermittlung der optimalen Modellparameter $\hat{\theta}$ ist die Quantifizierung der mit diesen Schätzungen verbundenen Unsicherheit essenziell. Analytisch erfolgt dies über die Betrachtung der Krümmung der Log-Likelihood-Funktion Λ im Maximum. Je stärker die Krümmung, desto präziser ist die Schätzung (geringere Varianz). Mathematisch erfolgt dies durch die drei Schritte: Wahl der statistischen Zielgröße (**R,F**), Berechnung des Standard-Fehlers (via **F** analog zu Gleichung 2.18) und Vertrauensbereich-Schätzung / Wald-Statistik (Gleichung 2.20 bzw. 2.21). So wird dies analog zu Gleichungen 2.18-2.19 durch die Hesse-Matrix **H_f** beschrieben, welche die zweiten partiellen Ableitungen der Log-Likelihood-Funktion nach den

Parametern θ_i (also β_j und b) enthält. Der negative Erwartungswert dieser Matrix führt damit zur Erwartung der Fisher-Informationsmatrix $\mathbf{F}$ [24, 91]:

$$\mathbf{F}_{\text{ob}} := -\mathbf{H}_f(\hat{\boldsymbol{\theta}}) = \begin{bmatrix} -\frac{\partial^2 \mathcal{L}}{\partial \theta_1^2} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_k} \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2^2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_k} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k^2} \end{bmatrix}. \quad (2.63)$$

Im Gegensatz zu klassischen linearen Modellen mit normalverteiltem Fehler hängt die Informationsmatrix im GLM-Framework somit nicht ausschließlich von der geometrischen Versuchsmatrix $\mathbf{X}$ ab, sondern ist eine explizite Funktion des zu schätzenden Parametervektors $\boldsymbol{\theta}$. Die asymptotische Varianz-Kovarianz-Matrix $\hat{\mathbf{V}}$ der Parameterschätzer wird anschließend durch die Inversion der Fisher-Informationsmatrix für $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}$ approximiert [6, 91]:

$$\hat{\mathbf{V}} \approx \mathbf{F}_{\text{ob}}^{-1} = \begin{bmatrix} \hat{\text{Var}}(\hat{\theta}_1) & \hat{\text{Cov}}(\hat{\theta}_1, \hat{\theta}_2) & \cdots & \hat{\text{Cov}}(\hat{\theta}_1, \hat{\theta}_k) \\ \hat{\text{Cov}}(\hat{\theta}_2, \hat{\theta}_1) & \hat{\text{Var}}(\hat{\theta}_2) & \cdots & \hat{\text{Cov}}(\hat{\theta}_2, \hat{\theta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\text{Cov}}(\hat{\theta}_k, \hat{\theta}_1) & \hat{\text{Cov}}(\hat{\theta}_k, \hat{\theta}_2) & \cdots & \hat{\text{Var}}(\hat{\theta}_k) \end{bmatrix}. \quad (2.64)$$

Die Hauptdiagonalelemente dieser Matrix liefern die geschätzten Varianzen $\hat{\text{Var}}(\hat{\theta}_j)$ der einzelnen Modellparameter. Unter der Annahme der asymptotischen Normalverteilung der MLE beschreibt Yang [6] neben weiteren Alternativen aus Meeker et al. [2] und Kremer und Bertsche [21] die symmetrischen $(1 - \alpha)$ -Konfidenzintervalle (Wald-Intervalle) wie nachfolgend - vgl. Gleichung 2.21:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\text{Var}}(\hat{\theta}_j)} \quad \text{bzw.} \cdots = \hat{\theta}_j \exp \left(\pm z_{1-\alpha/2} \cdot \frac{\sqrt{\hat{\mathbf{V}}_{jj}}}{\hat{\theta}_j} \right). \quad (2.65)$$

Vertrauensbereiche für Funktionswerte und Weibull-GLM

Oft ist nicht nur die Unsicherheit der Modellparameter selbst, sondern die der daraus abgeleiteten Funktionen - wie der Zuverlässigkeit $R(t)$ oder der Ausfallwahrscheinlichkeit $F(t)$ - von Interesse. Zur analytischen Ermittlung dieser sogenannten

Fisher-Vertrauensbereiche führt Yang [6] zunächst eine Hilfsgröße w ein - vergleiche auch z_e nach Meeker et al. [2]. Diese normiert die logarithmische Abweichung der betrachteten Zeit t von der geschätzten charakteristischen Lebensdauer $\hat{T}$ mit dem Formparameter $\hat{b}$ (vergleiche auch Bain und Engelhardt [23] für weitere Abschätzungen):

$$\hat{w} = \hat{b} \cdot \ln \left(\frac{t}{\hat{T}} \right). \quad (2.66)$$

Die Varianz dieser Größe lässt sich mittels Taylor-Reihenentwicklung (Delta-Methode, vgl. Abschnitt 2.1.4) approximativ aus den Varianzen und Kovarianzen der Parameterschätzer und analog zu Gleichungen 2.22 und 2.23 bestimmen:

$$\hat{\text{Var}}(\hat{w}) = \left(\frac{\hat{b}}{\hat{T}} \right)^2 \hat{\text{Var}}(\hat{T}) + \left(\frac{\hat{w}}{\hat{b}} \right)^2 \hat{\text{Var}}(\hat{b}) - \frac{2\hat{w}}{\hat{T}} \hat{\text{Cov}}(\hat{T}, \hat{b}). \quad (2.67)$$

Basierend auf der asymptotischen Normalverteilung ergeben sich die Vertrauensgrenzen $[\hat{w}_u, \hat{w}_o]$ gemäß:

$$[\hat{w}_u, \hat{w}_o] = \hat{w} \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\text{Var}}(\hat{w})}. \quad (2.68)$$

Die Rücktransformation dieser Grenzen in den Wertebereich der Ausfallwahrscheinlichkeit erfolgt anschließend über die Verteilungsfunktion der kleinsten Extremwerte $G = 1 - \exp[-\exp(\hat{w})]$, woraus sich direkt die Konfidenzintervalle der Zuverlässigkeit ableiten lassen. Im Fall von GLM ist zu berücksichtigen, dass die geschätzte charakteristische Lebensdauer $\hat{T}$ keine unabhängige Konstante ist, sondern funktional entsprechend Gleichung 2.56 von den Kovariaten x und dem Parametervektor $\hat{\beta}$ abhängt. Die für Gleichung 2.67 benötigte Varianz $\hat{\text{Var}}(\hat{T})$ muss folglich unter Berücksichtigung der gesamten Kovarianzmatrix der Regressionskoeffizienten aus Gleichung 2.64 berechnet werden. Dies erfolgt durch die allgemeine Fehlerfortpflanzung nach Gauß:

$$\hat{\text{Var}}(\hat{T}) \approx \sum_{i=1}^k \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i} \right)^2 \hat{\text{Var}}(\hat{\beta}_i) + \sum_{i=1}^k \sum_{\substack{j=1 \\ j \neq i}}^k \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i} \right) \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_j} \right) \hat{\text{Cov}}(\hat{\beta}_i, \hat{\beta}_j). \quad (2.69)$$

Modellgüte und Residuenanalyse

Die Validität eines parametrischen Lebensdauermodells (hier Weibull-GLM) beruht auf drei fundamentalen Annahmen, die es nach der Parameterschätzung zu verifizieren gilt: Erstens folgen die Lebensdauern der angenommenen Verteilung. Zweitens sind die Lebensdauern statistisch unabhängig. Drittens besteht ein log-linearer Zusammenhang zwischen dem Skalenparameter und den Einflussgrößen, wobei der Formparameter in einfachen Modellen als konstant über den gesamten Versuchsraum angenommen wird. Die Beurteilung dieser Modellgüte erfordert bei Lebensdauerdaten, bedingt durch Nicht-Normalverteilung und Zensierung, eine Anpassung klassischer Konzepte zur Residuenanalyse ($y - \hat{y}$) [27, 32]. Stattdessen werden transformierte Residuen betrachtet, die den Bezug zur Verteilung der kleinsten Extremwerte *SEV* herstellen, welcher der logarithmierten Weibull-Verteilung zugrunde liegt. Analog zur *z*-Transformation bei der Normalverteilung lassen sich für jede Beobachtung t_i standardisierte Residuen r_i berechnen. Dabei ersetzt der logarithmierte Schätzwert der charakteristischen Lebensdauer $\ln(\hat{T}_i)$ (vgl. Gleichung 2.56) den Lageparameter μ und der Kehrwert des Formparameters $1/\hat{b}$ die Skalierung σ . Dies entspricht exakt der in diesem Abschnitt eingeführten Hilfsgröße w :

$$r_i = \frac{\ln(t_i) - \ln(\hat{T}_i)}{1/\hat{b}} = \hat{b} \cdot \ln\left(\frac{t_i}{\hat{T}_i}\right). \quad (2.70)$$

Ist das Modell korrekt spezifiziert, müssen diese Residuen (unter Berücksichtigung der Zensierung) einer Verteilung der kleinsten Extremwerte *SEV* ($\mu = 0, \sigma = 1$) folgen. Eine allgemeinere Form der Validierung bieten die **Cox-Snell-Residuen** r_{CS} [2, 3]. Sie stellen eine Transformation der standardisierten Residuen dar und entsprechen dem Wert der kumulativen Hazard-Funktion an der Stelle der Beobachtung. Für das Weibull-Modell gilt der Zusammenhang:

$$r_{CSi} = -\ln(\hat{R}(t_i)) = \exp(r_i) = \left(\frac{t_i}{\hat{T}_i}\right)^{\hat{b}}. \quad (2.71)$$

Folgt das angepasste Modell den Daten, so verhalten sich die Residuen r_{CS} wie eine Stichprobe aus einer Standard-Exponentialverteilung mit Mittelwert 1. Diese Eigenschaft erlaubt eine grafische Validierung mittels Probability-Plots: Liegen die geplotteten Residuen auf einer Geraden im Exponential-Wahrscheinlichkeitsnetz, kann

von einer adäquaten Modellpassung ausgegangen werden. Zur Identifikation von Ausreißern oder einflussreichen Beobachtungen eignen sich hingegen standardisierte Devianz-Residuen r_{Dev} . Im Gegensatz zu den stets positiven Cox-Snell-Residuen sind diese symmetrischer um Null verteilt und folgen asymptotisch einer Standardnormalverteilung:

$$r_{\text{Dev}i} = \text{sgn}(r_{\text{CS}i} - 1) \cdot \sqrt{2 [r_{\text{CS}i} - \delta_i - \delta_i \ln(r_{\text{CS}i})]}. \quad (2.72)$$

Neben der Verteilungsprüfung dienen Streudiagramme dieser Residuen zur Aufdeckung struktureller Modelldefizite. Dabei werden r_{CS} oder r_{Dev} gegen die prädierten Werte oder gegen einzelne Einflussfaktoren aufgetragen und gegenüber Trendfreiheit und Varianzhomogenität bewertet. Besteht initiale Unsicherheit über die zugrundeliegende Physik, ermöglicht zudem der Vergleich den Wahrscheinlichkeitsnetzen der Residuen eine empirische Selektion: Dasjenige Modell, dessen Punktegraphen eine geringere Krümmung aufweisen und besser der theoretischen Geraden folgen, ist statistisch zu bevorzugen.

3 Effiziente Testplanung für die multivariate Lebensdauererprobung

3.1 Bewertung des Standes der Forschung und Technik

Der in Kapitel 2 dargelegte Stand der Forschung und Technik verdeutlicht, dass sowohl die Zuverlässigkeitstechnik als auch die statistische Versuchsplanung (DoE) isoliert betrachtet hochgradig etablierte Disziplinen mit einem profunden Methodenrepertoire darstellen [1, 28]. Die methodische Schnittmenge beider Felder - die effiziente Planung multivariater Lebensdauerersuche unter Berücksichtigung nicht-normalverteilter Ausfalldaten und Zensierungen (Weibull-GLM) - offenbart jedoch fundamentale Konflikte, welche den zwingenden Bedarf an weiterführender Forschung begründen.

Eignung und Limitierung klassischer Response Surface Designs Klassische Versuchspläne der RSM, insbesondere das CCD, haben sich als robuster Standard für die Modellierung nichtlinearer Zusammenhänge bewährt [3, 27]. Ihre Stärken manifestieren sich in der sequenziellen *Augmentierbarkeit*, der *Rotierbarkeit* und der Fähigkeit zur unabhängigen Schätzung des reinen Fehlers - vgl. Abschnitt 2.2.3. Basierend auf dem am IMA generierten Wissensstand nach Kremer [39] lässt sich ableiten, welche methodischen Vorgehen im Rahmen des L-DoE am besten geeignet sind, um erwartungstreue Schätzungen für Modellparameter [17] und Vertrauensbereiche [21] zu generieren.

Für die spezifischen Anforderungen der Lebensdauererprobung ist die starre geometrische Symmetrie des klassischen CCD jedoch hochgradig ineffizient. Die Zuverlässigkeitstechnik erfordert unweigerlich eine **Extrapolation**: Um Ausfälle in vertretbarer Zeit zu erzwingen, müssen die Tests bei erhöhten Lasten (ALT) durch-

geführt werden; das eigentliche Ziel der Modellbildung ist jedoch die verlässliche Prognose unter verhältnismäßig moderateren Feldbedingungen. Klassische **RSDs** sind mathematisch jedoch auf Interpolation und maximale Schätzgüte im Zentrum des Versuchsraums optimiert [50]. Ein geeigneter, struktureller Umgang mit dieser Diskrepanz ist in der industriellen Praxis bislang nicht etabliert. Zwar existieren rudimentäre Ansätze zur Modifikation von **CCDs** (vgl. Box und Wilson [50], Ahn [67] und Donev [92] und Ardakani et al. [93]), diese fokussieren sich jedoch primär auf den Erhalt generischer Optimalitätskriterien bei ungewollten Fehlerquellen. Sie adressieren nicht proaktiv die Herausforderung der probabilistischen Lebensdauerprognose im Extrapolationsraum unter Wahrung der statistischen **Trennschärfe** (*power*) [81]. Es fehlt ein etabliertes Vorgehen, um die Versuchspunkt-Topologie gezielt in Prognoserichtung abzustützen und so die Extrapolationsfähigkeit zu maximieren, ohne die ökonomische Balance des Versuchsaufwands zu zerstören.

3.1.1 Das methodische Paradoxon moderner Versuchsplanung

Der Einsatz computergenerierter, algorithmisch optimaler Versuchspläne erscheint zunächst als logische Konsequenz, um maßgeschneiderte Designs für **ALTs** zu entwerfen [33]. Im Kontext multivariater Lebensdauertests erfährt der Begriff der **Effizienz** jedoch eine signifikante Komplexitätssteigerung gegenüber der klassischen linearen Versuchsplanung, welche sich in den Dimensionen *Modellabhängigkeit*, *zeitliche Dynamik* und *strukturelle Flexibilität* niederschlägt.

Modellabhängigkeit und das Problem der lokalen Optimalität Die zugrundeliegende Modellierung mittels Weibull-**GLMs** stößt auf ein fundamentales stochastisches Hindernis [82, 88]. Im Gegensatz zu klassischen **OLS**-Modellen (Normalverteilung) hängt die Fisher-Informationsmatrix $\mathbf{M}(\mathbf{X}, \boldsymbol{\theta})$ bei **GLMs** nicht allein von den geometrischen Einstellungen der Faktoren $\mathbf{X}$ ab, sondern zwingend von den wahren, aber vorab unbekannten Modellparametern $\boldsymbol{\theta}$ (insbesondere dem Weibull-Formparameter b und via der Link-Funktion dem Lageparameter T):

$$\mathbf{M}(\mathbf{X}, \boldsymbol{\theta}) = -E \left[\frac{\partial^2 \Lambda(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^2} \right]. \quad (3.1)$$

Hieraus resultiert ein Zirkelschluss: Zur Konstruktion eines idealen optimalen Plans müssten exakt jene Parameterwerte bereits bekannt sein, die der Versuch erst ermitteln soll [88]. Zwar existieren numerische Algorithmen zur Bestimmung optimaler Versuchspläne für GLMs [82, 94], diese erfordern jedoch zwingend einen initialen *Best Guess* der wahren Werte. Stimmen diese anfänglichen Schätzungen nicht mit der physikalischen Realität überein, entartet das Design und verliert seine Integrität vollständig („The designs may be poor if the choice of values is far from the true parameter values“ Stufken und Yang [88, S.2]). Solche computergenerierten Pläne sind folglich lediglich **lokal optimal** und bergen bei Fehleinschätzungen ein extremes Ausfallrisiko für die gesamte Testkampagne.

Zeitliche und strukturelle Effizienz Zweitens muss die **zeitliche Effizienz** berücksichtigt werden. Da die Information in Lebensdauertests stochastisch über die Zeit generiert wird und durch Prüfstandskapazitäten oder Zensierung limitiert ist, skaliert die Schätzvarianz maßgeblich mit den tatsächlichen Ausfallzeiten [15]. Ein Versuchsplan ist im Lebensdauer-Kontext folglich nur dann effizient, wenn er die exponentiell skalierende Testdauer bei unbeeinträchtigter statistischer Effektivität minimiert.

Drittens adressiert die Klasse der OMARS-Designs die Forderung nach **struktureller Flexibilität**. Im direkten Vergleich zum CCD ermöglichen sie die Entkopplung von Faktoren- und Versuchsanzahl (z. B. $N = 40$ statt $N \geq 45$ für $k = 6$). Dieser *One-Step-Ansatz* [75], der Screening und Optimierung in einer singulären Matrix integriert, ist jedoch im Kontext von EoL-Testing rational nur schwer sequenziell erweiterbar [76]. Der Preis für diese strukturelle Effizienz ist zudem ein kontrolliertes Maß an *Aliasing* (Vermengung) zwischen Effekten zweiter Ordnung.

3.1.2 Schlussfolgerung für die Testplanung

Aus der Diskrepanz zwischen dem theoretischen Anspruch lokaler GLM-Optimalpläne und ihrer enormen Anfälligkeit in der Praxis leitet sich die Notwendigkeit einer pragmatischeren, robusteren Vorgehensweise ab. Anstatt ein artifizielles theoretisches Optimum zu berechnen, das bei Parameterabweichungen kollabiert, erweist sich die gezielte **Adaption bewährter, topologisch robuster Standard-Designs (CCD)** als der ingenieurwissenschaftlich überlegene Pfad.

Dabei dürfen die etablierten Optimalitätskriterien jedoch nicht als pauschales, alleiniges Entwurfsziel fungieren. Sie müssen in einen multidimensionalen Benchmark überführt werden:

- **Modellierungsgüte (A-, D-Kriterien):** Sichern ab, dass die Parameterschätzung (θ) auch nach geometrischen Modifikationen des Designs numerisch stabil bleibt [28].
- **Prognosefähigkeit (SPV, G-, I-, V-Kriterien):** Besitzen in der Lebensdauererprobung die absolute Priorität, da die präzise Vorhersage der Zuverlässigkeit $R(t)$ im fernen Einsatzbereich (*Extrapolation*) das eigentliche Versuchsziel darstellt [35].
- **Testdauer und Ressourceneffizienz:** Limitieren die Versuchsplanung durch die harte Realität exponentiell ansteigender **EoL**-Prüfzeiten und Prüfstandskosten $E(C_\Sigma)$ [95].
- **Trennschärfe (*power*):** Fungiert als unabdingbare Erfolgsgarantie. Ein theoretisch varianzminimales Design, das in der Praxis den Nachweis essenzieller physikalischer Effekte verfehlt, ist ökonomisch wertlos ($power \geq 80\%$) [77, 96].

Eine effiziente Testplanung erfordert folglich einen strategischen Kompromiss: Das Design muss asymmetrisch genug sein, um Extrapolationen zielgerichtet abzusichern, robust genug, um die Unsicherheiten der nichtlinearen **MLE** abzufangen, und gleichzeitig eine Trennschärfe gewährleisten, die das extreme Investitionsrisiko von Lebensdauerersuchen rechtfertigt.

3.2 Forschungsfragen und wissenschaftliche Zielsetzung

Als methodisches Fundament für die multivariate Lebensdauererprobung dient in dieser Arbeit das Central Composite Design (**CCD**). Diese Wahl begründet sich in fünf fundamentalen verfahrenstechnischen, physikalischen und statistischen Eigenschaften [2, 35, 46]:

1. Sequenzielle Augmentierbarkeit:

Ermöglicht den stufenweisen Ausbau vom linearen Screening zum vollwertigen quadratischen Modell und minimiert das ökonomische Fehlinvestitionsrisiko bei zeitintensiven Tests [1].

2. Rotierbarkeit und Richtungsneutralität:

Bietet eine homogene Ausgangsbasis für die Prädiktionsgüte bei a priori unbekannter Lage des Zuverlässigkeitsoptimums [2].

3. Modellierung nichtlinearer Schädigungskinetik:

Die Abtastung auf fünf Faktorstufen erlaubt die Validierung physikalischer Beschleunigungsmodelle und die Detektion von Linearitätsgrenzen [6, 85].

4. Schätzung der reinen Systemstreuung:

Zentralpunkt-Replikationen ermöglichen die modellunabhängige Trennung von reinem Versuchsfehler (*Pure Error*) und Modellanpassungsfehlern (*Lack of Fit*) [2].

5. Topologische Fehlertoleranz:

Die symmetrische Grundstruktur garantiert eine extrem hohe Toleranz gegenüber unvorhergesehenen Zensierungen (*Missing Data*) am Prüfstand [28].

Die vorliegende Arbeit zielt darauf ab, diese überlegene Grundarchitektur nicht zu verwerfen, sondern den ihr zugrundeliegenden **Augmentierungs-Gedanken konsequent fortzuführen**. Die methodische Kernüberlegung besteht darin, den Informationsgewinn für die Extrapolation nicht durch eine kostenintensive Vergrößerung der Prüflingsanzahl zu erzwingen, sondern als striktes **Nullsummenspiel im Versuchsraum** zu realisieren: Unter Beibehaltung oder gezielten Reduktion des gesamten Prüfumfangs ($N_{\text{adaptiv}} \leq N_{\text{CCD}}$) werden ungenutzte geometrische Freiheitsgrade und redundante Stützstellen identifiziert und proaktiv als Extrapolations-Ankerpunkte reinvestiert.

Hieraus leiten sich die zentrale Hauptforschungsfrage sowie die beiden Teilforschungsfragen ab:

Hauptforschungsfrage

Wie können multivariate Response Surface Designs unter Beibehaltung oder Reduktion des Gesamtstichprobenumfangs N adaptiert und optimiert werden, um beschleunigte Lebensdauerprüfungen für eine verlässliche Zuverlässigkeitsmodellierung im unbeschleunigten Feldbereich maximal ressourceneffizient auszulegen?

Teilforschungsfragen

- 1: In welchem Maße tolerieren klassische Response Surface Designs praxisinduzierte Orthogonalitätsabweichungen, und wie kann ein resultierendes geometrisches Gestaltungsbudget genutzt werden, um die Schätz- und Prognosegüte auf dem Extrapolationspfad ohne Vergrößerung des Prüfumfangs N gezielt zu stützen?
- 2: Über welche mathematischen und grafischen Metriken lässt sich die richtungsabhängige Prädiktionsunsicherheit asymmetrisch modifizierter Versuchspläne quantifizieren, und wie kann der fundamentale Zielkonflikt zwischen stochastischer Vorhersagegüte und exponentiell skalierenden Prüfstandskosten in ein skalares Effizienzoptimum überführt werden?

3.3 Methodische Forschungsarchitektur

Die Beantwortung der formulierten Forschungsfragen erfolgt entlang einer geschlossenen, fünfstufigen Methodenkette, welche das theoretische Konzept von der Parameteridentifikation bis zum industriellen Nutznachweis operationalisiert:

- **Stufe 1: Heuristisches Screening (Kapitel 4):**

Deterministische Reduktion des hochdimensionalen Parameterraums auf die lebensdauerkritischen Stressoren und deren Interdependenzen mittels strukturierter Systemanalyse (DSM, Grid-Analyse) zur Vermeidung kombinatorischer Versuchsraumexplosionen.

- **Stufe 2: Quantifizierung der Resilienz & Gestaltungsbudget (Abschnitt 5.2):**
Simulativer Nachweis der Fehlertoleranz des [CCD](#) gegenüber geometrischen Restriktionen und Ableitung des nutzbaren Gestaltungsbudgets für asymmetrische Modifikationen bei konstantem Stichprobenumfang [N](#).
- **Stufe 3: Fortführung der Augmentierung & Adaptive Testplanung (Abschnitt 5.3):**
Methodische Weiterentwicklung des Augmentierungsprinzips durch Allokation von Extrapolations-Ankerpunkten ([EmALT](#)) innerhalb mathematisch definierter Toleranzbereiche (*Exposure Area*) sowie richtungssensitive Analyse der [SPV](#) mittels des [EVG](#).
- **Stufe 4: Ganzheitliche stochastisch-ökonomische Bilanzierung (Abschnitte 5.4-5.5):**
Kopplung der MLE-basierten Weibull-AFT-Modellierung mit einem dynamischen Prüfstandskostenmodell und Etablierung des [EPI](#) zur Bestimmung des Pareto-Optimums aus Testdauer und Prognosegüte.
- **Stufe 5: Empirische Validierung & Falsifikation (Kapitel 6):**
Experimenteller Härtetest an realen Bauteilprüfungen (Lenksystem-Zahnriemen) mittels *Confirmation Experiments* (Abschnitt 6.2.1) und Prädiktionsintervallen zur Verifikation der Schutzwirkung gegen feldbetriebliche Sicherheitsüberschätzungen.

4 Parameter-Screening für multifaktorielle Lebensdauertests

Die in Kapitel 3 hergeleitete Notwendigkeit effizienter Testdesigns setzt zwingend voraus, dass die Dimensionalität des Versuchsraums k auf ein handhabbares Maß begrenzt ist. Da die Komplexität und der Versuchsumfang exponentiell mit der Anzahl der Faktoren skalieren (vgl. Gleichung (2.29)), determiniert die präzise Vorselektion der Einflussgrößen den gesamten ökonomischen und stochastischen Erfolg der Versuchsplanung. Klassische Ansätze der Zuverlässigkeitstechnik greifen hierfür oft auf experimentelle Screening-Pläne (z. B. fraktionelle faktorielle Pläne 2^{k-p_f} oder Plackett-Burman-Designs) zurück [3, 27]. Im Kontext der Lebensdauererprobung führt dies jedoch zu einem gravierenden methodischen Paradoxon: Um experimentell zu quantifizieren, ob ein Parameter die Lebensdauer signifikant beeinflusst, müssten bereits in der Screening-Phase zeit- und kostenintensive EoL-Tests durchgeführt werden. Dieser methodische Widerspruch macht den eigentlichen Effizienzvorteil des Screenings vollständig zunichte. Zudem gehen stark fraktionierte Designs zumeist von strikter Linearität und vernachlässigbaren Wechselwirkungen aus - eine Prämisse, die bei physikalischen Degradationsprozessen fatal sein kann, da Ausfälle häufig erst durch latente Interaktionen (z. B. thermomechanische Spannungen) getrieben werden [85].

Dieses Kapitel etabliert daher einen **heuristischen Screening-Ansatz** als zwingenden methodischen Filter *vor* dem Start physischer Versuche nach dem Vorbild von Arndt et al. [97]. Der Begriff der Heuristik ist hierbei nicht als intuitives Schätzen zu verstehen, sondern als algorithmisch gestützter Suchpfad, der physikalisches Domänenwissen formalisiert, um die kombinatorische Steigerung der Parameter mathematisch zu beherrschen. Der Fokus liegt hierbei explizit auf dem Paradigmenwechsel von der Betrachtung der initialen Streuung zur Bewertung echter Zuverlässigkeit. Aus der Perspektive der Zeitdomäne ist die differenzierte Klassifizierung der Einflussfaktoren essenziell: Stochastische Degradationspfade (vgl. Abschnitt 2.1.1)

sind nicht statisch, sondern unterliegen zeitvarianten Interaktionsstrukturen und einer sich verschiebenden Effekthierarchie. Parameter, die das Systemverhalten in der späten **EoL**-Phase treiben, divergieren oftmals signifikant von jenen, welche die initiale Performance bei $t = 0$ dominieren. Um diese komplexe, latente Dynamik systematisch zu beherrschen, überführt der vorgestellte Ansatz qualitative Expertenmethoden (z. B. **Fault-Tree-Analysis (FTA)**, Ishikawa-Analysen) in strukturierte, matrixbasierte Bewertungswerkzeuge (**DSM**, Grid-Analyse), wodurch eine belastbare, objektive Priorisierung der kritischen Einflussgrößen für die nachfolgende quantitative Versuchsplanung (Kapitel 5) ermöglicht und erzwungen wird.

4.1 Identifikation der latenten Einflussgrößen

Die Basis einer validen Versuchsplanung bildet die vollständige Erfassung der Systemgrenzen. Um das Risiko von *False Negatives* - also das fatale Übersehen eines lebensdauerbestimmenden Einflussparameters - auszuschließen, ist eine strukturierte Systemanalyse unerlässlich [1]. Ein zentrales Werkzeug hierfür ist das **FBD** [41, 45, 98]. Es abstrahiert das technische System auf seine Ein- sowie Ausgangsgrößen und klassifiziert nach den iterativen Flussgrößen *Energie*, *Stoff* und *Signal* (vgl. Abbildung 4.1) [43]. Innerhalb dieser physikalischen Grenzen werden Haupt- und Nebenfunktionen definiert, deren Degradation oder Nichterfüllung direkt den potenziellen Ausfallmechanismus determiniert.

Zur systematischen Informationsbeschaffung eignen sich, aufbauend auf dem **FBD**, etablierte Instrumente des Qualitätsmanagements - **Seven Quality Tools (Q7)** und **Seven Management and Planning Tools (M7)** - sowie intuitive Explorationsansätze (Kreativmethoden) [100, 101]:

- **Literaturrecherche & Simulation:** Analyse bestehender Ausfallmodi, physikalischer Wirkmechanismen (z. B. Arrhenius, inverse Potenzgesetze) sowie numerischer Analysen (**Finite-Elemente-Analyse (FEA)**) aus der frühen Entwicklungsphase [102].
- **Strukturiertes Brainstorming:** Ermöglicht es interdisziplinären Expertenteams, intuitives, oft implizites Domänenwissen formalisiert zu explizieren [42, 44].




Abbildung 4.1: FBD mit Haupt-, Neben- und Teilfunktionen zur lückenlosen Identifikation funktionskritischer Einflussgrößen (in Anlehnung an [97] nach [99]).

- **Delphi-Methode:** Durch mehrstufige, anonymisierte Befragungen werden subjektive Einschätzungen statistisch objektiviert und Konsens über die Kritikalität von Größen erzielt [44].
- **Morphologische Analyse:** Die formale Zerlegung des Systems in Lösungsprinzipien deckt systematisch konstruktive und operationale Einflussparameter auf [103, 104].

Das Ergebnis dieser Phase ist das *Supremum* des Parameterraums: Ein unsortierter, aber maximal vollständiger Pool aller physikalischen Größen, die das Systemverhalten potenziell tangieren.

4.2 Methodische Strukturierung und analytische Priorisierung

Dieser initial aggregierte Parameter-Pool unterliegt nun einem zwingenden Reduktionsprozess, um die vitalen Einflussgrößen (*vital few*) von den vernachlässigbaren (*trivial many*) abzugrenzen [97]. Dieser Filter schützt die nachgelagerte Design-

Matrix davor, durch irrelevante Dimensionen (*False Positives*) auf ein unfinanzierbares Maß zu explodieren. Auf Basis der Arbeiten von Gundlach [41], Kremer [105] und Mayers [42] werden Methoden angewandt, die insbesondere zeitvariante Interaktionsstrukturen für die Lebensdaueranalyse quantifizierbar machen.

4.2.1 Erfassung von Interdependenzen

Die reine Auflistung von Parametern greift in der Zuverlässigkeitstechnik zu kurz. Die Kernaufgabe der Strukturierung ist die Identifikation *gegenseitiger Beeinflussungen* und latenter Wechselwirkungen. Phänomene wie Materialermüdung oder Korrosion sind physikalisch meist hochgradig nichtlinear und resultieren aus multivariaten Interaktionen [28, 39, 97]. Um dieses hochvernetzte Verhalten für den Versuchsplaner greifbar zu machen, kommen folgende topologische Mapping-Verfahren zum Einsatz:

- **Affinitätsdiagramm & Mind-Mapping:** Dienen der thematischen Clusterung von Systemgrößen und der hierarchischen Gliederung, wobei Querbeziehungen erste Hinweise auf Abhängigkeiten liefern [101, 106].
- **Erweitertes Ishikawa-Diagramm:** Das klassische 6M-Ursache-Wirkungs-Diagramm wird hierbei funktional erweitert. Anstatt lediglich statische Haupteffekte abzubilden, werden explizit **Interaktionen** durch *Querverbindungen* zwischen den Ästen visualisiert (vgl. Abbildung 4.2). Dies offenbart unmittelbar, welche Faktoren im Verbund evaluiert werden müssen [44, 81].
- **Interdependenz-Netzwerke:** Für hochkomplexe Systeme erfolgt die Modellierung als gerichteter Graph, in welchem Kanten die zeitliche Dynamik und Wirkrichtung (positiv/negativ) zwischen Knoten (Parametern) abbilden [107].

Die hierdurch geschaffene Transparenz ist die Prämisse für die anschließende Überführung in eine quantitative Bewertungsmetrik.

4.2.2 Matrixbasierte Bewertungsmethodik (Decision Making)

Um die heuristische Struktur in harte Entscheidungen für das DoE zu überführen, werden paarweise Vergleichsmatrizen angewandt, die subjektive Expertenschätzungen algorithmisch objektivieren.




Abbildung 4.2: Erweitertes Ishikawa-Diagramm zur expliziten Visualisierung zwingender Interaktionen zwischen Einflussfaktoren (adaptiert nach [81]).

Design-Structure-Matrix (DSM)

Die **DSM** projiziert die Systemarchitektur auf eine quadratische $n \times n$ -Matrix. Ein Eintrag ij symbolisiert die gerichtete Kausalität, mit welcher ein Parameter i einen Parameter j beeinflusst [45, 105]. Für die Lebensdaueranalyse wird diese Struktur zwingend um einen Zielgrößen-Vektor t erweitert - die Beeinflussung wird somit auf die Systemantwort (demzufolge die Lebensdauer) projiziert. Die Bewertung erfolgt idealerweise **numerisch** (z. B. Skala 0 bis 3, ggf. „?“ falls unbekannt), um die Interaktionsstärke exakt zu priorisieren. Fundierte Informationen „!“ werden hierbei von unsicheren, intuitiven Einschätzungen „(!)“ getrennt, um die Konfidenz der Expertenmeinung zu quantifizieren. Faktoren ohne gesicherte Informationsgrundlage „(?)“ werden bewusst als *Noise* oder Kovariaten deklariert und nicht in die nachfolgende Versuchsplanung übernommen. Der größte methodische Vorteil der **DSM** liegt in der Aufdeckung asymmetrischer Dominanzen zweier möglicher Parameter A und B ($AB \neq BA$). Ein sich daran anschließendes *Grid-Scoring* (vgl. nachfolgender Abschnitt und Abbildung 4.4) erlaubt die algorithmische Ableitung der Rolle eines Faktors im nachfolgenden **DoE** über deren jeweilige **Aktiv-** und **Passivsum-**

men. Strikt wirkende *aktive* und *kritische* Parameter prädestinieren sich als ideale Steuer- und Monitoring-Größen für den Prüfstand [39, 97].

Numerische DSM mit Konfidenzbewertung							Zielgröße	Activ fundiert	Activ unsicher	unbekannt
Einfluss von zu		<i>j</i>								
Paramerter	#	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>		<i>y</i>	!-Σ	(!)-Σ	?-Σ
<i>i</i>	<i>A</i>									
	<i>B</i>									
	<i>C</i>									
	<i>D</i>									
	⋮						⋮	⋮	⋮	⋮
Passiv fundiert	!-Σ									
Passive unsicher	(!)-Σ									
unbekannt	?-Σ									

Abbildung 4.3: Numerische DSM mit Konfidenzangabe für die Abschätzung einflussreicher Parameter auf die Lebensdauer als Zielgröße, in Anlehnung an [42, 45, 97]

Grid-Analyse (Portfolio-Analyse)

Die DSM-Ergebnisse werden in ein zweidimensionales Portfolio-Diagramm (Grid) transferiert (vgl. Abbildung 4.4). Für jeden Parameter i werden die **Aktivsumme** (Treiberstärke auf das System) und die **Passivsumme** (Reaktivität) summiert (zur formalen Berechnungsvorschrift und Aggregation sei auf Arndt et al. [97] sowie Mayers [42] verwiesen). Die Lage im Grid determiniert unmittelbar die Funktion des Faktors im geplanten DoE:

- **Aktive Parameter (hohe Aktiv-, niedrige Passivsumme):** Ideale **Steuerfaktoren** (x) für die Versuchsmatrix. Auf Basis *fundierter* Informationslage treiben sie die Degradation deterministisch, ohne rückgekoppelte Instabilitäten.

- **Kritische Parameter (hohe Aktiv- und Passivsumme):** Risikofaktoren mit massiver Vernetzung auf *unsicherer* Informationsbasis.
- **Passive Parameter (niedrige Aktiv-, hohe Passivsumme):** Eignen sich primär als **Indikatoren oder Systemantworten** (*y*), da sie empfindlich auf Stressänderungen reagieren.
- **Träge Parameter:** Werden formal als **Konstanten** fixiert und konsequent aus der möglichen Design-Matrix *X* ausgeschlossen.




Abbildung 4.4: Grid-Analyse zur algorithmischen Ableitung der Faktor-Rollen (Aktiv, Kritisch, Passiv, Träge) für das nachfolgende DoE (entsprechend [97]). Koordinaten: Definiert durch Aktiv- und Passivsumme. Konfidenzvektoren: Visualisieren den Informationsstand und verweisen von unsicheren/intuitiven Werten „(!)“ auf fundierte Werte „!“.

Zur Absicherung dieser Qualifizierung wird das Raster um Konfidenz-Vektoren erweitert [97]. Signifikante Differenzen zwischen datengestützter Gewissheit und reiner Intuition decken blinde Flecken auf, die isolierte Vorversuche erfordern, bevor das hochpreisige L-DoE gestartet wird.

4.2.3 Physikalische und versuchsökonomische Randbedingungen

Der Transfer der identifizierten *vital few* in eine finale Teststrategie unterliegt strengen physikalischen und ökonomischen Schranken [41, 108]. Selbst als relevant identifizierte, potenzielle Einflussparameter müssen sich vor der Übernahme in das L-DoE entsprechenden operativen Filterkriterien unterziehen [28, 109].

Arndt et al. [97] betonen, dass die Versuchsökonomie zwingend die finale Auswahl der Faktoren determiniert:

- **Einstell- und Regelbarkeit:** Der Parameter muss am Prüfstand absolut reproduzierbar ansteuerbar sein. Unkontrollierbare Größen sind zwingend als *Noise* oder Kovariaten zu deklarieren.
- **Homogene Beschleunigbarkeit:** Eine Aussteuerung auf Extremwerte für ALT darf die Aktivierungsenergie der Physik nicht derart verfälschen, dass ein artifizieller, im Feld niemals auftretender Ausfallmechanismus provoziert wird.
- **Versuchsökonomie:** $n \propto m \cdot N^k$ zwingt die Versuchsplanung unter harten Kostendruck zu einem radikalen Schnitt auf maximal $k_{\max} \approx 2 \dots 4$ Parameter.
- **Alias-Freiheit (Design Resolution):** Falls das Budget eine hochauflösende Abtastung verhindert, muss das Vorab-Wissen aus der DSM genutzt werden, um das Aliasing so zu steuern, dass die identifizierten Haupttreiber nicht mit kritischen Interaktionen vermengt (engl. *confounded*) werden.

Schließlich liegt die finale Entscheidung über die Übernahme eines Faktors in das L-DoE beim Versuchsplaner, der die physikalische Relevanz, die statistische Signifikanz und die ökonomische Machbarkeit gegeneinander anhand nachfolgendem Ablauf abwägt.

4.3 Methodische Synthese des Screening-Prozesses

Die aufgezeigte Auswahl an heuristischen Methoden und Werkzeugen befähigt schließlich entlang des heuristischen Screenings das Parametervolumen auf Basis der initialen Analyse in einem dreistufigen, deterministischen Filterprozess zu konsolidieren (Arndt et al. [97], vgl. Abbildung 4.5). Dieser Prozess fungiert als methodischer Türsteher vor der ressourcenintensiven Prüfstandsphase.




Abbildung 4.5: Dreistufiger, kondensierender Ablauf des heuristischen Screenings als obligatorische Vorstufe zur multivariaten L-DoE-Planung und -Modellierung - in Anlehnung an [97].

Phase I: Isolation des Schädigungsmechanismus

Der Prozess erzwingt zunächst die Festlegung auf einen spezifischen *Failure Mode* (z. B. Wälzermüdung vs. Adhäsion, Dauerbruch, etc.) sowie die Analyse des Systems via FBD. Da konkurrierende Ausfallmechanismen meist durch gänzlich unterschiedliche Stress-Kombinationen getrieben werden, führt eine globale Misch-

betrachtung zu nicht modellierbarem statistischem Rauschen. Das System wird funktional entkoppelt.

Phase II: Heuristische Interaktionsanalyse

Der Parameter-Pool passiert das erweiterte Ishikawa-Diagramm und die [DSM](#). Arndt et al. [97] zeigen, dass diese Kombination die höchste Prognosegüte für zeitvarian- te Degradationen aufweist. Parameter mit hoher Aktivsumme und starker Vernet- zungsdichte werden algorithmisch als Haupttreiber priorisiert.

Phase III: Konfrontation mit der Design-Matrix

Im finalen Matching-Prozess trifft die physikalisch priorisierte Liste auf die harte Realität der Versuchsökonomie und es ist abzugleichen, ob die Parameteranzahl, Orthogonalität und gewünschte statistische *power* (rationale Abwägung, $\geq 80\%$) unter einem abbildbaren Budget realisierbar ist. Faktoren, die diesen Stresstest im Abgleich mit der Priorisierung der Parameterliste nicht bestehen, werden bewusst ausgeschlossen, fixiert oder der Reststreuung zugewiesen.

4.4 Fazit: Heuristisches Screening als Gatekeeper der Modellvalidität

Das in diesem Kapitel etablierte heuristische Screening ist keine optionale explora- tive Vorstufe, sondern das zwingend erforderliche Fundament der effizienten Ver- suchsplanung. Es löst das Dimensionalitäts-Paradoxon auf, welches experimentelle Screening-Designs für kostenintensive [EoL](#)-Tests ökonomisch disqualifiziert. Durch die Formalisierung von Expertenwissen mittels [DSM](#) und Grid-Analysen gelingt es, die Anzahl der Versuchs-Faktoren k deterministisch auf ein wirtschaftlich darstell- bares Maß ($k \approx 2 \dots 4$) zu verdichten. Der entscheidende Fokus auf latente Wech- selwirkungen schützt das anschließende Modell davor, physikalisch getriebene Aus- fälle fälschlicherweise als aleatorisches Systemrauschen zu interpretieren. Dieses formalisierte Vorgehen ist die Grundvoraussetzung dafür, dass die nachfolgenden, hochgradig optimierten [EmALT](#)-Designs (Kapitel 5) den realen Degradationspro- zess mathematisch korrekt erfassen und am Prüfstand überhaupt erst wirtschaftlich implementierbar werden.




Abbildung 4.6: Die Volumenreduktion des Parameterraums: Überführung der qualitativen Komplexität in eine finanzierbare, statistisch valide Dimension für das quantitative **L-DoE** (adaptiert nach [97]).

5 Statistische Effektivität als Fundament effizienter Lebensdauertests

Nach der qualitativen Vorselektion relevanter Einflussgrößen (Kapitel 4) fokussiert die nachfolgende Betrachtung nun die quantitative DoE-Planung. Die zentrale wissenschaftliche Zielsetzung besteht in der Entwicklung adäquater, multivariater Lebensdauertests, welche etablierte Standard-RSDs gezielt an die spezifischen Anforderungen der Lebensdauerprognose anpassen. Das CCD bildet hierbei das methodische Fundament, da es durch seine sequenzielle Augmentierbarkeit (Screening → lineares Modell → quadratische Modellterme) im Kontext kostenintensiver EoL-Tests eine unübertroffene operative Flexibilität bietet (vgl. Abschnitt 3.2).

Um den Paradigmenwechsel von klassischen, starren DoE-Ansätzen hin zu hochgradig effizienten Lebensdauertests methodisch abzusichern, gliedert sich dieses Kapitel in eine geschlossene fünfstufige Sequenz - ausgehend von einer kontrollierten simulationsbasierten Modellumgebung hin zur gekoppelten stochastisch-ökonomischen Realität der Zuverlässigkeitstechnik:

Zunächst etabliert **Abschnitt 5.1** die ganzheitliche Simulations- und Auswertarchitektur auf Basis eines flexiblen *Ground-Truth*-Modells als methodisches Fundament des Kapitels. Darauf aufbauend quantifiziert **Abschnitt 5.2** die statistische Sensitivität und Robustheit klassischer Designs gegenüber Praxisrestriktionen: Mittels MCS wird nachgewiesen, in welchem Maße Orthogonalitätsabweichungen die Schätzpräzision und die statistische Trennschärfe (*power*) kompromittieren und welches nutzbare geometrische Gestaltungsbudget hieraus resultiert. Das gewonnene Bewusstsein über die topologische Resilienz legitimiert in **Abschnitt 5.3** den Übergang zur adaptiven Versuchsplanung, in welcher freigewordene Stützstellen als strategische Ankerpunkte (APs) reinvestiert werden, deren richtungssensitive Wirkung entlang des Extrapolationspfads über den neu entwickelten EVG visualisiert wird. Den ökonomischen Rahmen spannt in **Abschnitt 5.4** ein Kostenmodell auf, welches die stochastischen Testlaufzeiten in reale Prüfstandsaufwände übersetzt. In

Abschnitt 5.5 erfolgt schließlich der Transfer auf multivariate Lebensdauermodelle: Ausgehend von einer OLS-Baseline unter Normalverteilung wird das **EmALT**-Konzept im Weibull-AFT-Raum mittels iterativer **MLE** validiert und über den **EPI** im Pareto-Optimum aus Testaufwand und Prognosegüte ganzheitlich bilanziert.

5.1 Methodische Simulationsarchitektur und pseudo-physikalisches Modell

Um die statistische Leistungsfähigkeit und Effektivität modifizierter Versuchspläne objektiv zu quantifizieren, bedarf es einer kontrollierten Untersuchungsumgebung, in welcher - im Gegensatz zu empirischen Prüfstandsläufen - das wahre Systemverhalten a priori exakt bekannt ist. Erst der systematische Abgleich der Modellierungs- und Schätzergebnisse mit einer mathematisch definierten Referenz (engl. *Ground Truth*) ermöglicht die deterministische Berechnung von zentralen Gütemetriken (**KPIs**) wie Schätzgüte, Varianzinflation und statistischer Trennschärfe (*power*). Zu diesem Zweck wird nachfolgend eine allgemeingültige, modulare Simulationsumgebung etabliert, welche als Auswertebasis für sämtliche Untersuchungen dieses Kapitels dient [110, 111].

Pseudo-physikalisches Ground-Truth-Modell

Das zugrundeliegende Systemverhalten wird durch ein polynomiales Regressionsmodell zweiter Ordnung approximiert. Dies entspricht exakt der Modellstruktur, die als Ergebnis einer klassischen **RSM**-Auswertung (vgl. Gleichung (2.27)) resultiert und das Fundament für multivariate Lebensdauer- und Zuverlässigkeitsmodelle bildet. Um die Grundanforderungen an eine multivariate Untersuchung ($k \geq 2$) abzubilden und die mathematische Nachvollziehbarkeit zu wahren, wird im Basiszenario von zwei Einflussfaktoren (x_1, x_2) ausgegangen. Die Begrenzung auf $k = 2$ Faktoren stellt methodisch eine konservative *Worst-Case*-Betrachtung dar: Da sich die negativen Auswirkungen lokaler topologischer Störungen mit zunehmender Dimensionalität des Versuchsplans über eine größere Anzahl verbleibender orthogonaler Stützstellen verteilen, reagiert ein zweidimensionaler Versuchsraum statistisch am empfindlichsten auf geometrische Verzerrungen [81]. Das Modell berücksichtigt neben den Haupteffekten explizit die für Lebensdaueranalysen kri-

tischen Wechselwirkungen ersten Grades sowie quadratische Terme zur Erfassung von Systemkrümmungen:

$$y_{\text{sim}} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \quad (5.1)$$

Simulationsarchitektur und Monte-Carlo-Inferenz

Die definierte *Ground Truth* wird mit der jeweils zu untersuchenden Design-Matrix $\mathbf{X}$ gekoppelt. Für jeden Stützpunkt des Versuchsplans werden stochastische Systemantworten generiert, aus welchen anschließend über geeignete Schätzverfahren (OLS, MLE) die Modellparameter rückgerechnet werden (vgl. Abschnitte 2.1.4 und 2.2.6). Um epistemische Unsicherheiten zu minimieren und eine reproduzierbare numerische Konvergenz sicherzustellen, ist das Verfahren in eine MCS mit $n_{\text{MC}} = 1 \times 10^4$ Iterationen eingebettet. Dieser Aufbau erlaubt die simultane Analyse zweier elementarer Bewertungskriterien:

1. **Präzision der Parameterschätzung:** Durch den Erwartungswert-Vergleich der geschätzten Koeffizienten $\hat{\beta}$ mit den wahren Modellparametern β_{true} werden der systematische Schätzfehler (**Bias**) sowie die Schätzvarianz (**MSE**) exakt quantifiziert.
2. **Empirische Trennschärfe (*power*):** Für jeden Simulationslauf wird über statistische Hypothesentests (ANOVA bzw. Likelihood-Ratio-Test) geprüft, ob signifikante Effekte vor dem Hintergrund des stochastischen Rauschens korrekt identifiziert werden ($p\text{-Wert} < \alpha$). Der relative Anteil erfolgreicher Identifikationen definiert die empirische Test-Power (vgl. Gleichung (2.53), in Anlehnung an [39, 77, 111]).

Die systematische Kopplung dieser stochastischen Inferenzschritte mit der geometrischen Design-Topologie und dem dynamischen Kostenmodell ist in Abbildung 5.1 als geschlossene Simulationsarchitektur zusammengefasst. Der modulare Aufbau verdeutlicht die iterative Abarbeitung: Ausgehend von der definierten *Ground Truth* und der Versuchsmatrix $\mathbf{X}$ werden in $n_{\text{MC}} = 10^4$ Durchläufen Systemantworten generiert. Auf deren Basis erfolgt je nach Untersuchungsziel entweder eine lineare OLS-Regression zur verteilungsunabhängigen Analyse geometrischer Verzerrungen (Abschnitte 5.2 bis 5.5.2) oder eine iterative MLE-Schätzung für Weibull-verteilte

Ausfalldaten (Abschnitt 5.5.3). Am Ausgang der Simulationsschleife werden die statistische Effektivität (*power*, *MSE*, richtungsspezifische *SPV*) und die akkumulierten Prüfstandskosten simultan bereitgestellt, um im *EPI* (Abschnitt 5.5.3) ganzheitlich synthetisiert zu werden.

5.2 Effektivität von Versuchsplänen mit Orthogonalitätsabweichungen

In der industriellen Erprobungspraxis resultieren Abweichungen von der idealen Versuchsgeometrie häufig aus physikalischen Anlagenrestriktionen, Bauteilgrenzen oder der gezielten Lastanhebung im Rahmen von *ALTs*. Die Verschiebung von Versuchspunkten in Hochlastbereiche forciert den Ausfallmechanismus und verkürzt die Prüfzeit, während Stützstellen nahe dem Nennbetrieb die Extrapolationsunsicherheit im Feld dämpfen.

Solche Modifikationen bergen jedoch das Risiko, die statistische Integrität des Versuchsplans empfindlich zu schwächen. Im Idealfall sind die Spalten der Design-Matrix $\mathbf{X}$ eines *CCD* orthogonal zueinander, was die vollkommen unkorrelierte Schätzung aller Modellparameter garantiert (vgl. Abschnitt 2.2.3). Geometrische Verzerrungen heben diese Orthogonalität unweigerlich auf ($\langle \mathbf{x}_i, \mathbf{x}_j \rangle \neq 0$). Besonders kritisch ist hierbei, dass die Konsequenzen asymmetrischer Stützstellenverschiebungen im klassischen sequenziellen Augmentierungsprozess erst spät zutage treten – nämlich bei der Erweiterung des faktoriellen Kerns um axiale *SPs*.

Während sich bisherige Forschungsarbeiten [67, 92, 112, 113, 114] vorwiegend auf die rein algebraische Charakterisierung der Design-Matrix und abstrakte Optimalitätskriterien (Abschnitt 2.2.5) beschränken, greift dieser Ansatz für die Zuverlässigkeitstechnik zu kurz: Rein geometrische Matrixmaße erlauben keine verlässliche Aussage über die tatsächliche Schätzvarianz und die statistische Trennschärfe unter stochastischen Rauschbedingungen. Zur belastbaren Quantifizierung dieser Praxisrestriktionen wird daher nachfolgend auf die in Abschnitt ?? etablierte Simulationsarchitektur zurückgegriffen.




Abbildung 5.1: Methodische Architektur der Monte-Carlo-Simulationsumgebung zur ganzheitlichen stochastisch-ökonomischen Bewertung multivariater Lebensdauertests für sämtliche Abschnitte in Kapitel 5.

5.2.1 Sensitivitätsanalyse geometrischer und stochastischer Einflussgrößen

Um die Robustheit klassischer Response Surface Designs gegenüber den eingangs identifizierten Praxisrestriktionen fundiert zu bewerten, wird eine umfassende Sensitivitätsanalyse durchgeführt. Diese folgt methodisch einem **DoE on Experimental Design**-Ansatz: Die topologischen Eigenschaften des Versuchsplans sowie die stochastischen Randbedingungen der *Ground Truth* werden als Faktoren eines übergeordneten Meta-Designs derart variiert, dass deren funktionale Auswirkung auf die Schätzgüte und insbesondere auf die statistische Trennschärfe (*power*) im polynomialen Regressionsmodell zweiter Ordnung quantifiziert werden kann [110]. Hierfür wird ein Spektrum aus acht praxisrelevanten Geometrie-, Stör- und Inferenzparametern definiert:

1. Geometrischer SP-Abstand (α_D) zur Erfassung radialer Stauchungen oder Streckungen;
2. Asymmetrischer SP-Shift infolge parasitärer co-faktorieller Stellgrößenkopplung;
3. Diskrete Variation der Zentralpunktanzahl (n_{ZP});
4. Diskrete Variation der Sternpunktanzahl (n_{SP}) durch partiellen Stützstellenentfall;
5. Streuung der wahren Modellparameter (epistemisches Effekt-Rauschen);
6. Relatives Amplitudenverhältnis konkurrierender Haupteffekte (β_1 / β_2);
7. Standardabweichung des experimentellen Versuchsfehlers (System- und Messrauschen, SNR);
8. Vorgegebenes statistisches Signifikanzniveau (α).

Um die stochastische Realität technischer Systeme ohne deterministische Verzerrungen abzubilden, werden die wahren Modellparameter β_j nicht starr fixiert. Ausgehend von kalibrierten nominalen Startwerten $\beta_{j,nom}$ (vgl. Tabelle 5.1) unterliegen die Koeffizienten in jedem Monte-Carlo-Lauf einer stochastischen Schwankung. Zusätzlich wird die Systemantwort y_{sim} mit einem additiven Restfehler ϵ beaufschlagt, welcher die unkontrollierbare aleatorische Unsicherheit (Messrauschen, Umwelteinflüsse) modelliert:

$$\epsilon \sim \mathcal{N}(0, \sigma_{sim}^2) \quad \text{und} \quad \beta_j \sim \mathcal{N}(\beta_{j,nom}, \sigma_{sim}^2). \quad (5.2)$$

Die bewusste Wahl der Normalverteilung für diese grundlegende Sensitivitätsstudie ist methodisch zwingend: Sie erfüllt exakt die Prämissen des Gauß-Markow-Theorems und stellt sicher, dass die statistische Inferenz (*p*-Wert- und Vertrauensbereichsberechnung) im ungestörten Basis-Design vollkommen erwartungstreu und varianzminimal operiert. Etwaige Schätzfehler oder Einbrüche der *power* lassen sich somit kausal und isoliert auf die induzierten geometrischen Orthogonalitätsabweichungen (Design-Penalties) zurückführen, ohne durch verteilungsbedingte Asymmetrien oder Zensierungsmechanismen überlagert zu werden [2].

Tabelle 5.1: Nominale Startwerte und Streuparameter des pseudo-physikalischen Simulationsmodells

Modellparameter	Default-Wert
Regressionskonstante β_0	30
Regressionskoeffizienten β_j (für $j \in \{1, 2, 12, 11, 22\}$)	10
Standardabweichung der Systemantwort σ_{sim}	1

Zur formalen mathematischen Beschreibung des Sensitivitätsraums werden die acht Einflussgrößen im Parametervektor $\xi = [\xi_a, \dots, \xi_h]^\top$ zusammengefasst und gemäß Tabelle 5.2 parametrisiert. Die versuchsplanerische Einbindung dieser Faktoren in das Meta-Design erfolgt methodisch differenziert: Während die sechs kontinuierlichen Geometrie- und Rauschparameter ($\xi_a, \xi_b, \xi_e, \xi_f, \xi_g, \xi_h$) den stetigen Parameterraum eines CCD aufspannen, werden die strukturellen Stützstellenzahlen (ξ_c, ξ_d) als kategoriale Blockfaktoren über jeweils drei diskrete Stufen ($-1, 0, +1$) variiert. Diese strikte methodische Entkopplung ist zwingend geboten: Eine Reduktion der Stützstellen verändert die Rang- und Freiheitsgradstruktur der Informationsmatrix **M** diskontinuierlich. Ein rein kontinuierliches Meta-Modell würde über strukturelle Singularitäten hinweg interpolieren - etwa bei einem vollständigen Verlust der Schätzbarkeit quadratischer Terme infolge extremer Ausdünnung. Aus diesem Grund werden die kontinuierlichen Sensitivitäten der Geometrie- und Rauschparameter isoliert innerhalb der resultierenden $3 \times 3 = 9$ diskreten Topologie-Blöcke ermittelt (vollständig dokumentiert in den Tabellen A1 bis A9 in Anhang B), während der Haupteffekt der Stützstellenreduktion separat über die Niveauverschiebungen (*Level-Shifts*) der *power* zwischen den Blöcken quantifiziert wird.

Gegenüber alternativen Screening-Verfahren wie reinen Korrelationsanalysen, *Space-Filling Designs* oder datengetriebenen Machine-Learning-Modellen gewährleistet dieser hierarchische DoE-Ansatz eine formal abgesicherte statistische Kausalitätsprüfung zur eindeutigen Trennung von Haupteffekten, Interaktionen und Krümmungsanteilen auf die resultierende Trennschärfe [27, 115]. Weitere Variationsdimensionen - wie eine Erhöhung der Faktorenanzahl $k > 2$ oder eine Modifikation der faktoriellen Eckpunkte - werden hierbei bewusst ausgeschlossen, um die Dimensionalität des Meta-Designs analytisch beherrschbar zu halten und den Fokus stringent auf die Beantwortung von Teilforschungsfrage 1 zu richten.

5.2.2 Ergebnisse der Sensitivitätsanalyse und Quantifizierung der Trennschärfe

Die simulative Untersuchung der Trennschärfe (*power*) im Meta-Design offenbart eine signifikante Dichotomie zwischen aktiven, **dispositiven Designfaktoren** (Geometrie, Stützstellenanzahl) und unveränderlichen, **externen Systemrestriktionen** (Rauschen, Signifikanzniveau). Tabelle 5.3 fasst die Ergebnisse der ANOVA zusammen, wobei die signifikante Effektstärke E als Maß für die Dominanz eines Faktors dient (Detaillauswertungen siehe Anhang B).

Wird zunächst die globale **Modell-Power** ($power_m$) betrachtet, zeigt sich eine extrem hohe Robustheit gegenüber allen Variationen mit einer mittleren Trennschärfe von $power > 99,7\%$. Diese pauschale Metrik verdeckt jedoch, dass das Verhalten spezifischer Einzel-Effekte - insbesondere die Identifikation der für die Lebensdauerprognose kritischen quadratischen Terme - deutlich sensibler ausfällt. Wie Tabelle 5.3 zeigt, liegt die mittlere Trennschärfe für quadratische Terme ($power_{\beta_{11}}, power_{\beta_{22}}$) nur noch im Bereich von 70 % bis 79 %. Auch die Trennschärfe der linearen Haupteffekte wird durch die Variation der Einflussgrößen maßgeblich gesteuert, was sich in einem breiten Wertebereich von 37,3 % bis 90,8 % widerspiegelt. Die entscheidende Erkenntnis liefert jedoch der Blick auf die **Sensitivitäts-Indizes** (Spalte „Dominante Sensitivität“). Für die Mehrheit der untersuchten Koeffizienten ($power_m, power_{\beta_1}, power_{\beta_{12}}, power_{\beta_{11}}$) ist nicht etwa eine unzureichende Versuchspunktzahl der limitierende Faktor, sondern das **Effektstärke-Verhältnis** (ζ_f) sowie das **Messrauschen** (ζ_g). Mit einem Sensitivitätsindex von bis zu $E = 2,53$ dominiert das physikalische Systemverhalten die Erfolgswahrscheinlichkeit des Tests. Da das Rauschen sowie

Tabelle 5.2: Definition und Parametrisierung der Untersuchungsfaktoren für die Sensitivitätsanalyse

	Beschreibung	Wertebereich	Charakteristik
ζ_a	SP-Abstand (α_D) Variation des axialen Sternpunktabstands zum Zentrum (flächenzentriert, rotierbar, extendiert).	$[1,00; 2 \cdot \alpha_D]$	Kontinuierlich (CCD)
ζ_b	SP-Shift Asymmetrische, co-faktorielle Verschiebung eines SP zur Simulation von Stellgrößen-Korrelationen.	$[0,10; \alpha_D]$	Kontinuierlich (CCD)
ζ_c	ZPs (n_{ZP}) Diskrete Variation der Zentralpunktanzahl $n_{ZP} \in \{1, 5, 8\}$.	$[1,00; 8,00]$	Diskret (Blockfaktor)
ζ_d	SPs (n_{SP}) Diskrete Variation der Sternpunktanzahl $n_{SP} \in \{2, 3, 4\}$ (Entfall bis 50 %).	$[2,00; 4,00]$	Diskret (Blockfaktor)
ζ_e	Effekt-Rauschen Streuung der wahren Modellparameter bezogen auf den Nominalwert (σ_{sim} / β_i).	$[0,80; 1,20]$	Kontinuierlich (CCD)
ζ_f	Effekt-Verhältnis (β_1 / β_2) Amplitudenverhältnis zweier linearer Haupteffekte zueinander.	$[0,10; 1,00]$	Kontinuierlich (CCD)
ζ_g	Mess-Rauschen (SNR: y/ϵ) Verhältnis zwischen mittlerer Effektamplitude und Standardabweichung des Fehlers.	$[0,80; 1,20]$	Kontinuierlich (CCD)
ζ_h	Signifikanzniveau (α) Vorgegebene Irrtumswahrscheinlichkeit für statistische Hypothesentests.	$[0,02; 0,08]$	Kontinuierlich (CCD)

das Signifikanzniveau (ζ_h) bei EoL-Tests an bestehenden Prüfständen zumeist feste Randbedingungen darstellen, definieren sie eine natürliche Obergrenze der erreichbaren Trennschärfe, die auch durch noch so ausgedehnte Versuchspläne nicht durchbrochen werden kann.

Tabelle 5.3: Zusammenfassende Statistik der Trennschärfe und Identifikation der zugehörigen, jeweils dominierenden Einflussfaktoren. Die Ergebnisse demonstrieren, dass die Power maßgeblich durch unveränderliche Systemgrößen (Rauschen) und nur im Ausnahmefall durch modifizierbare Designgrößen limitiert wird.

Koeffizient	Mittelwert	Wertebereich	Zugehörig dominante Sensitivität	
	$\overline{power}$	[min; max] %	Einflussfaktor ζ_i (Kategorie)	E
<i>Globale Modellgüte:</i>				
$power_m$	99,7 %	[94,5; 100,0]	ζ_g (System)	0,10
<i>Spezifische Modelleffekte:</i>				
$power_{\beta_0}$	97,9 %	[76,9; 100,0]	ζ_e (System)	0,52
$power_{\beta_1}$	78,6 %	[60,0; 90,8]	ζ_g (System)	1,50
$power_{\beta_2}$	66,0 %	[37,3; 84,1]	ζ_f (System)	2,53
$power_{\beta_{12}}$	72,6 %	[52,5; 85,9]	ζ_g (System)	1,93
$power_{\beta_{11}}$	70,9 %	[32,6; 86,8]	ζ_g (System)	1,99
$power_{\beta_{22}}$	79,3 %	[33,4; 100,0]	ζ_a (Design)	3,72

E : Absoluter Effekt des Faktors auf die Power (aus ANOVA zum Meta-Design).

Aus dieser Gegenüberstellung kristallisiert sich eine fundamentale Erkenntnis für die Versuchsökonomie heraus: Wenn die Nachweiswahrscheinlichkeit der linearen Haupteffekte ohnehin durch nicht-dispositive Systemrestriktionen limitiert wird, ist zu prüfen, ob eine gezielte Ausdünnung des Versuchsplans (Reduktion der Stützstellen ζ_c und ζ_d) die statistische Aussagekraft in der Praxis überhaupt signifikant kompromittiert. Tabelle 5.4 quantifiziert diesen passiven „Design-Penalty“ als mittleren Trennschärfe-Verlust infolge der Stützstellenausdünnung.

Die numerische Bilanzierung belegt eine erstaunliche Robustheit des CCD-Skeletts: Der Verzicht auf redundante Zentralpunkte oder die Ausdünnung der Sternpunkte zieht für die Haupteffekte und Interaktionen lediglich einen marginalen Trennschärfe-Verlust nach sich (z. B. $\Delta power = -2,4\%$ bis $-8,0\%$). Der signifikante Schwach-

Tabelle 5.4: Systematischer Trennschärfe-Verlust ($\Delta power$) bei Reduktion der Versuchsstützpunkte. Während lineare Haupteffekte relativ robust gegenüber einer Design-Ausdünnung bleiben, zeigt sich der primäre *Design-Penalty* in der Schätzung der quadratischen Terme.

Koeffizient	Durchschnittlicher Trennschärfe-Verlust ($\Delta power$)	
	bei ξ_c ($n_{ZP} = 8 \rightarrow 1$)	bei ξ_d ($n_{SP} = 4 \rightarrow 2$)
<i>Konstante, Haupt- und Interaktionseffekte</i>		
$power_{\beta_0}$	−4,5 %	−0,3 %
$power_{\beta_1}$	−2,4 %	−6,0 %
$power_{\beta_2}$	+1,1 %*	−8,0 %
$power_{\beta_{12}}$	−1,2 %	−0,9 %
<i>Quadratische Effekte</i>		
$power_{\beta_{11}}$	−13,9 %	−12,8 %
$power_{\beta_{22}}$	n. a.**	−6,1 %

* Positiver Wert resultiert aus Varianzverschiebungen bei instabilen Designs.

** Nicht auswertbar, da Singularität in quadratischem Term bei n_{ZP} .

punkt dieser Reduktion entlädt sich fast ausschließlich in den quadratischen Termen (bis zu $-13,9\%$ Einbruch bei $\text{power}_{\beta_{11}}$).

Hierin verbirgt sich die zentrale mathematische Rechtfertigung für die im weiteren Studienverlauf verfolgte Strategie gezielter Design-Manipulationen: Einerseits zeigt Tabelle 5.4, dass die Reduktion klassischer Stützstellen die Detektion von Haupteffekten kaum gefährdet. Dies erzeugt ein ungenutztes **geometrisches Gestaltungsbudget**, da diese Punkte für die reine Effektidentifikation hochgradig ineffizient sind. Andererseits belegt Tabelle 5.3 eindrücklich, dass die Geometrie (speziell der Sternpunkt Abstand ζ_a) mit einem herausragenden Index von $E = 3,72$ den massivsten Hebel auf exakt jene quadratischen Terme besitzt, die bei passiver Stützstellenreduktion am stärksten leiden. Dieses ungenutzte Budget sollte folglich nicht zur reinen Kostensenkung gestrichen, sondern durch proaktive Design-Manipulationen (asymmetrische, gezielt topologische Reallokationen von Versuchspunkten) umgewidmet werden. Dies gilt umso mehr, als das physikalische Systemverhalten (Effektstärken und Rauschniveau) in realen ALT-Szenarien naturgemäß als unveränderliche Randbedingung zu akzeptieren ist. Nur so lässt sich der enorme geometrische Hebel nutzen, um die quadratische Modellkrümmung abzustützen und die Extrapolationsvarianz im Feldbereich gezielt zu minimieren.

5.2.3 Generische Auswirkungen relevanter Orthogonalitätsabweichungen

Die Ergebnisse der vorangegangenen Sensitivitätsanalyse (siehe Abschnitt 5.2.2) zeigen, dass das CCD im Hinblick auf die statistische Trennschärfe ein robustes Verhalten gegenüber Modifikationen seiner Stützstellenanzahl aufweist, da im Regelfall das experimentelle System- und Messrauschen den limitierenden Faktor der Effektivität darstellt (vgl. Tabellen 5.3 und 5.4). Für die praktische EoL-Versuchsplanung greift dieser generalisierte, kombinatorische Ansatz jedoch noch zu kurz. In der Realität am Prüfstand treten Abweichungen von der idealen Design-Matrix technisch bedingt oft nicht als geplante, systematische Ausdünnung auf, sondern als unvorhergesehene, asymmetrische und isolierte Einzelphänomene, erzwungen durch physikalische oder normative Restriktionen [67, 81, 112, 116].

Gleichzeitig eröffnet das Bewusstsein über die erstaunlich geringen *Design-Penalties* aus Abschnitt 5.2.2 die Chance für eine gezielte adaptive Planung: Wenn Design-

Modifikationen die Effektivität des Nachweises ohnehin nur moderat beeinträchtigen und insbesondere für Terme höherer Ordnung durch die Platzierung von SPs vorteilhaft gestaltbar sind (vergleiche Faktor ξ_a in Tabelle 5.3), ist zu prüfen, inwiefern geometrische Manipulationen zur Kostenoptimierung, Prüfzeitverkürzung oder zur Vermeidung irrelevanter Ausfallmechanismen nicht sogar bewusst induziert werden sollten.

Um diese singulären Praxisphänomene systematisch bewerten zu können, ist die kombinatorische Betrachtung des Meta-Designs nicht mehr zielführend. Zwar ist der Parameterraum an denkbaren geometrischen Abweichungen und deren Kombinationen in der Realität nahezu unendlich und hochgradig abhängig von produktspezifischen, technologischen sowie modellspezifischen Randbedingungen. Ein allgemeingültiger, analytischer oder erschöpfend numerischer Beweis für sämtliche Permutationen ist folglich weder möglich noch methodisch erstrebenswert. Der wissenschaftliche Anspruch an dieser Stelle liegt vielmehr darin, anhand isolierter, archetypischer Störfälle die fundamentalen Wirkmechanismen zwischen den objektiven Design-Metriken (Optimalitäten) und der resultierenden Trennschärfe aufzudecken. Aus dem Verständnis dieser kausalen Zusammenhänge lassen sich schließlich generalisierbare, methodische Anreize für die *Entwicklung effizienter multivariater Lebensdauerversuche* ableiten. Dementsprechend werden basierend auf der Simulationethodik aus Abschnitt 5.1 vier spezifische, voneinander isolierte Störszenarien definiert, welche typische Einzelrestriktionen in multivariaten Lebensdauerversuchen abbilden [81, 116]:

- **Fall I (Axialer Abstandsfehler):** SPs ($n_{SP} \geq 1$) können aufgrund von Anlagenrestriktionen nicht auf dem nominellen Abstand α_D gefahren werden oder würden einen durch ALT induzierten Wechsel des Ausfallmechanismus provozieren. Zur methodischen Einordnung wird dieser Fall in drei Stufen simuliert: eine axiale Stauchung auf 80 %, eine Streckung auf 120 % sowie der Rückzug auf die Nennlasten des rein faktoriellen Würfels (*Face Centered* (FC), $\alpha_D = 1$).
- **Fall II (Co-faktorielle Korrelation):** Ein SP ist nicht mehr achsenrein isoliert realisierbar. Spezifische, physikalische Systemfunktionalitäten (beispielsweise kombinierte Einflüsse durch Temperatur und mechanische Kraft) könnten die simultane (parasitäre) Aussteuerung eines zweiten Faktors erzwingen, wodurch eine asymmetrische geometrische Korrelation im ansonsten ortho-

gonalen Raum entsteht. Dieser Fall wird in einer leichten und einer starken Ausprägung untersucht, indem der Sternpunkt der x_1 -Achse durch einen parasitären Stellgrößenanteil von $x_2 = 0,1$ sowie $x_2 = 1,0$ überlagert wird.

- **Fall III (Stellgrößen-Scatter):** Die Aktorik des Prüfstands erlaubt keine exakte Ansteuerung der Zielkoordinaten, sodass die SPs einer unbeabsichtigten stochastischen Streuung (uniformes Rauschen von $\pm 10\%$ auf der Eingangsvariablen x_i) unterliegen.
- **Fall IV (Früh-Ausfall / Zensierung):** Ein Versuchspunkt führt zu einem Frühausfall (ggf. konkurrierender Schadensmechanismus), einem Durchläufer oder kann aus Zeitgründen nicht abgeschlossen werden. Der Versuch entfällt somit vollständig aus der finalen Design-Matrix. Da die topologische Bedeutung der Punkte stark variiert, wird dieses Szenario zur methodischen Differenzierung in zwei Unterkategorien aufgeschlüsselt:
 - **Fall IV: ZP:** Eliminierung geometrisch redundanter ZPs.
 - **Fall IV: SP:** Asymmetrische Eliminierung extremer SPs - hier simuliert am nördlichen SP auf der Achse von Faktor x_1 .

Wird als Vergleichsbasis zusätzlich zu den Design-Variationen der **Fälle I-IV** das standardmäßige Basis *CCD* berücksichtigt, ergeben sich insgesamt **neun** Szenarien. Für diese werden die Auswirkungen der jeweiligen Praxisrestriktion auf die Effektivität der Parameterschätzung und die *power* der Effekte isoliert quantifiziert und verglichen. Es gilt zu quantifizieren, inwiefern der Verlust der Orthogonalität - messbar über den globalen A_2 -Indikator - zu Multikollinearität und folglich zu einer schädlichen Varianzinflation (*VIF* beziehungsweise *MSE*) oder gar zu systematischen Verzerrungen der Koeffizientenschätzung (*Bias*) führt (vgl. Abschnitt 2.2.5). Die analytische Differenzierung dieser Fehlerarten ist von entscheidender Bedeutung, da insbesondere ein signifikanter Bias die Validität der gesamten Lebensdauerprognose unbemerkt kompromittieren würde, während eine reine Varianzinflation primär die Konfidenzintervalle aufweitet.

Kalibrierung der Signal-to-Noise Ratio und analytische Justierung des Arbeitspunkts

Wie in der vorangegangenen Sensitivitätsanalyse (vgl. Abschnitt 5.2.2) dargelegt, konvergiert die Trennschärfe bei dominierenden physikalischen Effekten (hohes $\text{SNR} \gg 1$) in einen asymptotischen Sättigungsbereich nahe 100 %. Unter derart idealen Bedingungen ist das Regressionsmodell so robust, dass selbst signifikante geometrische Verzerrungen des Versuchsplans den Nachweis eines Effekts kaum gefährden. Für die Evaluation subtiler topologischer Schwachstellen ist ein solches Setup folglich inadäquat. Zudem stellen derart dominante Einflussgrößen in der Praxis der Zuverlässigkeitserprobung ohnehin selten die primäre Herausforderung dar. Vielmehr gilt es zumeist, schwache Degradationserscheinungen und sensible Interaktionen zu identifizieren, die sich nur knapp vom Systemrauschen abheben.

Um den isolierten Einfluss von Orthogonalitätsabweichungen - den spezifischen *Design-Penalty* - überhaupt quantifizierbar zu machen, wird der Arbeitspunkt der Simulation gezielt in einen kritischen Bereich verschoben und an den empirischen Grenzen der Sensitivitätsanalyse ausgerichtet. Da die Auswertung des Meta-Designs dem Messrauschen (ζ_g) einen dominierenden Einfluss auf die Modell-Power ($E = 1,99$) attestiert, wird das Basismodell am kritischen oberen Rand dieses Intervalls verankert: Bei einer fixierten Standardabweichung der Systemantwort von $\sigma = 5,0$ wird das Signal-Rausch-Verhältnis für die schätztechnisch anfälligen Terme zweiter Ordnung auf exakt $\text{SNR} = 1,20$ justiert ($|\beta_{11}| = |\beta_{22}| = |\beta_{12}| = 6,0$). Diese Parametrisierung zwingt das ideale Referenz-Design für die quadratischen Effekte und Wechselwirkungen exakt auf die steilste Flanke der sigmoidalen Trennschärfefunktion [28, 77], woraus eine empirische Basis-Trennschärfe von rund 70 % bis 80 % resultiert.

Gleichzeitig belegen die Screening-Ergebnisse, dass das relative Verhältnis der Effektstärken (ζ_f) die Trennschärfe hochgradig sensitiv steuert ($E = 2,53$). Unter Vorgriff auf das empirisch belegte *Sparsity of Effects Principle* [28] wird die *analytische Lupe* folglich hierarchisch asymmetrisch aufgeteilt: Während die Terme zweiter Ordnung den kritischen Schwellenwert (SNR) definieren, fließen die linearen Haupteffekte vom Betrag her proportional dominanter mit $\beta_1 = \beta_2 = 12,0$ ($\text{SNR} = 2,40$) in das Modell ein (vgl. Tabelle 5.5). Der Durchschnittswert der Konstanten ($\beta_0 = 24,0$) hebt die Systemantworten hierbei in einen anwendungsrelevanten positiven Be-

reich ($[0; 50]$). Die Wahl positiver Haupteffekte in Kombination mit negativen Krümmungstermen ist gezielt getroffen: Sie modelliert das in der **RSM** klassische Verhalten eines zu maximierenden Leistungsoptimums (analog zur Zuverlässigkeitstechnik z. B. Ausbeute oder Wirkungsgrad), welches durch Sättigungseffekte und antagonistische Wechselwirkungen bei extremen Faktorkombinationen physikalisch begrenzt wird.

Auf eine zusätzliche, stochastische Streuung der wahren Effektkoeffizienten (*Random Effects*) wird im Weiteren bewusst verzichtet. Wie die Sensitivitätsanalyse belegt, beeinflusst diese die Entdeckungswahrscheinlichkeit ohnehin nur marginal ($E = 0,52$). Eine methodische Integration würde die Untersuchung unnötig in einen *Random-Effects*-Ansatz überführen und die isolierte Evaluation rein geometrischer Design-Eigenschaften mathematisch verfälschen [28, 80].

In der Synthese eliminiert die Fixierung dieses künstlichen Arbeitspunkts jegliche statistischen Sättigungseffekte. Um bei der vergleichenden Gegenüberstellung der Design-Szenarien jedoch nicht nur die relative Abweichung der Trennschärfe ($\Delta power$) zu quantifizieren, sondern gleichzeitig den systematischen Schätzfehler (Bias) sowie die empirische Schätzvarianz (**MSE**) der Koeffizienten $\hat{\beta}$ valide zu beurteilen, ist eine iterative Auswertung zwingend erforderlich. Hierfür wird ein Monte-Carlo-Ansatz genutzt, der mittels einer strikten *Seed*-Fixierung deterministisch initialisiert wird [115]. Die Anwendung solch identischer Zufallszahlen (*Common Random Numbers*) über alle Szenarien hinweg stellt die notwendige methodische Kontrolle sicher: Sie eliminiert das stochastische Schwankungsrauschen zwischen den Simulationsläufen. Erst dadurch wird gewährleistet, dass jede beobachtete Varianzinflation (**VIF**) und jede messbare Abweichung in der Schätzgüte unmittelbar und unverfälscht auf den induzierten Orthogonalitätsverlust der jeweiligen Design-Matrix zurückzuführen ist.

Tabelle 5.5: Kalibrierte Startwerte und statistische Eigenschaften des additiven Normalverteilungs-Basismodells

Koeffizient	β_0	β_1, β_2	β_{11}, β_{22}	β_{12}	σ
Wahrer Wert	24,0	12,0	−6,0	−6,0	5,0
SNR	–	2,40	1,20	1,20	–

Quantitative Auswertung und explorative Optimalitäts-Analyse

Die Auswertung der definierten Praxis-Szenarien (**Fälle I-IV**) am kalibrierten, kritischen Arbeitspunkt ($SNR = 1,20$) offenbart eine hochgradig differenzierte Reaktion der klassischen Design-Metriken (Tabelle 5.6) und der numerisch ermittelten Schätzgüte. Zur detaillierten Evaluation wird diese Schätzgüte nachfolgend auf Basis der kombinierten Schätzvarianz (VIF in Tabelle 5.6 bzw. MSE in Tabelle B1 und Abbildung 5.2), dem systematischen Schätzfehler ($Bias$ in Tabelle 5.7) sowie der resultierenden Trennschärfe-Variation ($\Delta power$ in Tabelle 5.8) aufgeschlüsselt.

Ein erster Blick auf die topologischen und informationsbasierten Metriken aus Tabelle 5.6 offenbart physikalisch wie geometrisch plausible Muster:

- **Volumeneffekte und Prädiktionsgüte:** Kriterien wie die I - und D -Effizienz skalieren direkt mit der räumlichen Ausdehnung des Versuchsraums. So erzielt der nach außen gestreckte Shift (*Fall I*, +20 %) Bestwerte in der integrierten Prädiktionsvarianz mit $I_{eff} = 85,1 \%$ (Tabelle 5.6). Demgegenüber provozieren ungeplante Ausfälle periphere Informationsverluste. Bemerkenswert ist hierbei jedoch die topologische Sensitivität: Während der asymmetrische Entfall eines extremen Sternpunktes (*Fall IV: SP*) einen signifikanten Kollaps der I -Effizienz auf $I_{eff} = 69,0 \%$ provoziert, dämpft der Ausfall eines redundanten Zentralpunktes (*Fall IV: ZP*) die Vorhersagegüte keineswegs. Vielmehr steigt die SPV -normierte I_{eff} aufgrund des reduzierten Stichprobenumfangs N rechnerisch sogar leicht auf 85,7 % an. Dies belegt eindrücklich die statistische Ineffizienz reiner Basis- ZPs für den Bereich der fernen Extrapolation.
- **Topologische Warnsignale und blinde Flecken:** Eine starke *co-faktorielle Korrelation* (*Fall II, stark*) erzeugt einen statistischen blinden Fleck. Obwohl das globale Design-Volumen bei dieser Modifikation weitestgehend erhalten bleibt, schießt der A_2 -Indikator als Maß für die Nicht-Orthogonalität auf seinen Spitzenwert von 0,352. Die durch die parasitäre Abhängigkeit entstehenden Lücken im Parameterraum bestraft die an *Worst-Case*-Szenarien orientierte G -Effizienz mit einem drastischen Einbruch, während sich der reale Informationsverlust term-spezifisch in die betroffenen Koeffizienten verlagert.
- **Geometrische Selektivität der Varianzinflation:** Der VIF bildet den Orthogonalitätsverlust nicht global, sondern hochgradig *term-spezifisch* ab. Beim asym-

metrischen Sternpunkt-Ausfall (Fall IV: SP) greift die stringente Mathematik der isolierten Achsen: Da der zensierte SP exakt auf der x_1 -Achse liegt, leiden ausschließlich der zugehörige Haupteffekt $\hat{\beta}_1$ sowie der quadratische Term $\hat{\beta}_{11}$ unter spürbarer Varianzinflation. Die orthogonal dazu stehende x_2 -Achse bleibt von diesem topologischen Bruch vollkommen isoliert und unbeschadet.

Tabelle 5.6: Matriceigenschaften und Effizienzen zu Optimalitätskriterien der simulierten Störszenarien. Der VIF wird für alle Haupt- und quadratischen Terme dargestellt ($\hat{\beta}_0$ entfällt theoriekonform).

Szenario (Störfall)	A_2	Effizienzen [%]					VIF				
		A_{eff}	D_{eff}	G_{eff}	I_{eff}	V_{eff}	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	0,000	42,9	50,0	17,6	81,2	180,0	1,00	1,00	1,00	1,00	1,00
Fall I: Shift (−20 %)	0,037	40,3	47,0	15,9	76,0	181,7	1,04	1,00	1,00	1,04	1,00
Fall I: Shift (+20 %)	0,038	45,0	53,6	17,7	85,1	181,0	1,04	1,00	1,00	1,04	1,00
Fall I: FC	0,071	39,1	45,9	15,2	73,5	184,0	1,07	1,00	1,00	1,08	1,01
Fall II: Korrelation (leicht)	0,004	42,9	50,0	17,0	81,2	180,0	1,00	1,00	1,00	1,00	1,00
Fall II: Korrelation (stark)	0,352	42,5	51,3	13,9	80,3	183,5	1,16	1,07	1,23	1,18	1,07
Fall III: Scatter (±10 %)	0,007	43,8	51,5	16,6	83,0	180,2	1,00	1,00	1,00	1,00	1,00
Fall IV: SP	0,183	37,6	45,3	14,3	69,0	197,2	1,22	1,00	1,00	1,22	1,05
Fall IV: ZP	0,001	44,4	52,2	18,7	85,7	164,8	1,00	1,00	1,00	1,00	1,00

Der VIF schlägt die direkte Brücke zur absoluten Schätzvarianz, welche in Abbildung 5.2 über den MSE quantifiziert wird. Die Visualisierung zeigt das absolute Ausmaß der resultierenden Prognoseunsicherheit. Dabei fällt zunächst auf, dass der Wechselwirkungsterm $\hat{\beta}_{12}$ bereits im ungestörten Basisdesign (CCD) eine strukturell höhere Schätzvarianz aufweist ($MSE \approx 6,17$) als die rein quadratischen Terme ($MSE \approx 3,13$). Dies ist eine unvermeidbare topologische Eigenheit des CCD: Da die SPs strikt auf den Koordinatenachsen liegen (wobei der jeweils andere Faktor exakt Null ist), tragen sie systembedingt keinerlei Information zur Schätzung der Interaktion bei. Diese stützt sich stattdessen ausschließlich auf den faktoriellen Kern des Designs.

Die tatsächlichen, störungsinduzierten Ausreißer manifestieren sich jedoch exakt an den zuvor durch den VIF prognostizierten Schwachstellen. Der direkte Vergleich der Ausfallszenarien zeichnet ein für die Planungspraxis essenzielles Bild: Während die Zensierung des Zentralpunktes (Fall IV: ZP) mangels struktureller Varianzer-

höhung quasi unbemerkt verpufft (der MSE von $\hat{\beta}_{11}$ steigt lediglich marginal von 3,13 auf 3,24), treibt der asymmetrische Freiheitsgradverlust in *Fall IV: SP* den MSE massiv in die Höhe. Für den betroffenen Haupteffekt $\hat{\beta}_1$ (3,10 $\rightarrow$ 5,29) und die Krümmung $\hat{\beta}_{11}$ (3,13 $\rightarrow$ 5,46) entspricht dies einem drastischen Varianzanstieg von rund 70 % bis 75 % gegenüber dem fehlerfreien Referenz-Design.




Abbildung 5.2: Güte der Schätzer (MSE) am Arbeitspunkt $SNR = 1,20$. Geometrische Verzerrungen entladen sich primär in der Schätzvarianz, insbesondere beim Wegfall von Rand-Freiheitsgraden durch asymmetrische Ausfälle (*Fall IV: SP*).

Andererseits belegt die Auswertung die fundamentale Erwartungstreue des angewandten OLS -Schätzers: Trotz teils gravierender struktureller Abweichungen im Versuchsraum verharrt der relative systematische Schätzfehler (Bias) über alle Störscenarien und Koeffizienten hinweg im absoluten Promillebereich (vgl. Tabelle 5.7). Eine geometrische Verzerrung im CCD führt demnach nicht zu einer inhärent falschen, verschobenen Effekterkennung. Die Schätzungen der wahren physikalischen Koeffizienten bleiben im Mittel absolut korrekt und stabil (vgl. Abbildung 5.3), wenngleich ihre Vertrauensbereiche anwachsen.

Die hinreichende Dimensionierung von $n_{MC} = 1 \times 10^4$ Simulationsläufen zur Eliminierung des stochastischen Approximationsrauschens und zur Gewährleistung einer strikt reproduzierbaren Konvergenz wird dabei exemplarisch für den im Störfall orthogonal isolierten Koeffizienten $\hat{\beta}_2$ in Abbildung 5.4 visuell belegt. Ent-

Tabelle 5.7: Simulationsergebnisse: Relativer systematischer Schätzfehler (Bias) der einzelnen Koeffizienten in Prozent bezogen auf ihren Nominalwert bei $\text{SNR} = 1,20$.

Szenario (Störfall)	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	+0,05 %	−0,01 %	−0,06 %	−0,45 %	+0,17 %	+0,05 %
Fall I: Shift (−20 %)	+0,04 %	−0,00 %	−0,09 %	−0,06 %	−0,02 %	+0,31 %
Fall I: Shift (+20 %)	+0,01 %	−0,11 %	+0,05 %	−0,24 %	+0,08 %	−0,00 %
Fall I: FC	+0,08 %	+0,13 %	−0,02 %	−0,25 %	+0,13 %	−0,13 %
Fall II: Korrelation (leicht)	−0,08 %	+0,13 %	+0,08 %	−0,19 %	−0,03 %	−0,23 %
Fall II: Korrelation (stark)	−0,08 %	+0,01 %	−0,27 %	+0,55 %	−0,71 %	+0,17 %
Fall III: Scatter (± 10 %)	+0,02 %	+0,09 %	+0,19 %	+0,14 %	+0,10 %	+0,09 %
Fall IV: SP	−0,03 %	+0,14 %	+0,01 %	−0,56 %	−0,57 %	−0,07 %
Fall IV: ZP	−0,05 %	−0,13 %	−0,20 %	+0,01 %	+0,13 %	+0,07 %




Abbildung 5.3: Absolute Schätzwerte der Modellkoeffizienten für den Arbeitspunkt $\text{SNR} = 1,20$. Der Bias bleibt marginal; die OLS-Schätzung ist fundamental erwartungstreu.

sprechende Konvergenzplots der infizierten, stark streuenden Koeffizienten finden sich vergleichend im Anhang B.




Abbildung 5.4: Numerische Konvergenz am Beispiel des Schätzwertes zu $\hat{\beta}_2$ über die MCS-Iterationen.

Der resultierende **Einfluss auf die Trennschärfe** - in Tabelle 5.8 quantifiziert und in Abbildung 5.5 detailliert veranschaulicht - summiert die Effekte aus marginalem Bias und gesteigener Schätzvarianz (MSE) probabilistisch auf. Es resultiert folgendes praxisrelevantes Bild:

1. **Gutmütige Restriktionen (Scatter und ZP):** Eine ungenaue, stochastisch verzerrte Ansteuerung der Nenn-Koordinaten (Fall III) sowie der ungeplante Entfall eines Zentralpunktes (Fall IV: ZP) erzeugen kaum messbare Leistungseinbußen über alle Koeffizienten hinweg. Der punktuelle Trennschärfe-Verlust verbleibt hier zumeist auf dem Niveau des numerischen Rauschens ($\leq 1,3$ Prozentpunkte).
2. **Kritische Restriktionen für Terme höherer Ordnung (FC und asymmetrischer Ausfall):** Sobald die periphere Geometrie des Versuchsraums kompromittiert wird, leiden die quadratischen Terme signifikant. Selbst das noch symmetrische Zurückziehen aller SPs auf das physikalische Randniveau der Faktoren (FC, Fall I) generiert bereits einen Detektionsverlust von 6,7 Prozentpunkten der absoluten *power* bei den quadratischen Termen, wenngleich es

Tabelle 5.8: Simulationsergebnisse: Durchschnittliche Trennschärfe-Änderung ($\Delta power$) der Koeffizienten. Ein negatives Vorzeichen indiziert einen Verlust, ein positives Vorzeichen einen Gewinn an $power$ verglichen zur Referenz (Basis CCD)

Szenario (Störfall)	$power_{\beta_0}$	$power_{\beta_1}$	$power_{\beta_2}$	$power_{\beta_{12}}$	$power_{\beta_{11}}$	$power_{\beta_{22}}$
Referenz (Orthogonal)	—	—	—	—	—	—
Fall I: Shift (−20 %)	±0,0 %	−0,9 %	−0,0 %	±0,0 %	−4,5 %	−0,1 %
Fall I: Shift (+20 %)	−0,0 %	+0,3 %	−0,0 %	−0,0 %	+4,6 %	−0,1 %
Fall I: FC	±0,0 %	−1,4 %	−0,1 %	+0,1 %	−6,7 %	−0,2 %
Fall II: Korrelation (leicht)	±0,0 %	−0,1 %	−0,0 %	+0,1 %	+0,1 %	−0,0 %
Fall II: Korrelation (stark)	±0,0 %	−1,2 %	+0,3 %	+3,3 %	−3,1 %	−1,5 %
Fall III: Scatter (±10 %)	±0,0 %	−0,1 %	+0,4 %	+0,2 %	−1,2 %	+2,8 %
Fall IV: SP	±0,0 %	−4,4 %	−0,1 %	−0,3 %	−10,6 %	−1,5 %
Fall IV: ZP	−0,0 %	−0,3 %	−0,2 %	−0,8 %	−1,3 %	−0,9 %

die Haupt- und Interaktionseffekte nahezu unbeeindruckt belässt. Der vollständige, asymmetrische Entfall eines Sternpunktes (Fall IV: SP) führt unweigerlich zu den gravierendsten Schäden in den isolierten Störszenarien. Die Varianzerhöhung an den Rändern des Parameterraums resultiert im stärksten Einbruch, welcher spezifisch zur Dimension $\hat{\beta}_{11}$ einen Verlust von 10,6 Trennschärfe-Punkten sowie $\hat{\beta}_1$ einen Abzug von 4,4 Prozentpunkten kostet. Dies korrespondiert konsistent mit der bereits in Tabelle 5.4 nachgewiesenen Sensitivität: Eine systematische Ausdünnung peripherer Stützstellen provoziert primär bei den Krümmungseffekten (bis zu 13,9 Prozentpunkte Verlust) einen fundamentalen Zusammenbruch der Detektionswahrscheinlichkeit.

Zur Verifikation der methodischen Transparenz ist das korrespondierende numerische Konvergenzverhalten der empirischen Trennschärfe über die Simulationsläufe - wiederum exemplarisch für β_2 - in Abbildung 5.6 dokumentiert. Ergänzend sind die resultierenden Wahrscheinlichkeitsdichten der Signifikanztests (p -Wert) für alle Fälle in Abbildung 5.7 grafisch aufbereitet.

Zur abschließenden Synthese wird die Korrelation zwischen den *a priori* Design-Metriken und dem dynamisch simulierten Trennschärfe-Verlust $\Delta power$ analysiert. Explizit herangezogen werden hierfür der topologische Indikator A_2 , die prädiktive




Abbildung 5.5: Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der simulierten Störszenarien ($\text{SNR} = 1,20$).




Abbildung 5.6: Numerische Konvergenz der Trennschärfe über die Simulationsläufe am Beispiel von β_2 .




Abbildung 5.7: p -Wert Histogramm für den Signifikanztest am Beispiel von β_2 . Die kumulierte Häufigkeit links der $\alpha = 0,05$ -Schranke entspricht der berechneten $power$.

I_{eff} sowie die koeffizienten-spezifische Schätzvarianz MSE . Metriken wie der Bias scheiden aufgrund ihrer nachgewiesenen Unempfindlichkeit als Prädiktoren aus. Die D -Optimalität bleibt in dieser korrelativen Betrachtung ebenfalls unberücksichtigt, da sie als reines Volumenmaß die entscheidende interne Strukturverschiebung (Varianz-Hebelwirkung) unzureichend abbildet. Diese methodische Einordnung wird durch Untersuchungen von Rittmaier et al. [96] gestützt: Die Autoren belegen durch simulative Analysen, dass computergenerierte Optimalpläne unter Restriktionen zwar prinzipielle Vorteile bieten, ihre statistische Trennschärfe jedoch extrem sensibel und divergierend auf das jeweils gewählte Optimalitätskriterium (A -, D - oder V -Optimalität) reagiert. Ein rein volumenbasiertes Kriterium wie die D -Optimalität liefert demnach keinen deterministischen Garant für die Detektionssicherheit spezifischer Modelleffekte in verzerrten Topologien.

Abbildung 5.8 fasst diese korrelativen Beziehungen zusammen und bestätigt die in [96] identifizierte Kausalität zwischen spezifischen Optimalitätszielen und der resultierenden Schätzgüte nun quantitativ für asymmetrisch gestörte Versuchspläne. Während der rein algebraische A_2 -Indikator aufgrund der oftmals nichtlinearen Schwellenwert- und Sättigungseffekte der Sigmoidalfunktion von Trennschärfe-Verlusten nur ein extrem schwaches Bestimmtheitsmaß als Prädiktor liefert, erweisen

sich exakt jene Metriken als hochgradig robust, die direkt mit den spezialisierten Optimalitätskriterien korrespondieren: Einerseits fungiert der **MSE** infolge der zugrundeliegenden Prüfmathematik (in welcher die Teststatistik invers proportional zu $1/\sqrt{\text{MSE}}$ skaliert) als nahezu perfekter und deterministischer Prädiktor für den Trennschärfe-Erhalt isolierter Koeffizienten. Dies untermauert das Paradigma der A-Optimalität, deren primäre Zielfunktion exakt in der Minimierung dieser durchschnittlichen Koeffizientenvarianz liegt [28, 96]. Andererseits erweist sich die I_{eff} als hochgradig verlässliches globales Maß. Da sie - konzeptionell als kontinuierliches Äquivalent zur punktbasierten V-Optimalität [96] - die **SPV** über den gesamten Versuchsraum integriert, bewertet sie direkt die durchschnittliche Auswirkung der Varianzinflation auf die Prognosegüte. Diese Synthese schließt den methodischen Kreis: Um die Identifikation spezifischer Effekte (*power*) bei Design-Störungen abzusichern, ist die Betrachtung der isolierten Schätzvarianz (**MSE**, assoziiert mit A-Optimalität) zwingend erforderlich. Steht hingegen die belastbare Extrapolation im Fokus der Lebensdauererprobung, muss die Auslegung zwingend über ein prädiktives Maß wie die **SPV** beziehungsweise I_{eff} (assoziiert mit V-Optimalität) erfolgen.




Abbildung 5.8: Korrelation zwischen a priori Design-Metriken und dem resultierenden Trennschärfe-Verlust in den Störszenarien: Der **MSE** übersetzt den geometrischen Fehler am direktesten in die probabilistische Trennschärfe.

5.2.4 Fazit: Statistische Effektivität als Basis der explorativen Versuchsplanung

Die simulativen Analysen unterstreichen eine ausgeprägte, jedoch hochgradig term-spezifische Resilienz des **CCD** gegenüber geometrischen und anlagenbedingten Abweichungen. Während massive topologische Brüche - insbesondere der asymmetrische Wegfall von Extremstellen (*Fall IV: SP*) - eine eindeutig messbare Aufweitung der Schätzvarianz (**MSE**) provozieren, offenbart sich eine für die Versuchsplanung elementare Dichotomie: Die Detektion linearer Haupteffekte erweist sich gegenüber geometrischen Störungen als erstaunlich robust, wohingegen die für die Modellkrümmung essenziellen quadratischen Terme hochsensibel auf periphere Informationsverluste reagieren. Die Trennschärfe-Einbußen bei den Haupteffekten verbleiben über fast alle isolierten Störszenarien hinweg auf einem absolut tolerierbaren Niveau (zumeist deutlich unter 5 Prozentpunkten), während die quadratischen Effekte signifikante Einbrüche (bis zu 13,9 Prozentpunkte bei systematischer Ausdünnung, vgl. Tabelle 5.4) verzeichnen.

In Kombination mit der nachgewiesenen fundamentalen Erwartungstreue des **OLS**-Schätzers (vernachlässigbarer *Bias*) ergibt sich genau aus dieser term-spezifischen Robustheit ein entscheidender planerischer Spielraum: Die bewusste Reduktion oder Inkaufnahme moderater Einbußen in der Orthogonalität gefährdet die grundlegende Identifikation der primären Einflüsse nicht. Sie schafft stattdessen ein wertvolles **geometrisches Gestaltungsbudget**, da redundante Stützstellen zur operativen Optimierung von Prüfzeiten und Ressourcen freigegeben werden können.

Dass der Fokus im weiteren methodischen Verlauf dieser Arbeit konsequent von der reinen Detektionswahrscheinlichkeit (*power*) der Haupteffekte hin zur räumlichen Verteilung der Schätzpräzision in der Peripherie verschoben wird, legitimiert sich durch exakt dieses Erkenntnis. Die algorithmische Güte eines **EoL**-Tests ist untrennbar mit der Struktur der Prädiktionsvarianz im Versuchsraum verknüpft, welche maßgeblich durch die prädiktiven Metriken (*I_{eff}* und **MSE**) abgebildet wird. Im Kontext der **ALT** gewinnt dies eine existenzielle Bedeutung: Da Lebensdauermodelle naturgemäß auf die weite Extrapolation in den späteren Einsatzbereich (*Use-Space* bzw. *Field-Space*) angewiesen sind, wirkt die im Versuchsraum (*Design-Space*) vorliegende Varianz der Prädiktion - insbesondere getrieben durch unsichere Krümmungseffekte - als geometrischer Verstärker für Unsicherheiten in der Ferne.

Für die holistische Effizienzbewertung multivariater Lebensdauertests bedeutet dies: Sobald durch die fundamentale topologische Robustheit des Designs die grundlegende Identifikation der Haupteffekte gesichert ist, wird die zielgerichtete Kontrolle der SPV-Struktur zum primären Stellhebel der Versuchsökonomie. Die Minimierung der Prognoseunsicherheit auf dem Extrapolationspfad ist kein rein akademisches Gütemaß, sondern die unabdingbare Voraussetzung für eine belastbare und wirtschaftlich vertretbare Lebensdauerprognose durch ALT. Im Folgenden wird das aus topologisch unkritischen Zentral- und Sternpunkten freigewordene Gestaltungsbudget daher proaktiv genutzt, um diese Stützstellen gezielt in Richtung des anvisierten Feldbereichs zu verschieben. Diese asymmetrische, zielgerichtete Versuchsplanungsstrategie wird im weiteren Verlauf unter dem Akronym EmALT eingeführt. Positionsoptimierte Ankerpunkte investieren das gewonnene Budget exakt dort, wo es zur Stützung der kritischen Modellkrümmung und der Extrapolationsgüte gefordert wird, während die Grundstruktur des CCD als stabiler Identifikationskern erhalten bleibt. Ein *a priori* durchgeführter Optimierungsprozess der Design-Matrix erlaubt es, die Stützstellen sukzessive in Richtung des anvisierten Feldbereichs zu verschieben und die SPV entlang des Extrapolationspfads gezielt zu minimieren wie in nachfolgendem Abschnitt 5.3 beschrieben.

5.3 Adaptive Versuchsplanung zur Extrapolationsabsicherung

In der Praxis werden ALTs naturgemäß im Bereich hoher Belastungen durchgeführt - etwa in den nordöstlichen Quadranten des Parameterraums -, um Ausfälle in vertretbarer Prüfzeit zu erzwingen. Das eigentliche Ziel der Modellbildung bleibt jedoch die verlässliche Prognose unter moderaten Einsatzbedingungen im Feldbereich, der meist im südwestlichen Quadranten angesiedelt ist. Anstatt das in Abschnitt 5.2 erarbeitete geometrische Budget rein zur passiven Kostensenkung zu nutzen, wird dieses Gestaltungsbudget proaktiv verwertet: Die durch die nachgewiesene Robustheit zur Disposition stehenden Stützstellen - etwa substituierbare ZPs oder für den Schädigungsmechanismus irrelevante Sternpunkte (SPs) - werden gezielt in Richtung des anvisierten Feldbereichs verlagert. Dieser strategische *Brückenbau im Parameterraum* erzeugt asymmetrische APs, die das Regressionsmodell auf dem Extrapo-

lationspfad empirisch absichern, während der Gesamtversuchsumfang N des CCD unverändert bleibt [117, 118, 119]. Das gewählte RSD bleibt dabei als stabiler Kern erhalten und gewährleistet weiterhin die notwendige Identifikationsgüte für die Haupteffekte und Interaktionen. Zudem erfolgt nach Vorbild der sequenziellen Versuchsplanung aus Abschnitt 2.2.4 eine Erweiterung der Augmentierung sowie eine iterative, varianzgetriebene Verfeinerung der Stützstellenpositionen, um die SPV im kritischen Extrapolationspfad sukzessive zu optimieren [119]. Um den Leistungsgewinn dieser gerichteten Design-Manipulationen objektiv bewerten zu können, wird die SPV aus ihrer globalen Integralbetrachtung gelöst. Es bedarf ihrer Anwendung als lokale Maßzahl, die die Vorhersageunsicherheit gemäß Gleichung 2.32 punktgenau im kritischen Betriebspunkt quantifiziert.

5.3.1 Die Scaled Prediction Variance als Prognosemetrik

Zur Quantifizierung der ortsabhängigen Prognosegüte dienen sowohl die SPV für effizienzbasierte Varianzbewertungen als auch die UPV für die Bestimmung der absoluten Vorhersageunsicherheit. Da bei einer reinen geometrischen Umverteilung der Stützstellen der Stichprobenumfang N konstant bleibt, verhalten sich SPV und UPV streng proportional zueinander. Eine topologische Optimierung der Effizienzmetrik (SPV) führt in diesem Szenario zwangsläufig zu einer formgleichen Verbesserung der absoluten physikalischen Vorhersagepräzision (UPV).

Um die Auswirkungen von Design-Modifikationen speziell auf die Extrapolationsfähigkeit zu bewerten, erweist sich die Untersuchung mittels VDG und FDS jedoch als nur bedingt geeignet. Dies lässt sich anhand der Zentralpunkt-Reduktion (Fall IV: ZP) belegen: werden die ZPs von $n_{ZP} = 5$ auf beispielsweise $n_{ZP} = 3$ reduziert, ist im Zentrum $(0;0)$ lediglich ein marginaler Varianzanstieg zu verzeichnen. Gleichzeitig wirkt sich diese Modifikation nicht negativ auf die Peripherie aus. Wie Abbildung 5.9 zeigt, bleibt die SPV im Vergleich zum Basis-CCD im Extrapolationsraum nahezu unverändert oder sinkt aufgrund der Normierung mit dem geringeren N sogar ab. In der äußeren Sphäre ($r = \sqrt{2}$) reduziert sich die SPV dadurch um rund 15 % von 8,125 auf 6,875. Entgegengesetzt dazu führt eine Erhöhung der ZPs ($n_{ZP} > 5$) zu einem unvorteilhaften Anstieg der skalierten Varianz in der Peripherie. Die Reduktion des Grenznutzens lässt sich anhand des Grenzwerts der SPV im Versuchszentrum ($x_0 = 0$) formal belegen. Unter der Prämisse, dass die Schätzva-




Abbildung 5.9: Vorhersagegüte bei Variation der ZP-Anzahl n_{ZP} für einen CCD mit $k = 2$ Faktoren.

rianz im Ursprung orthogonaler Versuchspläne primär durch die mittlere Varianz der Zentralpunkte determiniert wird ($\text{Var}(\hat{y}) \approx \sigma^2/n_{ZP}$), ergibt sich für ein zweidimensionales CCD mit einer Struktur aus $n_F + n_{SP} = 8$ Randpunkten und einer zunehmenden Anzahl an Zentralpunkten n_{ZP} :

$$\begin{aligned}
 \lim_{n_{ZP} \rightarrow \infty} SPV(0) &= \lim_{n_{ZP} \rightarrow \infty} \frac{N \cdot \text{Var}(\hat{y}(0))}{\sigma^2} = \lim_{n_{ZP} \rightarrow \infty} \frac{(8 + n_{ZP}) \cdot \frac{\sigma^2}{n_{ZP}}}{\sigma^2} \\
 &= \lim_{n_{ZP} \rightarrow \infty} \left(\frac{8}{n_{ZP}} + 1 \right) = 1
 \end{aligned} \tag{5.3}$$

Dieses asymptotische Konvergenzverhalten liefert den Nachweis, dass die SPV im Zentrum am absoluten Minimum von 1 stagniert. Eine Erhöhung der Zentralpunktanzahl über $n_{ZP} \approx 3$ hinaus erweist sich als statistisch redundant für die globale Modellanpassung und insbesondere für die ferne Extrapolation. Folglich ist die Reallokation dieser Versuchsressourcen für das geometrische Gestaltungsbudget methodisch begründet.

Demgegenüber nehmen die Sternpunkte (Fall IV: SP) eine kritischere Rolle ein, da sie die Varianztopologie in der Peripherie dominieren. Wird ein Sternpunkt zensiert oder ausgelassen (hier exemplarisch im Hochlastbereich), wächst die SPV in dieser Region massiv an. Infolgedessen wird ein wesentlicher Teil des Versuchs-

raums durch unverhältnismäßig große Varianzwerte dominiert (vgl. **FDS** in Abbildung 5.10a). Diese asymmetrische Störung erzeugt jedoch eine komplexe, anisotro-




Abbildung 5.10: Vorhersagegüte bei Variation der SP-Anzahl n_{SP} für einen CCD mit $k = 2$ Faktoren. SPV-Werte für verschiedene Varianten entfallener Sternpunkte. Abbildung 5.10b zeigt den Fall des vollständigen Entfalls der Sternpunkte $(\alpha_D; 0)$ und $(0; \alpha_D)$ im Hochlastbereich.

pe Varianzstruktur, an der die klassische **VDG**-Darstellung fundamental scheitert. Abbildung 5.10b verdeutlicht diesen methodischen Informationsverlust: Zwar ist eine extreme radiale Aufweitung des Streubereichs (Min-Max-Bänder) erkennbar, die exakte geometrische *Richtung* dieser fatalen Varianzspitzen bleibt durch die sphärische Aggregation jedoch vollständig verborgen. Die wahre Ausprägung dieser Asymmetrie offenbart erst der dreidimensionale Konturverlauf in Abbildung 5.11. Aus ingenieurwissenschaftlicher Perspektive ist eine solche Richtungsabhängigkeit hochgradig kritisch, da sie die Vorhersagegüte entlang des maßgeblichen Extrapolationspfads unbemerkt zerstören kann. Für die Zuverlässigkeitsplanung resultieren hieraus drei zwingende Paradigmen:

1. Lokale Fehlstellen in der Versuchsmatrix prägen sich unmittelbar als massiv divergierende Varianzspitzen (*Blind Spots*) in exakt jener topologischen Himmelsrichtung der fehlenden Stützstelle aus.
2. Die Prognosegüte im fernen Feldbereich verhält sich in asymmetrischen Designs hochgradig richtungssensitiv; pauschale Rückschlüsse über die radiale




Abbildung 5.11: Dreidimensionale Darstellung der **SPV** und zugehöriger Konturverlauf für ein beispielhaft asymmetrisch manipuliertes Versuchsdesign: es entfallen $(0; \alpha_D)$ und $(\alpha_D; 0)$ eines **CCD** mit $k = 2$ Faktoren.

Extrapolationsfähigkeit mittels **VDG** oder **FDS** sind mathematisch unzulässig und industriell fahrlässig.

3. Sphärisch mittelnde Visualisierungen maskieren die erfolgskritische Richtungsabhängigkeit vollständig und deuten lediglich global auf die Existenz von Streuungen hin.

Für die effiziente Auslegung multivariater **ALT**-Szenarien erzwingt dieses Defizit die Entwicklung eines spezialisierten Bewertungswerkzeugs, welches die **SPV** exakt entlang des physikalischen Lastpfads quantifiziert.

5.3.2 Richtungsabhängige Bewertung: Der Extrapolation Variance Graph (EVG)

Wie aus den vorherigen Überlegungen hervorgeht, verliert die **SPV**-Topologie durch asymmetrische Modifikationen (wie die Verschiebung oder Streichung einzelner Versuchspunkte aus *Fall I*, **SP** und **ZP**) unweigerlich ihre konzentrische Rotations-symmetrie. Die Prädiktionsvarianz (**SPV** sowie **UPV**) divergiert folglich richtungs-

abhängig. Für die gezielte Extrapolation einer Lebensdauer- bzw. Zuverlässigkeitsprognose auf einen fernen Betriebspunkt im Feldbereich (*Field-Space*) ist daher nicht die durchschnittliche Varianz über alle Winkel entscheidend, sondern exakt die Entwicklung entlang des Vektors, der das Design-Zentrum mit diesem Zielpunkt verbindet. Da klassische Visualisierungswerkzeuge wie der VDG (vgl. Abbildung 5.10b) lediglich sphärische Mittel- und Extremwerte berechnen, bleiben sie für diese tatsächliche geometrische Ausrichtung der Varianz blind.

Um diesen *Blind Spot* in der Interpretationsfähigkeit der Prädiktionsvarianz und somit der Effektivität des Versuchsplans aufzulösen und asymmetrische Anpassungen gezielt quantifizieren zu können, entwickelten Arndt und Dazer [119] den EVG. Dieser transformiert die Fragestellung: Anstatt die SPV konzentrisch zu mitteln, wird sie ausschließlich entlang eines spezifischen, normierten Richtungsvektors $\vec{e}$ in Abhängigkeit des radialen Abstands r analysiert. Mathematisch wird diese richtungsabhängige Prädiktionsvarianz - im Folgenden als $v(r, \vec{e})$ bezeichnet - wie folgt definiert:

$$v(r, \vec{e}) = N \cdot [\mathbf{x}_0(r, \vec{e})]' \mathbf{M}^{-1} [\mathbf{x}_0(r, \vec{e})] \quad (5.4)$$

Die Auswertungsfunktion $\mathbf{x}_0(r, \vec{e})$ transformiert den abgetasteten Koordinatenpunkt $r \cdot \vec{e}$ in den korrespondierenden Modellvektor, welcher exakt auf die Polynomstruktur der Informationsmatrix $\mathbf{M}$ expandiert wird. Dadurch wird die Varianz gezielt entlang der kritischen Extrapolationsachse $\vec{e}$ hin zum Prognosepunkt auswertbar. Gleichzeitig bleibt die Methodik flexibel anwendbar für ingenieurstechnisch relevante Stellen im Parameterraum, etwa zur Untersuchung spezifischer Randbereiche des Betriebsraums. Dieser mathematische Zusammenhang befähigt zu einer weitreichenden Optimierungsstrategie: Um die Varianzdivergenz auf der kritischen Extrapolationsachse abzustützen, wird das geometrische Gestaltungsbudget gezielt umgewidmet. Dieses setzt sich aus obsoleten Stützstellen zusammen - beispielsweise einem substituierbaren ZP ($n_{\text{ZP}} = 1$) sowie entfallenen Sternpunkten aus dem Hochlastbereich, wie $(0; \alpha_D)$ und $(\alpha_D; 0)$. Diese Versuchspunkte fungieren fortan als Extrapolations-APs. Soll die skalierte Vorhersagevarianz $v(r_{\text{fix}}, \vec{e})$ in einem spezifischen Prognosepunkt minimiert werden, lässt sich die Ermittlung der optimalen AP-Allokation algorithmisch als diskretes Suchproblem formulieren. Für eine gegebene Anzahl freier Stützstellen n_{AP} (im vorliegenden Visualisierungsbeispiel $n_{\text{AP}} = 3$) wird die Designmatrix um die Vektoren potenzieller APs aus der Kandida-

tenmenge Ω erweitert. Da Prüfstandsrestriktionen eine punktgenaue Ansteuerung des theoretischen Optimums in der Praxis oft verhindern, identifiziert der Algorithmus jene Teilmenge des Parameterraums, in der eine Platzierung der Ankerpunkte die resultierende Varianz unterhalb einer definierten Toleranzschranke hält. Dieser Bereich wird über eine relative Toleranzmarge q (beispielsweise ein Aufschlag von 5 % auf das absolute Minimum, $q = 0,05$) definiert:

$$\mathcal{X} = \{x_{AP,i} \in \Omega \mid v(r_{\text{fix}}, \vec{e}) \leq \min(v) \cdot (1 + q)\} \quad (5.5)$$

Die Menge dieser zulässigen Koordinaten spannt die sogenannte **Anker-Exposition** (*Exposure-Area*) $\mathcal{X}$ auf. Jede physikalisch realisierbare Setzung der drei umgewidmeten Versuchspunkte innerhalb dieses Toleranzfeldes garantiert dem Versuchsplanner, dass das Regressionsmodell auf dem Extrapolationspfad empirisch hochgradig effizient verankert wird. Gleichzeitig bleibt ausreichend Flexibilität für die technische Umsetzung am Prüfstand gewahrt. Abbildung 5.12 illustriert diese Methodik exemplarisch: Das unveränderte Basis-CCD wird um drei strategisch investierte Extrapolations-APs im südwestlichen Quadranten erweitert. Die grau hinterlegte Anker-Exposition markiert dabei exakt jenen Parameterbereich, in dem eine beliebige Platzierung dieser APs die Prädiktionsvarianz im anvisierten Prognosepunkt $(-0,7; -1,9)$ zuverlässig auf den definierten Schwellenwert limitiert. Werden, wie in diesem Beispiel, konkrete Ankerpunkte identifiziert und fixiert, lässt sich das resultierende asymmetrische Design zur Überprüfung in einem 3D-Konturplot visualisieren (vgl. Abbildung 5.13). Beispielhaft werden die APs an dieser Stelle sowie in den nachfolgenden Abschnitten auf die Koordinaten $(-0,85; -2,60)$, $(-1,10; -2,35)$ und $(-0,85; -2,35)$ fixiert und als Design-Layout EmALT evaluiert. Hierbei wird deutlich, wie die gesetzten APs die Varianztopologie im Zielquadranten eindrücken und den divergierenden Anstieg der SPV gezielt dämpfen.

Der quantitative Nutzen dieser gezielten topologischen Manipulation manifestiert sich abschließend in der direkten Gegenüberstellung des klassischen VDG mit dem neu eingeführten EVG (vgl. Abbildung 5.14). Wird das EmALT-Design konventionell über den VDG evaluiert, maskiert dessen sphärische Mittelung den lokalen Informationsgewinn nahezu vollständig; das Design erscheint hierdurch fälschlicherweise kaum vorteilhafter als der Standard. Der EVG quantifiziert hingegen den tatsächlichen, zielgerichteten Erfolg der Modifikation: Durch die explizite Auswer-




Abbildung 5.12: Versuchsraum-Topologie: Das Basis-Design (CCD) wird durch strategische Extrapolations-APs (innerhalb der Exposure-Area) in Richtung des fernen Feld-Betriebspunktes (Ziel-Vektor) erweitert.




Abbildung 5.13: Dreidimensionale Darstellung der SPV und zugehöriger Konturverlauf für ein asymmetrisch manipuliertes Versuchsdesign: Das modifizierte CCD ($k = 2$) beinhaltet drei APs zur Stützung des südwestlichen Quadranten.

tung exakt entlang des Extrapolationsvektors $\vec{e}$ wird die **SPV** richtungsabhängig bis in den fernen Prognosepunkt aufgeschlüsselt. Hierbei wird ersichtlich, dass die strategisch platzierten Ankerpunkte (**APs**) einen markanten Sattelpunkt im radialen Varianzanstieg erzwingen. Diese topologische Stützung reduziert die Vorhersageunsicherheit auf dem Extrapolationspfad im Vergleich zum starren Standard-Design massiv.




Abbildung 5.14: Der klassische **VDG** verschleiert den lokalen Design-Nutzen des um **APs** modifizierten **CCD** durch radiale Mittelung. Der **EVG** belegt hingegen die signifikante **SPV**-Reduktion zielgerichtet entlang des Extrapolationsvektors zum Prognosepunkt.

Diese richtungsabhängige Varianzdämpfung erbringt den formalen Nachweis, dass eine gezielte Abkehr von strikter geometrischer Symmetrie im Kontext von Lebensdauerversuchen hochgradig effizient ist. Das durch topologische Ausdünnung gewonnene Gestaltungsbudget wird folglich nicht als passive Kosteneinsparung verbucht, sondern proaktiv zur Sicherstellung einer belastbaren Prognosegüte im Feldbereich reinvestiert.

5.4 Kostenstruktur der Lebensdauererprobung

Während Abschnitt 5.2 nachwies, dass die inhärente topologische Resilienz klassischer Versuchspläne ein wertvolles geometrisches Gestaltungsbudget freisetzt, de-

monstrierte Abschnitt 5.3 die proaktive Reinvestition dieses Budgets: Die zielgerichtete Allokation asymmetrischer Ankerpunkte minimiert die Prädiktionsvarianz im Extrapolationsraum signifikant. Die bisherige Evaluierung fokussierte sich dabei primär auf die **statistische Effektivität** der Versuchsdesigns - also auf deren fundamentale methodische Fähigkeit, die wahren physikalischen Zusammenhänge unverfälscht (*Bias*, *MSE*, Optimalitäten) und mit der geforderten Nachweissicherheit (*power*) zu identifizieren. Statistische Effektivität bildet jedoch lediglich die unabdingbare Grundvoraussetzung für die industrielle *EoL*-Versuchsplanung. Ein effektiver Versuchsplan wird in der Praxis erst dann zu einem **effizienten** Versuchsplan, wenn er die geforderten statistischen Zielvorgaben unter minimalem Ressourceneinsatz und zwingend innerhalb eines limitierten Zielbudgets erreicht. Effizienz definiert sich folglich direkt über das Verhältnis zwischen der algorithmischen Leistungsfähigkeit (statistische *KPIs*) und den real verursachten experimentellen Aufwänden.

Um die ganzheitliche Leistungsfähigkeit adaptiver Versuchsplan-Modifikationen bewerten zu können, bedarf es demnach zwingend einer komplementären ökonomischen Betrachtung. Nur wenn die methodischen Gewinne der Extrapolationsabsicherung mit den tatsächlichen Prüfkosten ins Verhältnis gesetzt werden, lässt sich die übergeordnete Forschungsfrage objektiv beantworten: *Wie viel Prädiktionsgüte ist finanzierbar?*

Zu diesem Zweck wird nachfolgend die Struktur eines Modells eingeführt, welches die monetären Aufwände der experimentellen Durchführung im *DoE* systematisch erfasst und bilanziert. Die methodische Grundlage hierfür bildet das in Arndt und Dazer [119] publizierte Kostenmodell für multivariate Lebensdauertests. An dieser Stelle werden zunächst die zugrundeliegenden Kostenpositionen, deren funktionale Zuordnung sowie die strukturellen Interdependenzen des Modells grundlegend definiert. Die detaillierte quantitative Auswertung dieses Modells erfolgt im Rahmen der Gesamtbewertung in Abschnitt 5.5, sobald die stochastischen Eigenschaften realer Lebensdauerdaten in die Betrachtung integriert sind.

Auch bei einer vorab fest definierten Anzahl an Versuchspunkten (N) und vorgegebenen Replikationen hängen die realen Versuchskosten maßgeblich von den individuellen Laufzeiten t_i der Prüflinge ab. Dies gilt insbesondere für *EoL*-Untersuchungen, bei denen Prüflinge oftmals sequenziell und bis zum Ausfallereignis unter stark variierenden Lastniveaus getestet werden. Um diese Aufwände generisch

und unabhängig vom spezifischen Prüflingstyp bilanzieren zu können, werden die Gesamtkosten C_{Σ} in drei wesentliche Hauptdomänen unterteilt [119]:

1. **Umgebungskosten C_A (*Ambient Conditions*):** Diese statische Domäne bündelt die standort- und laborbezogenen Bereitstellungskosten C_L , wie beispielsweise allgemeine Aufwände für die Laborinfrastruktur, den Flächenbedarf oder die grundlegende Raumklimatisierung.
2. **Prüfstandskosten C_T (*Test Equipment*):** Hierunter fallen die anlagenspezifischen Ausrüstungs- und Investitionskosten. Diese setzen sich primär aus der grundlegenden Prüfstandshardware C_B sowie der geforderten Güte der eingesetzten Messtechnik C_I und Steuerungstechnik C_C zusammen. Ein strategisches Absenken der geforderten Ansteuergenauigkeit (und die damit verbundene Inkaufnahme von Orthogonalitätsabweichungen, vgl. in Abschnitt 5.2.3 Scatter-Effekte in Fall III) würde sich hier direkt in signifikant reduzierten Hardware- und Investitionskosten niederschlagen.
3. **Laufende Durchführungskosten C_S (*Size of Testing*):** Diese hochgradig variable Kostengruppe skaliert direkt mit der zeitlichen Dauer und dem physikalischen Umfang der Versuchsreihe. Sie umfasst die kontinuierlichen Personalkosten C_O , die Aufwände für Hilfs- und Betriebsstoffe C_H , den lastabhängigen Energieverbrauch C_E sowie die belastungs- und zeitproportionalen Instandhaltungskosten C_M .

Das zugrundeliegende strukturelle Wirknetz dieser Kostenpositionen ist in Abbildung 5.15 visualisiert. Es verdeutlicht die Interdependenzen der Domänen und zeigt auf, wie die einzelnen Faktoren methodisch aggregiert werden, um die designspezifischen Gesamtkosten C_{Σ} abzuleiten. Um die theoretischen Relationen dieser Kostendomänen in einen ingenieurspraktischen Kontext zu setzen, können für typische EoL-Prüfszenarien im Maschinen- und Automobilbau charakteristische Annahmen getroffen werden. Die Investitionskosten für derartige Anlagen (C_T) belaufen sich branchenüblich auf mittlere bis hohe sechsstelligen Beträge, welche kalkulatorisch zumeist über eine Nutzungsdauer von sechs bis acht Jahren abgeschrieben werden [120]. Trotz dieser substanziellen Fixkosten verdeutlicht die praxisnahe Aufschlüsselung die absolute Dominanz der laufenden Durchführungskosten (C_S) bei




Abbildung 5.15: Struktur des Kostenmodells zur Berechnung der Gesamtkosten C_Σ als Funktion der Versuchsplan-Implementierung, identifizierter Kostenfaktoren sowie zufallsbehafteter Versuchslaufzeiten t_i (in Anlehnung an [95]).

EoL-Untersuchungen: Durch die inhärente Auslegung auf Dauerlauf - oftmals im 24/7-Betrieb mit Auslastungen von weit über 4.000 Betriebsstunden pro Jahr - degeneriert der Anteil der reinen Anlagenabschreibung pro Betriebsstunde auf einen marginalen Bruchteil der Investitionssumme.

Die tatsächliche Kostendynamik wird stattdessen von zwei operativen Hebeln determiniert: Erstens skaliert der lastabhängige Energieverbrauch C_E proportional mit den Laufzeiten t_i . Insbesondere bei kombinierten Umwelt- und Lastkollektiven (beispielsweise bei zyklischer thermischer Konditionierung gepaart mit hohen Antriebsleistungen) übersteigen die stündlichen Energiekosten die kalkulatorische Anlagenabschreibung oftmals signifikant. Zweitens definieren die Personalkosten C_O eine starke Asymmetrie: Während hochgradig automatisierte Dauerläufe personell lediglich für das initiale Rüsten der Prüflinge ins Gewicht fallen, treiben kurze, interaktionsintensive Versuchsläufe den effektiven Stundensatz durch den hohen Rüst- und Betreuungsaufwand massiv in die Höhe.

Neben diesen primären Treibern vervollständigen drei weitere Positionen die Bilanzierung, deren Charakteristika für das Gesamtmodell essenziell sind: Die Instandhaltungskosten (C_M) setzen sich typischerweise aus einem fixen Präventivanteil für zyklische Kalibrierungen und einem stark beanspruchungsabhängigen Verschleißanteil (beispielsweise für adaptive Sensorik oder mechanische Vorrichtungen) zusammen [121, 122]. Hilfs- und Betriebsstoffe (C_H), wie Schmier- und Kühlmittel, verhalten sich zumeist linear zur Versuchsdauer, nehmen jedoch monetär oft eine untergeordnete Rolle ein. Die Umgebungskosten (C_A) hingegen bilden den statischen Sockelbetrag: Sie werden in der Regel nach dem Verursacherprinzip über den Flächenbedarf des Prüfstandes umgelegt und verhalten sich unabhängig vom aktuellen Rüstzustand oder der Auslastung [123].

Tabelle 5.9 fasst diese ingenieurspraktischen Größenordnungen zusammen. Sie ordnet die identifizierten Kostenpositionen indikativ den gesamten **Capital Expenditure, Investitionskosten (CapEx)** des Prüfstandes zu. Diese normierten Verhältnisaangaben verdeutlichen das Spannungsfeld zwischen statischer Anlagenbereitstellung und dynamischer Laufzeit und dienen als Basis für die spätere Parametrierung der stochastischen Simulation.

Während die fixen Bereitstellungsblöcke für Labor (C_A) und Basis-Prüfstand (C_T) weitestgehend statisch und additiv in die Gesamtbilanz einfließen, verhalten sich die laufenden Durchführungskosten C_S extrem dynamisch. Da Lebensdauerversu-

Tabelle 5.9: Indikative Relationen der Kostenpositionen in Bezug auf die Gesamtinvestition C_T für beispielhafte, typische Komponentenprüfstände im Maschinenbau.

Kostendomäne	Kostenposition	Pos.	Relation zu C_T
Prüfstandskosten	Grundlegende Hardware (AfA) ^a	C_B	$\approx 12,5\% - 16,7\% \text{ p. a.}$
	Mess- und Steuerungstechnik	$C_{I,C}$	in C_T inkludiert
Umgebungskosten	Laborinfrastruktur ^b	C_L	$\approx 1,0\% - 3,0\% \text{ p. a.}$
Durchführung	Instandhaltung & Kalibrierung ^c	C_M	$\approx 3,0\% - 5,0\% \text{ p. a.}$
Durchführung	Maschinenstundensatz (rein) ^b	–	$\approx 0,01\% - 0,02\% \text{ p. Bh}$
Durchführung	Lastabhängige Energie ^b	C_E	$\approx 0,005\% - 0,02\% \text{ p. Bh}$
Durchführung	Hilfs- und Betriebsstoffe	C_H	$\ll 0,005\%$
Durchführung	Rüst- und Bedienpersonal	C_O	$\approx 0,015\% - 0,025\% \text{ p. Ah}$

^a bei 6-8 Jahren Nutzungsdauer [120]; ^b in Anlehnung an VDI 3258 [123]; ^c gem. VDI 2884 [121].

Anmerkung: Bh = Betriebsstunde (Anlage aktiv), Ah = Arbeitsstunde (Personal aktiv).

che stochastischen Ausfallprozessen unterliegen und die asymmetrische Verteilung unterschiedlicher Belastungsstufen (Faktorkombinationen im DoE) zu stark variierenden Testdauern führt, determinieren erst die individuellen, zufallsbehafteten Versuchslaufzeiten t_i den tatsächlichen Ressourcenverbrauch (Personal, Energie, Material, Anlagenverschleiß).

Im Rahmen der späteren Modellierung müssen diese dynamischen Kostentreiber folglich in einem iterativen Prozess evaluiert werden. Die Einbettung in eine Monte-Carlo-Simulation erlaubt es, die Verteilung der stochastischen Ausfallzeiten zu aggregieren, um einen belastbaren Erwartungswert für die Durchführungskosten $\bar{C}_S$ zu ermitteln. In der Summe stellt dieses Kostenmodell ein unabdingbares Instrument dar, um topologischen und statistischen Modifikationen eines Versuchsplans ein direktes ökonomisches Preisschild zuzuordnen.

5.5 Übertragung auf multivariate Lebensdauermodelle

Die vorangegangenen Abschnitte dieses Kapitels bauen die methodischen Grundlagen einer adaptiven Versuchsplanung für die Lebensdauererprobung sukzessi-

ve auf: In Abschnitt 5.2 evaluieren Sensitivitätsanalysen generelle Einflüsse von Orthogonalitätsabweichungen auf die Variabilität von Trennschärfe (*power*) und Schätzfehler (*Bias*). Diese Betrachtung gipfelt in Abschnitt 5.2.3 in der Erkenntnis, dass praxismotivierte Designmodifikationen hinsichtlich ihrer Auswirkungen auf die statistische Effektivität oftmals tolerabel bleiben. Abschnitt 5.3 greift diese Erkenntnis auf und bewertet sie aus der Perspektive einer für ALTs motivierten Optimierung der Prädiktionsvarianz. Es zeigt sich, wie freigewordene Versuchspunkte – das identifizierte geometrische Gestaltungsbudget – proaktiv genutzt werden, um die Extrapolationsvarianz für die multidimensionale und beschleunigte Lebensdauererprobung gezielt zu minimieren. Abschnitt 5.4 versieht diese topologischen Aspekte schließlich mit einem monetären Preisschild. Das eingeführte Kostenmodell dient der objektiven Quantifizierung ökonomischer Vergünstigungen, welche aus der asymmetrischen Re-Allokation der Versuchspunkte resultieren.

Der vorliegende Abschnitt bildet abschließend die Brücke zu lebensdauerverteilten Daten. Für die industrielle EoL-Versuchsplanung greift das bisherige, idealisierte Setup aus Sicht der spezifischen Datenlage noch zu kurz, da reale Ausfallzeiten streng positiv, oftmals rechtsschief verteilt und durch Prüfzeitverkürzungen zensiert sind [2]. In einem finalen Syntheseschritt vollzieht die Methodik der Extrapolationsabsicherung (EmALT) daher den Transfer in die komplexe stochastische Realität der Zuverlässigkeitstechnik, indem der in Abbildung 5.1 etablierte Gesamt-Simulationspfad nun vollumfänglich aktiviert wird. Während in den Vorstudien (Abschnitte 5.2 und 5.3) primär die statistische Effektivität unter idealisierter Normalverteilung betrachtet wurde, koppelt die nachfolgende Untersuchung nun die iterative MLE von Ausfalldaten direkt mit dem dynamischen Kostenmodell.

Um die geometrischen Eigenschaften der neuen EmALT-Topologie jedoch sauber von den verteilungsspezifischen Eigenheiten der Weibull-Schätzung zu trennen, erfolgt die Evaluierung in einem **zweistufigen Prozess**: Zunächst wird die asymmetrische Versuchsplanung isoliert unter idealisierten OLS-Bedingungen validiert (Abschnitt 5.5.2), bevor in Abschnitt 5.5.3 der vollständige stochastisch-ökonomische Transfer auf das Weibull-Modell stattfindet. Das gewählte EmALT orientiert sich dabei wie gehabt an dem in Abschnitt 5.3.2 beispielhaft gewählten Set an APs im südwestlichen Quadranten, um die Prädiktionsvarianz entlang des Extrapolationsvektors zum realen Feldbetriebspunkt zu minimieren.

Um die Effektivität der adaptiven Extrapolationsabsicherung abschließend zu quantifizieren, evaluiert die nachfolgende MCS drei spezifische Design-Konfigurationen gegeneinander. Alle Konfigurationen verfügen über den exakt gleichen Ressourcenaufwand von $N = 13$ Versuchspunkten:

1. **Basis CCD (Referenz)**: Der klassische rotationssymmetrische Versuchsplan, bestehend aus dem faktoriellen Kern ($n_F = 4$), vier axialen SPs ($n_{SP} = 4$, mit $\alpha_D = \sqrt{2}$) sowie fünf redundanten ZPs ($n_{ZP} = 5$).
2. **Passiv ausgedünntes Design (CCD_{-AP})**: Die aus Abschnitt 5.3.1 als ineffizient identifizierten Stützstellen entfallen ersatzlos. Dies betrifft einen redundanten Zentralpunkt sowie die beiden für die Extrapolation unkritischen Sternpunkte im Bereich der höchsten Belastung (Nordosten: $(0; \alpha_D)$ und $(\alpha_D; 0)$). Dieses künstliche Design dient primär als methodischer Zwischenschritt, um den isolierten Trennschärfe-Verlust dieser spezifischen Fehlstellen im Lebensdauer-Raum zu messen.
3. **EmALT (Proaktive Extrapolationsabsicherung)**: Das erarbeitete geometrische Budget aus den drei freigewordenen Stützstellen erfährt eine Reinvestition. Gemäß der in Abschnitt 5.3.2 beschriebenen *Exposure-Area*-Methode werden drei Versuchspunkte als asymmetrische Ankerpunkte (APs) in den südwestlichen Quadranten des Basis-Szenarios versetzt, in welchem sich üblicherweise ein realer Feldbetriebspunkt befindet, vgl. Abbildung 5.12. Eine realitätsnahe Allokation, die auch Prüfstandsrestriktionen an den absoluten Belastungsgrenzen berücksichtigt, platziert diese Anker in einem stützenden Layout entsprechend Abschnitt 5.3.2 bei $(-0,85; -2,60)$, $(-1,10; -2,35)$ und $(-0,85; -2,35)$ als beispielhafte Variante zur Minimierung der Prädiktionsvarianz.

Entsprechend der Vorgehensweise in Abschnitt 5.2.3 evaluiert die MCS die drei Design-Varianten auf Basis von $n_{MC} = 1 \times 10^4$ Iterationen.

5.5.1 Signal-Rausch-Kalibrierung unter dem Sparsity of Effects Principle

Um die in der linearen Vorstudie (Abschnitt 5.2) etablierte methodische Vergleichbarkeit der Trennschärfe-Verluste aufrechtzuerhalten, erfährt das Referenz-Design für die spätere Weibull-Simulation in Abschnitt 5.5.3 zunächst eine Sensibilisierung auf exakt denselben kritischen Arbeitspunkt $\text{SNR} = 1,20$. Da absolute Regressionskoeffizienten in β zwischen dem additiven Normalverteilungsraum und Lebensdauermodellen nicht translationsinvariant sind, erfordert dieser finale Transfer vorab die Ausnutzung der zugrundeliegenden Verteilungsmechanik.

Beim Übergang zum AFT-Modell ändert sich die Interpretation des Modells grundlegend: Aufgrund der strengen Positivität und der ausgeprägten Wertebereichsdynamik realer Ausfallzeiten modelliert die Regression nicht die Lebensdauer t selbst, sondern deren natürlichen Logarithmus $\ln(t)$ als Zielgröße. Unterliegt die physikalische Lebensdauer t einer Weibull-Verteilung, folgt ihr logarithmierter Wert $\ln(t)$ axiomatisch einer SEV - in der Literatur äquivalent als Gumbel-Verteilung für Minima bezeichnet [2]. Das AFT-Modell formuliert sich in diesem logarithmischen Raum als lineares Regressionsmodell:

$$\ln(t) = x'\beta + \sigma_{\text{SEV}} \cdot \epsilon \quad \text{mit} \quad \epsilon \sim \text{SEV}(0,1) \quad (5.6)$$

Die für die *power* entscheidende Rauschkomponente (σ_{SEV}) stellt im Weibull-Fall jedoch keine freie Variable dar. Sie entspricht exakt dem Skalenparameter der SEV, welcher über das Inverse des Weibull-Formparameters b intrinsisch an die Werkstoffphysik gekoppelt ist [2]:

$$\sigma_{\text{SEV}} = \frac{1}{b} \quad (5.7)$$

Unter der werkstoffmechanisch plausiblen Annahme eines progressiven Verschleiß-/Ermüdungsverhaltens fixiert sich dieser Formparameter repräsentativ auf $b = 3,0$ [13], was den Skalenparameter deterministisch auf $\sigma_{\text{SEV}} = 1/3 \approx 0,33$ beschränkt.

Für die methodische Konsistenz bleibt zu betonen, dass σ_{SEV} den rein mathematischen Skalenparameter und nicht die tatsächliche Standardabweichung der rechtschiefen SEV abbildet. Letztere definiert sich über die Eulersche Konstante und

skaliert proportional über den Faktor $\pi/\sqrt{6}$ zu $\sigma_{\text{total, SEV}} \approx 1,28 \cdot \sigma_{\text{SEV}}$. In der mathematischen Statistik der Zuverlässigkeitstechnik etabliert sich jedoch die gängige Praxis, das SNR invariant auf den Skalenparameter zu beziehen, da dieser als direkter Skalierungsfaktor in die Fisher-Informationsmatrix eingeht und somit die Asymptotik der Likelihood-basierten Prüfmathematik unmittelbar bestimmt [2].

Während die Normalverteilungs-Studie das Streuniveau künstlich auf $\sigma = 5,0$ skaliert, fixiert der AFT-Ansatz das Systemrauschen folglich intrinsisch. Um den kritischen Arbeitspunkt von SNR = 1,20 in den Weibull-Raum zu überführen, kalibrieren sich die vorzugebenden Effekte in β exakt auf diese SEV-Streuung: $\beta = \text{SNR} \cdot \sigma_{\text{SEV}}$. Für die quadratischen Modellkomponenten resultiert daraus eine exakte Ziel-Effektstärke von $\beta_{11} = \beta_{22} = \beta_{12} = |1,20 \cdot 0,33| = |0,40|$.

Eine physikalisch repräsentative Modellierung von ALTs erfordert darüber hinaus eine funktionale Differenzierung: Ein Anstieg des Stressniveaus induziert im Erwartungsfall eine Beschleunigung der Schädigungsmechanismen und damit eine Reduktion der Lebensdauer. Die Modellstruktur bildet dies durch strikt *negative* Vorzeichen der Effekte ab. Die relativen Effektstärken staffeln sich hierbei hierarchisch gemäß dem empirisch belegten *Sparsity of Effects Principle* [28]. Daraus leitet sich die Parametrisierung für die nachfolgende MCS ab:

- **Interaktionen und quadratische Effekte:** Diese Terme höherer Ordnung determinieren die Krümmung der Antwortfläche (vgl. Abbildung 5.16) und kalibrieren sich betragsmäßig auf den informationstheoretisch sensiblen Schwellenwert von $|\beta_{ij}| = 0,40$. Dies gewährleistet im orthogonalen Basis-Design eine hinreichende statistische Referenz-power ($\approx 70 - 80\%$). Die methodische Vorzeichenwahl ist hierbei physikalisch determiniert: Um eine valide Extrapolation in den Bereich extrem milder Feldlasten (negative Faktorstufen) zu ermöglichen, erzwingen positive quadratische Terme ($\beta_{11} = \beta_{22} = -0,40$) ein streng monotonen Ansteigen der Systemlebensdauer im AFT-Ansatz. Der synergistische Interaktionsterm verbleibt positiv ($\beta_{12} = 0,40$), um antagonistische Kompensations-Effekte bei kombinierter Extrembelastung auszuschließen.
- **Haupteffekte:** Entsprechend dem Sparsity-Prinzip fungieren sie als dominante, lebensdauermindernde Stressoren und parametrisieren sich mit einer betragsmäßig doppelt so hohen Effektamplitude: $\beta_1 = \beta_2 = -0,80$. Das korrespondierende SNR von 2,40 verleiht diesen Termen eine ausgeprägte statis-

tische Robustheit. Im Kontext des multiplikativen AFT-Ansatzes impliziert dies eine Verkürzung der zu erwartenden Lebensdauer um den konstanten Beschleunigungsfaktor $r = \exp(0,80) \approx 2,22$ pro normierter Stressstufe.

- **Intercept:** Die Regressionskonstante β_0 dimensioniert sich analytisch derart, dass die charakteristische Basislebensdauer T im Koordinatenursprung des Versuchsraums ein anwendungsnahes Referenzniveau von ca. 100.000 Lastwechseln abbildet ($\ln(10^5) \approx 11,51$).




Abbildung 5.16: Antwortfläche der charakteristischen Systemlebensdauer T in Abhängigkeit der Faktoren x_1 und x_2 . Die Projektion verdeutlicht die massive Extrapolationsdistanz zwischen dem DoE-Zentrum und den geforderten Feld-Bedingungen.

Tabelle 5.10: Kalibrierte Startwerte und statistische Eigenschaften des log-linearen Weibull-Basismodells (AFT-Ansatz)

Koeffizient	β_0	β_1, β_2	β_{11}, β_{22}	β_{12}	σ_{SEV}
Wahrer Wert	11,51	-0,80	-0,40	0,40	0,33
SNR	–	2,40	1,20	1,20	–

5.5.2 Generische Auswirkungen asymmetrischer Versuchsplanung

Analog zur Methodik aus Abschnitt 5.2.3 erfolgt die Auswertung der drei Design-Konfigurationen in einer stringenten zweistufigen Sequenz: Zunächst quantifizieren *a priori* Design-Metriken den topologischen Orthogonalitätsverlust, bevor die probabilistische MCS die tatsächlichen Auswirkungen auf Schätzpräzision und Entdeckungswahrscheinlichkeit beziffert.

Die *Ground Truth* der Simulation bildet in diesem methodischen Zwischenschritt nochmals das in Tabelle 5.5 definierte, normalverteilte Basismodell. Diese temporäre Rückkehr zur OLS-Baseline ist zwingend erforderlich, um eine direkte und unverfälschte Vergleichbarkeit der durch EmALT induzierten Varianzumverteilung gegenüber den generischen Orthogonalitätsabweichungen aus Abschnitt 5.2.3 zu gewährleisten, ohne dass diese durch die asymmetrische Schiefe und den inhärenten Bias der Weibull-MLE überlagert werden. Abschnitt 5.5.3 schafft nachfolgend schließlich den finalen Übertrag auf die multivariate Lebensdauererprobung und behandelt Lebensdauer-verteilte (Weibull) Daten.

Die algebraische Auswertung entlang Tabelle 5.11 bestätigt das erwartete Spannungsfeld: Der proaktive asymmetrische Eingriff bei Designmodifikationen nach EmALT erzwingt den partiellen Verlust der Orthogonalität - messbar im Anstieg der Werte von A_2 und VIF. Im direkten Vergleich zum rein passiv ausgedünnten Design CCD-AP belegt die I-Effizienz jedoch den strukturellen Mehrwert einer nach Abschnitt 5.3 motivierten Reallokation von Versuchspunkten zur Optimierung der Prädiktionsvarianzen im Feldbereich: Das geometrische Budget verpufft nicht ersatzlos, sondern stützt die integrierte Vorhersagevarianz signifikant ab. Für die

Tabelle 5.11: Matriceigenschaften und Effizienzen. Der VIF wird für alle Terme dargestellt ($\hat{\beta}_0$ entfällt).

Szenario	A_2	Effizienzen [%]					VIF				
		A_{eff}	D_{eff}	G_{eff}	I_{eff}	V_{eff}	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	0,017	46,7	56,9	21,0	95,5	134,2	1,00	1,00	1,00	1,02	1,02
CCD-AP	0,373	39,2	50,4	18,5	78,3	140,3	1,27	1,27	1,00	1,31	1,31
EmALT	2,596	39,1	68,9	15,5	73,1	136,3	1,45	3,84	3,18	1,32	5,91

ingenieurwissenschaftliche Lebensdauerprognose manifestiert sich hier ein elementarer Paradigmenwechsel: Die vollkommen isolierte, dekorrelierte Schätzung einzelner Systemparameter - das höchste Paradigma klassischer Screening-Designs - tritt zugunsten einer zielgerichteten, makroskopischen Prädiktionsschärfe in den Hintergrund.

Die stochastische Auswertung validiert diese topologischen Indikatoren probabilistisch. Die fundamentale Erwartungstreue des OLS-Schätzers bleibt unter asymmetrischen Bedingungen unbeschadet gewahrt; der systematische Schätzfehler (*Bias*) verharret über alle Design-Varianten hinweg auf einem vernachlässigbaren Niveau marginal nahe Null: vgl. Tabelle 5.12 sowie Abbildung 5.17. Flankierend weisen die aggregierten Wahrscheinlichkeitsdichten der Signifikanztests - Abbildung 5.18 - einen theoretisch konformen Verlauf auf, was numerische Artefakte infolge der Asymmetrie ausschließt.

Tabelle 5.12: Relativer systematischer Schätzfehler (Bias) in Prozent bei OLS-Baseline ($\text{SNR} = 1,2$).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	+0,01 %	+0,02 %	+0,08 %	+0,09 %	+0,42 %	-0,41 %
CCD-AP	-0,14 %	-0,13 %	+0,14 %	+0,96 %	-0,19 %	-0,38 %
EmALT	+0,24 %	-0,22 %	+0,15 %	-0,12 %	+0,59 %	+0,10 %

Ergänzend zur Verteilungsprüfung der Teststatistiken bestätigt die stichprobenartige Auswertung der standardisierten Residuen r_i (vgl. Gleichung (2.70)) sowie der Devianz-Residuen r_{Dev} (Gleichung (2.72)), dass die asymmetrische Stützstellenallokation im EmALT-Design keine systematischen Strukturbrüche in der Residuenstreuung induziert. Die Residuen verharren trendfrei und folgen im Mittel der theoretischen Extremwertverteilung $SEV(0,1)$, womit die Grundannahmen der GLM-Inferenz auch unter gerichteter Orthogonalitätsabweichung vollumfänglich erfüllt bleiben. Der geometrische Eingriff entlädt sich folglich primär in der Schätzvarianz - siehe MSE, Tabelle 5.13. Zwar weitet die topologisch induzierte Multikollinearität die Vertrauensbereiche auf, doch erweist sich das EmALT-Design der ersatzlosen Ausdünnung als deutlich überlegen: Die reinvestierten Extrapolations-APs dämpfen den Varianzanstieg im direkten Vergleich spürbar für alle Regressionskoeffizienten in β . Die durch die Asymmetrie gezielt induzierte Kovarianzstruktur




Abbildung 5.17: Absolute Schätzwerte der Modellkoeffizienten für die asymmetrischen Designvarianten am Arbeitspunkt $\text{SNR} = 1,20$. Der Bias bleibt marginal; die Erwartungstreue des OLS-Schätzers ist gewahrt.




Abbildung 5.18: Aggregierte p -Wert Histogramme der verglichenen Designvarianten. Der konforme Verlauf belegt die Abwesenheit systematischer Verzerrungen in der Signifikanzprüfung.

der Schätzer fungiert hierbei nicht als methodischer Makel, sondern als das exakte mathematische Vehikel, welches die SPV auf dem Extrapolationspfad stützt.

Tabelle 5.13: Schätzvarianz (MSE) der einzelnen Koeffizienten bei OLS-Baseline (SNR = 1,2).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	5,00	3,10	3,15	6,21	3,54	3,56
CCD _{-AP}	6,30	5,61	5,42	6,36	7,25	7,57
EmALT	5,33	4,89	5,32	4,95	6,97	2,05

Dieser dämpfende Effekt schlägt sich unmittelbar in der Erhaltung der *power* nieder, vgl. Tabelle 5.14 und Abbildung 5.19. Während das passiv ausgedünnte Design (CCD_{-AP}) einen massiven Einbruch der Entdeckungswahrscheinlichkeit - insbesondere bei den für die Krümmung essenziellen quadratischen Termen - verzeichnet, fängt das EmALT-Design diesen Verlust hochgradig effektiv ab. Es übertrifft die reduzierte Designvariante substanziell und unterschreitet das Baseline *power*-Niveau des orthogonalen Basis-CCD lediglich marginal.

Tabelle 5.14: Durchschnittlicher Trennschärfe-Verlust ($\Delta power$) bei OLS-Baseline (SNR = 1,2).

Szenario	$power_{\beta_0}$	$power_{\beta_1}$	$power_{\beta_2}$	$power_{\beta_{12}}$	$power_{\beta_{11}}$	$power_{\beta_{22}}$
Basis CCD	—	—	—	—	—	—
CCD _{-AP}	−0,2 %	−9,1 %	−9,1 %	−5,4 %	−20,4 %	−19,4 %
EmALT	+0,0 %	−3,3 %	−4,8 %	+5,6 %	−13,0 %	+9,3 %

Jegliche Variation der Modellgüte im additiven Normalverteilungsraum lässt sich somit deterministisch auf den variablen VIF der modifizierten Design-Topologie zurückführen. Alle im nachfolgenden Transfer auf Lebensdauermodelle auftretenden Effekte ordnen sich damit unmissverständlich der stochastischen Natur der Weibull-Verteilung und der iterativen MLE-Approximation zu.




Abbildung 5.19: Vergleichende Analyse der absoluten statistischen Trennschärfe. Die asymmetrische Extrapolationsabsicherung (EmALT) stellt die Detektionsrate im Vergleich zur reinen Ausdünnung nahezu vollständig wieder her.

5.5.3 Effizientes L-DoE und der Economic Extrapolation Power Index

Nachdem im vorangegangenen Abschnitt die topologische Leistungsfähigkeit des EmALT-Designs unter idealisierten Bedingungen nachgewiesen wurde, vollzieht die Synthese aus stochastischer Lebensdauermodellierung und varianzbasierter Versuchsplanung nun den finalen Übergang in die physikalische und ökonomische Realität beschleunigter Zuverlässigkeitstests. Auf Basis Weibull-verteilter Ausfallzeiten $t \sim \mathcal{W}(T, b)$ und einer log-linearen AFT-Modellierung findet die Parameteridentifikation hier nun iterativ via MLE statt. Dieser Übergang der mathematischen Domäne impliziert jedoch weit mehr als den Austausch des Schätzalgorithmus: Er aktiviert zwingend die in Abschnitt 5.4 eingeführte dynamische Kostenstruktur der Lebensdauererprobung.

In klassischen, landwirtschaftlichen oder chemischen Versuchsplänen entsprechen die experimentellen Kosten zumeist linear der bloßen Anzahl an Versuchen: $C \propto N$. In der Lebensdauererprobung erweist sich eine solche Entkopplung jedoch als physikalisch unzulässig, da die Zielgröße selbst - die Ausfallzeit t_i - als der primäre Kostentreiber fungiert [123]. Die Designmatrix $\mathbf{X}$ und die resultierenden Versuchskosten C_Σ sind dadurch stochastisch hart gekoppelt, siehe auch Abschnitt 5.4. Dieser Umstand zwingt die Versuchsplanung in einen fundamentalen Zielkonflikt:

Das **EmALT**-Design verschiebt Extrapolations-**APs** in Richtung geringerer Stressniveaus (i.d.R. Südwesten des Parameterraums), um die Prädiktionsvarianz im Feld zu stützen. Geringerer Stress erzwingt physikalisch jedoch exponentiell längere Testlaufzeiten, wodurch der Kostenerwartungswert $E(C_\Sigma)$ massiv ansteigt. Gleichzeitig minimiert das Design jedoch die Extrapolationsvarianz **SPV** am beispielhaft anvisierten Prognosepunkt $(-0,7; -1,9)$ um ein Vielfaches gegenüber dem standardisierten Basis-**CCD** und bewahrt die Detektionssicherheit sensibler Krümmungseffekte.

Um diesen inhärenten Konflikt zwischen statistischer Prädiktionssicherheit und realem Ressourcenverbrauch messbar zu machen und eine objektive Entscheidungsgrundlage zu schaffen, bedarf es einer adäquaten Effizienz-Metrik. Da im Kontext der Lebensdauererprobung die zielgerichtete Extrapolation im Fokus steht, entspricht der relevante Informationsgehalt exakt dem Kehrwert der prädiktiven Varianz am fernen Prognosepunkt $(1/\nu(\mathbf{x}_0))$. Unter Einbezug der Notwendigkeit, die zugrundeliegenden Modellparameter zuverlässig zu identifizieren, wird dieser Ansatz generisch für einen beliebigen Regressionskoeffizienten $\hat{\beta}_i$ zum **EPI** erweitert:

$$\eta_{\text{eco}} = \frac{\text{power}(\hat{\beta}_i)}{\nu(\mathbf{x}_0) \cdot E(C_\Sigma)} \times 10^3 \quad (5.8)$$

Der Faktor 10^3 dient hierbei als dimensionslose Skalierungskonstante zur Überführung der resultierenden Kennwerte in einen numerisch handhabbaren Wertebereich. Dieser Index überführt den multidimensionalen Zielkonflikt aus topologischer Geometrie, Inferenzstatistik und Ökonomie in ein skalares Optimierungskriterium: Die Metrik skaliert proportional zur statistischen Detektionssicherheit, während sowohl die Prädiktionsvarianz im Extrapolationsraum als auch der monetäre Ressourceneinsatz als inverse Faktoren fungieren. Um den Nachweis für die absolute Notwendigkeit dieses Trade-offs zu erbringen, erweitert das nachfolgende **MCS**-Setup hier die bisherige Evaluierung um ein begleitendes, viertes Referenz-Design: das Feld-**CCD**. Diese Konfiguration translatiert die orthogonale Designmatrix unskaliert auf die Koordinaten des fernen Prognosepunktes - den Feldbetriebsbereich. Methodisch fungiert dieses Konstrukt als analytischer Grenzwert, der das stochastische Ideal einer varianzarmen Interpolation unter Feldbedingungen mit der resultierenden, physikalisch determinierten Kostenfunktion kontrastiert. Die probabilistische Auswertung der **MCS** belegt unter diesen Prämissen zunächst die grundlegende numerische

Stabilität der iterativen **MLE** unter den Bedingungen stark eingeschränkter Stichprobenumfänge ($N = 13$). Beim Übergang von der idealisierten **OLS**-Regression zur **MLE** rechtsschiefer **SEV**-Residuen tritt theoriekonform eine systematische Verzerrung infolge des geringen Stichprobenumfangs (*Small-Sample Bias*) auf [2]. Da die asymptotische Erwartungstreue des **MLE**-Schätzers mathematisch erst für $N \rightarrow \infty$ konvergiert, induziert der limitierte Prüfumfang von $N = 13$ eine systematische Varianz- und Parameterverschiebung, welche in Tabelle 5.15 quantifiziert wird.

Tabelle 5.15: Relativer systematischer Schätzfehler (Bias) in Prozent bei GLLW-Schätzung (Weibull-Modell).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	+0,15 %	−0,08 %	+0,10 %	−0,24 %	+13,73 %	+12,79 %
CCD – AP	+0,24 %	+3,72 %	+3,39 %	+6,82 %	+23,17 %	+22,10 %
EmALT	−0,00 %	+19,55 %	−39,14 %	−47,84 %	+46,51 %	−53,26 %

Die detaillierte Analyse des relativen systematischen Schätzfehlers offenbart zwei fundamentale stochastische Gesetzmäßigkeiten: Erstens verharret die Schätzung der Regressionskonstante $\hat{\beta}_0$ über alle drei Design-Szenarien hinweg auf einem Niveau exzellenter Erwartungstreue (im **EmALT** mit einem relativen Bias von −0,00 %). Die Skalierung der charakteristischen Basislebensdauer im Koordinatenursprung bleibt von der asymmetrischen Topologie somit vollkommen unberührt. Zweitens entlädt sich die in Abschnitt 5.5.2 identifizierte Multikollinearität des **EmALT**-Designs ($VIF = 5,91$ für $\hat{\beta}_{22}$) im Zusammenspiel mit der iterativen **MLE** in einer term-spezifischen Varianzumverteilung. Während die orthogonalen Referenzpläne bei den Krümmungstermen moderat überschätzen (+12,79 % bis +23,17 %), verzeichnet das **EmALT**-Design bei $\hat{\beta}_{22}$ eine relative Abweichung von −53,26 %. In der ingenieurwissenschaftlichen Bewertung relativiert sich diese Zahl jedoch unmittelbar: Da der wahre Nominellwert des Krümmungseffekts bei $\hat{\beta}_{22} = -0,40$ liegt, entspricht dies einer absoluten Verschiebung von lediglich $\Delta\hat{\beta}_{22} \approx -0,21$. Entscheidend für die prädiktive Validität ist hierbei die lineare Prädiktorkombination $\mathbf{x}_0' \hat{\beta}$: Durch die gezielt induzierten Kovarianzen kompensieren sich die Einzelfehler auf dem Extrapolationspfad, sodass die rekonstruierte Wirkungsfläche (vgl. Abbildung 5.20) die monotone Schädigungskinetik ohne Gradientenumkehr mathematisch stabil abbildet.




Abbildung 5.20: Absolute Schätzwerte der MLE-Koeffizienten im Weibull-Modell ($\text{SNR} = 1,20$). Der Schätzwert der Basislebensdauer $\hat{\beta}_0$ bleibt exakt; die Terme höherer Ordnung spiegeln die durch die Multikollinearität induzierte Varianzumverteilung wider.

Ein herausragender methodischer Vorteil des EmALT-Designs offenbart sich bei der Identifikation des intrinsischen Weibull-Formparameters $\hat{b}$ (wahrer Wert $b = 3,00$). Klassische, eng konzentrierte Hochlast-Versuchspläne überschätzen diesen Parameter bei kleinen Stichproben massiv ($\hat{b} = 4,97$ im Basis-CCD bzw. $\hat{b} = 5,91$ im CCD-AP), was in der industriellen Praxis zu einer fatalen Unterschätzung der realen Bauteilstreuung führen würde. Das EmALT-Design hingegen stützt durch die weit in den Niedrigstressbereich ausgreifenden Ankerpunkte den stochastischen Hebelarm der Likelihood-Funktion. Mit $\hat{b} = 3,37$ rekonstruiert es die werkstoffphysikalische Ausfallstreuung mit überlegener Präzision. Flankierend belegen die aggregierten Wahrscheinlichkeitsdichten der Signifikanztests in Abbildung 5.21 eine artefaktfreie, theoriekonforme Verteilung der p -Werte, womit die statistische Validität der Likelihood-Ratio-Inferenz auch unter asymmetrischer Stützstellenallokation zweifelsfrei nachgewiesen ist.

Auf eine isolierte, parameterweise Ausweisung der Schätzvarianz (MSE) wird an dieser Stelle verzichtet, da sich die stochastische Unsicherheit des Modells infolge der Asymmetrie primär in der lokalen SPV am fernen Prognosepunkt bündelt und dort im Rahmen der ökonomischen Synthese über den EPI (η_{eco}) holistisch bewertet wird.

Hinsichtlich der statistischen Trennschärfe stabilisiert die Reallokation der Stützstellen den ungestörten quadratischen Haupteffekt $\hat{\beta}_{11}$ mit $\text{power} = 99,01\%$ auf




Abbildung 5.21: Aggregierte p -Wert Histogramme der MLE-Signifikanztests. Die stochastische Auswertung liefert artefaktfreie Verteilungen.

einem Niveau, welches das Basis-CCD (98,33 %) sogar leicht übertrifft (vgl. Abbildung 5.22). Zwar erfährt der Krümmungsterm der modifizierten Achse ($\hat{\beta}_{22}$) infolge der geometrischen Asymmetrie einen Rückgang der Detektionswahrscheinlichkeit auf 75,04 % (bei $\hat{\beta}_{12}$ auf 64,53 %), doch verbleibt dieser Wert vollumfänglich im Bereich statistisch hinreichender Test-Power ($\geq 75\%$) für Terme höherer Ordnung [77]. Das EmALT-Design opfert somit kontrolliert redundante Überkapazitäten lokaler Parameterkonfidenzen, um die primäre Zielgröße - die Minimierung der Extrapolationsvarianz am fernen Einsatzpunkt - ohne budgetäre Mehrbelastung zu garantieren.

Die abschließende ökonomische und stochastische Synthese manifestiert die finale Entscheidungsoberfläche der Versuchsplanauswahl - vgl. Tabelle 5.16 sowie Abbildung 5.23. In dieser Synthese kulminiert zugleich die fundamentale methodische Differenzierung zwischen **statistischer Effektivität** und **ökonomischer Effizienz**, welche den Kern dieser Arbeit prägt. Während die vorangegangenen Abschnitte nachgewiesen haben, dass das EmALT-Design prinzipiell statistisch effektiv agiert - also die methodische Fähigkeit besitzt, die Modellparameter erwartungstreu zu schätzen und die Prädiktionsvarianz im Einsatzbereich gezielt abzusichern -, bewertet der EPI erstmals die übergeordnete Effizienz: das konkrete Verhältnis aus dieser statistischen Zielerreichung und den hierfür real aufzuwendenden Prüfstandsressourcen.




Abbildung 5.22: Vergleichende Analyse der MLE-power. Das EmALT-Design rettet die für die Modellierung essenziellen Terme vor dem vollständigen Zusammenbruch.

Der linke Teilplot in Abbildung 5.23 veranschaulicht diese zwingende physikalisch-ökonomische Kopplung anhand einer exponentiellen Effizienzgrenze: Die Beibehaltung des orthogonalen Basis-CCD charakterisiert sich durch minimale EoL-Versuchsdauern und folglich geringe direkte Testkosten. Dennoch erweist sich dieser Ansatz als ineffizient, da die Vermeidung von Prüfkosten mit einer stochastisch inakzeptablen Prädiktionsunsicherheit im Feldbereich erkaufte wird - das Design verfehlt somit bereits die Grundvoraussetzung der Effektivität. Das theoretische Feld-CCD markiert das konträre Extremum: Zwar generiert es prinzipbedingt die maximale Effektivität am Prognosepunkt ($SPV \approx 1,0$), provoziert jedoch durch unbeschleunigte Prüfzeiten eine massive Bilanzerhöhung des Kostenerwartungswerts $E(C_\Sigma)$, was seine ökonomische Effizienz vollständig zunichtemacht. Das EmALT-Design positioniert sich auf dieser Pareto-Kurve als das maßgebliche physikalisch-ökonomische Optimum: Es transformiert hohe statistische Effektivität durch die drastische Verkürzung der Versuchszeiten via ALT in maximale ökonomische Effizienz.

Dieser Befund belegt die unzureichende Validität klassischer DoE-Metriken im Rahmen der Zuverlässigkeitstechnik. Während die konventionelle RSM ein D-optimales Design (Maximierung von D_{eff}) als universelle Zielgröße postuliert, widerlegt die vergleichende Analyse in Abbildung 5.23 (rechts) diese Prämisse fundamental. Die Gegenüberstellung von D-Effizienz und dem holistischen EPI - hier exemplarisch für den hochsensitiven Krümmungsterm $\eta_{eco}(\beta_{22})$ visualisiert - offen-

bart eine strikt inverse Kausalität: Das Basis-**CCD** erreicht zwar nominell die höchste D -Effizienz, disqualifiziert sich jedoch unter Berücksichtigung der gewichteten Extrapolationsgüte im Kontext der Lebensdauererprobung vollständig. Demgegenüber dominiert das **EmALT**-Design - ungeachtet seiner durch die geometrische Asymmetrie bedingten, klassisch geringsten D -Effizienz - die tatsächliche **wirtschaftliche Effizienz** (**EPI**) signifikant. Wenngleich die quantitative Ausprägung des **EPI** durch die spezifische Parametrisierung des Kostenmodells und die Kalibrierung des Arbeitsbereiches mit $SNR = 1,20$ determiniert wird, besitzt die identifizierte Pareto-Topologie universelle Gültigkeit für beschleunigte Lebensdauerprüfungen. Das theoretische Feld-**CCD** erzielt zwar durch $SPV = 2,60$ eine hohe Prognosegüte, verursacht jedoch durch unbeschleunigte Prüfzeiten prohibitive Erwartungskosten von $E(C_{\Sigma}) = 128,7$ kCU. Die unbeschleunigte Erprobung unter Feldbedingungen erweist sich gegenüber der für das **EmALT**-Design geschätzten Kostenumfänge demnach als um den Faktor 1,59 kostenintensiver, vergleiche Tabelle 5.16. Das im **ALT**-Bereich verortete Design unterbietet diesen Ressourcenaufwand drastisch, wobei das **EmALT**-Design diese deutliche Ersparnis bei nahezu identischer Prädiktions-schärfe ($SPV = 2,39$) realisiert. Obgleich das Basis-**CCD** mit 74,4 kCU den absolut geringsten monetären Aufwand erfordert, kollabieren seine η_{eco} -Werte aufgrund der massiven Extrapolationsvarianz ($v(\mathbf{x}_0) = 20,5$) nahezu vollständig. Im Gegensatz dazu dominiert das **EmALT**-Design die Metrik mit weitem Abstand - und zeigt insbesondere bei den für die Krümmung essenziellen quadratischen Termen (wie $\hat{\beta}_{22}$) signifikant überlegene η_{eco} -Werte. Die numerische Bilanz belegt damit unmissverständlich, dass das **EmALT**-Konzept das globale Optimum aus Kostendämpfung durch Beschleunigung und zwingend erforderlicher Prognosesicherheit im fernen Feldbereich darstellt. Dass diese antagonistische Kausalität kein isoliertes Phänomen des quadratischen Terms darstellt, sondern für alle verbleibenden Modellkoeffizienten systematisch Bestand hat, wird durch die vollumfängliche Evaluation in Tabelle 5.16 und Anhang B.2 zweifelsfrei belegt. Ein rein durch klassische Optimalitätskriterien motiviertes Festhalten an orthogonalen Versuchsplänen erweist sich somit im Rahmen der Lebensdauererprobung mittels **DoE** als systematisch ineffizient, da vordergründig eingesparte Prüfstandsressourcen durch eine unzulässig hohe, potenziell sicherheitskritische Prognoseunsicherheit im Feldbetrieb kompensiert werden müssen.

Tabelle 5.16: Ganzheitliche ökonomisch-statistische Gegenüberstellung aller Modellkoeffizienten. Der Index η_{eco} quantifiziert die prädiktive Effizienz unter Berücksichtigung der Erwartungskosten $E(C_{\Sigma})$.

Szenario / Ressourcen	Metrik	β_1	β_2	β_{12}	β_{11}	β_{22}
Basis CCD	$\Delta power$	—	—	—	—	—
$E(C_{\Sigma})$: 54,2 kCU	rel. Bias	−0,1 %	+0,1 %	−0,2 %	+13,7 %	+12,8 %
SPV: 30,02	η_{eco}	0,62	0,62	0,50	0,60	0,61
CCD_{AP}	$\Delta power$	−0,1 %	−0,0 %	+6,1 %	−4,5 %	−4,7 %
$E(C_{\Sigma})$: 48,2 kCU	rel. Bias	+3,7 %	+3,4 %	+6,8 %	+23,2 %	+22,1 %
SPV: 30,12	η_{eco}	0,69	0,69	0,60	0,65	0,65
EmALT	$\Delta power$	−0,2 %	−5,7 %	−16,9 %	+0,7 %	−23,6 %
$E(C_{\Sigma})$: 81,0 kCU	rel. Bias	+19,5 %	−39,1 %	−47,8 %	+46,5 %	−53,3 %
SPV: 2,39	η_{eco}	5,15	4,86	3,33	5,11	3,87




Abbildung 5.23: Links: Exponentieller Zielkonflikt aus Prädiktionsvarianz und Erwartungskosten mit dem **EmALT**-Design als ökonomischem Optimum. Rechts: Inverse Kausalität zwischen klassischer D -Effizienz und EPI am Beispiel von β_{22} (vollständige Evaluation in Anhang B.2).

Konsequenzen für die Prognoseunsicherheit im Feldbetrieb

Die übergeordnete Zielsetzung dieser Arbeit - die **Entwicklung effizienter multivariater Lebensdauertests** - erfüllt sich vor diesem Hintergrund in ihrer finalen ingenieurwissenschaftlichen Konsequenz: der Konstruktion belastbarer Prognosemodelle für Lebensdauern und nicht zuletzt für Zuverlässigkeiten. Der ökonomische Mehrwert des **EmALT**-Designs, holistisch quantifiziert durch den **EPI**, verbleibt dabei nicht als abstrakte methodische Kennzahl, sondern übersetzt sich in der industriellen Praxis in eine höhere Präzision dieser Vorhersagemodelle bei effizienter Ressourcennutzung. Wie flankierende Untersuchungen zu **CI**s in optimierten Versuchsplänen belegen [119], korreliert die topologische Kontrolle der **SPV** mit präziseren Schätzungen der Vertrauensbereiche für die prognostizierten Ausfallwahrscheinlichkeiten im realen Einsatzraum.

Um den methodischen Transfer aufzuzeigen, wie aus den ermittelten Regressionsparametern in $\hat{\theta}$ nun ein finales Zuverlässigkeitsmodell generiert wird, visualisiert Abbildung 5.24 den simulativen Verlauf der Überlebenswahrscheinlichkeit $R(t)$ exakt am anvisierten Extrapolationspunkt $(-0,7; -1,9)$ im Feldbereich (vgl. Abschnitt 5.3.2). Dargestellt sind die Zuverlässigkeitsfunktionen auf Grundlage der Gleichungen (2.2), (2.56) und (2.69) sowie die korrespondierenden Bänder der 90 %-**CI**s, resultierend aus der Invertierung der beobachteten Fisher-Informationsmatrix F_{ob} der jeweiligen **MLE**-Modellierung. Als objektive Referenz dient hierbei die Kurve des wahren Systemverhaltens nach bekannter Vorgabe aus Tabelle 5.10 mit $b = 3$.

Während die mittleren $R(t)$ -Prognosen (Punktschätzer) beider Designs - im Rahmen der verbleibenden Abweichungen der Koeffizientenschätzungen in $\hat{\beta}$ - den wahren physikalischen Degradationsverlauf valide approximieren, manifestieren sich im direkten Vergleich der Konfidenzbänder feststellbare topologische zusätzliche Unterschiede. Bedingt durch die massive Extrapolationsdistanz unterliegen naturgemäß beide Versuchspläne einer substanziellen Prognosevarianz, sodass ihre absoluten Streuungsamplituden auf einem vergleichbaren Grundniveau in $v(\mathbf{x}_0)$ verharren. Dennoch induziert das voll-orthogonale Basis-**CCD** die prägnanteste Aufweitung der Vertrauensgrenzen. Demgegenüber gelingt es dem **EmALT**-Design, diesen Unsicherheitsbereich durch die strategische Varianzdämpfung seiner Ankerpunkte sowohl kosteneffizienter als auch messbar zu verdichten. Die optisch leicht wellige Ausprägung der simulierten Vertrauensgrenzen $[\hat{R}(t)_u, \hat{R}(t)_o]$ ist dabei me-

thodisch begründet: Sie resultiert aus der multidimensionalen Natur der Stressoren in Kombination mit der empirischen Extraktion der Schranken mittels der Kovarianzmatrix $\hat{\mathbf{V}}$. Die stochastischen Streuungen der 1×10^4 Monte-Carlo-Schätzer transformieren sich stark nichtlinear durch die Weibull-Gleichung (2.2), was bei der punktweisen Ermittlung der Perzentile über die fortlaufende Zeitachse t zu leichten lokalen Fluktuationen führt.




Abbildung 5.24: Vergleich der prognostizierten Überlebenswahrscheinlichkeit $R(t)$ am Feldbetriebspunkt inklusive 90 %-CI. Aufgrund der Distanz weisen beide Designs hohe Prognoseunsicherheiten auf, das EmALT-Design (schwarz) reproduziert das wahre Zuverlässigkeitsmodell jedoch mit stellenweise geringerer Varianz als das Basis-CCD (grau).

In der industriellen Praxis und vor dem Kontext eines Prüflingsumfangs von $N = 13$ sind selbst derartige moderate Reduktionen der Vertrauensbereiche von Bedeutung, da normative Sicherheitsnachweise und Wartungsintervalle zumeist zwingend auf der unteren Vertrauensgrenze einer definierten $R(t)$ basieren [1, 2].

5.6 Methodische Synthese und Transfer

Das vorliegende Kapitel erbringt damit den theoretischen und simulativen Nachweis, dass klassische Prinzipien der statistischen Versuchsplanung zwar ein metho-

disch robustes Fundament für die Lebensdauererprobung bilden, in ihrer starren Ausprägung jedoch für die Lebensdauererprobung ökonomisch ineffizient sind. Die vollzogene Synthese liefert dabei drei zentrale Erkenntnisse für die Zuverlässigkeitstechnik:

1. **Topologische Resilienz:** RSDs wie das CCD reagieren auf periphere Modifikationen und Ausdünnungen erstaunlich robust, solange die Identifikation der Haupteffekte gesichert ist. Dies legitimiert die Abkehr vom Dogma der strengen Orthogonalität und eröffnet ein wertvolles geometrisches Gestaltungsbudget.
2. **Extrapolationsabsicherung:** Die SPV verhält sich in gestörten Designs hochgradig richtungssensitiv. Die entwickelte EmALT-Positionierung nutzt das freigewordene Gestaltungsbudget proaktiv, um über asymmetrische APs die Prognoseunsicherheit zielgerichtet entlang des Extrapolationsvektors zum fernen Feldbetriebspunkt zu minimieren. Der EVG dient hierbei als analytisches Instrumentarium, um die topologische Sensitivität von $v(\mathbf{x}_0)$ zu quantifizieren und die Ankerpunktpositionierung systematisch zu optimieren.
3. **Ökonomische Effizienz:** Die strenge Entkopplung von Design-Optimalität und Versuchsdauer verliert in der Lebensdauererprobung ihre Gültigkeit. Der neu eingeführte EPI (η_{eco}) weist nach, dass sich das EmALT-Design im Zielkonflikt zwischen stochastischer Prädiktionsgüte und exponentiell skalierenden Prüfkosten als das überlegene physikalisch-ökonomische Optimum positioniert und klassisch D -optimale Pläne signifikant dominiert. Dieser Befund wird durch Forschungsarbeiten zur statistischen Trennschärfe computergenerierter Optimalpläne gestützt: Wie Rittmaier et al. [96] durch simulative Analysen belegen, bieten algorithmisch optimierte Designs unter Ressourcenrestriktionen zwar prinzipielle Vorteile gegenüber starren Standard-Versuchsplänen, weisen jedoch in Abhängigkeit des gewählten Optimalitätskriteriums (A -, D - oder V -Optimalität) stark divergierende Detektionsraten für spezifische Modelleffekte auf. Die in dieser Arbeit vollzogene Abkehr von einer pauschalen D -Optimalität hin zu einer asymmetrischen, prädiktionszentrierten Zielfunktion (SPV) ist folglich der zwingende methodische Schritt, um das geometrische

Gestaltungsbudget ökonomisch zielführend für die Lebensdauererprobung zu erschließen.

Trotz dieser eindeutigen Befunde bedarf es einer kritischen Würdigung der Simulationsergebnisse. Die numerische Evaluation basiert auf der Prämisse eines strukturell korrekten log-linearen AFT-Modells sowie einer stetigen Degradationskinematik. Treten in der physikalischen Realität abrupte Wechsel der Schädigungsmechanismen zwischen Hochlast- (ALT) und Feldbereich auf, geraten rein modellbasierte Extrapolationen unweigerlich an ihre methodischen Grenzen. Gerade vor diesem Hintergrund entfaltet das EmALT-Design jedoch einen weiteren, entscheidenden Praxisvorteil: Durch die strategische Verortung der Ankerpunkte nahe dem realen Einsatzniveau fungieren diese Stützstellen nicht nur als stochastische Varianzdämpfer, sondern zugleich als physikalische Frühwarnsensoren. Im Rahmen der post-experimentellen Datenanalyse lassen sich diese Ankerpunkte analog zu *Confirmation Experiments* [124] auswerten. Entsprechende Metriken, wie etwa die *Probability of Agreement*, können hierbei herangezogen werden, um empirisch zu validieren, ob die am Hochlastprüfstand extrahierten Degradationsgesetze im moderaten *Use-Space* weiterhin Gültigkeit besitzen - eine Detektionsmöglichkeit, die durch reine Hochlastprüfungen vollständig verwehrt bliebe.

Während die durchgeführten Sensitivitätsanalysen und MCSs die theoretischen Gesetzmäßigkeiten des EmALT-Designs unter kontrollierten stochastischen Randbedingungen zweifelsfrei verifiziert haben, erfordert der Transfer in die Zuverlässigkeitspraxis einen finalen empirischen Härtetest. Im nachfolgenden Kapitel 6 wird das hergeleitete Instrumentarium daher auf eine physische Fallstudie übertragen. Anhand der realen multivariaten Lebensdauererprobung von Lenksystem-Zahnriemen wird das klassische Basis-Modell mittels *Confirmation Experiments* gezielt herausgefordert. Es wird empirisch nachgewiesen, dass die theoriebasierte Extrapolationsabsicherung durch das EmALT-Konzept weit mehr als eine effiziente Varianzdämpfung ist: Sie erweist sich als zwingende methodische Notwendigkeit, um das Zuverlässigkeitsmodell im realen Feldbetrieb vor fatalen, sicherheitskritischen Überschätzungen zu bewahren.

6 Empirische Validierung der Extrapolationsabsicherung

Die Ausführungen in Kapitel 5 erbringen auf Basis umfangreicher MCSs den theoretischen und algorithmischen Nachweis, dass das EmALT-Design im Rahmen der multivariaten, effizienten Lebensdauererprobung signifikante informationstheoretische Vorteile gegenüber klassisch orthogonalen Versuchsplänen für ALT bietet. Für den finalen Transfer dieser Methodik in die industrielle Zuverlässigkeitstechnik dient das vorliegende Kapitel der ergänzenden empirischen Validierung in der **Fallstudie** zum real vermessenen Hardwaredatensatz aus Untersuchungen von Arndt et al. [125]. Damit untermauert dieser Abschnitt die numerischen Ergebnisse des vorherigen Kapitels durch die Betrachtung realer Bauteilversuche an Zahnriemen für Lenksysteme in automobilen Anwendungen.

Der methodische Übergang von der Simulation zur physischen Erprobung impliziert zwei wesentliche Verschärfungen der Randbedingungen: Erstens weicht die idealisierte Gesetzmäßigkeit unendlicher Simulationsiterationen der harten statistischen Realität stark limitierter Stichprobenumfänge. Die Untersuchung basiert auf einem realen Versuchsdatensatz mit lediglich zweifacher Replikation und damit $N = 26$ Versuchspunkt-Durchführungen. Zweitens unterliegen experimentelle EoL-Versuche zwingenden physikalischen und normativen Restriktionen. Anstatt diese als Mangel zu betrachten, generieren sie aus Sicht der adaptiven Versuchsplanung durch EmALT das **geometrische Gestaltungsbudget** nach Abschnitt 5.3. Hier beispielhaft und abweichend von der rein theoriegeleiteten Ausdünnung redundanter ZPs speist sich dieses Budget im vorliegenden Fall aus dem Entfall des nördlichen und östlichen SPs - $(0; \alpha_D)$ und $(\alpha_D; 0)$ - sowie des faktoriellen Eckpunktes $(1; -1)$.

Diese topologische Limitierung ist physikalisch determiniert: Das komplexe tribologische Eingriffsverhalten des Zahnriemens verliert in diesem spezifischen, kombinierten Belastungsregime seine funktionale Plausibilität, wodurch abweichende Ausfallmechanismen provoziert werden können, vergleiche [126, 127].

Wenngleich die Prüfläufe in der Realität hier schon durchgeführt wurden, werden die als nicht realisierbar deklarierten Hochlast-Versuche zum Zweck des systematischen Design-Vergleichs konsequent aus der Design-Matrix gestrichen. Anstatt den Versuchsplan dadurch lediglich passiv auszudünnen und eine asymmetrische Varianzaufweitung in Kauf zu nehmen, wird das hypothetisch freigewordene Budget proaktiv umgewidmet: Die Aufwände werden in die direkte Peripherie des hier beispielhaft anvisierten Feldbetriebspunktes ($-1,50$; $-1,80$) im Niedrigstressbereich zur Prognoseoptimierung re-allokiert. Da der originäre Basis-Datensatz nach Arndt et al. [125] diese massiv entschärften Stressniveaus naturgemäß nicht abdeckt, werden die Positionierungen und Ausfallergebnisse der APs beispielhaft aus begleitenden Untersuchungen des Erprobungsprojekts übernommen: Es liegt somit ein vollständiger ALT-Datensatz mit realen EoL-Zeiten für einen orthogonalen CCD-Versuchsplan sowie die ergänzenden APs vor. Dieser subtile methodische Transfer dient primär dem Zweck, das Wirkprinzip der EmALT-Topologie an einem kohärenten Realdatensatz methodisch geschlossen zu exemplifizieren und greifbar zu visualisieren. Entscheidend ist hierbei, dass die Reallokation algorithmisch optimiert in Relation zum Prognosepunkt und nach den in Kapitel 5 entwickelten EmALT-Kriterien in Kombination mit realen Prüfstandsbeschränkungen erfolgen kann. Tabelle 6.1 fasst alle experimentell ermittelten Ausfallzeiten des untersuchten Lenksystem-Zahnriemens für die jeweiligen Faktorkombinationen übersichtlich zusammen. Da die APs im Gegensatz zur theoretischen Simulation nun mit realen Ausfallzeiten unterlegt sind, ermöglicht dieser Datensatz einen einzigartigen, zweiseitigen Modellvergleich: Die Parameterschätzung und Lebensdauerprognose erfolgen separat für das klassische Basis-CCD (ohne APs, isoliert aus den Untersuchungen von Arndt et al. [125]) sowie für das reallokierte EmALT-Design inklusive der Ankerpunkte. Dies erlaubt nicht nur die finale Evaluation der realen Modellanpassung, der SPV sowie der verursachten Versuchskosten, sondern rückt vor allem einen fundamentalen Validierungs-Aspekt in den Fokus: Die nachfolgende Analyse liefert den empirischen Nachweis, in welchem Maße reale Degradationsdaten auf dem Extrapolationspfad das ungestützte Basis-Modell vor fatalen Fehlprädiktionen schützen und zu einer signifikant geschärften Lebensdauerprognose führen.

Tabelle 6.1: Gegenüberstellung der Versuchspläne und realisierten Ausfallzeiten t_i für das Basis-**CCD** und das **EmALT**-Design ($N = 26$) auf Basis der Datenlage aus [125] und begleitenden Prüfläufen (**APs**).

Run	Basis- CCD			EmALT		
	x_1	x_2	t_i [h]	x_1	x_2	t_i [h]
<i>Replikation 1</i>						
1	1,00	1,00	314144	1,00	1,00	314144
2	1,00	-1,00	1440	-2,42	-2,17	1850000
3	-1,00	1,00	625776	-1,00	1,00	625776
4	-1,00	-1,00	4760	-1,00	-1,00	4760
5	α_D	0,00	2904	-3,15	-2,56	4200000
6	$-\alpha_D$	0,00	800000	$-\alpha_D$	0,00	800000
7	0,00	α_D	78368	-3,15	-2,56	3950000
8	0,00	$-\alpha_D$	32072	0,00	$-\alpha_D$	32072
9	0,00	0,00	43472	0,00	0,00	43472
10	0,00	0,00	40144	0,00	0,00	40144
11	0,00	0,00	70440	0,00	0,00	70440
12	0,00	0,00	45296	0,00	0,00	45296
13	0,00	0,00	44560	0,00	0,00	44560
<i>Replikation 2</i>						
14	1,00	1,00	210584	1,00	1,00	210584
15	1,00	-1,00	7656	-2,42	-2,17	1910000
16	-1,00	1,00	752936	-1,00	1,00	752936
17	-1,00	-1,00	5264	-1,00	-1,00	5264
18	α_D	0,00	1440	-3,15	-2,56	4120000
19	$-\alpha_D$	0,00	709336	$-\alpha_D$	0,00	709336
20	0,00	α_D	48840	-3,15	-2,56	4300000
21	0,00	$-\alpha_D$	42728	0,00	$-\alpha_D$	42728
22	0,00	0,00	20936	0,00	0,00	20936
23	0,00	0,00	71744	0,00	0,00	71744
24	0,00	0,00	57960	0,00	0,00	57960
25	0,00	0,00	22432	0,00	0,00	22432
26	0,00	0,00	65816	0,00	0,00	65816

6.1 Modellschätzung und Anpassungsgüte

Die MLE-basierte Auswertung der Modellparameter nach Gleichung (2.59) offenbart für beide Design-Varianten zunächst messbare Diskrepanzen in der Ausprägung der Schätzwerte zu physikalischen Effekten. Abbildung 6.1 veranschaulicht die Gegenüberstellung der geschätzten Regressionskoeffizienten in $\hat{\beta}$ sowie des korrespondierenden Weibull-Formparameters $\hat{b}$.




Abbildung 6.1: Vergleich der MLE-Parameterschätzungen für das klassische Basis-CCD und das EmALT-Design am realen Datensatz. Die Integration der Ankerpunkte führt zu einer elementaren Neukalibrierung ausgewählter Haupteffekte, Wechselwirkungen und der Streuung (Formparameter $\hat{b}$).

Die Integration der Ankerpunkte modifiziert das Regressionsmodell messbar und offenbart eine wertvolle Anreicherung des ungestützten Extrapolationsmodells. Während die Konstante $\hat{\beta}_0$ sowie die Effekte $\hat{\beta}_2$ und $\hat{\beta}_{22}$ mit relativen Abweichungen von lediglich rund 2 % bis 7 % ein – im Hinblick auf den limitierten Stichprobenumfang von $N = 26$ – absolut tolerierbares und hochgradig konsistentes Grundniveau aufzeigen, erfahren andere Terme eine signifikante Neukalibrierung. So wird der Haupteffekt $\hat{\beta}_1$ durch die Ankerpunkte drastisch gedämpft ($-1,34 \rightarrow -0,62$, ca. -54%), während sich der quadratische Term $\hat{\beta}_{11}$ mehr als verdoppelt ($0,23 \rightarrow 0,57$, ca. $+148\%$). Besonders bemerkenswert ist das Verhalten der Faktoren-Interaktion $\hat{\beta}_{12}$, welche eine vollständige Vorzeichenumkehr erfährt ($0,60 \rightarrow -0,37$).

Flankierend korrigiert das **EmALT**-Design die struktur- und stichprobenbedingte Unterschätzung des Weibull-Formparameters $\hat{b}$. Das eng im Hochlastzentrum konzentrierte Basis-**CCD** schätzt mit $\hat{b} = 1,25$ eine physikalisch verhältnismäßig breite Streuung der Lebensdauern. Die realen Ankerpunkte heben diesen Wert um 33 % auf ein Niveau von $\hat{b} = 1,66$ an, was einer geringeren, deterministischeren Bauteilstreuung entspricht. Diese numerische Verschiebung der Parameter manifestiert sich visuell prägnant in den rekonstruierten Antwortflächen nach Abbildung 6.2.




Abbildung 6.2: Modellanpassung im Parameterraum (logarithmische Darstellung): Beide Regressionsflächen im direkten visuellen Vergleich. Das Basis-**CCD** extrapoliert starr aus dem Hochlastzentrum. Das **EmALT**-Design wird durch die **APs** im südwestlichen Parameterbereich gestützt und erfährt eine merkliche Dämpfung der prognostizierten Lebensdauer.

Die dreidimensionale, gemeinsame Visualisierung der Regressionsflächen liefert die ingenieurwissenschaftliche Interpretation dieser methodischen Optimierung durch Anwendung eines **EmALT**-Designs – wohl berücksichtigend, dass die Approximation der Response Surface nur eine richtungsabhängige, statistische Repräsentation der realen Lebensdauer ist: Das Basis-**CCD** approximiert die Versuchspunkte im beschleunigten Zentrum präzise entlang der Ergebnislage, extrapoliert diesen steilen Gradienten jedoch linear und ungebremst in den fernen *Use-Space*.

Das EmALT-Design hingegen registriert durch seine APs, dass die Lebensdauer bei moderateren Lasten physikalisch nicht in dem Maße ansteigt, wie es die initiale Hochlast-Extrapolation vermuten ließe. Die Response Surface erfährt durch die Ankerpunkte damit eine deutliche Dämpfung in Richtung geringerer Lebensdauern und taucht im Extrapolationsbereich messbar unter die Fläche des Basis-Modells ab. Die durch das EmALT-Design induzierte Ausprägung der Wirkungsfläche im Feldbereich stellt somit nicht nur eine graduelle Reduktion der Prädiktionsvarianz dar, sondern eine konsequente und empirisch gestützte Verfeinerung des Regressionsmodells. Daraus ergibt sich die Notwendigkeit, die ingenieurwissenschaftlichen Auswirkungen auf die Zuverlässigkeitsprognose am Feldpunkt zu evaluieren und die grundlegende methodische Verträglichkeit beider Ansätze zu plausibilisieren.

6.1.1 Residuenanalyse und Verifikationsdiagnostik

Die fundamentale Neukalibrierung der Modellparameter – insbesondere die Dämpfung des Haupteffekts $\hat{\beta}_1$ sowie die Vorzeichenumkehr der Interaktion $\hat{\beta}_{12}$ – wirft die methodische Frage auf, ob das EmALT-Design die physikalische Realität adäquat abbildet oder Schätzartefakte induziert. Zur Beantwortung dieser Fragestellung wird die Residuenstruktur beider Regressionsmodelle anhand der in Abschnitt 2.2.6 hergeleiteten diagnostischen Metriken überprüft - vgl. Abbildung 6.3.

Die Analyse der standardisierten Devianz-Residuen r_{Dev} - siehe Gleichung (2.72) - über der logarithmierten charakteristischen Lebensdauer $\ln(\hat{T})$ in Abbildung 6.3 (links) bestätigt die Homoskedastizität beider Modelle: Die Residuen streuen symmetrisch um den Nullpunkt und verharren mit Ausnahme singulärer Randbeobachtungen innerhalb der statistischen Toleranzschranken von $\pm 2\sigma$. Das EmALT-Design weist über den gesamten Prädiktionsbereich von $\ln(\hat{T}) = 10,4$ bis $16,0$ (entsprechend einer Lebensdauer bis über 10^6 h) eine homogene, trendfreie Verteilung auf.

Flankierend liefert die Auswertung der Cox-Snell-Residuen r_{CS} (Gleichung (2.71)) in Abbildung 6.3 (rechts) den empirischen Nachweis der überlegenen Modellanpassung: Während die Residuen des Basis-CCD im oberen Wertebereich ($r_{\text{CS}i} > 2,0$) eine systematische Krümmung und Abweichung von den theoretischen Quantilen – $\ln(1 - F)$ aufweisen, folgen die Residuen des EmALT-Designs bis zu Werten von $r_{\text{CS}i} \approx 3,5$ nahezu ideal der theoretischen Winkelhalbierenden. Dies belegt, dass die Integration der Ankerpunkte einen möglichen Lack-of-Fit im Niedriglastbereich eli-




Abbildung 6.3: Residuenanalyse der Modellpassung für das Basis-CCD und das EmALT-Design am realen Prüfstandsdatensatz ($N = 26$): Standardisierte Devianz-Residuen über $\ln(\hat{T})$ (links) sowie Cox-Snell-Residuen (rechts).

minierte. Damit ist formal nachgewiesen, dass die signifikante Verschiebung der Modellparameter in $\hat{\beta}$ keine statistische Verzerrung darstellt, sondern das reale tribologische Verschleißverhalten des Zahnriemens mathematisch konsistent und frei von systematischen Anpassungsmängeln abbildet. Dieses empirische Ergebnis bestätigt die simulationsbasierten Erkenntnisse aus Kapitel 5: Die durch das EmALT-Design induzierte Umverteilung der Schätzvarianz bewahrt die statistische Signifikanz der Modelleffekte (vgl. Tabelle 5.16) und führt am realen Prüfstand zu einer signifikant überlegenen, physikalisch fundierten Modellgüte.

6.2 Konsequenzen für die Zuverlässigkeitsmodellierung

Die Korrektur der Antwortfläche wirkt sich unmittelbar auf die statistische Feldabsicherung am anvisierten Prognosepunkt $(-1,50; -1,80)$ aus. Abbildung 6.4 projiziert die parametrisierten Modelle auf den Verlauf der Überlebenswahrscheinlichkeit $\hat{R}(t)$. Dargestellt sind die Zuverlässigkeitsfunktionen auf Grundlage der Gleichungen (2.2), (2.56) und (2.69) sowie die korrespondierenden 90 %-CIs, ermittelt über

die Delta-Methode auf Basis der invertierten beobachteten Fisher-Informationsmatrix $\mathbf{F}_{\text{ob}}$.




Abbildung 6.4: Empirische Lebensdauerprognose am Feldpunkt. Das **EmALT**-Design liefert eine radikal verkleinerte Prädiktionsvarianz (schmales Konfidenzband). Sein Median verbleibt kohärent innerhalb des weiten Vertrauensbereichs des Basis-**CCD**, zeichnet jedoch ein realitätsnäheres und konservativeres Ausfallverhalten.

Die Auswertung bestätigt zunächst die theoriegeleitete Erwartung zur Varianzreduktion aus Kapitel 5: Das Basis-**CCD** weist aufgrund der ungestützten Extrapolationsdistanz eine stark ausgeprägte Prädiktionsvarianz von $SPV = 55,04$ im Prognosepunkt auf. Dies führt zu einem extrem breiten Konfidenzband für die Prognose im Feldbetriebspunkt, das bei einer beispielhaften Laufzeit von 5×10^5 h eine maximale Unschärfe von 98,2 % aufspannt. Das **EmALT**-Design hingegen reduziert die Varianz durch die implementierten **APs** massiv: Die **SPV** kollabiert auf 4,86, wodurch sich die Breite des **CI** am Referenzpunkt auf hochpräzise 7,4 % verdichtet. Die Extrapolationsunsicherheit wird somit um einen Faktor von 11,3 minimiert.

Neben dieser Varianzdämpfung offenbart Abbildung 6.4 ein für die methodische Einordnung essenzielles Phänomen: Das **EmALT**-Design zeichnet aufgrund der Dämpfung und des höheren Formparameters zwar einen steileren, konservativeren Verlauf des Zuverlässigkeitsabfalls. Der Median-Schätzwert dieses angepassten Modells wird jedoch über weite Strecken der Laufzeit nahezu vollständig vom breiten

Varianzbereich des Basis-**CCD**-Modells abgedeckt. Die Nutzung von Ankerpunkten dementiert das Basis-**CCD** nicht, sondern reichert es substanziell an. Das **EmALT**-Design überführt die valide, aber extrapolationsbedingt unscharfe Basisprognose des **CCD** in einen hochpräzisen und empirisch fundierten Vertrauenskorridor.

Diese stochastische Absicherung spiegelt sich unweigerlich in der ökonomischen Realität der Kostengleichung entsprechend Abschnitt 5.4 wider. Während das Basis-**CCD** mit aggregierten Gesamtkosten von lediglich 68,3 kCU vordergründig extrem wirtschaftlich erscheint, schlägt sich das **EmALT**-Design mit 371,2 kCU zu Buche. Dieser Kostenanstieg ist physikalisch determiniert: Die Verschiebung der **APs** in den Niedrigstress-Bereich (nahe dem Feldbetrieb) erzwingt exponentiell längere Testlaufzeiten der Prüflinge. Aus dieser Gegenüberstellung resultiert die Notwendigkeit, diesen monetären Mehraufwand objektiv zu evaluieren. Es gilt zu überprüfen, ob sich dieser Einsatz bei einem statistischen Härtetest des Basis-Modells als zwingend wirtschaftliche und stochastische Notwendigkeit erweist.

6.2.1 Confirmation Experiments: Der statistische Härtetest

Um das Basis-**CCD** einem belastbaren Härtetest zu unterziehen, wird dieses anhand der real getesteten Ankerpunkte mittels *prädiktionsintervall-basierter* Analysemethoden herausgefordert. Hierfür fungieren die **APs** als formale *Confirmation Runs* nach Stevens und Anderson-Cook [124]. Die zugrundeliegende Prüflogik besagt: Wenn das durch das Basis-**CCD** im Hochlastbereich extrahierte Modell die physikalische Realität auch an den Rändern des Versuchsraums noch valide abbildet, müssen die realen Ausfallzeiten der fernen Ankerpunkte zwingend innerhalb des vom **CCD** prä-dizierten Streubandes liegen. Sollten die empirischen Ausfallzeiten dieses Intervall wider Erwarten verfehlen, wäre das Basis-Modell stochastisch falsifiziert und müsste zwingend um zusätzliche Stützstellen korrigiert werden, um fatale Fehlinterpretationen im Feldbereich zu verhindern. Dazu wird für die **AP**-Koordinaten das **Prediction Interval (PI)** des Basis-**CCD** berechnet. Da die Ausfallzeiten Weibull-verteilt sind, definiert sich das **PI** über das 5 %- und 95 %-Quantil der geschätzten Verteilung, auf welches additiv die epistemische Parameterunsicherheit über die Δ -Methode der **F** angewandt wird.

Die quantitative Auswertung dieser Konfirmationsläufe liefert ein hochgradig aufschlussreiches stochastisches Resultat: Die empirisch realisierten Ausfallzeiten

an beiden peripheren Ankerpunkten (welche sich im Bereich von rund 3,95 bis $4,30 \times 10^6$ h für die erste und 1,85 bis $1,91 \times 10^6$ h für die zweite Stützstelle bewegen) liegen **vollständig innerhalb** der durch das Basis-CCD berechneten 90 %-PIs. Das ungestützte Basis-Modell wird durch die realen Testläufe somit formell statistisch bestätigt und keineswegs falsifiziert.

Eine ingenieurswissenschaftliche Betrachtung der berechneten Intervallgrenzen entlarvt jedoch die fundamentale Schwäche der reinen Hochlast-Extrapolation: Bedingt durch die extreme Prädiktionsvarianz spannen die Vertrauensbereiche des Basis-CCD an diesen Koordinaten unbrauchbare Größenordnungen auf – von minimal $3,63 \times 10^5$ h bis hin zu exorbitanten $8,23 \times 10^{12}$ h am ersten Ankerpunkt sowie von $7,11 \times 10^4$ h bis $1,51 \times 10^{10}$ h am zweiten. Dieser Härtetest verdeutlicht empirisch den Kern des Problems: Das orthogonale Basis-CCD besteht den formalen statistischen Test (90 % Coverage) paradoxerweise nur deshalb, weil seine ungebremschte Varianzinflation im Extrapolationsraum ein Streuband erzeugt, das mehrere Zehnerpotenzen umfasst. Für normative Zuverlässigkeitsnachweise und Garantieentscheidungen verliert es dadurch jegliche praktische Trennschärfe. Die methodische Allokation der APs stellt somit keine rein akademische Optimierung dar, sondern eine zwingende ingenieurswissenschaftliche Notwendigkeit: Sie zwingt das ausufernde Konfidenzband der Hochlast-Extrapolation in ein belastbares, praxistaugliches Prognosemodell mit eng geführten und empirisch fundierten Vertrauensgrenzen.

6.2.2 Ökonomische Schlussfolgerung und industrieller Business Case

Die Validierung am extremen Randbereich durch die *Confirmation Runs* liefert den abschließenden, formellen Beleg für die Natur der EoL-Kostengleichung. Vordergründig suggeriert der rein monetäre Vergleich eine Ineffizienz des EmALT-Designs: Einem ressourcenschonenden Basis-CCD mit Gesamtkosten von lediglich 68,3 kCU steht im EmALT-Design ein geforderter Prüfstandsaufwand von 371,2 kCU gegenüber. Werden diese Versuchspläne jedoch der industriellen Realität der Zuverlässigkeitsfreigabe unterzogen, entlarvt sich die reine ALT-Kostenreduktion des Basis-Designs als irreführende Investition.

Der entscheidende ingenieurswissenschaftliche Maßstab für die Testeffizienz ist nicht die alleinige Minimierung der nominalen Prüfkosten, sondern die Minimie-

rung von Garantierisiken bei gleichzeitiger Sicherstellung der *Time-to-Market*. Das Basis-CCD erkaufte sich seine geringen nominellen Testkosten durch eine Prädiktionsunsicherheit, die für normative Sicherheitsnachweise unzureichend ist: Die resultierenden Konfidenzbänder spannen am Prognosepunkt eine rechnerische Überlebenswahrscheinlichkeit zwischen nahezu 0 % und 100 % auf, wodurch eine belastbare Aussage zur Feldbewährung unmöglich wird.

Die fundamentale Überlegenheit der topologischen Anpassung offenbart sich beim Vergleich mit der vermeintlich idealen Alternative: einem direkt auf den Prognosepunkt zentrierten, orthogonalen Feld-CCD (13 Versuchspunkte mit zwei Replikationen, $N = 26$). Ein solcher Versuchsplan würde zwar die Extrapolationsunschärfe eliminieren, müsste jedoch vollständig unter unbeschleunigten, feldnahen Bedingungen betrieben werden. Die analytische Kostenprognose entlarvt die ökonomische Inkompatibilität dieses theoretischen Optimums mit industriellen Entwicklungszyklen: Der Feld-CCD würde an dieser Stelle exorbitante Prüfkosten von 22 152,0 kCU verursachen. Dieser extreme Aufwand blockiert nicht nur immense Prüfstandskapazitäten, sondern sprengt auch jegliche Entwicklungszeitpläne im Sinne der *Time-to-Market* vollständig.

Vor diesem Hintergrund transformiert sich die scheinbare Kostendifferenz von rund 300 kCU des EmALT-Designs im Vergleich zum Basis-CCD in eine hochprofitable Investitionsprämie. Das EmALT-Design agiert hierbei als hocheffiziente mathematisch-geometrische Brücke: Durch das strategische Re-Investment der asymmetrischen Ankerpunkte komprimiert es die Prognoseunschärfe im anvisierten Feld-Betriebspunkt auf präzise 7,4 %. Es realisiert somit die stochastische Präzision eines echten Feldtests für einen Bruchteil von dessen Kosten (lediglich ca. 1,68 % des Feld-CCD-Aufwands) und bewahrt gleichzeitig den signifikanten Beschleunigungsvorteil der klassischen ALT-Methodik.

Die adaptive Nutzung des topologischen Gestaltungsbudgets legitimiert sich somit nicht allein aus informationstheoretischer Ästhetik. Sie etabliert sich vielmehr als unabdingbares industrielles Steuerungswerkzeug, das die Vorhersagegüte schärft, konservative Systemreserven vor teurer Überdimensionierung schützt und das Zuverlässigkeitsmanagement befähigt, harte, wirtschaftlich belastbare Garantieentscheidungen zu treffen.

7 Zusammenfassung und Ausblick

Die vorliegende Arbeit löst den fundamentalen methodischen Konflikt auf, der einer effizienten, multivariaten Zuverlässigkeitsmodellierung bislang im Wege steht. Sie beantwortet die zentrale Forschungsfrage, wie klassische **RSDs** für die spezifischen Zwecke des **ALT** effizient geplant und individuell adaptiert werden können. Der erarbeitete Paradigmenwechsel – weg von der starren Maximierung klassischer Design-Volumina hin zu einer stochastisch und ökonomisch ausbalancierten Extrapolationsabsicherung unter Beibehaltung des Prüfumfangs **N** - beantwortet die in Kapitel 3 formulierte Hauptforschungsfrage sowie die zugehörigen Teilforschungsfragen abschließend. Dieser Erkenntnisgewinn manifestiert sich in fünf zentralen wissenschaftlichen Säulen:

1. Dynamische Systematik der Parametersелеktion:

Die Identifikation der maßgeblichen Stressfaktoren erfordert bereits in der qualitativen Screening-Phase eine Abkehr von starren methodischen Schablonen. Der entwickelte heuristische Screening-Ansatz (Kapitel 4) belegt, dass die Effizienz der Variablenselektion nur durch die explizite Berücksichtigung latenter Wechselwirkungen sowie der dynamischen Änderung von Aktivmen-gen maximiert werden kann. Dies legt das unabdingbare Fundament für alle nachfolgenden quantitativen Modellierungen.

2. Limitierung klassischer Optimalitätskriterien:

Die methodische Untersuchung beweist, dass volumenbasierte Optimalitätsmaße (insbesondere die als Standard verbreitete klassische *D*-Effizienz) für **EoL**-Versuche systematisch ineffizient sind. Da der Fokus beschleunigter Prüfungen nicht auf der Interpolation, sondern auf der weiten Extrapolation in den Feldbereich liegt, führt ein rein orthogonal ausgerichtetes Design zu einer unzulässig hohen skalierten Prädiktionsvarianz (**SPV**) am fernen Prognosepunkt.

3. Adaptionstrategie mittels topologischer Resilienz (Teilforschungsfrage 1):

Umfangreiche Sensitivitätsanalysen decken auf, dass etablierte Standard-Versuchspläne wie das **CCD** eine unerwartet hohe topologische Resilienz aufweisen. Der asymmetrische Entfall unkritischer Stützstellen bewirkt tolerierbare Einbußen in der statistischen Trennschärfe (*power*) der Haupteffekte. Diese Erkenntnis legitimiert den bewussten Verzicht auf strikte Orthogonalität und eröffnet dem Versuchsplaner ein wertvolles **geometrisches Gestaltungsbudget**, um den klassischen Augmentierungs-Gedanken isometrisch ($N_{\text{adaptiv}} \leq N_{\text{CCD}}$) durch gezielte Stützstellen-Reallokation fortzuführen.

4. Bewertungsmethodik und physikalisch-ökonomisches Optimum (Teilforschungsfrage 2):

Die proaktive Umwidmung des Gestaltungsbudgets in asymmetrische Ankerpunkte (**APs**) nahe dem Feldbereich (**EmALT**-Methodik) minimiert die Extrapolationsvarianz zielgerichtet. Um die Auswirkungen dieser Orthogonalitätsmanipulationen quantitativ zu bewerten, dient der richtungssensitive **EVG** als geometrischer Indikator. Flankierend überführt der Economic Extrapolation Power Index (**EPI**) die reine statistische *Effektivität* (Trennschärfe und Prädiktionsvarianz) unter Berücksichtigung exponentiell skalierender Prüflaufzeiten in eine ganzheitliche ökonomische *Effizienz*. Die Bilanzierung weist nach, dass das **EmALT**-Design das globale Pareto-Optimum aus reduzierter Prognoseunsicherheit und vertretbaren Prüfstandskosten darstellt.

5. Empirische Validierung und methodische Notwendigkeit:

Die industrielle Fallstudie liefert anhand realer Prüfstandsdaten den abschließenden Beweis, dass die Extrapolationsabsicherung keine rein theoretische Optimierung darstellt. Prädiktionsintervall-basierte Härtetests (*Confirmation Experiments*) belegen empirisch, dass ein ungestütztes Basis-Modell bei reiner Hochlast-Abtastung im fernen Feldbereich infolge massiver Varianzinflation jegliche praktische Aussagekraft einbüßt. Die methodische Allokation von Ankerpunkten erweist sich somit als zwingende Notwendigkeit, um Zuverlässigkeitsmodelle vor sicherheitskritischen Überschätzungen im Feldbetrieb zu bewahren und belastbare normative Nachweise zu ermöglichen.

Zusammenfassend lässt sich konstatieren, dass die entwickelte Methodik weit über den Rahmen der hier betrachteten Referenzdesigns und spezifischen Arbeitspunkte hinausreicht. Abseits der sorgfältigen numerischen Beweisführung etabliert die vorliegende Arbeit einen **allgemeingültigen Analyse-Leitpfad**. Das geschaffene Instrumentarium - bestehend aus richtungssensitiver Varianzbewertung (EVG), stochastisch-ökonomischer Bilanzierung (EPI) und prädiktiver Validierung (*Confirmation Experiments*) - dient künftig als universelles Leitgerüst. Es befähigt den Versuchsplaner, prinzipiell beliebige Modifikationen an multivariaten Testdesigns quantitativ zu charakterisieren, objektiv zu bewerten und effiziente Lebensdauerversuche in unterschiedlichsten industriellen Kontexten systematisch abzusichern.

7.1 Diskussion

Die entwickelte Methodik bietet ein weitreichendes Instrumentarium zur Steigerung der Modelleffizienz, bedarf jedoch hinsichtlich ihrer Anwendbarkeit und Skalierbarkeit einer kritischen ingenieurwissenschaftlichen Einordnung.

Die fundamentale Prämisse der Extrapolationsabsicherung durch EmALT beruht auf der Annahme einer stetigen Degradationskinematik. Das log-lineare AFT-Modell geht von einem einheitlichen Ausfallmechanismus über den gesamten abgetasteten Parameterraum aus. Die Ankerpunkte verschieben die empirische Absicherung zwar signifikant näher an den Feldbereich und reduzieren das Risiko unerkannter Nichtlinearitäten im Vergleich zur klassischen Hochlast-Prüfung massiv. Abrupte physikalische Mechanismenwechsel, die erst bei noch geringeren Lasten (zwischen den APs und dem nominellen Feld-Niveau) auftreten, kann jedoch auch dieses Design rein datenbasiert nicht a priori prädizieren. Das Modell verbleibt folglich eine stochastische Approximation der Realität, die stets durch physikalisches Domänenwissen plausibilisiert werden muss.

Eine zentrale methodische Randbedingung der adaptiven Versuchsplanung liegt zudem in der inhärenten Kopplung an das verfügbare *A-priori*-Wissen [82]. Die optimale Platzierung der Ankerpunkte innerhalb der *Exposure-Area* (gestützt durch den EVG) sowie die Vorabkalkulation des EPI erfordern initiale Annahmen über die zugrundeliegenden Weibull-Parameter und das Kostengefüge. Entspricht die frühe Schätzung der Effektgrößen nicht der wahren Systemkinematik, verschiebt sich die

topologische Effizienz des konzipierten Versuchsplans. Die Methodik ist somit in hohem Maße an die Qualität der vorangegangenen Screening-Phase (Kapitel 4) gebunden.

Hinsichtlich der algorithmischen Skalierbarkeit konzentrieren sich die grafischen und analytischen Nachweise im Rahmen dieser Arbeit auf den zweidimensionalen Versuchsraum ($k = 2$). Während die Berechnungen der Informationsmatrix, der SPV sowie der Trennschärfe mathematisch dimensionsunabhängig operieren, steigt die Komplexität der Identifikation und Visualisierung vorteilhafter APs in höherdimensionalen Parameterräumen signifikant an. Die Verortung von Ankerpunkten auf Basis rasterartiger Auswertungen stößt bei multivariaten Problemen mit drei oder mehr interagierenden Stressfaktoren an rechnerische und visuelle Grenzen.

7.2 Ausblick

Aus den identifizierten Restriktionen leiten sich direkte Impulse für die weiterführende wissenschaftliche Forschung im Schnittfeld von Zuverlässigkeitstechnik und statistischer Versuchsplanung ab.

Zur Adressierung des dimensional Skalierungsproblems empfiehlt sich die Entwicklung automatisierter Optimierungsalgorithmen. Die Überführung der EmALT-Positionierung in ein deterministisches *Constrained Optimization Problem* - bei welchem Algorithmen die Ankerpunkte unter Einhaltung numerischer SPV-Schranken und anlagenspezifischer Parametergrenzen selbstständig in mehrdimensionalen Räumen allokalieren - beschleunigt den industriellen Planungsprozess und macht ihn unabhängig von manuellen, visuellen EVG-Auswertungen.

Um die Abhängigkeit von initialem *A-priori*-Wissen zu reduzieren, bietet die Integration der EmALT-Methodik in sequenzielle oder Bayes'sche Versuchsplanungsstrategien ein herausragendes Potenzial [3, 82, 128]. Ein dynamisches DoE, welches erste Ausfallereignisse aus dem faktoriellen Hochlast-Kern in Echtzeit auswertet, um die Koordinaten der nachgelagerten Ankerpunkte laufend zu aktualisieren und an das sich abzeichnende Ausfallverhalten anzupassen, maximiert die Effizienz der experimentellen Ressourcenallokation.

Schließlich erfordert die Generalisierung des Ansatzes eine systematische Ausweitung jenseits des hier fokussierten AFT-Modells für isolierte Totalausfälle. Die

Übertragung der gerichteten Extrapolationsabsicherung auf Modelle mit konkurrierenden Ausfallmechanismen (*Competing Risks*) oder auf Degradationsmodelle, bei denen der kontinuierliche Verschleißverlauf als stochastische Zielgröße dient, stellt den logischen nächsten Paradigmenwechsel dar. Dies erweitert den Anwendungsbereich der **EmALT**-Strategie von der klassischen Lebensdauerprüfung auf die proaktive Zustandsüberwachung (*Condition Monitoring*) und zukunftsweisende *Predictive-Maintenance*-Architekturen.

Literatur

- [1] B. Bertsche und M. Dazer. *Zuverlässigkeit im Fahrzeug- und Maschinenbau: Ermittlung von Bauteil- und System-Zuverlässigkeiten*. 4. Auflage. Lehrbuch. Berlin und Heidelberg: Springer Vieweg, 2022. ISBN: 978-3-662-65023-3. URL: <http://www.springer.com/>.
- [2] W. Q. Meeker, L. A. Escobar und F. G. Pascual. *Statistical methods for reliability data*. Second edition. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2022. ISBN: 978-1-118-11545-9.
- [3] S. E. Rigdon, R. Pan, D. C. Montgomery und L. J. Freeman. *Design of experiments for reliability achievement*. Hoboken, NJ: Wiley, 2022. ISBN: 9781119237693. DOI: [10.1002/9781119237754](https://doi.org/10.1002/9781119237754).
- [4] *DAT Report 2025: Kurzbericht*. Ostfildern, Deutschland, 2025. URL: https://www.dat.de/fileadmin/protected/DAT_Report/2025/DAT-Report-2025-Kurzbericht.pdf (besucht am 13.06.2025).
- [5] A. Birolini. *Reliability Engineering*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2017. ISBN: 978-3-662-54208-8. DOI: [10.1007/978-3-662-54209-5](https://doi.org/10.1007/978-3-662-54209-5).
- [6] G. Yang. *Life cycle reliability engineering*. Hoboken, N.J.: Wiley, 2007. ISBN: 9780471715290. URL: <http://www.loc.gov/catdir/enhancements/fy0740/2006019150-b.html>.
- [7] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot und G. Tutz. *Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2016. ISBN: 978-3-662-50371-3. DOI: [10.1007/978-3-662-50372-0](https://doi.org/10.1007/978-3-662-50372-0).
- [8] E. L. Kaplan und P. Meier. „Nonparametric Estimation from Incomplete Observations“. In: *Journal of the American Statistical Association* 53.282 (1958), S. 457. ISSN: 01621459. DOI: [10.2307/2281868](https://doi.org/10.2307/2281868).

- [9] J. Hedderich und L. Sachs. *Angewandte Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2020. ISBN: 978-3-662-62293-3. DOI: [10.1007/978-3-662-62294-0](https://doi.org/10.1007/978-3-662-62294-0).
- [10] H. Rinne. *The Weibull Distribution: A Handbook*. 1st ed. London: CRC Press LLC, 2008. ISBN: 978-1-4200-8743-7. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=1633687>.
- [11] D. Kececioglu. *Reliability & life testing handbook*. Lancaster, PA: DEStech Publications, 2002. ISBN: 1-932078-03-7.
- [12] D. C. Montgomery, E. A. Peck und G. G. Vining. *Introduction to linear regression analysis*. Sixth edition. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2021. ISBN: 978-1-119-57872-7.
- [13] W. Nelson. *Accelerated Testing: Statistical Models, Test Plans, and Data Analysis*. 1st ed. Bd. v.344. Wiley Series in Probability and Statistics Series. Newark: John Wiley & Sons Incorporated, 1990. ISBN: 978-0471697367. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=469757>.
- [14] J. D. Kalbfleisch. *The statistical analysis of failure time data*. 2nd ed. Wiley series in probability and statistics. Hoboken, N.J.: J. Wiley, 2002. ISBN: 047136357X. DOI: [10.1002/9781118032985](https://doi.org/10.1002/9781118032985).
- [15] W. Nelson. *Applied Life Data Analysis*. Bd. v.577. Wiley series in probability and statistics. Hoboken: John Wiley & Sons Inc, 2005. ISBN: 9780471644620. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226561>.
- [16] H. Qiao und C. P. Tsokos. „Parameter estimation of the Weibull probability distribution“. In: *Mathematics and Computers in Simulation* 37.1 (1994), S. 47–55. ISSN: 0378-4754. DOI: [10.1016/0378-4754\(94\)90058-2](https://doi.org/10.1016/0378-4754(94)90058-2).
- [17] A. Kremer und B. Bertsche. „A New Approach for Parametrizing Multidimensional Lifetime Models“. In: *Proceedings of the 29th European Safety and Reliability Conference (ESREL)*. Hrsg. von M. Beer und E. Zio. Europe und Singapore: European Safety and Reliability Association und Research Publishing Services, 2019, S. 715–722. ISBN: 978-981-11-2724-3. DOI: [10.3850/978-981-11-2724-3\textunderscore0443-cd](https://doi.org/10.3850/978-981-11-2724-3\textunderscore0443-cd).

-
- [18] R. B. Abernethy. *The new Weibull handbook: Reliability & statistical analysis for predicting life, safety, risk, support costs, failures, and forecasting warranty claims, substantiation and accelerated testing, using Weibull, log normal, Crow-AMSAA, Probit, and Kaplan- meier Models*. 5. ed. North Palm Beach, Fla.: R.B. Abernethy, 2006. ISBN: 0965306232.
- [19] H. Hirose. „Bias correction for the maximum likelihood estimates in the two-parameter Weibull distribution“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 6.1 (1999), S. 66–68. ISSN: 10709878. DOI: [10.1109/94.752011](https://doi.org/10.1109/94.752011).
- [20] R. Ross. „Bias and standard deviation due to Weibull parameter estimation for small data sets“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 3.1 (1996), S. 28–42. ISSN: 10709878. DOI: [10.1109/94.485512](https://doi.org/10.1109/94.485512).
- [21] A. Kremer und B. Bertsche. „A Methodology for Consideration of Uncertainty in Lifetime Design of Experiments“. In: *2019 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2019, S. 1–6. ISBN: 978-1-5386-6554-1. DOI: [10.1109/RAMS.2019.8768906](https://doi.org/10.1109/RAMS.2019.8768906).
- [22] J. F. Lawless. *Statistical models and methods for lifetime data*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley-Interscience, 2003. ISBN: 0471372153. URL: <http://www.loc.gov/catdir/bios/wiley044/2002151805.html>.
- [23] L. J. Bain und M. Engelhardt. *Statistical Analysis of Reliability and Life-Testing Models*. Routledge, 2017. ISBN: 9780203738733. DOI: [10.1201/9780203738733](https://doi.org/10.1201/9780203738733).
- [24] R. A. Fisher. *The Design of Experiments*. Edinburgh: Oliver & Boyd, 1935.
- [25] G. E. P. Box, W. G. Hunter und J. S. Hunter. *Statistics for experimenters: An introduction to design, data analysis, and model building*. Wiley series in probability and mathematical statistics. New York: Wiley, 1978. ISBN: 0471093157. URL: <http://www.loc.gov/catdir/description/wiley033/77015087.html>.
- [26] G. Taguchi. *Taguchi's quality engineering handbook*. Hoboken, NJ: Wiley, 2005. ISBN: 9780471413349. DOI: [10.1002/9780470258354](https://doi.org/10.1002/9780470258354).
- [27] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 10., überarbeitete Auflage. Praxisreihe Qualität. München: Hanser, 2020. ISBN: 978-3-446-46397-4.

- [28] D. C. Montgomery. *Design and Analysis of Experiments*. 10th. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2020. ISBN: 9781119722106.
- [29] C.-F. Wu und M. Hamada. *Experiments: Planning, analysis and optimization*. Third edition. Wiley series in probability and statistics. Hoboken, NJ, USA: Wiley, 2021. ISBN: 9781119470106. URL: <https://zbmath.org/?q=an%3A1460.62003>.
- [30] W. Q. Meeker und L. A. Escobar. „A Review of Recent Research and Current Issues in Accelerated Testing“. In: *International Statistical Review / Revue Internationale de Statistique* 61.1 (1993), S. 147. ISSN: 03067734. DOI: [10.2307/1403600](https://doi.org/10.2307/1403600).
- [31] E. A. Elsayed und H. Zhang. „Design of PH-based accelerated life testing plans under multiple-stress-type“. In: *Reliability Engineering & System Safety* 92.3 (2007), S. 286–292. ISSN: 09518320. DOI: [10.1016/j.ress.2006.04.016](https://doi.org/10.1016/j.ress.2006.04.016).
- [32] K. Siebertz, D. van Bebber und T. Hochkirchen. *Statistische Versuchsplanung: Design of Experiments (DoE)*. 3. Auflage. VDI-Buch. Berlin und Heidelberg: Springer Vieweg, 2026. ISBN: 978-3-662-73090-4.
- [33] P. Goos und B. A. Jones. *Optimal Design of Experiments: A Case Study Approach*. 1st. Hoboken, NJ: John Wiley & Sons, Inc, 2011. ISBN: 9780470744611.
- [34] K. Hinkelmann. *Design and Analysis of Experiments - Volume 3: Special Designs and Applications*. 1st. John Wiley & Sons, Inc, 2012. ISBN: 978-0470-53068-9.
- [35] R. H. Myers, D. C. Montgomery und C. M. Anderson-Cook. *Response Surface Methodology: Process and Product Optimization Using Designed Experiments*. 4. Aufl. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2016. ISBN: 978-1-118-91601-8.
- [36] M. Dazer. *Zuverlässigkeitstestplanung mit Berücksichtigung von Vorwissen aus stochastischen Lebensdauerberechnungen*. 2019. DOI: [10.18419/OPUS-10501](https://doi.org/10.18419/OPUS-10501).
- [37] T. Herzig. *Anforderungsgerechte Produktauslegung durch Planung effizienter beschleunigter Zuverlässigkeitstests*. 2021. DOI: [10.18419/OPUS-12001](https://doi.org/10.18419/OPUS-12001).
- [38] A. Grundler. *Zuverlässigkeitsnachweis von Systemen durch Komponenten- und Systemtests unter Berücksichtigung von Vorkenntnissen*. 2024. DOI: [10.18419/OPUS-14393](https://doi.org/10.18419/OPUS-14393).

-
- [39] A. Kremer. „Statistische Versuchsplanung in der Lebensdauererprobung mit Vertrauensintervallen“. Diss. 2021. DOI: [10.18419/OPUS-11728](https://doi.org/10.18419/OPUS-11728).
- [40] D. E. Coleman und D. C. Montgomery. „A Systematic Approach to Planning for a Designed Industrial Experiment“. In: *Technometrics* 35.1 (1993), S. 1. ISSN: 0040-1706. DOI: [10.2307/1269280](https://doi.org/10.2307/1269280).
- [41] C. Gundlach. „Entwicklung eines ganzheitlichen Vorgehensmodells zur problemorientierten Anwendung des statistischen Versuchsplanung“. Zugl.: Kassel, Univ., Diss, 2004. Kassel. URL: <http://d-nb.info/971843546/34>.
- [42] B. Mayers. *Prozeß- und Produktoptimierung mit Hilfe der statistischen Versuchsmethodik*: Zugl.: Aachen, Techn. Hochsch., Diss., 1997. Als Ms. gedr. Bd. 97,9. Berichte aus der Produktionstechnik. Aachen: Shaker, 1997. ISBN: 3826524977.
- [43] G. Pahl, W. Beitz, J. Feldhusen und K.-H. Grote. *Engineering design: A systematic approach*. 3. ed. London: Springer, 2007. ISBN: 978-1-84628-318-5. DOI: [10.1007/978-1-84628-319-2](https://doi.org/10.1007/978-1-84628-319-2).
- [44] W. F. Daenzer und R. Haberfellner, Hrsg. *Systems Engineering: Methodik und Praxis*. 11., durchges. Aufl. Zürich: Verl. Industrielle Organisation, 2002. ISBN: 385743998X.
- [45] U. Lindemann, M. Maurer und T. Braun. *Structural Complexity Management: An Approach for the Field of Product Design*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008. ISBN: 978-3-540-87888-9. DOI: [10.1007/978-3-540-87889-6](https://doi.org/10.1007/978-3-540-87889-6).
- [46] G. E. P. Box und J. S. Hunter. „Multi-Factor Experimental Designs for Exploring Response Surfaces“. In: *The Annals of Mathematical Statistics* 28.1 (1957), S. 195–241.
- [47] G. E. P. Box und D. W. Behnken. „Some New Three Level Designs for the Study of Quantitative Variables“. In: *Technometrics* 2 (1960), S. 455–475. ISSN: 0040-1706.
- [48] B. Jones und C. J. Nachtsheim. „Efficient Designs With Minimal Aliasing“. In: *Technometrics* 53.1 (2011), S. 62–71. ISSN: 0040-1706. DOI: [10.1198/TECH.2010.09113](https://doi.org/10.1198/TECH.2010.09113).

- [49] A. M. Dean, D. Voss und D. Draguljić. *Design and analysis of experiments*. Second edition. Springer texts in statistics. Cham: Springer, 2017. ISBN: 978-3-319-52248-7. DOI: [10.1007/978-3-319-52250-0](https://doi.org/10.1007/978-3-319-52250-0).
- [50] G. E. P. Box und K. B. Wilson. „On the Experimental Attainment of Optimum Conditions“. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 13.1 (1951), S. 1–45. ISSN: 00359246. URL: <http://www.jstor.org/stable/2983966> (besucht am 23.03.2023).
- [51] G. E. P. Box, S. Bisgaard und C. Fung. „An explanation and critique of taguchi’s contributions to quality engineering“. In: *Quality and Reliability Engineering International* 4.2 (1988), S. 123–131. ISSN: 0748-8017. DOI: [10.1002/qre.4680040207](https://doi.org/10.1002/qre.4680040207).
- [52] S. Bisgaard. „A Conceptual Framework for the use of Quality Concepts and Statistical Methods in Product Design“. In: *Journal of Engineering Design* 3.1 (1992), S. 31–47. ISSN: 0954-4828. DOI: [10.1080/09544829208914746](https://doi.org/10.1080/09544829208914746).
- [53] I. Paschal und I. Fortune. „Performance Evaluation of Custom A-, D-, and I-Optimal Designs for Non-Standard Second-Order Models“. In: *American Journal of Theoretical and Applied Statistics* 13.5 (2024), S. 92–114. ISSN: 2326-8999. DOI: [10.11648/j.ajtas.20241305.11](https://doi.org/10.11648/j.ajtas.20241305.11).
- [54] K. G. Russell. *Design of experiments for generalized linear models*. Chapman and Hall/CRC Interdisciplinary Statistics Ser. Boca Raton, London und New York: CRC Press Taylor & Francis Group, 2019. ISBN: 9780429057489. DOI: [10.1201/9780429057489](https://doi.org/10.1201/9780429057489).
- [55] F. Pukelsheim. *Optimal design of experiments: Originally published: New York : J. Wiley, 1993*. Classic ed. Bd. 50. Classics in applied mathematics. Philadelphia, Pa.: Society for Industrial and Applied Mathematics (SIAM 3600 Market Street Floor 6 Philadelphia PA 19104), 2006. ISBN: 9780898716047. DOI: [10.1137/1.9780898719109](https://doi.org/10.1137/1.9780898719109).
- [56] M. Risberg Ellekjær und S. Bisgaard. „The use of experimental design in the development of new products“. In: *International Journal of Quality Science* 3.3 (1998), S. 254–274. ISSN: 1359-8538. DOI: [10.1108/13598539810229230](https://doi.org/10.1108/13598539810229230).

-
- [57] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 9., überarbeitete Auflage. Hanser eLibrary. München: Hanser, 2016. ISBN: 978-3-446-44716-5. DOI: [10.3139/9783446447172?locatt=mode:legacy](https://doi.org/10.3139/9783446447172?locatt=mode:legacy).
- [58] R. H. Myers, D. C. Montgomery, G. G. Vining und T. J. Robinson. *Generalized linear models: With applications in engineering and the sciences*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2010. ISBN: 9780470454633. DOI: [10.1002/9780470556986](https://doi.org/10.1002/9780470556986).
- [59] A. Zahran, C. M. Anderson-Cook und R. H. Myers. „Fraction of Design Space to Assess Prediction Capability of Response Surface Designs“. In: *Journal of Quality Technology* 35.4 (2003), S. 377–386. ISSN: 0022-4065.
- [60] A. Giovannitti-Jensen und R. H. Myers. „Graphical Assessment of the Prediction Capability of Response Surface Designs“. In: *Technometrics* 31.2 (1989), S. 159–171. ISSN: 0040-1706.
- [61] H. B. Goldfarb, C. M. Borror, D. C. Montgomery und C. M. Anderson-Cook. „Three-Dimensional Variance Dispersion Graphs for Mixture-Process Experiments“. In: *Journal of Quality Technology* 36.1 (2004), S. 109–124. ISSN: 0022-4065. DOI: [10.1080/00224065.2004.11980255](https://doi.org/10.1080/00224065.2004.11980255).
- [62] A. Ozol-Godfrey, C. M. Anderson-Cook und D. C. Montgomery. „Fraction of Design Space Plots for Examining Model Robustness“. In: *Journal of Quality Technology* 37.3 (2005), S. 223–235. ISSN: 0022-4065. DOI: [10.1080/00224065.2005.11980323](https://doi.org/10.1080/00224065.2005.11980323).
- [63] J. J. Borkowski, W. Limmun und B. Chomtee. „Factorwise variance dispersion graphs“. In: *Communications in Statistics - Theory and Methods* 51.23 (2022), S. 8427–8445. ISSN: 0361-0926. DOI: [10.1080/03610926.2021.1897144](https://doi.org/10.1080/03610926.2021.1897144).
- [64] R. H. Myers, G. G. Vining, A. Giovannitti-Jensen und S. L. Myers. „Variance Dispersion Properties of Second-Order Response Surface Designs“. In: *Journal of Quality Technology* 24.1 (1992), S. 1–11. ISSN: 0022-4065. DOI: [10.1080/00224065.1992.11979368](https://doi.org/10.1080/00224065.1992.11979368).
- [65] P. Schoonees, N. Le Roux und R. Coetzer. „Flexible Graphical Assessment of Experimental Designs in R : The vdg Package“. In: *Journal of Statistical Software* 74.3 (2016). DOI: [10.18637/jss.v074.i03](https://doi.org/10.18637/jss.v074.i03).

- [66] G. E. P. Box und N. R. Draper. *Response surfaces, mixtures, and ridge analyses*. 2. ed. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2007. ISBN: 9780470053577. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2006043975-b.html>.
- [67] H. Ahn. „Central Composite Design for the Experiments with Replicate Runs at Factorial and Axial Points“. In: *Industrial Engineering* 349 (2015), S. 969–979.
- [68] D. A. Belsley. *Regression diagnostics: Identifying influential data and sources of collinearity*. Wiley series in probability and statistics. New York: Wiley, 2004. ISBN: 9780471725145. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226535>.
- [69] L. Fahrmeir, T. Kneib und S. Lang. *Regression: Modelle, Methoden und Anwendungen*. 2. Auflage. Statistik und ihre Anwendungen. Heidelberg und Berlin: Springer, 2009. ISBN: 978-3-642-01836-7. DOI: [10.1007/978-3-642-01837-4](https://doi.org/10.1007/978-3-642-01837-4).
- [70] S. J. Walsh, L. Lu und C. M. Anderson-Cook. „I -optimal or G -optimal: Do we have to choose?“ In: *Quality Engineering* 36.2 (2024), S. 227–248. ISSN: 0898-2112. DOI: [10.1080/08982112.2023.2194963](https://doi.org/10.1080/08982112.2023.2194963).
- [71] S. P. Boyd und L. Vandenberghe. *Convex optimization*. Cambridge, New York, NY und Port Melbourne: Cambridge University Press, 2004. ISBN: 978-0-521-83378-3. URL: <http://www.loc.gov/catdir/description/cam041/2003063284.html>.
- [72] A. C. Atkinson. „The Design of Experiments to Estimate the Slope of a Response Surface“. In: *Biometrika* 57.2 (1970), S. 319. ISSN: 00063444. DOI: [10.2307/2334839](https://doi.org/10.2307/2334839).
- [73] A. C. Atkinson, A. N. Donev und R. D. Tobias. *Optimum Experimental Designs, with SAS*. 1st. New York: Oxford University Press Inc, 2007. ISBN: 9780199296590.
- [74] E. M. Monroe, R. Pan, C. M. Anderson-Cook, D. C. Montgomery und C. M. Borrer. „A generalized linear model approach to designing accelerated life test experiments“. In: *Quality and Reliability Engineering International* 27.4 (2011), S. 595–607. ISSN: 0748-8017. DOI: [10.1002/qre.1143](https://doi.org/10.1002/qre.1143).

-
- [75] P. Goos. „OMARS Designs for Factor Screening and Response Surface Experimentation in One Step: A Review“. In: *WIREs Computational Statistics* 17.2 (2025). ISSN: 1939-5108. DOI: [10.1002/wics.70018](https://doi.org/10.1002/wics.70018).
- [76] J. Núñez Ares und P. Goos. „Enumeration and Multicriteria Selection of Orthogonal Minimally Aliased Response Surface Designs“. In: *Technometrics* 62.1 (2020), S. 21–36. ISSN: 0040-1706. DOI: [10.1080/00401706.2018.1549103](https://doi.org/10.1080/00401706.2018.1549103).
- [77] J. Cohen. *Statistical power analysis for the behavioral sciences*. Second edition. Hillsdale, NJ: Lawrence Erlbaum Associates Publishers, 1988. ISBN: 9781134742707. DOI: [10.4324/9780203771587](https://doi.org/10.4324/9780203771587).
- [78] M. H. Kutner, C. J. Nachtsheim, J. Neter und W. Li. *Applied Linear Statistical Models*. 5. ed. McGraw-Hill/Irwin series Operations and decision sciences. Boston, Mass.: McGraw-Hill Irwin, 2005. ISBN: 0072386886. URL: <http://www.loc.gov/catdir/bios/mh042/2004052447.html>.
- [79] J. A. Nelder und R. W. M. Wedderburn. „Generalized Linear Models“. In: *Journal of the Royal Statistical Society. Series A (General)* 135.3 (1972), S. 370. ISSN: 00359238. DOI: [10.2307/2344614](https://doi.org/10.2307/2344614).
- [80] C. E. McCulloch und S. R. Searle. *Generalized, linear, and mixed models*. A Wiley-Interscience publication. New York und Weinheim: Wiley, 2001. ISBN: 9780471193647. DOI: [59430](https://doi.org/10.1002/9780471193647).
- [81] M. Arndt, P. Mell und M. Dazer. „Generic effects of deviations from test design orthogonality on test power and regression modelling of Central-Composite Designs“. In: *Proceedings of the 16th International Probabilistic Safety Assessment and Management Conference (PSAM16)*. Bd. PSAM 16. Honolulu, HI, USA, 2022.
- [82] A. Khuri. *Response Surface Methodology and Related Topics*. 1st. World Scientific Publishing Co Pte Ltd, 2006. ISBN: 9789812564580.
- [83] G. E. P. Box und D. R. Cox. „An Analysis of Transformations“. In: *Journal of the Royal Statistical Society Series B: Statistical Methodology* 26.2 (1964), S. 211–243. ISSN: 1369-7412. DOI: [10.1111/j.2517-6161.1964.tb00553.x](https://doi.org/10.1111/j.2517-6161.1964.tb00553.x).

- [84] M. V. Wüthrich und M. Merz. *Statistical Foundations of Actuarial Learning and its Applications*. Cham: Springer International Publishing, 2023. ISBN: 978-3-031-12408-2. DOI: [10.1007/978-3-031-12409-9](https://doi.org/10.1007/978-3-031-12409-9).
- [85] M. Modarres, M. Nuri-Amiri und C. Jackson. *Probabilistic physics of failure approach to reliability: Modeling, accelerated testing, prognosis and reliability assessment*. Performability engineering series. Beverly, MA und Hoboken, NJ: Scrivener Publishing und John Wiley & Sons Inc, 2017. ISBN: 9781119388630.
- [86] A. Kremer, L. Dücsö und B. Bertsche. „Reliability Prediction using Design of Experiments“. In: *Proceedings of the 30th European Safety and Reliability Conference and 15th Probabilistic Safety Assessment and Management Conference*. Hrsg. von P. Baraldi, F. Di Maio und E. Zio. Singapore: Research Publishing Services, 2020, S. 1501–1507. ISBN: 978-981-14-8593-0. DOI: [10.3850/978-981-14-8593-0{\textunderscore}3538-cd](https://doi.org/10.3850/978-981-14-8593-0{\textunderscore}3538-cd).
- [87] A. J. Dobson und A. G. Barnett. *An Introduction to Generalized Linear Models*. Fourth edition. Texts in statistical science. Boca Raton, FL: CRC Press, 2018. ISBN: 9781315182780. DOI: [10.1201/9781315182780](https://doi.org/10.1201/9781315182780).
- [88] J. Stufken und M. Yang. „Optimal Designs for Generalized Linear Models“. In: *Design and analysis of experiments*. Hrsg. von K. Hinkelmann. Bd. 3. Wiley series in probability and statistics. Hoboken, NJ: Wiley-Interscience, 2012, S. 137–164. ISBN: 9780470530689. DOI: [10.1002/9781118147634.ch4](https://doi.org/10.1002/9781118147634.ch4).
- [89] M. Aitkin und D. Clayton. „The Fitting of Exponential, Weibull and Extreme Value Distributions to Complex Censored Survival Data Using GLIM“. In: *Journal of the Royal Statistical Society Series C: Applied Statistics* 29.2 (1980), S. 156. ISSN: 0035-9254. DOI: [10.2307/2986301](https://doi.org/10.2307/2986301).
- [90] A. C. Rencher und G. B. Schaalje. *Linear models in statistics*. 2. ed. Hoboken, NJ: Wiley-Interscience, 2008. ISBN: 9780471754985. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2007024268-b.html>.
- [91] D. Rasch und D. Schott. *Mathematical statistics*. Hoboken, NJ: John Wiley & Sons Inc, 2018. ISBN: 9781119385288.
- [92] A. N. Donev. „Design of experiments in the presence of errors in factor levels“. In: *Statistical Planning and Inference* 126.2 (2004), S. 569–585.

- [93] M. K. Ardakani, D. Das, S. S. Wulf und T. J. Robinson. „Estimation in Second-Order Models with Errors in the Factor Levels“. In: *Commun. in Statistics* 40.9 (2011), S. 1573–1590. DOI: [10.1080/03610921003637421](https://doi.org/10.1080/03610921003637421).
- [94] M. Yang, B. Zhang und S. Huang. „Optimal designs for generalized linear models with multiple design variables“. In: *Statistica Sinica* 21.3 (2011), S. 1415–1430. ISSN: 10170405. DOI: [10.5705/ss.2009.115](https://doi.org/10.5705/ss.2009.115).
- [95] M. Arndt und M. Dazer. „Analysis of Efficiency in Response Surface Designs Considering Orthogonality Deviations and Cost Models“. In: *European Conference on Safety and Reliability (ESREL), 3rd September - 7th September 2023*. Hrsg. von M. P. Brito, T. Aven, P. Baraldi, M. Čepin und E. Zio. Singapore: Research Publishing Services, 2023, S. 1167–1174. ISBN: 978-981-18-8071-1. DOI: [10.3850/978-981-18-8071-1{\textunderscore}P160-cd](https://doi.org/10.3850/978-981-18-8071-1{\textunderscore}P160-cd).
- [96] E. Rittmaier, M. Arndt und M. Dazer. „Simulative Analysis of Statistical Power of Optimal Test Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–7. ISBN: 979-8-3503-6774-4. DOI: [10.1109/RAMS48127.2025.10935086](https://doi.org/10.1109/RAMS48127.2025.10935086).
- [97] M. Arndt, M. Dazer, W. Raither und B. Bertsche. „Parameter assessment for reliability modeling of machine components using heuristic screening“. In: *Forschung im Ingenieurwesen* 87.4 (2023), S. 1347–1370. ISSN: 0015-7899. DOI: [10.1007/s10010-023-00711-5](https://doi.org/10.1007/s10010-023-00711-5).
- [98] H. Krallmann, A. Bobrik und O. Levina. *Systemanalyse im Unternehmen: Prozessorientierte Methoden der Wirtschaftsinformatik*. 6., überarb. und erw. Aufl. München: Oldenbourg-Verl., 2013. ISBN: 978-3-486-72982-5. DOI: [10.1524/9783486729825](https://doi.org/10.1524/9783486729825).
- [99] K. Wallace, G. Pahl, W. Beitz, J. Feldhusen, K.-H. Grote und L. T. M. Blessing, Hrsg. *Engineering design: A systematic approach*. 3. ed. London: Springer, 2007. ISBN: 1846283183. URL: <http://site.ebrary.com/lib/librarytitles/docDetail.action?docID=10230457>.
- [100] D. C. Montgomery. *Introduction to statistical quality control*. Eighth edition, EMEA edition. Hoboken, NJ: Wiley, 2020. ISBN: 9781119657118.

- [101] C. Brückner. *Qualitätsmanagement: Das Praxishandbuch für die Automobilindustrie*. 2., vollständig überarbeitete und erweiterte Auflage. München: Hanser, 2019. ISBN: 978-3-446-45575-7. DOI: [10.3139/9783446459724](https://doi.org/10.3139/9783446459724).
- [102] A. Breiing und R. Knosala. *Bewerten technischer Systeme: Theoretische und methodische Grundlagen bewertungstechnischer Entscheidungshilfen*. Berlin und Heidelberg: Springer, 1997. ISBN: 978-3-642-63908-1. DOI: [10.1007/978-3-642-59229-4](https://doi.org/10.1007/978-3-642-59229-4).
- [103] S. Albers. *Handbuch Technologie- und Innovationsmanagement: Strategie — Umsetzung — Controlling*. SpringerLink Bücher. Wiesbaden und s.l.: Gabler Verlag, 2005. ISBN: 978-3-322-90787-5. DOI: [10.1007/978-3-322-90786-8](https://doi.org/10.1007/978-3-322-90786-8).
- [104] G. Thompson. *Improving maintainability and reliability through design*. London: Professional Engineering Publ, 1999. ISBN: 1860581358.
- [105] A. Kremer. „Ermittlung von lebensdauerbeeinflussenden Faktoren bei Zahnriemengetrieben“. In: *antriebstechnik* 2018.11 (11), S. 148–153. URL: <https://digital.antriebstechnik.de/antriebstechnik-11-2018/62195350> (besucht am 22.01.2026).
- [106] T. Buzan und B. Buzan. *The mind map book: Unlock your creativity, boost your memory, change your life*. 1. publ. Harlow u.a.: Pearson, BBC Active, 2010. ISBN: 9781406647167. URL: <https://permalink.obvsg.at/AC11808619>.
- [107] P. Tittmann. *Graphentheorie: Eine anwendungsorientierte Einführung : mit 115 Bildern, zahlreichen Beispielen und 92 Aufgaben*. 3., aktualisierte Auflage. Mathematik-Studienhilfen. München: Hanser, 2019. ISBN: 978-3-446-46052-2. DOI: [10.3139/9783446465039](https://doi.org/10.3139/9783446465039).
- [108] B. Klein. *Versuchsplanung - DoE: Einführung in die Taguchi/Shainin-Methodik*. 3rd ed. München: De Gruyter, 2011. ISBN: 978-3-486-71136-3. DOI: [10.1524/9783486711363](https://doi.org/10.1524/9783486711363).
- [109] K. Siebertz, D. van Bebber und T. Hochkirchen. *Statistische Versuchsplanung: Design of Experiments (DoE)*. 2. Auflage. VDI-Buch. Berlin und Heidelberg: Springer Vieweg, 2017. ISBN: 978-3-662-55742-6.

-
- [110] M. Arndt und M. Dazer. *Power and Accuracy Characterization of Regression Models in The Presence of Orthogonality Deviations in CCDs*. In: *6th International Conference on Design of Experiments (ICODOE 2022)*. 2023. URL: <https://www.memphis.edu/msci/icodoe22/index.php>.
- [111] M. Arndt, P. Mell und M. Dazer. „Generic effects of deviations from test design orthogonality on test power and regression modelling of Central-Composite Designs“. In: *Probabilistic Safety Assessment and Management PSAM 16, June 26-July 1, 2022, Honolulu, Hawaii*. URL: <https://www.iapsam.org/PSAM16/papers/MA19-PSAM16.pdf>.
- [112] G. E. P. Box. „The Effects of Errors in the Factor Levels and Experimental Design“. In: *Technometrics* 5.2 (1963), S. 247–262. ISSN: 0040-1706. URL: <https://doi.org/10.2307/1266066>.
- [113] M.-J. Zhang und R.-X. Yue. „Optimal designs for homoscedastic functional polynomial measurement error models“. In: *AStA Advances in Statistical Analysis* 105.3 (2021), S. 485–501. ISSN: 1863-8171. DOI: [10.1007/s10182-021-00399-4](https://doi.org/10.1007/s10182-021-00399-4).
- [114] D.-H. Jang. „Measures for Evaluating Non-Orthogonality of Experimental Designs“. In: *Communications in Statistics - Theory and Methods* 31.2 (2002), S. 249–260. ISSN: 0361-0926. DOI: [10.1081/STA-120002649](https://doi.org/10.1081/STA-120002649).
- [115] E. Zio. *The Monte Carlo simulation method for system reliability and risk analysis*. Springer series in reliability engineering. London: Springer, 2013. ISBN: 978-1-4471-4587-5. DOI: [10.1007/978-1-4471-4588-2](https://doi.org/10.1007/978-1-4471-4588-2).
- [116] P. Mell, M. Arndt und M. Dazer. „Non-orthogonality in test design: practical relevance of the theoretical concept in terms of regression quality and test plan efficiency“. In: *Proceedings of the Probabilistic Safety Assessment and Management Conference 2022 PSAM 16 (2022)*. URL: <https://www.iapsam.org/PSAM16/paper.php?ID=PH20>.
- [117] M. Arndt und M. Dazer. „Investigating Practical Orthogonality Deviations in RSM for Optimized Predictive Reliability Modeling“. In: *2024 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2024, S. 1–6. ISBN: 979-8-3503-0769-6. DOI: [10.1109/RAMS51492.2024.10457825](https://doi.org/10.1109/RAMS51492.2024.10457825).

- [118] M. Arndt, E. Rittmaier und M. Dazer. „Assessing the Extrapolation Variance of Non-Orthogonal Response Surface Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–6. ISBN: 979-8-3503-6774-4. DOI: [10.1109/RAMS48127.2025.10935022](https://doi.org/10.1109/RAMS48127.2025.10935022).
- [119] M. Arndt und M. Dazer. „Confidence Intervals in Optimized Response Surface Designs for Accelerated Lifetime Testing“. In: *35th European Safety and Reliability*, S. 867–874. DOI: [10.3850/978-981-94-3281-3\textunderscoreESREL-SRA-E2025-P2042-cd](https://doi.org/10.3850/978-981-94-3281-3\textunderscoreESREL-SRA-E2025-P2042-cd).
- [120] Bundesministerium der Finanzen. *AfA-Tabelle für die allgemein verwendbaren Anlagegüter (AfA-Tabelle AV): § 193ff AO , § 7 Abs 1 EStG*.
- [121] VDI-Gesellschaft Produkt- und Prozessgestaltung. *Beschaffung, Betrieb und Instandhaltung von Produktionsmitteln unter Anwendung von Life Cycle Costing (LCC): VDI 2884:2005-12*. 2005.
- [122] K. Ehrlenspiel und H. Meerkamm. *Integrierte Produktentwicklung: Denkabläufe, Methodeneinsatz, Zusammenarbeit*. 6., überarbeitete und erweiterte Auflage. Hanser eLibrary. München: Carl Hanser Verlag, 2017. ISBN: 9783446449084. DOI: [10.3139/9783446449084](https://doi.org/10.3139/9783446449084).
- [123] VDI-Gesellschaft Produkt- und Prozessgestaltung. *Kostenrechnung mit Maschinenstundensätzen; Begriffe, Bezeichnungen, Zusammenhänge: VDI 3258 Blatt 1:1962-10*. 1962.
- [124] N. T. Stevens und C. M. Anderson-Cook. „Design and analysis of confirmation experiments“. In: *Journal of Quality Technology* 51.2 (2019), S. 109–124. ISSN: 0022-4065. DOI: [10.1080/00224065.2019.1571344](https://doi.org/10.1080/00224065.2019.1571344).
- [125] M. Arndt, W. Raither und M. Dazer. „Multivariate Damage-based Reliability Assessment of Toothed Belts for Vehicle Steering Systems“. In: *IEEE Transactions on Reliability* (2026), S. 1–13. DOI: [10.1109/TR.2026.3713009](https://doi.org/10.1109/TR.2026.3713009).
- [126] R. Perneder. *Handbuch Zahnriementechnik: Grundlagen, Berechnung, Anwendungen*. Berlin und Heidelberg: Springer, 2009. ISBN: 978-3-540-89321-9.
- [127] T. Nagel. *Zahnriemengetriebe: Eigenschaften, Normung, Berechnung, Gestaltung*. 1. Aufl. München und Wien: Hanser, 2008. ISBN: 978-3-446-41380-1.

- [128] B. R. Englert, S. E. Rigdon, C. M. Borror, D. C. Montgomery und R. Pan. „Optimal Design for Multifactor Life Testing Experiments for Exponentially Distributed Lifetimes“. In: *Frontiers in Statistical Quality Control 10*. Hrsg. von H.-J. Lenz, W. Schmid und P.-T. Wilrich. SpringerLink Bücher. Heidelberg und s.l.: Physica-Verlag HD und Imprint Physica, 2012, S. 303–317. ISBN: 978-3-7908-2845-0. DOI: [10.1007/978-3-7908-2846-7{\textunderscore}20](https://doi.org/10.1007/978-3-7908-2846-7_textunderscore20).

Anhang A Sensitivitätsanalyse

In diesem Anhang sind die detaillierten Ergebnisse der Sensitivitätsanalyse für die verschiedenen Parameterkombinationen tabellarisch zusammengefasst. Die Tabellen zeigen die Power des Tests in Abhängigkeit von den Störfaktoren C (Zentrums-Läufe) und D (Stern-Läufe).

Tabelle A1: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9453	0.7362	0.6281	0.7168	0.5718	-	0.9935
power max	0.9905	0.8273	0.7994	0.8269	0.7495	-	1.0000
power min	0.7811	0.5999	0.3734	0.5517	0.3259	-	0.9451
Power (+)	0.9357	0.7304	0.6127	0.7163	0.5592	-	0.9949
Power (-)	0.9508	0.7353	0.6495	0.7148	0.5766	-	0.9909
Power (α)	0.9058	0.7022	0.6006	0.7086	0.5164	-	0.9939
Power ($-\alpha$)	0.9485	0.7162	0.7044	0.7046	0.5656	-	0.9826
a	0.3958	0.0298	0.3543	0.1940	0.3241	-	0.2432
b	0.2848	0.0084	0.0789	0.3961	0.7657	-	0.0546
e	0.9380	0.1534	1.6411	0.2953	0.7639	-	0.0440
f	0.0115	0.0411	2.6158	0.0315	0.0551	-	0.0403
g	1.1583	1.8408	2.3250	1.9725	2.7091	-	0.2193
h	0.6492	0.6492	1.8966	1.5782	2.2201	-	0.1176
aa	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0479
bb	0.0299	0.0299	0.0000	0.1089	0.0000	-	0.0000
ee	0.0988	0.0988	0.0797	0.0000	0.0000	-	0.0000
ff	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
gg	0.1851	0.1851	0.0672	0.1405	0.2111	-	0.0398
hh	0.0913	0.0913	0.1066	0.0861	0.2561	-	0.0179
ab	0.0000	0.0000	0.1039	0.0647	0.2700	-	0.0162
ae	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
af	0.0000	0.0000	0.0873	0.1034	0.0000	-	0.0197
ah	0.0375	0.0375	0.0000	0.0694	0.0000	-	0.0297
ag	0.1003	0.1003	0.0000	0.0000	0.0000	-	0.0625
be	0.0000	0.0000	0.0000	0.0850	0.0000	-	0.0284
bf	0.0000	0.0000	0.0948	0.0000	0.0000	-	0.0000
bh	0.0606	0.0606	0.0000	0.0000	0.0000	-	0.0000
bg	0.0434	0.0434	0.0000	0.0912	0.0934	-	0.0241
ef	0.0000	0.0000	0.3848	0.0000	0.0941	-	0.0000
eh	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
eg	0.0916	0.0916	0.1936	0.0000	0.0203	-	0.0203
fh	0.0000	0.0000	0.1073	0.0000	0.0000	-	0.0000
fg	0.0000	0.0000	0.0000	0.0000	0.0287	-	0.0287
gh	0.1616	0.1616	0.0000	0.0822	0.0000	-	0.0000
-	-	-	-	-	-	Lack of fit	-

Tabelle A2: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9518	0.7985	0.6387	0.7208	0.6531	-	0.9957
power max	0.9933	0.8573	0.8181	0.8411	0.7769	-	1.0000
power min	0.7685	0.6603	0.4066	0.5247	0.4672	-	0.9667
Power (+)	0.9444	0.7954	0.6178	0.7225	0.6561	-	0.9970
Power (-)	0.9556	0.7993	0.6589	0.7189	0.6485	-	0.9946
Power (α)	0.9215	0.7834	0.5775	0.7248	0.6577	-	0.9995
Power ($-\alpha$)	0.9533	0.7944	0.6938	0.7146	0.6361	-	0.9929
a	0.5743	0.0539	0.4599	0.2257	0.1838	-	0.1461
b	0.2434	0.0624	0.1787	0.5291	0.1289	-	0.0400
e	0.9031	0.1628	1.5864	0.2921	0.4940	-	0.0366
f	0.0191	0.0288	2.6353	0.0388	0.0186	-	0.0286
g	1.0501	1.4474	2.1712	1.9654	2.3119	-	0.1445
h	0.5934	1.1095	1.8017	1.5105	1.8671	-	0.0673
aa	0.0000	0.0000	0.1083	0.0000	0.0000	-	0.0162
bb	0.0000	0.0000	0.0000	0.1100	0.1570	-	0.0119
ee	0.1020	0.0000	0.1373	0.0875	0.0000	-	0.0000
ff	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
gg	0.1920	0.1289	0.1452	0.1150	0.1467	-	0.0312
hh	0.1089	0.2101	0.1396	0.1850	0.2392	-	0.0099
ab	0.0000	0.0972	0.1019	0.0906	0.0000	-	0.0267
ae	0.0000	0.0000	0.1122	0.0672	0.0000	-	0.0000
af	0.0000	0.0000	0.0000	0.0853	0.0000	-	0.0000
ah	0.0775	0.0000	0.0000	0.0000	0.0000	-	0.0239
ag	0.1522	0.0000	0.0000	0.1053	0.0000	-	0.0286
be	0.0356	0.0000	0.0000	0.0591	0.0000	-	0.0000
bf	0.0000	0.0000	0.0000	0.0703	0.0000	-	0.0117
bh	0.0400	0.0000	0.0000	0.0000	0.0797	-	0.0111
bg	0.0622	0.0934	0.0000	0.0603	0.1091	-	0.0000
ef	0.0441	0.0806	0.3800	0.0888	0.0000	-	0.0311
eh	0.0791	0.0000	0.0747	0.0000	0.0000	-	0.0000
eg	0.0738	0.0000	0.0000	0.1994	0.0972	-	0.0000
fh	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0152
fg	0.0000	0.0000	0.0775	0.0000	0.0000	-	0.0117
gh	0.1287	0.1422	0.0000	0.0906	0.0841	-	0.0164
-	-	-	-	-	-	Lack of fit	-

Tabelle A3: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9540	0.7986	0.7074	-	-	-	0.9975
power max	0.9989	0.8729	0.8406	-	-	-	1.0030
power min	0.7860	0.6751	0.4696	-	-	-	0.9723
Power (+)	0.9487	0.7962	0.6911	-	-	-	0.9976
Power (-)	0.9545	0.7996	0.7428	-	-	-	0.9967
Power (α)	0.9262	0.7884	0.7104	-	-	-	0.9956
Power ($-\alpha$)	0.9426	0.7981	0.8568	-	-	-	0.9930
a	0.7210	0.1280	0.4171	-	-	-	0.0960
b	0.3130	0.0177	0.7838	-	-	-	0.0204
e	0.8543	0.0783	1.3897	-	-	-	0.0216
f	0.0265	0.1084	2.2880	-	-	-	0.0300
g	0.9984	1.3910	1.8966	-	-	-	0.1050
h	0.5009	1.1444	1.4085	-	-	-	0.0433
aa	0.0000	0.0000	0.0000	-	-	-	0.0209
bb	0.0590	0.0823	0.0411	-	-	-	0.0000
ee	0.0766	0.0000	0.0514	-	-	-	0.0000
ff	0.0000	0.0000	0.2129	-	-	-	0.0000
gg	0.1704	0.0802	0.1430	-	-	-	0.0365
hh	0.1141	0.1227	0.1461	-	-	-	0.0000
ab	0.0742	0.0920	0.1405	-	-	-	0.0178
ae	0.0642	0.0000	0.1030	-	-	-	0.0000
af	0.0000	0.0000	0.0814	-	-	-	0.0125
ah	0.0739	0.0000	0.0545	-	-	-	0.0112
ag	0.1261	0.0000	0.0000	-	-	-	0.0366
be	0.0000	0.0000	0.0414	-	-	-	0.0000
bf	0.0000	0.0000	0.0483	-	-	-	0.0000
bh	0.0558	0.0000	0.0000	-	-	-	0.0000
bg	0.0000	0.0000	0.0530	-	-	-	0.0097
ef	0.0000	0.0820	0.4002	-	-	-	0.0131
eh	0.0000	0.0000	0.0000	-	-	-	0.0125
eg	0.0636	0.0000	0.0789	-	-	-	0.0000
fh	0.0000	0.0000	0.0911	-	-	-	0.0000
fg	0.0000	0.0830	0.0000	-	-	-	0.0231
gh	0.1339	0.1452	0.1148	-	-	-	0.0100
-	-	-	-	Lack of fit	Lack of fit	Lack of fit	-

Tabelle A4: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9902	0.7454	0.6374	0.7229	-	0.7645	0.9968
power max	0.9981	0.8382	0.7916	0.8411	-	0.9125	1.0000
power min	0.9588	0.6174	0.3968	0.5881	-	0.3337	0.9794
Power (+)	0.9843	0.7426	0.6232	0.7237	-	0.7862	0.9970
Power (-)	0.9934	0.7447	0.6596	0.7238	-	0.7243	0.9958
Power (α)	0.9668	0.7285	0.6175	0.7294	-	0.7777	0.9950
Power ($-\alpha$)	0.9924	0.7346	0.7206	0.7296	-	0.6029	0.9916
a	0.0155	0.0621	0.2866	0.2087	-	4.7500	0.0968
b	0.0000	0.0499	0.0228	0.4204	-	1.5342	0.0237
e	0.3993	0.2315	1.6512	0.2988	-	0.2277	0.0097
f	0.0000	0.0261	2.6397	0.0000	-	0.0597	0.0174
g	0.1461	1.6970	2.2654	1.9055	-	1.7045	0.0962
h	0.0774	1.3724	1.7403	1.3905	-	1.2919	0.0420
aa	0.0000	0.0819	0.0000	0.0000	-	0.5453	0.0177
bb	0.0000	0.1413	0.0635	0.1255	-	0.3322	0.0000
ee	0.0842	0.1212	0.0000	0.0986	-	0.1128	0.0000
ff	0.0000	0.0000	0.3990	0.0000	-	0.0000	0.0000
gg	0.0211	0.0681	0.1503	0.0726	-	0.0915	0.0089
hh	0.0000	0.0913	0.1597	0.1189	-	0.1559	0.0000
ab	0.0000	0.0000	0.0000	0.1508	-	0.0719	0.0125
ae	0.0175	0.0000	0.0000	0.0000	-	0.1094	0.0000
af	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0000
ah	0.0000	0.0000	0.0000	0.0000	-	0.1788	0.0116
ag	0.0000	0.0000	0.0000	0.0000	-	0.3075	0.0219
be	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0141
bf	0.0000	0.0884	0.0000	0.0000	-	0.0738	0.0000
bh	0.0000	0.0000	0.0000	0.0000	-	0.1050	0.0000
bg	0.0000	0.0000	0.0000	0.1005	-	0.1244	0.0147
ef	0.0000	0.0000	0.3547	0.0000	-	0.0862	0.0000
eh	0.0000	0.0000	0.0841	0.0000	-	0.0000	0.0000
eg	0.0441	0.0000	0.0000	0.0000	-	0.0000	0.0000
fh	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0000
fg	0.0000	0.0000	0.0000	0.0000	-	0.1187	0.0159
gh	0.0000	0.0000	0.0000	0.0995	-	0.0750	0.0000
-	-	-	-	-	Lack of fit	-	-

Tabelle A5: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9905	0.8010	0.6464	0.7278	0.7582	0.7765	0.9980
power max	0.9986	0.8732	0.7996	0.8508	0.8625	0.9315	1.0000
power min	0.9552	0.6885	0.4066	0.5683	0.6378	0.5508	0.9853
Power (+)	0.9848	0.7978	0.6275	0.7258	0.7535	0.7942	0.9981
Power (-)	0.9941	0.8076	0.6660	0.7273	0.7674	0.7376	0.9974
Power (α)	0.9694	0.8007	0.5947	0.7158	0.7564	0.7714	0.9970
Power ($-\alpha$)	0.9956	0.8282	0.7037	0.7199	0.7958	0.6113	0.9950
a	0.0027	0.1427	0.4640	0.2446	0.0495	4.0624	0.0608
b	0.0099	0.0559	0.0418	0.5323	0.3258	1.0318	0.0137
e	0.4114	0.0532	1.5052	0.2067	0.2528	0.1887	0.0100
f	0.0035	0.0072	2.5420	0.0221	0.0221	0.0399	0.0061
g	0.1383	1.4069	2.2154	1.9565	1.8537	1.5771	0.0754
h	0.0706	0.9461	1.7469	1.3671	1.2025	1.2268	0.0318
aa	0.0000	0.0000	0.0000	0.0000	0.0000	0.5061	0.0097
bb	0.0000	0.0000	0.0000	0.1137	0.0656	0.0787	0.0000
ee	0.0759	0.1234	0.1083	0.0887	0.1299	0.0926	0.0000
ff	0.0115	0.0000	0.0000	0.0513	0.0824	0.0000	0.0000
gg	0.0147	0.0860	0.0911	0.1219	0.1251	0.1168	0.0178
hh	0.0000	0.1129	0.1642	0.1101	0.0907	0.1474	0.0000
ab	0.0000	0.0000	0.0000	0.1018	0.0000	0.1845	0.0000
ae	0.0000	0.0000	0.0000	0.0000	0.0000	0.1461	0.0112
af	0.0000	0.0000	0.0000	0.0000	0.0000	0.0823	0.0097
ah	0.0000	0.0000	0.0000	0.0967	0.0000	0.1739	0.0113
ag	0.0000	0.0000	0.0000	0.1195	0.0000	0.2064	0.0219
be	0.0000	0.0000	0.0000	0.0000	0.0693	0.0000	0.0000
bf	0.0000	0.0000	0.1167	0.0889	0.0000	0.0717	0.0000
bh	0.0000	0.0000	0.0000	0.0000	0.0929	0.0777	0.0000
bg	0.0000	0.1098	0.0000	0.0000	0.0000	0.0895	0.0000
ef	0.0000	0.0767	0.3902	0.0000	0.0000	0.0000	0.0000
eh	0.0187	0.0000	0.1736	0.0000	0.0000	0.0945	0.0000
eg	0.0553	0.0767	0.0000	0.0836	0.0000	0.0000	0.0000
fh	0.0000	0.0000	0.1789	0.0000	0.0000	0.0000	0.0000
fg	0.0178	0.0000	0.0964	0.1392	0.0000	0.0000	0.0000
gh	0.0216	0.1333	0.0000	0.1445	0.0000	0.1073	0.0125

Tabelle A6: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9906	0.8001	0.7253	0.7307	0.7711	0.8209	-
power max	1.0000	0.8858	0.8277	0.8590	0.8612	0.9535	-
power min	0.9556	0.6939	0.4813	0.5676	0.6473	0.5788	-
Power (+)	0.9846	0.7993	0.7053	0.7301	0.7680	0.8377	-
Power (-)	0.9932	0.8053	0.7401	0.7247	0.7740	0.7956	-
Power (α)	0.9653	0.8030	0.6554	0.7123	0.7620	0.8464	-
Power ($-\alpha$)	0.9897	0.8198	0.7537	0.6969	0.7791	0.7271	-
a	0.0314	0.1339	0.2048	0.2370	0.0789	2.8293	-
b	0.0083	0.0793	0.5931	0.6122	0.1142	0.6457	-
e	0.4076	0.1149	1.1845	0.2977	0.1985	0.1012	-
f	0.0045	0.0841	2.2052	0.0770	0.0359	0.0660	-
g	0.1364	1.4107	1.7065	1.8462	1.5774	1.2572	-
h	0.0775	0.9693	1.3760	1.3693	1.2351	1.0155	-
aa	0.0000	0.0057	0.2197	0.0000	0.0000	0.2441	-
bb	0.0000	0.0024	0.0834	0.0852	0.0000	0.0754	-
ee	0.0564	0.0680	0.0000	0.1171	0.0619	0.0659	-
ff	0.0000	0.0593	0.1670	0.0000	0.0000	0.0000	-
gg	0.0276	0.0926	0.1028	0.0635	0.1037	0.0591	-
hh	0.0239	0.0714	0.1634	0.1792	0.1168	0.1448	-
ab	0.0000	0.0000	0.0861	0.1619	0.0000	0.1661	-
ae	0.0000	0.0194	0.0000	0.0000	0.0555	0.0952	-
af	0.0000	0.0000	0.0614	0.0000	0.0000	0.0000	-
ah	0.0192	0.0641	0.0686	0.0000	0.0000	0.1520	-
ag	0.0000	0.0000	0.0000	0.0000	0.0000	0.1133	-
be	0.0000	0.0000	0.0000	0.0000	0.0427	0.0000	-
bf	0.0158	0.0403	0.1277	0.0000	0.0000	0.0000	-
bh	0.0000	0.0000	0.0000	0.0000	0.1120	0.0000	-
bg	0.0000	0.0000	0.1030	0.1050	0.0000	0.0000	-
ef	0.0000	0.0000	0.3220	0.0000	0.0000	0.1180	-
eh	0.0208	0.0734	0.0000	0.1659	0.0702	0.0000	-
eg	0.0411	0.1172	0.0798	0.0000	0.0000	0.0808	-
fh	0.0000	0.0762	0.0780	0.0000	0.0000	0.0000	-
fg	0.0000	0.0000	0.1998	0.1400	0.0608	0.0000	-
gh	0.0000	0.0462	0.0000	0.0772	0.1202	0.1314	-
-	-	-	-	-	-	-	Lack of fit

Tabelle A7: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	-	0.6450	0.7284	0.7145	0.7727	-
power max	1.0000	-	0.7837	0.8358	0.8097	1.0000	-
power min	0.9742	-	0.3734	0.5875	0.4275	0.9829	-
Power (+)	0.9909	-	0.6216	0.7277	0.7073	0.7909	-
Power (-)	0.9968	-	0.6612	0.7291	0.7158	0.7401	-
Power (α)	0.9783	-	0.5599	0.7263	0.6791	0.7870	-
Power ($-\alpha$)	0.9948	-	0.6718	0.7303	0.7031	0.6435	-
a	0.0000	-	0.3510	0.1266	0.8831	4.5897	-
b	0.0013	-	0.0509	0.4785	1.0897	1.7627	-
e	0.2539	-	1.5429	0.2870	0.3910	0.2779	-
f	0.0013	-	2.5994	0.0812	0.0105	0.0011	-
g	0.0695	-	2.3087	1.9936	1.9692	1.7285	-
h	0.0302	-	1.6869	1.3665	1.3721	1.1623	-
aa	0.0000	-	0.0000	0.0000	0.1855	0.5719	-
bb	0.0000	-	0.0000	0.1214	0.2005	0.3038	-
ee	0.0476	-	0.0000	0.1196	0.1032	0.1125	-
ff	0.0000	-	0.0000	0.0000	0.0000	0.0000	-
gg	0.0000	-	0.1937	0.1661	0.2318	0.1463	-
hh	0.0219	-	0.1743	0.1704	0.2036	0.0694	-
ab	0.0000	-	0.0000	0.0000	0.2447	0.2175	-
ae	0.0000	-	0.0000	0.0000	0.0000	0.2034	-
af	0.0000	-	0.0000	0.0000	0.1066	0.0000	-
ah	0.0000	-	0.0816	0.0000	0.0000	0.1350	-
ag	0.0000	-	0.0000	0.0000	0.0966	0.3544	-
be	0.0000	-	0.1275	0.0000	0.0000	0.0000	-
bf	0.0000	-	0.0000	0.0000	0.0000	0.1050	-
bh	0.0000	-	0.1672	0.0000	0.0000	0.0000	-
bg	0.0194	-	0.1172	0.0939	0.2109	0.0000	-
ef	0.0000	-	0.3784	0.0000	0.0631	0.0000	-
eh	0.0000	-	0.2038	0.0000	0.0000	0.0775	-
eg	0.0303	-	0.0000	0.0000	0.0000	0.0000	-
fh	0.0000	-	0.0000	0.0000	0.0634	0.0000	-
fg	0.0153	-	0.1762	0.0000	0.0000	0.0000	-
gh	0.0000	-	0.0000	0.0000	0.0628	0.0000	-
-	-	Lack of fit	-	-	-	-	Lack of fit

Tabelle A8: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	0.8007	0.6497	-	0.7877	0.7861	0.9984
power max	1.0000	0.9077	0.8025	-	0.8681	0.9176	1.0000
power min	0.9771	0.7010	0.4032	-	0.6628	0.4751	0.9878
Power (+)	0.9912	0.7980	0.6315	-	0.7796	0.8027	0.9988
Power (-)	0.9968	0.8035	0.6766	-	0.7920	0.7578	0.9981
Power (α)	0.9796	0.7937	0.6208	-	0.7546	0.8030	0.9999
Power ($-\alpha$)	0.9953	0.8091	0.7482	-	0.7896	0.6759	0.9978
a	0.0060	0.0652	0.4519	-	0.0098	3.6725	0.0433
b	0.0183	0.0519	0.0116	-	0.3922	1.2550	0.0097
e	0.2406	0.1823	1.5806	-	0.1582	0.1947	0.0090
f	0.0000	0.0559	2.7147	-	0.0286	0.0000	0.0080
g	0.0803	1.4901	2.3085	-	1.5045	1.4975	0.0557
h	0.0313	0.9934	1.6549	-	1.0501	1.1319	0.0213
aa	0.0000	0.0000	0.0000	-	0.0000	0.3338	0.0000
bb	0.0000	0.0000	0.0686	-	0.0000	0.1913	0.0000
ee	0.0457	0.1627	0.1149	-	0.1524	0.1218	0.0050
ff	0.0000	0.0970	0.0000	-	0.0000	0.0000	0.0000
gg	0.0000	0.0000	0.1214	-	0.1445	0.0976	0.0082
hh	0.0000	0.0817	0.1258	-	0.0907	0.1776	0.0000
ab	0.0242	0.0000	0.0000	-	0.0000	0.0000	0.0131
ae	0.0000	0.0000	0.0000	-	0.0000	0.1000	0.0000
af	0.0000	0.0000	0.0000	-	0.0998	0.0000	0.0056
ah	0.0000	0.0000	0.0000	-	0.0000	0.1419	0.0084
ag	0.0000	0.0778	0.0000	-	0.0000	0.2569	0.0169
be	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0072
bf	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
bh	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
bg	0.0000	0.0772	0.0000	-	0.0842	0.0000	0.0000
ef	0.0000	0.1550	0.4475	-	0.0000	0.0000	0.0000
eh	0.0000	0.0000	0.0000	-	0.0000	0.0803	0.0000
eg	0.0236	0.0812	0.1231	-	0.0000	0.0000	0.0097
fh	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
fg	0.0000	0.0000	0.2075	-	0.0000	0.0000	0.0081
gh	0.0000	0.0600	0.1353	-	0.0711	0.0000	0.0084
-	-	-	-	Lack of fit	-	-	-

Tabelle A9: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	0.8035	-	0.7330	-	0.8378	0.9990
power max	1.0000	0.8784	-	0.8544	-	0.9286	1.0000
power min	0.9753	0.7101	-	0.5842	-	0.6034	0.9953
Power (+)	0.9918	0.7998	-	0.7345	-	0.8424	0.9990
Power (-)	0.9967	0.8031	-	0.7286	-	0.8177	0.9990
Power (α)	0.9828	0.7819	-	0.7297	-	0.8111	0.9989
Power ($-\alpha$)	0.9969	0.7912	-	0.7130	-	0.7411	0.9989
a	0.0010	0.0699	-	0.1136	-	2.4390	0.0192
b	0.0038	0.0659	-	0.7811	-	0.8272	0.0055
e	0.2297	0.1238	-	0.2768	-	0.0821	0.0063
f	0.0077	0.0349	-	0.0462	-	0.1113	0.0096
g	0.0584	1.2813	-	1.8702	-	1.2301	0.0336
h	0.0427	1.0310	-	1.2671	-	0.8845	0.0125
aa	0.0000	0.0000	-	0.0613	-	0.2086	0.0000
bb	0.0000	0.0000	-	0.1732	-	0.1142	0.0000
ee	0.0369	0.0706	-	0.0745	-	0.0000	0.0000
ff	0.0000	0.0000	-	0.0000	-	0.0000	0.0000
gg	0.0000	0.1056	-	0.1212	-	0.1036	0.0000
hh	0.0000	0.0931	-	0.1762	-	0.1711	0.0082
ab	0.0000	0.0000	-	0.0000	-	0.1048	0.0000
ae	0.0000	0.0000	-	0.0761	-	0.0000	0.0000
af	0.0000	0.0658	-	0.0000	-	0.0000	0.0000
ah	0.0123	0.0000	-	0.0000	-	0.1023	0.0000
ag	0.0000	0.0789	-	0.0000	-	0.1142	0.0000
be	0.0000	0.0000	-	0.0798	-	0.0000	0.0000
bf	0.0123	0.0000	-	0.0101	-	0.1023	0.0000
bh	0.0177	0.0000	-	0.0000	-	0.0000	0.0000
bg	0.0183	0.0000	-	0.0000	-	0.0983	0.0000
ef	0.0123	0.0000	-	0.0000	-	0.1023	0.0000
eh	0.0181	0.0123	-	0.0000	-	0.0000	0.0000
eg	0.0208	0.0000	-	0.0000	-	0.0000	0.0000
fh	0.0000	0.0000	-	0.0000	-	0.0000	0.0073
fg	0.0177	0.0714	-	0.1136	-	0.0670	0.0000
gh	0.0000	0.0000	-	0.1120	-	0.0848	0.0000
-	-	-	Lack of fit	-	Lack of fit	-	-

Anhang B Orthogonalitäts-Analysen der Design-Modifikationen

In diesem Anhang sind ergänzende Visualisierungen und Analysen zur Bewertung der geometrischen Design-Verzerrungen aufgeführt.

Tabelle B1: Simulationsergebnisse: Schätzvarianz (MSE) der einzelnen Koeffizienten bei $\text{SNR} = 2,4$.

Szenario (Störfall)	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	3,09	3,10	3,17	6,17	3,13	3,11
Fall I: Shift (−20 %)	3,05	3,57	3,15	6,20	4,15	3,17
Fall I: Shift (+20 %)	3,07	2,94	3,14	6,37	2,21	3,06
Fall I: FC	3,06	3,82	3,10	6,30	4,61	3,21
Fall II: Korrelation (leicht)	3,06	3,17	3,07	6,22	3,13	3,12
Fall II: Korrelation (stark)	3,10	3,59	3,01	5,21	3,83	3,44
Fall III: Scatter ($\pm 10\%$)	3,04	3,18	2,98	6,20	3,27	2,62
Fall IV: SP	3,18	5,29	3,07	6,17	5,46	3,47
Fall IV: ZP	3,53	3,09	3,13	6,29	3,24	3,25




Abbildung B1: Laufende Konvergenz der Trennschärfe für alle Modellparameter.
Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar.




Abbildung B2: Konvergenz der OLS-Parameterschätzwerte ($\hat{\beta}_i$). Alle Modelle erweisen sich unabhängig von der geometrischen Verzerrung als erwartungstreu. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar.




Abbildung B3: Relative Häufigkeiten der in der Simulation ermittelten p -Werte der Signifikanztests.




Abbildung B4: Korrelierende Metriken zur prozentualen Trennschärfe-Änderung ($\Delta power$ [%]) über alle Koeffizienten und Szenarien ergänzend zu Abbildung 5.8.

Anhang B.1 Szenarien bei Arbeitspunkt $\text{SNR} = 1$




Abbildung B5: Güte der Schätzer (MSE) für $\text{SNR} = 1$.




Abbildung B6: Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der Störszenarien für $\text{SNR} = 1$.

Anhang B.2 Effizienzanalysen




Abbildung B7: KPI ggü. D -Effizienz aller Koeffizienten.