

Effiziente Multivariate Lebensdauertests

Efficient Multivariate Life Tests

Der Fakultät Konstruktions-, Produktions- und Fahrzeugtechnik
der Universität Stuttgart
zur Erlangung der Würde eines Doktor-Ingenieurs (Dr.-Ing.) vorgelegte Abhandlung

von
Marco Arndt, M.Sc.
aus Ravensburg

Hauptberichter: PD Dr.-Ing. habil. Martin Dazer
Mitberichter: Prof. Dr.-Ing. Michael Hanss

Tag der mündlichen Prüfung:

Institut für Maschinenelemente der Universität Stuttgart

2026

Vorwort

Die vorliegende Arbeit entstand während meiner Tätigkeit als akademischer Mitarbeiter am Institut für Maschinenelemente (IMA) der Universität Stuttgart.

Mein tiefster Dank gilt meinem Doktorvater und Mentor Herrn PD Dr.-Ing. habil. Martin Dazer. Als sein Stellvertreter im Fachbereich Zuverlässigkeitstechnik durfte ich neben seinem herausragenden Fachwissen eine außergewöhnliche Förderung erfahren. Seine stetige Unterstützung, die unzähligen Diskussionen und sein uneingeschränktes Vertrauen legten das absolute Fundament für diese Arbeit. Für dieses freundschaftliche Miteinander bin ich zutiefst dankbar.

Besonderer Dank gebührt Herrn Prof. Dr.-Ing. Bernd Bertsche, dem ehemaligen Leiter des Instituts für Maschinenelemente. Er prägte zu meinem Beginn am IMA eine einzigartige Institutskultur, die mir den kreativen und methodischen Freiraum für diese Forschungsarbeit überhaupt erst eröffnete.

Herzlich danke ich Herrn Prof. Dr.-Ing. Michael Hanss für die Übernahme des Mitberichts und die kritische Durchsicht meiner Arbeit, sowie Herrn Prof. Dr.-Ing. André Casal Kulzer für die Übernahme des Prüfungsvorsitzes.

Für die hervorragende Zusammenarbeit im Industrieprojekt danke ich Herrn Dr. sc. ETH Wolfram Raither. Unser freundschaftlicher Austausch und die fruchtbaren Gespräche waren stets eine wertvolle Inspirationsquelle.

Mein Dank gilt ebenso allen Mitarbeiterinnen und Mitarbeitern des IMA für das einzigartige Arbeitsklima. Allen voran danke ich Philipp Mell für den stets fachlich bereichernden und befruchtenden Austausch sowie für das akribische Korrekturlesen dieser Arbeit. Giuseppe Mannone, Kim Hintz, Dr.-Ing. Alexander Grundler und Erich Rittmaier danke ich für die wertvollen Diskussionen und die großartige gemeinsame Zeit am Institut. Ein besonderer Dank gilt Dr.-Ing. Kevin Lucan für das von ihm initiierte vertrauensvolle Umfeld und die gelebte unternehmerische Freiheit, die meinen Weg und den vieler ehemaliger Kollegen nachhaltig und mit großer Freude prägen. Gleichermäßen danke ich allen studentischen Hilfskräften und Verfassern von Abschlussarbeiten für ihre tatkräftige Unterstützung.

Der wichtigste Dank gebührt meiner Familie. Meiner Ehefrau Marei und meiner Tochter Karla danke ich von ganzem Herzen für den unermüdlichen Rückhalt und die grenzenlose Geduld in all den Phasen, in denen diese Arbeit meine Zeit beansprucht hat.

Ravensburg, im September 2026

Marco Arndt

Kurzfassung

Die Zuverlässigkeitstechnik bedient sich beschleunigter Lebensdauererprobungen (*Accelerated Life Testing, ALT*), um Entwicklungszyklen zu reduzieren. Da das Ausfallverhalten technischer Systeme zumeist durch mehrere interagierende Belastungen determiniert wird, erfordert die zugehörige empirische Modellierung der Lebensdauer zwingend die multivariate statistische Versuchsplanung (*Design of Experiments, DoE*) mittels *Response Surface Methodology (RSM)*, wobei sich für technische Anwendungen das *Central Composite Design (CCD)* als Standard-Testplan etabliert hat. Dessen ungeprüfte Übertragung auf ALT birgt jedoch einen fundamentalen methodischen Konflikt: Während klassische Versuchspläne auf geometrische Symmetrie und Interpolation im Zentrum des Versuchsraums ausgelegt sind, erfordert die Lebensdauererprobung prinzipbedingt die Extrapolation von hohen Prüflasten auf moderate Feldbedingungen. Zudem verletzen Lebensdauerdaten durch asymmetrische Weibull-Verteilungen und Zensierungen die klassischen Prämissen normalverteilter Residuen. Die vorliegende Dissertation adressiert diesen Konflikt durch ein holistisches Framework zur Auslegung hocheffizienter Lebensdauertests. Zunächst reduziert ein heuristisches Screening-Verfahren die Dimensionalität des Parameterraums im Vorfeld rational auf die vitalen Einflussgrößen. Im informationstheoretischen Kern wird daraufhin per *Monte-Carlo-Simulation (MCS)* nachgewiesen, dass das CCD eine ausgeprägte topologische Resilienz gegenüber praxisinduzierten Orthogonalitätsabweichungen hinsichtlich der relevanten Metriken zur Bewertung der Modellierungsfähigkeit aufweist. Diese nachgewiesene Fehlertoleranz erschließt ein wertvolles geometrisches Gestaltungsbudget, welches den Übergang zur adaptiven Versuchsplanung legitimiert. Anstatt Versuchspunkte lediglich zur passiven Kostensenkung zu eliminieren, werden freigewordene Stützstellen proaktiv als Extrapolations-Ankerpunkte in Richtung des Feldbereichs verlagert. Dieser methodische Brückenbau - formalisiert im neu entwickelten *Extrapolation-Variance minimized Accelerated Lifetime Testing Design (EmALT)* - stützt das Regressionsmodell auf dem Extrapolationspfad empirisch ab. Zur richtungsabhängigen Quantifizierung der resultierenden Prognosevarianz wird der *Extrapolation*

tion Variance Graph (EVG) eingeführt. Dieser belegt formal, dass die Allokation der Ankerpunkte die Unsicherheit am anvisierten Feld-Betriebspunkt massiv reduziert. Den Abschluss bildet die Synthese mit einem Kostenmodell, welches den inhärenten Zielkonflikt der Lebensdauererprobung quantifiziert: Eine gesteigerte Prognosegüte im Feldbereich verursacht durch die reduzierte Stressbeschleunigung exponentiell höhere Prüfstandskosten. Die Arbeit etabliert hierfür den *Economic Extrapolation Power Index (EPI)* als holistische Bewertungsmetrik. Eine empirische Fallstudie verifiziert die Methodik abschließend anhand prädiktiver Confirmation Experiments. Die Dissertation weist somit nach, dass sich Effizienz in der Versuchsplanung nicht über die bedingungslose Minimierung von Prüfläufen definiert, sondern sich durch das ökonomische Optimum zwischen minimalem Ressourceneinsatz und der zwingenden Absicherung der statistischen Vorhersagegüte im Einsatzbereich manifestiert.

Abstract

Reliability engineering employs Accelerated Life Testing (ALT) to compress development cycles. Because the failure behavior of technical systems is typically governed by multiple interacting loads, the corresponding empirical modeling of component life strictly requires multivariate statistical Design of Experiments (DoE) utilizing Response Surface Methodology (RSM). Within this context, the Central Composite Design (CCD) has emerged as the standard experimental design for technical applications. However, applying this design to ALT without scrutiny introduces a fundamental methodological conflict: While classical experimental designs are optimized for geometric symmetry and interpolation within the center of the design space, life testing inherently necessitates extrapolation from elevated test loads to moderate field conditions. Furthermore, lifetime data - characterized by asymmetric Weibull distributions and censoring - violate the classical premises of normally distributed residuals.

This dissertation addresses this conflict by introducing a holistic framework for the design of highly efficient lifetime tests. Initially, a heuristic screening procedure rationally reduces the dimensionality of the parameter space to the critical influencing variables. In the information-theoretic core of the study, Monte Carlo Simulation (MCS) demonstrates that the CCD exhibits pronounced topological resilience against practice-induced deviations from orthogonality, as evaluated by relevant metrics for modeling capability. This proven fault tolerance unlocks a valuable geometric design budget, which legitimizes the transition toward adaptive experimental design. Rather than merely eliminating design points for passive cost reduction, available support points are proactively relocated as extrapolation anchor points toward the expected field operation domain. This methodological bridging - formalized in the newly developed Extrapolation-Variance minimized Accelerated Lifetime Testing Design (EmALT) - empirically anchors the regression model along the extrapolation path. To quantify the resulting prediction variance on a directional basis, the Extrapolation Variance Graph (EVG) is introduced. This metric formally substantiates that the strategic allo-

cation of anchor points significantly reduces uncertainty at the targeted field operating point.

The framework concludes with a synthesis incorporating a cost model that quantifies the inherent trade-off in life testing: Enhanced prediction accuracy in the field domain incurs exponentially higher test rig costs due to the reduced stress acceleration. To address this, the study establishes the Economic Extrapolation Power Index (EPI) as a holistic evaluation metric. Finally, an empirical case study verifies the methodology through predictive confirmation experiments.

Consequently, this dissertation demonstrates that efficiency in experimental design is not defined by the unconditional minimization of test runs, but rather manifests as the economic optimum between minimizing resource expenditure and rigorously ensuring statistical prediction quality within the intended application domain.

Inhaltsverzeichnis

Vorwort	iii
Kurzfassung	v
Abstract	vii
Nomenklatur	xiii
Abkürzungen	xiii
Indizes	xiv
Formelzeichen	xvi
1 Einleitung	1
1.1 Forschungsperspektive und Problembeschreibung	2
1.2 Beitrag dieser Arbeit	3
1.3 Aufbau der Arbeit	5
2 Stand der Technik und Forschung	7
2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie	7
2.1.1 Begriffe und Definitionen	8
2.1.2 Deskriptive Statistik für Lebensdauerdaten	9
2.1.3 Parametrische Lebensdauermodelle	10
2.1.4 Parameterschätzverfahren	12
2.2 Statistische Versuchsplanung und Modellbildung	14
2.2.1 Grundlagen zur statistischen Versuchsplanung	15
2.2.2 Parameter-Screening	16
2.2.3 Statistische Versuchsplanung zur Lebensdauererprobung . .	17
2.2.4 Strategische Vorgehensweisen	21
2.2.5 Bewertung und Optimierung von Versuchsplanung	23
2.2.6 Statistische Modellbildung	35

3	Testplanung für die multivariate Lebensdauererprobung	45
3.1	Bewertung des Forschungsstandes	45
3.1.1	Das methodische Paradoxon ALT-optimaler GLM-Designs	46
3.1.2	Diskrepanz zwischen geometrischer Optimalität und stochastischer Trennschärfe	47
3.1.3	Synthese des Forschungsstandes und Ableitung der Forschungslücke	49
3.2	Forschungsfragen und wissenschaftliche Zielsetzung	51
3.3	Methodische Forschungsarchitektur	53
4	Statistische Effektivität als Fundament effizienter Lebensdauererprobung	55
4.1	Methodische Simulationsarchitektur und pseudo-physikalisches Modell	56
4.1.1	Pseudo-physikalisches Ground-Truth-Modell	56
4.1.2	Simulationsarchitektur und Monte-Carlo-Inferenz	57
4.2	Effektivität von Versuchsplänen mit Orthogonalitätsabweichungen	60
4.2.1	Potenzialanalyse geometrischer und stochastischer Einflussgrößen	61
4.2.2	Ergebnisse der Potenzialanalyse und Quantifizierung der Trennschärfe	64
4.2.3	Generische Auswirkungen relevanter Orthogonalitätsabweichungen	65
4.2.4	Fazit: Statistische Effektivität als Basis der explorativen Versuchsplanung	70
4.3	Adaptive Versuchsplanung zur Extrapolationsabsicherung	72
4.3.1	Die Scaled Prediction Variance als Prognosemetrik	72
4.3.2	Richtungsabhängige Bewertung: Der Extrapolation Variance Graph (EVG)	74
4.3.3	Isolierte stochastische Validierung der asymmetrischen Topologie	75
4.4	Kostenstruktur der Lebensdauererprobung	80
4.5	Übertragung auf multivariate Lebensdauermodelle	80
4.5.1	Signal-Rausch-Kalibrierung im AFT-Raum	80

4.5.2	Effizientes Lifetime Design of Experiments (L-DoE) und der Economic Extrapolation Power Index	82
4.6	Methodische Synthese und Transfer	86
5	Empirische Validierung der Extrapolationsabsicherung	89
5.1	Modellschätzung und Anpassungsgüte	92
5.1.1	Residuenanalyse und Verifikationsdiagnostik	94
5.2	Konsequenzen für die Zuverlässigkeitsmodellierung	95
5.2.1	Confirmation Experiments: Der statistische Härtetest	97
5.2.2	Ökonomische Schlussfolgerung und industrieller Business Case	99
6	Zusammenfassung und Ausblick	101
6.1	Diskussion	103
6.2	Ausblick	104
Literatur		107
Anhang		119
A	Sensitivitätsanalyse	119
B	Orthogonalitäts-Analysen der Design-Modifikationen	128
B.1	Szenarien bei Arbeitspunkt SNR= 1	133
B.2	Effizienzanalysen	133

Nomenklatur

Abkürzungen

<i>cdf</i>	Cumulative Distribution Function
<i>pdf</i>	Probability Density Function
AFT	Accelerated Failure Time
ALT	Accelerated Lifetime Testing
ANOVA	Varianzanalyse, engl. Analysis of Variance
AP	Ankerpunkt
CCD	Central Composite Design
CI	Confidence Interval
DoE	Design of Experiments
DSD	Definitive Screening Design
DSM	Design-Structure-Matrix
EmALT	Extrapolationvariance minimized Accelerated Lifetime Testing
EoL	End-of-Life
EPI	Economic Extrapolation Power Index
EVG	Extrapolation Variance Graph
FC	Face Centered
FDS	Fraction of Design Space
GLL	Generalized Log-Linear
GLM	Generalized Linear Model
ILP	Integer Linear Programming
IMA	Institut für Maschinenelemente

IWLS	Iteratively Weighted Least Squares
KPI	Leistungsindikator, engl. Key Performance Indicator
L-DoE	Lifetime Design of Experiments
LR-Test	Likelihood-Ratio Test
MCS	Monte-Carlo-Simulation
MLE	Maximum Likelihood Estimation
MSE	Mean Squared Error
OLS	Ordinary Least Squares
OMARS	Orthogonal Minimally Aliased Response Surface
PH	Proportional Hazard
PI	Prediction Interval
RSD	Response Surface Design
RSM	Response Surface Methodology
SNR	Signal-zu-Rausch Verhältnis, engl. Signal-to-Noise Ratio
SP	Sternpunkt
SPV	Scaled Prediction Variance
UPV	Unscaled Prediction Variance
VDG	Variance Dispersion Graph
VIF	Varianz-Inflations-Faktor
ZP	Zentralpunkt

Indizes

0	Zeitpunkt $t = 0$ Regressionskonstante Position im Versuchsraum
Σ	Gesamtkosten
AP	Ankerpunkt

A	Umgebungskosten (Ambient Conditions)
BC	Box-Cox-Transformation
B	Basis-Prüfstandshardware
C	Steuerungstechnik (Control)
D	Sternpunkt Abstand CCD
E	Energiekosten
F	Faktorieller Punkt
H	Hilfs- und Betriebsstoffe
I	Messtechnik (Instrumentation)
L	Labor- und Infrastrukturkosten
MC	Monte-Carlo-Simulation
M	Instandhaltungskosten (Maintenance)
O	Personalkosten (Operator)
SP	Sternpunkt
S	Laufende Durchführungskosten (Size of Testing)
T	Prüfstandskosten (Test Equipment)
V	Transformation
ZP	Zentralpunkt
a	Simulationsfaktor: Sternpunkt-Abstand
b	Simulationsfaktor: Sternpunkt-Shift
c	Simulationsfaktor: Zentralpunkte
d	Simulationsfaktor: Sternpunkte
error	Fehler 2. Art (Wahrscheinlichkeit für ein falsch-negatives Ergebnis)
e	Simulationsfaktor: System-Rauschen
f	Simulationsfaktor: Effekt-Verhältnis
g	Simulationsfaktor: Mess-Rauschen
h	Simulationsfaktor: Signifikanzniveau

m	Modellbezogen
nc	Nichtzentral (non-central)
nom	Nominale Werte
ob	Beobachtet (Observed)
sim	Simulationsergebnisse
i	Laufvariable
j	Laufvariable
k	Laufvariable (für Faktor-Indizierung)
l	Laufvariable
o	Obere Grenze des Vertrauensbereichs
q	Quantilwert
u	Untere Grenze des Vertrauensbereichs
z	Zensierungsindikator

Formelzeichen

A_2	Nicht-Orthogonalitätsindikator (A_2 -Kriterium)
A_{opt}	A-Optimalitätskriterium (Spur-Minimierung)
α	Signifikanzniveau Abstand der Sternpunkte (Axial Points)
b	Weibull-Formparameter (Weibull-Modul)
β	Koeffizientenmatrix
β	Regressionskoeffizient, Modellparameter Fehler 2.Art
C	Kosten (allgemein)
Ω	Kandidatenmenge (Menge aller möglichen Faktorstufenkombinationen)
$\chi^2(\cdot)$	Chi-Quadrat-Verteilung

$\text{Cov}[\cdot]$	Covarianz-Operator
COVRATIO	Einflussstatistik auf Schätzwerte (Covariance Ratio)
D	Cook's Distanz
d_f	Anzahl der Freiheitsgrade
D_{opt}	D-Optimalitätskriterium (Determinanten-Maximierung)
γ	Binäre Entscheidungsvariable für die Design-Optimierung (1 = Versuchspunkt ausgewählt)
δ	Statusindikator (1=Ausfall, 0=Zensiert)
DFBETAS	Einflussstatistik auf Koeffizienten (Difference in Betas)
DFFITS	Einflussstatistik auf Prädiktionen (Difference in Fits)
$E(\cdot)$	Erwartungswert
$\vec{e}$	Richtungsvektor zur extrapolierten Prognose
E	Effekt
A_{eff}	A-Effizienz
D_{eff}	D-Effizienz (Normierte Determinante)
G_{eff}	G-Effizienz (Verhältnis Modellparameter zu max. Varianz)
I_{eff}	I-Effizienz
V_{eff}	V-Effizienz
λ	Eigenwert (einer Matrix)
	Transformationsparameter (Box-Cox)
η_{eco}	Economic Extrapolation Power Index
ϵ	Fehlerterm-Matrix
ϵ	Fehlerterm
$E(\cdot)$	Erwartungswert
$F(\cdot)$	Ausfallwahrscheinlichkeit, Verteilungsfunktion
$f(\cdot)$	Dichtefunktion
F	Fisher-Informationsmatrix
$G(\cdot)$	Verteilungsfunktion der kleinsten Extremwerte

G_{opt}	G-Optimalitätskriterium (Minimierung max. Prädiktionsvarianz)
$\Gamma(\cdot)$	Gamma-Funktion
$\mathbf{H}_f$	Hesse-Matrix (der Log-Likelihood-Funktion)
h	Eintrag von H , Hebelwert
H_0	Nullhypothese
H_1	Alternativhypothese
$\mathbf{H}$	Orthogonale Projektionsmatrix, Prädiktionsmatrix, Hat-Matrix
I_{opt}	I-Optimalitätskriterium (Minimierung durchschn. Prädiktionsvarianz)
k	Anzahl der Modellparameter
$\mathcal{L}(\cdot)$	Likelihood-Funktion
$\Lambda(\cdot)$	Log-Likelihood-Funktion
$\lambda(t)$	Ausfallrate (zeitabhängig)
LR	Likelihood-Ratio
$\mathbf{M}$	Informationsmatrix X' X
m	Replikation
MSE	Mittlerer quadratischer Fehler (Mean Squared Error)
μ	Lageparameter
N	Versuchsanzahl
n	Stichprobenumfang Anzahlvariable
k_f	Anzahl der Faktoren (Dimension)
p	Anzahl der Regressionskoeffizienten
p -Wert	Überschreitungs-, Rest-Irrtumswahrscheinlichkeit
p_f	Fraktionsgrad
$power$	Trennschärfe, Power
Pr	Wahrscheinlichkeit

$v(\mathbf{x}_0)$	Prädiktionsvarianz an der Stelle $\mathbf{x}_0$ (skaliert)
q	Quantilwert
R	Zuverlässigkeit
r	Paarweiser (Pearson-)Korrelationskoeffizient Radius im Versuchsraum (Euklidische Distanz) Studentisiertes Residuum
R^2	Bestimmtheitsmaß (Determinationskoeffizient)
r_{CS}	Cox-Snell-Residuum
r_{Dev}	Standardisiertes Devianz-Residuum
r	Standardisiertes Residuum (bezogen auf die SEV-Verteilung)
$\mathbb{R}$	Menge der reellen Zahlen
s	Empirische Standardabweichung (von x)
s^2	Empirische Varianz (von x)
$SEV(\cdot, \cdot)$	Verteilung der kleinsten Extremwerte, engl. Smallest Extreme Value
σ	Standardabweichung (theoretisch) Skalenparameter
σ^2	Varianz der Lebensdauer (theoretisch)
SNR	Signal-zu-Rausch Verhältnis (engl. Signal-to-Noise Ratio)
T	Charakteristische Lebensdauer (Skalenparameter)
t	Zeit, Lebensdauermerkmal Teststatistik in Bezug zur Signal-to-Noise Ratio
$\mathbf{t}$	Vektor der Ausfallzeiten
τ	kontinuierliche Zufallsvariable
θ	Modellparameter, Schätzung
$\boldsymbol{\theta}$	Vektor der Modellparameter
U_{opt}	U-Optimalitätskriterium (Minimierung der Prädiktionsvarianz am spezifischen Extrapolations- oder Betriebspunkt $\mathbf{x}_0$)
v	Integrationsvariable (Gamma-Funktion)

V	Varianz-Kovarianz-Matrix
V_{opt}	V-Optimalitätskriterium (Punktuelle Varianz-Minimierung)
$\text{Var}[\cdot]$	Varianz-Operator
$\mathcal{W}(\cdot, \cdot)$	Weibull-Verteilung
w	Hilfsgröße zur Berechnung von Vertrauensbereichen (standardisierte Log-Lebensdauer)
W	Gewichtsmatrix (Diagonalmatrix im angenommenen GLM)
X	Versuchsplan-Matrix oder Modellmatrix
x	Messwert, Variable, Parameter
$\bar{x}$	Arithmetischer Mittelwert (empirisch)
$\mathcal{X}$	Anker-Exposition (zulässiges Toleranzfeld für Extrapolationsankerpunkte)
x	Position im Parameterraum
ζ	Einflussfaktor im Meta-Design der Sensitivitätsanalyse
$\boldsymbol{\zeta}$	Vektor der Einflussfaktoren im Meta-Design der Sensitivitätsanalyse
y	Antwortmatrix
y	Systemantwort, -variable
z	Quantil der Standardnormalverteilung
z_e	Standardisierte Variable der Kleinstwertverteilung (SEV); Hilfsgröße für Wald-Konfidenzintervalle (äquivalent zu w)

Änderungen

Autor:in: Anonym

Keine Änderungen.

Autor:in: Daz (Martin)

Eingefügt 5
Gelöscht 2
Ersetzt 8
Hervorgehoben 11
Kommentiert 13

Autor:in: Mell (Heiko)

Eingefügt 0
Gelöscht 0
Ersetzt 0
Hervorgehoben 6
Kommentiert 1

1 Einleitung

Die funktionale Absicherung technischer Produkte und Systeme über ihre gesamte **LebensdauerLebenszyklus**^{Daz} bildet das Fundament einer beherrschten industriellen Produktentwicklung. Motiviert durch zugesicherte Systemeigenschaften, die Wahrung der Markenintegrität sowie zunehmend restriktive und regulatorische Rahmenbedingungen ist ein proaktives Zuverlässigkeitsmanagement, **innerhalb dessen die Lebensdauererprobung eine grundlegende Validierungsmethode darstellt**^{Daz}, für Produkthersteller unerlässlich. Aus der Marktperspektive manifestiert sich dies in der Anforderung, dass komplexe technische Systeme - von automatisierten Fahrzeugarchitekturen über vernetzte mechatronische Subsysteme bis hin zu energie- und antriebstechnischen Anlagen - ihre spezifizierte Funktionalität über den definierten Einsatz- und Gewährleistungszeitraum **ausfallfrei**^{Daz} erfüllen.

Die Zuverlässigkeitstechnik stellt die **erforderlichen Methoden**^{Daz} bereit, um das Produkt-Ausfallverhalten über die Einsatzdauer hinweg quantitativ zu beherrschen. Das Spektrum reicht von **präventivendeterministischen**^{Daz} Methoden der funktionalen Sicherheit über die stochastische Analyse von Felddaten bis hin zu Verfahren der statistischen Versuchsplanung für die beschleunigte Lebensdauererprobung - engl. *Accelerated Lifetime Testing (ALT)*. Ein **zentrales Ergebnis** ist darauf aufbauend die probabilistische Modellierung der zeitabhängigen Überlebenswahrscheinlichkeit bzw. Zuverlässigkeit $R(t)$, welche die Wahrscheinlichkeit quantifiziert, dass ein System unter definierten Betriebs- und Umgebungsbedingungen bis zu einem Zeitpunkt t funktionsfähig bleibt [1]. Ungenügende Zuverlässigkeitsprognosen in der industriellen Praxis resultieren dabei **nicht ausschließlich**^{Daz} aus einem rein quantitativen Mangel an Prüfstandskapazitäten. Vielmehr begründen sich Fehleinschätzungen **auch primär**^{Daz} darin, dass im Betrieb simultan *mehrere* heterogene Stressoren als Einflussparameter auf das System einwirken. Auch können resultierenden Schädigungsmechanismen durch latente Wechselwirkungen getrieben werden, welche durch isolierte, univariate Versuchsstrategien methodisch schlichtweg nicht erfasst werden können [2, 3].

[Daz 1] präziser

Die Beherrschung multivariater Beanspruchungskollektive erfordert folglich den Einsatz passender, statistischer Versuchsmethoden. Mit der fortschreitenden mechanischen Integration und Funktionsverdichtung gewinnt die multivariate Lebensdauererprobung damit eine existenzielle Bedeutung für die ressourceneffiziente Produktabsicherung.

1.1 Forschungsperspektive und Problembeschreibung

[Daz 2] knapper formuliert

Werden multivariate Abhängigkeiten bei der Lebensdauerabsicherung methodisch unzureichend aufgelöst, ist in der industriellen Praxis das Ausweichen auf kostenintensive Kompensationsstrategien eine gängige aber unvorteilhafte Folge: Komponenten werden konservativ überdimensioniert, Austauschintervalle präventiv verkürzt oder unerkannte Wechselwirkungen provozieren fatale Feldausfälle mit unter Umständen kapitalen Gewährleistungs- und Reputationsfolgen. Um Lebensdauerdominierende Schädigungsmechanismen unter multivariaten Beanspruchungskollektiven empirisch und ausfallbasiert zu quantifizieren und gleichzeitig ressourcenintensive Prüfzeiten zu minimieren, ist die methodische Kopplung von statistischer Versuchsplanung - *Design of Experiments (DoE)* - mit der *End-of-Life (EoL)*-Erprobung durch *ALT* zwingend erforderlich.

An dieser methodischen Schnittstelle offenbart sich jedoch eine fundamentale Diskrepanz zwischen dem statistischen Werkzeug und der ingenieurtechnischen Zielsetzung: Klassische Konzepte der *Response Surface Methodology (RSM)* und etablierte Versuchsdesigns (wie das *Central Composite Design (CCD)*) sind stochastisch und topologisch strikt auf Interpolation ausgelegt [3, 4]. Ihre geometrische Struktur minimiert die Schätzvarianz exakt im Zentrum des experimentellen Versuchsraums. Die angewandte Zuverlässigkeitsmodellierung erfordert hingegen die Überbrückung zweier räumlich getrennter Domänen: Um physikalische Ausfälle innerhalb strenger ökonomischer Restriktionen zu provozieren, muss die *ALT*-Prüfung im Hochlastbereich erfolgen - im *Test-Parameterraum*. Die prädiktive Anwendung der erzeugten Modelle - die Absicherung der Systemlebensdauer - verlangt jedoch eine Prognose unter moderaten Feldbedingungen - im *Betriebs-Parameterraum*. Da der experimentelle Prüfraum und der reale Betriebsraum topologisch getrennt sind, wird das Regressionsmodell unweigerlich zur fernen Extrapolation gezwungen, vergleiche Abbildung 1.1.




Abbildung 1.1: Schematische Darstellung des Zusammenhangs von *Betriebs-Parameterraum* und *Test-Parameterraum* für die Anwendung von ALT in einem normalisierten Raum mit zwei Einflussparametern x_1 und x_2 .

Dieser strukturelle Widerspruch zwischen einem interpolationsoptimierten Versuchsentwurf und der extrapolationsbasierten Zuverlässigkeitsanwendung führt in der Prüfpraxis zu einer drastischen Fehlallokation experimenteller Ressourcen: Standard-DoEs konzentrieren ihre maximale Schätzpräzision im prädiktiv irrelevanten aber ökonomisch interessanten Test-Parameterraum des Hochlastbereichs, während die Vorhersagegüte entlang des kritischen Extrapolationspfads in Richtung der realen Einsatzbedingungen kollabiert und die Prädiktionsvarianz massiv divergiert. Die unmodifizierte Anwendung klassischer, zentrums-fokussierter Versuchspläne in der Lebensdauererprobung generiert demnach lediglich Scheingenauigkeiten im unmittelbaren Prüfraum, induziert am maßgeblichen Feld-Betriebspunkt jedoch unkontrollierbare stochastische Unsicherheiten.

1.2 Beitrag dieser Arbeit

Ausgehend von diesem **mathematisch-topologischen Widerspruch** formuliert die vorliegende Dissertation eine neuartige Systematik zur Auslegung hocheffizienter, multi-variater Lebensdauertests. Liegt ein System vor, dessen Zuverlässigkeit unter Einwir-

[Daz 3] schärfung Konflikt/Kern

kung mehrerer interagierender Stressfaktoren experimentell durch [EoL](#) abzusichern ist, stellt diese Arbeit die erforderlichen theoretischen, simulativen und empirischen Methoden zur Verfügung, um klassische Versuchspläne in extrapolations-optimierte Lebensdauerprüfungen zu transformieren. Der wissenschaftliche Kern der Arbeit besteht folglich in der gezielten topologischen Absicherung der Vorhersagegüte für Lebensdauern bzw. Zuverlässigkeiten im Parameterraum der Feldbetriebspunkte - die zwingende mathematische Voraussetzung, um [ALT](#) unter ökonomischen Restriktionen überhaupt stochastisch belastbar zu legitimieren.

Der wissenschaftliche Beitrag gliedert sich somit in [drei-vier](#) zentrale Kernelemente:

- **Quantifizierung topologischer Resilienz:**

Systematischer, simulativer Nachweis mittels Monte-Carlo-Methoden, dass klassische [Response Surface Designs \(RSDs\)](#) eine signifikante Robustheit gegenüber praxisinduzierten, [strukturellen Modifikationen](#) [Orthogonalitätsabweichungen](#) aufweisen. Hieraus werden neben der methodischen Existenz eines nutzbaren geometrischen *Gestaltungsbudgets* auch die adäquaten Bewertungsmetriken für die Versuchsplaneignung abgeleitet.

- **Adaptive Versuchsplanung und richtungs-sensitive Varianzbewertung:**

Proaktive Umwidmung des identifizierten Gestaltungsbudgets zur gezielten Anpassung des Versuchsplans in Richtung des angestrebten Prognosebereichs im Feld-Parameterraum, formalisiert im adaptiven [Extrapolationvariance minimized Accelerated Lifetime Testing \(EmALT\)](#)-Design. Zur objektiven Quantifizierung des stochastischen Leistungsgewinns wird begleitend der [Extrapolation Variance Graph \(EVG\)](#) als neuartiges Bewertungswerkzeug eingeführt, welches die Prognoseunsicherheit zum Prädiktionspunkt gerichtet erfasst.

- **Ökonomische Synthese:**

Etablierung einer ganzheitlichen Bewertungsmetrik zur simultanen Bilanzierung von statistischer Trennschärfe, Extrapolationsunsicherheit und realen Prüfstandskosten.

[Daz 4] Kap 4
raus

[Daz 5] allge-
meiner

1.3 Aufbau der Arbeit

Der strukturelle Aufbau der vorliegenden Arbeit orientiert sich an der methodischen Sequenz einer effizienten multivariaten Versuchskampagne (vgl. Abbildung 1.2).

Nach der in diesem Kapitel dargelegten Problemstellung widmet sich **Kapitel 2** dem aktuellen Stand der Forschung und Technik. Dort werden die mathematisch-statistischen Grundlagen der Zuverlässigkeits-Datenanalyse, der *Maximum Likelihood Estimation (MLE)*, der statistischen Versuchsplanung (DoE) sowie der multivariaten Modellbildung im Rahmen von *Generalized Linear Models (GLMs)* systematisch aufbereitet. **Kapitel 3** synthetisiert diese Grundlagen, identifiziert die inhärenten Schwachstellen klassischer Optimalitätskriterien bei Lebensdauerprüfungen und leitet hieraus die zentralen Forschungsfragen der Dissertation ab.

Darauf aufbauend vollzieht zunächst **Kapitel 4** den methodischen Schritt zur quantitativen Versuchsplanung: Ausgehend von der quantifizierten **strukturellen Robustheittopologischen-Resilienz^{Daz}** klassischer Designs werden die Methodik der richtungssensitiven Varianzanalyse, das Konzept der asymmetrischen Extrapolationsabsicherung sowie die ökonomisch-statistische Effizienzbilanzierung hergeleitet und im Weibull-Kontext simulativ aufgezeigt.

In **Kapitel 5** erfolgt der Transfer in die industrielle Praxis. Anhand eines realen Datensatzes zur Lebensdauerprüfung von Lenksystem-Zahnriemen wird die Leistungsfähigkeit der entwickelten Methodik durch statistische Bestätigungsversuche empirisch verifiziert und der resultierende ökonomische Business Case dargelegt. Die Arbeit schließt in **Kapitel 6** mit einer Zusammenfassung der Kernergebnisse, einer kritischen Diskussion methodischer Anwendungsgrenzen sowie einem Ausblick auf weiterführende Forschungsfelder ab.




Abbildung 1.2: Aufbau der Arbeit.

2 Stand der Technik und Forschung

Dieses Kapitel stellt die für diese Arbeit erforderlichen technischen und methodischen Grundlagen bereit. Zunächst werden in Abschnitt 2.1 zentrale Begriffe und Konzepte der Zuverlässigkeitstechnik sowie das grundlegende statistische Verfahren zur Lebensdauer-Datenanalyse in Kombination mit Versuchsplänen erläutert. Darauf aufbauend folgen in Abschnitt 2.2 die Einführung und die Einordnung von DoE für Lebensdaueruntersuchungen sowie der multivariaten Lebensdauermodellierung aus dem Stand der Technik und der Wissenschaft, die beide für die Entwicklung effizienter Lebensdauerversuchspläne maßgeblich sind. Im Kontext der Lebensdauererprobung umfasst dies insbesondere typische, statistische Versuchspläne sowie Metriken und Indikatoren zur allgemeinen Bewertung der Versuchspläne.

2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie

Die Zuverlässigkeitstechnik befasst sich mit der probabilistischen Beschreibung der Lebensdauer technischer Produkte und Systeme sowie der strategischen und statistischen Planung von Lebensdauertests. Ziel ist die statistische Modellierung des Ausfallverhaltens unter Berücksichtigung der Funktionalität des Produkts bei relevanten Randbedingungen. Eine zentrale Aufgabe besteht somit in der statistischen Charakterisierung des Ausfallbegriffs mithilfe deskriptiver Statistik sowie in der Parametrisierung geeigneter Verteilungen zur Abbildung des Lebensdauerverhaltens. Die Modellierung kann - abhängig von den Randbedingungen - auf Basis *einer einzelnen* Belastungsgröße oder *mehrerer* Beanspruchungsparameter erfolgen, die gemeinsam den Produktausfall determinieren. Ein grundlegendes Verständnis des Umgangs mit zufallsverteilten Lebensdauerereignissen ist daher eine elementare Voraussetzung für die statistische Versuchsplanung im Rahmen der Zuverlässigkeitstechnik. Weiterführende Konzepte und vertiefte methodische Ansätze zur Zuverlässigkeitstechnik sowie

zur statistischen Testplanung sind allen voran in der Standardliteratur von Bertsche und Dazer [1] dargelegt, an deren Vorgehensweise sich die nachfolgende Übersicht orientiert.

2.1.1 Begriffe und Definitionen

Der *Ausfall* eines Produkts bezeichnet das Ende der Lebensdauer durch Verlust der geforderten Funktionalität. Maßgeblich hierfür sind für Ermüdungsausfälle^{Daz} von außen einwirkende *Belastungen* (einzelne oder zeitgleich mehrere Einflussparameter - Kräfte und Momente im mechanischen Kontext) sowie die daraus resultierenden inneren *Beanspruchungen* (innere Kräfte, Momente und lokale Spannungen). Die Ausfallzeit wird als kontinuierliche Zufallsvariable $\tau > 0$ verstanden, wobei $\tilde{t}$ ^{Mell} als zugehörige zeitliche Integrationsvariable fungiert. Die fundamentalen Funktionen zur probabilistischen Beschreibung des Lebensdauerverhaltens sind gemeinsam mit deskriptiven Statistiken in Tabelle 2.1 zusammengefasst [1, 2, 5].

Tabelle 2.1: Mathematische Definitionen der Zuverlässigkeitsfunktionen

Wahrscheinlichkeitsdichte (*Probability Density Function (pdf)*):

Änderungsrate der Ausfallwahrscheinlichkeit.

$$f(t) = \frac{d}{dt}F(t) = \frac{d}{dt}\Pr(\tau \leq t), \quad t \geq 0. \quad (2.1)$$

Kumulative Ausfallwahrscheinlichkeit (*Cumulative Distribution Function (cdf)*):

Wahrscheinlichkeit eines Ausfalls bis zum Zeitpunkt t .

$$F(t) = \Pr(\tau \leq t) = \int_0^t f(\tilde{t}) d\tilde{t} \quad (2.2)$$

Tabelle 2.1 (Fortsetzung): Mathematische Definitionen

Zuverlässigkeit:

Überlebenswahrscheinlichkeit über den Zeitpunkt t hinaus.

$$R(t) = 1 - F(t) = \int_t^{\infty} f(\tilde{t}) d\tilde{t} \quad (2.3)$$

Ausfallrate (Hazard-Function):

Momentanes Ausfallrisiko, bedingt auf das Überleben bis t .

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t < \tau \leq t + \Delta t | \tau > t)}{\Delta t} = \frac{f(t)}{R(t)} \quad (2.4)$$

2.1.2 Deskriptive Statistik für Lebensdauerdaten

Um die theoretischen Parameter der Grundgesamtheit in der Praxis nutzbar zu machen, müssen diese auf Basis empirisch ermittelter Lebensdauerdaten (Stichprobe vom Umfang n mit den Ausfallzeiten $t_1, \dots, t_n$) approximiert werden. Die deskriptive Statistik liefert hierfür Methoden zur Berechnung von *Lageparametern* (Zentrum) und *Streuungsmaßen* (Breite). Tabelle 2.2 fasst die theoretischen Definitionen der Zufallsvariable τ sowie die grundlegenden Zuverlässigkeitsfunktionen und ihre korrespondierenden empirischen Schätzer kompakt zusammen.

Tabelle 2.2: Deskriptive Kennzahlen im Kontext der Lebensdaueranalyse

Erwartungswert und Mittelwert:

Erwartungswert μ des theoretischen Lageparameters der Grundgesamtheit. Der arithmetische **Mittelwert** $\bar{t}$ dient als üblicher, *empirischer Schätzer* für eine endliche Stichprobe.

$$\mu = E[\tau] = \int_0^{\infty} \tilde{t} \cdot f(\tilde{t}) d\tilde{t} \quad \text{geschätzt durch} \quad \bar{t} = \frac{1}{n} \sum_{i=1}^n t_i \quad (2.5)$$

Quantile und Median:

Das Quantil t_q definiert den Zeitpunkt, an dem die Verteilung $F(t)$ den Anteil $q \in [0, 1]$ erreicht. Der Median $t_{0.5}$ teilt die Fläche unter der *pdf* in zwei Hälften [6, 7].

$$F(t_q) = q \quad \text{bzw. für Median:} \quad F(t_{0.5}) = 0.5 \quad (2.6)$$

Varianz und Standardabweichung:

Die theoretische Varianz σ^2 (mittlere quadratische Abweichung) wird durch die erwartungstreue empirische Varianz s^2 geschätzt. Die empirische Standardabweichung folgt daraus zu $s = \sqrt{s^2}$.

$$\sigma^2 = E[(\tau - \mu)^2] \quad \approx \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (t_i - \bar{t})^2 \quad (2.7)$$

2.1.3 Parametrische Lebensdauermodelle

Während die deskriptiven Statistiken $\bar{x}$ und s^2 die zentrale Tendenz und die Streuung der vorliegenden Stichprobe quantifizieren, erlauben sie keine Extrapolation oder die Modellierung der zugrundeliegenden Funktionen $F(t)$ und $f(t)$ der Grundgesamtheit. Um eine prädiktive, mathematische Beschreibung des stochastischen Ausfallverhaltens zu erhalten, müssen die in Abschnitt 2.1.1 definierten Lebensdauerfunktionen

durch geeignete parametrische Verteilungsmodelle approximiert werden. Andernfalls können nur nichtparametrische Modellierungsansätze zur Schätzung der kumulierten Wahrscheinlichkeit in Überlebensfunktionen wie beispielsweise nach Kaplan und Meier [8] genutzt werden [2, 3]. Die Verteilungsmodelle hingegen bieten eine geschlossene mathematische Form für *cdf* und *pdf* und ermöglichen es, das komplexe Ausfallverhalten durch eine geringe Anzahl von Parametern zu charakterisieren.

Weibull-Verteilung

In der Zuverlässigkeitstechnik hat sich die *Weibull-Verteilung* aufgrund ihrer hohen Flexibilität als das am häufigsten verwendete Modell etabliert. Je nach zugrundeliegendem physikalischen Ausfallmechanismus finden jedoch auch andere statistische Verteilungen Anwendung, wie beispielsweise die *Lognormalverteilung* (häufig bei Ermüdungs-, Korrosions- oder Diffusionsprozessen) oder die *Exponentialverteilung* (zur Modellierung von Zufallsausfällen ohne Alterungseffekte) ~~oder die *Beta-Verteilung*~~ ~~(allgemein zur formenreichen Modellierung von R über dem festen Intervall $[0, 1]$)~~^{Daz} [5, 6]. Für weitere Ausführungen dazu sei an dieser Stelle jedoch auf bereits ausreichend diskutierte Aufbereitungen von Bertsche und Dazer [1], Rigdon et al. [3], Biro lini [5], Yang [6] und Hedderich und Sachs [9] verwiesen.

Die (zweiparametrische) Weibull-Verteilung ist das Standardmodell zur Beschreibung der Lebensdauer von technischen Produkten ohne die Berücksichtigung eines möglichen dritten Parameters - der ausfallfreien Zeit t_0 . Sie wird durch den *Formparameter* $b > 0$ (Weibull-Modul) und die *charakteristische Lebensdauer* $T > 0$ (Skalenparameter), welche dem 63,2-ten Perzentil $t_{0,632}$ entspricht, beschrieben. Unabhängig von b gilt hier somit: $F(T) = 1 - e^{-1} \approx 63,2\%$. Folgt die Lebensdauer-Zufallsvariable τ dieser Verteilung, wird dies mathematisch als $\tau \sim \mathcal{W}(T, b)$ notiert. Damit ist sie in der Lage, alle drei Phasen der "Badewannenkurve" (Frühausfälle mit $b < 1$, Zufallsausfälle $b \approx 1$, Verschleißausfälle mit $b > 1$) durch die Wahl ihrer Parametrisierung abzubilden, vgl. Bertsche und Dazer [1]. Die Einheit des Skalenparameters T entspricht der des Messwertes. Die charakteristischen Funktionen und statistischen Momente der Weibull-Verteilung sind in Tabelle 2.3 zusammengefasst.

Tabelle 2.3: Funktionen und Kennzahlen der Weibull-Verteilung

Dichte- und Verteilungsfunktion (*pdf* & *cdf*):

$$f(t) = \frac{b}{T^b} t^{b-1} \exp \left[- \left(\frac{t}{T} \right)^b \right], \quad t > 0 \quad (2.8)$$

$$F(t) = 1 - \exp \left[- \left(\frac{t}{T} \right)^b \right], \quad t > 0 \quad (2.9)$$

Ausfallrate (Hazard-Funktion:)

$$\lambda(t) = \frac{b}{T} \left(\frac{t}{T} \right)^{b-1}, \quad t > 0 \quad (2.10)$$

Momente und Gamma-Funktion:

Mit der Gamma-Funktion (2.11) $\Gamma(x) = \int_0^\infty v^{x-1} e^{-v} dv$ ergeben sich Erwartungswert μ (vgl. Gleichung (2.5)) und Varianz σ^2 (vgl. Gleichung (2.7)) der Weibull-verteilten Lebensdauer τ :

$$\mu = T \cdot \Gamma \left(1 + \frac{1}{b} \right) \quad (2.12)$$

$$\sigma^2 = T^2 \left[\Gamma \left(1 + \frac{2}{b} \right) - \Gamma^2 \left(1 + \frac{1}{b} \right) \right] \quad (2.13)$$


Die Flexibilität der Verteilung zeigt sich in den Spezialfällen des Formparameters: Für $b = 1$ geht sie in die Exponentialverteilung über ($\lambda(t) = \text{konst.}$), während sie sich für $b \approx 3,6$ ^{Mell} einer Normalverteilung annähert (vgl. Abb. 2.1) [10, 11].

[Daz 6]
b=3,60235 ->
Schiefe=0

2.1.4 Parameterschätzverfahren

[Daz 7] Jetzt
hauptsächlich
in Kap. 2.2.6

Soll eine geschlossene mathematische Beschreibung des stochastischen Ausfallverhaltens gefunden werden, ist nach Vorbild von Abschnitt 2.1.3 ein adäquates Verteilungsmodell zu parametrisieren. Die zentrale Problemstellung besteht darin, aus der



Abbildungung 2.1: Weibull $f(t)$ für ausgewählte Werte von T und b .

empirischen Stichprobe bestehend aus n Realisierungen der Zufallsvariable τ statistisch fundierte Schätzwerte für die wahren Parameter der Grundgesamtheit (z. B. $\hat{T}$ und $\hat{b}$ für $\tau = \mathcal{W}(b, T)$) zu extrahieren. Diese Parameteridentifikation ist die zwingende Voraussetzung, um prädiktive Aussagen zur Zuverlässigkeit $R(t)$ abzuleiten.

Während in der klassischen, normalverteilten Statistik häufig die *Methode der kleinsten Fehlerquadrate* (*Ordinary Least Squares (OLS)*) Anwendung findet, ist diese für die Lebensdauerdatenanalyse unzureichend. Wesentliche Hauptgründe hierfür sind das Auftreten unvollständiger (rechts-zensierter) Beobachtungen, sogenannter *Durchläufer*, sowie die möglicherweise nicht-normalverteilte Natur der Zufallsvariablen Lebensdauer τ . Zur simultanen und erwartungstreuen Abbildung von exakten Ausfällen und Zensierungen hat sich stattdessen die *MLE* als universeller Standard etabliert [2, 12].

Das Grundprinzip der *MLE* besteht darin, diejenigen Parameterwerte als Schätzwerte $\hat{\theta}$ zu identifizieren, welche die Wahrscheinlichkeit (Likelihood) maximieren, exakt die vorliegende empirische Stichprobe beobachtet zu haben. Formal wird die Stichprobe über Paare (t_i, δ_i) definiert, wobei t_i der Prüfzeit und δ_i einem Statusindikator (1 = Ausfall, 0 = Zensierung) entspricht [2, 13]. Unter der Annahme stochastisch unabhängiger Beobachtungen ergibt sich die Likelihood-Funktion $\mathcal{L}$ als Produkt aus

den Wahrscheinlichkeitsdichten $f(\cdot)$ der Ausfälle und den Zuverlässigkeiten $R(\cdot)$ der zensierten Einheiten:

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^n \left[f(t_i|\boldsymbol{\theta})^{\delta_i} \cdot R(t_i|\boldsymbol{\theta})^{1-\delta_i} \right]. \quad (2.14)$$

Zur algorithmischen Maximierung wird dieser Ausdruck durch Logarithmierung in die numerisch stabilere *Log-Likelihood-Funktion* Λ überführt:

$$\Lambda := \ln(\mathcal{L}(\mathbf{t}|\boldsymbol{\theta})) \propto \sum_{i=1}^n [\delta_i \cdot \ln f(t_i|\boldsymbol{\theta}) + (1 - \delta_i) \cdot \ln R(t_i|\boldsymbol{\theta})]. \quad (2.15)$$

Die Identifikation des Parametersatzes $\hat{\boldsymbol{\theta}}$, der $\Lambda(\boldsymbol{\theta})$ maximiert, erfolgt durch das Nullsetzen der partiellen Ableitungen ($\partial \Lambda / \partial \boldsymbol{\theta} \stackrel{!}{=} 0$). Da für die Weibull-Verteilung hierfür keine geschlossenen analytischen Lösungen existieren, werden in der Praxis iterative, numerische Optimierungsalgorithmen (wie das *Newton-Raphson-Verfahren* oder *Pattern-Search-Algorithmen*) angewandt [14, 15, 16]. Methodisch ist dabei zu beachten, dass die MLE zwar asymptotisch erwartungstreu ist, bei kleinen Stichprobenumfängen n jedoch systematische Verzerrungen (*Bias*) in $\hat{\boldsymbol{\theta}}$ aufweisen kann [17], welche sich bei Bedarf durch etablierte Korrekturverfahren kompensieren lassen (*Bias-Korrektur*) [18, 19].

Die MLE liefert jedoch nicht nur die Punktschätzer $\hat{\boldsymbol{\theta}}$, sondern bildet auch das stochastische Fundament zur Quantifizierung der Modellunsicherheiten und *Vertrauensbereiche* (*Confidence Intervals (CIs)*). Da diese Unsicherheitsquantifizierung insbesondere bei Vorliegen multivariater Beanspruchungen (GLMs) über die strukturelle Effizienz der Versuchsplanung entscheidet, wird die dafür erforderliche mathematische Herleitung der Informationsmatrizen geschlossen im multivariaten Kontext in Abschnitt 2.2.6 behandelt.

2.2 Statistische Versuchsplanung und Modellbildung

[Daz 8] Einleitung zum Abschnitt kompakter

Multivariate Lebensdauertests erfordern definitionsgemäß die Variation mehrerer Einflussfaktoren ($k \geq 2$). Die systematische Planung derartiger experimenteller Untersuchungen erfolgt mittels Methoden von DoE, was im spezifischen Kontext der Zuverlässigkeitstechnik nach Kremer [4] auch unter dem Paradigma *L-DoE* zusammen-

mengefasst wird. Während detaillierte historische Abrisse zur klassischen Versuchsplanung der einschlägigen Standardliteratur zu entnehmen sind [20, 21, 22], fokussiert dieser Abschnitt explizit auf die methodischen Anforderungen mehrdimensionaler Lebensdauertests um ferner deren Effizienz zu erörtern.

Der primäre Anspruch von DoE besteht in der ökonomisch effizienten Versuchsplanung sowie empirischen Modellierung einer Systemantwort in Abhängigkeit erklärender Variablen. In der Zuverlässigkeitstechnik zielt dies auf die parametrische Charakterisierung des multivariaten Ausfallverhaltens bzw. der Lebensdauer ab. Eine fundamentale methodische Herausforderung stellt hierbei jedoch die zwingende Integration der beschleunigten Lebensdauererprobung (ALT) dar: Um physikalische Ausfälle innerhalb vertretbarer Prüfzeiten zu provozieren, operieren die Versuchspläne gezwungenermaßen in einem hochbelasteten *Test-Parameterraum*. Die eigentliche Zielsetzung der Modellbildung - die prädiktive Absicherung der Zuverlässigkeit - verlangt jedoch verlässliche Vorhersagen im moderaten *Betriebs-Parameterraum*. Diese räumliche Diskrepanz erzwingt eine formale stochastische Extrapolation, welche grundlegend zum vorliegenden Stand der Technik bislang nicht formal in die Versuchsplanung integriert wurde und im Rahmen von L-DoE als methodische Lücke identifiziert werden kann. Bisherige Ansätze des L-DoE fokussieren primär auf die reine statistische Modellbildung und klammern diesen Beschleunigungs- und Extrapolationsaspekt weitgehend aus. Dadurch bleibt die tatsächliche prädiktive Vorhersagegüte und strategische Effizienz der Versuchspläne für den Feldbetrieb oft unberücksichtigt.

2.2.1 Grundlagen zur statistischen Versuchsplanung

Die methodische Grundlage der statistischen Versuchsplanung bildet die funktionale Abbildung einer Systemantwort y in Abhängigkeit gezielt variiertter Einflussfaktoren - der *Steuergrößen* [22, 23]. Nicht kontrollierbare Einflüsse werden formal als *Störgrößen* abgebildet. Zur empirischen Modellierung werden die Faktoren im definierten *Test-Parameterraum* (*Design-Space*) auf diskreten, typischerweise kodierten *Faktorstufen* (z. B. -1 und $+1$) variiert. Die strukturierte Kombination dieser Stufen definiert die individuellen Versuchspunkte und konstituiert die *Versuchsplan-Matrix*.

Der kausale Einfluss der Faktoren auf die Systemantwort wird mathematisch durch Polynomfunktionen approximiert. Ein fundamentales Regressionsmodell erster Ord-

[Daz 9] gekürzt

nung für $k = 2$ Faktoren erfasst neben der Regressionskonstanten β_0 die linearen Haupteffekte β_1, β_2 sowie deren Wechselwirkung β_{12} :

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \epsilon. \quad (2.16)$$

Sollen bei einer Lebensdauer- und Zuverlässigkeitsanalyse zudem signifikante Nichtlinearitäten quantifiziert werden, wird der Ansatz zu einem Modell *zweiter Ordnung* mit *quadratischen Termen* β_{11}, β_{22} erweitert:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \quad (2.17)$$

Für n Beobachtungen und p zu schätzende Modellparameter lässt sich dieses Gleichungssystem verallgemeinert in Matrixnotation formulieren:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad (2.18)$$

wobei $\boldsymbol{\beta}$ als $p \times 1$ Vektor der Regressionskoeffizienten ($p = k + 1$) durch den $n \times 1$ Vektor $\mathbf{y}$ aller Beobachtungen sowie durch die Versuchsplan-Matrix $\mathbf{X}$ ($n \times p$ Einträge) unter Zuhilfenahme eines geeigneten Schätzverfahrens (vgl. Abschnitt 2.1.4) zu ermitteln ist [6, 14]. Der Parametervektor $\boldsymbol{\beta}$ wird hierbei über etablierte stochastische Optimierungsverfahren (vgl. Abschnitt 2.1.4) geschätzt. Da die Komplexität dieser Modelle exponentiell mit der Anzahl der betrachteten Faktoren skaliert, wird der quantitativen Versuchsdurchführung in der Praxis ein heuristisches oder experimentelles Parameter-Screening vorgeschaltet, um die Dimension des Parameterraums a priori auf die maßgeblichen Einflussgrößen zu reduzieren [24].

2.2.2 Parameter-Screening

Im Hinblick auf die Realisierung eines unter Zeit- und Kostenrestriktionen hochgradig effizienten DoE ist die effiziente Ausgestaltung einer Screening-Strategie selbst schon von primärem Interesse. In traditionellen DoE-Ansätzen impliziert dies den Einsatz von *Kreativmethoden*, wie sie Standardliteratur [22] aufführt oder exemplarisch durch Kremer [4] und Gundlach [25] zusammengefasst werden. Hierbei ist ein Rückgriff auf Ergebnisse aus Experimenten, die explizit für das Forschungsziel ausgelegt wären, in dieser Phase unter Umständen noch nicht möglich. Es gilt damit zunächst,

qualitativ eine rein rational erlesene Sammlung an potenziellen Einflussparameter zu erstellen, um diese dann anhand ihrer geschätzten Einflüsse auf die Systemantwort zu priorisieren. Ansätze aus der Kreativmethodik können dazu genutzt werden und fundieren auf der technischen *Systemanalyse*, die sowohl mit als auch ohne spezifisches Vorwissen über das System erfolgen kann [1]. Hilfsmittel zur Priorisierung einer hier erstellten Parametersammlung können beispielsweise Entscheidungsfindungsprotokolle, wie die *Design-Structure-Matrix (DSM)*, und Methoden aus dem Komplexitätsmanagement, z.B. *Ishikawa-Diagramm*, sein - siehe hierzu auch weiterführende Werke von Mayers [26], Pahl et al. [27], Wu und Hamada [28], Daenzer und Haberfellner [29] sowie Lindemann et al. [30]. Das Screening liefert somit eine rational festgestellte Auswahl an möglichst wenigen Einflussparametern, die perspektivisch den entscheidenden Anteil an statistisch begründeter Manipulation der Systemantwort tragen und sich daher für eine Untersuchung in Versuchsplänen qualifizieren. Eine Abstimmung dieser heuristischen Herangehensweise im Screening insbesondere auf Lebensdaueruntersuchungen findet dabei unter Berücksichtigung der Wechselwirkungen zwischen Faktoren und den Randbedingungen des *Test-Parameterraums* in einem strategischen Ablauf nach [24] statt. Entsprechend ist daraufhin ein geeigneter Versuchsplan für die physischen Datenerhebungen zu wählen.

2.2.3 Statistische Versuchsplanung zur Lebensdauererprobung

Standardprotokolle aus dem DoE eignen sich grundsätzlich auch für Lebensdaueruntersuchungen, da statistische Effekte hierbei formal als Differenz der mittleren Systemantwort zwischen diskreten Einstellstufen berechnet werden. Etablierte Versuchspläne, wie sie in der einschlägigen Literatur [22, 31] beschrieben werden, können daher auch für die Lebensdauererprobung adaptiert werden und sind wie folgt zu klassifizieren:

Faktorielle Versuchspläne zur linearen Modellbildung

Um ein multivariates Parameterset systematisch zu untersuchen, etabliert der 2^k voll-faktorielle Versuchsplan die Basis der klassischen Testplanung. Durch die Kombination von k Faktoren auf jeweils zwei Einstellstufen ermöglicht er die Anpassung eines linearen

[Daz 10] Abschnitt gekürzt

Modells erster Ordnung inklusive aller Wechselwirkungen. Bei einfacher Durchführung (Replikation $m = 1$) erfordert dieses Design exakt

$$n = 2^k \quad (2.19)$$

Versuche. Ein daraus resultierendes, gesättigtes Gleichungssystem erlaubt die eindeutige stochastische Bestimmung aller $n - 1$ Modellterme erster Ordnung. Entscheidend für die prädiktive Aussagekraft ist hierbei die Definition der Faktor-Umfänge: Schrittweite bzw. Stufenabstände. Die Stufenabstände sind einerseits ausreichend groß zu wählen, um signifikante Effekte vom experimentellen Versuchsrauschen zu isolieren - vgl. *Signal-zu-Rausch Verhältnis, engl. Signal-to-Noise Ratio (SNR)*. Andererseits dürfen die Intervalle nicht zu weit gefasst sein, um unerkannte Nichtlinearitäten innerhalb des Interpolationsraums zu vermeiden [28, 31, 32].

Übersteigt die Dimensionalität des Systems eine kritische Grenze (typischerweise $k > 5$), skaliert der Versuchsumfang exponentiell und wird für ressourcenintensive ALT-Kampagnen ökonomisch ineffizient. In diesen Fällen kann das physikalische Screening auf *teil-faktorielle Versuchspläne* reduziert werden, welche lediglich eine definierte Fraktion $n = 2^{k-p_f}$ der vollständigen Planmatrix abbilden [31, 33]. Dieser bewusste Informationsverzicht wird durch zwei empirische Postulate stochastisch legitimiert [3, 33]:

- **Effekthierarchie:** Haupteffekte besitzen in der Regel eine signifikant größere Amplitude als Effekte höherer Ordnung.
- **Effektvererbung:** Die Signifikanz von Wechselwirkungen setzt strukturell die Relevanz der zugehörigen Haupteffekte voraus.

Die systemimmanente Konsequenz dieser Reduktion ist die statistische Vermengung (*Aliasing*) von Haupteffekten und Wechselwirkungen. Für die industriennahe Lebensdauererprobung ist dieser Kompromiss jedoch dann zwingend erforderlich, wenn testintensive Ressourcen zu bündeln und ein faktorielles Screening-Design zu generieren ist, welches in nachfolgenden Entwicklungsphasen nahtlos *augmentiert* werden kann.

Wirkungsflächenversuchspläne zur quadratischen Modellbildung

In generalisierten Ansätzen zur GLM-Parametrisierung kann weiter entscheidend sein, wie die bestehende Datenbasis aus der faktoriellen Erprobung weitergenutzt und augmentiert werden kann, falls die Systemantwort signifikante *Krümmungen* aufweist und die quantitativen Beziehungen zwischen Faktoren und Zielgröße für eine Optimierung detaillierter beschrieben werden müssen.

Die *RSM* behandelt als Teildisziplin des DoE derartige Herangehensweisen und bietet hierfür spezielle *Wirkungsflächenversuchspläne* (*RSDs*) an. Der erste Schritt zur Detektion von Nichtlinearitäten besteht in der Integration von n_{ZP} sogenannten *Zentralpunkte* (*ZPs*) in den faktoriellen Basisplan. Hierbei werden alle Faktoren auf die kodierte Stufe 0 (die Mitte des Versuchsraums) gesetzt. Weicht der Mittelwert der Systemantwort in den *ZPs* signifikant vom Mittelwert über die faktoriellen Eckpunkte ab, deutet dies auf eine Krümmung der Antwortfläche hin [22].

Um diese quadratischen Zusammenhänge explizit zu bestimmen, gilt der *Zentral-Zusammengesetzte-Versuchsplan* (*CCD*) als etablierter Standard [3, 34]^{Daz}. Ein *CCD* entsteht durch die *Augmentierung* des ursprünglichen voll- (oder teil-)faktoriellen Plans (den n_{F} Eckpunkten), vgl. Abbildung 2.2, um:


- eine definierte Anzahl n_{ZP} an wiederholten *ZPs* (üblicherweise $3 \leq n_{\text{ZP}} \leq 5$ zur Abschätzung des reinen Fehlers) [33]; sowie
- $n_{\text{SP}} = 2 \cdot k$ zusätzliche *Sternpunkte* (*SPs*), die auf den Achsen des Koordinatensystems im Abstand $\pm \alpha_{\text{D}}$ vom Zentrum liegen.

[Mell 1] Punkttyp in Abb.

Während die *ZPs* das Vorhandensein quadratischer Effekte validieren, ermöglichen die *SPs* deren Wertbestimmung. Die Wahl des Abstands α_{D} wird primär durch die Geometrie des relevanten *Test-Parameterraums* (*Region of Interest*) diktiert. Wird dieser Raum als *Sphäre* verstanden, ist die *Drehbarkeit* (*Rotierbarkeit*) ein wesentliches Qualitätsmerkmal. Sie stellt sicher, dass die Varianz der Vorhersage nur vom Abstand zum Zentrum abhängt und invariant gegenüber einer Rotation des Koordinatensystems ist. Um diese Eigenschaft zu gewährleisten, berechnet sich der Abstand α_{D} in Abhängigkeit der faktoriellen Versuchspunkte n_{F} zu [22, 35]:

$$\alpha_{\text{D}} = (n_{\text{F}})^{1/4}. \quad (2.20)$$

[Daz 11] Abhängigkeit von n_{F} und damit Faktorenanzahl



(a) Versuchsplan (CCD)

Versuchs- #	Faktorstufen		Punkt- Typ
	x_1	x_2	
1	-1	-1	n_F
2	+1	-1	
3	-1	+1	
4	+1	+1	
5	$-\alpha_D$	0	n_{SP}
6	$+\alpha_D$	0	
7	0	$-\alpha_D$	
8	0	$+\alpha_D$	
9	0	0	n_{ZP}
10	0	0	
11	0	0	
12	0	0	
13	0	0	

(b) Versuchsplanmatrix (Stufen) zu Abb. 2.2a

Abbildung 2.2: Zentral zusammengesetzter Versuchsplan (CCD) mit $k = 2$

Alternativ kann für sphärische Räume auch $\alpha_D = \sqrt{k}$ gewählt werden (*Sphärisches CCD*), wodurch alle faktoriellen Punkte und SPs auf einer Kugeloberfläche liegen [36]. Ist der Versuchsraum hingegen durch harte physikalische Grenzen (z.B. maximale Temperatur) kubisch beschränkt, bietet sich der *flächenzentrierte CCD* (*Face Centered CCD*) an. Hierbei wird $\alpha_D = 1$ gesetzt, sodass die SPs direkt auf den Flächenmitten des Würfels liegen. Dies vereinfacht die Durchführung, da nur drei Faktorstufen (-1 , 0 , $+1$) benötigt werden, opfert jedoch die Eigenschaft der Rotierbarkeit. Eine effiziente Alternative zum CCD stellt das *Box-Behnken-Design* dar [37]. Dieses Design kombiniert 2^k -Faktorielle mit unvollständigen Blockplänen und platziert Versuchspunkte auf den Kantenmitten des Versuchsraums, vermeidet jedoch die extremen faktoriellen Versuchspunkte. Dies kann vorteilhaft für Lebensdauertests sein, bei denen extreme Ecken oft zu verfrühten Ausfällen führen können. Zudem ist es bei korrekter Wahl der ZPs alias-optimal gegenüber kubischen Modellen [38]. Stoßen Standard-Designs (CCD, Box-Behnken) aufgrund von Restriktionen im Versuchsraum, nicht-standardmäßigen Modellierungszielen oder ungewöhnlichen Stichprobenumfängen an ihre Grenzen, empfiehlt sich der Einsatz von *Optimalen Versuchsplänen*, vergleiche Abschnitt 2.2.5. Diese computergenerierten Designs minimieren beispielsweise algorithmisch die durchschnittliche Vorhersagevarianz über den gesamten Designraum und können Standard-Designs in ihrer Prädiktionsgüte oft übertreffen [22, 39]. Gleichzeitig ist zu dieser Stelle festzuhalten, dass mit den Eigenschaften der Rotierbarkeit und der Orthogonalität zwei fundamentale Qualitätsmerkmale für CCDs existieren, die einen varianz-optimierten Versuchsplan charakterisieren.

2.2.4 Strategische Vorgehensweisen

In der versuchstechnischen Praxis entsteht ein CCD vorzugsweise im Rahmen einer *sequenziellen Versuchsstrategie*. Zeigt das initiale lineare Modell signifikante Anpassungsmängel (*Lack-of-Fit*), wird der bestehende faktorielle Basisplan um die SPs augmentiert, um ein Regressionsmodell zweiter Ordnung abzubilden [36]. In der Zuverlässigkeitstechnik ist diese Erweiterung essenziell: Primäres Ziel ist hierbei nicht die Suche nach lokalen Extrema, sondern die korrekte stochastische Erfassung nicht-linearer Schädigungsmechanismen unter multivariaten Belastungen [3, 40]. Prinzipielle Vorgehensweisen wie *Blockbildung* oder *Randomisierung* (vgl. [31, 32]), die ein erfolgreiches Umsetzen von DoE bzw. L-DoE begünstigen sollten, seien hier bereits

vorausgesetzt. Abbildung 2.3 fasst eine derartige strategische Vorgehensweise zur Realisierung eines CCD zusammen, wie sie beispielsweise Box und Wilson [41], Box et al. [42] und Bisgaard [43] vorschlagen.




Abbildung 2.3: Strategischer Ansatz zur augmentierten Versuchsplanung für die Lebensdauererprobung nach [42, 43], beispielhaft im zweidimensionalen Fall ($k = 2$) dargestellt.

Da die zwingend erforderliche Anzahl an Versuchspunkten N direkt mit der Anzahl der zu schätzenden Parameter p [44] korrespondiert, kann die schrittweise Augmentierung das ökonomische Risiko der Lebensdauererprobung minimieren. Während lineare Effekte durch zwei Stützstellen auflösbar sind, erfordert die Modellierung quadratischer Terme im Gleichungssystem zwingend mindestens drei Faktorstufen. Anstatt ein ressourcenintensives CCD a priori vollständig aufzulegen, erlaubt eine theoretische Sequenzierung eine datengetriebene Entscheidungsfindung: Zunächst sequenziert ein faktorieller Plan (bei $k \geq 3$ ggf. teil-faktoriell) die signifikanten von den trivialen Faktoren. Anschließend detektieren ergänzte ZPs das Vorliegen globaler Krümmungen. Lediglich bei nachgewiesener Nichtlinearität oder bei einer geplanten, fernen Extrapolation in den Feldbereich erfolgt die finale Erweiterung durch SPs [45, 46]. Während eine Randomisierung jenseits dieser Sequenzierung durchgeführt werden kann, wird auf diese Weise die experimentelle Aufwand-Nutzen-Bilanz maximiert, da kostenintensive Prüfläufe ausschließlich zur fundierten Absicherung der Extrapolationsgüte allokiert werden [22, 36, 47].

[Daz 12] $2^{(k-p)}$ -Plan

2.2.5 Bewertung und Optimierung von Versuchsplanung

Wird maximale Flexibilität jenseits starrer Standard-Designs wie dem voll-faktoriellen Setup oder dem CCD verlangt, können *optimale Versuchspläne* einen leistungsfähigen, *effizienten* Lösungsansatz für *multivariate* Versuchsplanung bieten [22, 36, 48]. Diese verfolgen das Ziel, die Versuchspunkte algorithmisch so im Versuchsraum zu positionieren, dass spezifische Qualitätskriterien - allen voran die Verteilung der (um die Versuchsanzahl N skalierten) *Prädiktionsvarianz*, engl. *Scaled Prediction Variance* (SPV),

$$v(\mathbf{x}_0) = \frac{N \text{Var}[\hat{y}(\mathbf{x}_0)]}{\sigma^2} = \mathbf{x}_0' \left(\frac{\mathbf{M}}{N} \right)^{-1} \mathbf{x}_0 = N \mathbf{x}_0' \mathbf{M}^{-1} \mathbf{x}_0 \quad (2.21)$$

optimiert werden [22, 36]. Die Prädiktionsvarianz ist ein dimensionsloses Maß, das ausschließlich über die geometrische Anordnung der N Versuchspunkte (der Matrix $\mathbf{X}$) in der *Informationsmatrix* (auch *Momentenmatrix*)

$$\mathbf{M} \stackrel{m=1}{=} \mathbf{X}'\mathbf{X} \quad (2.22)$$

definiert und damit positionsabhängig von einer Referenz $\mathbf{x}_0' = [1, x_{01}, \dots, x_{0k}]$ im Parameterraum ist [36]. Sie ist damit unabhängig von der tatsächlichen Streuung der Messdaten (σ^2). Weiter wird sie über die Anzahl der Versuchspunkte N skaliert, um zwischen Versuchsplänen mit unterschiedlicher Stichprobengröße hinsichtlich des Gestaltungsbudgets und der geometrischen Effizienz zu vergleichen [36, 39]. Im Sinne der absoluten Schätzpräzision und direkt über die Breite der resultierenden Konfidenzintervalle kann sie im ingenieurwissenschaftlichen Blickwinkel aber auch unskaliert betrachtet werden: als *Unscaled Prediction Variance* (UPV)

$$v(\mathbf{x}_0)/N = \text{Var}[\hat{y}(\mathbf{x}_0)]/\sigma^2 = \mathbf{x}_0' \mathbf{M}^{-1} \mathbf{x}_0, \quad (2.23)$$

vgl. Montgomery [22] und Myers et al. [49]. Die strikte methodische Differenzierung dieser beiden Metriken ist für die Auslegung von Lebensdauertests essenziell: Während die UPV die *absolute, physikalische Schätzpräzision* repräsentiert - welche sich nach informationstheoretischen Grundsätzen mit jedem zusätzlichen Versuchspunkt zwingend verbessert oder zumindest stagniert -, fungiert die SPV als reines Maß der *geometrischen Design-Effizienz*. Sie bewertet den Informationsgewinn pro investiertem Versuchsaufwand N . Ein geometrisch ineffizient platzierter Versuchspunkt (etwa ein

redundanter Zentralpunkt für eine ferne Extrapolation) kann zwar die absolute UPV marginal senken, jedoch die SPV verschlechtern, da die Aufwandserhöhung (Steigerung von N) den minimalen Informationsgewinn überkompensiert. Somit dient die SPV dem topologischen Strukturvergleich und der Budget-Allokation, während die UPV die Basis zur Berechnung realer Konfidenzintervalle für die tatsächliche Lebensdauerprognose im Feld bildet. Zusammen mit der Varianz des Versuchsfehlers σ^2 (vgl. Gleichung 2.26) erlaubt die Prädiktionsvarianz somit eine direkte Quantifizierung der *Unsicherheit in der Modellvorhersage* $\text{Var}[\hat{y}(\mathbf{x}_0)]$ an einer beliebigen Stelle $\mathbf{x}_0$ im Versuchsraum. Um sie über verschiedene Stellen im Parameterraum zu bewerten, konnten allen voran Zahran et al. [50] und Giovannitti-Jensen und Myers [51] mit dem *Mell* *Variance Dispersion Graph* (VDG) oder *Fraction of Design Space* (FDS)-Plot Visualisierungsstrategien entwickeln. Diverse Anwendungen folgten daraufhin und festigten durch Arbeiten von Goldfarb et al. [52] und Ozol-Godfrey et al. [53] deren Relevanz bei der Untersuchung von Designtypen durch beispielsweise Borkowski et al. [54], Myers et al. [55] und Schoonees et al. [56] für verschiedenste Designmodifikationen oder -Störungen. Der FDS stellt dabei die kumulative Verteilung der Prädiktionsvarianz über den jeweiligen Anteil des Design-Space' entsprechend Abbildung 2.4a dar, während der VDG (neben den Extremwerten) die durchschnittliche, sphärische Prädiktionsvarianz als Funktion des Abstands r zum Zentrum des Versuchsraums visualisiert - vgl. Abbildung 2.4b. Eine effiziente Versuchsplanung für multivariate




Abbildung 2.4: FDS und VDG für einen CCD mit $k = 2$ Faktoren.

Lebensdaueruntersuchungen muss sich neben pragmatischen Beweggründen maß-

geblich an der Prädiktionsvarianz orientieren, weshalb im Folgenden eine Übersicht der darauf basierenden, gängigen Metriken und Qualitätsmerkmale gegeben wird.

Orthogonalität, Ausgewogenheit und Multikollinearität

Der Einsatz optimaler Versuchspläne ist zunächst prädestiniert für Szenarien, in denen klassische Pläne an ihre Grenzen stoßen - sei es durch physikalische Randbedingungen, welche bestimmte Faktorstufenkombinationen ausschließen, oder durch strikte Limitierungen der verfügbaren Versuchskapazität [32, 39]. Derart klassische Versuchspläne wie der voll-faktorielle Versuchsplan sind aufgrund ihrer Versuchspunktanordnung stets *orthogonal* [3, 22]. Ein Versuchsplan wird als orthogonal bezeichnet, wenn keine Korrelation zwischen jeweils zwei Spalten der Versuchsplan-Matrix vorliegt - deren Skalarprodukte also jeweils null ergeben:

$$\langle x_i, x_j \rangle = 0 \quad \text{für alle } i \neq j. \quad (2.24)$$

Oder in anderen Worten: entspricht die Informationsmatrix $\mathbf{M}$ einer reinen Diagonalmatrix, ist der Versuchsplan orthogonal [3, 33]. So können Effekte eindeutig identifiziert werden - die Vektoren der Faktorstufenkombinationen sind linear unabhängig und Effekte lassen sich unverzerrt schätzen. Dies stellt einen Versuchsplan also zunächst einmal qualitativ günstig dar.

Um den Grad der Abweichung von diesem Idealzustand - etwa bei asymmetrisch ausgedünnten Designs oder durch praxisbedingte Modifikationen der Versuchsraumgeometrie - quantitativ bewerten zu können, hat sich in der Literatur der A_2 -Indikator als globales Maß für Nicht-Orthogonalität etabliert [57, 58]. Er berechnet sich als Summe der quadrierten Elemente abseits der Hauptdiagonalen der normierten Informationsmatrix $\mathbf{M}$:

$$A_2 = \sum_{i=1}^p \sum_{\substack{j=1 \\ j \neq i}}^p r_{ij}^2 \quad \text{mit} \quad r_{ij} = \frac{\mathbf{M}_{ij}}{\sqrt{\mathbf{M}_{ii}\mathbf{M}_{jj}}}, \quad (2.25)$$

wobei r_{ij} den paarweisen Korrelationskoeffizienten zwischen der i -ten und j -ten Spalte der Versuchsplan-Matrix repräsentiert. Folglich gilt für einen streng orthogonalen Plan $A_2 = 0$. Jeder Anstieg dieses Wertes signalisiert zunehmende Multikollinearität im Design, was das Risiko von Fehlschlüssen bei der Identifikation kausaler Haupteffekte und Interaktionen erhöht [28].

Zudem liegt *Ausgewogenheit* vor, sofern für einen jeweiligen Faktor alle anderen Faktoreinstellungen gleichmäßig aufgeteilt sind [31]. Damit wird Varianzhomogenität und Gleichbehandlung der Faktoren gewährleistet, sodass die Schätzung der Effekte unverzerrt erfolgt.

Mathematisch fundiert die Bewertung der Schätzgenauigkeit auf der Inversen der Informationsmatrix, welche als *Varianz-Kovarianz-Matrix* (oder *Dispersionsmatrix*) $(\mathbf{X}'\mathbf{X})^{-1}$ der Regressionskoeffizienten definiert ist:

$$\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}, \quad (2.26)$$

wobei wie gehabt σ^2 die Varianz des Versuchsfehlers darstellt.

Ein universelles Maß zur Beurteilung der Schätzgüte einzelner Parameter ist der *Mean Squared Error (MSE)*. Er vereint die Varianz des Schätzers und dessen systematische Verzerrung (*Bias*) generell über alle Beobachtungen durch $1/n \sum_i^n (y_i - \hat{y}_i)^2$ in einer Metrik und beschreibt für einen geschätzten Parameter $\hat{\beta}_j$ die erwartete quadratische Abweichung von dessen wahren Wert β_j :

$$\text{MSE}(\hat{\beta}_j) = E[(\hat{\beta}_j - \beta_j)^2] = \text{Var}(\hat{\beta}_j) + (\text{Bias}(\hat{\beta}_j))^2. \quad (2.27)$$

Da klassische Schätzverfahren (wie *OLS* oder *MLE*) unter regulären Bedingungen (hinreichend große Stichprobenumfänge, adäquate Modellannahmen) erwartungstreu sind ($\text{Bias} = 0$), entspricht der *MSE* in diesen Fällen exakt der Schätzvarianz $\text{Var}(\hat{\beta}_j)$ und skaliert folglich direkt mit den Diagonalelementen der inversen Informationsmatrix [9].

Während der A_2 -Indikator die Gesamtmatrix bewertet, stehen genau diese Diagonalelemente in direktem Zusammenhang mit dem *Varianz-Inflations-Faktor (VIF)* für die Evaluation einzelner Modellterme [31, 32]. Der *VIF* dient als Maßzahl für Multikollinearität und quantifiziert den Faktor, um den sich die Varianz (und damit der *MSE*) eines geschätzten Koeffizienten im Vergleich zu einem vollständig orthogonalen Design aufgrund von Korrelationen zwischen den Faktoren erhöht (vergleiche auch *Konditionszahl*) [9]. Während bei orthogonalen Plänen (Idealfall) ein $\text{VIF} = 1$ vorliegt, deuten hohe Werte (typischerweise > 5 oder > 10) auf eine instabile Modellschätzung hin [32, 33].

[Daz 13] Quellen: [33], Kap. 9.4.2 + [32], Kapitel 16.4

Zur lokalen Diagnose von Versuchspunkten und deren Auswirkung auf die Regressionsparameter existieren in der Fachliteratur etablierte Maßzahlen wie die Hebelwerte h_{ii} der Prädiktionsmatrix (*Hat-Matrix*) $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, die Cook-Distanz (D_i) sowie detaillierte Einflussstatistiken wie **DFBETAS**, **DFFITS** und **COVRATIO** - vergleiche Werke von Siebertz et al. [31], Montgomery et al. [33], Belsley [59] und Fahrmeir et al. [60]. Da es sich hierbei jedoch um rein retrospektive Diagnostikwerkzeuge handelt, die bereits vorliegende Versuchsergebnisse zwingend voraussetzen, finden sie im Rahmen der a priori Testplanung dieser Arbeit keine weitere Anwendung.

Optimalitätskriterien

Da in restriktiven Versuchsräumen Orthogonalität oft nicht erreichbar ist, zielen optimale Versuchspläne darauf ab, durch Minimierung spezifischer Eigenschaften der Dispersionsmatrix den Informationsgehalt der Versuchsmatrix algorithmisch zu maximieren. In klassischen, normalverteilten **OLS**-Modellen stützt sich diese Optimierung ausschließlich auf die geometrischen Eigenschaften der Matrix $(\mathbf{X}'\mathbf{X})^{-1}$. Für die Auslegung multivariater Lebensdauertests (**GLMs**) muss diese klassische Momentenmatrix jedoch zwingend durch die parameterabhängige Fisher-Informationsmatrix substituiert werden. Mittels *Iteratively Weighted Least Squares* (**IWLS**) lässt sich diese Informationsmatrix **M** als gewichtetes Skalarprodukt ausdrücken [61]:

$$\mathbf{M} = \mathbf{X}'\mathbf{W}\mathbf{X}. \quad (2.28)$$

Die $n \times n$ Diagonalmatrix **W** enthält die Varianzen der Beobachtungen, welche wiederum direkte Funktionen der a priori unbekannten Modellparameter $\boldsymbol{\theta}$ sind. Diese strukturelle Kopplung zwingt die Versuchsplanung bei Lebensdauerdaten zur Lösung eines streng lokalen Optimalitätsproblems, wofür zwingend theoretische Vorabannahmen (*Planning Values*) für $\boldsymbol{\theta}$ getroffen werden müssen [62, 63]. Damit ist eine a-priori Grundkenntnis der zu erwartenden Lebensdauerverteilung und deren Parameter unabdingbar, um die geometrische Güte des Versuchsplans erfolgreich zu maximieren. Verfahren zur Bayesschen Optimierung der *Planning Values* erlauben die Reduktion etwaiger Unsicherheiten und werden von Monroe et al. [61] detailliert beschrieben.

Unter steter Berücksichtigung dieses fundamentalen stochastischen Vorbehalts fasst Tabelle 2.4 die etablierten Optimalitätskriterien zusammen, welche primär die geome-

trische Güte quantifizieren und den Vergleich zur Standard-Methodik ermöglichen [22, 39]. Sie bilden mitunter die Grundlage für diverse weitere Optimalitäten und hybride Ansätze und lassen sich prinzipiell in Modellierungskriterien (*A*-, *D*- Optimalität) und Prädiktionskriterien (*G*-, *I*-, *U*-, *V* - Optimalität) unterteilen [3, 36]. Während konventionelle Ansätze stets die Optimierung eines einzelnen Kriteriums anstreben, können in der Praxis auch mehrere Kriterien gleichzeitig berücksichtigt werden, um eine ausgewogene Optimierung zu erreichen [39, 64].

Tabelle 2.4: Übersicht, Zielsetzung und mathematische Definition verschiedener Optimalitätskriterien für Versuchspläne

Kriterium	Zielgröße, Beschreibung und Definition
A-Optimalität	Minimierung der Spur der inversen Informationsmatrix [3, 22, 32]. <i>Ziel: Maximale Präzision der einzelnen Parameter im Durchschnitt.</i> $A_{\text{opt}} = \min \left(\text{spur} \left(\mathbf{M}^{-1} \right) \right) = \min \left(\sum_{j=1}^k \text{Var} \left(\hat{\beta}_j \right) \right) \quad (2.29)$
D-Optimalität	Maximierung der Determinante der Informationsmatrix $\mathbf{M}$. Da das Volumen des Vertrauensellipsoids der Koeffizientenschätzwerte umgekehrt proportional zur Quadratwurzel der Determinante ($\sqrt{\det(\mathbf{M})}$) ist, minimiert dieses Kriterium das Unsicherheitsvolumen im Parameterraum [22, 32, 36, 65]. <i>Ziel: Minimierung des Volumens des gemeinsamen Vertrauensbereichs aller Modellparameter.</i> $D_{\text{opt}} = \max \left(\det(\mathbf{M}) \right) = \min \left(\det \left(\mathbf{M}^{-1} \right) \right) \quad (2.30)$

Fortsetzung auf der nächsten Seite...

Tabelle 2.4 (Fortsetzung): Übersicht der Optimalitätskriterien

Kriterium	Zielgröße, Beschreibung und Definition
G-Optimalität	Minimierung der maximalen skalierten Prädiktionsvarianz $v(\mathbf{x}_0)$ im relevanten Parameterraum [22, 36, 44]. <i>Ziel: Qualität der Vorhersage an der ungünstigsten Stelle sichern.</i> $G_{\text{opt}} = \min \left(\max_{\mathbf{x}_0 \in \mathbb{R}^k} v(\mathbf{x}_0) \right) \quad (2.31)$
I-Optimalität	Minimierung der durchschnittlichen (integrierten) Prädiktionsvarianz über den Parameterraum [3, 65]. <i>Ziel: Optimale Vorhersagegüte (SPV) im Mittel über den gesamten Raum - z.B. bei initialer Parametrisierung eines multivariaten Lebensdauermodells.</i> $I_{\text{opt}} = \min \left(\frac{N}{\int_{\mathbb{R}^k} d\mathbf{x}} \int_{\mathbb{R}^k} v(\mathbf{x}_0) d\mathbf{x} \right) \quad (2.32)$
U-Optimalität	Minimierung der Prädiktionsvarianz an einem spezifischen Betriebspunkt, der Standard-Nutzungsbedingung (Use-Condition). $\mathbf{W}$ bezeichnet die parameterabhängige Gewichtsmatrix des GLM (vgl. Abschnitt 2.2.6), deren Aufstellung initiale Vorab-Annahmen der Modellparameter voraussetzt. [3, 61, 62, 63]. <i>Ziel: Maximale Vorhersagegenauigkeit für extrapolierte Lebensdauern unter realen Feldbedingungen.</i> $U_{\text{opt}} = \min \left(\mathbf{x}_0' \cdot (\mathbf{X}'\mathbf{W}\mathbf{X})^{-1} \cdot \mathbf{x}_0 \right) \quad (2.33)$

Fortsetzung auf der nächsten Seite...

Tabelle 2.4 (Fortsetzung): Übersicht der Optimalitätskriterien

Kriterium	Zielgröße, Beschreibung und Definition
V-Optimalität	Minimierung der durchschnittlichen Prädiktionsvarianz über ein diskretes Set von N Punkten [22, 39, 49]. Ziel: Optimale Vorhersagegüte (SPV) an spezifischen i Stellen - z.B. bei L-DoE-Versuchspunkten oder spezifischen Nennlasten. $V_{\text{opt}} = \min \left(\frac{1}{N} \sum_{i=1}^N v(x_i) \right) \quad (2.34)$

Zur vergleichbaren Bewertung unterschiedlicher Designs unabhängig von der Skalierung werden normierte Effizienzen herangezogen [22]. Aus Tabelle 2.4 lassen sich die A-Effizienz A_{eff} , D-Effizienz D_{eff} , G-Effizienz G_{eff} , I-Effizienz I_{eff} und V-Effizienz V_{eff} ableiten, welche jeweils die Güte $[0, 1]$ eines Versuchsplans quantifizieren - vergleiche Tabelle 2.5.

Tabelle 2.5: Übersicht, Zielsetzung und mathematische Definition verschiedener Effizienzkriterien für Versuchspläne

Kriterium	Zielgröße, Beschreibung und Definition
A-Effizienz	Maß für die durchschnittliche Präzision der Regressionskoeffizienten. [36, 39]. $A_{\text{eff}} = 100 \cdot \frac{p}{\text{spur}(N \cdot \mathbf{M}^{-1})} \quad (2.35)$

Fortsetzung auf der nächsten Seite...

Tabelle 2.5 (Fortsetzung): Übersicht der Effizienzkriterien

Kriterium	Zielgröße, Beschreibung und Definition
D-Effizienz	Maß für den Informationsgehalt der Informationsmatrix $\mathbf{M}$, definiert über die Determinante, umgekehrt proportional zum Volumen des Vertrauensellipsoids der Parameterschätzwerte und durch die Potenzierung mit $1/p$ pro Schätzparameter normiert. [36, 39]. $D_{\text{eff}} = 100 \cdot \frac{\det(\mathbf{M})^{1/p}}{N} \quad (2.36)$
G-Effizienz	Maß für die Vorhersagegüte im ungünstigsten Fall innerhalb des Versuchsraums. Da für die maximale SPV die theoretische Untergrenze $v(\mathbf{x}_0)_{\max} \geq p$ gilt, beschreibt dieses Kriterium das Verhältnis zwischen idealer und realisierter maximaler Varianz [36]. $G_{\text{eff}} = 100 \cdot \frac{p}{v(\mathbf{x}_0)_{\max}} \quad (2.37)$
I-Effizienz	Maß für die durchschnittliche Vorhersagegüte über den gesamten Versuchsraum [36]. $I_{\text{eff}} = 100 \cdot \frac{p}{\frac{1}{\int_R dx} \int_R v(\mathbf{x}_0) dx} \quad (2.38)$
V-Effizienz	Maß für die durchschnittliche Vorhersagegüte über ein diskretes Set von N Punkten analog zu Gleichung 2.38 [36]. $V_{\text{eff}} = 100 \cdot \frac{1}{N} \sum_{i=1}^N \frac{p}{v(\mathbf{x}_0)(x_i)} \quad (2.39)$

Forschungsschwerpunkte in der RSM

Während die klassische sequentielle Strategie (Screening gefolgt von Augmentierung zum CCD oder Anpassung von Parameterräumen mit optimalen Versuchsplänen) die methodischen Risiken minimiert, erfordert sie oft einen hohen administrativen und zeitlichen Aufwand durch mehrere Versuchsphasen - insbesondere bei technischen Versuchsanlagen mit hohem Rüst-Aufwand. Als Antwort darauf entwickelten Jones und Nachtsheim [38] zunächst die Klasse der *Definitive Screening Designs* (DSDs), um auch bei größeren Faktorenzahlen (typisch $k \geq 4$) Haupteffekte von **Effekten zweiter Ordnung (Zweifach-Wechselwirkungen und quadratische Terme) nicht-linearen Effekten**^{Daz} in einem Schritt zu separieren. Da DSDs jedoch eine starre Struktur aufweisen und oft nur eine geringe statistische Power zur Schätzung quadratischer Effekte bieten, etablierte sich in jüngster Forschung die umfassendere Klasse der *Orthogonal Minimally Aliased Response Surface* (OMARS)-Designs, zu der Goos [66] zuletzt eine detaillierte Übersichtsarbeit vorlegte. Núñez Ares und Goos [67] erarbeiteten hierfür einen Katalog verschiedener OMARS-Designs, die im Gegensatz zu klassischen Plänen eine flexible Wahl der Versuchsanzahl n ermöglichen. Diese Designs zielen spezifisch auf den fließenden Übergang von Screening zu RSD in einem einzigen experimentellen Schritt ab (*One-Step Approach*). Dazu basieren sie auf der Variation aller quantitativen Faktoren auf drei Stufen ($-1, 0, +1$), um quadratische Zusammenhänge prinzipiell abzubilden. Die statistische Konstruktion garantiert dabei zwei fundamentale Orthogonalitätseigenschaften, die sie von klassischen Optimal-Designs abgrenzen: Erstens sind alle Haupteffekte orthogonal zueinander, was eine unabhängige Schätzung der linearen Einflüsse sichert. Zweitens sind die Haupteffekte vollständig unkorreliert mit sämtlichen Effekten zweiter Ordnung (sowohl Zweifach-Wechselwirkungen als auch quadratische Terme). Das verbleibende Aliasing (Ver-mengung) beschränkt sich somit ausschließlich auf die Gruppe der Effekte zweiter Ordnung untereinander und wird algorithmisch minimiert (engl. *Minimally Aliased*). Dies erlaubt eine signifikante Flexibilisierung der Stichprobengröße im Vergleich zu starr definierten Plänen wie dem CCD, bei gleichzeitigem Erhalt der robusten Schätzbarkeit der primären Haupteffekte. Die Generierung eines solchen OMARS-Designs erfolgt dabei nicht über geometrische Konstruktionsvorschriften (wie beim CCD), sondern algorithmisch durch die Lösung eines ganzzahligen linearen Optimierungsproblems (engl. *Integer Linear Programming* (ILP)). Basierend auf der Kandidatenmen-

ge Ω (üblicherweise entsprechend einem voll-faktoriellen 3^{k_f} Plan) wird ein Vektor binärer Entscheidungsvariablen $\gamma \in \{0, 1\}^{|\Omega|}$ gesucht, der folgende mathematische Restriktionen simultan erfüllt:

- **Einhaltung des Stichprobenumfangs:**

Die Summe der ausgewählten Versuchspunkte muss exakt der gewünschten Anzahl n entsprechen:

$$\sum_{i=1}^{|\Omega|} \gamma_i = n. \quad (2.40)$$

- **Orthogonalität der Haupteffekte:**

Jedes Paar von Haupteffekt-Spalten j und l muss unkorreliert sein. Für die kodierten Faktorstufen $x_{ij} \in \{-1, 0, +1\}$ des i -ten Kandidaten gilt:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot x_{il} = 0 \quad \forall 1 \leq j < l \leq k_f. \quad (2.41)$$

- **Orthogonalität Haupteffekt zu Effekten zweiter Ordnung:**

Dies ist das definierende Merkmal. Jeder Haupteffekt j muss orthogonal zu jedem Effekt zweiter Ordnung (Interaktion $x_l x_k$ oder quadratischer Term x_l^2) sein:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot (x_{il} \cdot x_{ik}) = 0 \quad \forall j, l, k \in \{1, \dots, k_f\}. \quad (2.42)$$

Unter Einhaltung dieser harten Nebenbedingungen wird anschließend jene Design-Variante ausgewählt, welche die Aliasing-Struktur der Effekte zweiter Ordnung untereinander minimiert (z. B. durch Maximierung von D_{opt} , vgl. Gleichung 2.30).

Signifikanz und Trennschärfe

Weiter muss sichergestellt werden, dass der Versuchsplan über eine ausreichende *Trennschärfe* (*power*) verfügt. Die Trennschärfe beschreibt als Metrik diejenige Wahrscheinlichkeit, mit der ein existierender Einfluss durch Faktoren vor dem Hintergrund des experimentellen Rauschens (vergleiche *t*-Statistik, SNR, Signifikanztests nach [22, 32, 39]) korrekt als *signifikanter* Effekt E identifiziert wird [31, 32]. Insofern ist ein Effekt in praktischem Umfeld natürlich problemabhängig (Streuungscharakteristik

der Lebensdauer, realisierbare Stichprobengröße, etc.) und meist von Bedeutung für $E \geq 2\sigma$, wobei Trennschärfewerte $\geq 80\%$ als befriedigend gelten [3, 22]. Insbesondere bei reduzierten Versuchsplänen und unter dem Einfluss stochastischer Lebensdauerstreuung ist die *power*-Analyse jedoch essenziell, um das Risiko von falsch-negativen Schlussfolgerungen zu minimieren. Letztendlich kann die Trennschärfe somit als Garantimetrik verstanden werden, die sicherstellt, dass ein geplanter Versuchsaufbau in der Lage ist, Effekte von praktischer Relevanz zu detektieren [36, 68] – was vornehmlich in Bezug auf Lebensdauertests aufgrund genannter wirtschaftlicher Randbedingungen von hoher Bedeutung ist.

Formalisiert wird dies im Rahmen *statistischer Hypothesentests* [22, 32]. Die Zielsetzung besteht darin, den Nachweis zu erbringen, ob ein bestimmter Faktor x_j einen signifikanten Einfluss auf die Systemantwort y ausübt. Dazu werden zwei konkurrierende Hypothesen formuliert: Die *Nullhypothese* H_0 unterstellt, dass kein Zusammenhang besteht, der korrespondierende Regressionskoeffizient β_j (vgl. Abschnitt 2.2.6) also den Wert Null annimmt:

$$H_0 : \beta_j = 0 \quad \text{gegen} \quad H_1 : \beta_j \neq 0. \quad (2.43)$$

Die *Alternativhypothese* H_1 postuliert hingegen einen signifikanten Effekt ($\beta_j \neq 0$). Die Entscheidung über die Annahme oder Ablehnung von H_0 basiert auf dem *p-Wert*. Dieser quantifiziert die Wahrscheinlichkeit, unter der Annahme der Gültigkeit von H_0 die beobachteten Daten (oder extremere Ergebnisse) zu erhalten. Unterschreitet der *p-Wert* das a priori definierte *Signifikanzniveau* α (üblicherweise $\alpha = 0,05$), wird H_0 zugunsten der Alternativhypothese H_1 verworfen. Der Fehler, H_0 fälschlicherweise abzulehnen, obwohl kein Effekt vorliegt, wird als Fehler 1. Art bezeichnet; seine Wahrscheinlichkeit ist durch α begrenzt. Die *Trennschärfe* fokussiert hingegen auf den Fehler 2. Art (oft mit β_{error} notiert), welcher das Risiko beschreibt, einen tatsächlich vorhandenen Effekt nicht zu erkennen (falsch-negative Entscheidung). Die *power* ist folglich definiert als das Komplement dieses Fehlers ($1 - \beta_{\text{error}}$) und entspricht der Wahrscheinlichkeit, H_0 korrekterweise abzulehnen, wenn H_1 wahr ist:

$$\text{power} = \Pr(H_0 \text{ ablehnen} \mid H_1 \text{ ist wahr}) = 1 - \beta_{\text{error}}. \quad (2.44)$$

In idealisierten, orthogonalen Standard-Versuchsplänen unter der Annahme normalverteilter Residuen $\epsilon \sim \mathcal{N}(0, \sigma^2)$ lässt sich die Trennschärfe für klassische OLS-Regressionsmodelle exakt analytisch bestimmen. Die *power* berechnet sich hierbei aus der Wahrscheinlichkeit, dass die Teststatistik unter der Alternativhypothese H_1 den kritischen Wert einer nicht-zentralen Prüfverteilung überschreitet. Der Grad dieser Verschiebung wird durch den sogenannten *Nichtzentralitätsparameter* δ_{nc} quantifiziert [22, 69]. Für die Überprüfung eines individuellen Modellparameters β_j ist dieser definiert als:

$$\delta_{nc} = \frac{|\beta_j|}{\sigma \sqrt{(\mathbf{X}'\mathbf{X})_{jj}^{-1}}}, \quad (2.45)$$

wobei $|\beta_j|$ die zu detektierende wahre Effektstärke und σ die Standardabweichung des experimentellen Rauschens darstellt [36, 68]. Anhand dieser analytischen OLS-Metrik wird der fundamentale geometrische Hebel der Versuchsplanung deutlich: Sobald die Orthogonalität verloren geht, entstehen signifikante Kovarianzen in der Informationsmatrix $\mathbf{M} = \mathbf{X}'\mathbf{X}$. Die Matrixinvertierung führt zu einer Inflation des Diagonalelements $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$, was δ_{nc} unmittelbar reduziert und somit die Trennschärfe mindert.

Für die multivariate Lebensdauererprobung verliert diese analytische Berechnung jedoch ihre methodische Anwendbarkeit. Aufgrund der asymmetrischen Verteilungsannahmen (Weibull) und dem Vorliegen zensierter Daten existieren im GLM-Framework keine geschlossenen analytischen Lösungen zur exakten Bestimmung der Trennschärfe. Die Signifikanz der Koeffizienten β_j muss hier vorzugsweise über numerische *Likelihood-Ratio Tests (LR-Tests)* oder approximativ über *Wald-Tests* ermittelt werden [2, 3, 70]. Die Quantifizierung der Trennschärfe erfordert in der modernen Zuverlässigkeitsplanung folglich zwingend *Monte-Carlo-Simulationen (MCSs)* [4, 71, 72]. Hierbei wird der geplante Versuchsplan unter Vorgabe eines definierten Effektmodells virtuell iteriert (n_{MC} Simulationsläufe), mit stochastischer Streuung überlagert und zensiert, um den relativen Anteil korrekter Signifikanz-Entscheidungen ($p\text{-Wert} < \alpha$) als empirischen Schätzer der Test-Power zu extrahieren.

2.2.6 Statistische Modellbildung

Die statistische Modellbildung quantifiziert den funktionalen Zusammenhang zwischen den systematisch variierten Einflussfaktoren x_i und der beobachteten System-

lebensdauer. Aufgrund der in Abschnitt 2.1 dargelegten Eigenschaften empirischer Lebensdauerdaten mit inhärenter Nicht-Normalverteilung und rechts-zensierten Beobachtungen verletzt die klassische Methode entsprechend OLS fundamentale stochastische Regressionsprämissen und generiert systematisch verzerrte Schätzer. Zur methodisch belastbaren Modellierung kommt stattdessen das Framework der GLMs zur Anwendung, welches den linearen Prädiktor formal mit der zugrundeliegenden Verteilung verknüpft [2, 3, 6]. Hinsichtlich der Modellauswahl kann in klassischen Ansätzen der Versuchsplanung dabei oft auf Potenztransformationen der Antwortvariablen in Form $y^{(\lambda_{BC})}$ oder $\ln(y)$ (für $\lambda_{BC} = 0$ mit geometrischem Mittelwert der Beobachtung $\bar{y} = \exp[\frac{1}{n} \sum_{i=1}^n \ln(y_i)]$) zurückgegriffen werden - wie die *Box-Cox-Transformation* nach Montgomery et al. [33] und Box und Cox [73]. So wird die Varianzhomogenität und Normalverteilung approximiert zu [33] Daz:

$$y_i^{(\lambda_{BC})} = \begin{cases} \frac{y_i^{\lambda_{BC}} - 1}{\lambda_{BC} \bar{y}^{\lambda_{BC} - 1}}, & \text{für } \lambda_{BC} \neq 0, \\ \bar{y} \ln(y_i), & \text{für } \lambda_{BC} = 0. \end{cases} \quad (2.46)$$

Im Kontext der expliziten Lebensdaueranalyse ist dieser generische Ansatz jedoch weniger gebräuchlich, da die physikalisch motivierte Verteilungsannahme (z.B. Weibull) bereits eine inhärente Transformation der Ausfallzeit impliziert - vgl. Abschnitt 2.1.3, Gleichung 2.8 sowie Yang [6] und Wu und Hamada [28]. Unter der Annahme Weibullverteilter Ausfallzeiten (Abschnitt 2.1.3) führen $j = 0, \dots, k$ betrachtete Parameter aus Gleichung 2.17 und n Beobachtungen entsprechend Gleichung 2.8 zum Erwartungswert der charakteristischen Lebensdauer als *Link-Funktion* der Einflussfaktoren x_i und des unbekannten Koeffizientenvektors $\hat{\beta}$ [6, 28, 74] über *Accelerated Failure Time (AFT)*-Modell:

$$E_{\theta_x}(\ln(T)) = y = \beta_0 + \sum_{j=1}^k \beta_j x_j + \dots + \epsilon. \quad (2.47)$$

In der Lebensdauer-Datenanalyse wird neben den GLM-Ansätzen insbesondere der *Proportional Hazard (PH)*-Modell-Ansatz verwendet. Die Stärke dieser PH-Modelle bildet dabei die Abbildung zeitabhängiger Kovariaten, weshalb sie vornehmlich in der Biostatistik verwendet werden [75, 76]:

$$f(t, \mathbf{X}) = \lambda(t)(t, \mathbf{X}) \cdot R(t, \mathbf{X}) = b \cdot t^{b-1} \cdot e^{[y - t^b e^y]}. \quad (2.48)$$

Weibull-GLM

Im ingenieurwissenschaftlichen Kontext - maßgeblich gestützt durch Ausführungen in Meeker et al. [2], Yang [6], Wu und Hamada [28], Myers et al. [49], Kremer et al. [76], Dobson und Barnett [77] und Stufken und Yang [78] - finden hingegen *Log-Location-Scale-Modelle*, also GLMs, überwiegend Anwendung. Obwohl für die Weibull-Verteilung eine mathematische Äquivalenz zwischen beiden Ansätzen besteht, sprechen drei fundamentale Gründe für deren Verwendung.

- **Physikalischer Bezug:**

Gängige physikalische Beschleunigungsmodelle (Arrhenius, Inverses Potenzgesetz) beschreiben die Änderung der *Zeit* bis zum Ausfall ($\ln(\hat{T})$) und nicht der Ausfallrate. Die Log-Linearisierung dieser Gesetze führt direkt auf die Regressionsgleichung der Location-Scale-Modelle.

- **Universalität der Auswertung:**

Das Modell bietet einen einheitlichen mathematischen Rahmen, der nicht nur für die Weibull-Verteilung, sondern identisch auch für die Lognormal-Verteilung und Normalverteilung gültig ist. Das PH-Modell hingegen ist für Lognormal-Verteilungen mathematisch nicht geschlossen anwendbar.

- **Fokus auf Lebensdauer-Quantile:**

In der Zuverlässigkeitstechnik liegt das Interesse primär auf der Prädiktion von Ausfallzeiten für geringe Ausfallanteile (z.B. t_{10}).

Diese Größen sind direkte Ergebnisse der Location-Scale-Gleichung, während sie im PH-Modell nur indirekt über die Invertierung der Hazard-Funktion zugänglich sind. Folglich wird eine zufallsverteilte Lebensdauer τ für ein Weibull-GLM mit der Dichtefunktion

$$f(t, \mathbf{X}) = b \cdot t^{b-1} e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_j)} \cdot e^{-t^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_j)}}, \quad t > 0. \quad (2.49)$$

beschrieben und analog zu Gleichung 2.15 in die *Generalized Log-Linear (GLL)-Funktion* überführt [6, 44, 79]:

$$\begin{aligned} \Lambda &= \ln(\mathcal{L}(t_i; b, \beta_0, \dots, \beta_k)) \\ &\propto \sum_{i=1}^n \left[\ln(b) - b \left(\beta_0 + \sum_{j=1}^k \beta_j x_{ij} \right) + (b-1) \ln(t_i) - t_i^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})} \right]. \end{aligned} \quad (2.50)$$

Werden außerdem (rechts-) zensierte Daten berücksichtigt, so ergibt sich analog zu Gleichung 2.15 über Gleichung 2.50 die erweiterte GLL-Funktion [2, 6]:

$$\Lambda_z \propto \Lambda - (1 - \delta_i) \cdot t_i^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})}. \quad (2.51)$$

Sollen über die rein empirische Datenauswertung hinaus bekannte physikalische Gesetzmäßigkeiten im Modell berücksichtigt werden, ist die lineare Struktur des Prädiktors entsprechend anzupassen. Dies erfolgt durch eine Transformation der physikalischen Beanspruchungsgrößen x in den Modellraum. Anstelle der direkten Verwendung des Einflussfaktors in der GLL-Beziehung (Gleichung 2.49) wird eine transformierte Größe x_V eingesetzt, welche die physikalische Natur des Schädigungsmechanismus abbildet. Gängige Transformationen umfassen hierbei die reziproke Anpassung für thermische Lasten (*Arrhenius*) oder logarithmische Ansätze für elektrische Potenzmodelle, vgl. Tabelle 2.6. Eine Übersicht verschiedener Modellierungsansätze (z.B.

Tabelle 2.6: Übersicht gängiger Transformationen der Belastungsgrößen zur Abbildung physikalischer Lebensdauermodelle

Art	Transformation	Lebensdauermodell	Anwendungsfall
Keine	$x_V = x$	Exponential / Wöhler	mechanisch
Reziprok	$x_V = 1/x$	Arrhenius	thermisch
Logarithmisch	$x_V = e^x$	Potenzmodell	elektrisch

Arrhenius-Modell, Inverses Potenzgesetz, Eyring, Coffin-Manson-Modell, etc.) und deren Einbindung in die GLM-Struktur findet sich in [2, 3, 75]. Die Schätzung der unbekannten Parameter $\hat{\beta}$ und $\hat{b}$ erfolgt mittels numerischer Maximierung der GLL-Funktion (Gleichung 2.51).

Signifikanzanalyse

Liegen die Parameterschätzungen $\hat{\theta}_i$ vor, erfolgt die Bewertung ihrer statistischen Relevanz mittels **LR-Test**. Dieses Verfahren stellt das methodische Äquivalent zur *Varianzanalyse*, engl. *Analysis of Variance* (ANOVA) bei normalverteilten Daten dar und prüft, ob die Aufnahme eines Parameters die Modellanpassung signifikant verbessert. Der Test basiert auf dem Vergleich der maximalen Likelihood des vollständigen Modells $\mathcal{L}(\hat{\theta}_i)$ gegenüber der eines reduzierten Modells $\mathcal{L}(\hat{\theta}_{-i})$, aus dem der zu untersuchende Parameter eliminiert wurde [4, 80]. Die Teststatistik **LR** quantifiziert den Informationsverlust durch die Modellreduktion und ist definiert als *Devianz-Funktion* [2, 81]:

$$LR = -2 \ln \left(\frac{\mathcal{L}(\hat{\theta}_{-i})}{\mathcal{L}(\hat{\theta}_i)} \right) = 2 \cdot [\ln(\mathcal{L}(\hat{\theta}_i)) - \ln(\mathcal{L}(\hat{\theta}_{-i}))]. \quad (2.52)$$

Unter der Nullhypothese H_0 , dass der ausgeschlossene Parameter keinen Einfluss hat, folgt **LR** asymptotisch einer χ^2 -Verteilung mit d_f Freiheitsgraden (Anzahl der ausgeschlossenen Parameter, hier meist $d_f = 1$). Die Signifikanzentscheidung erfolgt über den **p-Wert**, der die Wahrscheinlichkeit angibt, einen Testwert $\geq LR$ zu beobachten:

$$p\text{-Wert} = \Pr(\chi^2(d_f) \geq LR). \quad (2.53)$$

Ist dieser **p-Wert** kleiner als das definierte Signifikanzniveau $p\text{-Wert} < \alpha$, wird der Parameter als signifikant in das Modell aufgenommen.

Erwartungswerte und Konfidenzintervalle

Nach der Ermittlung der optimalen Modellparameter $\hat{\theta}$ ist die Quantifizierung der mit diesen Schätzungen verbundenen Unsicherheit essenziell. Analytisch erfolgt dies über die Betrachtung der Krümmung der Log-Likelihood-Funktion Λ im Maximum. Je stärker die Krümmung, desto präziser ist die Schätzung (geringere Varianz). Mathematisch erfordert dies die Auswertung der Hesse-Matrix $\mathbf{H}_f$, welche die zweiten partiellen Ableitungen der Log-Likelihood-Funktion nach den Parametern θ_i (also β_j und b) enthält.

Da die theoretische (erwartete) Fisher-Informationsmatrix die Kenntnis der wahren Parameter θ erfordert, wird in der statistischen Praxis stattdessen die *beobachtete* Fisher-Informationsmatrix $\mathbf{F}_{ob}$ (engl. *Observed Fisher Information*) herangezogen [12,

82]. Diese ist definiert als die negative Hesse-Matrix, ausgewertet an der Stelle der MLE-Schätzwerte $\hat{\boldsymbol{\theta}}$ [20, 83]:

$$\mathbf{F}_{\text{ob}} := -\mathbf{H}_{\mathbf{f}}(\hat{\boldsymbol{\theta}}) = \begin{bmatrix} -\frac{\partial^2 \mathcal{L}}{\partial \theta_1^2} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_k} \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2^2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_k} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k^2} \end{bmatrix}. \quad (2.54)$$

Die asymptotische Varianz-Kovarianz-Matrix $\hat{\mathbf{V}}$ der Parameterschätzer wird anschließend durch die Inversion der Fisher-Informationsmatrix für $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}$ approximiert [6, 83]:

$$\hat{\mathbf{V}} \approx \mathbf{F}_{\text{ob}}^{-1} = \begin{bmatrix} \hat{\text{Var}}(\hat{\theta}_1) & \hat{\text{Cov}}(\hat{\theta}_1, \hat{\theta}_2) & \cdots & \hat{\text{Cov}}(\hat{\theta}_1, \hat{\theta}_k) \\ \hat{\text{Cov}}(\hat{\theta}_2, \hat{\theta}_1) & \hat{\text{Var}}(\hat{\theta}_2) & \cdots & \hat{\text{Cov}}(\hat{\theta}_2, \hat{\theta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\text{Cov}}(\hat{\theta}_k, \hat{\theta}_1) & \hat{\text{Cov}}(\hat{\theta}_k, \hat{\theta}_2) & \cdots & \hat{\text{Var}}(\hat{\theta}_k) \end{bmatrix}. \quad (2.55)$$

Die Hauptdiagonalelemente dieser Matrix liefern die geschätzten Varianzen $\hat{\text{Var}}(\hat{\theta}_j)$ der einzelnen Modellparameter. Unter der Annahme der asymptotischen Normalverteilung der MLE beschreibt Yang [6] neben weiteren Alternativen aus Meeker et al. [2] und Kremer und Bertsche [80] die symmetrischen $(1 - \alpha)$ -Konfidenzintervalle (Wald-Intervalle) wie nachfolgend:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\text{Var}}(\hat{\theta}_j)} \quad \text{bzw.} \cdots = \hat{\theta}_j \exp \left(\pm z_{1-\alpha/2} \cdot \frac{\sqrt{\hat{\mathbf{V}}_{jj}}}{\hat{\theta}_j} \right), \quad (2.56)$$

wobei $z_{1-\alpha/2}$ dem $(1 - \alpha/2)$ -Quantil der Standardnormalverteilung entspricht. Da Lebensdauerparameter (z. B. der Skalenparameter T) definitionsgemäß auf den positiven reellen Zahlenraum beschränkt sind, erfolgt die Berechnung der CIs standardmäßig über die im rechten Teil der Gleichung 2.56 aufgeführte Log-Transformation, um physikalisch unmögliche, negative Intervallgrenzen mathematisch konsistent auszuschließen.

Vertrauensbereiche für Funktionswerte und Weibull-GLM

Oft ist nicht nur die Unsicherheit der Modellparameter selbst, sondern die der daraus abgeleiteten Funktionen - wie der Zuverlässigkeit $R(t)$ oder der Ausfallwahrscheinlichkeit $F(t)$ - von Interesse. Zur analytischen Ermittlung dieser sogenannten Fisher-Vertrauensbereiche führt Yang [6] zunächst eine Hilfsgröße w ein - vergleiche auch z_e nach Meeker et al. [2]. Diese normiert die logarithmische Abweichung der betrachteten Zeit t von der geschätzten charakteristischen Lebensdauer $\hat{T}$ mit dem Formparameter $\hat{b}$ (vergleiche auch Bain und Engelhardt [84] für weitere Abschätzungen):

$$\hat{w} = \hat{b} \cdot \ln \left(\frac{t}{\hat{T}} \right). \quad (2.57)$$

Die Varianz dieser transformierten Hilfsgröße lässt sich mittels der *Delta-Methode* (einer auf der Taylor-Reihenentwicklung basierenden, linearen Fehlerfortpflanzung) approximativ aus den Varianzen und Kovarianzen der Parameterschätzer bestimmen:

$$\hat{\text{Var}}(\hat{w}) = \left(\frac{\hat{b}}{\hat{T}} \right)^2 \hat{\text{Var}}(\hat{T}) + \left(\frac{\hat{w}}{\hat{b}} \right)^2 \hat{\text{Var}}(\hat{b}) - \frac{2\hat{w}}{\hat{T}} \hat{\text{Cov}}(\hat{T}, \hat{b}). \quad (2.58)$$

Basierend auf der asymptotischen Normalverteilung ergeben sich die Vertrauensgrenzen $[\hat{w}_u, \hat{w}_o]$ gemäß:

$$[\hat{w}_u, \hat{w}_o] = \hat{w} \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\text{Var}}(\hat{w})}. \quad (2.59)$$

Die Rücktransformation dieser Grenzen in den Wertebereich der Ausfallwahrscheinlichkeit erfolgt anschließend über die Verteilungsfunktion der kleinsten Extremwerte $G = 1 - \exp[-\exp(\hat{w})]$, woraus sich direkt die Konfidenzintervalle der Zuverlässigkeit ableiten lassen. Im Fall von GLM ist zu berücksichtigen, dass die geschätzte charakteristische Lebensdauer $\hat{T}$ keine unabhängige Konstante ist, sondern funktional entsprechend Gleichung 2.47 von den Kovariaten x und dem Parametervektor $\hat{\beta}$ abhängt. Die für Gleichung 2.58 benötigte Varianz $\hat{\text{Var}}(\hat{T})$ muss folglich unter Berücksichtigung der gesamten Kovarianzmatrix der Regressionskoeffizienten aus Gleichung

chung 2.55 berechnet werden. Dies erfolgt durch die allgemeine Fehlerfortpflanzung nach Gauß:

$$\hat{\text{Var}}(\hat{T}) \approx \sum_{i=1}^k \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i} \right)^2 \hat{\text{Var}}(\hat{\beta}_i) + \sum_{i=1}^k \sum_{\substack{j=1 \\ j \neq i}}^k \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i} \right) \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_j} \right) \hat{\text{Cov}}(\hat{\beta}_i, \hat{\beta}_j). \quad (2.60)$$

Modellgüte und Residuenanalyse

Die Validität eines parametrischen Lebensdauermodells (hier Weibull-GLM) beruht auf drei fundamentalen Annahmen, die es nach der Parameterschätzung zu verifizieren gilt: Erstens folgen die Lebensdauern der angenommenen Verteilung. Zweitens sind die Lebensdauern statistisch unabhängig. Drittens besteht ein log-linearer Zusammenhang zwischen dem Skalenparameter und den Einflussgrößen, wobei der Formparameter in einfachen Modellen als konstant über den gesamten Versuchsraum angenommen wird. Die Beurteilung dieser Modellgüte erfordert bei Lebensdauerdaten, bedingt durch Nicht-Normalverteilung und Zensierung, eine Anpassung klassischer Konzepte zur Residuenanalyse ($y - \hat{y}$) [31, 32]. Stattdessen werden transformierte Residuen betrachtet, die den Bezug zur Verteilung der kleinsten Extremwerte *SEV* herstellen, welcher der logarithmierten Weibull-Verteilung zugrunde liegt. Analog zur *z*-Transformation bei der Normalverteilung lassen sich für jede Beobachtung t_i standardisierte Residuen r_i berechnen. Dabei ersetzt der logarithmierte Schätzwert der charakteristischen Lebensdauer $\ln(\hat{T})^{\text{Mell}}$ (vgl. Gleichung 2.47) den Lageparameter μ und der Kehrwert des Formparameters $1/\hat{b}$ die Skalierung σ . Dies entspricht exakt der in diesem Abschnitt eingeführten Hilfsgröße w :

$$r_i = \frac{\ln(t_i) - \ln(\hat{T})}{1/\hat{b}} = \hat{b} \cdot \ln \left(\frac{t_i}{\hat{T}} \right). \quad (2.61)$$

Ist das Modell korrekt spezifiziert, müssen diese Residuen (unter Berücksichtigung der Zensierung) einer Verteilung der kleinsten Extremwerte *SEV* ($\mu = 0, \sigma = 1$) folgen. Eine allgemeinere Form der Validierung bieten die *Cox-Snell-Residuen* r_{CS} [2, 3]. Sie stellen eine Transformation der standardisierten Residuen dar und entsprechen

dem Wert der kumulativen Hazard-Funktion an der Stelle der Beobachtung. Für das Weibull-Modell gilt der Zusammenhang:

$$r_{CSi} = -\ln(\hat{R}(t_i)) = \exp(r_i) = \left(\frac{t_i}{\hat{T}}\right)^{\hat{b}}. \quad (2.62)$$

Folgt das angepasste Modell den Daten, so verhalten sich die Residuen r_{CS} wie eine Stichprobe aus einer Standard-Exponentialverteilung mit Mittelwert 1. Diese Eigenschaft erlaubt eine grafische Validierung mittels Probability-Plots: Liegen die geplotteten Residuen auf einer Geraden im Exponential-Wahrscheinlichkeitsnetz, kann von einer adäquaten Modellpassung ausgegangen werden. Zur Identifikation von Ausreißern oder einflussreichen Beobachtungen eignen sich hingegen standardisierte Devianz-Residuen r_{Dev} . Im Gegensatz zu den stets positiven Cox-Snell-Residuen sind diese symmetrischer um Null verteilt und folgen asymptotisch einer Standardnormalverteilung:

$$r_{Devi} = \text{sgn}(r_{CSi} - 1) \cdot \sqrt{2[r_{CSi} - \delta_i - \delta_i \ln(r_{CSi})]}. \quad (2.63)$$

Neben der Verteilungsprüfung dienen Streudiagramme dieser Residuen zur Aufdeckung struktureller Modelldefizite. Dabei werden r_{CS} oder r_{Dev} gegen die prädizierten Werte oder gegen einzelne Einflussfaktoren aufgetragen und gegenüber Trendfreiheit und Varianzhomogenität bewertet. Besteht initiale Unsicherheit über die zugrundeliegende Physik, ermöglicht zudem der Vergleich der Wahrscheinlichkeitsnetze der Residuen eine empirische Selektion: Dasjenige Modell, dessen Punktegraphen eine geringere Krümmung aufweisen und besser der theoretischen Geraden folgen, ist statistisch zu bevorzugen.

3 Testplanung für die multivariate Lebensdauererprobung

3.1 Bewertung des Forschungsstandes

Der in Kapitel 2 dargelegte Stand der Forschung und Technik verdeutlicht, dass die Zuverlässigkeitstechnik und das DoE profunde Methodenrepertoires bereitstellen. Die methodische Schnittmenge beider Felder - die Planung effizienter multivariater Lebensdauererprobungen unter Berücksichtigung schiefer Verteilungen und Zensierungen im Rahmen von Weibull-GLMs - offenbart jedoch fundamentale Konflikte, welche den zwingenden Bedarf an weiterführender Forschung für die versuchstechnische Praxis beim Einsatz von multivariatem ALT begründen.

Zur systematischen Einordnung dieser Defizite bedarf es zunächst einer grundlegenden Definition der zentralen Bewertungsmetriken, wie sie aus ingenieurwissenschaftlicher Sicht für die Lebensdauererprobung relevant sind. Für die vorliegende Arbeit wird daher definiert, dass ein Versuchsplan nur dann als adäquat anwendbar gilt, wenn er die folgenden beiden Zielgrößen erfüllt:

- **Statistische Effektivität:** Die Fähigkeit eines Versuchsplans, eine physikalische Kausalität (entsprechend der Effekte, der Degradationen oder der Schädigungsmechanismen) hinsichtlich der Lebensdauer eines Produkts stochastisch verlässlich mit geforderter *power* sowie hinreichender Parameter-Schätzgüte zu approximieren. So soll die Lebensdauer über den relevanten Parameterraum hinweg unverzerrt prognostiziert werden können. Demzufolge werden hierbei eine effektive GLM-Parameterschätzung, die Trennschärfe sowie die Prognosefähigkeit bzw. die Prädiktionsvarianz als Maßstäbe herangezogen.
- **Ökonomische Effizienz:** Die Allokation minimaler Ressourcen (allen voran ein restriktiver Stichprobenumfang N und eine adäquate Erprobungsdauer) zur Erreichung dieser geforderten statistischen Effektivität.

Ein Lebensdauertest ist folglich nur dann praxistauglich, wenn er das Investitionsrisiko der physikalischen Erprobung minimiert, ohne die Garantie zur Effekterkennung, deren Approximation selbst sowie die Anwendbarkeit der Modellierung zu kompromittieren. Demnach qualifizieren sich diese Metriken sowohl für die Bestandsaufnahme im aktuellen Forschungsumfeld als auch für die unmittelbare Planung effizienter, multivariater Versuchspläne. Anhand dieses Anforderungsprofils werden die methodischen Defizite aktueller Forschungsansätze im Folgenden diskutiert. Dies untergliedert sich in die methodische Dekonstruktion der optimalen Versuchsplanung (Abschnitt 3.1.1), die Einordnung der beschränkten analytischen Quantifizierbarkeit stochastischer Trennschärfe als Optimierungsgröße (Abschnitt 3.1.2) sowie die finale Synthese, welche in die Ableitung der in dieser Arbeit adressierten Forschungslücke mündet (Abschnitt 3.1.3).

3.1.1 Das methodische Paradoxon ALT-optimaler GLM-Designs

Der Einsatz computergenerierter, algorithmisch optimaler Versuchspläne (*D*-, *I*- oder *U*-Optimalität) erscheint aus theoretischer Sicht zunächst als logische Konsequenz, um maßgeschneiderte, effiziente Designs für ALT zu entwerfen. Im Kontext der Lebensdauer-Datenanalyse führt dies jedoch in ein methodisches Paradoxon [39]. Khuri [72], Stufken und Yang [78] und Yang et al. [85] weisen darauf hin, dass insbesondere die *lokale Optimalität* dieser Pläne immer dann eine fundamentale Limitation darstellt, wenn die wahren Modellparameter θ (allen voran der Formparameter b) *a priori* nicht bekannt oder abschätzbar sind.

Forschungsarbeiten zu GLM-optimalen Designs für ALT von Monroe et al. [62] und Seo und Pan [63] adressieren dieselbe Problematik und belegen das fundamentale stochastische Hindernis: Im Gegensatz zu klassischen OLS-Modellen, deren Informationsmatrix alleinig von der Versuchspunktopologie $\mathbf{X}$ abhängt, weist die Fisher-Informationsmatrix bei Weibull-GLMs (gemäß Gleichung 2.28 und 2.54) eine zwingende Abhängigkeit von den wahren, aber vorab unbekannten Modellparametern θ auf. Die Versuchsplanung erfordert damit unweigerlich stochastisches Vorwissen, welches sich, etwa im Fall der *U*-Optimalität für Prognostik in relevanten Betriebsbereichen, in der Vorgabe theoretischer *Planning Values* für die Regressionskoeffizienten in β und den Formparameter b manifestiert. Monroe et al. [61] erweitern diesen Ansatz durch iteratives Aktualisieren mittels Bayes'scher *Updating*-Prozesse, um die lokale

Optimalität sukzessive an die physikalische Realität anzupassen und so Effektivität und Effizienz zu maximieren. In konservativer Annahme muss jedoch davon ausgegangen werden, dass dem pragmatisch handelnden Ingenieur im Maschinen- oder Fahrzeugbau im realen Projektumfeld a priori Kenntnisse dieses Detailgrads zumeist vollständig fehlen. Stimmen anfängliche Schätzungen nicht mit der physikalischen Realität überein, entartet das GLM-optimale Testdesign und verliert seine statistische Integrität („The designs may be poor if the choice of values is far from the true parameter values“ Stufken und Yang [78, S. 2]). Kompensationsstrategien entgegen dieser Design-Entartung werden in der Theorie so durch drastische Erhöhung des Stichprobenumfangs N oder durch signifikante Verlängerung etwaiger Zensierungszeiten adressiert [62], was die Methode für die industrielle Praxis jedoch wirtschaftlich unbrauchbar macht.

Auch die in Forschungsarbeiten von Núñez Ares und Goos [67] und Goos [66] favorisieren optimale Testplaungen durch OMARS-Designs. Aus ingenieurwissenschaftlicher Perspektive lösen jedoch auch diese Ansätze nicht das fundamentale Problem der inhärenten Parameterabhängigkeit. Sie zielen auf strukturelle Flexibilität und die orthogonale Schätzung von Haupteffekten in einem einzigen experimentellen Schritt (*One-Step Approach*) ab, erkaufen dies jedoch durch eine algorithmisch kontrollierte Vermengung von Wechselwirkungen. Vor allem aber adressieren sie nicht den fundamentalen ALT-Konflikt: Die Notwendigkeit einer über den Raffungsfaktor hinweg reichenden *Extrapolation* in den Feldbetrieb steht der inhärenten Optimierung dieser Pläne auf *Interpolation* im Zentrum des Versuchsraums diametral entgegen. Konservativ wird in der Testplanung angenommen, dass im Vorfeld zumeist unbekannt ist, wie viele Faktoren tatsächlich relevant sind und ob diese in erster oder zweiter Ordnung wirken. Schlussfolgernd beraubt ein OMARS-Design den Prüfenieur der essenziellen strategischen Rückfallebene, eine sequenzielle Erweiterung von in der Regel kostenintensiven Versuchspunkten durchzuführen (vgl. Abschnitt 2.2.4).

3.1.2 Diskrepanz zwischen geometrischer Optimalität und stochastischer Trennschärfe

Ein weiteres fundamentales Forschungsdefizit besteht in der Entkopplung von geometrischen Optimalitätskriterien und der tatsächlichen, probabilistischen Erfolgswahrscheinlichkeit eines Tests. Wie in Abschnitt 2.2.5 dargelegt, basieren klassische Metri-

ken auf der Minimierung der Prädiktionsvarianz. Die Varianz allein garantiert jedoch nicht, dass ein physikalischer Effekt überhaupt signifikant vom Rauschen getrennt werden kann.

Im klassischen OLS-Umfeld lässt sich dies noch über den Nichtzentralitätsparameter δ_{nc} analytisch korrelieren. Im Kontext der Lebensdauerdatenanalyse, bei der grundlegend mit asymmetrischer Datenverteilungen und Zensierung zu rechnen ist, lassen sich diese Wahrscheinlichkeiten folglich nicht mehr über klassische *t-Tests* ableiten. Ausgehend von den Arbeiten zu GLMs [86] wird die Signifikanz der Koeffizienten vorzugsweise über *LR-Tests* (oder approximativ über *Wald-Tests*) ermittelt [2, 3]. Da für diese komplexen Verteilungsmodelle - insbesondere unter dem Einfluss asymmetrischer Versuchsraumänderungen und kleiner Stichprobenumfänge N - keine geschlossenen analytischen Lösungen zur Berechnung der Trennschärfe existieren, muss entsprechend Kremer [4] die Untersuchung numerisch mittels *MCS* erfolgen [71]. Hierbei wird der geplante Versuchsplan iterativ unter Vorab-Annahmen eines vorliegenden Regressionsmodells simuliert, verrauscht und zensiert, um den Anteil korrekter Signifikanz-Entscheidungen ($p\text{-Wert} < \alpha$) bei virtueller Design-Anwendung als empirische *power* zu extrahieren. Die Forschungslücke manifestiert sich darin, dass die Auswirkungen asymmetrischer Versuchsplanmodifikationen auf diese Trennschärfe empirisch nicht hinreichend untersucht sind. Aus Praxisperspektive ist die *power* als quantitative Erfolgsmetrik für den *Return-on-Investment* eines Versuchs zu interpretieren, doch ihre Korrelation zu den reinen geometrischen Optimalitätskriterien am Extrapolationspunkt ist bei individuellen Designmodifikationen bislang unzureichend beleuchtet.

Darüber hinaus wird die in der klassischen Versuchsplanung oft rein geometrisch betrachtete Design-Güte im Kontext der Zuverlässigkeitstechnik durch eine zeitliche Dynamik überlagert. Da die Information in Lebensdauertests stochastisch über die Zeit generiert wird, skaliert die tatsächliche Schätzvarianz in der Praxis maßgeblich mit den realisierten Ausfallzeiten [14]. Ein Versuchsplan ist folglich nur dann im Sinne der ökonomischen Effizienz tragfähig, wenn er die exponentiell ansteigende Testdauer bei unbeeinträchtigter statistischer Effektivität minimiert. Dieser fundamentale Zielkonflikt zwischen geometrischem Informationsgewinn und realen zeitlichen Prüfkosten bleibt in gängigen statistischen Gütekriterien und Optimalitäten jedoch vollständig unberücksichtigt.

3.1.3 Synthese des Forschungsstandes und Ableitung der Forschungslücke

Aus der Diskrepanz zwischen dem theoretischen Anspruch streng *lokaler*, GLM-optimaler Designs und der strukturellen Starrheit einstufiger *One-Step*-Ansätze leitet sich für die versuchstechnische Praxis die Notwendigkeit einer global robusteren Vorgehensweise ab. Anstatt ein künstliches Optimum zu berechnen, das bei geringfügigen Parameterabweichungen (*Planning Values*) in seiner Modellbildung kollabiert, erweist sich eine perspektivische, gezielte Adaption bewährter, topologisch fehlertoleranter Standard-Designs als der methodisch zielführende Pfad.

Dabei dürfen isolierte Optimalitätskriterien jedoch nicht als pauschales Entwurfsziel fungieren. Um den eingangs definierten Leitgrößen der ingenieurwissenschaftlichen ALT-Praxis gerecht zu werden, muss das Anforderungsprofil an ein Testdesign in einen multidimensionalen Benchmark überführt werden, der vier Zieldimensionen abbildet:

- **Modellierungsgüte (A-, D-Kriterien):** Adressiert die geforderte *topologische Robustheit*. Sie sichert ab, dass die GLM-Parameterschätzung in $\hat{\theta}$ auch bei Modifikationen des Designs und fehlendem Vorwissen numerisch stabil bleibt [22].
- **Prognosefähigkeit (SPV, G-, I-, U-, V-Kriterien):** Quantifiziert die *Prognosefähigkeit im Prädiktionsraum*. In der Lebensdauererprobung besitzt diese absolute Priorität, da die präzise Vorhersage der Zuverlässigkeit $R(t)$ im zumeist abweichenden *Betriebs-Parameterraum* das eigentliche Versuchsziel darstellt [3, 36].
- **Testdauer und Ressourceneffizienz:** Gewährleistet die *ökonomische Effizienz* sowie die *strukturelle Flexibilität*. Sie limitiert die Versuchsplanung durch die harte Realität exponentiell ansteigender *EoL*-Prüfzeiten sowie Prüfstandskosten $E(C_{\Sigma})$ und bewertet die zeitliche Skalierung der Informationsgewinnung [87].
- **Trennschärfe (*power*):** Dient als *Garantie-Metrik* für einen erfolgreichen Testausgang. Ein theoretisch varianzminimales Design, das in der Praxis den Nachweis essenzieller physikalischer Effekte verfehlt, ist industriell wertlos (Anforderungshorizont: *power* $\geq 80\%$) [68, 88].

Diese vier Zieldimensionen verhalten sich in der realen Versuchspraxis zumeist gegensätzlich zueinander: Eine extreme Beschleunigung der Belastungen senkt zwar

die Testdauer, kompromittiert jedoch die Prognosegüte im Feld. Ein reiner Fokus auf lokale D -Optimalität maximiert zwar die Schätzpräzision für Effekt-Koeffizienten, ignoriert jedoch die asymmetrische Extrapolationsrichtung und die tatsächliche *power*. Die Ausrichtung auf U -Optimalität minimiert zwar theoretisch die Prädiktionsvarianz am fernen Betriebspunkt, erzwingt jedoch eine Konzentration der Versuchspunkte auf niedrige Stressniveaus; dies lässt die Erprobungsdauer massiv eskalieren und zieht bei fehlerhaften *Planning Values* unwirtschaftliche Kompensationsmaßnahmen in Form von erhöhtem N oder drastisch verlängerten Zensierungszeiten nach sich. Ebenso reduzieren moderne OMARS-Designs zwar den Stichprobenumfang durch einen einstufigen Versuchsaufbau (*One-Step*), erkaufen diese strukturelle Effizienz jedoch durch eine unvermeidbare Vermengung der Wechselwirkungen und limitieren die stochastische Modellbildung durch ihre systemimmanente Beschränkung auf den Hyperwürfel $[-1, 1]^k$ strikt auf die reine Interpolation. Eine effiziente Testplanung erfordert folglich zwingend einen strategischen Kompromiss.

Als methodisches Fundament für diesen Kompromiss zeichnet sich insbesondere das CCD aus, welches sich als robuster Standard - insbesondere für quadratische Ansätze der Lebensdauermodellierung - bewährt hat [3, 4, 32]. Gegenüber alternativen Designs garantiert es durch seine *Rotierbarkeit* sowie eine hohe D -Effizienz ein vorteilhaftes Verhältnis zwischen Modellierungsumfang und benötigter Stichprobengröße [3]. Zudem erlaubt es den strategisch starken, sequenziellen Aufbau - vom Screening über augmentierte ZPs hin zu ergänzten SPs [22, 43]. Basierend auf dem am Institut für Maschinenelemente (IMA) generierten Wissensstand [4] ist das CCD im Rahmen des L-DoE folglich gleichermaßen bekannt sowie geeignet, um erwartungstreue Schätzungen und Vertrauensbereiche zu generieren [16, 80].

Für die spezifischen Anforderungen der ALT-Erprobung erweist sich die starre geometrische Symmetrie des klassischen CCD jedoch als limitierend. Die erforderliche *Extrapolation* steht im direkten Konflikt mit der mathematischen Optimierung klassischer RSDs auf *Interpolation* im Zentrum des Versuchsraums [41]. Bestehende Ansätze zur Modifikation von CCDs [58, 89, 90] adressieren diese Diskrepanz nicht proaktiv für den fernen Extrapolationsraum, sondern fokussieren sich zumeist auf den Erhalt generischer Optimalitätskriterien bei Ausfällen [71, 88].

Genau an diesem Konfliktpunkt verankert sich der methodische Beitrag der vorliegenden Arbeit. Die inhärente strukturelle Überbestimmtheit des CCD (beispielsweise

durch mehrfache Zentralpunkt-Replikationen) birgt ein ungenutztes Potenzial, welches hier als geometrisches *Gestaltungsbudget* für die prädiktionsbasierte Designoptimierung definiert wird. Wird die geometrische Symmetrie des Plans kritisch hinterfragt, können zur Disposition stehende Versuchspunkte aus dem originären Plan hinsichtlich ihrer Position gezielt modifiziert werden. Die identifizierte Forschungslücke besteht somit darin, dieses Gestaltungsbudget nicht primär zur passiven Kostenreduktion zu streichen. Vielmehr sollen diese verfügbaren Stützstellen als dedizierte *Extrapolations-Ankerpunkte* exakt dorthin verlagert werden, wo der perspektivische Prognosepunkt im Feldbetrieb allokiert ist, um das Regressionsmodell auf dem Extrapolationspfad stochastisch abzustützen.

Dieser proaktive, methodische Schritt wird durch Erkenntnisse der Optimalitätsforschung theoretisch legitimiert: Seo und Pan [63] sowie Monroe et al. [62] belegen, dass algorithmisch auf eine Feldbetriebs-Prognose optimierte Designs (*U*-Optimalität) von Natur aus eine massive topologische Asymmetrie erzwingen, indem sie einen erheblichen Großteil der Versuchspunkte auf das niedrigste Stressniveau allokieren. Zudem beweisen Monroe und Pan [34], dass gezielt asymmetrische Designs in physikalisch restriktiven Versuchsräumen die Breite der Konfidenzintervalle für Parameterschätzungen im Vergleich zu konventionellen, starren Designs drastisch reduzieren können. Um diese mathematisch nachgewiesenen Effizienzsprünge der Asymmetrie zu nutzen, ohne die Ausfallrisiken lokaler Optimalpläne in Kauf zu nehmen, formuliert diese Arbeit einen methodischen Brückenschlag: Auf Basis des CCD entsteht ein adaptiver Versuchsplan, der eine hin zur Prädiktionsvarianz optimierte Informationsgewinnung in Extrapolationsrichtung sicherstellt, während die parallel quantifizierte *power* garantiert, dass der *Return-on-Investment* des Lebensdauertests gewahrt bleibt.

3.2 Forschungsfragen und wissenschaftliche Zielsetzung

Als methodisches Fundament für die multivariate Lebensdauererprobung dient in dieser Arbeit somit das CCD aus der Klasse der RSDs. Diese Wahl begründet sich zusammenfassend in fünf fundamentalen verfahrenstechnischen, physikalischen und statistischen Eigenschaften [2, 35, 36]:

1. **Sequenzielle Augmentierbarkeit:** Ermöglicht den stufenweisen Ausbau vom Screening zum vollwertigen quadratischen Modell und minimiert das ökonomische Fehlinvestitionsrisiko bei zeitintensiven Tests [1].
2. **Rotierbarkeit und Richtungsneutralität:** Bietet eine homogene Ausgangsbasis für die Prädiktionsgüte bei a priori unbekannter Lage des Zuverlässigkeitsoptimums [2].
3. **Modellierung nichtlinearer Schädigungskinetik:** Die Abtastung auf fünf Faktorstufen erlaubt die Validierung physikalischer Beschleunigungsmodelle und die Detektion von Linearitätsgrenzen [6, 75].
4. **Schätzung der reinen Systemstreuung:** Zentralpunkt-Replikationen ermöglichen die modellunabhängige Trennung von reinem Versuchsfehler (*Pure Error*) und Modellanpassungsfehlern (*Lack of Fit*) [2].
5. **Topologische Fehlertoleranz:** Die symmetrische Grundstruktur garantiert eine extrem hohe Robustheit gegenüber unvorhergesehenen Zensierungen (*Missing Data*) am Prüfstand [22].

Die vorliegende Arbeit verfolgt die wissenschaftliche Zielsetzung, diese für die Lebensdauererprobung überlegene Grundarchitektur nicht zu verwerfen, sondern den ihr zugrundeliegenden Ansatz zur Augmentierung konsequent auf den Extrapolationsraum auszuweiten. Die forschungsleitende Hypothese besteht darin, dass der Informationsgewinn für die Feldbetriebs-Prognose nicht durch eine kostenintensive Vergrößerung der Prüflingsanzahl erzwungen werden muss. Vielmehr wird postuliert, dass sich durch die Identifikation ungenutzter geometrischer Freiheitsgrade ein Gestaltungsbudget ableiten lässt, dessen strategische Reinvestition als Extrapolations-Ankerpunkte ein stochastisches Nullsummenspiel im Versuchsraum ermöglicht.

Um diese Hypothese zu überprüfen und den in Abschnitt 3.1 identifizierten Zielkonflikt aufzulösen, leitet sich die zentrale Hauptforschungsfrage dieser Arbeit wie folgt ab:

Hauptforschungsfrage

Wie kann die Architektur zentral zusammengesetzter Versuchspläne unter Beibehaltung oder Reduktion des Gesamtstichprobenumfangs asymmetrisch adaptiert werden, um beschleunigte Lebensdauerprüfungen für eine varianzminimierte Zuverlässigkeitsmodellierung im Extrapolationsraum des Feldbetriebs maximal effizient auszulegen?

Zur systematischen Beantwortung dieser übergeordneten Problemstellung werden drei spezifische Teilforschungsfragen definiert:

Teilforschungsfragen

- 1: Welches geometrische Gestaltungsbudget lässt sich aus der strukturellen Überbestimmtheit klassischer CCDs ableiten, ohne die grundlegende topologische Stabilität der multivariaten GLM-Parameterschätzung zu gefährden?
- 2: Wie lassen sich diese freigewordenen Versuchspunkte als richtungsspezifische Extrapolations-Ankerpunkte allokalieren, und mit welchen Metriken kann die Wahrung der statistischen Trennschärfe (*power*) hierbei quantitativ garantiert werden?
- 3: Wie lässt sich der fundamentale Zielkonflikt zwischen stochastischer Vorhersagegüte und exponentiell skalierenden Prüfstandskosten in einem ökonomischen Bewertungsmodell abbilden, um ein skalares Effizienzoptimum für die Testplanung zu ermitteln?

3.3 Methodische Forschungsarchitektur

Die Beantwortung der formulierten Forschungsfragen erfolgt entlang einer vierstufigen Methodenkette, welche das theoretische Konzept von der stochastischen Basisidentifikation bis hin zum industriellen Nutzennachweis führt:

- **Stufe 1: Quantifizierung der Resilienz & Gestaltungsbudget (Abschnitt 4.2):** Simulativer Nachweis der Fehlertoleranz des klassischen CCD gegenüber geometrischen Restriktionen und Ableitung des nutzbaren Gestaltungsbudgets für asymmetrische Modifikationen bei konstantem Stichprobenumfang N (Beantwortung Teilforschungsfrage 1). Hier wird eine Potenzialanalyse der asymmetrischen Designmodifikation durchgeführt, um die Auswirkungen auf die Trennschärfe als grundlegende Eigenschaft im Sinne einer Erfolgswahrscheinlichkeit für die Testplanung zu quantifizieren.
- **Stufe 2: Adaptive Testplanung & Extrapolations-Ankerpunkte (Abschnitt 4.3):** Methodische Weiterentwicklung des Augmentierungsprinzips durch die Allokation von Extrapolations-Ankerpunkten in modifizierten Designs auf Basis eines CCD innerhalb mathematisch definierter Toleranzbereiche (*Exposure Area*) sowie die richtungssensitive Analyse der Vorhersagevarianz unter Wahrung der Trennschärfe (Beantwortung Teilforschungsfrage 2).
- **Stufe 3: Stochastisch-ökonomische Bilanzierung (Abschnitte 4.4-4.5):** Koppung der MLE-basierten Weibull-AFT-Modellierung mit einem dynamischen Prüfstandskostenmodell und ökonomischer Bilanzierung zur Bestimmung des Pareto-Optimums aus Testdauer und Prognosegüte (Beantwortung Teilforschungsfrage 3).
- **Stufe 4: Empirische Verifikation (Kapitel 5):** Experimenteller Härtetest an realen Bauteilprüfungen (Lenksystem-Zahnriemen) mittels *Confirmation Experiments* (Abschnitt 5.2.1) und Prädiktionsintervallen zur Verifikation der entwickelten Methodik und der Validierung der in Stufe 3 ermittelten ökonomischen Effizienz (Beantwortung der Hauptforschungsfrage).

4 Statistische Effektivität als Fundament effizienter Lebensdauertests

Nach der methodischen Einordnung des Forschungsstandes und der Identifikation der wesentlichen Defizite in Kapitel 3 etabliert das vorliegende Kapitel die stochastische und topologische Basis für die Planung effizienter multivariater Lebensdauertests. Die wissenschaftliche Zielsetzung besteht darin, das Fundament zentral zusammengesetzter Versuchspläne (CCDs) gezielt an die asymmetrischen Anforderungen der Feldbetriebs-Extrapolation zu adaptieren. Um den Übergang von der klassischen *D*-Optimalität bzw. RSM hin zu einer Prädiktion-fokussierten Lebensdauererprobung nachvollziehbar zu segmentieren, gliedert sich der Untersuchungsansatz in eine fünfstufige Sequenz - ausgehend von einer isolierten Simulationsumgebung hin zur stochastisch-ökonomischen Synthese im AFT-Raum:

Zunächst etabliert **Abschnitt 4.1** die Simulations- und Auswertearchitektur auf Basis eines flexiblen *Ground-Truth*-Modells. Der Grundgedanke dieser Modellierung wird auch in weiteren Abschnitten aufgegriffen: Die statistische Effektivität der Versuchspläne wird in einer kontrollierten Umgebung quantifiziert, in welcher die wahren Systemparameter a priori bekannt sind und sich in Abhängigkeit der spezifischen Randbedingungen in den Untersuchungsschritten anpassen lassen. Darauf aufbauend quantifiziert **Abschnitt 4.2** die statistische Sensitivität klassischer Designs gegenüber geometrischen Praxisrestriktionen. Mittels MCS wird analysiert, in welchem Maße Orthogonalitätsabweichungen die Schätzpräzision und die statistische Trennschärfe (*power*) beeinflussen und welches topologische Gestaltungsbudget hieraus abgeleitet werden kann. Dieses Verständnis legitimiert in **Abschnitt 4.3** die adaptive Versuchsplanung, in welcher redundante Stützstellen als strategische Ankerpunkte (APs) allokiert werden. Deren richtungssensitive Wirkung entlang des Extrapolationspfads wird über den EVG visualisiert und ihre topologische Überlegenheit isoliert validiert. Den ökonomischen Rahmen definiert **Abschnitt 4.4** durch ein Kostenmodell, welches stochastische Testlaufzeiten über physikalische Beschleunigungsfaktoren in reale

Prüfstandsaufwände überführt. In **Abschnitt 4.5** erfolgt die Synthese für multivariate Lebensdauermodelle: Das asymmetrische **EmALT**-Konzept wird im Weibull-AFT-Raum über die Parameterschätzung unter realen Erprobungsbedingungen bewertet und über den **Economic Extrapolation Power Index (EPI)** im Pareto-Optimum aus Testaufwand und Prognosegüte bilanziert.

4.1 Methodische Simulationsarchitektur und pseudo-physikalisches Modell

Um die statistische Leistungsfähigkeit modifizierter Versuchspläne objektiv zu quantifizieren, bedarf es einer kontrollierten Untersuchungsumgebung, in welcher das wahre Systemverhalten *a priori* exakt definiert ist. Erst der systematische Abgleich der Modellierungs- und Schätzergebnisse mit einer deterministischen Referenz (*Ground Truth*) ermöglicht die Berechnung von **Key Performance Indicators (KPIs)** wie Schätzgüte, Varianzinflation und statistischer Trennschärfe (*power*). Zu diesem Zweck wird nachfolgend eine allgemeingültige, modulare Simulationsumgebung aufgebaut, welche als Auswertebasis für sämtliche Untersuchungen dieses Kapitels dient [91, 92].

4.1.1 Pseudo-physikalisches Ground-Truth-Modell

Das zugrundeliegende Systemverhalten wird durch ein polynomielles Regressionsmodell zweiter Ordnung approximiert. Dies entspricht der Modellstruktur, die als Ergebnis einer klassischen **RSM**-Auswertung (vgl. Gleichung (2.17)) resultiert und das Fundament für multivariate Lebensdauer- und Zuverlässigkeitsmodelle bildet. Zur Abbildung einer multivariaten Untersuchung ($k \geq 2$) wird im Basisszenario von zwei Einflussfaktoren (x_1, x_2) ausgegangen. Die Begrenzung auf $k = 2$ stellt methodisch eine konservative Betrachtung dar: Da sich die negativen Auswirkungen lokaler topologischer Störungen mit zunehmender Dimensionalität über eine größere Anzahl verbleibender orthogonaler Stützstellen verteilen, reagiert ein zweidimensionaler Versuchsraum statistisch am empfindlichsten auf geometrische Verzerrungen [71]. Das Modell berücksichtigt neben den Haupteffekten explizit Wechselwirkungen ersten Grades sowie quadratische Terme zur Erfassung der Krümmung der Systemantwort:

$$y_{\text{sim}} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \quad (4.1)$$

Unter Berücksichtigung von Gleichung 2.47 eignet sich diese Regressionsgleichung sowohl zur Abbildung repräsentativer Datenlagen aus der statistischen Versuchsplanung sowie der logarithmierten charakteristischen Lebensdauer T im AFT-Raum (vgl. Abschnitt 2.1.3).

4.1.2 Simulationsarchitektur und Monte-Carlo-Inferenz

Die definierte *Ground Truth* wird mit der jeweils zu untersuchenden Design-Matrix $\mathbf{X}$ entsprechend Gleichung 2.18 aufgelöst. Um epistemische Unsicherheiten zu minimieren und eine reproduzierbare numerische Konvergenz sicherzustellen, ist das Verfahren in eine MCS mit $n_{MC} = 1 \cdot 10^4$ Iterationen eingebettet. Hierbei kommt in der algorithmischen Umsetzung das Prinzip der *Seed-Fixierung* (*Common Random Numbers*) zum Einsatz: In die Prüfstandspraxis der Zuverlässigkeitstechnik übersetzt bedeutet dies, dass alle evaluierten Design-Varianten an exakt demselben Kollektiv virtueller Prüflinge mit identischer inhärenter Materialstreuung getestet werden, so dass resultierende Schätzabweichungen kausal auf die Topologie des Versuchsplans und nicht auf das Rauschen zufällig variierender Stichproben im MCS-Sampling zurückzuführen sind.

Ausgehend von der definierten *Ground Truth* und der Versuchsmatrix $\mathbf{X}$ werden in den MCS-Iterationen somit stochastische Systemantworten generiert. Die nachfolgende Parameterschätzung erfordert methodisch eine strikte Zweiteilung der Inferenzverfahren (OLS versus MLE), um topologische Design-Effekte von verteilungsspezifischen Schätzfehlern zu isolieren: Würde die Evaluierung asymmetrisch modifizierter Versuchspläne unmittelbar über eine MLE an zensierten, Weibull-verteilten Daten erfolgen, ließen sich Varianzerhöhungen und Trennschärfe-Verluste nicht mehr eindeutig zuordnen. Sie wären das ununterscheidbare Produkt aus der geometrischen Verzerrung der Design-Matrix $\mathbf{X}$ einerseits und dem stochastischen *Small-Sample Bias* der MLE andererseits. Aus diesem Grund erfolgt die Auswertung in entsprechender Abfolge:

- **Stufe 1 (Isolierter topologischer Fehler via OLS):** In den Abschnitten 4.2 und 4.3 operiert die Simulation unter den Prämissen der additiven Normalverteilung (Gauss-Markow-Theorem). Der OLS-Schätzer liefert hier die erwartungstreue Baseline. Jeder in dieser Phase messbare Verlust an statistischer Effektivität ist

ausschließlich auf die geometrische Modifikation des Versuchsplans zurückzuführen.

- **Stufe 2 (Stochastische Realität via MLE):** Nach dem Nachweis der Design-Integrität vollzieht Abschnitt 4.5 nachgestellt den Transfer auf das log-lineare AFT-Modell. Hier quantifiziert die MLE die Vorhersagegüte unter den Bedingungen rechtsschiefer (und ggf. zensierter) Lebensdauerdaten.

Am Ausgang dieser Simulationsschleife werden die statistische Effektivität und die akkumulierten Prüfstandskosten simultan bereitgestellt. Dies erlaubt die Analyse der zwei elementaren Bewertungskriterien:

1. **Präzision der Parameterschätzung:** Durch den Erwartungswert-Vergleich der geschätzten Koeffizienten $\hat{\beta}$ mit den wahren Modellparametern β_{true} werden der systematische Schätzfehler (**Bias**) sowie die Schätzvarianz (**MSE**) quantifiziert.
2. **Empirische Trennschärfe (*power*):** Für jeden Simulationslauf wird über statistische Hypothesentests (**ANOVA** bzw. **LR-Test**) geprüft, ob signifikante Effekte vor dem Hintergrund des Rauschens korrekt identifiziert werden ($p\text{-Wert} < \alpha$). Der relative Anteil erfolgreicher Identifikationen definiert die empirische *power* (vgl. Gleichung (2.44), in Anlehnung an [4, 68, 92]).

Die systematische Kopplung dieser Inferenzschritte mit der topologischen Design-Auswahl und dem dynamischen Kostenmodell ist in Abbildung 4.1 zusammengefasst. Da diese Architektur als übergeordneter methodischer Fahrplan für die sukzessive Argumentationskette fungiert, integriert sie Parameter und Konzepte, deren formale Herleitung abschnittsspezifisch erfolgt. Der modulare Ablauf lässt sich entlang dreier Kernpfade strukturieren:

- **1. Kalibrierung des Pseudo-Physikalischen Modells (Linker Pfad im Schaubild):** Die Definition der wahren Systemantwort erfordert je nach Untersuchungsziel differenzierte **SNR**-Kalibrierungen. Für die grundlegende Analyse geometrischer Störungen operiert das Modell im Normalverteilungsraum (**OLS**). Für den Transfer in die Lebensdauererprobung erfolgt die Kalibrierung im log-linearen Weibull-Raum. Dies erfordert die spezifische Skalierung über die **SEV**-Streuung (σ_{SEV}), welche in Abschnitt 4.5 hergeleitet wird.




Abbildung 4.1: Methodische Architektur der Monte-Carlo-Simulationsumgebung. Das Framework fungiert als struktureller Fahrplan für die Validierung der statistischen Effektivität und ökonomischen Effizienz.

- **2. Evolution der Versuchstopologie X (Rechter Pfad im Schaubild):** Ausgehend vom Basis-CCD bei konstantem Ressourcenaufwand von $N = 13$ Versuchspunkten (vier Randpunkte, vier Sternpunkte, fünf Zentralpunkte [3, 22]) werden zunächst in Abschnitt 4.2 systematische Variationen sowie isolierte Störfälle simuliert, um das Gestaltungsbudget des Plans zu quantifizieren. In Abschnitt 4.3 wird dieses Budget genutzt, um über die Definition eines statistischen Toleranzraums (*Exposure-Area*) die asymmetrischen Extrapolations-Ankerpunkte der modifizierter Topologie abzuleiten, die hinsichtlich ihrer Auswirkung auf die Varianz in der Prädiktion zu präferieren sind.
- **3. Stochastisch-ökonomische Synthese (Unterer Pfad im Schaubild):** Am Ausgang der Simulationsschleife werden die ermittelte statistische Effektivität (geprägt durch *power*, MSE und die Positions-sensitive Prädiktionsvarianz) und der über das Kostenmodell (Abschnitt 4.4) ermittelte monetäre Erwartungswert $E(C_\Sigma)$ zusammengeführt. Diese kulminieren in Abschnitt 4.5 in der Effizienzbewertung, welcher die Relation aus Testaufwand zu Prognosegüte quantifiziert.

4.2 Effektivität von Versuchsplänen mit Orthogonalitätsabweichungen

In der industriellen Erprobungspraxis resultieren Abweichungen von der idealen Versuchsgeometrie häufig aus physikalischen Anlagenrestriktionen, Bauteilgrenzen oder der gezielten Lastanhebung im Rahmen von ALTs. Die Verschiebung von Versuchspunkten in Hochlastbereiche forciert den Ausfallmechanismus und verkürzt die Prüfzeit, während Stützstellen nahe dem Nennbetrieb die Extrapolationsunsicherheit dämpfen.

Modifikationen an RSDs wie dem CCD bergen das Risiko, die statistische Integrität des Versuchsplans zu schwächen. Im Idealfall sind die Spalten der Design-Matrix X eines CCD orthogonal zueinander, was die unkorrelierte Schätzung aller Modellparameter garantiert. Geometrische Verzerrungen heben diese Orthogonalität unweigerlich auf ($\langle x_i, x_j \rangle \neq 0$). Die Ausprägung der resultierenden Varianzinflation hängt dabei maßgeblich von der Topologie der Störung ab: Während Eingriffe im faktoriellen Kern die Schätzung der linearen Haupteffekte unmittelbar kompromittieren, entfalten die für ALTs typischen asymmetrischen Verschiebungen an den absoluten

Belastungsgrenzen ihre Konsequenzen für die Modellkrümmung zumeist erst bei der Erweiterung um periphere axiale SPs.

Wie in Kapitel 3 hergeleitet, erlauben rein algebraische Matrixmaße und Optimalitätskriterien hierbei keine verlässliche Aussage über die tatsächliche Schätzvarianz und die statistische Trennschärfe. Zur probabilistischen Quantifizierung dieser Praxisrestriktionen unter stochastischen Rauschbedingungen wird daher direkt auf die in Abschnitt 4.1 etablierte Simulationsarchitektur zurückgegriffen.

4.2.1 Potenzialanalyse geometrischer und stochastischer Einflussgrößen

Um die Robustheit klassischer CCDs fundiert zu bewerten, wird eine *Potenzialanalyse* durchgeführt. Diese folgt methodisch dem Prinzip einer *Meta-Versuchsplanung* (*Meta-DoE*): Die topologischen Eigenschaften des Versuchsplans sowie die stochastischen Randbedingungen werden als Faktoren eines übergeordneten Meta-Designs derart variiert, dass deren funktionale Auswirkung auf die Schätzgüte, hier insbesondere auf die statistische Trennschärfe, quantifiziert werden kann [91]. Hierfür wird ein Spektrum aus acht als für diese Arbeit praxisrelevant identifizierten Geometrie-, Stör- und Inferenzparametern definiert:

1. Geometrischer SP-Abstand (α_D) zur Erfassung radialer Stauchungen oder Streckungen;
2. Asymmetrischer SP-Shift infolge parasitärer co-faktorieller Stellgrößenkopplung;
3. Diskrete Variation der Zentralpunktanzahl (n_{ZP});
4. Diskrete Variation der Sternpunktanzahl (n_{SP}) durch partiellen Stützstellenentfall;
5. Streuung der wahren Modellparameter (epistemisches Effekt-Rauschen);
6. Relatives Amplitudenverhältnis konkurrierender Haupteffekte (β_1/β_2);
7. Standardabweichung des experimentellen Versuchsfehlers (System- und Messrauschen, SNR);
8. Vorgegebenes statistisches Signifikanzniveau (α).

Um die stochastische Realität technischer Systeme abzubilden, werden die wahren Modellparameter β_j nicht starr fixiert. Ausgehend von kalibrierten nominalen Startwerten $\beta_{j,nom}$ (vgl. Tabelle 4.1) unterliegen die Koeffizienten in jedem Monte-Carlo-Lauf einer stochastischen Schwankung. Zusätzlich wird die Systemantwort y_{sim} mit

einem additiven Restfehler ϵ beaufschlagt, welcher die aleatorische Unsicherheit modelliert:

$$\epsilon \sim \mathcal{N}(0, \sigma_{\text{sim}}^2) \quad \text{und} \quad \beta_j \sim \mathcal{N}(\beta_{j,\text{nom}}, \sigma_{\text{sim}}^2). \quad (4.2)$$

Die Wahl der Normalverteilung ist methodisch zwingend: Sie erfüllt die Prämissen des Gauß-Markow-Theorems und stellt sicher, dass die statistische Inferenz im ungestörten Basis-Design erwartungstreu operiert. Etwaige Schätzfehler lassen sich somit kausal auf induzierte Orthogonalitätsabweichungen zurückführen, ohne durch verteilungsbedingte Asymmetrien überlagert zu werden [2].

Tabelle 4.1: Nominale Startwerte und Streuparameter des pseudo-physikalischen Simulationsmodells

Modellparameter	Default-Wert
Regressionskonstante β_0	30
Regressionskoeffizienten β_j (für $j \in \{1, 2, 12, 11, 22\}$)	10
Standardabweichung der Systemantwort σ_{sim}	1

Zur formalen Beschreibung des Sensitivitätsraums werden die acht Einflussgrößen im Parametervektor $\xi = [\xi_a, \dots, \xi_h]^\top$ zusammengefasst und gemäß Tabelle 4.2 parametrisiert. Die Einbindung in das Meta-Design erfolgt methodisch differenziert: Während die sechs kontinuierlichen Geometrie- und Rauschparameter den stetigen Parameterraum aufspannen, werden die strukturellen Stützstellenzahlen (ξ_c, ξ_d) als kategoriale Blockfaktoren über jeweils drei diskrete Stufen ($-1, 0, +1$) variiert. Diese Entkopplung ist geboten: Eine Reduktion der Stützstellen verändert die Rang- und Freiheitsgradstruktur der Informationsmatrix diskontinuierlich. Ein kontinuierliches Meta-Modell würde über strukturelle Singularitäten interpolieren. Die kontinuierlichen Sensitivitäten werden isoliert innerhalb der resultierenden neun diskreten Topologie-Blöcke ermittelt (dokumentiert im Anhang B), während der Haupteffekt der Stützstellenreduktion separat über die Niveauverschiebungen der *power* zwischen den Blöcken quantifiziert wird.

Gegenüber alternativen Screening-Verfahren gewährleistet dieser hierarchische DoE-Ansatz eine formal abgesicherte Kausalitätsprüfung zur Trennung von Haupteffekten, Interaktionen und Krümmungsanteilen auf die resultierende Trennschärfe [32, 93].

Tabelle 4.2: Definition und Parametrisierung der Untersuchungsfaktoren für die Sensitivitätsanalyse

	Beschreibung	Wertebereich	Charakteristik
ζ_a	SP-Abstand (α_D) Variation des axialen Sternpunktabstands zum Zentrum.	$[1,00; 2 \cdot \alpha_D]$	Kontinuierlich
ζ_b	SP-Shift Asymmetrische, co-faktorielle Verschiebung eines SP.	$[0,10; \alpha_D]$	Kontinuierlich
ζ_c	ZPs (n_{ZP}) Diskrete Variation der Zentralpunktanzahl $n_{ZP} \in \{1, 5, 8\}$.	$[1,00; 8,00]$	Diskret (Blockfaktor)
ζ_d	SPs (n_{SP}) Diskrete Variation der Sternpunktanzahl $n_{SP} \in \{2, 3, 4\}$.	$[2,00; 4,00]$	Diskret (Blockfaktor)
ζ_e	Effekt-Rauschen Streuung der wahren Modellparameter ($\sigma_{\text{sim}} / \beta_i$).	$[0,80; 1,20]$	Kontinuierlich
ζ_f	Effekt-Verhältnis (β_1 / β_2) Amplitudenverhältnis zweier Haupteffekte.	$[0,10; 1,00]$	Kontinuierlich
ζ_g	Mess-Rauschen (SNR : y / ϵ) Verhältnis zwischen mittlerer Effektamplitude und Fehler.	$[0,80; 1,20]$	Kontinuierlich
ζ_h	Signifikanzniveau (α) Vorgegebene Irrtumswahrscheinlichkeit.	$[0,02; 0,08]$	Kontinuierlich

4.2.2 Ergebnisse der Potenzialanalyse und Quantifizierung der Trennschärfe

Die Untersuchung der Trennschärfe im Meta-Design offenbart eine strukturelle Dichotomie zwischen dispositiven Designfaktoren (Geometrie, Stützstellenanzahl) und externen Systemrestriktionen (Rauschen). Tabelle 4.3 fasst die Ergebnisse der ANOVA zusammen, wobei die signifikante Effektstärke E als Maß für die Dominanz eines Faktors dient.

Wird die globale Modell-Power ($power_m$) betrachtet, zeigt sich eine hohe Robustheit mit einer mittleren Trennschärfe von $power > 99,7\%$. Diese Metrik verdeckt jedoch, dass das Verhalten spezifischer Einzel-Effekte - insbesondere die Identifikation der quadratischen Terme - sensibler ausfällt. Die mittlere Trennschärfe für quadratische Terme ($power_{\beta_{11}}, power_{\beta_{22}}$) liegt im Bereich von 70 % bis 79 %. Die Sensitivitäts-Indizes verdeutlichen, dass für die Mehrheit der Koeffizienten nicht die Versuchspunktzahl der limitierende Faktor ist, sondern das Effektstärke-Verhältnis (ζ_f) sowie das Messrauschen (ζ_g). Da das Rauschen in der Praxis zumeist eine feste Randbedingung darstellt, definiert es eine natürliche Obergrenze der erreichbaren Trennschärfe.

Tabelle 4.3: Zusammenfassende Statistik der Trennschärfe und Identifikation der dominierenden Einflussfaktoren.

Koeffizient	Mittelwert	Wertebereich	Dominierende Sensitivität	
	$power$	[min; max] %	Einflussfaktor ζ_i (Kategorie)	E
$power_m$	99,7 %	[94,5; 100,0]	ζ_g (System)	0,10
$power_{\beta_0}$	97,9 %	[76,9; 100,0]	ζ_e (System)	0,52
$power_{\beta_1}$	78,6 %	[60,0; 90,8]	ζ_g (System)	1,50
$power_{\beta_2}$	66,0 %	[37,3; 84,1]	ζ_f (System)	2,53
$power_{\beta_{12}}$	72,6 %	[52,5; 85,9]	ζ_g (System)	1,93
$power_{\beta_{11}}$	70,9 %	[32,6; 86,8]	ζ_g (System)	1,99
$power_{\beta_{22}}$	79,3 %	[33,4; 100,0]	ζ_a (Design)	3,72

Aus dieser Gegenüberstellung leitet sich ab: Wenn die Nachweiswahrscheinlichkeit der linearen Haupteffekte durch externe Systemrestriktionen limitiert wird, ist zu prüfen, inwieweit eine gezielte Reduktion der Stützstellen (ζ_c, ζ_d) die statistische Aussagekraft kompromittiert. Tabelle 4.4 quantifiziert diesen topologisch induzierten Schätzgüteverlust als mittleren Trennschärfe-Rückgang.

Tabelle 4.4: Systematischer Trennschärfe-Verlust ($\Delta power$) bei Ausdünnung der Versuchsstützpunkte.

Koeffizient	Durchschnittlicher Trennschärfe-Verlust ($\Delta power$)	
	bei ξ_c ($n_{ZP} = 8 \rightarrow 1$)	bei ξ_d ($n_{SP} = 4 \rightarrow 2$)
$power_{\beta_0}$	−4,5 %	−0,3 %
$power_{\beta_1}$	−2,4 %	−6,0 %
$power_{\beta_2}$	+1,1 %*	−8,0 %
$power_{\beta_{12}}$	−1,2 %	−0,9 %
$power_{\beta_{11}}$	−13,9 %	−12,8 %
$power_{\beta_{22}}$	n. a.**	−6,1 %

* Resultiert aus Varianzverschiebungen bei instabilen Designs.

** Nicht auswertbar aufgrund von Singularität.

Die numerische Bilanzierung belegt die Robustheit des CCD-Skeletts: Der Verzicht auf redundante Zentralpunkte oder die Ausdünnung der Sternpunkte zieht für die Haupteffekte lediglich einen geringen Trennschärfe-Verlust nach sich. Der signifikante Schwachpunkt dieser Reduktion manifestiert sich in den quadratischen Termen (bis zu −13,9 % bei $power_{\beta_{11}}$).

Hierin begründet sich die Strategie gezielter Design-Modifikationen: Die Reduktion klassischer Stützstellen gefährdet die Detektion von Haupteffekten kaum, was ein **geometrisches Gestaltungsbudget** freisetzt. Gleichzeitig belegt Tabelle 4.3, dass die periphere Geometrie (Sternpunktabstand ξ_a) mit $E = 3,72$ den stärksten Hebel auf die quadratischen Terme besitzt. Dieses Budget wird folglich nicht zur Kostensenkung gestrichen, sondern durch asymmetrische topologische Reallokationen umgewidmet, um die quadratische Modellkrümmung abzustützen und die Extrapolationsvarianz zu minimieren.

4.2.3 Generische Auswirkungen relevanter Orthogonalitätsabweichungen

Die Ergebnisse zeigen, dass das CCD im Hinblick auf die statistische Trennschärfe ein robustes Verhalten gegenüber Modifikationen seiner Stützstellenanzahl aufweist. In der Erprobungspraxis treten Abweichungen jedoch häufig als unvorhergesehene,

asymmetrische und isolierte Einzelphänomene auf, erzwungen durch physikalische Restriktionen [58, 71, 94, 95]. Um diese singulären Praxisphänomene systematisch bewerten zu können, werden vier archetypische Störszenarien definiert:

- **Fall I (Axialer Abstandsfehler):** SPs ($n_{SP} \geq 1$) können nicht auf dem nominalen Abstand α_D gefahren werden. (Simulation: Stauchung auf 80 %, Streckung auf 120 %, Rückzug auf *Face Centered* (FC), $\alpha_D = 1$).
- **Fall II (Co-faktorielle Korrelation):** Ein SP ist nicht achsenrein realisierbar, was eine asymmetrische geometrische Korrelation erzeugt. (Simulation: Überlagerung durch $x_2 = 0,1$ und $x_2 = 1,0$).
- **Fall III (Stellgrößen-Scatter):** Die SPs unterliegen einem stochastischen Rauschen ($\pm 10\%$ auf x_i).
- **Fall IV (Früh-Ausfall / Zensierung):** Ein Versuchspunkt entfällt vollständig.
 - **Fall IV: ZP:** Eliminierung geometrisch redundanter ZPs.
 - **Fall IV: SP:** Asymmetrische Eliminierung extremer SPs.

Zusätzlich zum Basis-CCD ergeben sich insgesamt neun Szenarien. Es wird quantifiziert, inwiefern der Verlust der Orthogonalität zu einer Varianzinflation (VIF beziehungsweise MSE) oder zu systematischen Verzerrungen (*Bias*) führt.

Kalibrierung der Signal-to-Noise Ratio und analytische Justierung des Arbeitspunkts

Um den isolierten Einfluss von Orthogonalitätsabweichungen quantifizierbar zu machen, wird der Arbeitspunkt der Simulation in einen kritischen Bereich verschoben. Bei einer fixierten Standardabweichung von $\sigma = 5,0$ wird das Signal-Rausch-Verhältnis für die Terme zweiter Ordnung auf $SNR = 1,20$ justiert ($|\beta_{11}| = |\beta_{22}| = |\beta_{12}| = 6,0$). Die linearen Haupteffekte fließen entsprechend dem empirisch belegten *Sparsity of Effects Principle* [22] proportional dominanter mit $\beta_1 = \beta_2 = 12,0$ ($SNR = 2,40$) in das Modell ein (vgl. Tabelle 4.5). Die Wahl positiver Haupteffekte in Kombination mit negativen Krümmungstermen modelliert ein durch Sättigungseffekte physikalisch begrenztes Leistungsoptimum. Auf eine zusätzliche stochastische Streuung der Effektkoeffizienten (*Random Effects*) wird verzichtet.

Tabelle 4.5: Kalibrierte Startwerte und statistische Eigenschaften des Normalverteilungs-Basismodells

Koeffizient	β_0	β_1, β_2	β_{11}, β_{22}	β_{12}	σ
Wahrer Wert	24,0	12,0	−6,0	−6,0	5,0
SNR	–	2,40	1,20	1,20	–

Quantitative Auswertung und explorative Optimalitäts-Analyse

Die Auswertung der Praxis-Szenarien am kalibrierten Arbeitspunkt offenbart eine differenzierte Reaktion der klassischen Design-Metriken (Tabelle 4.6).

Tabelle 4.6: Matrixeigenschaften und Effizienzen zu Optimalitätskriterien der simulierten Störszenarien. Der VIF wird für alle Haupt- und quadratischen Terme dargestellt ($\hat{\beta}_0$ entfällt theoriekonform).

Szenario (Störfall)	A_2	Effizienzen [%]					VIF				
		A_{eff}	D_{eff}	G_{eff}	I_{eff}	V_{eff}	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	0,000	42,9	50,0	17,6	81,2	180,0	1,00	1,00	1,00	1,00	1,00
Fall I: Shift (−20 %)	0,037	40,3	47,0	15,9	76,0	181,7	1,04	1,00	1,00	1,04	1,00
Fall I: Shift (+20 %)	0,038	45,0	53,6	17,7	85,1	181,0	1,04	1,00	1,00	1,04	1,00
Fall I: FC	0,071	39,1	45,9	15,2	73,5	184,0	1,07	1,00	1,00	1,08	1,01
Fall II: Korrelation (leicht)	0,004	42,9	50,0	17,0	81,2	180,0	1,00	1,00	1,00	1,00	1,00
Fall II: Korrelation (stark)	0,352	42,5	51,3	13,9	80,3	183,5	1,16	1,07	1,23	1,18	1,07
Fall III: Scatter (± 10 %)	0,007	43,8	51,5	16,6	83,0	180,2	1,00	1,00	1,00	1,00	1,00
Fall IV: SP	0,183	37,6	45,3	14,3	69,0	197,2	1,22	1,00	1,00	1,22	1,05
Fall IV: ZP	0,001	44,4	52,2	18,7	85,7	164,8	1,00	1,00	1,00	1,00	1,00

- **Volumeneffekte und Prädiktionsgüte:** Die I - und D -Effizienz skalieren mit der räumlichen Ausdehnung. Der nach außen gestreckte Shift (Fall I) erzielt Bestwerte in der integrierten Prädiktionsvarianz. Der asymmetrische Entfall eines Sternpunktes (Fall IV: SP) provoziert einen signifikanten Rückgang der I -Effizienz auf $I_{\text{eff}} = 69,0$ %, während der Ausfall eines Zentralpunktes (Fall IV: ZP) die Vorhersagegüte nicht dämpft.

- **Lokale Varianzmaxima:** Eine starke co-faktorielle Korrelation (*Fall II*) erzeugt topologische Lücken im Parameterraum. Der A_2 -Indikator konvergiert gegen sein lokales Maximum von 0,352.
- **Geometrische Selektivität der Varianzinflation:** Der VIF bildet den Orthogonalitätsverlust term-spezifisch ab. Beim Ausfall des SP auf der x_1 -Achse weisen ausschließlich der zugehörige Haupteffekt $\hat{\beta}_1$ und der quadratische Term $\hat{\beta}_{11}$ eine Varianzinflation auf.

Diese Varianzerhöhung wird in Abbildung 4.2 über den MSE quantifiziert. Während die Zensierung des Zentralpunktes (*Fall IV: ZP*) in keiner signifikanten Varianzinflation resultiert, induziert der asymmetrische Freiheitsgradverlust in *Fall IV: SP* einen substanziellen Anstieg des MSE für die betroffenen Terme. Gleichzeitig belegt die Auswertung die Erwartungstreue des OLS-Schätzers: Der relative systematische Schätzfehler (Bias) verharrt im Promillebereich (vgl. Tabelle 4.7 und Abbildung 4.3).




Abbildung 4.2: Güte der Schätzer (MSE) am Arbeitspunkt $\text{SNR} = 1,20$. Geometrische Verzerrungen entladen sich primär in der Schätzvarianz (*Fall IV: SP*).

Der resultierende Einfluss auf die Trennschärfe (Tabelle 4.8 und Abbildung 4.4) zeigt folgendes Bild:

1. **Gutmütige Restriktionen:** Stochastisch verzerrte Ansteuerung (*Fall III*) und der Entfall eines Zentralpunktes (*Fall IV: ZP*) erzeugen lediglich marginale Einbußen.

Tabelle 4.7: Simulationsergebnisse: Relativer systematischer Schätzfehler (Bias) der einzelnen Koeffizienten in Prozent bezogen auf ihren Nominalwert bei $\text{SNR} = 1,20$.

Szenario (Störfall)	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	+0,05 %	−0,01 %	−0,06 %	−0,45 %	+0,17 %	+0,05 %
Fall I: Shift (−20 %)	+0,04 %	−0,00 %	−0,09 %	−0,06 %	−0,02 %	+0,31 %
Fall I: Shift (+20 %)	+0,01 %	−0,11 %	+0,05 %	−0,24 %	+0,08 %	−0,00 %
Fall I: FC	+0,08 %	+0,13 %	−0,02 %	−0,25 %	+0,13 %	−0,13 %
Fall II: Korrelation (leicht)	−0,08 %	+0,13 %	+0,08 %	−0,19 %	−0,03 %	−0,23 %
Fall II: Korrelation (stark)	−0,08 %	+0,01 %	−0,27 %	+0,55 %	−0,71 %	+0,17 %
Fall III: Scatter (± 10 %)	+0,02 %	+0,09 %	+0,19 %	+0,14 %	+0,10 %	+0,09 %
Fall IV: SP	−0,03 %	+0,14 %	+0,01 %	−0,56 %	−0,57 %	−0,07 %
Fall IV: ZP	−0,05 %	−0,13 %	−0,20 %	+0,01 %	+0,13 %	+0,07 %




Abbildung 4.3: Absolute Schätzwerte der Modellkoeffizienten für den Arbeitspunkt $\text{SNR} = 1,20$. Der Bias bleibt marginal.

2. **Kritische Restriktionen für Terme höherer Ordnung:** Sobald die periphere Geometrie kompromittiert wird, reduziert sich die Trennschärfe der quadratischen Terme maßgeblich. Der asymmetrische Entfall eines Sternpunktes (*Fall IV: SP*) führt zum signifikantesten Rückgang der Entdeckungswahrscheinlichkeit.

Tabelle 4.8: Simulationsergebnisse: Durchschnittliche Trennschärfe-Änderung ($\Delta power$) der Koeffizienten. Ein negatives Vorzeichen indiziert einen Verlust, ein positives Vorzeichen einen Gewinn an $power$ verglichen zur Referenz (Basis CCD)

Szenario (Störfall)	$power_{\beta_0}$	$power_{\beta_1}$	$power_{\beta_2}$	$power_{\beta_{12}}$	$power_{\beta_{11}}$	$power_{\beta_{22}}$
Referenz (Orthogonal)	—	—	—	—	—	—
Fall I: Shift (−20 %)	±0,0 %	−0,9 %	−0,0 %	±0,0 %	−4,5 %	−0,1 %
Fall I: Shift (+20 %)	−0,0 %	+0,3 %	−0,0 %	−0,0 %	+4,6 %	−0,1 %
Fall I: FC	±0,0 %	−1,4 %	−0,1 %	+0,1 %	−6,7 %	−0,2 %
Fall II: Korrelation (leicht)	±0,0 %	−0,1 %	−0,0 %	+0,1 %	+0,1 %	−0,0 %
Fall II: Korrelation (stark)	±0,0 %	−1,2 %	+0,3 %	+3,3 %	−3,1 %	−1,5 %
Fall III: Scatter (±10 %)	±0,0 %	−0,1 %	+0,4 %	+0,2 %	−1,2 %	+2,8 %
Fall IV: SP	±0,0 %	−4,4 %	−0,1 %	−0,3 %	−10,6 %	−1,5 %
Fall IV: ZP	−0,0 %	−0,3 %	−0,2 %	−0,8 %	−1,3 %	−0,9 %

Die Korrelation zwischen den *a priori* Design-Metriken und dem Trennschärfe-Verlust $\Delta power$ (Abbildung 4.5) belegt, dass der MSE als verlässlicher Prädiktor für den Trennschärfe-Erhalt isolierter Koeffizienten fungiert. Die I_{eff} erweist sich als robustes Maß zur Bewertung der globalen Prognosegüte.

4.2.4 Fazit: Statistische Effektivität als Basis der explorativen Versuchsplanung

Die simulativen Analysen unterstreichen eine ausgeprägte, jedoch term-spezifische Resilienz des CCD gegenüber geometrischen Abweichungen. Während topologische Brüche eine Aufweitung der Schätzvarianz provozieren, erweist sich die Detektion linearer Haupteffekte als robust, wohingegen quadratische Terme sensibel auf periphere Informationsverluste reagieren. Die bewusste Reduktion der Orthogonalität gefährdet die Identifikation der primären Einflüsse nicht, sondern schafft ein geometrisches Gestaltungsbudget. Die Minimierung der Prognoseunsicherheit auf dem




Abbildung 4.4: Trennschärfe mit 95%-Konfidenzintervallen in Abhängigkeit der simulierten Störszenarien.




Abbildung 4.5: Korrelation zwischen a priori Design-Metriken und dem resultierenden Trennschärfe-Verlust.

Extrapolationspfad ist die Voraussetzung für eine belastbare Lebensdauerprognose. Im Folgenden wird das aus topologisch unkritischen Punkten freigewordene Budget systematisch genutzt, um diese Stützstellen in Richtung des anvisierten Feldbereichs zu verschieben (**EmALT**).

4.3 Adaptive Versuchsplanung zur Extrapolationsabsicherung

In der Praxis werden **ALTs** im Bereich hoher Belastungen durchgeführt, um Ausfälle in vertretbarer Prüfzeit zu erzwingen. Das Ziel der Modellbildung ist jedoch die Prognose im Feldbereich. Das identifizierte Gestaltungsbudget wird proaktiv eingesetzt: Redundante Stützstellen werden in Richtung des anvisierten Feldbereichs verlagert. Diese topologische Rekonfiguration erzeugt asymmetrische **APs**, die das Regressionsmodell auf dem Extrapolationspfad empirisch absichern, während der Gesamtversuchsumfang N konstant bleibt [96, 97, 98].

4.3.1 Die Scaled Prediction Variance als Prognosemetrik

Zur Quantifizierung der ortsabhängigen Prognosegüte dienen die skalierte Vorhersagevarianz (**SPV**) und die unskalierte Vorhersagevarianz (**UPV**). Zur Bewertung der Extrapolationsfähigkeit erweist sich die Untersuchung mittels **VDG** und **FDS** als bedingt geeignet. Die Reduktion der **ZPs** wirkt sich nicht negativ auf die Peripherie aus (Abbildung 4.6). Das asymptotische Konvergenzverhalten (Gleichung ??) belegt, dass eine Erhöhung der Zentralpunktanzahl über $n_{ZP} \approx 3$ hinaus statistisch redundant ist.

Wird ein Sternpunkt zensiert, wächst die **SPV** in dieser Region an (Abbildung ??). Diese Asymmetrie erzeugt eine anisotrope Varianzstruktur, welche durch den **VDG** nicht richtungsaufgelöst dargestellt werden kann (Abbildung ??). Die Ausprägung offenbart erst der Konturverlauf in Abbildung 4.8. Sphärisch mittelnende Visualisierungen maskieren die erfolgskritische Richtungsabhängigkeit.




Abbildung 4.6: Vorhersagegüte bei Variation der ZP-Anzahl n_{ZP} .




Abbildung 4.7: Vorhersagegüte bei Variation der SP-Anzahl n_{SP} .




Abbildung 4.8: Dreidimensionale Darstellung der SPV und Konturverlauf für ein asymmetrisches Versuchsdesign.

4.3.2 Richtungsabhängige Bewertung: Der Extrapolation Variance Graph (EVG)

Um die SPV entlang des Vektors zum Zielpunkt zu analysieren, entwickelten Arndt und Dazer [98] den EVG. Die Varianz wird entlang eines normierten Richtungsvektors $\vec{e}$ in Abhängigkeit des Abstands r analysiert:

$$v(r, \vec{e}) = N \cdot [\mathbf{x}_0(r, \vec{e})]' \mathbf{M}^{-1} [\mathbf{x}_0(r, \vec{e})] \quad (4.3)$$

Die Auswertungsfunktion $\mathbf{x}_0(r, \vec{e})$ transformiert den abgetasteten Koordinatenpunkt $r \cdot \vec{e}$ in den korrespondierenden Polynomialvektor, welcher auf die Struktur der Informationsmatrix expandiert wird. Um die Vorhersagevarianz $v(r_{\text{fix}}, \vec{e})$ zu minimieren, wird eine Toleranzschranke q definiert:

$$\mathcal{X} = \{x_{\text{AP},i} \in \Omega \mid v(r_{\text{fix}}, \vec{e}) \leq \min(v) \cdot (1 + q)\} \quad (4.4)$$

Die Menge der zulässigen Koordinaten definiert die *Exposure-Area* $\mathcal{X}$ (Abbildung 4.9).

Werden die APs fixiert, lässt sich das EmALT-Design im Konturplot visualisieren (Abbildung 4.10). Der EVG (Abbildung 4.11) quantifiziert den Informationsgewinn




Abbildung 4.9: Die *Exposure-Area* für asymmetrische Extrapolations-APs.

entlang des Extrapolationsvektors und belegt eine substantielle Reduktion der Vorhersageunsicherheit.

4.3.3 Isolierte stochastische Validierung der asymmetrischen Topologie

Um den geometrischen Integritätsnachweis der asymmetrischen *EmALT*-Topologie formal abzuschließen (Stufe 1 der Inferenz-Kaskade), wird das Design isoliert unter *OLS*-Bedingungen evaluiert. Die Simulation quantifiziert drei Design-Konfigurationen bei konstantem $N = 13$: Das Basis-*CCD*, ein passiv ausgedünntes Design (*CCD-AP*) sowie das reallokierte *EmALT*-Design.

Die algebraische Auswertung (Tabelle 4.9) bestätigt, dass der asymmetrische Eingriff einen partiellen Verlust der Orthogonalität erzwingt (*VIF* steigt). Im direkten Vergleich zur ersatzlosen Ausdünnung belegt die *I-Effizienz* jedoch den strukturellen Mehrwert der Reallokation: Das geometrische Budget stützt die integrierte Vorhersagevarianz signifikant ab. Die fundamentale Erwartungstreue des *OLS*-Schätzers bleibt unbeschadet gewahrt (Tabelle 4.10 und Abbildung 4.12).




Abbildung 4.10: Dreidimensionale Darstellung der SPV für das EmALT-Design.




Abbildung 4.11: Vergleich von VDG und EVG für das EmALT-Design.

Tabelle 4.9: Matrixeigenschaften und Effizienzen. Der VIF wird für alle Terme dargestellt ($\hat{\beta}_0$ entfällt).

Szenario	A_2	Effizienzen [%]					VIF				
		A_{eff}	D_{eff}	G_{eff}	I_{eff}	V_{eff}	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	0,017	46,7	56,9	21,0	95,5	134,2	1,00	1,00	1,00	1,02	1,02
CCD-AP	0,373	39,2	50,4	18,5	78,3	140,3	1,27	1,27	1,00	1,31	1,31
EmALT	2,596	39,1	68,9	15,5	73,1	136,3	1,45	3,84	3,18	1,32	5,91

Tabelle 4.10: Relativer systematischer Schätzfehler (Bias) in Prozent bei OLS-Baseline ($\text{SNR} = 1,2$).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	+0,01 %	+0,02 %	+0,08 %	+0,09 %	+0,42 %	-0,41 %
CCD-AP	-0,14 %	-0,13 %	+0,14 %	+0,96 %	-0,19 %	-0,38 %
EmALT	+0,24 %	-0,22 %	+0,15 %	-0,12 %	+0,59 %	+0,10 %




Abbildung 4.12: Absolute Schätzwerte der Modellkoeffizienten im OLS-Modell.




Abbildung 4.13: Aggregierte p -Wert Histogramme im OLS-Modell.

Das EmALT-Design dämpft den Varianzanstieg (MSE) gegenüber der bloßen Ausdünnung signifikant (Tabelle 4.11). Dies resultiert in der Erhaltung der Trennschärfe (Tabelle 4.12 und Abbildung 4.14). Das Design übertrifft die reduzierte Variante substantiell und unterschreitet das $power$ -Niveau des orthogonalen Basis-CCD lediglich marginal.

Tabelle 4.11: Schätzvarianz (MSE) der einzelnen Koeffizienten bei OLS-Baseline (SNR = 1,2).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	5,00	3,10	3,15	6,21	3,54	3,56
CCD-AP	6,30	5,61	5,42	6,36	7,25	7,57
EmALT	5,33	4,89	5,32	4,95	6,97	2,05

Mit diesem Nachweis ist die topologische Stabilität gesichert. Der nachfolgende Transfer fokussiert sich auf die stochastische Lebensdauererprobung und die ökonomische Evaluation.

Tabelle 4.12: Durchschnittlicher Trennschärfe-Verlust ($\Delta power$) bei OLS-Baseline ($SNR = 1,2$).

Szenario	$power_{\beta_0}$	$power_{\beta_1}$	$power_{\beta_2}$	$power_{\beta_{12}}$	$power_{\beta_{11}}$	$power_{\beta_{22}}$
Basis CCD	—	—	—	—	—	—
CCD _{-AP}	−0,2 %	−9,1 %	−9,1 %	−5,4 %	−20,4 %	−19,4 %
EmALT	+0,0 %	−3,3 %	−4,8 %	+5,6 %	−13,0 %	+9,3 %




Abbildung 4.14: Trennschärfe der Designvarianten im OLS-Modell.

4.4 Kostenstruktur der Lebensdauererprobung

Die ganzheitliche Leistungsfähigkeit adaptiver Versuchsplan-Modifikationen erfordert eine komplementäre ökonomische Betrachtung. Die Gesamtkosten C_{Σ} werden in drei Domänen unterteilt [98]:

1. **Umgebungskosten** C_A : Standort- und laborbezogene Bereitstellungskosten C_L .
2. **Prüfstandskosten** C_T : Anlagenspezifische Ausrüstungs- und Investitionskosten.
3. **Laufende Durchführungskosten** C_S : Diese variablen Kosten skalieren direkt mit der zeitlichen Dauer der Versuchsreihe.

Das Wirknetz ist in Abbildung 4.15 visualisiert. Da die individuellen Versuchslaufzeiten t_i physikalisch zwingend von den allokierten Stressniveaus abhängen, sind die Designmatrix und die Versuchskosten stochastisch gekoppelt. Die exakte Transformation dieser Stressniveaus in beschleunigte Laufzeiten erfolgt im log-linearen Raum über das AFT-Modell, dessen Integration in die Monte-Carlo-Simulation den Erwartungswert für die Durchführungskosten $\bar{C}_S$ liefert (vgl. Abschnitt 4.5).

4.5 Übertragung auf multivariate Lebensdauermodelle

In einem finalen Syntheseschritt vollzieht das EmALT-Konzept den Transfer in die stochastische Realität der Zuverlässigkeitstechnik unter Nutzung der iterativen MLE. Die Evaluation vergleicht die drei zuvor etablierten Konfigurationen (Basis-CCD, CCD-AP, EmALT).

4.5.1 Signal-Rausch-Kalibrierung im AFT-Raum

Beim Übergang zum log-linearen AFT-Modell definiert sich die Rauschkomponente (σ_{SEV}) über das Inverse des Weibull-Formparameters b [2]:

$$\sigma_{SEV} = \frac{1}{b} \quad (4.5)$$

Mit $b = 3,0$ resultiert $\sigma_{SEV} \approx 0,33$. Die in der OLS-Basisstudie etablierte Effekthierarchie (*Sparsity of Effects*) bleibt strukturell bestehen. Um den kalibrierten Arbeitspunkt von $SNR = 1,20$ in den Weibull-Raum zu überführen, transformieren sich die Effekte




Abbildung 4.15: Struktur des Kostenmodells zur Berechnung der Gesamtkosten C_Σ .

mathematisch über diese *SEV*-Streuung: $\beta = \text{SNR} \cdot \sigma_{\text{SEV}}$. Für die quadratischen Modellkomponenten resultiert eine Effektstärke von $|0,40|$, während die dominierenden Haupteffekte sich mit $|0,80|$ parametrisieren.




Abbildung 4.16: Antwortfläche der charakteristischen Systemlebensdauer T .

Tabelle 4.13: Kalibrierte Startwerte des log-linearen Weibull-Basismodells

Koeffizient	β_0	β_1, β_2	β_{11}, β_{22}	β_{12}	σ_{SEV}
Wahrer Wert	11,51	-0,80	-0,40	0,40	0,33
SNR	–	2,40	1,20	1,20	–

4.5.2 Effizientes *L-DoE* und der Economic Extrapolation Power Index

Die finale Evaluation verknüpft die *MLE* an Weibull-verteilten Daten mit dem dynamischen Kostenmodell. Die Metrik des *EPI* bewertet die Effizienz durch die Einbeziehung der normierten Prädiktionsvarianz (*SPV*) im Extrapolationsraum und des monetären Erwartungswerts:

$$\eta_{\text{eco}} = \frac{\text{power}(\hat{\beta}_i)}{\text{SPV} \cdot E(C_{\Sigma})} \times 10^3 \quad (4.6)$$

Die Auswertung belegt die Stabilität der **MLE**. Der *Small-Sample Bias* (Tabelle 4.14) verschiebt die Krümmungsterme, jedoch kompensieren sich die Fehler auf dem Extrapolationspfad.

Tabelle 4.14: Relativer systematischer Schätzfehler (Bias) in Prozent bei GLLW-Schätzung (Weibull-Modell).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	+0,15 %	−0,08 %	+0,10 %	−0,24 %	+13,73 %	+12,79 %
CCD –AP	+0,24 %	+3,72 %	+3,39 %	+6,82 %	+23,17 %	+22,10 %
EmALT	−0,00 %	+19,55 %	−39,14 %	−47,84 %	+46,51 %	−53,26 %




Abbildung 4.17: Absolute Schätzwerte der **MLE**-Koeffizienten im Weibull-Modell.

Ein wesentlicher Vorteil des **EmALT**-Designs zeigt sich in der präziseren Schätzung des Weibull-Formparameters $\hat{b}$. Das **EmALT**-Design stabilisiert zudem die *power* der essentiellen Krümmungsterme (Abbildung 4.19).

Das **EmALT**-Design erweist sich als physikalisch-ökonomisches Optimum (Abbildung 4.20). Es dominiert die klassische *D*-Effizienz, sobald die Prädiktionsvarianz (*SPV*) im Extrapolationsraum berücksichtigt wird. Der zugehörige *EPI* für das Basis-**CCD** degradiert infolge der signifikanten Extrapolationsvarianz auf ein ineffizientes Minimum.




Abbildung 4.18: Aggregierte p -Wert Histogramme der MLE-Signifikanztests.




Abbildung 4.19: Vergleichende Analyse der MLE-power.

Tabelle 4.15: Ganzheitliche ökonomisch-statistische Gegenüberstellung aller Modellkoeffizienten. Der Index η_{eco} quantifiziert die prädiktive Effizienz unter Berücksichtigung der Erwartungskosten $E(C_{\Sigma})$.

Szenario / Ressourcen	Metrik	β_1	β_2	β_{12}	β_{11}	β_{22}
Basis CCD	$\Delta power$	—	—	—	—	—
$E(C_{\Sigma})$: 54,2 kCU	rel. Bias	−0,1 %	+0,1 %	−0,2 %	+13,7 %	+12,8 %
SPV: 30,02	η_{eco}	0,62	0,62	0,50	0,60	0,61
CCD_{AP}	$\Delta power$	−0,1 %	−0,0 %	+6,1 %	−4,5 %	−4,7 %
$E(C_{\Sigma})$: 48,2 kCU	rel. Bias	+3,7 %	+3,4 %	+6,8 %	+23,2 %	+22,1 %
SPV: 30,12	η_{eco}	0,69	0,69	0,60	0,65	0,65
EmALT	$\Delta power$	−0,2 %	−5,7 %	−16,9 %	+0,7 %	−23,6 %
$E(C_{\Sigma})$: 81,0 kCU	rel. Bias	+19,5 %	−39,1 %	−47,8 %	+46,5 %	−53,3 %
SPV: 2,39	η_{eco}	5,15	4,86	3,33	5,11	3,87




Abbildung 4.20: Exponentieller Zielkonflikt aus Prädiktionsvarianz und Erwartungskosten sowie die inverse Kausalität zwischen D -Effizienz und EPI .

Konsequenzen für die Prognoseunsicherheit im Feldbetrieb

Die Reduktion der Extrapolationsvarianz durch das **EmALT**-Design verdichtet die Konfidenzbänder der prognostizierten Überlebenswahrscheinlichkeit $R(t)$ im Feldbereich (Abbildung 4.21).




Abbildung 4.21: Vergleich der prognostizierten Überlebenswahrscheinlichkeit $R(t)$ am Feldbetriebspunkt inklusive 90 %-CI.

4.6 Methodische Synthese und Transfer

Das vorliegende Kapitel liefert den theoretischen Nachweis, dass klassische **RSDs** für die Lebensdauererprobung ökonomisch optimiert werden können. Die vollzogene Synthese liefert drei Erkenntnisse:

1. **Topologische Resilienz:** Die Identifikation der Haupteffekte ist gegenüber peripheren Modifikationen robust.
2. **Extrapolationsabsicherung:** Das **EmALT**-Design minimiert die richtungssensitive Prädiktionsvarianz im Feldbereich gezielt.

3. **Ökonomische Effizienz:** Der **EPI** belegt, dass asymmetrische, prädiktionszentrierte Designs die klassische *D*-Optimalität im Zielkonflikt zwischen Prüfkosten und Prognosegüte signifikant dominieren.

Unterliegen die physikalischen Schädigungsmechanismen beim Übergang vom Hochlast- (**ALT**) in den Feldbereich diskontinuierlichen Strukturbrüchen, verliert die rein modellbasierte Extrapolation ihre physikalische Gültigkeit. In diesem Kontext entfaltet das **EmALT**-Design seinen empirischen Mehrwert: Durch die strategische Allokation der Extrapolations-**APs** nahe dem realen Einsatzniveau fungieren diese Stützstellen als stochastische Frühwarnindikatoren. Im Rahmen der post-experimentellen Inferenz erlauben sie eine datengetriebene Verifikation, ob die im **ALT**-Raum extrahierten Degradationsgesetze im moderaten *Use-Space* Bestand haben [99]. Im nachfolgenden Kapitel 5 wird das Konzept anhand einer physischen Fallstudie verifiziert, um Zuverlässigkeitsmodelle vor unzulässigen, sicherheitskritischen Überschätzungen zu bewahren.

5 Empirische Validierung der Extrapolationsabsicherung

Die Ausführungen in Kapitel 4 erbringen auf Basis umfangreicher MCSs den theoretischen und algorithmischen Nachweis, dass das EmALT-Design im Rahmen der multivariaten, effizienten Lebensdauererprobung signifikante informationstheoretische Vorteile gegenüber klassisch orthogonalen Versuchsplänen für ALT bietet. Für den finalen Transfer dieser Methodik in die industrielle Zuverlässigkeitstechnik dient das vorliegende Kapitel der ergänzenden empirischen Validierung in der Fallstudie zum real vermessenen Hardwaredatensatz aus Untersuchungen von Arndt et al. [100]. Damit untermauert dieser Abschnitt die numerischen Ergebnisse des vorherigen Kapitels durch die Betrachtung realer Bauteilversuche an Zahnriemen für Lenksysteme in automobilen Anwendungen.

Der methodische Übergang von der Simulation zur physischen Erprobung impliziert zwei wesentliche Verschärfungen der Randbedingungen: Erstens weicht die idealisierte Gesetzmäßigkeit unendlicher Simulationsiterationen der harten statistischen Realität stark limitierter Stichprobenumfänge. Die Untersuchung basiert auf einem realen Versuchsdatensatz mit lediglich zweifacher Replikation und damit $N = 26$ Versuchspunkt-Durchführungen. Zweitens unterliegen experimentelle EoL-Versuche zwingenden physikalischen und normativen Restriktionen. Anstatt diese als Mangel zu betrachten, generieren sie aus Sicht der adaptiven Versuchsplanung durch EmALT das **geometrische Gestaltungsbudget** nach Abschnitt 4.3. Hier beispielhaft und abweichend von der rein theoriegeleiteten Ausdünnung redundanter ZPs speist sich dieses Budget im vorliegenden Fall aus dem Entfall des nördlichen und östlichen SPs - $(0; \alpha_D)$ und $(\alpha_D; 0)$ - sowie des faktoriellen Eckpunktes $(1; -1)$.

Diese topologische Limitierung ist physikalisch determiniert: Das komplexe tribologische Eingriffsverhalten des Zahnriemens verliert in diesem spezifischen, kombinierten Belastungsregime seine funktionale Plausibilität, wodurch abweichende Ausfallmechanismen provoziert werden können, vergleiche [101, 102].

Wenngleich die Prüfläufe in der Realität hier schon durchgeführt wurden, werden die als nicht realisierbar deklarierten Hochlast-Versuche zum Zweck des systematischen Design-Vergleichs konsequent aus der Design-Matrix gestrichen. Anstatt den Versuchsplan dadurch lediglich passiv auszudünnen und eine asymmetrische Varianzaufweitung in Kauf zu nehmen, wird das hypothetisch freigewordene Budget proaktiv umgewidmet: Die Aufwände werden in die direkte Peripherie des hier beispielhaft anvisierten Feldbetriebspunktes $(-1,50; -1,80)$ im Niedrigstressbereich zur Prognoseoptimierung re-alloziert. Da der originäre Basis-Datensatz nach Arndt et al. [100] diese massiv entschärften Stressniveaus naturgemäß nicht abdeckt, werden die Positionierungen und Ausfallergebnisse der APs beispielhaft aus begleitenden Untersuchungen des Erprobungsprojekts übernommen: Es liegt somit ein vollständiger ALT-Datensatz mit realen EoL-Zeiten für einen orthogonalen CCD-Versuchsplan sowie die ergänzenden APs vor. Dieser subtile methodische Transfer dient primär dem Zweck, das Wirkprinzip der EmALT-Topologie an einem kohärenten Realdatensatz methodisch geschlossen zu exemplifizieren und greifbar zu visualisieren. Entscheidend ist hierbei, dass die Reallokation algorithmisch optimiert in Relation zum Prognosepunkt und nach den in Kapitel 4 entwickelten EmALT-Kriterien in Kombination mit realen Prüfstandsbeschränkungen erfolgen kann. Tabelle 5.1 fasst alle experimentell ermittelten Ausfallzeiten des untersuchten Lenksystem-Zahnriemens für die jeweiligen Faktorkombinationen übersichtlich zusammen. Da die APs im Gegensatz zur theoretischen Simulation nun mit realen Ausfallzeiten unterlegt sind, ermöglicht dieser Datensatz einen einzigartigen, zweiseitigen Modellvergleich: Die Parameterschätzung und Lebensdauerprognose erfolgen separat für das klassische Basis-CCD (ohne APs, isoliert aus den Untersuchungen von Arndt et al. [100]) sowie für das reallokierte EmALT-Design inklusive der Ankerpunkte. Dies erlaubt nicht nur die finale Evaluation der realen Modellanpassung, der SPV sowie der verursachten Versuchskosten, sondern rückt vor allem einen fundamentalen Validierungs-Aspekt in den Fokus: Die nachfolgende Analyse liefert den empirischen Nachweis, in welchem Maße reale Degradationsdaten auf dem Extrapolationspfad das ungestützte Basis-Modell vor fatalen Fehlprädiktionen schützen und zu einer signifikant geschärften Lebensdauerprognose führen.

Tabelle 5.1: Gegenüberstellung der Versuchspläne und realisierten Ausfallzeiten t_i für das Basis-CCD und das EmALT-Design ($N = 26$) auf Basis der Datenlage aus [100] und begleitenden Prüfläufen (APs).

Run	Basis-CCD			EmALT		
	x_1	x_2	t_i [h]	x_1	x_2	t_i [h]
<i>Replikation 1</i>						
1	1,00	1,00	314144	1,00	1,00	314144
2	1,00	-1,00	1440	-2,42	-2,17	1850000
3	-1,00	1,00	625776	-1,00	1,00	625776
4	-1,00	-1,00	4760	-1,00	-1,00	4760
5	α_D	0,00	2904	-3,15	-2,56	4200000
6	$-\alpha_D$	0,00	800000	$-\alpha_D$	0,00	800000
7	0,00	α_D	78368	-3,15	-2,56	3950000
8	0,00	$-\alpha_D$	32072	0,00	$-\alpha_D$	32072
9	0,00	0,00	43472	0,00	0,00	43472
10	0,00	0,00	40144	0,00	0,00	40144
11	0,00	0,00	70440	0,00	0,00	70440
12	0,00	0,00	45296	0,00	0,00	45296
13	0,00	0,00	44560	0,00	0,00	44560
<i>Replikation 2</i>						
14	1,00	1,00	210584	1,00	1,00	210584
15	1,00	-1,00	7656	-2,42	-2,17	1910000
16	-1,00	1,00	752936	-1,00	1,00	752936
17	-1,00	-1,00	5264	-1,00	-1,00	5264
18	α_D	0,00	1440	-3,15	-2,56	4120000
19	$-\alpha_D$	0,00	709336	$-\alpha_D$	0,00	709336
20	0,00	α_D	48840	-3,15	-2,56	4300000
21	0,00	$-\alpha_D$	42728	0,00	$-\alpha_D$	42728
22	0,00	0,00	20936	0,00	0,00	20936
23	0,00	0,00	71744	0,00	0,00	71744
24	0,00	0,00	57960	0,00	0,00	57960
25	0,00	0,00	22432	0,00	0,00	22432
26	0,00	0,00	65816	0,00	0,00	65816

5.1 Modellschätzung und Anpassungsgüte

Die MLE-basierte Auswertung der Modellparameter nach Gleichung (2.50) offenbart für beide Design-Varianten zunächst messbare Diskrepanzen in der Ausprägung der Schätzwerte zu physikalischen Effekten. Abbildung 5.1 veranschaulicht die Gegenüberstellung der geschätzten Regressionskoeffizienten in $\hat{\beta}$ sowie des korrespondierenden Weibull-Formparameters $\hat{b}$.




Abbildung 5.1: Vergleich der MLE-Parameterschätzungen für das klassische Basis-CCD und das EmALT-Design am realen Datensatz. Die Integration der Ankerpunkte führt zu einer elementaren Neukalibrierung ausgewählter Haupteffekte, Wechselwirkungen und der Streuung (Formparameter $\hat{b}$).

Die Integration der Ankerpunkte modifiziert das Regressionsmodell messbar und offenbart eine wertvolle Anreicherung des ungestützten Extrapolationsmodells. Während die Konstante $\hat{\beta}_0$ sowie die Effekte $\hat{\beta}_2$ und $\hat{\beta}_{22}$ mit relativen Abweichungen von lediglich rund 2 % bis 7 % ein – im Hinblick auf den limitierten Stichprobenumfang von $N = 26$ – absolut tolerierbares und hochgradig konsistentes Grundniveau aufzeigen, erfahren andere Terme eine signifikante Neukalibrierung. So wird der Haupteffekt $\hat{\beta}_1$ durch die Ankerpunkte drastisch gedämpft ($-1,34 \rightarrow -0,62$, ca. -54%), während sich der quadratische Term $\hat{\beta}_{11}$ mehr als verdoppelt ($0,23 \rightarrow 0,57$, ca. $+148\%$). Besonders bemerkenswert ist das Verhalten der Faktoren-Interaktion $\hat{\beta}_{12}$, welche eine vollständige Vorzeichenumkehr erfährt ($0,60 \rightarrow -0,37$).

Flankierend korrigiert das **EmALT**-Design die struktur- und stichprobenbedingte Unterschätzung des Weibull-Formparameters $\hat{b}$. Das eng im Hochlastzentrum konzentrierte Basis-**CCD** schätzt mit $\hat{b} = 1,25$ eine physikalisch verhältnismäßig breite Streuung der Lebensdauern. Die realen Ankerpunkte heben diesen Wert um 33 % auf ein Niveau von $\hat{b} = 1,66$ an, was einer geringeren, deterministischeren Bauteilstreuung entspricht. Diese numerische Verschiebung der Parameter manifestiert sich visuell prägnant in den rekonstruierten Antwortflächen nach Abbildung 5.2.




Abbildung 5.2: Modellanpassung im Parameterraum (logarithmische Darstellung): Beide Regressionsflächen im direkten visuellen Vergleich. Das Basis-**CCD** extrapoliert starr aus dem Hochlastzentrum. Das **EmALT**-Design wird durch die **APs** im südwestlichen Parameterbereich gestützt und erfährt eine merkliche Dämpfung der prognostizierten Lebensdauer.

Die dreidimensionale, gemeinsame Visualisierung der Regressionsflächen liefert die ingenieurwissenschaftliche Interpretation dieser methodischen Optimierung durch Anwendung eines **EmALT**-Designs – wohl berücksichtigend, dass die Approximation der Response Surface nur eine richtungsabhängige, statistische Repräsentation der realen Lebensdauer ist: Das Basis-**CCD** approximiert die Versuchspunkte im beschleunigten Zentrum präzise entlang der Ergebnislage, extrapoliert diesen steilen Gradienten jedoch linear und ungebremst in den fernen *Use-Space*. Das **EmALT**-Design hingegen

registriert durch seine **APs**, dass die Lebensdauer bei moderateren Lasten physikalisch nicht in dem Maße ansteigt, wie es die initiale Hochlast-Extrapolation vermuten ließe. Die Response Surface erfährt durch die Ankerpunkte damit eine deutliche Dämpfung in Richtung geringerer Lebensdauern und taucht im Extrapolationsbereich messbar unter die Fläche des Basis-Modells ab. Die durch das **EmALT**-Design induzierte Ausprägung der Wirkungsfläche im Feldbereich stellt somit nicht nur eine graduelle Reduktion der Prädiktionsvarianz dar, sondern eine konsequente und empirisch gestützte Verfeinerung des Regressionsmodells. Daraus ergibt sich die Notwendigkeit, die ingenieurwissenschaftlichen Auswirkungen auf die Zuverlässigkeitsprognose am Feldpunkt zu evaluieren und die grundlegende methodische Verträglichkeit beider Ansätze zu plausibilisieren.

5.1.1 Residuenanalyse und Verifikationsdiagnostik

Die fundamentale Neukalibrierung der Modellparameter – insbesondere die Dämpfung des Haupteffekts $\hat{\beta}_1$ sowie die Vorzeichenumkehr der Interaktion $\hat{\beta}_{12}$ – wirft die methodische Frage auf, ob das **EmALT**-Design die physikalische Realität adäquat abbildet oder Schätzartefakte induziert. Zur Beantwortung dieser Fragestellung wird die Residuenstruktur beider Regressionsmodelle anhand der in Abschnitt 2.2.6 hergeleiteten diagnostischen Metriken überprüft - vgl. Abbildung 5.3.

Die Analyse der standardisierten Devianz-Residuen r_{Dev} - siehe Gleichung (2.63) - über der logarithmierten charakteristischen Lebensdauer $\ln(\hat{T})$ in Abbildung 5.3 (links) bestätigt die Homoskedastizität beider Modelle: Die Residuen streuen symmetrisch um den Nullpunkt und verharren mit Ausnahme singulärer Randbeobachtungen innerhalb der statistischen Toleranzschranken von $\pm 2\sigma$. Das **EmALT**-Design weist über den gesamten Prädiktionsbereich von $\ln(\hat{T}) = 10,4$ bis 16,0 (entsprechend einer Lebensdauer bis über 10^6 h) eine homogene, trendfreie Verteilung auf.

Flankierend liefert die Auswertung der Cox-Snell-Residuen r_{CS} (Gleichung (2.62)) in Abbildung 5.3 (rechts) den empirischen Nachweis der überlegenen Modellanpassung: Während die Residuen des Basis-**CCD** im oberen Wertebereich ($r_{\text{CS}i} > 2,0$) eine systematische Krümmung und Abweichung von den theoretischen Quantilen $-\ln(1 - F)$ aufweisen, folgen die Residuen des **EmALT**-Designs bis zu Werten von $r_{\text{CS}i} \approx 3,5$ nahezu ideal der theoretischen Winkelhalbierenden. Dies belegt, dass die Integration der Ankerpunkte einen möglichen Lack-of-Fit im Niedriglastbereich eli-




Abbildung 5.3: Residuenanalyse der Modellpassung für das Basis-CCD und das EmALT-Design am realen Prüfstandsdatensatz ($N = 26$): Standardisierte Devianz-Residuen über $\ln(\hat{T})$ (links) sowie Cox-Snell-Residuen (rechts).

minierte. Damit ist formal nachgewiesen, dass die signifikante Verschiebung der Modellparameter in $\hat{\beta}$ keine statistische Verzerrung darstellt, sondern das reale tribologische Verschleißverhalten des Zahnriemens mathematisch konsistent und frei von systematischen Anpassungsmängeln abbildet. Dieses empirische Ergebnis bestätigt die simulationsbasierten Erkenntnisse aus Kapitel 4: Die durch das EmALT-Design induzierte Umverteilung der Schätzvarianz bewahrt die statistische Signifikanz der Modelleffekte (vgl. Tabelle 4.15) und führt am realen Prüfstand zu einer signifikant überlegenen, physikalisch fundierten Modellgüte.

5.2 Konsequenzen für die Zuverlässigkeitsmodellierung

Die Korrektur der Antwortfläche wirkt sich unmittelbar auf die statistische Feldabsicherung am anvisierten Prognosepunkt $(-1,50; -1,80)$ aus. Abbildung 5.4 projiziert die parametrisierten Modelle auf den Verlauf der Überlebenswahrscheinlichkeit $\hat{R}(t)$. Dargestellt sind die Zuverlässigkeitsfunktionen auf Grundlage der Gleichungen (2.3), (2.47) und (2.60) sowie die korrespondierenden 90 %-CIs, ermittelt über die Delta-Methode auf Basis der invertierten beobachteten Fisher-Informationsmatrix $\mathbf{F}_{ob}$.




Abbildung 5.4: Empirische Lebensdauerprognose am Feldpunkt. Das EmALT-Design liefert eine radikal verkleinerte Prädiktionsvarianz (schmales Konfidenzband). Sein Median verbleibt kohärent innerhalb des weiten Vertrauensbereichs des Basis-CCD, zeichnet jedoch ein realitätsnäheres und konservativeres Ausfallverhalten.

Die Auswertung bestätigt zunächst die theoriegeleitete Erwartung zur Varianzreduktion aus Kapitel 4: Das Basis-**CCD** weist aufgrund der ungestützten Extrapolationsdistanz eine stark ausgeprägte Prädiktionsvarianz von $SPV = 55,04$ im Prognosepunkt auf. Dies führt zu einem extrem breiten Konfidenzband für die Prognose im Feldbetriebspunkt, das bei einer beispielhaften Laufzeit von 5×10^5 h eine maximale Unschärfe von 98,2 % aufspannt. Das **EmALT**-Design hingegen reduziert die Varianz durch die implementierten **APs** massiv: Die SPV kollabiert auf 4,86, wodurch sich die Breite des **CI** am Referenzpunkt auf hochpräzise 7,4 % verdichtet. Die Extrapolationsunsicherheit wird somit um einen Faktor von 11,3 minimiert.

Neben dieser Varianzdämpfung offenbart Abbildung 5.4 ein für die methodische Einordnung essenzielles Phänomen: Das **EmALT**-Design zeichnet aufgrund der Dämpfung und des höheren Formparameters zwar einen steileren, konservativeren Verlauf des Zuverlässigkeitsabfalls. Der Median-Schätzwert dieses angepassten Modells wird jedoch über weite Strecken der Laufzeit nahezu vollständig vom breiten Varianzbezug des Basis-**CCD**-Modells abgedeckt. Die Nutzung von Ankerpunkten dementiert das Basis-**CCD** nicht, sondern reichert es substanziell an. Das **EmALT**-Design überführt die valide, aber extrapolationsbedingt unscharfe Basisprognose des **CCD** in einen hochpräzisen und empirisch fundierten Vertrauenskorridor.

Diese stochastische Absicherung spiegelt sich unweigerlich in der ökonomischen Realität der Kostengleichung entsprechend Abschnitt 4.4 wider. Während das Basis-**CCD** mit aggregierten Gesamtkosten von lediglich 68,3 kCU vordergründig extrem wirtschaftlich erscheint, schlägt sich das **EmALT**-Design mit 371,2 kCU zu Buche. Dieser Kostenanstieg ist physikalisch determiniert: Die Verschiebung der **APs** in den Niedrigstress-Bereich (nahe dem Feldbetrieb) erzwingt exponentiell längere Testlaufzeiten der Prüflinge. Aus dieser Gegenüberstellung resultiert die Notwendigkeit, diesen monetären Mehraufwand objektiv zu evaluieren. Es gilt zu überprüfen, ob sich dieser Einsatz bei einem statistischen Härtetest des Basis-Modells als zwingend wirtschaftliche und stochastische Notwendigkeit erweist.

5.2.1 Confirmation Experiments: Der statistische Härtetest

Um das Basis-**CCD** einem belastbaren Härtetest zu unterziehen, wird dieses anhand der real getesteten Ankerpunkte mittels *prädiktionsintervall-basierter* Analysemethoden herausgefordert. Hierfür fungieren die **APs** als formale *Confirmation Runs* nach

Stevens und Anderson-Cook [99]. Die zugrundeliegende Prüflogik besagt: Wenn das durch das Basis-**CCD** im Hochlastbereich extrahierte Modell die physikalische Realität auch an den Rändern des Versuchsraums noch valide abbildet, müssen die realen Ausfallzeiten der fernen Ankerpunkte zwingend innerhalb des vom **CCD** prädizierten Streubandes liegen. Sollten die empirischen Ausfallzeiten dieses Intervall wider Erwarten verfehlen, wäre das Basis-Modell stochastisch falsifiziert und müsste zwingend um zusätzliche Stützstellen korrigiert werden, um fatale Fehlinterpretationen im Feldbereich zu verhindern. Dazu wird für die **AP**-Koordinaten das **Prediction Interval (PI)** des Basis-**CCD** berechnet. Da die Ausfallzeiten Weibull-verteilt sind, definiert sich das **PI** über das 5 %- und 95 %-Quantil der geschätzten Verteilung, auf welches additiv die epistemische Parameterunsicherheit über die Δ -Methode der **F** angewandt wird.

Die quantitative Auswertung dieser Konfirmationsläufe liefert ein hochgradig aufschlussreiches stochastisches Resultat: Die empirisch realisierten Ausfallzeiten an beiden peripheren Ankerpunkten (welche sich im Bereich von rund $3,95$ bis $4,30 \times 10^6$ h für die erste und $1,85$ bis $1,91 \times 10^6$ h für die zweite Stützstelle bewegen) liegen **vollständig innerhalb** der durch das Basis-**CCD** berechneten 90 %-**PIs**. Das ungestützte Basis-Modell wird durch die realen Testläufe somit formell statistisch bestätigt und keineswegs falsifiziert.

Eine ingenieurwissenschaftliche Betrachtung der berechneten Intervallgrenzen entlarvt jedoch die fundamentale Schwäche der reinen Hochlast-Extrapolation: Bedingt durch die extreme Prädiktionsvarianz spannen die Vertrauensbereiche des Basis-**CCD** an diesen Koordinaten unbrauchbare Größenordnungen auf – von minimal $3,63 \times 10^5$ h bis hin zu exorbitanten $8,23 \times 10^{12}$ h am ersten Ankerpunkt sowie von $7,11 \times 10^4$ h bis $1,51 \times 10^{10}$ h am zweiten. Dieser Härtetest verdeutlicht empirisch den Kern des Problems: Das orthogonale Basis-**CCD** besteht den formalen statistischen Test (90 % Coverage) paradoxerweise nur deshalb, weil seine ungebremschte Varianzinflation im Extrapolationsraum ein Streuband erzeugt, das mehrere Zehnerpotenzen umfasst. Für normative Zuverlässigkeitsnachweise und Garantieentscheidungen verliert es dadurch jegliche praktische Trennschärfe. Die methodische Allokation der **APs** stellt somit keine rein akademische Optimierung dar, sondern eine zwingende ingenieurwissenschaftliche Notwendigkeit: Sie zwingt das ausufernde Konfidenzband

der Hochlast-Extrapolation in ein belastbares, praxistaugliches Prognosemodell mit eng geführten und empirisch fundierten Vertrauensgrenzen.

5.2.2 Ökonomische Schlussfolgerung und industrieller Business Case

Die Validierung am extremen Randbereich durch die *Confirmation Runs* liefert den abschließenden, formellen Beleg für die Natur der **EoL**-Kostengleichung. Vordergründig suggeriert der rein monetäre Vergleich eine Ineffizienz des **EmALT**-Designs: Einem ressourcenschonenden Basis-**CCD** mit Gesamtkosten von lediglich 68,3 kCU steht im **EmALT**-Design ein geforderter Prüfstandsaufwand von 371,2 kCU gegenüber. Werden diese Versuchspläne jedoch der industriellen Realität der Zuverlässigkeitsfreigabe unterzogen, entlarvt sich die reine **ALT**-Kostenreduktion des Basis-Designs als irreführende Investition.

Der entscheidende ingenieurswissenschaftliche Maßstab für die Testeffizienz ist nicht die alleinige Minimierung der nominalen Prüfkosten, sondern die Minimierung von Garantierisiken bei gleichzeitiger Sicherstellung der *Time-to-Market*. Das Basis-**CCD** erkaufte sich seine geringen nominellen Testkosten durch eine Prädiktionsunsicherheit, die für normative Sicherheitsnachweise unzureichend ist: Die resultierenden Konfidenzbänder spannen am Prognosepunkt eine rechnerische Überlebenswahrscheinlichkeit zwischen nahezu 0 % und 100 % auf, wodurch eine belastbare Aussage zur Feldbewährung unmöglich wird.

Die fundamentale Überlegenheit der topologischen Anpassung offenbart sich beim Vergleich mit der vermeintlich idealen Alternative: einem direkt auf den Prognosepunkt zentrierten, orthogonalen Feld-**CCD** (13 Versuchspunkte mit zwei Replikationen, $N = 26$). Ein solcher Versuchsplan würde zwar die Extrapolationsunschärfe eliminieren, müsste jedoch vollständig unter unbeschleunigten, feldnahen Bedingungen betrieben werden. Die analytische Kostenprognose entlarvt die ökonomische Inkompatibilität dieses theoretischen Optimums mit industriellen Entwicklungszyklen: Der Feld-**CCD** würde an dieser Stelle exorbitante Prüfkosten von 22 152,0 kCU verursachen. Dieser extreme Aufwand blockiert nicht nur immense Prüfstandskapazitäten, sondern sprengt auch jegliche Entwicklungszeitpläne im Sinne der *Time-to-Market* vollständig.

Vor diesem Hintergrund transformiert sich die scheinbare Kostendifferenz von rund 300 kCU des **EmALT**-Designs im Vergleich zum Basis-**CCD** in eine hochprofitable In-

vestitionsprämie. Das **EmALT**-Design agiert hierbei als hocheffiziente mathematisch-geometrische Brücke: Durch das strategische Re-Investment der asymmetrischen Ankerpunkte komprimiert es die Prognoseunschärfe im anvisierten Feld-Betriebspunkt auf präzise 7,4 %. Es realisiert somit die stochastische Präzision eines echten Feldtests für einen Bruchteil von dessen Kosten (lediglich ca. 1,68 % des Feld-CCD-Aufwands) und bewahrt gleichzeitig den signifikanten Beschleunigungsvorteil der klassischen **ALT**-Methodik.

Die adaptive Nutzung des topologischen Gestaltungsbudgets legitimiert sich somit nicht allein aus informationstheoretischer Ästhetik. Sie etabliert sich vielmehr als unabdingbares industrielles Steuerungswerkzeug, das die Vorhersagegüte schärft, konservative Systemreserven vor teurer Überdimensionierung schützt und das Zuverlässigkeitsmanagement befähigt, harte, wirtschaftlich belastbare Garantieentscheidungen zu treffen.

6 Zusammenfassung und Ausblick

Die vorliegende Arbeit löst den fundamentalen methodischen Konflikt auf, der einer effizienten, multivariaten Zuverlässigkeitsmodellierung bislang im Wege steht. Sie beantwortet die zentrale Forschungsfrage, wie klassische **RSDs** für die spezifischen Zwecke des **ALT** effizient geplant und individuell adaptiert werden können. Der erarbeitete Paradigmenwechsel – weg von der starren Maximierung klassischer Design-Volumina hin zu einer stochastisch und ökonomisch ausbalancierten Extrapolationsabsicherung unter Beibehaltung des Prüfumfangs **N** - beantwortet die in Kapitel 3 formulierte Hauptforschungsfrage sowie die zugehörigen Teilforschungsfragen abschließend. Dieser Erkenntnisgewinn manifestiert sich in fünf zentralen wissenschaftlichen Säulen:

1. Dynamische Systematik der Parametersелеktion:

Die Identifikation der maßgeblichen Stressfaktoren erfordert bereits in der qualitativen Screening-Phase eine Abkehr von starren methodischen Schablonen. Der entwickelte heuristische Screening-Ansatz (Kapitel ??) belegt, dass die Effizienz der Variablenselektion nur durch die explizite Berücksichtigung latenter Wechselwirkungen sowie der dynamischen Änderung von Aktivmengen maximiert werden kann. Dies legt das unabdingbare Fundament für alle nachfolgenden quantitativen Modellierungen.

2. Limitierung klassischer Optimalitätskriterien:

Die methodische Untersuchung beweist, dass volumenbasierte Optimalitätsmaße (insbesondere die als Standard verbreitete klassische *D*-Effizienz) für **EoL**-Versuche systematisch ineffizient sind. Da der Fokus beschleunigter Prüfungen nicht auf der Interpolation, sondern auf der weiten Extrapolation in den Feldbereich liegt, führt ein rein orthogonal ausgerichtetes Design zu einer unzulässig hohen skalierten Prädiktionsvarianz (**SPV**) am fernen Prognosepunkt.

3. Adaptionstrategie mittels topologischer Resilienz (Teilforschungsfrage 1):

Umfangreiche Sensitivitätsanalysen decken auf, dass etablierte Standard-Versuchspläne wie das CCD eine unerwartet hohe topologische Resilienz aufweisen. Der asymmetrische Entfall unkritischer Stützstellen bewirkt tolerierbare Einbußen in der statistischen Trennschärfe (*power*) der Haupteffekte. Diese Erkenntnis legitimiert den bewussten Verzicht auf strikte Orthogonalität und eröffnet dem Versuchsplaner ein wertvolles **geometrisches Gestaltungsbudget**, um den klassischen Augmentierungs-Gedanken isometrisch ($N_{\text{adaptiv}} \leq N_{\text{CCD}}$) durch gezielte Stützstellen-Reallokation fortzuführen.

4. Bewertungsmethodik und physikalisch-ökonomisches Optimum (Teilforschungsfrage 2):

Die proaktive Umwidmung des Gestaltungsbudgets in asymmetrische Ankerpunkte (APs) nahe dem Feldbereich (EmALT-Methodik) minimiert die Extrapolationsvarianz zielgerichtet. Um die Auswirkungen dieser Orthogonalitätsmanipulationen quantitativ zu bewerten, dient der richtungssensitive EVG als geometrischer Indikator. Flankierend überführt der Economic Extrapolation Power Index (EPI) die reine statistische *Effektivität* (Trennschärfe und Prädiktionsvarianz) unter Berücksichtigung exponentiell skalierender Prüflaufzeiten in eine ganzheitliche ökonomische *Effizienz*. Die Bilanzierung weist nach, dass das EmALT-Design das globale Pareto-Optimum aus reduzierter Prognoseunsicherheit und vertretbaren Prüfstandskosten darstellt.

5. Empirische Validierung und methodische Notwendigkeit:

Die industrielle Fallstudie liefert anhand realer Prüfstandsdaten den abschließenden Beweis, dass die Extrapolationsabsicherung keine rein theoretische Optimierung darstellt. Prädiktionsintervall-basierte Härtetests (*Confirmation Experiments*) belegen empirisch, dass ein ungestütztes Basis-Modell bei reiner Hochlast-Abtastung im fernen Feldbereich infolge massiver Varianzinflation jegliche praktische Aussagekraft einbüßt. Die methodische Allokation von Ankerpunkten erweist sich somit als zwingende Notwendigkeit, um Zuverlässigkeitsmodelle vor sicherheitskritischen Überschätzungen im Feldbetrieb zu bewahren und belastbare normative Nachweise zu ermöglichen.

Zusammenfassend lässt sich konstatieren, dass die entwickelte Methodik weit über den Rahmen der hier betrachteten Referenzdesigns und spezifischen Arbeitspunkte hinausreicht. Abseits der sorgfältigen numerischen Beweisführung etabliert die vorliegende Arbeit einen **allgemeingültigen Analyse-Leitpfad**. Das geschaffene Instrumentarium - bestehend aus richtungssensitiver Varianzbewertung (EVG), stochastisch-ökonomischer Bilanzierung (EPI) und prädiktiver Validierung (*Confirmation Experiments*) - dient künftig als universelles Leitgerüst. Es befähigt den Versuchsplaner, prinzipiell beliebige Modifikationen an multivariaten Testdesigns quantitativ zu charakterisieren, objektiv zu bewerten und effiziente Lebensdauerversuche in unterschiedlichsten industriellen Kontexten systematisch abzusichern.

6.1 Diskussion

Die entwickelte Methodik bietet ein weitreichendes Instrumentarium zur Steigerung der Modelleffizienz, bedarf jedoch hinsichtlich ihrer Anwendbarkeit und Skalierbarkeit einer kritischen ingenieurwissenschaftlichen Einordnung.

Die fundamentale Prämisse der Extrapolationsabsicherung durch EmALT beruht auf der Annahme einer stetigen Degradationskinematik. Das log-lineare AFT-Modell geht von einem einheitlichen Ausfallmechanismus über den gesamten abgetasteten Parameterraum aus. Die Ankerpunkte verschieben die empirische Absicherung zwar signifikant näher an den Feldbereich und reduzieren das Risiko unerkannter Nichtlinearitäten im Vergleich zur klassischen Hochlast-Prüfung massiv. Abrupte physikalische Mechanismenwechsel, die erst bei noch geringeren Lasten (zwischen den APs und dem nominellen Feld-Niveau) auftreten, kann jedoch auch dieses Design rein datenbasiert nicht a priori prädictieren. Das Modell verbleibt folglich eine stochastische Approximation der Realität, die stets durch physikalisches Domänenwissen plausibilisiert werden muss.

Eine zentrale methodische Randbedingung der adaptiven Versuchsplanung liegt zudem in der inhärenten Kopplung an das verfügbare *A-priori*-Wissen [72]. Die optimale Platzierung der Ankerpunkte innerhalb der *Exposure-Area* (gestützt durch den EVG) sowie die Vorabkalkulation des EPI erfordern initiale Annahmen über die zugrundeliegenden Weibull-Parameter und das Kostengefüge. Entspricht die frühe Schätzung der Effektgrößen nicht der wahren Systemkinematik, verschiebt sich die topologische

Effizienz des konzipierten Versuchsplans. Die Methodik ist somit in hohem Maße an die Qualität der vorangegangenen Screening-Phase gebunden.

Hinsichtlich der algorithmischen Skalierbarkeit konzentrieren sich die grafischen und analytischen Nachweise im Rahmen dieser Arbeit auf den zweidimensionalen Versuchsraum ($k = 2$). Während die Berechnungen der Informationsmatrix, der SPV sowie der Trennschärfe mathematisch dimensionsunabhängig operieren, steigt die Komplexität der Identifikation und Visualisierung vorteilhafter APs in höherdimensionalen Parameterräumen signifikant an. Die Verortung von Ankerpunkten auf Basis rasterartiger Auswertungen stößt bei multivariaten Problemen mit drei oder mehr interagierenden Stressfaktoren an rechnerische und visuelle Grenzen.

6.2 Ausblick

Aus den identifizierten Restriktionen leiten sich direkte Impulse für die weiterführende wissenschaftliche Forschung im Schnittfeld von Zuverlässigkeitstechnik und statistischer Versuchsplanung ab.

Zur Adressierung des dimensionalen Skalierungsproblems empfiehlt sich die Entwicklung automatisierter Optimierungsalgorithmen. Die Überführung der EmALT-Positionierung in ein deterministisches *Constrained Optimization Problem* - bei welchem Algorithmen die Ankerpunkte unter Einhaltung numerischer SPV-Schranken und anlagenspezifischer Parametergrenzen selbstständig in mehrdimensionalen Räumen allokieren - beschleunigt den industriellen Planungsprozess und macht ihn unabhängig von manuellen, visuellen EVG-Auswertungen.

Um die Abhängigkeit von initialem *A-priori*-Wissen zu reduzieren, bietet die Integration der EmALT-Methodik in sequenzielle oder Bayes'sche Versuchsplanungsstrategien ein herausragendes Potenzial [3, 72, 103]. Ein dynamisches DoE, welches erste Ausfallereignisse aus dem faktoriellen Hochlast-Kern in Echtzeit auswertet, um die Koordinaten der nachgelagerten Ankerpunkte laufend zu aktualisieren und an das sich abzeichnende Ausfallverhalten anzupassen, maximiert die Effizienz der experimentellen Ressourcenallokation.

Schließlich erfordert die Generalisierung des Ansatzes eine systematische Ausweitung jenseits des hier fokussierten AFT-Modells für isolierte Totalausfälle. Die Übertragung der gerichteten Extrapolationsabsicherung auf Modelle mit konkurrieren-

den Ausfallmechanismen (*Competing Risks*) oder auf Degradationsmodelle, bei denen der kontinuierliche Verschleißverlauf als stochastische Zielgröße dient, stellt den logischen nächsten Paradigmenwechsel dar. Dies erweitert den Anwendungsbereich der **EmALT**-Strategie von der klassischen Lebensdauerprüfung auf die proaktive Zustandsüberwachung (*Condition Monitoring*) und zukunftsweisende *Predictive-Maintenance*-Architekturen.

Literatur

- [1] B. Bertsche und M. Dazer. *Zuverlässigkeit im Fahrzeug- und Maschinenbau: Ermittlung von Bauteil- und System-Zuverlässigkeiten*. 4. Auflage. Berlin und Heidelberg: Springer Vieweg, 2022. ISBN: 978-3-662-65023-3. DOI: [10.1007/978-3-662-65024-0](https://doi.org/10.1007/978-3-662-65024-0).
- [2] W. Q. Meeker, L. A. Escobar und F. G. Pascual. *Statistical methods for reliability data*. Second edition. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2022. ISBN: 978-1-118-11545-9.
- [3] S. E. Rigdon, R. Pan, D. C. Montgomery und L. J. Freeman. *Design of experiments for reliability achievement*. Hoboken, NJ: Wiley, 2022. ISBN: 9781119237693. DOI: [10.1002/9781119237754](https://doi.org/10.1002/9781119237754).
- [4] A. Kremer. „Statistische Versuchsplanung in der Lebensdauererprobung mit Vertrauensintervallen“. Diss. 2021. DOI: [10.18419/OPUS-11728](https://doi.org/10.18419/OPUS-11728).
- [5] A. Birolini. *Reliability Engineering*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2017. ISBN: 978-3-662-54208-8. DOI: [10.1007/978-3-662-54209-5](https://doi.org/10.1007/978-3-662-54209-5).
- [6] G. Yang. *Life cycle reliability engineering*. Hoboken, N.J.: Wiley, 2007. ISBN: 9780471715290. URL: <http://www.loc.gov/catdir/enhancements/fy0740/2006019150-b.html>.
- [7] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot und G. Tutz. *Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2016. ISBN: 978-3-662-50371-3. DOI: [10.1007/978-3-662-50372-0](https://doi.org/10.1007/978-3-662-50372-0).
- [8] E. L. Kaplan und P. Meier. „Nonparametric Estimation from Incomplete Observations“. In: *Journal of the American Statistical Association* 53.282 (1958), S. 457. ISSN: 01621459. DOI: [10.2307/2281868](https://doi.org/10.2307/2281868).
- [9] J. Hedderich und L. Sachs. *Angewandte Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2020. ISBN: 978-3-662-62293-3. DOI: [10.1007/978-3-662-62294-0](https://doi.org/10.1007/978-3-662-62294-0).

- [10] H. Rinne. *The Weibull Distribution: A Handbook*. 1st ed. London: CRC Press LLC, 2008. ISBN: 978-1-4200-8743-7. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=1633687>.
- [11] D. Kececioglu. *Reliability & life testing handbook*. Lancaster, PA: DEStech Publications, 2002. ISBN: 1-932078-03-7.
- [12] W. Nelson. *Accelerated Testing: Statistical Models, Test Plans, and Data Analysis*. 1st ed. Bd. v.344. Wiley Series in Probability and Statistics Series. Newark: John Wiley & Sons Incorporated, 1990. ISBN: 978-0471697367. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=469757>.
- [13] J. D. Kalbfleisch. *The statistical analysis of failure time data*. 2nd ed. Wiley series in probability and statistics. Hoboken, N.J.: J. Wiley, 2002. ISBN: 047136357X. DOI: [10.1002/9781118032985](https://doi.org/10.1002/9781118032985).
- [14] W. Nelson. *Applied Life Data Analysis*. Bd. v.577. Wiley series in probability and statistics. Hoboken: John Wiley & Sons Inc, 2005. ISBN: 9780471644620. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226561>.
- [15] H. Qiao und C. P. Tsokos. „Parameter estimation of the Weibull probability distribution“. In: *Mathematics and Computers in Simulation* 37.1 (1994), S. 47–55. ISSN: 0378-4754. DOI: [10.1016/0378-4754\(94\)90058-2](https://doi.org/10.1016/0378-4754(94)90058-2).
- [16] A. Kremer und B. Bertsche. „A New Approach for Parametrizing Multidimensional Lifetime Models“. In: *Proceedings of the 29th European Safety and Reliability Conference (ESREL)*. Hrsg. von M. Beer und E. Zio. Europe und Singapore: European Safety and Reliability Association und Research Publishing Services, 2019, S. 715–722. ISBN: 978-981-11-2724-3. DOI: [10.3850/978-981-11-2724-3\u005Ctextunderscore0443-cd](https://doi.org/10.3850/978-981-11-2724-3\u005Ctextunderscore0443-cd).
- [17] R. B. Abernethy. *The new Weibull handbook: Reliability & statistical analysis for predicting life, safety, risk, support costs, failures, and forecasting warranty claims, substantiation and accelerated testing, using Weibull, log normal, Crow-AMSAA, Probit, and Kaplan-meier Models*. 5. ed. North Palm Beach, Fla.: R.B. Abernethy, 2006. ISBN: 0965306232.

-
- [18] H. Hirose. „Bias correction for the maximum likelihood estimates in the two-parameter Weibull distribution“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 6.1 (1999), S. 66–68. ISSN: 10709878. DOI: [10.1109/94.752011](https://doi.org/10.1109/94.752011).
- [19] R. Ross. „Bias and standard deviation due to Weibull parameter estimation for small data sets“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 3.1 (1996), S. 28–42. ISSN: 10709878. DOI: [10.1109/94.485512](https://doi.org/10.1109/94.485512).
- [20] R. A. Fisher. *The Design of Experiments*. Edinburgh: Oliver & Boyd, 1935.
- [21] G. E. P. Box, W. G. Hunter und J. S. Hunter. *Statistics for experimenters: An introduction to design, data analysis, and model building*. Wiley series in probability and mathematical statistics. New York: Wiley, 1978. ISBN: 0471093157. URL: <http://www.loc.gov/catdir/description/wiley033/77015087.html>.
- [22] D. C. Montgomery. *Design and Analysis of Experiments*. 10th. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2020. ISBN: 9781119722106.
- [23] D. E. Coleman und D. C. Montgomery. „A Systematic Approach to Planning for a Designed Industrial Experiment“. In: *Technometrics* 35.1 (1993), S. 1. ISSN: 0040-1706. DOI: [10.2307/1269280](https://doi.org/10.2307/1269280).
- [24] M. Arndt, M. Dazer, W. Raither und B. Bertsche. „Parameter assessment for reliability modeling of machine components using heuristic screening“. In: *Forschung im Ingenieurwesen* 87.4 (2023), S. 1347–1370. ISSN: 0015-7899. DOI: [10.1007/s10010-023-00711-5](https://doi.org/10.1007/s10010-023-00711-5).
- [25] C. Gundlach. „Entwicklung eines ganzheitlichen Vorgehensmodells zur problemorientierten Anwendung des statistischen Versuchsplanung“. Zugl.: Kassel, Univ., Diss, 2004. Kassel. URL: <http://d-nb.info/971843546/34>.
- [26] B. Mayers. *Prozeß- und Produktoptimierung mit Hilfe der statistischen Versuchsmethodik: Zugl.: Aachen, Techn. Hochsch., Diss., 1997*. Als Ms. gedr. Bd. 97,9. Berichte aus der Produktionstechnik. Aachen: Shaker, 1997. ISBN: 3826524977.
- [27] G. Pahl, W. Beitz, J. Feldhusen und K.-H. Grote. *Engineering design: A systematic approach*. 3. ed. London: Springer, 2007. ISBN: 978-1-84628-318-5. DOI: [10.1007/978-1-84628-319-2](https://doi.org/10.1007/978-1-84628-319-2).

- [28] C.-F. Wu und M. Hamada. *Experiments: Planning, analysis and optimization*. Third edition. Wiley series in probability and statistics. Hoboken, NJ, USA: Wiley, 2021. ISBN: 9781119470106. URL: <https://zbmath.org/?q=an%3A1460.62003>.
- [29] W. F. Daenzer und R. Haberfellner, Hrsg. *Systems Engineering: Methodik und Praxis*. 11., durchges. Aufl. Zürich: Verl. Industrielle Organisation, 2002. ISBN: 385743998X.
- [30] U. Lindemann, M. Maurer und T. Braun. *Structural Complexity Management: An Approach for the Field of Product Design*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008. ISBN: 978-3-540-87888-9. DOI: [10.1007/978-3-540-87889-6](https://doi.org/10.1007/978-3-540-87889-6).
- [31] K. Siebertz, D. van Bebbler und T. Hochkirchen. *Statistische Versuchsplanung: Design of Experiments (DoE)*. 3. Auflage. VDI-Buch. Berlin und Heidelberg: Springer Vieweg, 2026. ISBN: 978-3-662-73090-4.
- [32] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 10., überarbeitete Auflage. Praxisreihe Qualität. München: Hanser, 2020. ISBN: 978-3-446-46397-4.
- [33] D. C. Montgomery, E. A. Peck und G. G. Vining. *Introduction to linear regression analysis*. Sixth edition. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2021. ISBN: 978-1-119-57872-7.
- [34] E. M. Monroe und R. Pan. „Experimental Design Considerations for Accelerated Life Tests with Nonlinear Constraints and Censoring“. In: *Journal of Quality Technology* 40.4 (2008), S. 355–367. ISSN: 0022-4065. DOI: [10.1080/00224065.2008.11917742](https://doi.org/10.1080/00224065.2008.11917742).
- [35] G. E. P. Box und J. S. Hunter. „Multi-Factor Experimental Designs for Exploring Response Surfaces“. In: *The Annals of Mathematical Statistics* 28.1 (1957), S. 195–241.
- [36] R. H. Myers, D. C. Montgomery und C. M. Anderson-Cook. *Response Surface Methodology: Process and Product Optimization Using Designed Experiments*. 4. Aufl. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2016. ISBN: 978-1-118-91601-8.

-
- [37] G. E. P. Box und D. W. Behnken. „Some New Three Level Designs for the Study of Quantitative Variables“. In: *Technometrics* 2 (1960), S. 455–475. ISSN: 0040-1706.
- [38] B. Jones und C. J. Nachtsheim. „Efficient Designs With Minimal Aliasing“. In: *Technometrics* 53.1 (2011), S. 62–71. ISSN: 0040-1706. DOI: [10.1198/TECH.2010.09113](https://doi.org/10.1198/TECH.2010.09113).
- [39] P. Goos und B. A. Jones. *Optimal Design of Experiments: A Case Study Approach*. 1st. Hoboken, NJ: John Wiley & Sons, Inc, 2011. ISBN: 9780470744611.
- [40] A. M. Dean, D. Voss und D. Draguljić. *Design and analysis of experiments*. Second edition. Springer texts in statistics. Cham: Springer, 2017. ISBN: 978-3-319-52248-7. DOI: [10.1007/978-3-319-52250-0](https://doi.org/10.1007/978-3-319-52250-0).
- [41] G. E. P. Box und K. B. Wilson. „On the Experimental Attainment of Optimum Conditions“. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 13.1 (1951), S. 1–45. ISSN: 00359246. URL: <http://www.jstor.org/stable/2983966> (besucht am 23. 03. 2023).
- [42] G. E. P. Box, S. Bisgaard und C. Fung. „An explanation and critique of taguchi’s contributions to quality engineering“. In: *Quality and Reliability Engineering International* 4.2 (1988), S. 123–131. ISSN: 0748-8017. DOI: [10.1002/qre.4680040207](https://doi.org/10.1002/qre.4680040207).
- [43] S. Bisgaard. „A Conceptual Framework for the use of Quality Concepts and Statistical Methods in Product Design“. In: *Journal of Engineering Design* 3.1 (1992), S. 31–47. ISSN: 0954-4828. DOI: [10.1080/09544829208914746](https://doi.org/10.1080/09544829208914746).
- [44] K. G. Russell. *Design of experiments for generalized linear models*. Chapman and Hall/CRC Interdisciplinary Statistics Ser. Boca Raton, London und New York: CRC Press Taylor & Francis Group, 2019. ISBN: 9780429057489. DOI: [10.1201/9780429057489](https://doi.org/10.1201/9780429057489).
- [45] I. Paschal und I. Fortune. „Performance Evaluation of Custom A-, D-, and I-Optimal Designs for Non-Standard Second-Order Models“. In: *American Journal of Theoretical and Applied Statistics* 13.5 (2024), S. 92–114. ISSN: 2326-8999. DOI: [10.11648/j.ajtas.20241305.11](https://doi.org/10.11648/j.ajtas.20241305.11).

- [46] F. Pukelsheim. *Optimal design of experiments: Originally published: New York : J. Wiley, 1993. Classic ed. Bd. 50. Classics in applied mathematics. Philadelphia, Pa.: Society for Industrial and Applied Mathematics (SIAM 3600 Market Street Floor 6 Philadelphia PA 19104), 2006. ISBN: 9780898716047. DOI: [10.1137/1.9780898719109](https://doi.org/10.1137/1.9780898719109).*
- [47] M. Risberg Ellekjær und S. Bisgaard. „The use of experimental design in the development of new products“. In: *International Journal of Quality Science* 3.3 (1998), S. 254–274. ISSN: 1359-8538. DOI: [10.1108/13598539810229230](https://doi.org/10.1108/13598539810229230).
- [48] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 9., überarbeitete Auflage. Hanser eLibrary. München: Hanser, 2016. ISBN: 978-3-446-44716-5. DOI: [10.3139/9783446447172?locatt=mode:legacy](https://doi.org/10.3139/9783446447172?locatt=mode:legacy).
- [49] R. H. Myers, D. C. Montgomery, G. G. Vining und T. J. Robinson. *Generalized linear models: With applications in engineering and the sciences*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2010. ISBN: 9780470454633. DOI: [10.1002/9780470556986](https://doi.org/10.1002/9780470556986).
- [50] A. Zahran, C. M. Anderson-Cook und R. H. Myers. „Fraction of Design Space to Assess Prediction Capability of Response Surface Designs“. In: *Journal of Quality Technology* 35.4 (2003), S. 377–386. ISSN: 0022-4065.
- [51] A. Giovannitti-Jensen und R. H. Myers. „Graphical Assessment of the Prediction Capability of Response Surface Designs“. In: *Technometrics* 31.2 (1989), S. 159–171. ISSN: 0040-1706.
- [52] H. B. Goldfarb, C. M. Borror, D. C. Montgomery und C. M. Anderson-Cook. „Three-Dimensional Variance Dispersion Graphs for Mixture-Process Experiments“. In: *Journal of Quality Technology* 36.1 (2004), S. 109–124. ISSN: 0022-4065. DOI: [10.1080/00224065.2004.11980255](https://doi.org/10.1080/00224065.2004.11980255).
- [53] A. Ozol-Godfrey, C. M. Anderson-Cook und D. C. Montgomery. „Fraction of Design Space Plots for Examining Model Robustness“. In: *Journal of Quality Technology* 37.3 (2005), S. 223–235. ISSN: 0022-4065. DOI: [10.1080/00224065.2005.11980323](https://doi.org/10.1080/00224065.2005.11980323).
- [54] J. J. Borkowski, W. Limmun und B. Chomtee. „Factorwise variance dispersion graphs“. In: *Communications in Statistics - Theory and Methods* 51.23 (2022), S. 8427–8445. ISSN: 0361-0926. DOI: [10.1080/03610926.2021.1897144](https://doi.org/10.1080/03610926.2021.1897144).

-
- [55] R. H. Myers, G. G. Vining, A. Giovannitti-Jensen und S. L. Myers. „Variance Dispersion Properties of Second-Order Response Surface Designs“. In: *Journal of Quality Technology* 24.1 (1992), S. 1–11. ISSN: 0022-4065. DOI: [10.1080/00224065.1992.11979368](https://doi.org/10.1080/00224065.1992.11979368).
- [56] P. Schoonees, N. Le Roux und R. Coetzer. „Flexible Graphical Assessment of Experimental Designs in R : The vdg Package“. In: *Journal of Statistical Software* 74.3 (2016). DOI: [10.18637/jss.v074.i03](https://doi.org/10.18637/jss.v074.i03).
- [57] G. E. P. Box und N. R. Draper. *Response surfaces, mixtures, and ridge analyses*. 2. ed. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2007. ISBN: 9780470053577. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2006043975-b.html>.
- [58] H. Ahn. „Central Composite Design for the Experiments with Replicate Runs at Factorial and Axial Points“. In: *Industrial Engineering* 349 (2015), S. 969–979.
- [59] D. A. Belsley. *Regression diagnostics: Identifying influential data and sources of collinearity*. Wiley series in probability and statistics. New York: Wiley, 2004. ISBN: 9780471725145. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226535>.
- [60] L. Fahrmeir, T. Kneib und S. Lang. *Regression: Modelle, Methoden und Anwendungen*. 2. Auflage. Statistik und ihre Anwendungen. Heidelberg und Berlin: Springer, 2009. ISBN: 978-3-642-01836-7. DOI: [10.1007/978-3-642-01837-4](https://doi.org/10.1007/978-3-642-01837-4).
- [61] E. M. Monroe, R. Pan, C. M. Anderson-Cook, D. C. Montgomery und C. M. Borrór. „A generalized linear model approach to designing accelerated life test experiments“. In: *Quality and Reliability Engineering International* 27.4 (2011), S. 595–607. ISSN: 0748-8017. DOI: [10.1002/qre.1143](https://doi.org/10.1002/qre.1143).
- [62] E. M. Monroe, R. Pan, C. M. Anderson-Cook, D. C. Montgomery und C. M. Borrór. „Sensitivity Analysis of Optimal Designs for Accelerated Life Testing“. In: *Journal of Quality Technology* 42.2 (2010), S. 121–135. ISSN: 0022-4065. DOI: [10.1080/00224065.2010.11917811](https://doi.org/10.1080/00224065.2010.11917811).
- [63] K. Seo und R. Pan. „ALTopt: An R Package for Optimal Experimental Design of Accelerated Life Testing“. In: *The R Journal* 7.2 (2015), S. 177. DOI: [10.32614/RJ-2015-029](https://doi.org/10.32614/RJ-2015-029).

- [64] S. J. Walsh, L. Lu und C. M. Anderson-Cook. „I -optimal or G -optimal: Do we have to choose?“ In: *Quality Engineering* 36.2 (2024), S. 227–248. ISSN: 0898-2112. DOI: [10.1080/08982112.2023.2194963](https://doi.org/10.1080/08982112.2023.2194963).
- [65] A. C. Atkinson, A. N. Donev und R. D. Tobias. *Optimum Experimental Designs, with SAS*. 1st. New York: Oxford University Press Inc, 2007. ISBN: 9780199296590.
- [66] P. Goos. „OMARS Designs for Factor Screening and Response Surface Experimentation in One Step: A Review“. In: *WIREs Computational Statistics* 17.2 (2025). ISSN: 1939-5108. DOI: [10.1002/wics.70018](https://doi.org/10.1002/wics.70018).
- [67] J. Núñez Ares und P. Goos. „Enumeration and Multicriteria Selection of Orthogonal Minimally Aliased Response Surface Designs“. In: *Technometrics* 62.1 (2020), S. 21–36. ISSN: 0040-1706. DOI: [10.1080/00401706.2018.1549103](https://doi.org/10.1080/00401706.2018.1549103).
- [68] J. Cohen. *Statistical power analysis for the behavioral sciences*. Second edition. Hillsdale, NJ: Lawrence Erlbaum Associates Publishers, 1988. ISBN: 9781134742707. DOI: [10.4324/9780203771587](https://doi.org/10.4324/9780203771587).
- [69] M. H. Kutner, C. J. Nachtsheim, J. Neter und W. Li. *Applied Linear Statistical Models*. 5. ed. McGraw-Hill/Irwin series Operations and decision sciences. Boston, Mass.: McGraw-Hill Irwin, 2005. ISBN: 0072386886. URL: <http://www.loc.gov/catdir/bios/mh042/2004052447.html>.
- [70] C. E. McCulloch und S. R. Searle. *Generalized, linear, and mixed models*. A Wiley-Interscience publication. New York und Weinheim: Wiley, 2001. ISBN: 9780471193647. DOI: [59430](https://doi.org/10.1002/9780471193647).
- [71] M. Arndt, P. Mell und M. Dazer. „Generic effects of deviations from test design orthogonality on test power and regression modelling of Central-Composite Designs“. In: *Proceedings of the 16th International Probabilistic Safety Assessment and Management Conference (PSAM16)*. Bd. PSAM 16. Honolulu, HI, USA, 2022.
- [72] A. Khuri. *Response Surface Methodology and Related Topics*. 1st. World Scientific Publishing Co Pte Ltd, 2006. ISBN: 9789812564580.
- [73] G. E. P. Box und D. R. Cox. „An Analysis of Transformations“. In: *Journal of the Royal Statistical Society Series B: Statistical Methodology* 26.2 (1964), S. 211–243. ISSN: 1369-7412. DOI: [10.1111/j.2517-6161.1964.tb00553.x](https://doi.org/10.1111/j.2517-6161.1964.tb00553.x).

-
- [74] M. V. Wüthrich und M. Merz. *Statistical Foundations of Actuarial Learning and its Applications*. Cham: Springer International Publishing, 2023. ISBN: 978-3-031-12408-2. DOI: [10.1007/978-3-031-12409-9](https://doi.org/10.1007/978-3-031-12409-9).
- [75] M. Modarres, M. Nuri-Amiri und C. Jackson. *Probabilistic physics of failure approach to reliability: Modeling, accelerated testing, prognosis and reliability assessment*. Performability engineering series. Beverly, MA und Hoboken, NJ: Scrivener Publishing und John Wiley & Sons Inc, 2017. ISBN: 9781119388630.
- [76] A. Kremer, L. Dücsö und B. Bertsche. „Reliability Prediction using Design of Experiments“. In: *Proceedings of the 30th European Safety and Reliability Conference and 15th Probabilistic Safety Assessment and Management Conference*. Hrsg. von P. Baraldi, F. Di Maio und E. Zio. Singapore: Research Publishing Services, 2020, S. 1501–1507. ISBN: 978-981-14-8593-0. DOI: [10.3850/978-981-14-8593-0{\textunderscore}3538-cd](https://doi.org/10.3850/978-981-14-8593-0{\textunderscore}3538-cd).
- [77] A. J. Dobson und A. G. Barnett. *An Introduction to Generalized Linear Models*. Fourth edition. Texts in statistical science. Boca Raton, FL: CRC Press, 2018. ISBN: 9781315182780. DOI: [10.1201/9781315182780](https://doi.org/10.1201/9781315182780).
- [78] J. Stufken und M. Yang. „Optimal Designs for Generalized Linear Models“. In: *Design and analysis of experiments*. Hrsg. von K. Hinkelmann. Bd. 3. Wiley series in probability and statistics. Hoboken, NJ: Wiley-Interscience, 2012, S. 137–164. ISBN: 9780470530689. DOI: [10.1002/9781118147634.ch4](https://doi.org/10.1002/9781118147634.ch4).
- [79] M. Aitkin und D. Clayton. „The Fitting of Exponential, Weibull and Extreme Value Distributions to Complex Censored Survival Data Using GLIM“. In: *Journal of the Royal Statistical Society Series C: Applied Statistics* 29.2 (1980), S. 156. ISSN: 0035-9254. DOI: [10.2307/2986301](https://doi.org/10.2307/2986301).
- [80] A. Kremer und B. Bertsche. „A Methodology for Consideration of Uncertainty in Lifetime Design of Experiments“. In: *2019 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2019, S. 1–6. ISBN: 978-1-5386-6554-1. DOI: [10.1109/RAMS.2019.8768906](https://doi.org/10.1109/RAMS.2019.8768906).
- [81] A. C. Rencher und G. B. Schaalje. *Linear models in statistics*. 2. ed. Hoboken, NJ: Wiley-Interscience, 2008. ISBN: 9780471754985. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2007024268-b.html>.

- [82] J. F. Lawless. *Statistical models and methods for lifetime data*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley-Interscience, 2003. ISBN: 0471372153. URL: <http://www.loc.gov/catdir/bios/wiley044/2002151805.html>.
- [83] D. Rasch und D. Schott. *Mathematical statistics*. Hoboken, NJ: John Wiley & Sons Inc, 2018. ISBN: 9781119385288.
- [84] L. J. Bain und M. Engelhardt. *Statistical Analysis of Reliability and Life-Testing Models*. Routledge, 2017. ISBN: 9780203738733. DOI: [10.1201/9780203738733](https://doi.org/10.1201/9780203738733).
- [85] M. Yang, B. Zhang und S. Huang. „Optimal designs for generalized linear models with multiple design variables“. In: *Statistica Sinica* 21.3 (2011), S. 1415–1430. ISSN: 10170405. DOI: [10.5705/ss.2009.115](https://doi.org/10.5705/ss.2009.115).
- [86] J. A. Nelder und R. W. M. Wedderburn. „Generalized Linear Models“. In: *Journal of the Royal Statistical Society. Series A (General)* 135.3 (1972), S. 370. ISSN: 00359238. DOI: [10.2307/2344614](https://doi.org/10.2307/2344614).
- [87] M. Arndt und M. Dazer. „Analysis of Efficiency in Response Surface Designs Considering Orthogonality Deviations and Cost Models“. In: *European Conference on Safety and Reliability (ESREL), 3rd September - 7th September 2023*. Hrsg. von M. P. Brito, T. Aven, P. Baraldi, M. Čepin und E. Zio. Singapore: Research Publishing Services, 2023, S. 1167–1174. ISBN: 978-981-18-8071-1. DOI: [10.3850/978-981-18-8071-1-textunderscoreP160-cd](https://doi.org/10.3850/978-981-18-8071-1-textunderscoreP160-cd).
- [88] E. Rittmaier, M. Arndt und M. Dazer. „Simulative Analysis of Statistical Power of Optimal Test Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–7. ISBN: 979-8-3503-6774-4. DOI: [10.1109/RAMS48127.2025.10935086](https://doi.org/10.1109/RAMS48127.2025.10935086).
- [89] A. N. Donev. „Design of experiments in the presence of errors in factor levels“. In: *Statistical Planning and Inference* 126.2 (2004), S. 569–585.
- [90] M. K. Ardakani, D. Das, S. S. Wulf und T. J. Robinson. „Estimation in Second-Order Models with Errors in the Factor Levels“. In: *Commun. in Statistics* 40.9 (2011), S. 1573–1590. DOI: [10.1080/03610921003637421](https://doi.org/10.1080/03610921003637421).

-
- [91] M. Arndt und M. Dazer. *Power and Accuracy Characterization of Regression Models in The Presence of Orthogonality Deviations in CCDs*. In: *6th International Conference on Design of Experiments (ICODOE 2022)*. 2023. URL: <https://www.memphis.edu/msci/icodoe22/index.php>.
- [92] M. Arndt, P. Mell und M. Dazer. „Generic effects of deviations from test design orthogonality on test power and regression modelling of Central-Composite Designs“. In: *Probabilistic Safety Assessment and Management PSAM 16, June 26-July 1, 2022, Honolulu, Hawaii*. URL: <https://www.iapsam.org/PSAM16/papers/MA19-PSAM16.pdf>.
- [93] E. Zio. *The Monte Carlo simulation method for system reliability and risk analysis*. Springer series in reliability engineering. London: Springer, 2013. ISBN: 978-1-4471-4587-5. DOI: [10.1007/978-1-4471-4588-2](https://doi.org/10.1007/978-1-4471-4588-2).
- [94] P. Mell, M. Arndt und M. Dazer. „Non-orthogonality in test design: practical relevance of the theoretical concept in terms of regression quality and test plan efficiency“. In: *Proceedings of the Probabilistic Safety Assessment and Management Conference 2022 PSAM 16 (2022)*. URL: <https://www.iapsam.org/PSAM16/paper.php?ID=PH20>.
- [95] G. E. P. Box. „The Effects of Errors in the Factor Levels and Experimental Design“. In: *Technometrics* 5.2 (1963), S. 247–262. ISSN: 0040-1706. URL: <https://doi.org/10.2307/1266066>.
- [96] M. Arndt und M. Dazer. „Investigating Practical Orthogonality Deviations in RSM for Optimized Predictive Reliability Modeling“. In: *2024 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2024, S. 1–6. ISBN: 979-8-3503-0769-6. DOI: [10.1109/RAMS51492.2024.10457825](https://doi.org/10.1109/RAMS51492.2024.10457825).
- [97] M. Arndt, E. Rittmaier und M. Dazer. „Assessing the Extrapolation Variance of Non-Orthogonal Response Surface Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–6. ISBN: 979-8-3503-6774-4. DOI: [10.1109/RAMS48127.2025.10935022](https://doi.org/10.1109/RAMS48127.2025.10935022).
- [98] M. Arndt und M. Dazer. „Confidence Intervals in Optimized Response Surface Designs for Accelerated Lifetime Testing“. In: *35th European Safety and Reliability*, S. 867–874. DOI: [10.3850/978-981-94-3281-3\textunderscoreESREL-SRA-E2025-P2042-cd](https://doi.org/10.3850/978-981-94-3281-3\textunderscoreESREL-SRA-E2025-P2042-cd).

- [99] N. T. Stevens und C. M. Anderson-Cook. „Design and analysis of confirmation experiments“. In: *Journal of Quality Technology* 51.2 (2019), S. 109–124. ISSN: 0022-4065. DOI: [10.1080/00224065.2019.1571344](https://doi.org/10.1080/00224065.2019.1571344).
- [100] M. Arndt, W. Raither und M. Dazer. „Multivariate Damage-based Reliability Assessment of Toothed Belts for Vehicle Steering Systems“. In: *IEEE Transactions on Reliability* (2026), S. 1–13. DOI: [10.1109/TR.2026.3713009](https://doi.org/10.1109/TR.2026.3713009).
- [101] R. Perneder. *Handbuch Zahnriementchnik: Grundlagen, Berechnung, Anwendungen*. Berlin und Heidelberg: Springer, 2009. ISBN: 978-3-540-89321-9.
- [102] T. Nagel. *Zahnriemengetriebe: Eigenschaften, Normung, Berechnung, Gestaltung*. 1. Aufl. München und Wien: Hanser, 2008. ISBN: 978-3-446-41380-1.
- [103] B. R. Englert, S. E. Rigdon, C. M. Borror, D. C. Montgomery und R. Pan. „Optimal Design for Multifactor Life Testing Experiments for Exponentially Distributed Lifetimes“. In: *Frontiers in Statistical Quality Control* 10. Hrsg. von H.-J. Lenz, W. Schmid und P.-T. Wilrich. SpringerLink Bücher. Heidelberg und s.l.: Physica-Verlag HD und Imprint Physica, 2012, S. 303–317. ISBN: 978-3-7908-2845-0. DOI: [10.1007/978-3-7908-2846-7{\textunderscore}20](https://doi.org/10.1007/978-3-7908-2846-7{\textunderscore}20).

Anhang A Sensitivitätsanalyse

In diesem Anhang sind die detaillierten Ergebnisse der Sensitivitätsanalyse für die verschiedenen Parameterkombinationen tabellarisch zusammengefasst. Die Tabellen zeigen die Power des Tests in Abhängigkeit von den Störfaktoren C (Zentrums-Läufe) und D (Stern-Läufe).

Tabelle A1: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9453	0.7362	0.6281	0.7168	0.5718	-	0.9935
power max	0.9905	0.8273	0.7994	0.8269	0.7495	-	1.0000
power min	0.7811	0.5999	0.3734	0.5517	0.3259	-	0.9451
Power (+)	0.9357	0.7304	0.6127	0.7163	0.5592	-	0.9949
Power (-)	0.9508	0.7353	0.6495	0.7148	0.5766	-	0.9909
Power (α)	0.9058	0.7022	0.6006	0.7086	0.5164	-	0.9939
Power ($-\alpha$)	0.9485	0.7162	0.7044	0.7046	0.5656	-	0.9826
a	0.3958	0.0298	0.3543	0.1940	0.3241	-	0.2432
b	0.2848	0.0084	0.0789	0.3961	0.7657	-	0.0546
e	0.9380	0.1534	1.6411	0.2953	0.7639	-	0.0440
f	0.0115	0.0411	2.6158	0.0315	0.0551	-	0.0403
g	1.1583	1.8408	2.3250	1.9725	2.7091	-	0.2193
h	0.6492	0.6492	1.8966	1.5782	2.2201	-	0.1176
aa	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0479
bb	0.0299	0.0299	0.0000	0.1089	0.0000	-	0.0000
ee	0.0988	0.0988	0.0797	0.0000	0.0000	-	0.0000
ff	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
gg	0.1851	0.1851	0.0672	0.1405	0.2111	-	0.0398
hh	0.0913	0.0913	0.1066	0.0861	0.2561	-	0.0179
ab	0.0000	0.0000	0.1039	0.0647	0.2700	-	0.0162
ae	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
af	0.0000	0.0000	0.0873	0.1034	0.0000	-	0.0197
ah	0.0375	0.0375	0.0000	0.0694	0.0000	-	0.0297
ag	0.1003	0.1003	0.0000	0.0000	0.0000	-	0.0625
be	0.0000	0.0000	0.0000	0.0850	0.0000	-	0.0284
bf	0.0000	0.0000	0.0948	0.0000	0.0000	-	0.0000
bh	0.0606	0.0606	0.0000	0.0000	0.0000	-	0.0000
bg	0.0434	0.0434	0.0000	0.0912	0.0934	-	0.0241
ef	0.0000	0.0000	0.3848	0.0000	0.0941	-	0.0000
eh	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
eg	0.0916	0.0916	0.1936	0.0000	0.0203	-	0.0203
fh	0.0000	0.0000	0.1073	0.0000	0.0000	-	0.0000
fg	0.0000	0.0000	0.0000	0.0000	0.0287	-	0.0287
gh	0.1616	0.1616	0.0000	0.0822	0.0000	-	0.0000
-	-	-	-	-	-	Lack of fit	-

Tabelle A2: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9518	0.7985	0.6387	0.7208	0.6531	-	0.9957
power max	0.9933	0.8573	0.8181	0.8411	0.7769	-	1.0000
power min	0.7685	0.6603	0.4066	0.5247	0.4672	-	0.9667
Power (+)	0.9444	0.7954	0.6178	0.7225	0.6561	-	0.9970
Power (-)	0.9556	0.7993	0.6589	0.7189	0.6485	-	0.9946
Power (α)	0.9215	0.7834	0.5775	0.7248	0.6577	-	0.9995
Power ($-\alpha$)	0.9533	0.7944	0.6938	0.7146	0.6361	-	0.9929
a	0.5743	0.0539	0.4599	0.2257	0.1838	-	0.1461
b	0.2434	0.0624	0.1787	0.5291	0.1289	-	0.0400
e	0.9031	0.1628	1.5864	0.2921	0.4940	-	0.0366
f	0.0191	0.0288	2.6353	0.0388	0.0186	-	0.0286
g	1.0501	1.4474	2.1712	1.9654	2.3119	-	0.1445
h	0.5934	1.1095	1.8017	1.5105	1.8671	-	0.0673
aa	0.0000	0.0000	0.1083	0.0000	0.0000	-	0.0162
bb	0.0000	0.0000	0.0000	0.1100	0.1570	-	0.0119
ee	0.1020	0.0000	0.1373	0.0875	0.0000	-	0.0000
ff	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
gg	0.1920	0.1289	0.1452	0.1150	0.1467	-	0.0312
hh	0.1089	0.2101	0.1396	0.1850	0.2392	-	0.0099
ab	0.0000	0.0972	0.1019	0.0906	0.0000	-	0.0267
ae	0.0000	0.0000	0.1122	0.0672	0.0000	-	0.0000
af	0.0000	0.0000	0.0000	0.0853	0.0000	-	0.0000
ah	0.0775	0.0000	0.0000	0.0000	0.0000	-	0.0239
ag	0.1522	0.0000	0.0000	0.1053	0.0000	-	0.0286
be	0.0356	0.0000	0.0000	0.0591	0.0000	-	0.0000
bf	0.0000	0.0000	0.0000	0.0703	0.0000	-	0.0117
bh	0.0400	0.0000	0.0000	0.0000	0.0797	-	0.0111
bg	0.0622	0.0934	0.0000	0.0603	0.1091	-	0.0000
ef	0.0441	0.0806	0.3800	0.0888	0.0000	-	0.0311
eh	0.0791	0.0000	0.0747	0.0000	0.0000	-	0.0000
eg	0.0738	0.0000	0.0000	0.1994	0.0972	-	0.0000
fh	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0152
fg	0.0000	0.0000	0.0775	0.0000	0.0000	-	0.0117
gh	0.1287	0.1422	0.0000	0.0906	0.0841	-	0.0164
-	-	-	-	-	-	Lack of fit	-

Tabelle A3: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9540	0.7986	0.7074	-	-	-	0.9975
power max	0.9989	0.8729	0.8406	-	-	-	1.0030
power min	0.7860	0.6751	0.4696	-	-	-	0.9723
Power (+)	0.9487	0.7962	0.6911	-	-	-	0.9976
Power (-)	0.9545	0.7996	0.7428	-	-	-	0.9967
Power (α)	0.9262	0.7884	0.7104	-	-	-	0.9956
Power ($-\alpha$)	0.9426	0.7981	0.8568	-	-	-	0.9930
a	0.7210	0.1280	0.4171	-	-	-	0.0960
b	0.3130	0.0177	0.7838	-	-	-	0.0204
e	0.8543	0.0783	1.3897	-	-	-	0.0216
f	0.0265	0.1084	2.2880	-	-	-	0.0300
g	0.9984	1.3910	1.8966	-	-	-	0.1050
h	0.5009	1.1444	1.4085	-	-	-	0.0433
aa	0.0000	0.0000	0.0000	-	-	-	0.0209
bb	0.0590	0.0823	0.0411	-	-	-	0.0000
ee	0.0766	0.0000	0.0514	-	-	-	0.0000
ff	0.0000	0.0000	0.2129	-	-	-	0.0000
gg	0.1704	0.0802	0.1430	-	-	-	0.0365
hh	0.1141	0.1227	0.1461	-	-	-	0.0000
ab	0.0742	0.0920	0.1405	-	-	-	0.0178
ae	0.0642	0.0000	0.1030	-	-	-	0.0000
af	0.0000	0.0000	0.0814	-	-	-	0.0125
ah	0.0739	0.0000	0.0545	-	-	-	0.0112
ag	0.1261	0.0000	0.0000	-	-	-	0.0366
be	0.0000	0.0000	0.0414	-	-	-	0.0000
bf	0.0000	0.0000	0.0483	-	-	-	0.0000
bh	0.0558	0.0000	0.0000	-	-	-	0.0000
bg	0.0000	0.0000	0.0530	-	-	-	0.0097
ef	0.0000	0.0820	0.4002	-	-	-	0.0131
eh	0.0000	0.0000	0.0000	-	-	-	0.0125
eg	0.0636	0.0000	0.0789	-	-	-	0.0000
fh	0.0000	0.0000	0.0911	-	-	-	0.0000
fg	0.0000	0.0830	0.0000	-	-	-	0.0231
gh	0.1339	0.1452	0.1148	-	-	-	0.0100
-	-	-	-	Lack of fit	Lack of fit	Lack of fit	-

Tabelle A4: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9902	0.7454	0.6374	0.7229	-	0.7645	0.9968
power max	0.9981	0.8382	0.7916	0.8411	-	0.9125	1.0000
power min	0.9588	0.6174	0.3968	0.5881	-	0.3337	0.9794
Power (+)	0.9843	0.7426	0.6232	0.7237	-	0.7862	0.9970
Power (-)	0.9934	0.7447	0.6596	0.7238	-	0.7243	0.9958
Power (α)	0.9668	0.7285	0.6175	0.7294	-	0.7777	0.9950
Power ($-\alpha$)	0.9924	0.7346	0.7206	0.7296	-	0.6029	0.9916
a	0.0155	0.0621	0.2866	0.2087	-	4.7500	0.0968
b	0.0000	0.0499	0.0228	0.4204	-	1.5342	0.0237
e	0.3993	0.2315	1.6512	0.2988	-	0.2277	0.0097
f	0.0000	0.0261	2.6397	0.0000	-	0.0597	0.0174
g	0.1461	1.6970	2.2654	1.9055	-	1.7045	0.0962
h	0.0774	1.3724	1.7403	1.3905	-	1.2919	0.0420
aa	0.0000	0.0819	0.0000	0.0000	-	0.5453	0.0177
bb	0.0000	0.1413	0.0635	0.1255	-	0.3322	0.0000
ee	0.0842	0.1212	0.0000	0.0986	-	0.1128	0.0000
ff	0.0000	0.0000	0.3990	0.0000	-	0.0000	0.0000
gg	0.0211	0.0681	0.1503	0.0726	-	0.0915	0.0089
hh	0.0000	0.0913	0.1597	0.1189	-	0.1559	0.0000
ab	0.0000	0.0000	0.0000	0.1508	-	0.0719	0.0125
ae	0.0175	0.0000	0.0000	0.0000	-	0.1094	0.0000
af	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0000
ah	0.0000	0.0000	0.0000	0.0000	-	0.1788	0.0116
ag	0.0000	0.0000	0.0000	0.0000	-	0.3075	0.0219
be	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0141
bf	0.0000	0.0884	0.0000	0.0000	-	0.0738	0.0000
bh	0.0000	0.0000	0.0000	0.0000	-	0.1050	0.0000
bg	0.0000	0.0000	0.0000	0.1005	-	0.1244	0.0147
ef	0.0000	0.0000	0.3547	0.0000	-	0.0862	0.0000
eh	0.0000	0.0000	0.0841	0.0000	-	0.0000	0.0000
eg	0.0441	0.0000	0.0000	0.0000	-	0.0000	0.0000
fh	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0000
fg	0.0000	0.0000	0.0000	0.0000	-	0.1187	0.0159
gh	0.0000	0.0000	0.0000	0.0995	-	0.0750	0.0000
-	-	-	-	-	Lack of fit	-	-

Tabelle A5: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9905	0.8010	0.6464	0.7278	0.7582	0.7765	0.9980
power max	0.9986	0.8732	0.7996	0.8508	0.8625	0.9315	1.0000
power min	0.9552	0.6885	0.4066	0.5683	0.6378	0.5508	0.9853
Power (+)	0.9848	0.7978	0.6275	0.7258	0.7535	0.7942	0.9981
Power (-)	0.9941	0.8076	0.6660	0.7273	0.7674	0.7376	0.9974
Power (α)	0.9694	0.8007	0.5947	0.7158	0.7564	0.7714	0.9970
Power ($-\alpha$)	0.9956	0.8282	0.7037	0.7199	0.7958	0.6113	0.9950
a	0.0027	0.1427	0.4640	0.2446	0.0495	4.0624	0.0608
b	0.0099	0.0559	0.0418	0.5323	0.3258	1.0318	0.0137
e	0.4114	0.0532	1.5052	0.2067	0.2528	0.1887	0.0100
f	0.0035	0.0072	2.5420	0.0221	0.0221	0.0399	0.0061
g	0.1383	1.4069	2.2154	1.9565	1.8537	1.5771	0.0754
h	0.0706	0.9461	1.7469	1.3671	1.2025	1.2268	0.0318
aa	0.0000	0.0000	0.0000	0.0000	0.0000	0.5061	0.0097
bb	0.0000	0.0000	0.0000	0.1137	0.0656	0.0787	0.0000
ee	0.0759	0.1234	0.1083	0.0887	0.1299	0.0926	0.0000
ff	0.0115	0.0000	0.0000	0.0513	0.0824	0.0000	0.0000
gg	0.0147	0.0860	0.0911	0.1219	0.1251	0.1168	0.0178
hh	0.0000	0.1129	0.1642	0.1101	0.0907	0.1474	0.0000
ab	0.0000	0.0000	0.0000	0.1018	0.0000	0.1845	0.0000
ae	0.0000	0.0000	0.0000	0.0000	0.0000	0.1461	0.0112
af	0.0000	0.0000	0.0000	0.0000	0.0000	0.0823	0.0097
ah	0.0000	0.0000	0.0000	0.0967	0.0000	0.1739	0.0113
ag	0.0000	0.0000	0.0000	0.1195	0.0000	0.2064	0.0219
be	0.0000	0.0000	0.0000	0.0000	0.0693	0.0000	0.0000
bf	0.0000	0.0000	0.1167	0.0889	0.0000	0.0717	0.0000
bh	0.0000	0.0000	0.0000	0.0000	0.0929	0.0777	0.0000
bg	0.0000	0.1098	0.0000	0.0000	0.0000	0.0895	0.0000
ef	0.0000	0.0767	0.3902	0.0000	0.0000	0.0000	0.0000
eh	0.0187	0.0000	0.1736	0.0000	0.0000	0.0945	0.0000
eg	0.0553	0.0767	0.0000	0.0836	0.0000	0.0000	0.0000
fh	0.0000	0.0000	0.1789	0.0000	0.0000	0.0000	0.0000
fg	0.0178	0.0000	0.0964	0.1392	0.0000	0.0000	0.0000
gh	0.0216	0.1333	0.0000	0.1445	0.0000	0.1073	0.0125

Tabelle A6: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9906	0.8001	0.7253	0.7307	0.7711	0.8209	-
power max	1.0000	0.8858	0.8277	0.8590	0.8612	0.9535	-
power min	0.9556	0.6939	0.4813	0.5676	0.6473	0.5788	-
Power (+)	0.9846	0.7993	0.7053	0.7301	0.7680	0.8377	-
Power (-)	0.9932	0.8053	0.7401	0.7247	0.7740	0.7956	-
Power (α)	0.9653	0.8030	0.6554	0.7123	0.7620	0.8464	-
Power ($-\alpha$)	0.9897	0.8198	0.7537	0.6969	0.7791	0.7271	-
a	0.0314	0.1339	0.2048	0.2370	0.0789	2.8293	-
b	0.0083	0.0793	0.5931	0.6122	0.1142	0.6457	-
e	0.4076	0.1149	1.1845	0.2977	0.1985	0.1012	-
f	0.0045	0.0841	2.2052	0.0770	0.0359	0.0660	-
g	0.1364	1.4107	1.7065	1.8462	1.5774	1.2572	-
h	0.0775	0.9693	1.3760	1.3693	1.2351	1.0155	-
aa	0.0000	0.0057	0.2197	0.0000	0.0000	0.2441	-
bb	0.0000	0.0024	0.0834	0.0852	0.0000	0.0754	-
ee	0.0564	0.0680	0.0000	0.1171	0.0619	0.0659	-
ff	0.0000	0.0593	0.1670	0.0000	0.0000	0.0000	-
gg	0.0276	0.0926	0.1028	0.0635	0.1037	0.0591	-
hh	0.0239	0.0714	0.1634	0.1792	0.1168	0.1448	-
ab	0.0000	0.0000	0.0861	0.1619	0.0000	0.1661	-
ae	0.0000	0.0194	0.0000	0.0000	0.0555	0.0952	-
af	0.0000	0.0000	0.0614	0.0000	0.0000	0.0000	-
ah	0.0192	0.0641	0.0686	0.0000	0.0000	0.1520	-
ag	0.0000	0.0000	0.0000	0.0000	0.0000	0.1133	-
be	0.0000	0.0000	0.0000	0.0000	0.0427	0.0000	-
bf	0.0158	0.0403	0.1277	0.0000	0.0000	0.0000	-
bh	0.0000	0.0000	0.0000	0.0000	0.1120	0.0000	-
bg	0.0000	0.0000	0.1030	0.1050	0.0000	0.0000	-
ef	0.0000	0.0000	0.3220	0.0000	0.0000	0.1180	-
eh	0.0208	0.0734	0.0000	0.1659	0.0702	0.0000	-
eg	0.0411	0.1172	0.0798	0.0000	0.0000	0.0808	-
fh	0.0000	0.0762	0.0780	0.0000	0.0000	0.0000	-
fg	0.0000	0.0000	0.1998	0.1400	0.0608	0.0000	-
gh	0.0000	0.0462	0.0000	0.0772	0.1202	0.1314	-
-	-	-	-	-	-	-	Lack of fit

Tabelle A7: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	-	0.6450	0.7284	0.7145	0.7727	-
power max	1.0000	-	0.7837	0.8358	0.8097	1.0000	-
power min	0.9742	-	0.3734	0.5875	0.4275	0.9829	-
Power (+)	0.9909	-	0.6216	0.7277	0.7073	0.7909	-
Power (-)	0.9968	-	0.6612	0.7291	0.7158	0.7401	-
Power (α)	0.9783	-	0.5599	0.7263	0.6791	0.7870	-
Power ($-\alpha$)	0.9948	-	0.6718	0.7303	0.7031	0.6435	-
a	0.0000	-	0.3510	0.1266	0.8831	4.5897	-
b	0.0013	-	0.0509	0.4785	1.0897	1.7627	-
e	0.2539	-	1.5429	0.2870	0.3910	0.2779	-
f	0.0013	-	2.5994	0.0812	0.0105	0.0011	-
g	0.0695	-	2.3087	1.9936	1.9692	1.7285	-
h	0.0302	-	1.6869	1.3665	1.3721	1.1623	-
aa	0.0000	-	0.0000	0.0000	0.1855	0.5719	-
bb	0.0000	-	0.0000	0.1214	0.2005	0.3038	-
ee	0.0476	-	0.0000	0.1196	0.1032	0.1125	-
ff	0.0000	-	0.0000	0.0000	0.0000	0.0000	-
gg	0.0000	-	0.1937	0.1661	0.2318	0.1463	-
hh	0.0219	-	0.1743	0.1704	0.2036	0.0694	-
ab	0.0000	-	0.0000	0.0000	0.2447	0.2175	-
ae	0.0000	-	0.0000	0.0000	0.0000	0.2034	-
af	0.0000	-	0.0000	0.0000	0.1066	0.0000	-
ah	0.0000	-	0.0816	0.0000	0.0000	0.1350	-
ag	0.0000	-	0.0000	0.0000	0.0966	0.3544	-
be	0.0000	-	0.1275	0.0000	0.0000	0.0000	-
bf	0.0000	-	0.0000	0.0000	0.0000	0.1050	-
bh	0.0000	-	0.1672	0.0000	0.0000	0.0000	-
bg	0.0194	-	0.1172	0.0939	0.2109	0.0000	-
ef	0.0000	-	0.3784	0.0000	0.0631	0.0000	-
eh	0.0000	-	0.2038	0.0000	0.0000	0.0775	-
eg	0.0303	-	0.0000	0.0000	0.0000	0.0000	-
fh	0.0000	-	0.0000	0.0000	0.0634	0.0000	-
fg	0.0153	-	0.1762	0.0000	0.0000	0.0000	-
gh	0.0000	-	0.0000	0.0000	0.0628	0.0000	-
-	-	Lack of fit	-	-	-	-	Lack of fit

Tabelle A8: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	0.8007	0.6497	-	0.7877	0.7861	0.9984
power max	1.0000	0.9077	0.8025	-	0.8681	0.9176	1.0000
power min	0.9771	0.7010	0.4032	-	0.6628	0.4751	0.9878
Power (+)	0.9912	0.7980	0.6315	-	0.7796	0.8027	0.9988
Power (-)	0.9968	0.8035	0.6766	-	0.7920	0.7578	0.9981
Power (α)	0.9796	0.7937	0.6208	-	0.7546	0.8030	0.9999
Power ($-\alpha$)	0.9953	0.8091	0.7482	-	0.7896	0.6759	0.9978
a	0.0060	0.0652	0.4519	-	0.0098	3.6725	0.0433
b	0.0183	0.0519	0.0116	-	0.3922	1.2550	0.0097
e	0.2406	0.1823	1.5806	-	0.1582	0.1947	0.0090
f	0.0000	0.0559	2.7147	-	0.0286	0.0000	0.0080
g	0.0803	1.4901	2.3085	-	1.5045	1.4975	0.0557
h	0.0313	0.9934	1.6549	-	1.0501	1.1319	0.0213
aa	0.0000	0.0000	0.0000	-	0.0000	0.3338	0.0000
bb	0.0000	0.0000	0.0686	-	0.0000	0.1913	0.0000
ee	0.0457	0.1627	0.1149	-	0.1524	0.1218	0.0050
ff	0.0000	0.0970	0.0000	-	0.0000	0.0000	0.0000
gg	0.0000	0.0000	0.1214	-	0.1445	0.0976	0.0082
hh	0.0000	0.0817	0.1258	-	0.0907	0.1776	0.0000
ab	0.0242	0.0000	0.0000	-	0.0000	0.0000	0.0131
ae	0.0000	0.0000	0.0000	-	0.0000	0.1000	0.0000
af	0.0000	0.0000	0.0000	-	0.0998	0.0000	0.0056
ah	0.0000	0.0000	0.0000	-	0.0000	0.1419	0.0084
ag	0.0000	0.0778	0.0000	-	0.0000	0.2569	0.0169
be	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0072
bf	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
bh	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
bg	0.0000	0.0772	0.0000	-	0.0842	0.0000	0.0000
ef	0.0000	0.1550	0.4475	-	0.0000	0.0000	0.0000
eh	0.0000	0.0000	0.0000	-	0.0000	0.0803	0.0000
eg	0.0236	0.0812	0.1231	-	0.0000	0.0000	0.0097
fh	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
fg	0.0000	0.0000	0.2075	-	0.0000	0.0000	0.0081
gh	0.0000	0.0600	0.1353	-	0.0711	0.0000	0.0084
-	-	-	-	Lack of fit	-	-	-

Tabelle A9: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	0.8035	-	0.7330	-	0.8378	0.9990
power max	1.0000	0.8784	-	0.8544	-	0.9286	1.0000
power min	0.9753	0.7101	-	0.5842	-	0.6034	0.9953
Power (+)	0.9918	0.7998	-	0.7345	-	0.8424	0.9990
Power (-)	0.9967	0.8031	-	0.7286	-	0.8177	0.9990
Power (α)	0.9828	0.7819	-	0.7297	-	0.8111	0.9989
Power ($-\alpha$)	0.9969	0.7912	-	0.7130	-	0.7411	0.9989
a	0.0010	0.0699	-	0.1136	-	2.4390	0.0192
b	0.0038	0.0659	-	0.7811	-	0.8272	0.0055
e	0.2297	0.1238	-	0.2768	-	0.0821	0.0063
f	0.0077	0.0349	-	0.0462	-	0.1113	0.0096
g	0.0584	1.2813	-	1.8702	-	1.2301	0.0336
h	0.0427	1.0310	-	1.2671	-	0.8845	0.0125
aa	0.0000	0.0000	-	0.0613	-	0.2086	0.0000
bb	0.0000	0.0000	-	0.1732	-	0.1142	0.0000
ee	0.0369	0.0706	-	0.0745	-	0.0000	0.0000
ff	0.0000	0.0000	-	0.0000	-	0.0000	0.0000
gg	0.0000	0.1056	-	0.1212	-	0.1036	0.0000
hh	0.0000	0.0931	-	0.1762	-	0.1711	0.0082
ab	0.0000	0.0000	-	0.0000	-	0.1048	0.0000
ae	0.0000	0.0000	-	0.0761	-	0.0000	0.0000
af	0.0000	0.0658	-	0.0000	-	0.0000	0.0000
ah	0.0123	0.0000	-	0.0000	-	0.1023	0.0000
ag	0.0000	0.0789	-	0.0000	-	0.1142	0.0000
be	0.0000	0.0000	-	0.0798	-	0.0000	0.0000
bf	0.0123	0.0000	-	0.0101	-	0.1023	0.0000
bh	0.0177	0.0000	-	0.0000	-	0.0000	0.0000
bg	0.0183	0.0000	-	0.0000	-	0.0983	0.0000
ef	0.0123	0.0000	-	0.0000	-	0.1023	0.0000
eh	0.0181	0.0123	-	0.0000	-	0.0000	0.0000
eg	0.0208	0.0000	-	0.0000	-	0.0000	0.0000
fh	0.0000	0.0000	-	0.0000	-	0.0000	0.0073
fg	0.0177	0.0714	-	0.1136	-	0.0670	0.0000
gh	0.0000	0.0000	-	0.1120	-	0.0848	0.0000
-	-	-	Lack of fit	-	Lack of fit	-	-

Anhang B Orthogonalitäts-Analysen der Design-Modifikationen

In diesem Anhang sind ergänzende Visualisierungen und Analysen zur Bewertung der geometrischen Design-Verzerrungen aufgeführt.

Tabelle B1: Simulationsergebnisse: Schätzvarianz (MSE) der einzelnen Koeffizienten bei $\text{SNR} = 2,4$.

Szenario (Störfall)	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	3,09	3,10	3,17	6,17	3,13	3,11
Fall I: Shift (−20 %)	3,05	3,57	3,15	6,20	4,15	3,17
Fall I: Shift (+20 %)	3,07	2,94	3,14	6,37	2,21	3,06
Fall I: FC	3,06	3,82	3,10	6,30	4,61	3,21
Fall II: Korrelation (leicht)	3,06	3,17	3,07	6,22	3,13	3,12
Fall II: Korrelation (stark)	3,10	3,59	3,01	5,21	3,83	3,44
Fall III: Scatter (± 10 %)	3,04	3,18	2,98	6,20	3,27	2,62
Fall IV: SP	3,18	5,29	3,07	6,17	5,46	3,47
Fall IV: ZP	3,53	3,09	3,13	6,29	3,24	3,25




Abbildung B1: Laufende Konvergenz der Trennschärfe für alle Modellparameter. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar.




Abbildung B2: Konvergenz der OLS-Parameterschätzwerte ($\hat{\beta}_i$). Alle Modelle erweisen sich unabhängig von der geometrischen Verzerrung als erwartungstreu. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar.




Abbildung B3: Relative Häufigkeiten der in der Simulation ermittelten p -Werte der Signifikanztests.




Abbildung B4: Korrelierende Metriken zur prozentualen Trennschärfe-Änderung ($\Delta power$ [%]) über alle Koeffizienten und Szenarien ergänzend zu Abbildung 4.5.

Anhang B.1 Szenarien bei Arbeitspunkt SNR= 1




Abbildung B5: Güte der Schätzer (MSE) für SNR = 1.




Abbildung B6: Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der Stör-szenarien für SNR = 1.

Anhang B.2 Effizienzanalysen




Abbildung B7: KPI ggü. D-Effizienz aller Koeffizienten.