# Entwicklung Effizienter Multivariater Lebensdauertests

Efficient Multivariate Lifetime Testing

Der Fakultät Konstruktions-, Produktions- und Fahrzeugtechnik
der Universität Stuttgart
zur Erlangung der Würde eines Doktor-Ingenieurs (Dr.-Ing.) vorgelegte
Abhandlung

von
**Marco Arndt, M.Sc.**
aus Ravensburg

| | |
|---|---|
| Hauptberichter: | PD Dr.-Ing. habil. Martin Dazer |
| Mitberichter: | Univ.-Prof. Dr.-Ing. Mit Berichter |

Tag der mündlichen Prüfung:

Institut für Maschinenelemente der Universität Stuttgart

2026

# Vorwort

Thanks for your service.

# Kurzfassung/Abstract

–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO:

- 
- Abstract / Kurzfassung / Danksagung
- Bilder prüfen
- "mark changes after your Oral presentation for review"
- "textcolor blueïn definitions ändern
- "Print"Funktion aktivieren
- "nocite"Funktion deaktivieren in main Z.269

–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–TODO–

# Inhaltsverzeichnis

# Nomenklatur

## Abkürzungen

| | |
|---|---|
| ***cdf*** | Cumulative Distribution Function |
| ***pdf*** | Probability Density Function |
| **ALT** | Accelerated Lifetime Testing |
| **ANOVA** | Varianzanalyse, engl. Analysis of Variance |
| **BEV** | Battery Electric Vehicle |
| **CCD** | Central Composite Design |
| **CI** | Confidence Interval |
| **CP** | Center Point |
| **DfR** | Design for Reliability |
| **DoE** | Design of Experiments |
| **DSD** | Definitive Screening Design |
| **DSM** | Design-Structure-Matrix |
| **ECU** | Electronic Control Unit |
| **EoL** | End-of-Life |
| **EVG** | Evaluation Graph |
| **FBD** | Function Block Diagram |
| **FC** | Face Centered |
| **FDS** | Fraction of Design Space |
| **FEA** | Finite-Elemente-Analyse |
| **FTA** | Fault-Tree-Analysis |

| | |
|---|---|
| **GLL** | Generalized Log-Linear |
| **GLM** | Generalized Linear Model |
| **ILP** | Integer Linear Programming |
| **IMA** | Institut für Maschinenelemente |
| **KPI** | Leistungsindikator, engl. Key Performance Indicator |
| **L-DoE** | Lifetime Design of Experiments |
| **LR-Test** | Likelihood-Ratio Test |
| **M7** | Seven Management and Planning Tools |
| **MCS** | Monte-Carlo-Simulation |
| **ML** | Machine Learning |
| **MLE** | Maximum-Likelihood-Estimation |
| **MMR** | Median-Rank-Regression-Methode |
| **MSE** | Mean Squared Error |
| **OFAT** | One Factor At Time |
| **OLS** | Ordinary Least Squares |
| **OMARS** | Orthogonal Minimally Aliased Response Surface |
| **PH** | Proportional Hazard |
| **Q7** | Seven Quality Tools |
| **RSD** | Response Surface Design |
| **RSM** | Response Surface Methodology |
| **SNR** | Signal-zu-Rausch Verhältnis, engl. Signal-to-Noise Ratio |
| **SP** | Sternpunkt |
| **SPV** | Scaled Prediction Variance |
| **UPV** | Unscaled Prediction Variance |
| **VDG** | Variance Dispersion Graph |
| **VIF** | Varianz-Inflations-Faktor |
| **ZP** | Zentralpunkt |

# Indizes

| | |
|---|---|
| 0 | Zeitpunkt $t = 0$<br>Zentralpunkt<br>Regressionskonstante<br>Position im Versuchsraum |
| BC | Box-Cox-Transformation |
| C | Zentralpunkt |
| D | Sternpunktabstand CCD |
| F | Faktorieller Punkt |
| MC | Monte-Carlo-Simulation |
| M | Modellbezogen |
| O | Beobachtet (Observed) |
| S | Sternpunkt |
| V | Transformation |
| a | Simulationsfaktor: Sternpunkt-Abstand |
| b | Simulationsfaktor: Sternpunkt-Shift |
| c | Simulationsfaktor: Zentralpunkte |
| d | Simulationsfaktor: Sternpunkte |
| error | Fehler 2. Art (Wahrscheinlichkeit für ein falsch-negatives Ergebnis) |
| e | Simulationsfaktor: System-Rauschen |
| f | Simulationsfaktor: Effekt-Verhältnis |
| g | Simulationsfaktor: Mess-Rauschen |
| h | Simulationsfaktor: Signifikanzniveau |
| nc | Nichtzentral (non-central) |
| nom | Nominale Werte |
| sim | Simulationsergebnisse |
| $i$ | Laufvariable |

| | |
|---|---|
| $j$ | Laufvariable |
| $k$ | Laufvariable (für Faktor-Indizierung) |
| $l$ | Laufvariable |
| $o$ | Obere Grenze des Vertrauensbereichs |
| $q$ | Quantilwert |
| $u$ | Untere Grenze des Vertrauensbereichs |
| $z$ | Zensierungsindikator |

## Formelzeichen

| | |
|---|---|
| $A_2$ | Nicht-Orthogonalitätsindikator ($A_2$-Kriterium) |
| $A_{\text{opt}}$ | A-Optimalitätskriterium (Spur-Minimierung) |
| $\alpha$ | Signifikanzniveau<br>Abstand der Sternpunkte (Axial Points) |
| $b$ | Weibull-Formparameter (Weibull-Modul) |
| $\boldsymbol{\beta}$ | Koeffizientenmatrix |
| $\beta$ | Regressionskoeffizient, Modellparameter<br>Fehler 2.Art |
| $\Omega$ | Kandidatenmenge (Menge aller möglichen Faktorstufenkombinationen) |
| $\chi^2(\cdot)$ | Chi-Quadrat-Verteilung |
| $\text{Cov}[\cdot]$ | Covarianz-Operator |
| COVRATIO | Einflussstatistik auf Schätzwerte (Covariance Ratio) |
| $D$ | Cook's Distanz |
| $d_{\text{f}}$ | Anzahl der Freiheitsgrade |
| $D_{\text{opt}}$ | D-Optimalitätskriterium (Determinanten-Maximierung) |
| $\gamma$ | Binäre Entscheidungsvariable für die Design-Optimierung (1 = Versuchspunkt ausgewählt) |

| | |
|---|---|
| $\delta$ | Statusindikator (1=Ausfall, 0=Zensiert) |
| $\delta_{\text{nc}}$ | Nichtzentralitätsparameter der Prüfverteilung |
| DFBETAS | Einflussstatistik auf Koeffizienten (Difference in Betas) |
| DFFITS | Einflussstatistik auf Prädiktionen (Difference in Fits) |
| $E(\cdot)$ | Erwartungswert |
| $E$ | Effekt |
| $A_{\text{eff}}$ | A-Effizienz |
| $D_{\text{eff}}$ | D-Effizienz (Normierte Determinante) |
| $G_{\text{eff}}$ | G-Effizienz (Verhältnis Modellparameter zu max. Varianz) |
| $I_{\text{eff}}$ | I-Effizienz |
| $V_{\text{eff}}$ | V-Effizienz |
| $\lambda$ | Eigenwert (einer Matrix)<br>Transformationsparameter (Box-Cox) |
| $\boldsymbol{\epsilon}$ | Fehlerterm-Matrix |
| $\epsilon$ | Fehlerterm |
| $\boldsymbol{E}(\cdot)$ | Erwartungswert |
| $\eta$ | Linearer Prädiktor (Logarithmus der charakteristischen Lebensdauer) |
| $F(\cdot)$ | Ausfallwahrscheinlichkeit, Verteilungsfunktion |
| $f(\cdot)$ | Dichtefunktion |
| $\mathbf{F}$ | Fisher-Informationsmatrix |
| $F$ | Teststatistik (ANOVA) |
| $G(\cdot)$ | Verteilungsfunktion der kleinsten Extremwerte |
| $g(\cdot)$ | Abgeleitete Funktion (für Delta-Methode) |
| $\mathbf{g}'$ | Gradientenvektor der Funktion $g$ |
| $G_{\text{opt}}$ | G-Optimalitätskriterium (Minimierung max. Prädiktionsvarianz) |
| $\Gamma(\cdot)$ | Gamma-Funktion |

| | |
|---|---|
| $\mathbf{H_f}$ | Hessian-Matrix (der Log-Likelihood-Funktion) |
| $h$ | Eintrag von $\mathbf{H}$, Hebelwert |
| $H_0$ | Nullhypothese |
| $H_1$ | Alternativhypothese |
| $\mathbf{H}$ | Orthogonale Projektionsmatrix, Prädiktionsmatrix, Hat-Matrix |
| $I_{\text{opt}}$ | I-Optimalitätskriterium (Minimierung durchschn. Prädiktionsvarianz) |
| $k$ | Anzahl der Modellparameter |
| $\mathcal{L}(\cdot)$ | Likelihood-Funktion |
| $\Lambda(\cdot)$ | Log-Likelihood-Funktion |
| $\lambda(t)$ | Ausfallrate (zeitabhängig) |
| $LR$ | Likelihood-Ratio |
| $\mathbf{M}$ | Informationsmatrix $\mathbf{X}'\mathbf{X}$ |
| $m$ | Replikation |
| MSE | Mittlerer quadratischer Fehler (Mean Squared Error) |
| $\mu$ | Lageparameter |
| $N$ | Versuchsanzahl |
| $n$ | Stichprobenumfang<br>Anzahlvariable |
| $k_{\text{f}}$ | Anzahl der Faktoren (Dimension) |
| $p$ | Anzahl der Regressionskoeffizienten |
| $p$-Wert | Überschreitungs-, Rest-Irrtumsdwahrscheinlichkeit |
| $p_{\text{f}}$ | Fraktionsgrad |
| *power* | Trennschärfe, Power |
| Pr | Wahrscheinlichkeit |
| $v(\mathbf{x}_0)$ | Prädiktionsvarianz an der Stelle $\mathbf{x}_0$ (skaliert) |
| $q$ | Quantilwert |

| | |
|---|---|
| $R$ | Zuverlässigkeit |
| $r$ | Paarweiser (Pearson-)Korrelationskoeffizient<br>Radius im Versuchsraum (Euklidische Distanz)<br>Studentisiertes Residuum |
| $R^2$ | Bestimmtheitsmaß (Determinationskoeffizient) |
| $r_{\mathrm{CS}}$ | Cox-Snell-Residuum |
| $r_{\mathrm{Dev}}$ | Standardisiertes Devianz-Residuum |
| $r$ | Standardisiertes Residuum (bezogen auf die SEV-Verteilung) |
| $\mathbb{R}$ | Menge der reellen Zahlen |
| $s$ | Empirische Standardabweichung (von $x$) |
| $s^2$ | Empirische Varianz (von $x$) |
| $SEV(\cdot,\cdot)$ | Verteilung der kleinsten Extremwerte, engl. Smallest Extreme Value |
| $\sigma$ | Standardabweichung (theoretisch)<br>Skalenparameter |
| $\sigma^2$ | Varianz der Lebensdauer (theoretisch) |
| SNR | Signal-zu-Rausch Verhältnis (engl. Signal-to-Noise Ratio) |
| $T$ | Charakteristische Lebensdauer (Skalenparameter) |
| $t$ | Zeit, Lebensdauermerimal<br>Teststatistik in Bezug zur Signal-to-Noise Ratio |
| $\mathbf{t}$ | Vektor der Ausfallzeiten |
| $\tau$ | kontinuierliche Zufallsvariable |
| $\theta$ | Modellparameter, Schätzung |
| $\boldsymbol{\theta}$ | Vektor der Modellparameter |
| $v$ | Integrationsvariable (Gamma-Funktion) |
| $\mathbf{V}$ | Varianz-Kovarianz-Matrix |
| $V_{\mathrm{opt}}$ | V-Optimalitätskriterium (Punktuelle Varianz-Minimierung) |
| $\mathrm{Var}[\cdot]$ | Varianz-Operator |

| | |
|---|---|
| $V$ | Varianz-Dispersion (mittlere skalierte Prädiktionsvarianz auf dem Radius $r$) |
| $\mathcal{W}(\cdot,\cdot)$ | Weibull-Verteilung |
| $w$ | Hilfsgröße zur Berechnung von Vertrauensbereichen (standardisierte Log-Lebensdauer) |
| $\mathbf{X}$ | Versuchsplan-Matrix oder Modellmatrix |
| $x$ | Messwert, Variable, Parameter |
| $\bar{x}$ | Arithmetischer Mittelwert (empirisch) |
| $\mathbf{x}$ | Postion im Parameterraum |
| $\xi$ | Einflussfaktor im Meta-Design der Sensitivitätsanalyse |
| $\boldsymbol{\xi}$ | Vektor der Einflussfaktoren im Meta-Design der Sensitivitätsanalyse |
| $\mathbf{y}$ | Antwortmatrix |
| $y$ | Systemantwort, -variable |
| $z$ | Quantil der Standardnormalverteilung |
| $z$ | Hilfsvariable für die Log-Likelihood-Berechnung |
| $z_{\mathrm{e}}$ | Standardisierte Variable der Kleinstwertverteilung (SEV); Hilfsgröße für Wald-Konfidenzintervalle (äquivalent zu $w$) |

# Abbildungsverzeichnis

# Tabellenverzeichnis

# 1 Einleitung

Die Absicherung technischer Produkte und Systeme hinsichtlich ihrer Funktionalität bildet einen zentralen Bestandteil der ingenieurwissenschaftlichen Verantwortlichkeiten im Produktentwicklungsprozess. Motiviert durch Produktversprechen gegenüber der potenziellen Käuferschaft sowie bestehender Kunden, zur Wahrung des Selbstverständnisses einer Marke oder rein aufgrund regulatorischer Vorgaben soll hier im Kontext des vorgesehenen Einsatzzweckes Zuverlässigkeitsmanagement betrieben werden. So wird insbesondere aus Marktperspektive erwartet, dass ein (technisches) Produkt - ein Fahrzeug, ein Smartphone, eine Photovoltaikanlage - seine Funktionalität mindestens zum Gewährleistungs- oder Garantiezeitraum uneingeschränkt erfüllt.
Über den gesamten Produktlebenszyklus hinweg unterstützen Methoden der Zuverlässigkeitstechnik dabei, diese Anforderungen systematisch zu erfüllen. Verfahren aus dem Bereich „Safety“, explorative Datenanalysen zur Untersuchung der Produktperformance im Betrieb oder Test, effiziente Versuchsplanung zur Analyse oder zum Nachweis der Lebensdauer am Design, Methoden der beschleunigten Versuchsplanung, engl. Accelerated Lifetime Testing (ALT), der Aufbau probabilistischer Lebensdauermodelle sowie das Risikomanagement im Allgemeinen eignen sich für diese Herausforderung. Das zentrale Ergebnis liegt in der Ermittlung der Ausfallwahrscheinlichkeit als Komplement zur Zuverlässigkeit - also der Wahrscheinlichkeit, dass ein Produkt unter den definierten Randbedingungen eine vorgegebene Zeitdauer ohne funktionskritischen Ausfall übersteht [**Bertsche.2022**]. Üblicherweise soll so nachgewiesen werden, dass das Erzeugnis dem Einfluss einer bestimmten Belastung - beispielsweise einer physikalischen oder elektrischen Kraft, einem Wärmeeintrag oder der Exposition gegenüber einer chemischen Beanspruchung - standhält. Gelingt in der Praxis keine hinreichend genaue Quantifizierung dieser probabilistischen Metrik, so liegen die Ursachen jedoch nicht zwangsläufig allein in ökonomischen Einschränkungen wie dem Zeit- und Kostenbudget für ein

erforderliches Testing oder einem fehlenden methodischen Know-how - vielmehr könnten *mehrere* Einflussfaktoren auf die Zuverlässigkeit einwirken und sogar Wechselwirkungen ausprägen, ohne dass dies adäquat wahrgenommen oder antizipiert wird.

Moderne Produkte können schlichtweg durch multivariat bedingte Fehlermechanismen ausfallen. Die wirtschaftliche Tragweite dieser Erkenntnis wurde bereits 1996 im renommierten *Forbes Magazine* thematisiert, welches die einschlägigen Erfolge multivariabler Testmethoden in der industriellen Praxis hervorhob [**Koselka.1996**].

## 1.1 Forschungsperspektive und Problembeschreibung

Da trotz genannter Umstände die Kundenanforderungen und Garantiebedingungen üblicherweise als unveränderlich, teils sogar als zunehmend anspruchsvoller zu verstehen sind, werden Unsicherheiten in der Lebensdauerabsicherung dann meist nur durch präventive Wartungsstrategien, durch Tolerierung von Restrisiken oder durch die Inkaufnahme nachträglicher Schadensbegrenzung behandelt. Der zugrunde liegende Gedanke: ehe ein Produkt, dessen Lebensdauerverhalten nicht quantifizierbar verstanden ist, einen kritischen Verschleißzustand erreicht, wird es im Rahmen eines festgelegten Wartungsintervalls vorsorglich ersetzt. Dabei könnte zugrunde liegen, dass schlichtweg kein physikalisches Modell oder eine ausreichend ausgeprägte empirische Datengrundlage vorhanden ist. Führt auch diese Vorsorge zu erheblichen Regress- oder Kulanzkosten, müssen ausfallschutzorientierte Maßnahmen - bis hin zu Rückrufaktionen - frühzeitig eingeplant und umgesetzt werden, um Image- und Kostenrisiken (wenn auch selten nachhaltig) zu minimieren. Um jenes zu vermeiden, muss also bereits im Vorfeld den verschiedensten Randbedingungen mithilfe der Zuverlässigkeitstechnik begegnet werden. Besonders komplexe Randbedingungen lassen sich beispielsweise durch eine hochgradige Integration von Elektrifizierung und Digitalisierung, verkürzte Entwicklungszyklen, verschärfter Kostendruck, sich per se verändernde Prioritäten aus Marktperspektive, wandelnde Materialauswahl und -komposition, leistungsoptimierte Belastungsszenarien, intensivierte Einsatzbedingungen und nicht zuletzt eine effiziente Ressourcennutzung innerhalb eines Produkts beschreiben - um nur einige zu nennen. Ein einfaches

Beispiel verdeutlicht dies: Der komfortable sowie ausfallfreie Betrieb eines Fahrzeugs soll einerseits gegenüber verschiedensten Schadensursachen gewährleistet werden; andererseits hängt er maßgeblich vom Funktionserhalt einer inzwischen bis zu dreistelligen Anzahl an Electronic Control Units (ECUs) ab - während in der jüngeren Vergangenheit noch eine geringe bis mittlere zweistellige Anzahl mit nur begrenztem Funktionsumfang üblich war [**dat.2025**]. Oder aber der störungsfreie Betrieb digitaler Services im Battery Electric Vehicle (BEV) setzt bei Zentralisierung von ECU-Funktionen die stetige Funktionsfähigkeit der Traktionsbatterie voraus, durch deren chemische Alterung, verschiedenst beeinflusst, sich jedoch zeitgleich wiederum weitere Unsicherheiten aus verschiedenen Einflüssen eingliedern können. Ein damit betrachtetes System bildet somit ein vielfältig komplexeres Netzwerk aus teils wechselwirkenden oder direkten Eigenschaften, die zu einem Versagen führen könnten.

Damit kann festgehalten werden: Produktdesigns werden angesichts steigender Kundenanforderungen zunehmend raffinierter und im Sinne des Effizienzgedankens optimiert (z.B. durch mehr Sensorik, Rechenleistung und fortschrittliche Assistenzsysteme), gleichzeitig wird jedoch die Art und Weise eines möglichen Funktionsverlustes zunehmend komplexer. Somit rückt die Fähigkeit, Prognosen über die Lebensdauer und Ausfallwahrscheinlichkeit in Abhängigkeit von mehreren Einflussgrößen treffen zu können, zunehmend in den unternehmerischen Fokus. Über die klassische Testplanung im Rahmen der Zuverlässigkeitstechnik hinaus erfordert dies also Methoden der statistischen Versuchsplanung bei gleichzeitiger Berücksichtigung *mehrerer* Einflussfaktoren auf die Lebensdauer. Methoden wie ALT und die Lebensdauermodellbildung behalten dabei weiterhin ihre Relevanz und bilden einen unverzichtbaren Bestandteil einer fundierten Teststrategie.

## 1.2 Beitrag dieser Arbeit

Ausgehend von der beschriebenen Problemstellung lässt sich der übergeordnete Beitrag dieser Arbeit wie folgt formulieren: Liegt ein komplexes technisches System vor und soll dieses hinsichtlich seiner Lebensdauer empirisch untersucht werden, um fundierte Prognosen über die Funktionalität im Betrieb treffen zu können, so müssen mehrdimensionale Lebensdaueruntersuchungen nach dem Prinzip des De-

sign of Experiments (DoE) geplant werden. Neben der bloßen Implementierung von mehrdimensionale Tests für die Lebensdauererprobung berücksichtigt dieser Ansatz damit:

- eine effiziente Methodik zur gezielten Vorauswahl relevanter Faktoren aus der Gesamtheit potenzieller Systemparameter - mit dem Ziel, deren signifikanten Einfluss auf die Lebensdauer zu untersuchen;
- die Auswahl geeigneter Strategien und passender Testpläne zur statistisch abgesicherten Quantifizierung von Einflüssen auf die Lebensdauer, in Kombination mit konventionellen Zuverlässigkeitsmethoden wie beispielsweise ALT;
- eine präzise Parameterschätzung zur mathematischen Beschreibung der Effekte auf Basis der als signifikant identifizierten Einflussgrößen;
- die Bilanzierung geeigneter Testpläne im Vergleich zu etablierten, in der Literatur bereits umfangreich diskutierten Versuchsplänen, insbesondere hinsichtlich potenzieller Abweichungen bei nicht-normalverteilten Daten.

## 1.3 Aufbau der Arbeit

Der allgemeine inhaltliche Aufbau der vorliegenden Arbeit kann Abb. 1 entnommen werden. So folgt auf die in diesem Abschnitt beschriebene Problemstellung sowie Ausführung über den generellen Beitrag der Arbeit weiter in Kapitel 2 der relevante Stand aus aktueller Forschung und Literatur. Kapitel 3 fasst schließlich den Forschungsbedarf zusammen und stellt das Ziel der Arbeit, aus der sich die relevanten Forschungsfragen ergeben, konkret heraus. Kapitel 4 beinhaltet die Vorstellung zu effizienten, qualitativen Screening-Methoden. Hier werden die herausgearbeiteten Vorschläge zu einer Auswahl an heuristischen Methoden für die Selektion der perspektivisch wenig relevanten Faktoren beschrieben, die für die Umsetzung in der experimentellen statistischen Datenerhebung für maßgeblich erachtet werden. Weiter werden in Kapitel 5 darauf die Rahmenbedingungen für die zur statistischen Versuchsplanung neu herausgearbeiteten Versuchsplankonfigurationen für effiziente Lebensdauertests abgeglichen und schließlich bewertet. Als Ergebnis sind neben neuen, effizienten Versuchsplänen auch die relevanten Merkmale beschrieben, die es

bedarf, um Versuchspläne im Kontext von Lebensdauertests zu bewerten. Kapitel 6 . Abschließend stellt Kapitel 7 eine Zusammenfassung über die methodische Herangehensweise und die erreichten Ergebnisse der Arbeit zusammen und ordnet diese für künftige Forschungsbestrebungen im Bereich der multivariaten Lebensdauer-Versuchsplanung ein.

# 2 Stand der Technik und Forschung

Dieses Kapitel stellt die für diese Arbeit erforderlichen technischen und methodischen Grundlagen bereit. Zunächst werden in Abschnitt 2.1 zentrale Begriffe und Konzepte der Zuverlässigkeitstechnik sowie das grundlegende statistische Verfahren zur Lebensdauer-Datenanalyse in Kombination mit Versuchsplänen erläutert. Darauf aufbauend folgen in Abschnitt 2.2 die Einführung und die Einordnung von DoE für Lebensdaueruntersuchungen sowie der multivariaten Lebensdauermodellierung aus dem Stand der Technik und der Wissenschaft, die beide für die Entwicklung effizienter Lebensdauerversuchspläne maßgeblich sind. Im Kontext der Lebensdauererprobung umfasst dies insbesondere typische, statistische Versuchspläne sowie Metriken und Indikatoren zur allgemeinen Bewertung der Versuchspläne.

## 2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie

Die Zuverlässigkeitstechnik befasst sich mit der probabilistischen Beschreibung der Lebensdauer technischer Produkte und Systeme sowie der strategischen und statistischen Planung von Lebensdauertests. Ziel ist die statistische Modellierung des Ausfallverhaltens unter Berücksichtigung der Funktionalität des Produkts bei relevanten Randbedingungen. Eine zentrale Aufgabe besteht somit in der statistischen Charakterisierung des Ausfallbegriffs mithilfe deskriptiver Statistik sowie in der Parametrisierung geeigneter Verteilungen zur Abbildung des Lebensdauerverhaltens. Die Modellierung kann - abhängig von den Randbedingungen - auf Basis *einer einzelnen* Belastungsgröße oder *mehrerer* Beanspruchungsparameter erfolgen, die gemeinsam den Produktausfall determinieren. Ein grundlegendes Verständnis des Umgangs mit zufallsverteilten Lebensdauerereignissen ist daher eine elementare Voraussetzung für die statistische Versuchsplanung im Rahmen der Zuverlässig-

keitstechnik. Weiterführende Konzepte und vertiefte methodische Ansätze zur Zuverlässigkeitstechnik sowie zur statistischen Testplanung sind allen voran in der Standardliteratur von **Bertsche.2022** dargelegt, an deren Vorgehensweise sich die nachfolgende Übersicht orientiert.

### 2.1.1 Begriffe und Definitionen

Der **Ausfall**, engl. **End-of-Life (EoL)**, eines Produkts bezeichnet das Ende der Lebensdauer durch Verlust der geforderten Funktionalität. Maßgeblich hierfür sind von außen einwirkende **Belastungen** (*einzelne* oder zeitgleich *mehrere* Einflussparameter - Kräfte und Momente im mechanischen Kontext) sowie die daraus resultierenden inneren **Beanspruchungen** (innere Kräfte, Momente und lokale Spannungen). Die Ausfallzeit wird als kontinuierliche Zufallsvariable $\tau > 0$ verstanden. Die fundamentalen Funktionen zur probabilistischen Beschreibung des Lebensdauerverhaltens sind gemeinsam mit deskriptiven Statistiken in Tabelle 2.1 zusammengefasst [**Bertsche.2022**, **Meeker.2022**, **Birolini.2017**].

Tabelle 2.1: Mathematische Definitionen der Zuverlässigkeitsfunktionen

**Ausfallwahrscheinlichkeit** (engl. **Cumulative Distribution Function (*cdf*)**):
Wahrscheinlichkeit eines Ausfalls bis zum Zeitpunkt $t$.

$$F(t) = \Pr(\tau \leq t) = \int_0^t f(t)\,dt \tag{2.1}$$

**Zuverlässigkeit** (engl. Reliability):
Überlebenswahrscheinlichkeit über den Zeitpunkt $t$ hinaus.

$$R(t) = 1 - F(t) = \int_t^\infty f(t)\,dt \tag{2.2}$$

Tabelle 2.1 (*Fortsetzung*): Mathematische Definitionen

**Wahrscheinlichkeitsdichte** (engl. **Probability Density Function (*pdf*)**):
Änderungsrate der Ausfallwahrscheinlichkeit (Ausfallintensität).

$$f(t) = \frac{d}{dt}F(t) = \frac{d}{dt}\Pr(\tau \leq t), \quad t \geq 0. \tag{2.3}$$

**Ausfallrate** (engl. Hazard-Function):
Momentanes Ausfallrisiko, bedingt auf das Überleben bis $t$.

$$\lambda(t) = \lim_{\Delta t \to 0} \frac{\Pr(t < \tau \leq t + \Delta t | \tau > t)}{\Delta t} = \frac{f(t)}{R(t)} \tag{2.4}$$

### 2.1.2 Deskriptive Statistik für Lebensdauerdaten

Um die theoretischen Parameter der Grundgesamtheit in der Praxis nutzbar zu machen, müssen diese auf Basis empirisch ermittelter Lebensdauerdaten (Stichprobe vom Umfang $n$ mit Werten $x_1, \ldots, x_n$) approximiert werden. Die deskriptive Statistik liefert hierfür Methoden zur Berechnung von **Lageparametern** (Zentrum) und **Streuungsmaßen** (Breite). Tabelle 2.2 fasst die theoretischen Definitionen der Zufallsvariable $\tau$ sowie die grundlegenden Zuverlässigkeitsfunktionen und ihre korrespondierenden empirischen Schätzer kompakt zusammen.

Tabelle 2.2: Deskriptive Kennzahlen im Kontext der Lebensdaueranalyse

**Erwartungswert und Mittelwert**:
Erwartungswert $\mu$ des theoretischen Lageparameters der Grundgesamtheit. Der arithmetische Mittelwert $\bar{x}$ dient als üblicher, **empirischer Schätzer** für eine endliche Stichprobe.

$$\mu = E[\tau] = \int_0^\infty t \cdot f(t)dt \quad \text{geschätzt durch} \quad \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \tag{2.5}$$

**Quantile und Median**:
Das Quantil $t_q$ definiert den Zeitpunkt, an dem die Verteilung $F(t)$ den Anteil $q \in [0,1]$ erreicht. Der Median $t_{0.5}$ teilt die Fläche unter der $pdf$ in zwei Hälften [**Yang.2007**, **Fahrmeir.2016**].

$$F(t_q) = q \quad \text{bzw. für Median:} \quad F(t_{0.5}) = 0.5 \tag{2.6}$$

**Varianz und Standardabweichung**:
Die theoretische Varianz $\sigma^2$ (mittlere quadratische Abweichung) wird durch die erwartungstreue empirische Varianz $s^2$ geschätzt. Die empirische Standardabweichung folgt daraus zu $s = \sqrt{s^2}$.

$$\sigma^2 = E[(\tau - \mu)^2] \quad \approx \quad s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 \tag{2.7}$$

### 2.1.3 Parametrische Lebensdauermodelle

Während die deskriptiven Statistiken $\bar{x}$ und $s^2$ die zentrale Tendenz und die Streuung der vorliegenden Stichprobe quantifizieren, erlauben sie keine Extrapolation oder die Modellierung der zugrundeliegenden Funktionen $F(t)$ und $f(t)$ der Grund-

gesamtheit. Um eine prädiktive, mathematische Beschreibung des stochastischen Ausfallverhaltens zu erhalten, müssen die in Abschnitt 2.1.1 definierten Lebensdauerfunktionen durch geeignete parametrische Verteilungsmodelle approximiert werden. Andernfalls können nur nichtparametrische Modellierungsansätze zur Schätzung der kumulierten Wahrscheinlichkeit in Überlebensfunktionen wie beispielsweise nach **Kaplan.1958** genutzt werden [**Rigdon.2022**, **Meeker.2022**]. Die Verteilungsmodelle hingegen bieten eine geschlossene mathematische Form für *cdf* und *pdf* und ermöglichen es, das komplexe Ausfallverhalten durch eine geringe Anzahl von Parametern zu charakterisieren.

### Weibull-Verteilung

In der Zuverlässigkeitstechnik hat sich die **Weibull-Verteilung** aufgrund ihrer hohen Flexibilität als das am häufigsten verwendete Modell etabliert. Je nach zugrundeliegendem physikalischen Ausfallmechanismus finden jedoch auch andere statistische Verteilungen Anwendung, wie beispielsweise die **Lognormal-Verteilung** (häufig bei Ermüdungs-, Korrosions- oder Diffusionsprozessen), die **Exponentialverteilung** (zur Modellierung von Zufallsausfällen ohne Alterungseffekte) oder die **Beta-Verteilung** (allgemein zur formenreichen Modellierung von $R$ über dem festen Intervall $[0, 1]$). Für weitere Ausführungen dazu sei an dieser Stelle jedoch auf bereits ausreichend diskutierte Aufbereitungen von **Bertsche.2022**, **Birolini.2017**, **Yang.2007**, **Hedderich.2020**, **Rigdon.2022** verwiesen.

Die (zweiparametrige) Weibull-Verteilung ist das Standardmodell zur Beschreibung der Lebensdauer von technischen Produkten ohne die Berücksichtigung eines möglichen dritten Parameters - der ausfallfreien Zeit $t_0$. Sie wird durch den **Formparameter** $b > 0$ (Weibull-Modul) und die **charakteristische Lebensdauer** $T > 0$ (Skalenparameter), welche dem $63,2$-ten Perzentil $t_{0,632}$ entspricht, beschrieben. Unabhängig von $b$ gilt hier somit: $F(T) = 1 - e^{-1} \approx 63,2\%$. Folgt die Lebensdauer-Zufallsvariable $\tau$ dieser Verteilung, wird dies mathematisch als $\tau \sim \mathcal{W}(T, b)$ notiert. Damit ist sie in der Lage, alle drei Phasen der "Badewannenkurve"(Frühausfälle mit $b < 1$, Zufallsausfälle $b \approx 1$, Verschleißausfälle mit $b > 1$) durch die Wahl ihrer Parametrisierung abzubilden, vgl. **Bertsche.2022**. Die Einheit des Skalenparameters $T$ entspricht der des Messwertes. Die charakteristischen Funktionen und statistischen Momente der Weibull-Verteilung sind in Tabelle 2.3 zusammengefasst.

Tabelle 2.3: Funktionen und Kennzahlen der Weibull-Verteilung

**Dichte- und Verteilungsfunktion** (*pdf* & *cdf*)

$$f(t) = \frac{b}{T^b} t^{b-1} \exp\left[-\left(\frac{t}{T}\right)^b\right], \quad t > 0 \tag{2.8}$$

$$F(t) = 1 - \exp\left[-\left(\frac{t}{T}\right)^b\right], \quad t > 0 \tag{2.9}$$

**Ausfallrate** (Hazard-Funktion)

$$\lambda(t) = \frac{b}{T}\left(\frac{t}{T}\right)^{b-1}, \quad t > 0 \tag{2.10}$$

**Momente und Gamma-Funktion**
Mit der Gamma-Funktion (2.11) $\Gamma(x) = \int_0^\infty v^{x-1} e^{-v}\, dv$ ergeben sich Erwartungswert $\mu$ (vgl. Gleichung (2.5)) und Varianz $\sigma^2$ (vgl. Gleichung (2.7)) der Weibull-verteilten Lebensdauer $\tau$:

$$\mu = T \cdot \Gamma\left(1 + \frac{1}{b}\right) \tag{2.12}$$

$$\sigma^2 = T^2 \left[\Gamma\left(1 + \frac{2}{b}\right) - \Gamma^2\left(1 + \frac{1}{b}\right)\right] \tag{2.13}$$

Die Flexibilität der Verteilung zeigt sich in den Spezialfällen des Formparameters: Für $b = 1$ geht sie in die Exponentialverteilung über ($\lambda(t) =$ konst.), während sie sich für $b \approx 3,6$ einer Normalverteilung annähert (vgl. Abb. 2.1) [**Rinne.2008**, **Kececioglu.2002**].

### 2.1.4 Parameterschätzverfahren

Soll eine geschlossene mathematische Beschreibung des stochastischen Ausfallverhaltens eines Produktes gefunden werden, ist das im vorherigen Abschnitten 2.1.3

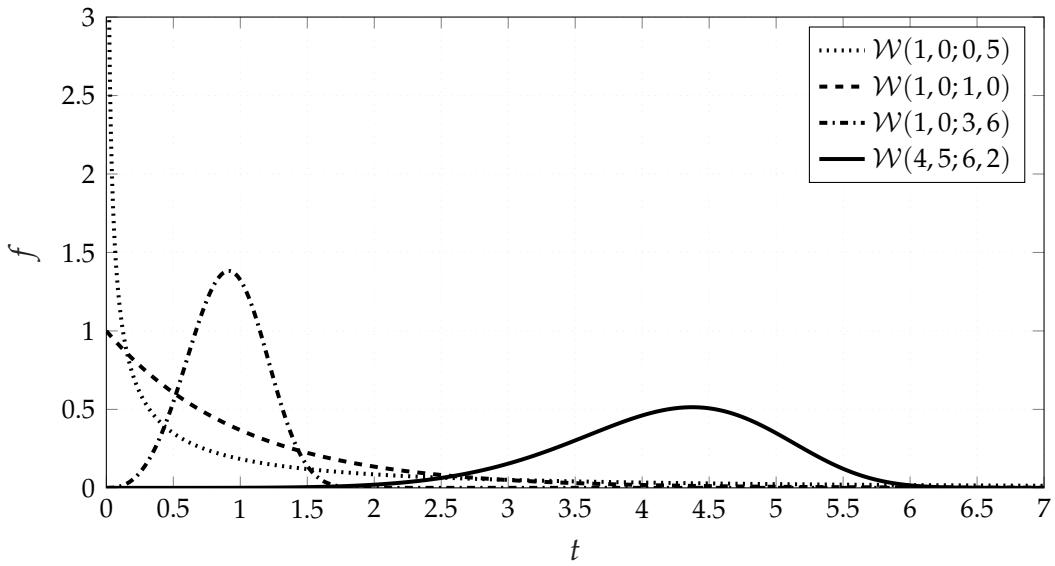


Abbildung 2.1: Weibull $f(t)$ für ausgewählte Werte von $T$ und $b$.

definierte parametrische Verteilungsmodell $\tau \sim \mathcal{W}(T, b)$ zu schätzen. Die Modellparameter der Grundgesamtheit sind in der praktischen Anwendung jedoch unbekannt. Die zentrale Problemstellung der **Parameterschätzung** besteht somit darin, aus der empirischen Stichprobe bestehend aus $n$ Realisierungen $t_1, \ldots, t_n$ der Zufallsvariable $\tau$ statistisch fundierte Schätzwerte $\hat{T}$ und $\hat{b}$ zu gewinnen. Diese sind Voraussetzung, um das Lebensdauermodell (z.B. Gleichung (2.9)) zu quantifizieren und prädiktive Aussagen zu Quantilen oder der Zuverlässigkeit $R(t)$ zu ermöglichen. Eine wesentliche Komplikation hierbei sind jedoch das mögliche Auftreten von unvollständigen bzw. **zensierten** Daten sowie *multivariate* Abhängigkeiten der Belastungen zur Messgröße. Während für die Schätzung von Verteilungsparametern einfache Verfahren, wie die **Momentenmethode** oder die **Methode der kleinsten Fehlerquadrate** - engl. **Ordinary Least Squares (OLS)**, die beispielsweise bei der **Median-Rank-Regression-Methode (MMR)** im Wahrscheinlichkeitsnetz Anwendung findet, existieren, sind diese für die umfassende Analyse vielschichtiger Lebensdauerdaten in der Regel unzureichend und hier nur der Vollständigkeit wegen erwähnt - vgl. [**Bertsche.2022**, **Montgomery.2021**]. Das universell anwendbare und robuste Verfahren, das Herausforderungen wie zensierte Daten und multivariate Modelle inhärent behandelt, ist die **Maximum-Likelihood-Estimation (MLE)** [**Meeker.2022**, **Nelson.1990**].

### Maximum-Likelihood-Estimation

Das Grundprinzip der MLE besteht darin, diejenigen Parameterwerte (z.B. $\hat{T}, \hat{b}$) als Schätzwerte auszuwählen, welche die Wahrscheinlichkeit (engl. Likelihood) maximieren, die empirisch beobachtete Stichprobe (bestehend aus unabhängigen Ausfällen und Zensierungen) zu erhalten. Mathematisch wird die Wahrscheinlichkeit der Realisierung von $\mathbf{t} = (t_1, \ldots, t_n)$ einer Stichprobe durch die **Likelihood-Funktion** $\mathcal{L}$ bestimmt. Diese ist eine Funktion des unbekannten Parametervektors $\boldsymbol{\theta}$, der $k$ zu schätzende Parameter enthält (z.B. $\boldsymbol{\theta} = (T, b)$ mit $k = 2$).

Für den vereinfachten Fall, dass die Stichprobe ausschließlich aus $n$ exakten Ausfallereignissen (vollständige Daten) besteht, ist die Likelihood-Funktion $\mathcal{L}$ das Produkt der einzelnen Wahrscheinlichkeitsdichten $f(\cdot)$:

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^{n} f(t_i|\boldsymbol{\theta}). \tag{2.14}$$

Zur Vereinfachung der numerischen Berechnung wird in der Anwendung die **Log-Likelihood-Funktion** $\Lambda$ verwendet. Durch die Logarithmierung wird das Produkt (Gleichung (2.14)) in eine äquivalente, leichter zu maximierende Summe überführt:

$$\Lambda := \ln\left(\mathcal{L}(\boldsymbol{\theta})\right) \propto \sum_{i=1}^{n} \ln\left[f(t_i|\boldsymbol{\theta})\right]. \tag{2.15}$$

Wie zuvor dargelegt, ist dieser vereinfachte Ansatz für Lebensdauerdaten jedoch oft unzureichend, da er das Auftreten von zensierten Daten vernachlässigt. Für die praktische Anwendung existiert jedoch die entsprechende Erweiterung der Likelihood-Funktion um die Differenzierung etwaiger Testausgänge als *Durchläufer*. Dazu wird die Stichprobe als Paarung von $t_i, \delta_i$ für $\mathbf{t}$ definiert, wobei $t_i$ der beobachteten Zeit und $\delta_i$ einem Statusindikator ($\delta_i = 1$ für einen exakten Ausfall; $\delta_i = 0$ für eine Rechts-Zensierung) entspricht [**Meeker.2022**, **Kalbfleisch.2002**]. $\mathcal{L}$ für rechts-zensierte Lebensdauerdaten lautet somit:

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^{n} \left[f(t_i|\boldsymbol{\theta})^{\delta_i} \cdot R(t_i|\boldsymbol{\theta})^{1-\delta_i}\right] \tag{2.16}$$

und definiert die Log-Likelihood Funktion als:

$$\Lambda := \ln\left(\mathcal{L}(\mathbf{t}|\boldsymbol{\theta})\right) \propto \sum_{i=1}^{n} \left[\delta_i \cdot \ln f(t_i|\boldsymbol{\theta}) + (1-\delta_i) \cdot \ln R(t_i|\boldsymbol{\theta})\right]. \tag{2.17}$$

Der Parametervektor $\hat{\boldsymbol{\theta}}$, der den Wert von $\Lambda(\boldsymbol{\theta})$ maximiert, liefert die MLE-Werte. Die Schätzwerte repräsentieren die (asymptotisch) effizientesten Schätzwerte für die Parameter der Grundgesamtheit. Dies erfolgt mathematisch durch Nullsetzen $k$ partieller Ableitungen von $\Lambda$, sofern mathematisch entsprechende Schätzwerte in geschlossener Form durch $\partial\Lambda/\partial\boldsymbol{\theta} \stackrel{!}{=} 0$ identifiziert werden können [**Nelson.2005**, **Rinne.2008**]. Andernfalls werden numerische Optimierungsalgorithmen, vgl. Newton-Raphson-Verfahren, Patternsearch und vergleichbare, dafür herangezogen - siehe weiterführend [**Nelson.2005**, **Qiao.1994**] sowie detaillierte Untersuchungen von **Kremer.2019b**. An dieser Stelle sei erwähnt, dass systematische Verzerrungen (engl. **Bias**) in $\hat{\boldsymbol{\theta}}$ aufgrund kleiner Stichprobenumfänge auftreten können [**Abernethy.2006**] - jedoch auch korrigierbar sind, vgl. Arbeiten von **Hirose.1999**, **Ross.1996**.

Die Qualität der Parameterschätzung beeinflusst daraus nicht nur die Prädiktionsgüte zur Schätzung der Lebensdauer oder Zuverlässigkeit - sie bedingt schließlich auch die Effizienz des Schätzverfahrens. Wird im Sinne eines effizienten Verfahrens zur multivariaten Lebensdauermodellbildung eine Methodik gesucht, ist auch die Qualität der Parameterschätzung damit entscheidend. Vertrauensbereiche, oder engl. **Confidence Intervals (CIs)**, können eine Metrik für die Qualität der Modellierung einnehmen, da sie die Unsicherheit oder *Unschärfe* in der Prädiktion bemessen.

Die MLE liefert nicht nur die Punktschätzer $\hat{\boldsymbol{\theta}}$, sondern auch die Quantifizierung von deren statistischer Unsicherheit (Präzision). Obwohl verschiedene Ansätze, wie die numerisch anspruchsvolleren Berechnungen nach Likelihood-Ratio-Methode, Bootstrap-Perzentil-Methode oder Monte-Carlo-Approximation existieren, ist das gängigste Verfahren zur Berechnung von CIs die Approximation mittels asymptotischer Normalverteilung der MLE-Schätzer $\hat{\boldsymbol{\theta}}$ [**Bertsche.2022**, **Nelson.1990**]. Dies erfolgt über die **Fisher-Informationsmatrix F**, welche die Information der Stichprobe über die Parameter $\boldsymbol{\theta}$ gemäß **Kremer.2019c** bezüglich des Rechenaufwands und resultierender Modellqualität vergleichsweise effizient quantifiziert. So wird diese Methodik auch in gängiger Applikationen als Standard angewandt, vgl. [**Nelson.2005**, **Nelson.1990**, **Yang.2007**]. In der praktischen Anwendung wird die Fisher-Informationsmatrix

auf Basis der resultierenden Schätzwerte $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}$ so als Schätzung zur Beobachtung nach $\mathbf{F}_{\mathrm{O}}$ verwendet [**Nelson.1990**, **Lawless.2003**]. Diese ist definiert als die negative **Hesse-Matrix** $\mathbf{H_f}$ der Log-Likelihood-Funktion, ausgewertet an der Stelle der MLE-Schätzwerte $\hat{\boldsymbol{\theta}}$:

$$\mathbf{F}_{\mathrm{O}} := -\mathbf{H_f}(\hat{\boldsymbol{\theta}}) = -\left[\frac{\partial^2 \Lambda(\boldsymbol{\theta})}{\partial\theta_j \partial\theta_l}\right]_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}}. \tag{2.18}$$

Die Matrix $\mathbf{H_f}$ entspricht der $(k \times k)$-Matrix der $k$ zweiten partiellen Ableitungen von $\Lambda$ (vgl. Gl. (2.17)). Eine Invertierung $\hat{\mathbf{F}}_{\mathrm{O}}^{-1}$ ergibt die geschätzte **Varianz-Kovarianz-Matrix** $\hat{\mathbf{V}}$:

$$\hat{\mathbf{V}} \approx \hat{\mathbf{F}}_{\mathrm{O}}^{-1}. \tag{2.19}$$

Die Diagonalelemente dieser Matrix $\hat{\mathbf{V}}_{jj}$ entsprechen den Varianzen $\mathrm{Var}(\hat{\theta}_j)$ der einzelnen Parameterschätzwerte [**Nelson.1990**]. Die Nicht-Diagonalelemente $\hat{\mathbf{V}}_{jl}$ (für $j \neq l$) repräsentieren die **Kovarianzen** $\mathrm{Cov}(\hat{\theta}_j, \hat{\theta}_l)$ [**Nelson.1990**, **Yang.2007**]. Diese Kovarianzen sind von entscheidender Bedeutung, da sie die statistische Abhängigkeit zwischen den Schätzwerten (z.B. zwischen $\hat{T}$ und $\hat{b}$) quantifizieren, welche für die Berechnung der CIs von abgeleiteten Funktionen wie $\hat{R}(t)$ erforderlich sind [**Meeker.2022**]. Basierend auf der Annahme der asymptotischen Normalität der Schätzer wird ein zweiseitiges $(1-\alpha)$-CI für einen einzelnen Parameter $\hat{\theta}_j$ direkt aus dessen Varianz approximiert durch:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\mathbf{V}}_{jj}}, \tag{2.20}$$

wobei $z_{1-\alpha/2}$ dem $(1-\alpha/2)$-Quantil der Standardnormalverteilung entspricht. Da Lebensdauerparameter (z.B. $T, b$) üblicherweise auf $\mathbb{R}_{>0}$ beschränkt sind, werden CIs robust über eine Log-Transformation der Parameter berechnet, um physikalisch unmögliche (negative) Intervallgrenzen zu vermeiden [**Meeker.2022**, **Yang.2007**, **Nelson.1990**]:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \exp\left(\pm z_{1-\alpha/2} \cdot \frac{\sqrt{\hat{\mathbf{V}}_{jj}}}{\hat{\theta}_j}\right). \tag{2.21}$$

Die Berechnung dieser CIs für Schätzwerte $g(\hat{\boldsymbol{\theta}})$ zu Größen wie $\hat{R}(t)$ oder $\hat{t}_q$ erfolgt mittels **Delta-Methode** [**Nelson.1990**, **Meeker.2022**]. Dieses auf einer Taylor-

Reihenentwicklung basierende Verfahren (Gauß'sche Fehlerfortpflanzung) approximiert die Varianz der Funktion $\hat{g} = g(\hat{\boldsymbol{\theta}})$ unter Einbeziehung der gesamten Varianz-Kovarianz-Matrix. Dazu wird der **Gradientenvektor** $\mathbf{g}'$ der Funktion $g$ (z.B. $g = R(t)$) bezüglich des $k$-dimensionalen Parametervektors $\boldsymbol{\theta}$ gebildet:

$$\mathbf{g}' := \left[\frac{\partial g(\boldsymbol{\theta})}{\partial \theta_1}, \ldots, \frac{\partial g(\boldsymbol{\theta})}{\partial \theta_k}\right]^T_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}}. \tag{2.22}$$

Die approximierte Varianz $\mathrm{Var}(\hat{g})$ der Funktion ergibt sich dann aus:

$$\mathrm{Var}(\hat{g}) \approx \mathbf{g}'^T \hat{\mathbf{V}} \mathbf{g}'. \tag{2.23}$$

Das Vertrauensintervall für die Funktion $\hat{g}$ wird anschließend unter Verwendung dieser Varianz (bzw. des Standardfehlers $\sqrt{\mathrm{Var}(\hat{g})}$) analog zu Gleichung (2.20) berechnet [**Bain.2017b**, **Yang.2007**, **Nelson.1990**]:

$$[g_u, g_o] = \hat{g} \pm z_{1-\alpha/2}\sqrt{\mathrm{Var}(\hat{g})}. \tag{2.24}$$

Sollen auch hier nur positive Werte für $g$ berücksichtigt werden, kann eine Logarithmierung in der Berechnung der Vertrauensbereiche analog zu Gl. 2.21 erfolgen [**Yang.2007**].

## 2.2 Statistische Versuchsplanung und Modellbildung

Multivariate Lebensdauertests erfordern definitionsgemäß die Betrachtung mehrerer $k \geq 2$ Einflussfaktoren als Versuchsparameter. Dementsprechend entscheidend ist das Verständnis der wesentlichen Grundlagen im Umgang mit statistischer Versuchsplanung (DoE) für Lebensdauerdaten - auch unter dem Begriff **Lifetime Design of Experiments (L-DoE)** zusammengefasst - sowie der darauffolgenden Lebensdauermodellbildung. Während detaillierte Übersichten zur Historie von DoE von anfänglichen einschlägigen Beschreibungen durch **Fisher.1935**, außerdem maßgebliche Weiterentwicklungen durch **Box.1978** oder evolutionäre Schritte durch **Taguchi.2005** ausgiebig in Werken von **Kleppmann.2020**, **Rigdon.2022**, **Montgomery.2020** beschrieben sind, wird im Folgenden auf die wesentlichen Inhalte für die Forschungsschwerpunkte eingegangen.

Der primäre Anspruch von DoE besteht in der effizienten Planung empirischer Datenerhebungen, um Zielgrößen in Abhängigkeit erklärender Variablen zunächst robust zu modellieren und schließlich zu optimieren. Dieses Paradigma lässt sich auch unter der Begrifflichkeit Design for Reliability (DfR) unmittelbar wiedererkennen und so auf die Analyse von Lebensdauer und Zuverlässigkeit übertragen [**Yang.2007**, **Wu.2021**]. Da das lokale oder globale Optimum der Lebensdauer- bzw. Zuverlässigkeitsfunktion eines Produktes a priori meist unbekannt ist, erfordert dessen Identifikation eine systematische Exploration des Parameterraumes. Eine besondere Herausforderung stellt hierbei zusätzlich die Integration von ALT dar: Die Diskrepanz zwischen dem hochbelasteten Testraum (engl. **Design Space**) und dem regulären **Prädiktionsraum** (engl. Use Space oder **Field Space**) kann eine **Extrapolation** erforderlich machen, welche die Anforderungen an die Daten- und somit auch an die Designqualität deutlich verschärft. Für umfassendere Ausführungen zu Forschungserkenntnissen in ALT sei hierbei insbesondere auf Arbeiten von **Meeker.1993**, **Meeker.2022**, **Nelson.1990**, **Elsayed.2007** verwiesen. Das Unwissen zur tatsächlichen Lage optimaler Antwortwerte und die Möglichkeit, per se einen systematischen Offset zwischen Design- und Field-Space durch ALT vorzufinden, stellen Teststrategien nach Best-Guess Ansätzen nachteilig. Hier wird in der industriellen Praxis häufig fälschlicherweise ein **One Factor At Time (OFAT)**-Testing Ansatz gewählt - unabhängig, ob vom Vorhandensein von Lebensdauer- oder anderen Daten, welcher schlichtweg die Wahrscheinlichkeit, Optimalstellen im Parameterraum systematisch zu treffen, senkt und somit gegenüber L-DoE nachteilig ist, vgl. [**Montgomery.2020**, **Siebertz.2026**]. Da nun die geometrische Struktur eines Versuchsplans die erreichbare Modellierungsqualität deterministisch begrenzt, ist eine präzise Bewertung der Plangüte anhand genau dieser Eigenschaft im Vorfeld unerlässlich. Hierfür können objektive **Performance-Indikatoren** sowie mathematische **Optimalitätskriterien** dienen, vgl. [**Montgomery.2020**, **Goos.2011**]. Ergänzend zu rationalen Metriken wie der statistischen **Trennschärfe** (engl. **Power**) und dem Schätzergebnis einer **Koeffizienten**- bzw. Parameterschätzung sind diese Größen damit bestimmend für effiziente multivariate Lebensdauertests.

Vor diesem Hintergrund fokussiert sich dieser Abschnitt auf eine gezielte Auswahl an Grundbegriffen und Metriken für multivariate Testpläne im Kontext von L-DoE sowie auf eine Übersicht der für Lebensdauertests geeigneten Versuchspläne, bevor abschließend die statistische Modellbildung beleuchtet wird.

Für eine grundsätzlichere Auseinandersetzung mit konventionellen Methoden und Werkzeugen von DoE sei, mit Blick auf den Fokus der vorliegenden Arbeit, hingegen auf die einschlägige Literatur von **Kleppmann.2020**, **Siebertz.2026**, **Hinkelmann.2012** sowie vornehmlich **Montgomery.2020** und **Myers.2016** verwiesen. Diese Werke behandeln intensiv die Inhalte grundsätzlicher statistischer Versuchsplanung, welche um Perspektiven zu L-DoE bereits durch am Institut für Maschinenelemente (IMA) entstandene Dissertationen von **Dazer.2019**, **Herzig.2021**, **Grundler.2024** und maßgeblich durch **Kremer.2021** fortschreitend ergänzt wurden. Konsequenterweise werden Hintergründe zum Umgang mit normalverteilten Daten oder Abweichungen davon im Rahmen des DoE, die Diskussion zu einschlägigen Vor- und Nachteilen auch unter Abgrenzung zu Alternativen wie OFAT, die Regressionsmodellierung auf Basis der **Varianzanalyse, engl. Analysis of Variance (ANOVA)**, konventionelle Hypothesentests sowie fundamentale Ausführungen zu ALT in den nachfolgenden Ausführungen nicht explizit betrachtet, sondern als bekannt vorausgesetzt.

### 2.2.1 Grundlagen zur statistischen Versuchsplanung

Die Anwendung von DoE versteht sich grundsätzlich als Verfahrenskette entlang mehrerer Prozessschritte [**Coleman.1993**, **Montgomery.2020**], die beginnend von einer spezifischen Aufgabendefinition in einer statistisch abgesicherten Testentscheidung und Datenmodellierung mündet, vgl. Abbildung 2.2. Das erklärte Ziel ist es,

1. Definition des Untersuchungsziels
2. Identifizierung von Einflussparametern und Systemantwort
3. Auswahl von Faktoren, Stufen und Parameterbereich
4. Auswahl des Versuchsplans
5. Durchführung der Versuchsreihe gemäß Versuchsplan
6. Statistische Datenanalyse
7. Schlussfolgerungen und Empfehlungen/Optimierung

Abbildung 2.2: DoE Steps gemäß [**Coleman.1993**]

den kausalen Zusammenhang zwischen Einflussfaktoren und Systemantwort funktional abzubilden. Darin abgebildete Einflussfaktoren sollen also per se **statistisch signifikant** und somit relevant für das Systemverhalten sein. So kann beispielsweise

die zufallsverteilte Lebensdauer $\tau$ in Abhängigkeit von $k \geq 2$ technischen Beanspruchungen zunächst empirisch untersucht und anschließend modelliert sowie optimiert werden (*Schritt 1* in Abbildung 2.2).

Im Zentrum der Betrachtung steht damit generell ein technisches **System**, welches abstrakt als Produkt oder Prozess verstanden wird und den Zustand der Ausgangsgröße in Abhängigkeit der **d**efiniert. Die zu untersuchende oder zu optimierende Ausgangsgröße wird als **Systemantwort** $y$ (engl. **Response**) bezeichnet. Die gezielt kontrollierbaren und variierten Eingangsgrößen sind **Faktoren** (**Steuergrößen**), während nicht kontrollierbare oder unbekannte Einflüsse als **Störgrößen** (engl. **Noise**) klassifiziert werden (*Schritt 2*, vgl. [**Kleppmann.2020**]). Eine visuelle Aufstellung des genannten Zusammenspiels der Parameter kann dem Parameterdiagramm, kurz **P-Diagramm**, in Abbildung 2.3 entnommen werden [**Montgomery.2020**]. Um

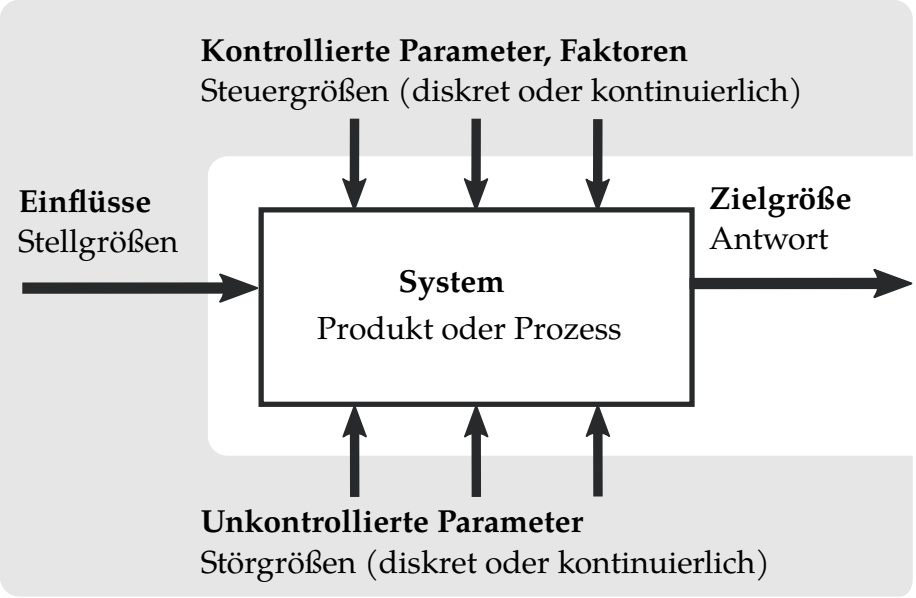


Abbildung 2.3: Parameter-Diagramm (P-Diagramm)

das Systemverhalten zu charakterisieren, werden die Faktoren als kategoriale oder kontinuierliche Parameter im Versuch auf diskreten Werten, den sogenannten **Faktorstufen** (engl. **Level**), variiert (*Schritt 3*). Dies erfolgt in aller Regel in kodierter Darstellung, so entsprechen gemäß der gängigsten Konvention die Stufe *-1* der niedrigen und *+1* der hohen Einstellstufe. Die planerische Kombination verschiedener Faktorstufen äußert sich in spezifischen **Versuchspunkten** innerhalb des Parameterraums und entspricht der Versuchsplan-Matrix [**Kleppmann.2020**, **Siebertz.2026**].

Der **Versuchsraum** (engl. **Design Space**) wird hierbei durch die Gesamtheit der technisch realisierbaren und im Versuch einstellbaren Parameterkombinationen aufgespannt. Die Auswahl geeigneter statistischer Versuchspläne (*Schritt 4*) für die Durchführung (*Schritt 5*) wird in Abschnitt 2.2.3 detailliert behandelt.

Die aus der Variation resultierende Änderung der Systemantwort quantifiziert den Einfluss des Faktors, der statistisch als **Effekt** $E$ bezeichnet wird und den Mittelwertunterschiede zweier Faktorstufen beschreibt (*Schritte 6-7*). Mittels **Kontrastmethode** wird also die Änderung der Systemantwort über alle durchgeführten Versuche mit jeweiligen Faktorstufen registriert [**Kleppmann.2020**, **Montgomery.2020**]:

$$E = \frac{1}{n|_{+1}} \sum y|_{+1} - \frac{1}{n|_{-1}} \sum y|_{-1} \tag{2.25}$$

So können mittels DoE strukturiert, effizient und verbindlich Informationen gewonnen werden, die über die direkten Effekte hinausgehen und differenziert Aufschluss über **Haupteffekte** sowie etwaige **Wechselwirkungen** der Faktoren auf die Antwort des Systems geben - vergleiche Abb. 2.4 sowie **Montgomery.2020**, **Kleppmann.2020**, **Siebertz.2026**, **Kremer.2021**. Abbildung 2.4 visualisiert derartige Effekte. So gibt die Darstellung eines Haupteffekts in Abhängigkeit des Vorzeichens und der Steigung (**positiver** oder **negativer** Haupteffekt) sozusagen die Einflussstärke und -richtung wieder, während bei Wechselwirkung der Effekt in Abhängigkeit der Einstellung eines **Co-Faktors** dargestellt wird. Diese Zusammenhänge können mathematisch

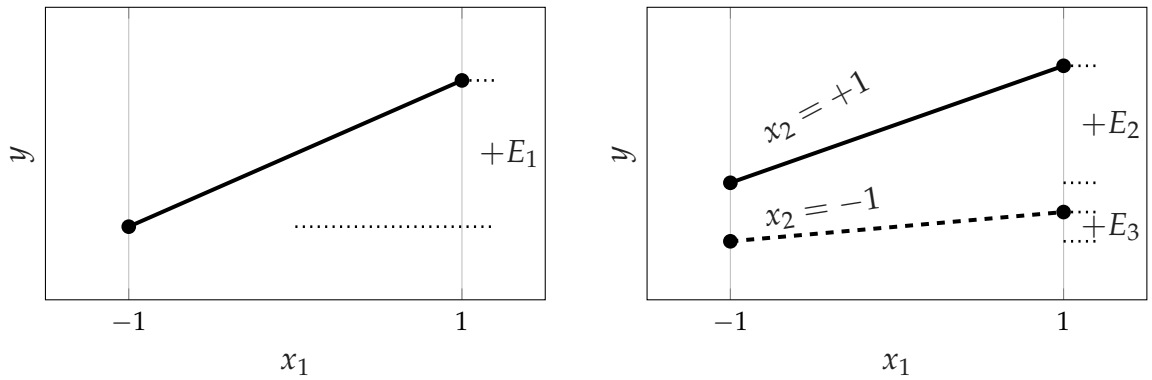


(a) Positiver Haupteffekt $E_1$ (b) Wechselwirkungseffekte $E_2$ und $E_3$

Abbildung 2.4: Schematische Darstellung der Effekte: (a) positiver Haupteffekt von Faktor $x_1$, (b) Wechselwirkungseffekte zwischen $x_1$ und $x_2$.

positiv oder negativ beschrieben sowie durch Polynomfunktionen höherer Ordnung approximiert werden, um zusätzlich beispielsweise **quadratische Effekte** oder **Mehrfachwechselwirkungen** abzubilden. In einem einfachen Fall wird für die lineare Beschreibung des Einflusses von Faktoren auf eine Antwortvariable ein durchschnittlicher Effekt durch eine Regressionskonstante $\beta_0$ sowie Haupteffekte durch die Regressionskoeffizienten $\beta_j, j = 0, 1, \ldots, k$ zu einem Regressionsmodell erster Ordnung geschätzt. Falls relevant, erfolgt die Ergänzung um die jeweilige Wechselwirkung und einen Fehlerterm $\epsilon$ als Zufallsvariable für Abweichungen durch Mess- und Streufehler [**Montgomery.2020**, **Myers.2016**, **Rigdon.2022**]. Beispielhaft $k = 2$ Faktoren resultiert daraus:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \epsilon. \tag{2.26}$$

Ein Modell zweiter Ordnung enthält zudem quadratische Terme, welche üblicherweise in Optimierungsaufgaben - so auch in der Lebensdauer- und Zuverlässigkeitsanalyse - relevant werden können:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \tag{2.27}$$

Die Gleichung der Modellierung kann so zur einfacheren Handhabung auch in Matrixnotation notiert werden und resultiert in:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \tag{2.28}$$

wobei $\boldsymbol{\beta}$ als $p \times 1$ Vektor der Regressionskoeffizienten ($p = k + 1$) durch den $n \times 1$ Vektor $\mathbf{y}$ aller Beobachtungen sowie durch die Versuchsplan-Matrix $\mathbf{X}$ ($n \times p$ Einträge) unter Zuhilfenahme eines geeigneten Schätzverfahrens (vgl. Abschnitt 2.1.4) zu ermittelten ist [**Yang.2007**, **Nelson.2005**]. Sollen zunächst perspektivisch relevante Faktoren für eine versuchstechnische Untersuchung identifiziert werden, kann ein **Parameter-Screening** durchgeführt werden. Dessen Durchführung kann sowohl heuristisch als auch versuchstechnisch erfolgen.

### 2.2.2 Parameter-Screening

Angesichts der potenziell hohen Komplexität durch Wechselwirkungen und Nichtlinearitäten sind die in Abbildung 2.2 beschriebenen *Schritte 2-3* als propädeutische Arbeiten für ein effizientes Testdesign zu interpretieren. Methodisch lassen sich diese unter dem Terminus **Screening** subsumieren. Screening-Schritte sind zwischen der Definition des Untersuchungsziels und der Durchführung der physischen Screening-Experimente angeordnet (vgl. *Schritt 3* in Abbildung 2.2 sowie Abschnitt 2.2.3). Daraus folgend dienen Screening-Methoden und -Versuchspläne dem Ziel, Informationsverluste bei einer minimalen Anzahl an Versuchsläufen zu begrenzen und die vitalen (*Steuergrößen*) von den trivialen (*Störgrößen*) Faktoren zu separieren, vgl. Abbildung 2.3.

Im Hinblick auf die Realisierung eines unter Zeit- und Kostenrestriktionen hochgradig effizienten DoE ist die effiziente Ausgestaltung der Screening-Strategie selbst schon von primärem Interesse. In traditionellen DoE-Ansätzen impliziert dies den Einsatz von **Kreativmethoden**, wie sie Standardliteratur von **Montgomery.2020** aufführen oder exemplarisch durch **Kremer.2021** und **Gundlach.2004** zusammengefasst werden. Hierbei ist ein Rückgriff auf Ergebnisse aus Experimenten, die explizit für das Forschungsziel ausgelegt wären, in dieser Phase unter Umständen noch nicht möglich. Es gilt damit zunächst, qualitativ eine rein rational erlesene Sammlung an potenziellen Einflussparameter zu erstellen, um diese dann anhand ihrer geschätzten Einflüsse auf die Systemantwort zu priorisieren. Ansätze aus der Kreativmethodik können dazu genutzt werden und fundieren auf der technischen **Systemanalyse**, die sowohl mit als auch ohne spezifisches Vorwissen über das System erfolgen kann [**Bertsche.2022**]. Hilfsmittel zur Priorisierung einer hier erstellten Parametersammlung können beispielsweise Entscheidungsfindungsprotokolle, wie die Design-Structure-Matrix (DSM), und Methoden aus dem Komplexitätsmanagement, z.B. **Ishikawa-Diagramm**, sein - siehe hierzu auch weiterführende Werke von **Mayers.1997**, **Pahl.2007**,**Wu.2021**, **Daenzer.2002** sowie **Lindemann.2008**. Das Screening liefert somit eine rational festgestellte Auswahl an möglichst wenigen Einflussparametern, die mutmaßlich den entscheidenden Anteil an statistisch begründeter Manipulation der Systemantwort tragen und sich daher für eine Untersuchung in Versuchsplänen qualifizieren. Entsprechend ist daraufhin ein geeigneter Versuchsplan für die physischen Datenerhebungen zu wählen.

### 2.2.3 Statistische Versuchsplanung zur Lebensdauererprobung

Standardprotokolle aus dem DoE wie der $2^k$ **voll-faktorielle Versuchsplan** eignen sich grundsätzlich auch für Lebensdaueruntersuchungen, da sich hier analog zu vergleichbar statistisch verteilter Datenlage Effekte stets als (Mittelwert-) Unterschiede in der Beobachtung der Systemantwort aus dem Vergleich zweier Einstellstufen eines oder mehrerer Faktoren ergeben [**Kleppmann.2020**].

#### $2^k$ Faktorielle Versuchspläne

Demzufolge kann auch ein Lebensdauer-beeinflussendes Parameterset - beispielhaft $(x_1, x_2)$ - voll-faktoriell auf zwei Stufen variiert und vollständig kombiniert werden, vgl. Abbildung 2.5. Ein derartiges Setup erlaubt es, die perspektivische Differenz er-

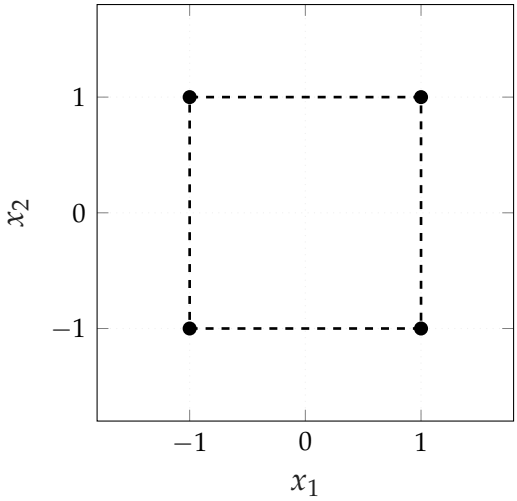


(a) Versuchsplan

| Faktorstufen-Kombination | Faktoren und Wechselwirkung | | |
|---|---|---|---|
| # | $x_1$ | $x_2$ | $x_1x_2$ |
| 1 | $-1$ | $-1$ | $+1$ |
| 2 | $+1$ | $-1$ | $-1$ |
| 3 | $-1$ | $+1$ | $-1$ |
| 4 | $+1$ | $+1$ | $+1$ |

(b) Versuchsplanmatrix zu Abb. 2.5a

Abbildung 2.5: Standard voll-faktorieller Versuchsplan

reichbarer EoL-Werte durch niedrige und hohe Beanspruchungswerte der Faktoren zu beobachten [**Yang.2007**, **Meeker.2022**]. Der voll-faktorielle Versuchsplan bildet somit den Standard-Versuchsplan im DoE und fordert bei einmaliger Durchführung (**Replikation** $m = 1$)

$$n = 2^k \tag{2.29}$$

Versuche. Dieser Stichprobenumfang stellt sicher, dass das resultierende Gleichungssystem **gesättigt** ist: Mit $n$ Versuchen lassen sich $n - 1$ Effekte für Hauptfaktoren und

Wechselwirkungen eindeutig bestimmen. Von entscheidender Bedeutung für die Aussagekraft des Versuchsplans ist die Wahl der Faktorstufen (vgl. Abbildung 2.6). Die Differenz der gewählten Level muss bereits im Vorfeld definiert werden, sodass signifikante Effekte sicher detektiert werden - vgl. **Signal-zu-Rausch Verhältnis, engl. Signal-to-Noise Ratio (SNR)** [**Montgomery.2021**] - wobei gleichzeitig zu geringe Abstände (Rauschen) sowie zu große Intervalle (Gefahr unerkannter Nichtlinearitäten) zu vermeiden sind, siehe auch Abbildung 2.6 sowie **Wu.2021**, **Siebertz.2026**, **Kleppmann.2020**. Auf Basis eines solchen zweistufigen Setups lässt

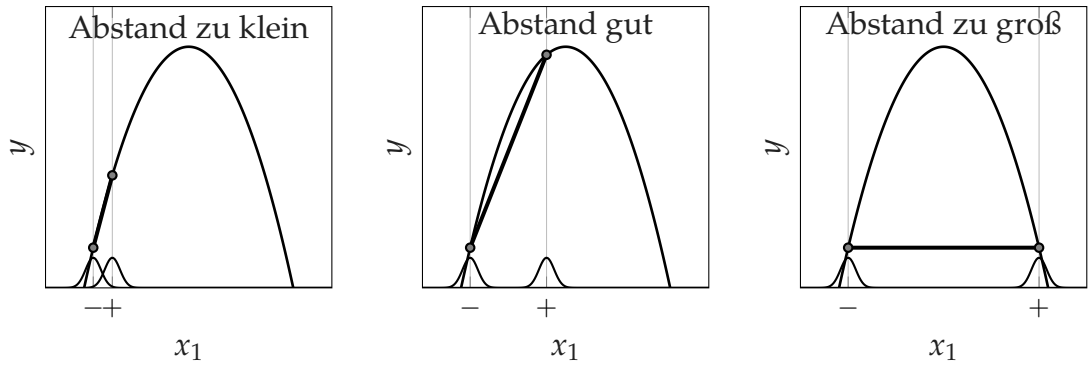


Abbildung 2.6: Einfluss der Schrittweite auf die Approximation des Effekts $E$

sich der Zusammenhang zwischen Einflussgrößen und Lebensdauer interpolieren und in einem linearen Modell abbilden, welches zudem die Schätzung von Wechselwirkungen erlaubt. Werden davon abweichende Modellterme zur Abbildung der Systemantwort erwartet, berücksichtigen alternative Versuchspläne typischerweise drei bis fünf Faktorstufen. Der voll-faktorielle Versuchsplan nimmt dabei eine entscheidende Schlüsselrolle in der strategischen Modellbildung ein - insbesondere im Hinblick auf Lebensdauerdaten und Zuverlässigkeitstechnik. Darin aufgeführte Versuchspunkte können auf Basis der Struktur ihrer Zuordnung üblicherweise ideal aus Voruntersuchungen übernommen oder durch weiterführende Untersuchungen nachfolgend erweitert werden. Ausgehend vom qualitativen Parameter-Screening (vgl. Abschnitt 2.2.1) ist ohne initiale Experimente oft unklar, welche Faktoren die Antwortvariable, also beispielsweise die Lebensdauer eines Systems, nun tatsächlich signifikant beeinflussen. Folglich ist es essenziell, diese Fragestellung vor der eigentlichen Versuchsplanumsetzung effizient zu klären.

### $2^{k-p_f}$ Fraktionell Faktorielle Versuchspläne

Sind nach Anwendung der Kreativmethoden (qualitatives Screening) weiterhin so viele Einflussfaktoren als relevant eingestuft, dass ein voll-faktorieller Ansatz gemäß Gleichung 2.29 zu einem wirtschaftlich nicht vertretbaren Versuchsumfang führen würde, muss die Strategie hin zu physikalischen Screening-Tests verschärft werden. Dies empfiehlt sich insbesondere für Systeme mit $k > 5$ Faktoren, um die experimentelle Effizienz zu gewährleisten. Zur Veranschaulichung der Notwendigkeit: Bereits eine einzelne Replikation eines voll-faktoriellen Experiments mit $k = 8$ Faktoren würde $2^8 = 256$ Versuchsdurchläufe erfordern, was in der Lebensdauererprobung meist illusorisch ist.

Für derartige Selektionsaufgaben eignen sich daher **Screening-Versuchspläne**, wie der **teil-faktorielle Versuchsplan** (Fractional Factorial Design) oder alternativ der **Plackett-Burman-Plan** [**Kleppmann.2020**, **Siebertz.2026**, **Montgomery.2020**]. Bei diesem Ansatz wird lediglich eine selektive Teilmenge (Fraktion) der voll-faktoriellen Versuchsagenda umgesetzt, um mit minimalem Informationsverlust die für den Anwendungsfall signifikanten Effekte zu beschreiben. Mathematisch wird die Anzahl der Versuche dabei auf

$$n = 2^{k-p_f} \tag{2.30}$$

reduziert, wobei $p_f$ den Grad der Fraktionierung (die Anzahl der Generatoren) angibt. Die Validität dieses Vorgehens stützt sich auf zwei fundamentale empirische Postulate [**Montgomery.2021**, **Rigdon.2022**]:

- Die **Effekthierarchie** besagt, dass Effekte niedrigerer Ordnung – primär Haupteffekte – in der Regel eine größere Amplitude aufweisen und mit höherer Wahrscheinlichkeit signifikant sind als Effekte höherer Ordnung.

- Die **Effektvererbung** impliziert, dass das Auftreten signifikanter Wechselwirkungen oder quadratischer Terme strukturell an die Signifikanz ihrer korrespondierenden Haupteffekte gekoppelt ist.

Eine direkte Konsequenz dieser Reduktion („Der Preis der Einsparung“) ist jedoch, dass sich in teil-faktoriellen Versuchsplänen bestimmte Effekte nicht mehr isoliert betrachten lassen (vgl. Abbildung 2.5a für den Fall einer Fraktionierung). So sind beispielsweise Haupteffekte unter Umständen nicht mehr zweifelsfrei von Wechsel-

wirkungen höherer Ordnung zu unterscheiden. Da sich diese Effekte statistisch überlagern, spricht man von einer **Vermengung** (engl. **Aliasing**). Die Schwere dieser Vermengung wird dabei über die **Auflösung** (engl. Resolution) des Versuchsplans klassifiziert (z. B. Auflösung III, IV oder V). Wird dieser Informationsverlust jedoch bewusst in Kauf genommen und ingenieurwissenschaftlich bewertet, ermöglicht dies eine signifikante Reduktion des Versuchsumfangs, um effizient die dominanten Faktoren aus der initialen Parametermenge zu isolieren. Diese Vorgehensweise ist von hoher Relevanz, da Lebensdauertests – ob als beschleunigte Prüfung mittels ALT oder unter Feldbedingungen – durch die inhärente Zeitabhängigkeit der Systemantwort erhebliche Kapazitäten binden und Ergebnisse nicht ad hoc verfügbar sind. Im Sinne einer ressourceneffizienten Gesamtstrategie sollten die Screening-Versuche daher idealerweise so konzipiert sein, dass sie nahtlos in einen nachfolgenden, höher aufgelösten Versuchsplan integriert (**augmentiert**) werden können.

### Wirkungsflächenversuchspläne

Die bisher diskutierten Versuchspläne beschränken sich auf die Untersuchung von Faktoren auf jeweils zwei Stufen ($\pm 1$). Dies ermöglicht zwar eine effiziente Darstellung linearer Beziehungen und Interaktionen, jedoch ist die Modellierung komplexerer, nicht-linearer Effekte aufgrund fehlender Stützstellen im Versuchsraum damit physikalisch nicht möglich. Perspektivisch ist daher entscheidend, wie die bestehende Datenbasis weitergenutzt und augmentiert werden kann, falls die Systemantwort signifikante **Krümmungen** (engl. **Curvature**) aufweist und die quantitativen Beziehungen zwischen Faktoren und Zielgröße für eine Optimierung detaillierter beschrieben werden müssen.

Die **Response Surface Methodology (RSM)** behandelt als Teildisziplin des DoE derartige Herangehensweisen und bietet hierfür spezielle **Wirkungsflächenversuchspläne** - engl. **Response Surface Designs (RSDs)** - an. Der erste Schritt zur Detektion von Nichtlinearitäten besteht in der Integration von $n_C$ sogenannten **Zentralpunkte (ZPs)**, engl. **Center Points (CPs)**, in den faktoriellen Basisplan. Hierbei werden alle Faktoren auf die kodierte Stufe *0* (die Mitte des Versuchsraums) gesetzt. Weicht der Mittelwert der Systemantwort in den ZPs signifikant vom Mittelwert über die faktoriellen Eckpunkte ab, deutet dies auf eine Krümmung der Antwortfläche hin [**Montgomery.2020**].

Um diese quadratischen Zusammenhänge explizit zu bestimmen, gilt der **Zentral-Zusammengesetzte-Versuchsplan**, engl. **Central Composite Design (CCD)**, als etablierter Standard. Ein CCD entsteht durch die Augmentierung des ursprünglichen voll- (oder teil-)faktoriellen Plans (den $n_F$ Eckpunkten), vgl. Abbildung 2.7, um:

- eine definierte Anzahl $n_C$ an wiederholten ZPs (üblicherweise $3 \leq n_C \leq 5$ zur Abschätzung des reinen Fehlers) sowie
- $n_S = 2 \cdot k$ zusätzliche **Sternpunkte (SPs)** (engl. **Axial Points** oder **Star Points**), die auf den Achsen des Koordinatensystems im Abstand $\pm\alpha_D$ vom Zentrum liegen.

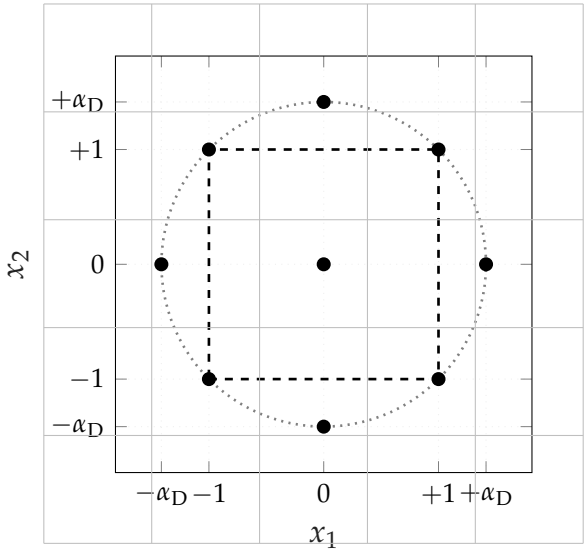


(a) Versuchsplan (CCD)

| Versuchs-# | Faktorstufen $x_1$ | $x_2$ |
|---|---|---|
| 1 | $-1$ | $-1$ |
| 2 | $+1$ | $-1$ |
| 3 | $-1$ | $+1$ |
| 4 | $+1$ | $+1$ |
| 5 | $-\alpha_D$ | 0 |
| 6 | $+\alpha_D$ | 0 |
| 7 | 0 | $-\alpha_D$ |
| 8 | 0 | $+\alpha_D$ |
| 9 | 0 | 0 |
| 10 | 0 | 0 |
| 11 | 0 | 0 |
| 12 | 0 | 0 |
| 13 | 0 | 0 |

(b) Versuchsplanmatrix (Stufen) zu Abb. 2.7a

Abbildung 2.7: Zentral zusammengesetzter Versuchsplan (CCD) mit $k = 2$

Während die ZPs das Vorhandensein quadratischer Effekte validieren, ermöglichen die SPs deren Wertbestimmung. Die Wahl des Abstands $\alpha_D$ wird primär durch die Geometrie des interessierenden Versuchsraums (**Region of Interest**) diktiert. Betrachtet man diesen Raum als Kugel (**sphärisch**), ist die **Drehbarkeit** (**Rotierbarkeit**,

engl. **Rotatability**) ein wesentliches Qualitätsmerkmal. Sie stellt sicher, dass die Varianz der Vorhersage nur vom Abstand zum Zentrum abhängt und invariant gegenüber einer Rotation des Koordinatensystems ist. Um diese Eigenschaft zu gewährleisten, berechnet sich der Abstand $\alpha_{\mathrm{D}}$ in Abhängigkeit der faktoriellen Versuchspunkte $n_{\mathrm{F}}$ zu [**Box.1957**, **Montgomery.2020**]:

$$\alpha_{\mathrm{D}} = (n_{\mathrm{F}})^{1/4}. \tag{2.31}$$

Alternativ kann für sphärische Räume auch $\alpha_{\mathrm{D}} = \sqrt{k}$ gewählt werden (**Sphärisches CCD**), wodurch alle Versuchs- und SPs auf einer Kugeloberfläche liegen [**Myers.2016**]. Ist der Versuchsraum hingegen durch harte physikalische Grenzen (z.B. maximale Temperatur) kubisch beschränkt, bietet sich der **flächenzentrierte CCD** (**Face Centered CCD**) an. Hierbei wird $\alpha_{\mathrm{D}} = 1$ gesetzt, sodass die SPs direkt auf den Flächenmitten des Würfels liegen. Dies vereinfacht die Durchführung, da nur drei Faktorstufen ($-1$, $0$, $+1$) benötigt werden, opfert jedoch die Eigenschaft der Rotierbarkeit. Eine effiziente Alternative zum CCD stellt das **Box-Behnken-Design** dar [**Box.1960**]. Dieses Design kombiniert $2^k$-Faktorielle mit unvollständigen Blockplänen und platziert Versuchspunkte auf den Kantenmitten des Versuchsraums, vermeidet jedoch die extremen faktoriellen Versuchspunkte. Dies kann vorteilhaft für Lebensdauertests sein, bei denen extreme Ecken oft zu verfrühten Ausfällen führen können. Zudem ist es bei korrekter Wahl der ZPs alias-optimal gegenüber kubischen Modellen [**Jones.2011**]. Stoßen Standard-Designs (CCD, Box-Behnken) aufgrund von Restriktionen im Versuchsraum (**Constraints**), nicht-standardmäßigen Modellierungszielen oder ungewöhnlichen Stichprobenumfängen an ihre Grenzen, empfiehlt sich der Einsatz von **Optimalen Versuchsplänen**, vergleiche übernächsten Abschnitt. Diese computergenerierten Designs minimieren algorithmisch die durchschnittliche Vorhersagevarianz über den gesamten Designraum und können Standard-Designs in ihrer Prädiktionsgüte oft übertreffen [**Goos.2011**, **Montgomery.2020**].

### 2.2.4 Strategische Vorgehensweisen

In der Praxis entsteht ein CCD häufig im Rahmen einer **sequenziellen Versuchsstrategie**: Zeigt das initiale lineare Modell Anpassungsmängel (**Lack-of-Fit**), wird der bestehende faktorielle Plan um die SPs augmentiert, um ein Modell zweiter Ord-

nung zu fitten [**Myers.2016**]. Modelle zweiter Ordnung sind insbesondere in der Lebensdauer- und Zuverlässigkeitstechnik vermehrt von Bedeutung, da sie die Existenz von lokalen Extrema (Minima oder Maxima) der Systemantwort im Versuchsraum detaillierter abbilden können [**Rigdon.2022**, **Dean.2017**]. Prinzipielle Vorgehensweisen, die ein erfolgreiches Umsetzen von DoE bzw. L-DoE begünstigen sollten, wie **Blockbildung** oder **Randomisierung** (vgl. [**Siebertz.2026**, **Kleppmann.2020**]), seien hier bereits vorausgesetzt. Abbildung 2.8 fasst eine derartige strategische Vorgehensweise zur Realisierung eines CCD zusammen, wie sie beispielsweise **Box.1951**, **Box.1988**, **Bisgaard.1992** vorschlagen.

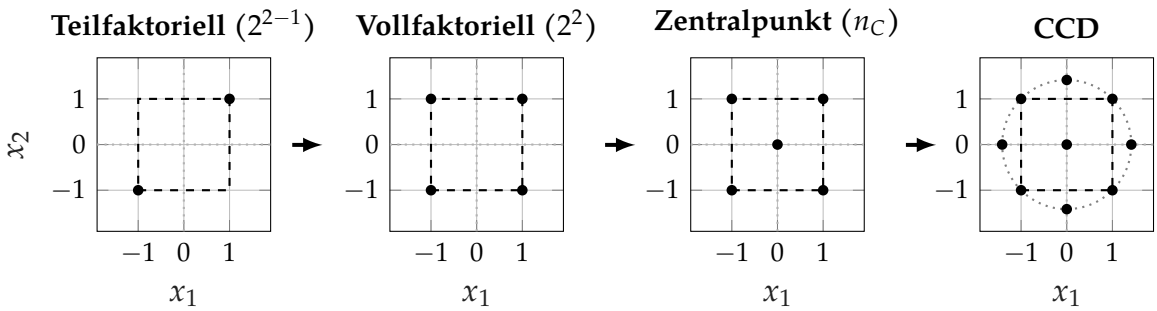


Abbildung 2.8: Strategischer Ansatz zu augmentierter Versuchsplanung für die Lebensdauererprobung nach [**Box.1988**, **Bisgaard.1992**]

Um effizient Versuchspunkte zu allokieren und für sequentiell fortlaufende Versuche weiterverwendet zu werden, wird in Abgleich mit Abbildung 2.2 zunächst ein **teil-faktorieller Versuchsplan** zur Identifikation signifikanter Faktoren durchgeführt. Anschließend wird der Plan zu einem **voll-faktoriellen Versuchsplan** erweitert, um alle Haupteffekte und Wechselwirkungen erster Ordnung zu schätzen. Daraufhin werden **ZPs** ergänzt, um das Vorhandensein von Krümmungen zu validieren. Abschließend werden bei Bedarf die **SPs** hinzugefügt, um ein vollständiges CCD zu realisieren. Insbesondere in der Lebensdauererprobung ist eine derartige schrittweise Vorgehensweise sinnvoll, um den Versuchsumfang zu minimieren und dennoch eine fundierte Modellierung der Systemantwort zu gewährleisten. Schließlich kann ein hierbei sequentiell ausgewertet und ausgewählt werden, inwiefern ein optimiertes Modell mit ausgewählten Termen gegenüber einem konventionellen Modell quadratischer Ordnung überlegen wäre, um die Modellantwort abzuschätzen, vgl. **Paschal.2024**. Gleichzeitig erlaubt diese Strategie eine flexible Anpassung an unerwartete Ergebnisse in den einzelnen Phasen der Untersuchung, während lokale

Optima von Zuverlässigkeiten im Sinne von DfR im Vorfeld ohnehin nicht bekannt sind. In Abhängigkeit der Anpassung zur Wahl eines geeigneten Modells, linear oder quadratisch, kann die Versuchsplanung so stets an die aktuellen Erkenntnisse angepasst werden. Dies folgt im Wesentlichen einer übergeordneten Logik der Modellkomplexität: Gemäß **Russell.2019** korrespondiert die minimale Anzahl notwendiger Versuchspunkte direkt mit der Anzahl der zu schätzenden Modellparameter $p$. Intuitiv erfordert bereits die Bestimmung der Parameter einer einfachen Geraden $(\beta_0, \beta_1)$ mindestens $N = 2$ unterschiedliche Stützstellen. Soll hingegen ein quadratischer Zusammenhang $(\beta_0, \beta_1, \beta_{11})$ abgebildet werden, sind zwingend mindestens drei Stützstellen erforderlich, um das Gleichungssystem zu lösen. Im Kontext optimaler Versuchspläne definiert nach **Pukelsheim.2006** der Maßerweiterungssatz von Carathéodory dabei eine theoretische Obergrenze für die notwendigen Stützstellen von $N = p(p+1)/2 + 1$, beziehungsweise $N = p(p+1)/2$, sofern das Interesse der Schätzung aller Elemente des Parametervektors $\boldsymbol{\beta}$ gilt [**Russell.2019**]. Es kann beispielsweise auf Basis der Ergebnisse des teil-faktoriellen Plans entschieden werden, ob eine Erweiterung zum voll-faktoriellen Plan überhaupt notwendig ist. Genauso kann die Anzahl der ZPs an die beobachtete Streuung der Lebensdauerdaten angepasst werden, um eine robuste Schätzung des Fehlers zu gewährleisten. Ist dann eine Extrapolation in Richtung a-priori unbekannter Beanspruchungsniveaus geplant, verfügt der CCD über die notwendigen Stützstellen, um eine adäquate Exploration des Versuchsraums zu ermöglichen. Zuletzt kann selbst bei Extrapolation über die Grenzen des Versuchsraums hinaus auf Basis der modellierten Krümmungen eine fundierte Abschätzung der Systemantwort erfolgen [**Myers.2016**, **Montgomery.2020**] und sogar mit Validierungsversuchen unter realen Einsatzbedingungen hinterlegt werden [**Dean.2017**]. So wird eine effiziente und zugleich robuste Lebensdauererprobung ermöglicht, die den Anforderungen der DfR gerecht wird und wirtschaftlich abbildbar bleibt [**RisbergEllekjr.1998**].

### 2.2.5 Bewertung und Optimierung von Versuchsplanung

Wird maximale Flexibilität jenseits starrer Standard-Designs wie dem voll-faktoriellen Setup oder dem CCD verlangt, können **optimale Versuchspläne** einen leistungsfähigen, *effizienten* Lösungsansatz für *multivariate* Versuchsplanung bieten [**Kleppmann.2016**, **Montgomery.2020**, **Myers.2016**]. Diese verfolgen das Ziel, die Versuchspunkte algo-

rithmisch so im Versuchsraum zu positionieren, dass spezifische Qualitätskriterien - allen voran die Verteilung der (um die Versuchsanzahl $N$ **skalierten**) **Prädiktionsvarianz**, engl. **Scaled Prediction Variance (SPV)**,

$$\nu(\mathbf{x}_0) = \frac{N\mathrm{Var}[\hat{y}(\mathbf{x}_0)]}{\sigma^2} = \mathbf{x}_0{}' \left(\frac{\mathbf{M}}{N}\right)^{-1} \mathbf{x}_0 = N\mathbf{x}_0{}'\mathbf{M}^{-1}\mathbf{x}_0 \tag{2.32}$$

optimiert werden [**Myers.2016**, **Montgomery.2020**]. Die Prädiktionsvarianz ist ein dimensionsloses Maß, das ausschließlich über die geometrische Anordnung der $N$ Versuchspunkte (der Matrix $\mathbf{X}$) in der **Informationsmatrix** (auch ***M*omentenmatrix**)

$$\mathbf{M} \overset{m=1}{=} \mathbf{X}'\mathbf{X} \tag{2.33}$$

definiert und damit positionsabhängig von einer Referenz $\mathbf{x}_0{}' = [1, x_{01}, \cdots, x_{0k}]$ im Parameterraum ist [**Myers.2016**]. Sie ist damit unabhängig von der tatsächlichen Streuung der Messdaten ($\sigma^2$). Weiter wird sie über die Anzahl der Versuchspunkte $N$ skaliert, um Vergleiche zwischen Versuchsplänen mit unterschiedlicher Stichprobengröße zu ermöglichen [**Goos.2011**, **Myers.2016**] - kann aber auch unskaliert betrachtet werden: als **Unscaled Prediction Variance (UPV)** $= \mathrm{Var}[\hat{y}(\mathbf{x}_0)]/\sigma^2 = \mathbf{x}_0{}'\mathbf{M}^{-1}\mathbf{x}_0$, vgl. **Montgomery.2020**, **Myers.2010**. Zusammen mit der Varianz des Versuchsfehlers $\sigma^2$ (vgl. Gleichung 2.36) erlaubt die Prädiktionsvarianz somit eine direkte Quantifizierung der **Unsicherheit in der Modellvorhersage** $\mathrm{Var}[\hat{y}(\mathbf{x}_0)]$ an einer beliebigen Stelle $\mathbf{x}_0$ im Versuchsraum. Um sie über verschiedene Stellen im Parameterraum zu bewerten, konnten allen voran **Zahran.2003**, **GiovannittiJensen.1989** mit dem **Variance Dispersion Graph (VDG)** oder **Fraction of Design Space (FDS)-Plot** Visualisierungsstrategien entwickeln und die Grundlage für weitreichende Designmodifikationen bilden [**Goldfarb.2004**, **Ardakani.2011**, **Borkowski.2022**, **Myers.1992**, **OzolGodfrey.2005**, **Schoonees.2016**]. Eine effiziente Versuchsplanung für multivariate Lebensdaueruntersuchungen muss sich neben pragmatischen Beweggründen maßgeblich an diesen Größen orientieren, weshalb im Folgenden eine Übersicht der gängigen Metriken und Qualitätsmerkmale gegeben wird.

### Orthogonalität, Ausgewogenheit und Multikollinearität

Der Einsatz optimaler Versuchspläne ist zunächst prädestiniert für Szenarien, in denen klassische Pläne an ihre Grenzen stoßen - sei es durch physikalische Randbedingungen welche bestimmte Faktorstufenkombinationen ausschließen, oder durch strikte Limitierungen der verfügbaren Versuchskapazität [**Goos.2011**, **Kleppmann.2020**]. Derart klassische Versuchspläne wie der voll-faktorielle Versuchsplan sind aufgrund ihrer Versuchspunktanordnung stets **orthogonal** [**Rigdon.2022**, **Montgomery.2020**]. Ein Versuchsplan wird als orthogonal bezeichnet, wenn keine Korrelation zwischen jeweils zwei Spalten der Versuchsplan-Matrix vorliegt - deren Skalarprodukte also jeweils null ergeben:

$$\langle x_i, x_j \rangle = 0 \quad \text{für alle } i \neq j. \tag{2.34}$$

Oder in anderen Worten: entspricht die Informationsmatrix $\mathbf{M}$ einer reinen Diagonalmatrix, ist der Versuchsplan orthogonal [**Montgomery.2021**, **Rigdon.2022**]. So können Effekte eindeutig identifiziert werden - die Vektoren der Faktorstufenkombinationen sind linear unabhängig und Effekte lassen sich unverzerrt schätzen. Dies stellt einen Versuchsplan also zunächst einmal qualitativ günstig dar.

Um den Grad der Abweichung von diesem Idealzustand - etwa bei asymmetrisch ausgedünnten Designs oder durch praxisbedingte Modifikationen der Versuchsraumgeometrie - quantitativ bewerten zu können, hat sich in der Literatur der $A_2$**-Indikator** als globales Maß für Nicht-Orthogonalität etabliert [**Box.2007**, **Ahn.2015**]. Er berechnet sich als Summe der quadrierten Elemente abseits der Hauptdiagonalen der normierten Informationsmatrix $\mathbf{M}$:

$$A_2 = \sum_{i=1}^{p} \sum_{\substack{j=1 \\ j \neq i}}^{p} r_{ij}^2 \quad \text{mit} \quad r_{ij} = \frac{\mathbf{M}_{ij}}{\sqrt{\mathbf{M}_{ii}\mathbf{M}_{jj}}}, \tag{2.35}$$

wobei $r_{ij}$ den paarweisen Korrelationskoeffizienten zwischen der $i$-ten und $j$-ten Spalte der Versuchsplan-Matrix repräsentiert. Folglich gilt für einen streng orthogonalen Plan $A_2 = 0$. Jeder Anstieg dieses Wertes signalisiert zunehmende Multikollinearität im Design, was das Risiko von Fehlschlüssen bei der Identifikation kausaler Haupteffekte und Interaktionen erhöht [**Wu.2021**].

Zudem liegt **Ausgewogenheit** vor, sofern für einen jeweiligen Faktor alle anderen Faktoreinstellungen gleichmäßig aufgeteilt sind [**Siebertz.2026**]. Damit wird

Varianzhomogenität und Gleichbehandlung der Faktoren gewährleistet, sodass die Schätzung der Effekte unverzerrt erfolgt.

Mathematisch fundiert die Bewertung der Schätzgenauigkeit auf der Inversen der Informationsmatrix, welche als **Varianz-Kovarianz-Matrix** (oder **Dispersionsmatrix**) $(\mathbf{X}'\mathbf{X})^{-1}$ der Regressionskoeffizienten definiert ist:

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}, \tag{2.36}$$

wobei wie gehabt $\sigma^2$ die Varianz des Versuchsfehlers darstellt.

Ein universelles Maß zur Beurteilung der Schätzgüte einzelner Parameter ist der **Mean Squared Error (MSE)**. Er vereint die Varianz des Schätzers und dessen systematische Verzerrung (**Bias**) in einer Metrik:

$$\mathrm{MSE}(\hat{\beta}_j) = E\left[(\hat{\beta}_j - \beta_j)^2\right] = \mathrm{Var}(\hat{\beta}_j) + \left(\mathrm{Bias}(\hat{\beta}_j)\right)^2. \tag{2.37}$$

Da klassische Schätzverfahren (wie OLS oder MLE) unter regulären Bedingungen erwartungstreu sind (Bias $= 0$), entspricht der MSE in diesen Fällen exakt der Schätzvarianz $\mathrm{Var}(\hat{\beta}_j)$ und skaliert folglich direkt mit den Diagonalelementen der inversen Informationsmatrix.

Während der $A_2$-Indikator die Gesamtmatrix bewertet, stehen genau diese Diagonalelemente in direktem Zusammenhang mit dem **Varianz-Inflations-Faktor (VIF)** für die Evaluation einzelner Modellterme [**Siebertz.2026**, **Kleppmann.2020**]. Der VIF dient als Maßzahl für Multikollinearität und quantifiziert den Faktor, um den sich die Varianz (und damit der MSE) eines geschätzten Koeffizienten im Vergleich zu einem vollständig orthogonalen Design aufgrund von Korrelationen zwischen den Faktoren erhöht (vergleiche auch **Konditionszahl**) [**Hedderich.2020**]. Während bei orthogonalen Plänen (Idealfall) ein VIF $= 1$ vorliegt, deuten hohe Werte (typischerweise $> 5$ oder $> 10$) auf eine instabile Modellschätzung hin [**Kleppmann.2020**, **Montgomery.2021**].

Ergänzend zur globalen Bewertung der Multikollinearität durch den VIF erlaubt die Betrachtung der sogenannten **Prädiktionsmatrix** (engl. auch **Hat-Matrix**)

$$\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \tag{2.38}$$

eine lokale Diagnose der Versuchspunkte. Die Diagonalelemente $h_{ii} \in \left[\frac{1}{n}, 1\right]$ dieser Projektionsmatrix, bezeichnet als **Hebelwerte** (engl. **Leverage**), quantifizieren den Einfluss eines einzelnen Versuchslaufs auf die Modellvorhersage. Punkte mit hohen Hebelwerten (typischerweise $h_{ii} > 2p/n$) befinden sich geometrisch weit vom Zentrum des Versuchsraums entfernt und dominieren die Regression, was den Plan anfällig für Ausreißer in diesen spezifischen Einstellungen macht [**Siebertz.2026**, **Montgomery.2021**].

Während Hebelwerte jedoch lediglich das *Potenzial* einer Beobachtung zur Modellbeeinflussung aufgrund ihrer geometrischen Exponiertheit indizieren, quantifizieren Einflussstatistiken die *tatsächliche* Auswirkung auf die Regressionsparameter und die Vorhersagegüte. Die Identifikation solcher Beobachtungen erfolgt methodisch durch den iterativen Ausschluss des $i$-ten Datensatzes (*Leave-One-Out*-Methodik) und den Vergleich der resultierenden Modellstatistiken mit dem ursprünglichen Modell basierend auf $n$ Beobachtungen [**Belsley.2004**, **Montgomery.2021**]. Als globales Maß für den Einfluss der $i$-ten Beobachtung auf den Vektor aller geschätzten Regressionskoeffizienten $\hat{\boldsymbol{\beta}}$ dient die **Cook-Distanz** ($D_i$). Sie verknüpft die Information des intern studentisierten Residuums $r_i$ mit dem Hebelwert $h_{ii}$:

$$D_i = \frac{r_i^2}{p} \cdot \frac{h_{ii}}{1 - h_{ii}}. \tag{2.39}$$

Ein hoher Wert (typischerweise $D_i > 1$ oder $D_i > 4/n$) signalisiert, dass das Entfernen der Beobachtung zu einer signifikanten Verschiebung der Modellparameter führen würde, da der Punkt sowohl weit vom Zentrum liegt als auch einen großen Fehler aufweist [**Fahrmeir.2009**, **Belsley.2004**].

Für eine differenzierte Analyse auf Ebene der einzelnen Modellterme wird die Metrik DFBETAS (Difference in Betas, Standardized) herangezogen. Sie misst die standardisierte Änderung eines spezifischen Regressionskoeffizienten $\beta_j$ bei Ausschluss der $i$-ten Beobachtung:

$$\text{DFBETAS}_{j,i} = \frac{\hat{\beta}_j - \hat{\beta}_{j(-i)}}{\sqrt{\hat{\sigma}^2_{(-i)} (\mathbf{X}'\mathbf{X})^{-1}_{jj}}}, \tag{2.40}$$

wobei $\hat{\beta}_{j(-i)}$ den Koeffizienten ohne die $i$-te Beobachtung und $\hat{\sigma}^2_{(-i)}$ die entsprechende Fehlerquadratschätzung darstellt. Hiermit lässt sich prüfen, ob einzelne Versuche die Schätzung eines Effekt-Terms verzerren (kritischer Schwellenwert oft $> 2/\sqrt{n}$) [**Belsley.2004**, **Montgomery.2021**].

Ergänzend beschreibt DFFITS (Difference in Fits) die Änderung des Vorhersagewertes an der Stelle $i$ selbst, normiert auf die Standardabweichung der Anpassung:

$$\text{DFFITS}_i = \frac{\hat{y}_i - \hat{y}_{i(-i)}}{\sqrt{\hat{\sigma}^2_{(-i)} h_{ii}}}. \tag{2.41}$$

Abschließend bewertet die COVRATIO den Einfluss auf die Präzision der Schätzung. Sie setzt die Determinante der Varianz-Kovarianz-Matrix ohne die $i$-te Beobachtung ins Verhältnis zur ursprünglichen Matrix:

$$\text{COVRATIO}_i = \frac{\det((\mathbf{X}'_{(-i)}\mathbf{X}_{(-i)})^{-1})}{\det((\mathbf{X}'\mathbf{X})^{-1})}. \tag{2.42}$$

Werte, die signifikant von 1 abweichen (Grenzen $1 \pm 3p/n$), zeigen an, dass die Beobachtung die Konfidenzbereiche der Koeffizienten unverhältnismäßig beeinflusst [**Belsley.2004**].

### Optimalitätskriterien

Da in restriktiven Versuchsräumen Orthogonalität oft nicht erreichbar ist, zielen optimale Versuchspläne darauf ab, durch Minimierung spezifischer Eigenschaften der Dispersionsmatrix $(\mathbf{X}'\mathbf{X})^{-1}$ den Informationsgehalt trotz Korrelationen zu maximieren. Die Generierung solcher maßgeschneiderten Pläne erfolgt algorithmisch unter Maximierung spezifischer statistischer Gütekriterien. Eine Übersicht der einschlägigen **Optimalitätskriterien** - oder einfach **Optimalitäten** - welche den quantitativen Vergleich zur Standard-Methodik ermöglichen, ist in Tabelle 2.4 zusammengefasst [**Goos.2011**, **Montgomery.2020**]. Sie bilden mitunter die Grundlage für diverse weitere Optimalitäten und hybride Ansätze und lassen sich prinzipiell in Modellierungskriterien (***A***-, ***D***- Optimalität) und Prädiktionskriterien (***G***-, ***I***-, ***U***-, ***V*- Optimalität**) unterteilen [**Myers.2016**, **Rigdon.2022**]. Während konventionelle Ansätze stets die Optimierung eines einzelnen Kriteriums anstreben, können in der Praxis

auch mehrere Kriterien gleichzeitig berücksichtigt werden, um eine ausgewogene Optimierung zu erreichen [**Goos.2011**, **Walsh.2024**].

Jenseits praktischer Kriterien sind hier der Vollständigkeit halber auch eine Teilmenge eher theoretischerer Optimalitäten zu nennen. Die ***E*-Optimalität**, führt zur Minimierung des maximalen Eigenwerts der Dispersionsmatrix, was eine Worst-Case-Absicherung zur Varianzschätzung begünstigt - vergleiche **Boyd.2004**, **Russell.2019**. Für explorative Zielsetzungen ohne starre Modellannahmen kann nach **Atkinson.1970** die ***S*-Optimalität** relevant sein, da hier durch die Maximierung der euklidischen Abstände benachbarter Punkte eine gleichmäßige Raumfüllung (*Space-Filling*) sichergestellt werden kann. So können für sich ändernde Modelle entlang einzelner Parameter wie beispielsweise $\hat{T} \in \hat{\theta}$ Sensitivatsanalysen effizient durchgeführt werden. Eine Verallgemeinerung der prädiktionsorientierten Kriterien stellt die ***Q*-Optimalität** dar, welche analog zur ***I***-Optimalität die integrierte Prädiktionsvarianz minimiert, jedoch mittels Gewichtsfunktionen eine differenzierte Priorisierung spezifischer Regionen im Versuchsraum erlaubt, vgl. **Goos.2011**. Liegt der Fokus hingegen isoliert auf einer Teilmenge der Modellparameter - etwa zur Trennung von Haupteffekten und Blockeffekten oder von Termen erster und zweiter Ordnung - ermöglicht die ***D*$_S$-Optimalität** als Derivat der ***D***-Optimalität eine gezielte Maximierung der Schätzgüte für genau dieses jeweilige *S*ubset der Parametergruppe - siehe auch Werke von **Goos.2011**, **Atkinson.2007**, **Myers.2016**.

Tabelle 2.4: Übersicht, Zielsetzung und mathematische Definition verschiedener Optimalitätskriterien für Versuchspläne

| **Kriterium** | **Zielgröße, Beschreibung und Definition** |
|---|---|
| ***A*-Optimalität** | Minimierung der Spur der inversen Informationsmatrix [**Kleppmann.2020**, **Montgomery.2020**, **Rigdon.2022**].<br>*Ziel: Maximale Präzision der einzelnen Parameter im Durchschnitt.*<br>$$A_{\text{opt}} = \min\left(\text{spur}\left(\mathbf{M}^{-1}\right)\right) = \min\left(\sum_{j=1}^{k} \text{Var}\left(\hat{\beta}_j\right)\right) \quad (2.43)$$ |

*Fortsetzung auf der nächsten Seite...*

Tabelle 2.4 (*Fortsetzung*): Übersicht der Optimalitätskriterien

| **Kriterium** | **Zielgröße, Beschreibung und Definition** |
|---|---|
| ***D*-Optimalität** | Maximierung der Determinante der Informationsmatrix $\mathbf{M}$. Da das Volumen des Vertrauensellipsoids der Koeffizientenschätzwerte umgekehrt proportional zur Quadratwurzel der Determinante ($\sqrt{\det(\mathbf{M})}$) ist, minimiert dieses Kriterium das Unsicherheitsvolumen im Parameterraum [**Montgomery.2020**, **Kleppmann.2020**, **Myers.2016**, **Atkinson.2007**]. *Ziel: Minimierung des Volumens des gemeinsamen Vertrauensbereichs aller Modellparameter.* $$D_{\text{opt}} = \max\left(\det(\mathbf{M})\right) = \min\left(\det\left(\mathbf{M}^{-1}\right)\right) \tag{2.44}$$ |
| ***G*-Optimalität** | Minimierung der maximalen skalierten Prädiktionsvarianz $\nu(\mathbf{x}_0)$ im relevanten Parameterraum [**Montgomery.2020**, **Myers.2016**, **Russell.2019**]. *Ziel: Qualität der Vorhersage an der ungünstigsten Stelle sichern.* $$G_{\text{opt}} = \min\left(\max_{\mathbf{x}_0 \in \mathbb{R}^k} \nu(\mathbf{x}_0)\right) \tag{2.45}$$ |

*Fortsetzung auf der nächsten Seite...*

Tabelle 2.4 (*Fortsetzung*): Übersicht der Optimalitätskriterien

| **Kriterium** | **Zielgröße, Beschreibung und Definition** |
|---|---|
| ***I*-Optimalität** | Minimierung der durchschnittlichen (*integrierten*) Prädiktionsvarianz über den Parameterraum - auch als ***U*-Optimalität** im ingenieurwissenschaftlich-statistischen Sinn bekannt: Optimierung bzgl. einer *uniformen* Prädiktionsvarianz [**Monroe.2011**, **Rigdon.2022**, **Atkinson.2007**]. *Ziel: Optimale Vorhersagegüte (SPV) im Mittel über den gesamten Raum - z.B. bei initialer Parametrisierung eines multivariaten Lebensdauermodells.* $$I_{\text{opt}} = \min\left(\frac{N}{\int_{\mathbb{R}^k} dx} \int_{\mathbb{R}^k} \nu(\mathbf{x}_0)\, dx\right) \tag{2.46}$$ |
| ***V*-Optimalität** | Minimierung der durchschnittlichen Prädiktionsvarianz über ein diskretes Set von $N$ Punkten [**Goos.2011**, **Montgomery.2020**, **Myers.2010**]. *Ziel: Optimale Vorhersagegüte (SPV) an spezifischen $i$ Stellen - z.B. bei L-DoE-Versuchspunkten oder spezifischen Nennlasten.* $$V_{\text{opt}} = \min\left(\frac{1}{N}\sum_{i=1}^{N} \nu(x_i)\right) \tag{2.47}$$ |

Zur vergleichbaren Bewertung unterschiedlicher Designs unabhängig von der Skalierung werden normierte **Effizienzen** herangezogen [**Montgomery.2020**]. Aus Tabelle 2.4 lassen sich die ***A*-Effizienz** $A_{\text{eff}}$, ***D*-Effizienz** $D_{\text{eff}}$, ***G*-Effizienz** $G_{\text{eff}}$, ***I*-Effizienz** $I_{\text{eff}}$ und ***V*-Effizienz** $V_{\text{eff}}$ ableiten, welche jeweils die Güte $[0, 1]$ eines Versuchsplans quantifizieren - vergleiche Tabelle 2.5.

Tabelle 2.5: Übersicht, Zielsetzung und mathematische Definition verschiedener Effizienzkriterien für Versuchspläne

| Kriterium | Zielgröße, Beschreibung und Definition |
|---|---|
| ***A*-Effizienz** | Maß für die durchschnittliche Präzision der Regressionskoeffizienten. [**Myers.2016**, **Goos.2011**]. $$A_{\text{eff}} = 100 \cdot \frac{p}{\text{spur}(N \cdot \mathbf{M}^{-1})} \quad (2.48)$$ |
| ***D*-Effizienz** | Maß für den Informationsgehalt der Informationsmatrix $\mathbf{M}$, definiert über die Determinante, umgekehrt proportional zum Volumen des Vertrauensellipsoids der Parameterschätzwerte und durch die Potenzierung mit $1/p$ pro Schätzparameter normiert. [**Myers.2016**, **Goos.2011**]. $$D_{\text{eff}} = 100 \cdot \frac{\det(\mathbf{M})^{1/p}}{N} \quad (2.49)$$ |
| ***G*-Effizienz** | Maß für die Vorhersagegüte im ungünstigsten Fall innerhalb des Versuchsraums. Da für die maximale SPV die theoretische Untergrenze $\nu(\mathbf{x}_0)_{\max} \geq p$ gilt, beschreibt dieses Kriterium das Verhältnis zwischen idealer und realisierter maximaler Varianz [**Myers.2016**]. $$G_{\text{eff}} = 100 \cdot \frac{p}{\nu(\mathbf{x}_0)_{\max}} \quad (2.50)$$ |
| ***I*-Effizienz** | Maß für die durchschnittliche Vorhersagegüte über den gesamten Versuchsraum [**Myers.2016**]. $$I_{\text{eff}} = 100 \cdot \frac{p}{\frac{1}{\int_R dx} \int_R \nu(\mathbf{x}_0)\, dx} \quad (2.51)$$ |

*Fortsetzung auf der nächsten Seite...*

Tabelle 2.5 (*Fortsetzung*): Übersicht der Effizienzkriterien

| Kriterium | Zielgröße, Beschreibung und Definition |
|---|---|
| ***V*-Effizienz** | Maß für die durchschnittliche Vorhersagegüte über ein diskretes Set von $N$ Punkten analog zu Gleichung 2.51 [**Myers.2016**]. $$V_{\text{eff}} = 100 \cdot \frac{1}{N} \sum_{i=1}^{N} \frac{p}{v(\mathbf{x}_0)(x_i)} \tag{2.52}$$ |

### Forschungsschwerpunkte in der RSM

Während die klassische sequentielle Strategie (Screening gefolgt von Augmentierung zum CCD oder Anpassung von Parameterräumen mit optimalen Versuchsplänen) die methodischen Risiken minimiert, erfordert sie oft einen hohen administrativen und zeitlichen Aufwand durch mehrere Versuchsphasen - insbesondere bei technischen Versuchsanlagen mit hohem Rüst-Aufwand. Als Antwort darauf entwickelten **Jones.2011** zunächst die Klasse der **Definitive Screening Designs (DSDs)**, um auch bei größeren Faktorenzahlen (typisch $k \geq 4$) Haupteffekte von nicht-linearen Effekten in einem Schritt zu trennen. Da DSDs jedoch eine starre Struktur aufweisen und oft nur eine geringe statistische Power zur Schätzung quadratischer Effekte bieten, etablierte sich in jüngster Forschung die umfassendere Klasse der **Orthogonal Minimally Aliased Response Surface (OMARS)-Designs** (*Orthogonal Minimally Aliased Response Surface Designs*), zu der **Goos.2025** zuletzt eine detaillierte Übersichtsarbeit vorlegten. **NunezAres.2020** erarbeiteten hierfür einen Katalog verschiedener OMARS-Designs, die im Gegensatz zu klassischen Plänen eine flexible Wahl der Versuchsanzahl $n$ ermöglichen. Diese Designs zielen spezifisch auf den fließenden Übergang von Screening zu RSD in einem einzigen experimentellen Schritt ab (*One-Step Approach*). Dazu basieren sie auf der Variation aller quantitativen Faktoren auf drei Stufen $(-1, 0, +1)$, um quadratische Zusammenhänge prinzipiell abzubilden. Die statistische Konstruktion garantiert dabei zwei fundamentale Orthogonalitätseigenschaften, die sie von klassischen Optimal-Designs abgrenzen: Erstens sind alle Haupteffekte orthogonal zueinander, was eine unabhängige Schätzung der linearen Einflüsse sichert. Zweitens sind die Haupteffekte vollständig unkorreliert

mit sämtlichen Effekten zweiter Ordnung (sowohl Zweifach-Wechselwirkungen als auch quadratische Terme). Das verbleibende Aliasing (Vermengung) beschränkt sich somit ausschließlich auf die Gruppe der Effekte zweiter Ordnung untereinander und wird algorithmisch minimiert (engl. *Minimally Aliased*). Dies erlaubt eine signifikante Flexibilisierung der Stichprobengröße im Vergleich zu starr definierten Plänen wie dem CCD, bei gleichzeitigem Erhalt der robusten Schätzbarkeit der primären Haupteffekte. Die Generierung eines solchen OMARS-DesignsST erfolgt dabei nicht über geometrische Konstruktionsvorschriften (wie beim CCD), sondern algorithmisch durch die Lösung eines ganzzahligen linearen Optimierungsproblems (engl. **Integer Linear Programming (ILP)**). Basierend auf der Kandidatenmenge $\Omega$ (üblicherweise entsprechend einem voll-faktoriellen $3^{k_f}$ Plan) wird ein Vektor binärer Entscheidungsvariablen $\gamma \in \{0,1\}^{|\Omega|}$ gesucht, der folgende mathematische Restriktionen simultan erfüllt:

- **Einhaltung des Stichprobenumfangs:** Die Summe der ausgewählten Versuchspunkte muss exakt der gewünschten Anzahl $n$ entsprechen:

$$\sum_{i=1}^{|\Omega|} \gamma_i = n. \tag{2.53}$$

- **Orthogonalität der Haupteffekte:** Jedes Paar von Haupteffekt-Spalten $j$ und $l$ muss unkorreliert sein. Für die kodierten Faktorstufen $x_{ij} \in \{-1, 0, +1\}$ des $i$-ten Kandidaten gilt:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot x_{il} = 0 \quad \forall\, 1 \leq j < l \leq k_f. \tag{2.54}$$

- **OMARS-Eigenschaft (Orthogonalität Haupteffekt zu Effekten zweiter Ordnung):** Dies ist das definierende Merkmal. Jeder Haupteffekt $j$ muss orthogonal zu jedem Effekt zweiter Ordnung (Interaktion $x_l x_k$ oder quadratischer Term $x_l^2$) sein:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot (x_{il} \cdot x_{ik}) = 0 \quad \forall\, j, l, k \in \{1, \ldots, k_f\}. \tag{2.55}$$

Unter Einhaltung dieser harten Nebenbedingungen wird anschließend jene Design-Variante ausgewählt, welche die Aliasing-Struktur der Effekte zweiter Ordnung untereinander minimiert (z. B. durch Maximierung von $D_{\text{opt}}$, vgl. Gleichung 2.44).

### Signifikanz und Trennschärfe

Zuletzt muss sichergestellt werden, dass der Versuchsplan über eine ausreichende **Trennschärfe** (engl. *power*) verfügt. Die Trennschärfe beschreibt als Metrik diejenige Wahrscheinlichkeit, mit der ein existierender Einfluss durch Faktoren vor dem Hintergrund des experimentellen Rauschens (vergleiche $t$**-Statistik**, **SNR**, **Signifikanztests** nach **Kleppmann.2020**, **Montgomery.2020**, **Goos.2011**) korrekt als **signifikanter** Effekt $E$ identifiziert wird [**Siebertz.2026**, **Kleppmann.2020**]. Insofern ist ein Effekt in praktischem Umfeld natürlich problemabhängig (Streuungscharakteristik der Lebensdauer, realisierbare Stichprobengröße, etc.) und meist von Bedeutung für $E \geq 2\sigma$, wobei Trennschärfewerte $\geq 80\,\%$ als befriedigend gelten [**Rigdon.2022**, **Montgomery.2020**]. Insbesondere bei reduzierten Versuchsplänen und unter dem Einfluss stochastischer Lebensdauerstreuung ist die Power-Analyse jedoch essenziell, um das Risiko von falsch-negativen Schlussfolgerungen zu minimieren. Letztendlich kann die Trennschärfe somit als Garantiemetrik verstanden werden, die sicherstellt, dass ein geplanter Versuchsaufbau in der Lage ist, Effekte von praktischer Relevanz zu detektieren [**Cohen.1988**, **Myers.2016**] - was vornehmlich in Bezug auf Lebensdauertests aufgrund genannter wirtschaftlicher Randbedingungen von hoher Bedeutung ist.

Formalisiert wird dies im Rahmen **statistischer Hypothesentests** [**Kleppmann.2020**, **Montgomery.2020**]. Die Zielsetzung besteht darin, den Nachweis zu erbringen, ob ein bestimmter Faktor $x_j$ einen signifikanten Einfluss auf die Systemantwort $y$ ausübt. Dazu werden zwei konkurrierende Hypothesen formuliert: Die **Nullhypothese** $H_0$ unterstellt, dass kein Zusammenhang besteht, der korrespondierende Regressionskoeffizient $\beta_j$ (vgl. Abschnitt 2.2.6) also den Wert Null annimmt:

$$H_0 : \beta_j = 0 \quad \text{gegen} \quad H_1 : \beta_j \neq 0. \tag{2.56}$$

Die **Alternativhypothese** $H_1$ postuliert hingegen einen signifikanten Effekt ($\beta_j \neq 0$). Die Entscheidung über die Annahme oder Ablehnung von $H_0$ basiert auf dem $p$-Wert. Dieser quantifiziert die Wahrscheinlichkeit, unter der Annahme der Gül-

tigkeit von $H_0$ die beobachteten Daten (oder extremere Ergebnisse) zu erhalten. Unterschreitet der $p$-Wert das a priori definierte **Signifikanzniveau** $\alpha$ (üblicherweise $\alpha = 0,05$), wird $H_0$ zugunsten der Alternativhypothese $H_1$ verworfen. Der Fehler, $H_0$ fälschlicherweise abzulehnen, obwohl kein Effekt vorliegt, wird als Fehler 1. Art bezeichnet; seine Wahrscheinlichkeit ist durch $\alpha$ begrenzt. Die **Trennschärfe** fokussiert hingegen auf den Fehler 2. Art (oft mit $\beta_{\text{error}}$ notiert), welcher das Risiko beschreibt, einen tatsächlich vorhandenen Effekt nicht zu erkennen (falsch-negative Entscheidung). Die Power folglich ist definiert als das Komplement dieses Fehlers ($1 - \beta_{\text{error}}$) und entspricht somit der Wahrscheinlichkeit, $H_0$ korrekterweise abzulehnen, wenn $H_1$ wahr ist:

$$power = \Pr(H_0 \text{ ablehnen} \mid H_1 \text{ ist wahr}) = 1 - \beta_{\text{error}}. \tag{2.57}$$

In idealisierten, orthogonalen Standard-Versuchsplänen unter der Annahme normalverteilter Residuen $\epsilon \sim \mathcal{N}(0, \sigma^2)$ lässt sich die Trennschärfe für klassische OLS-Regressionsmodelle exakt analytisch bestimmen. Die *power* für den Signifikanztest eines einzelnen Regressionskoeffizienten $\beta_j$ berechnet sich aus der Wahrscheinlichkeit, dass die Teststatistik den kritischen Wert der zentralen Prüfverteilung überschreitet. Unter der Gültigkeit der Alternativhypothese $H_1$ folgt die Teststatistik jedoch einer verschobenen, *nicht-zentralen* Verteilung (z.B. der nicht-zentralen $t$-Verteilung). Der Grad dieser Verschiebung wird durch den sogenannten **Nichtzentralitätsparameter** $\delta_{\text{nc}}$ quantifiziert [**Montgomery.2020**, **Kutner.2005**]. Für die Überprüfung eines individuellen Modellparameters ist dieser definiert als:

$$\delta_{\text{nc}} = \frac{|\beta_j|}{\sigma\sqrt{(\mathbf{X}'\mathbf{X})^{-1}_{jj}}} \tag{2.58}$$

wobei $|\beta_j|$ die zu detektierende wahre Effektstärke, $\sigma$ die Standardabweichung des experimentellen Rauschens und $(\mathbf{X}'\mathbf{X})^{-1}_{jj}$ das $j$-te Diagonalelement der inversen Informationsmatrix $\mathbf{M}^{-1}$ (vgl. Abschnitt 2.2.5) darstellt [**Cohen.1988**, **Myers.2016**]. Anhand von Gleichung 2.58 wird der mathematische Zusammenhang der Effektivität deutlich: Die Trennschärfe, welche monoton mit $\delta_{\text{nc}}$ wächst, steigt bei größeren Effekten und sinkt bei stärkerem Rauschen.

Die entscheidende Rolle des Versuchsplans manifestiert sich im Term $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$. In einem vollständig orthogonalen Versuchsplan ist die Informationsmatrix $\mathbf{M} = \mathbf{X}'\mathbf{X}$ eine reine Diagonalmatrix. Die Schätzer der Koeffizienten sind somit linear unabhängig und das Diagonalelement der Inversen minimiert sich. Sobald jedoch geometrische Verzerrungen auftreten und die Orthogonalität verloren geht, entstehen signifikante Kovarianzen (Werte abseits der Hauptdiagonalen in $\mathbf{M}$). Bei der Invertierung der Matrix führt dies zu einer Inflation der Varianzen, wodurch der Wert $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ anwächst. Dies vergrößert den Nenner in Gleichung 2.58, reduziert den Nichtzentralitätsparameter $\delta_{\text{nc}}$ und mindert somit unmittelbar die analytische Trennschärfe.

Solche analytischen Berechnungen, die auf der exakten Bestimmung von $\delta_{\text{nc}}$ beruhen, verkomplizieren sich erheblich, sobald asymmetrische Design-Modifikationen und Mehrfach-Korrelationen greifen. Im Kontext der Lebensdauerdatenanalyse, bei der zudem nicht-normalverteilte und zensierte Daten vorliegen, lassen sich diese Wahrscheinlichkeiten folglich ohnehin nicht mehr über klassische $t$**-Tests** ableiten. Aus der Arbeit von **Nelder.1972** kommen hier **Verallgemeinerte Lineare Modelle**, engl. **Generalized Linear Models (GLMs)** zum Einsatz, bei denen die Signifikanz der Koeffizienten $\beta_j$ vorzugsweise über den **Likelihood-Ratio Test (LR-Test)** (oder approximativ über **Wald-Tests** - vergleiche hierzu Arbeiten von **Rigdon.2022**, **Meeker.2022**, **Montgomery.2020**, **McCulloch.2001**) ermittelt wird. Da für diese komplexen Verteilungsmodelle - insbesondere unter dem Einfluss von Orthogonalitätsabweichungen und bei kleinen Stichprobenumfängen $n$ - keine geschlossenen analytischen Lösungen zur Berechnung der Trennschärfe existieren, erfolgt die Untersuchung in der modernen Praxis numerisch mittels **Monte-Carlo-Simulation (MCS)** [**Kremer.2021**, **Arndt.2022**, **Khuri.2006**]. Hierbei wird der geplante Versuchsplan virtuell vielfach durchlaufen (z.B. $n_{\text{MC}} = 10^4$ Simulationsläufe). Für jeden Lauf werden basierend auf einem angenommenen Modell Ausfallzeiten generiert, verrauscht bzw. mit Streuung überlagert und/oder zensiert. Anschließend erfolgt die Modellbildung und Hypothesenprüfung. Der Anteil der Simulationsläufe, in denen der definierte Effekt korrekt als signifikant ($p$-Wert $< \alpha$) erkannt wird, entspricht der geschätzten *power* des Designs.

### 2.2.6 Statistische Modellbildung

Die statistische Modellbildung transformiert die durch den Versuchsplan generierte Datenbasis in einen funktionalen, empirisch basierten Zusammenhang zwischen den Einflussfaktoren $x_i$ und der Lebensdauerantwort. Aufgrund der in Abschnitt 2.1 dargelegten Eigenschaften von Lebensdauerdaten (Nicht-Normalverteilung, Zensierung) sind klassische Regressionsverfahren (OLS) hier nicht zulässig. Stattdessen kommt i.d.R. das Framework der GLM zur Anwendung, welches die lineare Prädiktion mit der zugrundeliegenden Verteilung verknüpft [**Yang.2007**, **Meeker.2022**, **Rigdon.2022**]. Hinsichtlich der Modellauswahl können in klassischen Ansätzen der Versuchsplanung dabei oft auf Potenztransformationen der Antwortvariablen in Form $y^{(\lambda_{\mathrm{BC}})}$ oder $\ln(y)$ (für $\lambda_{\mathrm{BC}} = 0$ mit geometrischem Mittelwert der Beobachtung $\dot{y} = \exp\left[\frac{1}{n}\sum_{i=1}^{n}\ln(y_i)\right]$) zurückgegriffen werden - wie die **Box-Cox-Transformation** nach **Box.1964**, **Montgomery.2021**. So wird Varianzhomogenität und Normalverteilung approximiert zu:

$$y_i^{(\lambda_{\mathrm{BC}})} = \begin{cases} \frac{y_i^{\lambda_{\mathrm{BC}}}-1}{\lambda_{\mathrm{BC}}\dot{y}^{\lambda_{\mathrm{BC}}-1}}, & \text{für } \lambda_{\mathrm{BC}} \neq 0, \\ \dot{y}\ln(y_i), & \text{für } \lambda_{\mathrm{BC}} = 0. \end{cases} \tag{2.59}$$

Im Kontext der expliziten Lebensdaueranalyse ist dieser generische Ansatz jedoch weniger gebräuchlich, da die physikalisch motivierte Verteilungsannahme (z.B. Weibull) bereits eine inhärente Transformation der Lebensdauerzeit impliziert - vgl. Abschnitt 2.1.3, Gleichung 2.8 sowie **Wu.2021**, **Yang.2007**. Wird also für die Lebensdauerverteilung die Weibull-Verteilung (Abschnitt 2.1.3) angenommen, so ergibt sich für $j = 0, ..., k$ betrachtete Parameter aus beispielsweise Gleichung 2.27 und $n$ Beobachtungen analog zu Gleichung 2.8 der Erwartungswert der charakteristischen Lebensdauer als **Link-Funktion** der Einflussfaktoren $x_i$ und des unbekannten Koeffizientenvektors $\hat{\boldsymbol{\beta}}$ [**Wu.2021**, **Yang.2007**, **Wuthrich.2023**]:

$$E_{\theta_x}(\ln(T)) = y = \beta_0 + \sum_{j=1}^{k}\beta_j x_j + \cdots + \epsilon. \tag{2.60}$$

In der Lebensdauer-Datenanalyse werden insbesondere zwei weitere Modellierungsansätze verwendet: neben den GLM-Ansätzen insbesondere der **Proportional Hazard (PH)-Modell**-Ansatz. Jedoch werden PH-Modelle vornehmlich in der Bio-

statistik verwendet und spielen hier ihre Stärke bei der Abbildung zeitabhängiger Kovariate aus [**Modarres.2017**, **Kremer.2020**]:

$$f(t,\mathbf{X}) = \lambda(t)(t,\mathbf{X}) \cdot R(t,\mathbf{X}) = b \cdot t^{b-1} \cdot e^{\left[y - t^b e^y\right]}. \tag{2.61}$$

### Weibull-GLM

Im ingenieurwissenschaftlichen Kontext - maßgeblich gestützt durch Ausführungen in **Meeker.2022**, **Wu.2021**, **Yang.2007**, **Dobson.2018**, **Kremer.2020**, **Stufken.2012**, **Myers.2010** - finden hingegen **Log-Location-Scale-Modelle**, also GLMs, überwiegend Anwendung. Obwohl für die Weibull-Verteilung eine mathematische Äquivalenz zwischen beiden Ansätzen besteht, sprechen drei fundamentale Gründe für deren Verwendung. **Physikalischer Bezug:** Gängige physikalische Beschleunigungsmodelle (Arrhenius, Inverses Potenzgesetz) beschreiben die Änderung der *Zeit* bis zum Ausfall ($\ln(\hat{T})$) und nicht der Ausfallrate. Die Log-Linearisierung dieser Gesetze führt direkt auf die Regressionsgleichung der Location-Scale-Modelle. **Universalität der Auswertung:** Das Modell bietet einen einheitlichen mathematischen Rahmen, der nicht nur für die Weibull-Verteilung, sondern identisch auch für die Lognormal-Verteilung und Normalverteilung gültig ist. Das PH-Modell hingegen ist für Lognormal-Verteilungen mathematisch nicht geschlossen anwendbar. **Fokus auf Lebensdauer-Quantile:** Im Engineering und DfR liegt das Interesse primär auf der Prädiktion von Ausfallzeiten für geringe Ausfallanteile (z.,B. $t_{10}$). Diese Größen sind direkte Ergebnisse der Location-Scale-Gleichung, während sie im PH-Modell nur indirekt über die Invertierung der Hazard-Funktion zugänglich sind. Folglich wird eine zufallsverteilte Lebensdauer $\tau$ für ein Weibull-GLM mit der Dichtefunktion

$$f(t,\mathbf{X}) = b \cdot t^{b-1} e^{-b\left(\beta_0 + \sum_{j=1}^{k} \beta_j x_j\right)} \cdot e^{-t^b e^{-b\left(\beta_0 + \sum_{j=1}^{k} \beta_j x_j\right)}}, \quad t > 0. \tag{2.62}$$

beschrieben und analog zu Gleichungen 2.14–2.17 in die **Generalized Log-Linear (GLL)-Funktion** überführt [**Russell.2019**, **Yang.2007**, **Aitkin.1980**]:

$$\begin{aligned} \Lambda &= \ln\left(\mathcal{L}(t_i; b, \beta_0, \ldots, \beta_k)\right) \\ &\propto \sum_{i=1}^{n} \left[ \ln(b) - b\left(\beta_0 + \sum_{j=1}^{k} \beta_j x_{ij}\right) + (b-1)\ln(t_i) - {t_i}^b e^{-b\left(\beta_0 + \sum_{j=1}^{k} \beta_j x_{ij}\right)} \right]. \end{aligned} \tag{2.63}$$

Werden außerdem (rechts-) zensierte Daten berücksichtigt, so ergibt sich analog zu Gleichung 2.17 über Gleichung 2.63 die erweiterte GLL-Funktion [**Yang.2007**, **Meeker.2022**]:

$$\Lambda_z \propto \Lambda - (1 - \delta_i) \cdot {t_i}^b e^{-b\left(\beta_0 + \sum_{j=1}^{k} \beta_j x_{ij}\right)}. \tag{2.64}$$

Sollen über die rein empirische Datenauswertung hinaus bekannte physikalische Gesetzmäßigkeiten im Modell berücksichtigt werden, ist die lineare Struktur des Prädiktors entsprechend anzupassen. Dies erfolgt durch eine Transformation der physikalischen Beanspruchungsgrößen $x$ in den Modellraum. Anstelle der direkten Verwendung des Einflussfaktors in der GLL-Beziehung (Gleichung 2.62) wird eine transformierte Größe $x_\mathrm{V}$ eingesetzt, welche die physikalische Natur des Schädigungsmechanismus abbildet. Gängige Transformationen umfassen hierbei die reziproke Anpassung für thermische Lasten oder logarithmische Ansätze für elektrische Potenzmodelle, vgl. Tabelle 2.6. Eine Übersicht verschiedener Modellierungs-

Tabelle 2.6: Übersicht gängiger Transformationen der Belastungsgrößen zur Abbildung physikalischer Lebensdauermodelle

| **Art** | **Transformation** | **Lebensdauermodell** | **Anwendungsfall** |
|---|---|---|---|
| Keine | $x_\mathrm{V} = x$ | Exponential / Wöhler | mechanisch |
| Reziprok | $x_\mathrm{V} = 1/x$ | Arrhenius | thermisch |
| Logarithmisch | $x_\mathrm{V} = e^x$ | Potenzmodell | elektrisch |

ansätze (z.B. **Arrhenius-Modell**, **Inverses Potenzgesetz**, **Eyring**, **Coffin-Manson-Modell**, etc.) und deren Einbindung in die GLM-Struktur findet sich in den Arbeiten von **Meeker.2022**, **Rigdon.2022**, **Modarres.2017**. Die Schätzung der unbekannten Parameter $\hat{\boldsymbol{\beta}}$ und $\hat{b}$ erfolgt anschließend mittels MLE durch Maximierung der Log-Likelihood-Funktion (Gleichung 2.64) mittels beispielsweise **Newton-Raphson-Verfahren** bzw. **Pattern-Search-Algorithmen** oder **Gradientenverfahren**, [**Yang.2007**, **Qiao.1994**]. Geeignete numerische Optimierungsverfahren wurden in Abschnitt 2.1.4 erwähnt und unter anderem durch Vorarbeiten von **Kremer.2019b** evaluiert.

### Signifikanzanalyse

Liegen die Parameterschätzungen $\hat{\theta}_i$ vor, erfolgt die Bewertung ihrer statistischen Relevanz mittels LR-Test. Dieses Verfahren stellt das methodische Äquivalent zur ANOVA bei normalverteilten Daten dar und prüft, ob die Aufnahme eines Parameters die Modellanpassung signifikant verbessert. Der Test basiert auf dem Vergleich der maximalen Likelihoods des vollständigen Modells $\mathcal{L}(\hat{\theta}_i)$ gegenüber einem reduzierten Modell $\mathcal{L}(\hat{\theta}_{-i})$, aus dem der zu untersuchende Parameter eliminiert wurde [**Kremer.2021**, **Kremer.2019c**]. Die Teststatistik $LR$ quantifiziert den Informationsverlust durch die Modellreduktion und ist definiert als **Devianz**-Funktion [**Meeker.2022**, **Rencher.2008**]:

$$LR = -2\ln\left(\frac{\mathcal{L}\left(\hat{\theta}_{-i}\right)}{\mathcal{L}\left(\hat{\theta}_i\right)}\right) = 2\cdot\left[\ln\left(\mathcal{L}(\hat{\theta}_i)\right) - \ln\left(\mathcal{L}(\hat{\theta}_{-i})\right)\right]. \tag{2.65}$$

Unter der Nullhypothese $H_0$, dass der ausgeschlossene Parameter keinen Einfluss hat, folgt $LR$ asymptotisch einer $\chi^2$-Verteilung mit $d_\mathrm{f}$ Freiheitsgraden (Anzahl der ausgeschlossenen Parameter, hier meist $d_\mathrm{f} = 1$). Die Signifikanzentscheidung erfolgt über den $p$-Wert, der die Wahrscheinlichkeit angibt, einen Testwert $\geq LR$ zu beobachten:

$$p\text{-Wert} = \Pr\left(\chi^2\left(d_\mathrm{f}\right) \geq LR\right). \tag{2.66}$$

Ist dieser $p$-Wert kleiner als das definierte Signifikanzniveau $p\text{-Wert} < \alpha$, wird der Parameter als signifikant in das Modell aufgenommen.

### Erwartungswerte und Konfidenzintervalle

Nach der Ermittlung der optimalen Modellparameter $\hat{\boldsymbol{\theta}}$ ist die Quantifizierung der mit diesen Schätzungen verbundenen Unsicherheit essenziell. Analytisch erfolgt dies über die Betrachtung der Krümmung der Log-Likelihood-Funktion $\Lambda$ im Maximum. Je stärker die Krümmung, desto präziser ist die Schätzung (geringere Varianz). Mathematisch erfolgt dies durch die drei Schritte: Wahl der statistischen Zielgröße ($R$,$F$), Berechnung des Standard-Fehlers (via $\mathbf{F}$ analog zu Gleichung 2.18) und Vertrauensbereich-Schätzung / Wald-Statistik (Gleichung 2.20 bzw. 2.21). So wird dies analog zu Gleichungen 2.18-2.19 durch die Hesse-Matrix $\mathbf{H_f}$ beschrieben, welche die zweiten partiellen Ableitungen der Log-Likelihood-Funktion nach den Para-

metern $\theta_i$ (also $\beta_j$ und $b$) enthält. Der negative Erwartungswert dieser Matrix führt damit zur Erwartung der Fisher-Informationsmatrix $\mathbf{F}$ [**Fisher.1935**, **Rasch.2018**]:

$$\mathbf{F}_{\mathrm{O}} := -\mathbf{H}_{\mathbf{f}}(\hat{\boldsymbol{\theta}}) = \begin{bmatrix} -\frac{\partial^2 \mathcal{L}}{\partial \theta_1^2} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_k} \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2^2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_k} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k^2} \end{bmatrix}. \tag{2.67}$$

Die asymptotische Varianz-Kovarianz-Matrix $\hat{\mathbf{V}}$ der Parameterschätzer wird anschließend durch die Inversion der Fisher-Informationsmatrix für $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}$ approximiert [**Yang.2007**, **Rasch.2018**]:

$$\hat{\mathbf{V}} \approx \mathbf{F}_{\mathrm{O}}{}^{-1} = \begin{bmatrix} \hat{\mathrm{Var}}(\hat{\theta}_1) & \hat{\mathrm{Cov}}(\hat{\theta}_1, \hat{\theta}_2) & \cdots & \hat{\mathrm{Cov}}(\hat{\theta}_1, \hat{\theta}_k) \\ \hat{\mathrm{Cov}}(\hat{\theta}_2, \hat{\theta}_1) & \hat{\mathrm{Var}}(\hat{\theta}_2) & \cdots & \hat{\mathrm{Cov}}(\hat{\theta}_2, \hat{\theta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\mathrm{Cov}}(\hat{\theta}_k, \hat{\theta}_1) & \hat{\mathrm{Cov}}(\hat{\theta}_k, \hat{\theta}_2) & \cdots & \hat{\mathrm{Var}}(\hat{\theta}_k) \end{bmatrix}. \tag{2.68}$$

Die Hauptdiagonalelemente dieser Matrix liefern die geschätzten Varianzen $\hat{\mathrm{Var}}(\hat{\theta}_j)$ der einzelnen Modellparameter. Unter der Annahme der asymptotischen Normalverteilung der MLE beschreibt **Yang.2007** neben weiteren Alternativen aus **Meeker.2022**, **Kremer.2019c** die symmetrischen $(1-\alpha)$-Konfidenzintervalle (Wald-Intervalle) wie nachfolgend - vgl. Gleichung 2.21:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\mathrm{Var}}(\hat{\theta}_j)} \quad \text{bzw.} \cdots = \hat{\theta}_j \exp\left(\pm z_{1-\alpha/2} \cdot \frac{\sqrt{\hat{\mathbf{V}}_{jj}}}{\hat{\theta}_j}\right). \tag{2.69}$$

### Vertrauensbereiche für Funktionswerte und Weibull-GLM

Oft ist nicht nur die Unsicherheit der Modellparameter selbst, sondern die der daraus abgeleiteten Funktionen - wie der Zuverlässigkeit $R(t)$ oder der Ausfallwahrscheinlichkeit $F(t)$ - von Interesse. Zur analytischen Ermittlung dieser sogenannten Fisher-Vertrauensbereiche führt **Yang.2007** zunächst eine Hilfsgröße $w$ ein - vergleiche auch $z_{\mathrm{e}}$ nach **Meeker.2022**. Diese normiert die logarithmische Abweichung der

betrachteten Zeit $t$ von der geschätzten charakteristischen Lebensdauer $\hat{T}$ mit dem Formparameter $\hat{b}$ (vergleiche auch **Bain.2017b** für weitere Abschätzungen):

$$\hat{w} = \hat{b} \cdot \ln\left(\frac{t}{\hat{T}}\right). \tag{2.70}$$

Die Varianz dieser Größe lässt sich mittels Taylor-Reihenentwicklung (Delta-Methode, vgl. Abschnitt 2.1.4) approximativ aus den Varianzen und Kovarianzen der Parameterschätzer und analog zu Gleichungen 2.22 und 2.23 bestimmen:

$$\hat{\mathrm{Var}}(\hat{w}) = \left(\frac{\hat{b}}{\hat{T}}\right)^2 \hat{\mathrm{Var}}(\hat{T}) + \left(\frac{\hat{w}}{\hat{b}}\right)^2 \hat{\mathrm{Var}}(\hat{b}) - \frac{2\hat{w}}{\hat{T}} \hat{\mathrm{Cov}}(\hat{T}, \hat{b}). \tag{2.71}$$

Basierend auf der asymptotischen Normalverteilung ergeben sich die Vertrauensgrenzen $[\hat{w}_u, \hat{w}_o]$ gemäß:

$$[\hat{w}_u, \hat{w}_o] = \hat{w} \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\mathrm{Var}}(\hat{w})}. \tag{2.72}$$

Die Rücktransformation dieser Grenzen in den Wertebereich der Ausfallwahrscheinlichkeit erfolgt anschließend über die Verteilungsfunktion der kleinsten Extremwerte $G = 1 - \exp[-\exp(\hat{w})]$, woraus sich direkt die Konfidenzintervalle der Zuverlässigkeit ableiten lassen. Im Fall von GLM ist zu berücksichtigen, dass die geschätzte charakteristische Lebensdauer $\hat{T}$ keine unabhängige Konstante ist, sondern funktional entsprechend Gleichung 2.60 von den Kovariaten $x$ und dem Parametervektor $\hat{\boldsymbol{\beta}}$ abhängt. Die für Gleichung 2.71 benötigte Varianz $\hat{\mathrm{Var}}(\hat{T})$ muss folglich unter Berücksichtigung der gesamten Kovarianzmatrix der Regressionskoeffizienten aus Gleichung 2.68 berechnet werden. Dies erfolgt durch die allgemeine Fehlerfortpflanzung nach Gauß:

$$\hat{\mathrm{Var}}(\hat{T}) \approx \sum_{i=1}^{k} \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i}\right)^2 \hat{\mathrm{Var}}(\hat{\beta}_i) + \sum_{i=1}^{k} \sum_{\substack{j=1 \\ j \neq i}}^{k} \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i}\right) \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_j}\right) \hat{\mathrm{Cov}}(\hat{\beta}_i, \hat{\beta}_j). \tag{2.73}$$

### Modellgüte und Residuenanalyse

Die Validität eines parametrischen Lebensdauermodells (hier Weibull-GLM) beruht auf drei fundamentalen Annahmen, die es nach der Parameterschätzung zu verifizieren gilt: Erstens folgen die Lebensdauern der angenommenen Verteilung. Zweitens sind die Lebensdauern statistisch unabhängig. Drittens besteht ein loglinearer Zusammenhang zwischen dem Skalenparameter und den Einflussgrößen, wobei der Formparameter in einfachen Modellen als konstant über den gesamten Versuchsraum angenommen wird. Die Beurteilung dieser Modellgüte erfordert bei Lebensdauerdaten, bedingt durch Nicht-Normalverteilung und Zensierung, eine Anpassung klassischer Konzepte zur Residuenanalyse $(y - \hat{y})$ [**Kleppmann.2020**, **Siebertz.2026**]. Stattdessen werden transformierte Residuen betrachtet, die den Bezug zur Verteilung der kleinsten Extremwerte $SEV$ herstellen, welcher der logarithmierten Weibull-Verteilung zugrunde liegt. Analog zur $z$-Transformation bei der Normalverteilung lassen sich für jede Beobachtung $t_i$ standardisierte Residuen $r_i$ berechnen. Dabei ersetzt der logarithmierte Schätzwert der charakteristischen Lebensdauer $\ln(\hat{T}_i)$ (vgl. Gleichung 2.60) den Lageparameter $\mu$ und der Kehrwert des Formparameters $1/\hat{b}$ die Skalierung $\sigma$. Dies entspricht exakt der in diesem Abschnitt eingeführten Hilfsgröße $w$:

$$r_i = \frac{\ln(t_i) - \ln(\hat{T}_i)}{1/\hat{b}} = \hat{b} \cdot \ln\left(\frac{t_i}{\hat{T}_i}\right). \tag{2.74}$$

Ist das Modell korrekt spezifiziert, müssen diese Residuen (unter Berücksichtigung der Zensierung) einer Verteilung der kleinsten Extremwerte $SEV(\mu = 0, \sigma = 1)$ folgen. Eine allgemeinere Form der Validierung bieten die **Cox-Snell-Residuen** $r_{\mathrm{CS}}$ [**Rigdon.2022**, **Meeker.2022**]. Sie stellen eine Transformation der standardisierten Residuen dar und entsprechen dem Wert der kumulativen Hazard-Funktion an der Stelle der Beobachtung. Für das Weibull-Modell gilt der Zusammenhang:

$$r_{\mathrm{CS}i} = -\ln\left(\hat{R}(t_i)\right) = \exp(r_i) = \left(\frac{t_i}{\hat{T}_i}\right)^{\hat{b}}. \tag{2.75}$$

Folgt das angepasste Modell den Daten, so verhalten sich die Residuen $r_{\mathrm{CS}}$ wie eine Stichprobe aus einer Standard-Exponentialverteilung mit Mittelwert 1. Diese Eigenschaft erlaubt eine grafische Validierung mittels Probability-Plots: Liegen die geplot-

teten Residuen auf einer Geraden im Exponential-Wahrscheinlichkeitsnetz, kann von einer adäquaten Modellpassung ausgegangen werden. Zur Identifikation von Ausreißern oder einflussreichen Beobachtungen eignen sich hingegen standardisierte Devianz-Residuen $r_{\mathrm{Dev}}$. Im Gegensatz zu den stets positiven Cox-Snell-Residuen sind diese symmetrischer um Null verteilt und folgen asymptotisch einer Standardnormalverteilung:

$$r_{\mathrm{Dev}\,i} = \mathrm{sgn}(r_{\mathrm{CS}i} - 1) \cdot \sqrt{2\left[r_{\mathrm{CS}i} - \delta_i - \delta_i \ln(r_{\mathrm{CS}i})\right]}. \tag{2.76}$$

Neben der Verteilungsprüfung dienen Streudiagramme dieser Residuen zur Aufdeckung struktureller Modelldefizite. Dabei werden $r_{\mathrm{CS}}$ oder $r_{\mathrm{Dev}}$ gegen die prädizierten Werte oder gegen einzelne Einflussfaktoren aufgetragen und gegenüber Trendfreiheit und Varianzhomogenität bewertet. Besteht initiale Unsicherheit über die zugrundeliegende Physik, ermöglicht zudem der Vergleich den Wahrscheinlichkeitsnetzen der Residuen eine empirische Selektion: Dasjenige Modell, dessen Punktegraphen eine geringere Krümmung aufweisen und besser der theoretischen Geraden folgen, ist statistisch zu bevorzugen.

# 3 Effiziente Testplanung für die multivariate Lebensdauererprobung

## 3.1 Bewertung des Standes der Forschung und Technik

Der in Kapitel 2 dargelegte Stand der Forschung und Technik zur Versuchsplanungsmethodik verdeutlicht, dass sowohl die Zuverlässigkeitstechnik als auch DoE für sich genommen etablierte Disziplinen mit jeweils umfangreichen Methodenrepertoire darstellen. Die Schnittmenge beider Felder, die effiziente Planung multivariater Lebensdauerversuche unter Berücksichtigung nicht-normalverteilter Daten und Zensierung (Weibull-GLM), weist jedoch spezifische Lücken auf, die den Bedarf an weiterführender Forschung begründen.

### 3.1.1 Eignung klassischer Response Surface Designs

Klassische Versuchspläne der RSM, insbesondere das CCD, haben sich als robuster Standard für die Modellierung nicht-linearer Zusammenhänge bewährt [**Kleppmann.2020**, **Rigdon.2022**]. Ihre Stärken liegen in der sequenziellen *Augmentierbarkeit*, der *Rotierbarkeit* und der Fähigkeit zur unabhängigen Schätzung des reinen Fehlers (vgl. Abschnitt 2.2.3). Zudem lässt sich aus dem am IMA bislang generierten Wissensstand nach **Kremer.2021** ableiten, welche methodischen Vorgehen im Rahmen des L-DoE sich bestenfalls dazu eigenen, adäquate Schätzungen für Modellparameter [**Kremer.2019b**] und Vertrauensbereiche [**Kremer.2019c**] zu erhalten. Für die spezifischen Anforderungen der Lebensdauererprobung, die häufig eine Extrapolation der Ergebnisse aus einem hochbelasteten ALT-Testraum in einen niedriger belasteten Anwendungsraum erfordert, ist die starre Symmetrie des klassischen CCD jedoch nicht zwangsläufig optimal. Ein geeigneter, *effizienter* Umgang mit dieser Herausfor-

derung ist bislang nicht etabliert. Es existieren zwar bereits vereinzelte Ansätze zur Modifikation von CCDs, wie die Arbeiten von **Ahn.2015**, **Donev.2004**, **Box.1951** und **Ardakani.2011** zeigen. Diese fokussieren sich jedoch zumeist auf generische Optimalitätskriterien oder spezifische geometrische Restriktionen und adressieren nicht explizit die Herausforderungen der probabilistischen Lebensdauerprognose unter Extrapolation im Kontext der statistischen **Trennschärfe** (*power*). Obgleich für die Anwendung im Maschinen- und Fahrzeugbau von entscheidender Bedeutung, existiert bislang kein etabliertes Vorgehen, um die Versuchspunkt-Konstellation gezielt in Prognoserichtung zu optimieren und so die Extrapolationsfähigkeit zu maximieren, ohne die Balance zwischen Modellgüte und Versuchsaufwand zu gefährden.

### 3.1.2 Limitierungen und Effizienzbegriffe moderner Versuchsplanung

Der Einsatz computergenerierter optimaler Versuchspläne erscheint zunächst als logischer Schritt, um maßgeschneiderte Designs für Lebensdauererprobungen zu entwerfen. Im Kontext multivariater Lebensdauertests (ALT) erfährt der Begriff der **Effizienz** jedoch eine signifikante Komplexitätssteigerung gegenüber der klassischen linearen Versuchsplanung, die sich in den drei Dimensionen *Modellabhängigkeit*, *zeitliche Dynamik* und *strukturelle Flexibilität* aufgliedert. Formal definiert sich die Effizienz eines Versuchsplans einerseits analytisch über die Informationsmatrix $\mathbf{M}(\mathbf{X}, \theta)$ [**Khuri.2006**, **Stufken.2012**], andererseits generisch über das Verhältnis von Leistungsfähigkeit zur Informationsbeschaffung - ein Anspruch, der nach **Thommen.2022** in einem fundamentalen Spannungsfeld zum Grundsatz der Vollständigkeit steht. Damit determiniert die Effizienz maßgeblich die **Effektivität** und Wirtschaftlichkeit der Lebensdauererprobung und in letzter Instanz die Verlässlichkeit der Modellierung (vgl. Abschnitt 2.2.5: *power*) sowie die Prognosegüte der Zuverlässigkeit $R(t)$.

#### Modellabhängigkeit und Lokale Optimalität

Erstens stößt die zugrundeliegende Modellierung mittels Weibull-GLMs auf ein fundamentales Problem, das von **Khuri.2006** und **Stufken.2012** hinlänglich diskutiert wird. Im Gegensatz zu klassischen linearen Modellen (unter Normalverteilungs-

annahme) hängt die Fisher-Informationsmatrix $\mathbf{F}$ bei GLMs nicht allein von den Einstellungen der Faktoren $\mathbf{X}$ ab, sondern vollständig von den wahren, aber unbekannten Modellparametern $\theta$ (insbesondere dem Formparameter $\hat{b}$ und via der Link-Funktion dem Lageparameter $\hat{T}$):

$$\mathbf{M}(\mathbf{X}, \theta) = E\left[-\frac{\partial^2 \mathcal{L}(\theta)}{\partial \theta^2}\right]. \tag{3.1}$$

Daraus resultiert das Paradoxon, dass zur Konstruktion eines optimalen Plans bereits Kenntnisse über die zu ermittelnden Parameter vorliegen müssten. Zwar existieren auf Basis von Exponential- oder Poissonverteilung diverse Algorithmen zur numerischen Bestimmung optimaler Versuchspläne für GLMs [**Khuri.2006**], und auch für Experimente mit binärer Antwortstruktur (logistische oder Probit-Modelle) wurden Ansätze entwickelt [**Yang.2011**]. Diese Verfahren setzen jedoch stets voraus, dass die wahren Parameterwerte $\theta$ bekannt sind oder verlässlich geschätzt werden können - beispielsweise mittels initialem *best guess*. Folglich sind solche Designs, wie **Stufken.2012** ausführen, allenfalls nur **lokal optimal**. Da die Parameter im Vorfeld einer Lebensdaueruntersuchung unbekannt sind, existieren keine universell optimalen GLM-Designs für die Weibull-Lebensdauermodellierung. Ein Design, das für einen angenommenen Parametersatz optimal ist, kann sich bei Abweichung der realen Werte als ineffizient erweisen („The designs may be poor if the choice of values is far from the true parameter values“, **Stufken.2012**).

### Zeitliche und Strukturelle Effizienz

Zweitens muss die **zeitliche Effizienz** berücksichtigt werden. Da die Information in Lebensdauertests stochastisch über die Zeit generiert wird und womöglich durch Zensierung limitiert ist, wird die Varianz der Schätzung maßgeblich durch die Anzahl der tatsächlich ausgefallenen Einheiten getrieben [**Nelson.2005**].

**Ein Versuchsplan gilt folglich nur dann als effizient, wenn er die erwartete Testdauer bei gegebener Präzision und damit unbeeinträchtigter Effektivität minimiert.**

Drittens bietet die Klasse der OMARS-Designs eine Antwort auf die Forderung nach **struktureller Effizienz** und Flexibilität. Im direkten Vergleich zum etablierten CCD, das durch seine geometrische Konstruktion eine starre Anzahl an Versuchen fordert, ermöglichen OMARS-Designs zwar eine Entkopplung von Faktoren- und Versuchsanzahl (z.B. $N = 40$ statt $N \geq 45$ für $k = 6$). Sie resultieren jedoch in einer finalen Versuchspunktverteilung, die sich im Kontext von Aufwänden in EoL-Testing rational nur schwer sequenziell erweitern oder anpassen lässt. Strategisch verfolgen sie einen *One-Step*-Ansatz [**Goos.2025**], der Screening und Optimierung integriert, um Rüstzeiten und zeitliche Drifts zu vermeiden. Der Preis für diese Effizienz ist ein kontrolliertes Maß an *Aliasing* zwischen Effekten zweiter Ordnung. Damit qualifizieren sich diese Designs insbesondere für ressourcenbeschränkte Untersuchungen, wenngleich das CCD seine Stärke in der Robustheit und sequenziellen Kontrollierbarkeit behält.

### 3.1.3 Schlussfolgerung für die Testplanung

Aus der Diskrepanz zwischen theoretischem Anspruch (optimale GLM-Designs) und praktischer Anwendbarkeit (unbekannte Parameter) leitet sich die Notwendigkeit einer pragmatischen und zugleich statistisch fundierten Vorgehensweise ab. Anstatt sich auf die Suche nach einem theoretisch ***optimalen* GLM-Design** zu versteifen, das aufgrund der Parameterabhängigkeit in der Praxis kaum robust umsetzbar ist, erscheint die Adaption bewährter Standard-Designs (CCD) vielversprechender. Dabei dürfen die etablierten Optimalitätskriterien jedoch nicht als alleiniges Entwurfsziel fungieren, sondern müssen durch praxisrelevante Benchmark-Metriken ergänzt werden:

- **Modellierungsgüte (A-, D-Kriterien):** Diese Metriken sichern ab, dass die Parameterschätzung (Bestimmung von $\theta$) auch im modifizierten Design statistisch solide und präzise bleibt.

- **Prognosefähigkeit (G-, I-, V-Kriterien):** Diese Metriken gewinnen im Kontext der Lebensdauererprobung an primärer Bedeutung, da das Ziel die präzise Vorhersage der Zuverlässigkeit $R(t)$ unter Einsatzbedingungen (Extrapolation) ist.

- **Testdauer und Ressourceneffizienz:** Diese Metriken berücksichtigen die praktischen Rahmenbedingungen von Lebensdauertests, indem sie die erwartete Testdauer und den Ressourcenverbrauch minimieren, ohne die statistische Aussagekraft unzulässig zu beschneiden.
- **Trennschärfe (Power):** Sie fungiert als die entscheidende „Erfolgsgarantie" des Tests. Insbesondere bei kostenintensiven EoL-Versuchen ist es ökonomisch riskant, ein Design zu wählen, das zwar theoretisch optimal schätzt, aber praktisch relevante Effekte mit hoher Wahrscheinlichkeit übersieht. Die Power muss daher als primäres Entscheidungskriterium gegen Einsparpotenziale abgewogen werden.

Eine effiziente Testplanung für die multivariate Lebensdauererprobung erfordert folglich weit mehr als die Maximierung theoretischer Informationsmaße. Sie verlangt einen strategischen Kompromiss: Das Design muss flexibel genug sein, um Extrapolationen durch ALT gezielt zu unterstützen (Prognosegüte), robust genug, um die Unsicherheiten der nicht-linearen GLM-Parameterschätzung abzufangen (Modellierungsgüte), und dabei eine statistische Trennschärfe gewährleisten, die das Investitionsrisiko des Versuchs rechtfertigt. Nur wenn die Wahrscheinlichkeit der Effektdetektion (*power*) in einem ökonomisch vertretbaren Verhältnis zu den Testkosten steht, ist die Bedingung der Effizienz erfüllt und Effektivität gewährleistet.

## 3.2 Forschungsfragen und Aufbau der Arbeit

Das übergeordnete Ziel dieser Arbeit, die Entwicklung effizienter multivariater Lebensdauerversuche, fußt damit auf der Prämisse, dass etablierte Standard-Designs nicht zwingend durch vollkommen neuartige Algorithmen ersetzt, sondern vielmehr intelligent adaptiert werden müssen. Als methodischer Anker und Referenzpunkt dient hierbei das **CCD**. Dieser Konsens begründet sich auf einer Synthese aus verfahrenstechnischen, physikalischen und statistischen Vorzügen, die das CCD für die Zuverlässigkeitsmodellierung im Maschinen- und Fahrzeugbau prädestinieren. Dies lässt sich aus praktischen Erfahrungen wie beispielsweise nach **Myers.2016**, **Kleppmann.2020**, **Rigdon.2022** sowie einer Vielzahl wissenschaftlicher Publikationen ableiten (vgl. Kapitel 2) und umfasst insbesondere folgende Aspekte:

1. **Sequenzielle Augmentierbarkeit:** Das Design unterstützt ideal den ökonomischen Zwang zur Ressourceneffizienz. Es ermöglicht eine schrittweise Erweiterung vom Screening über lineare Modelle bis hin zur quadratischen Modellierung. Dies erlaubt den Abbruch oder die Ausweitung von Versuchen basierend auf Zwischenergebnissen und minimiert das Risiko von Fehlinvestitionen bei zeitintensiven Lebensdauertests [**Bertsche.2022**].

2. **Universelle Prädiktionseigenschaften:** Da der exakte Betriebsbereich oder das Optimum der Zuverlässigkeit a priori oft unbekannt sind und Tests beschleunigt (ALT, Offset zwischen Test- und Feldraum) stattfinden, bietet die Rotierbarkeit des Designs günstige Voraussetzungen für eine richtungsunabhängige Prädiktionsgüte [**Meeker.2022**, **Montgomery.2020**].

3. **Wissenschaftliche Fundierung:** Das CCD ist als breit diskutierter und gut erforschter Standard etabliert, was die Akzeptanz und Vergleichbarkeit der Ergebnisse im wissenschaftlichen und industriellen Umfeld sicherstellt, vgl. **Kleppmann.2020**, **Montgomery.2020**, **Rigdon.2022**.

4. **Validierung physikalischer Modelle:** Durch die Variation auf fünf Faktorstufen ($-\alpha_D, -1, 0, +1, +\alpha_D$) ermöglicht das Design - im Gegensatz zu einfacheren Plänen - die Überprüfung der Gültigkeit physikalischer Beschleunigungsgesetze (z.B. Arrhenius) und die Detektion von Linearitätsabweichungen bei hohen Lasten [**Yang.2007**, **Modarres.2017**, **Meeker.2022**].

5. **Schätzung des reinen Fehlers:** Die Integration mehrfacher ZPs erlaubt eine robuste Schätzung der natürlichen Streuung (*Pure Error*) unabhängig vom Anpassungsfehler des Modells (*Lack of Fit*). Dies ist für die Berechnung verlässlicher Vertrauensbereiche der Zuverlässigkeit essenziell [**Meeker.2022**].

6. **Orthogonale Blockbildung:** Das Design lässt sich exzellent in orthogonale Blöcke unterteilen [**Montgomery.2020**, **Rigdon.2022**]. Dies ist für Langzeitversuche von entscheidender Bedeutung, um zeitliche Trends durch beispielsweise Chargenunterschiede statistisch zu bereinigen, ohne die Parameterschätzung zu verzerren.

7. **Robustheit gegen Datenverlust:** Aufgrund seiner symmetrischen Struktur weist das CCD eine hohe Toleranz gegenüber fehlenden Werten (*Missing Da-*

*ta*) auf, was die Auswertbarkeit des Versuchs auch bei unvorhergesehenen Ausfällen oder technischer Zensierung auf dem Prüfstand weitgehend sichert [**Montgomery.2020**, **Myers.2016**].

Ausgehend von diesem Status quo zielt die vorliegende Arbeit darauf ab, dieses bewährte Grundkonstrukt nicht zu verwerfen, sondern es gezielt für die spezifischen Anforderungen der Lebensdauerprognose zu modifizieren. Dies führt zur zentralen **Forschungsfrage** dieser Arbeit:

**Wie können effiziente, multivariate Testdesigns (RSDs) entwickelt und geplant werden, um eine beschleunigte Lebensdauererprobung zum Zweck einer multivariaten Zuverlässigkeitsmodellierung umzusetzen?**

Zur Beantwortung dieser Hauptfragestellung werden folgende Teilfragestellungen abgeleitet:

1. **Adaptionsbedarf und -strategie:** Wie können konventionelle Planungsstrategien und Testdesigns - allen voran CCDs - adäquat zum Zweck der beschleunigten Lebensdauererprobung (ALT) angepasst werden?

2. **Bewertungsmethodik:** Wie können die Auswirkungen derartiger Anpassungen (Manipulationen der Orthogonalität) an CCDs auf die Prognosegüte quantitativ charakterisiert und vergleichbar bewertet werden?

### 3.2.1 Aufbau der Arbeit

Der weitere Aufbau der Arbeit orientiert sich an der logischen Abfolge von der Parameteridentifikation bis zur Design-Optimierung. In **Kapitel 4** wird zunächst das Themenfeld des Screenings adressiert. Hier wird ein Vorschlag zu einem heuristischen Screening-Ansatz vorgestellt, der darauf abzielt, die Effizienz im Prozess der Parameterselektion gezielt für Lebensdauer-beeinflussende Faktoren zu steigern und somit die Basis für nachfolgende RSDs unter dem Prädikat *effizient* zu legen. Grundsätzlich neu ist hierbei die Behandlung mutmaßlicher Wechselwirkungen der Lebensdauer-beeinflussenden Faktoren sowie die Berücksichtigung von Änderungen in der signifikanten Aktivmenge der Einflussparameter durch den Screening-Prozess. Darauf aufbauend widmet sich **Kapitel 5** der generischen Untersuchung

und Bewertung von Versuchsplanabweichungen, ausgehend vom CCD als Referenz. Zwar erfolgt die Demonstration der Methodik exemplarisch am CCD, der Anspruch auf Gültigkeit erstreckt sich jedoch auch auf andere RSDs. Dies begründet sich durch die in Abschnitt 2.2.5 dargelegten Eigenschaften, welche universell auf der Fisher-Informationsmatrix sowie der empirischen Datenlage basieren. In diesem Kontext werden ein Kostenmodell sowie ein neu entwickeltes Tool zur Bewertung der Prädiktionsgüte in Abhängigkeit der SPV eingeführt. Daraus abgeleitet werden konkrete Strategieempfehlungen für die Anpassung von CCDs, etwa zur Optimierung der Extrapolationsfähigkeit, vorgestellt und diskutiert. Abschließend ist in **Kapitel 6** die Vorstellung einer Fallstudie dokumentiert, um die erarbeitete Methodik an einem praxisnahen Anwendungsbeispiel zu veranschaulichen und die theoretischen Erkenntnisse in den operativen Kontext zu transferieren.

# 4 Parameter-Screening für multifaktorielle Lebensdauertests

Die in Kapitel 3 hergeleitete Notwendigkeit effizienter Testdesigns setzt voraus, dass die Anzahl der zu untersuchenden Faktoren $k$ auf ein handhabbares Maß begrenzt ist. Da die Komplexität und der Versuchsumfang exponentiell mit der Anzahl der Faktoren steigen (vgl. Gleichung 2.29), ist eine präzise Vorselektion der Einflussgrößen entscheidend. Klassische Ansätze der Versuchsplanung setzen hierfür oft auf experimentelle Screening-Pläne. Im Kontext der Lebensdauererprobung führen diese jedoch zu einem Paradoxon: Um experimentell zu prüfen, ob ein Parameter die Lebensdauer beeinflusst, müssten gleichermaßen bei konventionellen Screeningdesigns (z.B. $2^{k-p_f}$ Designs, Plackett-Burman-Designs) sowie modernen RSDs (z.B. OMARS-Designs) bereits zeitintensive EoL-Tests durchgeführt werden, was den Effizienzvorteil des Screenings zunichtemacht.

Dieses Kapitel stellt daher einen effizienten methodischen Ansatz zum **heuristischen Screening** vor. Ziel ist es, basierend auf Expertenwissen und systematischer Analyse eine qualitative Reduktion des Parameterraums vorzunehmen, *bevor* physische Versuche gestartet werden [**Arndt.2023c**]. Dabei liegt der Fokus explizit auf der Unterscheidung zwischen bloßer Robustheit (zum Zeitpunkt $t = 0$) und echter Zuverlässigkeit (über die Zeit $t > 0$). Aus der Perspektive der Zeitdomäne ist die differenzierte Klassifizierung der Einflussfaktoren für die Konzeption zuverlässigkeitstechnischer Untersuchungen von entscheidender Bedeutung. Schließlich sind stochastische Degradationspfade entsprechend Abschnitt 2.1.1 und die daraus resultierende Überlebenswahrscheinlichkeit $R(t)$ nicht statisch zu betrachten, sondern zeitvarianten Interaktionsstrukturen und einer sich verschiebenden Effekthierarchie unterlegen. Folglich kann das Parameterset, welches das Systemverhalten in fortgeschrittenen Phasen des Lebensdauerzyklus determiniert, signifikant von jenen Faktoren divergieren, die lediglich die initiale Performanceverteilung des Systems bei $t = 0$ dominieren. Die Auswahl der relevanten Kovariaten ist somit inhärent dem

Einfluss der Zeit ausgesetzt. Um dieser Dynamik gerecht zu werden, synergiert der vorgestellte Ansatz teils bestens etablierte Kreativtechniken (z.B. Brainstorming, Fehlerbaum-Analysen - engl. Fault-Tree-Analysis (FTA), Ishikawa-Diagramme) mit strukturierten Bewertungswerkzeugen (z.B. DSM, Grid-Analyse), um eine belastbare Identifikation und Priorisierung der kritischen Einflussgrößen zu gewährleisten.

## 4.1 Identifikation potenzieller Einflussgrößen

Die Basis eines jeden Screenings bildet die vollständige Erfassung aller potenziellen Einflussgrößen. Um eine lückenlose Identifikation zu gewährleisten, ist eine strukturierte Systemanalyse unerlässlich, wie sie in der Zuverlässigkeitstechnik nach **Bertsche.2022** etabliert ist. Ein zentrales Werkzeug hierfür ist das **Funktionsblockdiagramm**, engl. **Function Block Diagram (FBD)** [**Lindemann.2008**, **Krallmann.2013**, **Gundlach.2004**]. Es abstrahiert das technische System auf seine Ein- und Ausgangsgrößen, klassifiziert nach den Flussgrößen *Energie*, *Stoff* und *Signal* (vgl. Abbildung 4.1) [**Pahl.2007**]. Innerhalb der Systemgrenzen werden Haupt- und Nebenfunktionen definiert, deren Nichterfüllung direkt zu potenziellen Ausfallmechanismen führt. Zur initialen Sammlung der Parameter (Informationsbe-

Abbildung 4.1: Funktionsstruktur mit Haupt-, Neben- und Teilfunktionen zur Identifikation von Einflussgrößen (nach **Wallace.2007**)

schaffung) eignen sich, aufbauend auf dem FBD, entsprechend **Montgomery.2020b**, **Bruckner.2019** klassische Methoden des Qualitätsmanagements (Seven Quality Tools (Q7) and Seven Management and Planning Tools (M7)) sowie etliche Kreativtechniken:

- **Literaturrecherche:** Analyse bestehender Ausfallmodi und physikalischer Wirkmechanismen (z.B. Arrhenius, Wöhler) aus vergleichbaren Anwendungen aber auch simulativen Untersuchungen (Finite-Elemente-Analyse (FEA)) [**Breiing.1997**].
- **Brainstorming** bzw. **ABC-Brainstorming** ermöglichen es interdisziplinären Expertenteams, intuitives Erfahrungswissen zu explizieren [**Daenzer.2002**, **Mayers.1997**].

- **Delphi-Methode:** Durch mehrstufige, anonymisierte Befragungen von Experten können subjektive Einschätzungen objektiviert und Konsens über potenzielle Einflussgrößen erzielt werden [**Daenzer.2002**].
- **Morphologische Analyse:** Durch die Zerlegung des Systems in Teilfunktionen und die Variation von Lösungsprinzipien werden systematisch konstruktive Einflussparameter aufgedeckt [**Albers.2005**, **Thompson.1999**].

Das Ergebnis dieses Schrittes ist eine unsortierte, aber möglichst vollständige Liste (Parameter-Pool) aller Größen, die potenziell auf das System einwirken.

## 4.2 Kreativmethoden zum Auswahlprozesse im Parameter-Screening

Kreativmethoden zum Auswahlprozess im Parameter-Screening Nach der Identifikation muss der Parameter-Pool zunächst strukturiert und anschließend bewertet werden, um die vitalen Einflussgrößen (*vital few*) von den trivialen (*trivial many*) zu trennen, vergleiche **Arndt.2023c**. Insbesondere basierend auf Arbeiten von **Gundlach.2004**, **Kremer.2018b**, **Mayers.1997** werden im Folgenden geeignete Methoden vorgestellt, die sich für das heuristische Screening im Kontext von zeitvarianten Parametersets in der Lebensdaueranalyse eignen und darüber hinaus auf Randbedingungen der Versuchsplanung Rücksicht nehmen.

### 4.2.1 Strukturierungsmethoden

Nachdem durch die vorangegangenen Schritte der Informationsbeschaffung eine möglichst vollständige Sammlung aller potenziellen Systemparameter, Inputs und Outputs generiert wurde, bedarf es einer systematischen Strukturierung auf Basis eines vertieften Systemverständnisses. Dieser Schritt darf sich nicht auf eine reine Clusterung in Parametergruppen beschränken. Vielmehr gilt es, die *gegenseitigen Beeinflussungen* der Größen zu identifizieren und zu offenbaren. Insbesondere für die Lebensdaueranalyse stellt dies einen entscheidenden Mehrwert dar, der im Einklang mit den Prinzipien des L-DoE steht [**Montgomery.2020**, **Kremer.2021**]: Phänomene wie Alterungseffekte oder die zeitvariante Änderung von Materialeigenschaften

sind physikalisch oft nicht trivial durch Einzelgrößen beschreibbar, sondern resultieren maßgeblich aus Interaktionen (vgl. Abbildung 4.5). Um diese komplexen, teils zeitabhängigen Zusammenhänge für die weitere Selektion greifbar zu machen, eignen sich primär grafische Methoden, die über die reine Auflistung hinausgehen:

- **Affinitätsdiagramm:** Als Werkzeug der *M7* dient es der thematischen Clusterung der oft unstrukturierten Ergebnisse aus Brainstorming-Sessions [**Bruckner.2019**]. Es ordnet Parameter übergeordneten Kategorien zu und deckt erste logische Gruppierungen auf, womit es als ideale Vorstufe für detailliertere Analysen (z.B. Ishikawa) fungiert.

- **Mind-Mapping:** Diese Methode ermöglicht eine hierarchische Gliederung der Einflussgrößen ausgehend vom Untersuchungsziel (Wurzel) über Haupt- zu Nebenparametern (Äste). Der entscheidende Vorteil für das Screening liegt in der Möglichkeit, *Querbeziehungen* durch Verbindungslinien zwischen den Ästen zu visualisieren, wodurch Interdependenzen abseits der direkten Hierarchie offensichtlich werden [**Buzan.2010**].

- **Erweitertes Ishikawa-Diagramm:** Das klassische Ursache-Wirkungs - Diagramm (Fischgräten-Diagramm) strukturiert Parameter traditionell nach 6*M* (Mensch, Maschine, Material, Methode, Mitwelt, Messung). Für das heuristische Screening wird es dahingehend modifiziert, dass nicht nur statische Haupteffekte, sondern explizit **Interaktionen** durch *Querverbindungen* zwischen den Ästen visualisiert werden (vgl. Abbildung 4.2) [**Arndt.2022**, **Daenzer.2002**].

- **Interdependenz-Netzwerke (Vernetztes Denken):** Für hochkomplexe Systeme bietet sich die Modellierung als gerichteter Graph an. Hierbei werden Parameter als Knoten und ihre Wirkbeziehungen als Kanten dargestellt [**Tittmann.2019**]. Dies erlaubt nicht nur die Abbildung der Wirkrichtung (positiv/negativ), sondern auch die Integration zeitlicher Dynamiken und Intensitäten, was für die Modellierung von Degradationsprozessen vorteilhaft ist.

- **ABC-Analyse:** Zur Reduktion der Komplexität klassifiziert die ABC-Analyse die Parameter nach dem Pareto-Prinzip in Klassen hoher (A), mittlerer (B) und geringer (C) Relevanz. Dies dient als erster Filter, um den Fokus auf die vermuteten Haupttreiber der Lebensdauer zu lenken [**Montgomery.2020**].

Abbildung 4.2: Erweitertes Ishikawa-Diagramm zur Visualisierung von Interaktionen zwischen Einflussfaktoren (adaptiert nach [**Arndt.2022**])

Die hierdurch erreichte Transparenz über die Vernetzung der Parameter bildet die notwendige Basis für den nächsten Schritt: Die Überführung der qualitativen Struktur in eine quantitative Priorisierung, um die finalen Faktoren für den Versuchsplan zu selektieren.

### 4.2.2 Bewertungsmethoden (Decision Making)

Aufbauend auf der qualitativen Strukturierung der Einflussgrößen (vgl. Abschnitt 4.2.1) ist nun eine analytische Bewertung erforderlich, um die *vital few* von den *trivial many* zu separieren. Ziel ist es, die gesammelten Parameter in eine Rangfolge zu bringen, die sowohl deren vermutete Relevanz für die Lebensdauer als auch deren Interaktionspotenzial widerspiegelt. Hierfür eignen sich matrixbasierte Ansätze, die eine systematische Paarvergleichung erzwingen und subjektive Einschätzungen objektivierbar machen.

#### Design-Structure-Matrix (DSM)

Die DSM ist eine quadratische $n \times n$-Matrix, in der alle $n$ identifizierten Systemparameter sowohl in den Zeilen als auch in den Spalten aufgetragen sind. Ein Eintrag $y_{ij}$ in der Matrix symbolisiert dabei eine gerichtete Abhängigkeit: Der Parameter in Zeile $i$ beeinflusst den Parameter in Spalte $j$ [**Kremer.2018b**, **Lindemann.2008**]. Für das Screening im Kontext der Zuverlässigkeit wird die Matrix häufig um eine Zielgrößen-Spalte erweitert, um den direkten Einfluss auf die Lebensdauer $t$ zu erfassen. Die Bewertung kann auf zwei Detailebenen erfolgen:

- **Binäre DSM:** Erfasst lediglich die Existenz einer Interaktion ($y_{ij} \in \{0, 1\}$). Dies eignet sich für frühe Phasen mit geringem Detailwissen, um prinzipielle Vernetzungen aufzudecken.

- **Numerische DSM:** Gewichtet die Stärke des Einflusses, z.B. auf einer Skala von 0 (kein Einfluss) bis 3 (starker Einfluss). Dies erlaubt eine differenzierte Priorisierung.

Ein wesentlicher Vorteil der DSM ist die Aufdeckung von Asymmetrien: Ein Parameter A kann Parameter B stark beeinflussen, ohne dass B signifikant auf A zurückwirkt ($y_{AB} \neq y_{BA}$). Solche *aktiven* Parameter sind potenzielle Steuergrößen für den Versuchsplan [**Kremer.2021**, **Arndt.2023c**]. Zudem ermöglicht die Matrix durch algorithmische Partitionierung (Clustering) das Identifizieren von Parametergruppen, die eng miteinander interagieren, was Hinweise auf physikalische Wirkmechanismen liefert [**Lindemann.2008**].

Abbildung 4.3: Beispielhafte Darstellung einer binären DSM zur Identifikation von Interaktionen zwischen Systemparametern (adaptiert nach [**Arndt.2022**])

### Grid-Analyse (Portfolio-Analyse)

Die Grid-Analyse visualisiert die Ergebnisse der numerischen DSM in einem zweidimensionalen Portfolio-Diagramm (vgl. Abbildung 4.4). Hierfür werden für jeden Parameter $i$ zwei Kennzahlen berechnet [**Mayers.1997**]:

1. **Aktivsumme (Active Sum):** Die Summe der Zeileneinträge ($\sum_j y_{ij}$). Sie ist ein Maß dafür, wie stark der Parameter das Gesamtsystem treibt.

2. **Passivsumme (Passive Sum):** Die Summe der Spalteneinträge ($\sum_i y_{ij}$). Sie beschreibt, wie stark der Parameter selbst von anderen Größen beeinflusst wird (Reaktivität).

Die Positionierung im Diagramm erlaubt eine Klassifizierung in vier Quadranten, aus denen sich direkte Handlungsempfehlungen für das DoE ableiten:

- **Aktive Parameter (hohe Aktiv-, niedrige Passivsumme):** Diese Größen qualifizieren sich als ideale Steuerfaktoren ($x$) für den Versuchsplan, da sie das System dominieren, ohne selbst instabil zu sein.

- **Kritische Parameter (hohe Aktiv- und Passivsumme):** Diese Faktoren weisen eine starke Vernetzung auf. Sie sind relevant für die Lebensdauer, bergen aber aufgrund ihrer Abhängigkeiten ein hohes Risiko für unerwünschte Wechselwirkungen. Ihre Überwachung im Versuch ist von besonderer Bedeutung.

- **Passive Parameter (niedrige Aktiv-, hohe Passivsumme):** Diese Größen eignen sich primär als Indikatoren oder Antwortgrößen ($y$), da sie empfindlich auf Änderungen im System reagieren, während ihre Eignung als Steuerfaktoren als gering einzustufen ist.
- **Träge Parameter (niedrige Summen):** Diese Faktoren spielen eine untergeordnete Rolle und lassen sich im Screening oft vernachlässigen oder als Konstanten fixieren.

Zur Abbildung der Unsicherheit heuristischer Schätzungen ist eine Erweiterung der Grid-Analyse um Konfidenz-Vektoren möglich [**Arndt.2023c**]. Hierbei geben Experten für jede Bewertung an, ob diese auf gesichertem Wissen (Daten, Literatur) oder Intuition beruht. Große Differenzen zwischen *gesicherter* und *intuitiver* Position im Grid indizieren Wissenslücken, deren Schließung durch experimentelle Voruntersuchungen vor der Aufnahme des Parameters in ein aufwendiges L-DoE erforderlich ist.

Abbildung 4.4: Grid-Analyse zur Klassifizierung von Parametern in aktive, kritische, passive und träge Faktoren

### 4.2.3 Finale Parameter-Diskussion

Die Ergebnisse aus DSM und Grid-Analyse bilden die Entscheidungsgrundlage für die finale Selektion der Versuchs-Faktoren [**Arndt.2023c**]. In diesem Diskurs erfolgt eine Abwägung der heuristischen Erkenntnisse gegen die harten Restriktionen des Versuchsplans (Budget, Planungsumfang, Messbarkeit). Ziel ist ein Kompromiss zwischen der vollständigen Abbildung aller wirksamen Mechanismen (Modellgüte) und der Reduktion auf eine handhabbare Anzahl an Faktoren (Effizienz). Als relevant identifizierte, aber aus Budgetgründen nicht variierbare Faktoren sind explizit als Konstanten zu dokumentieren oder als Noise-Faktoren in einer Robustheitsbetrachtung zu berücksichtigen.

## 4.3 Randbedingungen in der Parameterauswahl für die Zuverlässigkeitsmodellierung

Die Anwendung der oben genannten Methoden muss im Kontext der Lebensdaueranalyse spezifische Randbedingungen berücksichtigen, die sich fundamental von der klassischen Robustheitsoptimierung unterscheiden [**Gundlach.2004**, **Mayers.1997**, **Klein.2011**].

### 4.3.1 Unterscheidung: Robustheit vs. Zuverlässigkeit

Ein häufiges Missverständnis im Screening ist die Gleichsetzung von initialer Streuung der Produktperformance mit Lebensdauerstreuung. Wie in Abbildung 4.5 dargestellt, betrachtet die klassische Robustheitsanalyse nach **Klein.2014** im Verständnis von *Taguchi/Shainin* oft nur die Verteilung der Systemantwort zum Zeitpunkt $t = 0$. Die Zuverlässigkeitstechnik fokussiert jedoch auf die **Degradation** über die Zeit. Faktoren, die initial kaum Einfluss auf die Performance haben (z.B. Materialalterung, Verschleiß, Wechselwirkungen), können im Zeitverlauf dominante Treiber für Ausfallmechanismen werden. Heuristisches Screening für L-DoE muss daher explizit Parameter priorisieren, die *zeitabhängige* Schädigungsmechanismen treiben, selbst wenn sie *initial inaktiv* erscheinen.

Abbildung 4.5: Abgrenzung zwischen initialer Performance-Verteilung (A) und zeitabhängiger Degradation (B) im Screening-Prozess

### 4.3.2 Anforderungen aus dem Versuchsplan (L-DoE)

Die im heuristischen Prozess ausgewählten Faktoren werden darauffolgend im statistischen Versuchsplan (DoE) schließlich verarbeitet. Daraus ergeben sich zunächst harte Restriktionen für die Auswahl:

- **Einstell- und Regelbarkeit:** Nur Parameter, die im Versuch aktiv und präzise auf verschiedene Stufen eingestellt werden können, qualifizieren sich als Faktoren. Nicht steuerbare Größen lassen sich sonst in *Noise* oder *Co-Faktoren* einordnen.

- **Beschleunigbarkeit:** Für ALT werden schließlich nur Faktoren gewählt, die eine physikalische Beschleunigung der Schädigung ermöglichen (z.B. Temperatur, mechanische Spannung), ohne den Fehlermechanismus zu verändern.

- **Kosten und Komplexität:** Da der Stichprobenumfang bei voll-faktoriellen Plänen mit $n \propto m \cdot N^k$ wächst, vergleiche Abschnitte 2.2.3,2.2.4, zwingt die Ökonomie zur drastischen Reduktion von $k$. Gleiches Verhalten zeigt sich wie schon erwähnt auch bei konventionellen und modernisierten Algorithmen von RSDs. Das heuristische Screening definiert bestenfalls also ein wirtschaftlich abbildbares Maximum an umsetzbaren Faktoren $k_{\max} \leq 2 \ldots 4$, vgl. [**Montgomery.2020**, **Siebertz.2017**].

- **Design Resolution (Auflösung):** Für den Fall, dass ultimativ dennoch viele vermeintlich relevante Faktoren aus dem Screening-Prozess resultieren, verbleiben nur Screening-Designs für die weitere experimentell empirische Analyse. Das Screening muss vorab klären, welche Interaktionen physikalisch plausibel sind, um eine geeignete Auflösung (Resolution III, IV oder V) oder Konfiguration von Screening-RSDs zu wählen und Aliasing von Haupteffekten mit wichtigen Wechselwirkungen zu minimieren bzw. zu vermeiden.

Mit den genannten Anforderungen zur methodischen Anwendung von L-DoE ermöglichen schließlich die in Abschnitt 4.2 identifizierten heuristischen Methoden für das Parameter-Screening ein strukturiertes Vorgehen zur effizienten Auswahl relevanter Einflussgrößen [**Arndt.2023c**].

## 4.4 Vorgehen zum heuristischen Screening für die Zuverlässigkeitsmodellierung

Basierend auf der Analyse der Methoden und Randbedingungen wird in Anlehnung an **Arndt.2023c** folgendes prozedurales Vorgehen für das Parameter-Screening in der Zuverlässigkeitsmodellierung vorgeschlagen - vergleiche auch Abbildung 4.6:. Dieser Ansatz fungiert als methodische Barriere vor dem eigentlichen ressourcenintensiven Lebensdauerversuch, um die Effizienz der Datenerhebung zu maximieren.

Abbildung 4.6: Methodischer Ablauf des heuristischen Screenings als Vorstufe zum L-DoE

### 4.4.1 *Phase I*: Systemanalyse und Fehlermechanismen

Der Prozess initiiert nicht mit der isolierten Betrachtung von Parametern, sondern mit der Identifikation des relevanten Ausfallmechanismus. Basierend auf dem FBD (Abschnitt 4.1) erfolgt die Definition des spezifischen **Failure Mode** (z.B. Zahnbruch vs. Abrieb bei einem Riemen). Da unterschiedliche Fehlermodi in der Regel von divergenten Parametersets getrieben werden, führt eine Vermischung unweigerlich zu Rauschen in den Daten und ist zu vermeiden.

### 4.4.2 *Phase II*: Heuristische Parameterassessment und Interaktionsanalyse

Im zweiten Schritt unterliegt der Parameter-Pool einer Filterung durch die in Abschnitt 4.2 vorgestellten Methoden (z.B. Ishikawa-Diagramm in Kombination mit Grid-Analyse). **Arndt.2023c** stellen hierzu durch Bewertung der Eignung der Methoden im Kontext der Lebensdaueranalyse fest, dass vornehmlich die Kombination aus erweitertem Ishikawa-Diagramm (zur Visualisierung von Interaktionen) und DSM (zur quantitativen Bewertung der Vernetzung) eine belastbare Grundlage für die Priorisierung der Faktoren darstellt. Kritisch ist hierbei die Bewertung der Interaktionsdichte in Bezug auf die Lebensdauer als Zielgröße. Faktoren, die im Ishikawa-Diagramm oder der DSM eine hohe Vernetzung aufweisen (korrespondierend mit einer hohen Aktivsumme), erfahren eine Priorisierung, da sie mit hoher Wahrscheinlichkeit - insbesondere wechselwirkend über jedenfalls Abschnitte der Lebensdauer - als Katalysatoren für Degradationsprozesse fungieren. Das Ergebnis dieses Prozessschrittes ist eine hierarchische Ordnung der Faktoren nach ihrer vermuteten Relevanz für die Lebensdauer.

### 4.4.3 *Phase III*: Abgleich mit dem Versuchsdesign

Im finalen Schritt erfolgt der Abgleich der priorisierten Faktorenliste mit den Restriktionen des gewählten L-DoE (vgl. Abschnitt 3.2 sowie Abschnitt 4.3.2). Hierbei sind folgende Prüffragen essenziell:

- Korrespondiert die Anzahl der Faktoren $k$ mit dem verfügbaren Budget für $n$ Versuche?
- Ist die physikalische Unabhängigkeit der Faktoreinstellung (Orthogonalität) gewährleistet?
- Ermöglichen die gewählten Stufenabstände eine signifikante, detektierbare Änderung der Lebensdauer (Power $> 80\%$), vgl. Abschnitt 2.2.1?

Lediglich Faktoren, die diesen Filter passieren, werden in das finale L-DoE-Modell integriert. Parameter, die als relevant klassifiziert wurden, jedoch aus Budgetgründen entfallen, sind als konstante Randbedingungen zu dokumentieren oder als Noise-Faktoren in Robustheitsanalysen auszulagern.

Das Resultat dieses dreistufigen Vorgehens ist eine kondensierte Parametermenge, die das Optimum zwischen notwendigem Informationsgehalt und vertretbarem experimentellem Aufwand repräsentiert. Wie in Abbildung 4.7 visualisiert, wird das Volumen der zu betrachtenden Einflussgrößen von der initialen Systemanalyse (Gesamtmenge) über die heuristische Bewertung bis hin zum finalen Design-Matching kontinuierlich auf das für das L-DoE essenzielle Maß verdichtet.

Abbildung 4.7: Prozedurale Volumenreduktion des Parameterraums im heuristischen Screening für L-DoE (adaptiert nach **Arndt.2023c**)

## 4.5 Zusammenfassung

Das in diesem Kapitel vorgestellte heuristische Screening schließt die methodische Lücke zwischen der qualitativen Systemanalyse und der quantitativen Versuchsplanung. Durch die strukturierte Nutzung von Expertenwissen (z.B. mittels DSM und erweiterten Ishikawa-Diagrammen) lässt sich die Anzahl der Versuchs-Faktoren

$k$ rational reduzieren, ohne relevante Interaktionen zu vernachlässigen. Entscheidend ist dabei der vollzogene Perspektivwechsel von der Betrachtung der initialen Performance-Streuung hin zur Analyse der zeitabhängigen Degradation eines Performancemerkmals. Dieses Vorgehen schafft die notwendige Voraussetzung für die Anwendbarkeit der in Kapitel 3 diskutierten effizienten Versuchspläne für Lebensdauererprobungen, da diese ihre Stärken erst bei einer begrenzten Anzahl an Faktoren ($k \approx 3 \ldots 5$) wirtschaftlich ausspielen. Die methodische Vorarbeit des Screenings fungiert somit als zentraler Hebel für die Effizienz des gesamten Lebensdauerversuchs.

# 5 Effizienz durch Effektivität in der multivariaten Versuchsplanung

Nach der qualitativen Vorselektion relevanter Einflussgrößen (Kapitel 4) fokussiert die vorliegende Betrachtung nun die quantitative DoE-Planung. Die zentrale wissenschaftliche Zielsetzung besteht in der Entwicklung adäquater, multivariater Lebensdauertests, welche etablierte Standard-RSDs gezielt an die spezifischen Anforderungen der Lebensdauerprognose anpassen. Das CCD bildet hierbei das methodische Fundament, da es durch seine sequenzielle Augmentierbarkeit (Screening → lineares Modell → quadratische Modellterme) im Kontext kostenintensiver EoL-Tests eine unübertroffene operative Flexibilität bietet (vgl. Abschnitt 3.2).

Um den Paradigmenwechsel von klassischen, starren DoE-Ansätzen hin zu hochgradig effizienten Lebensdauertests methodisch abzusichern, gliedert sich dieses Kapitel in vier aufeinander aufbauende Schwerpunkte - ausgehend von einer idealisierten Theorie (Normalverteilung, OLS) hin zur komplexen, gekoppelten Realität der Zuverlässigkeitstechnik (Weibull, MLE, Prüfkosten):

Zunächst wird in Abschnitt 5.1 die statistische Sensitivität des ungestörten Designs evaluiert, um die Robustheit von Standard-Versuchsplänen gegenüber Praxisrestriktionen zu prüfen. Unabhängig von einer ALT-Beschleunigung wird quantifiziert, wie das CCD auf typische, unbeabsichtigte Restriktionen - wie Anlagenlimits, asymmetrische Ausfälle oder Streuungen der Steuerung - reagiert. Mittels Monte-Carlo-Simulationen (MCS) auf Basis eines fiktiv-physikalischen *Ground-Truth*-Modells wird nachgewiesen, ab welchem Grad solche Orthogonalitätsabweichungen die Schätzpräzision und insbesondere die statistische Trennschärfe (*power*) kompromittieren. Das daraus gewonnene Bewusstsein über die erstaunliche Robustheit des CCD legitimiert in einem zweiten Schritt (Abschnitt tbd) den gezielten, asymmetrischen Eingriff in die Planmatrix im Sinne einer adaptiven Versuchsplanung. Hierbei wird untersucht, wie durch den Verzicht redundanter Versuche "freigewordeneÜmfänge als strategische Brückenpunkte genutzt werden können, um die SPV

bei der Extrapolation in den realen Feldbereich zu minimieren. Zur richtungsabhängigen Veranschaulichung dieser Extrapolationsabsicherung wird eine dedizierte visuelle Bewertungsmethodik, der Evaluation Graph (EVG), eingeführt.

Darauf aufbauend werden die bis dato unter Normalverteilungsannahme abgeleiteten Design-Modifikationen in Abschnitt tbd auf multivariate Lebensdauermodelle übertragen. Anhand lebensdauerverteilter Daten (Weibull) und der Parameteridentifikation via MLE wird validiert, ob der adaptive Brückenbau auch unter den erschwerten Bedingungen von Zensierungen und Lebensdauerskalierungen seine überlegene Prognosefähigkeit behält, welche maßgeblich über die resultierenden Konfidenzintervalle im Feldbereich evaluiert wird. Den Abschluss bildet in Abschnitt 5.4 eine ökonomische Effizienz- und Kostenmodellierung, die das holistische Bild vervollständigt. Indem die resultierenden Testlaufzeiten in reale Prüfstandskosten übersetzt werden, wird die statistische Testgüte - repräsentiert durch *power* und SPV - direkt mit dem monetären Aufwand verknüpft. Nur durch diesen finalen Trade-off lässt sich die zentrale Kernfrage der Effizienz beantworten: *Wie viel Trennschärfe ist finanzierbar?*

## 5.1 Effektivität von Versuchsplänen mit Orthogonalitätsabweichungen

Generell können sich Orthogonalitätsabweichungen durch physikalische Restriktionen der technischen Versuchsausführung, die spezifische Performance und Funktionalität des Systems oder Produkts prinzipiell oder bei ALT durch möglicherweise bewusste Manipulation des Versuchsraums zur Steigerung der Extrapolationsgüte sein. Insbesondere im Kontext der Lebensdauerprognose sind solche Eingriffe praxisrelevant und begründet: Die Verschiebung der Versuchspunkte in Richtung höherer Lastniveaus verkürzt die Prüfzeit und senkt die Kosten, während eine Verortung nahe dem Operationsbereich die Modellanpassung verbessert und die Extrapolationsunsicherheit reduziert.

Allerdings bergen solche Modifikationen das Risiko, die statistische Integrität des Designs zu beeinträchtigen. Im Idealfall sind die Design-Matrix-Spalten eines CCD orthogonal zueinander, was eine unabhängige Schätzung der Modellparameter ermöglicht - vgl. Abschnitt 2.2.3. Geometrische Verzerrungen führen zwangsläufig

zu einem Verlust dieser Orthogonalität (vgl. Gleichung 2.34). Besonders kritisch ist, dass die Auswirkungen peripherer Parameterstufen (SPs) im augmentierten Ansatz erst spät im sequenziellen Prozess sichtbar werden - nämlich dann, wenn das initiale faktorielle Design erweitert wird. Daher ist es essenziell, die Robustheit des CCD gegenüber typischen Design-Abweichungen systematisch zu quantifizieren. Entgegen bereits erfolgter Untersuchungen durch **Box.1963**, **Ahn.2015**, **Donev.2004**, **Zhang.2021** sowie **Jang.2002** oder vergleichbarer liegt der Fokus hierbei allerdings nicht auf der reinen geometrischen Verzerrung und der Analyse sowie Bewertung durch geeignete Optimalitätskriterien (entsprechend Abschnitt 2.2.5). Die hier erwähnten Beiträge konzentrieren sich primär auf die geometrische Charakterisierung der Design-Abweichungen und deren Einfluss auf die Struktur der Design-Matrix bzw. geeigneter Optimalätskriterien. Vielmehr erfolgt hier eine Quantifizierung der Auswirkungen auf die Schätzpräzision und insbesondere die Trennschärfe im Kontext von Lebensdauerprognosen. Die Bewertung mittels Optimalitätskriterien wäre aus genannten Gründen ohnehin nicht zielführend, da im Umkehrschluss die Erfüllung der Kriterien im Planungsprozess erneut Unkenntnis über die tatsächlichen Auswirkungen auf die Schätzpräzision und Trennschärfe erzeugen würde. Dies hat zur Folge, dass zunächst eine numerische Simulation erforderlich ist, um die Auswirkungen von Design-Abweichungen auf die statistische Güte quantifizieren zu können, bevor überhaupt eine Bewertung der Design-Alternativen erfolgen kann.

### 5.1.1 Methodik zur simulativen Ermittlung von Auswirkungen durch Orthogonalitätsabweichungen

Um die Auswirkungen von Design-Abweichungen auf die statistische Güte quantifizieren zu können, bedarf es einer kontrollierten Untersuchungsumgebung, in der - im Gegensatz zu physischen Experimenten - die **wahre** Natur des Systems bekannt ist. Durch den Vergleich von beiderseits Modellierungs- als auch Analyse-Ergebnissen mit einer vorab definierten Wahrheit (engl. *Ground Truth*) lassen sich Key Performance Indicators (KPIs) wie die Schätzpräzision und allen voran die *power* bestimmen. Zu diesem Zweck wird für die Untersuchungen eine allgemeingültige Simulationsumgebung geschaffen, die auf einem scheinbar-physikalischen Modell basiert [**Arndt.2023**, **Arndt.2022c**].

**Pseudo-physikalisches Simulationsmodell**

Das zugrundeliegende Systemverhalten im Sinne einer *Ground Truth* wird durch ein polynomiales Regressionsmodell zweiter Ordnung approximiert. Dies entspricht exakt der Struktur, die als Ergebnis einer RSM-Auswertung (vgl. Gleichung 2.27) erwartet wird und welche die Basis für die Lebensdauer- bzw. Zuverlässigkeitsmodellierung eines technischen Produktes bildet. Um die Anforderungen an eine multivariate Untersuchung ($k \geq 2$) zu erfüllen und die Komplexität handhabbar zu halten, wird im Basisszenario von zwei Faktoren ($x_1, x_2$) ausgegangen. Diese Begrenzung auf $k = 2$ Faktoren stellt zugleich eine bewusste, konservative *Worst-Case*-Betrachtung dar, da sich die negativen Auswirkungen einzelner geometrischer Störfälle mit zunehmender Dimensionalität des Versuchsplans signifikant verdünnen, weil die Informationsmatrix durch eine absolut höhere Anzahl intakter Stützpunkte robuster abgestützt wird [**Arndt.2022**]. Das Modell berücksichtigt neben den Haupteffekten explizit die für die Lebensdaueranalyse kritischen Wechselwirkungen ersten Grades sowie quadratische Terme zur Abbildung von Nichtlinearitäten:

$$y_{\text{sim}} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \tag{5.1}$$

Um ein realistisches, stochastisches Verhalten abzubilden, sind die Modellparameter nicht deterministisch fixiert. Den Regressionskoeffizienten $\beta_j$ werden zwar nominale Startwerte zugewiesen (vgl. Tabelle 5.1), diese werden jedoch in jedem Simulationslauf mit einer definierten Streuung überlagert. Zusätzlich wird die resultierende Systemantwort $y_{\text{sim}}$ mit einer Reststreuung $\epsilon$ beaufschlagt, um die inhärente **aleatorische Unsicherheit** des Systems (Messfehler, unbekannte Einflüsse) abzubilden. Mathematisch wird dies proportional durch normalverteilte Zufallsvariablen modelliert, sodass für den Fehlerterm sowie für die fluktuierenden Modellparameter um ihre nominalen Startwerte ($\beta_{j,\text{nom}}$) gilt:

$$\epsilon \sim \mathcal{N}(0, {\sigma_{\text{sim}}}^2) \quad \text{und} \quad \beta_j \sim \mathcal{N}(\beta_{j,\text{nom}}, {\sigma_{\text{sim}}}^2). \tag{5.2}$$

Die bewusste Wahl der Normalverteilung als zugrundeliegende Stochastik ist für diese isolierte Designuntersuchung methodisch zwingend und in einem ersten Schritt zweckdienlich: Sie entspricht der elementaren Grundannahme klassischer Regressionsmodelle (Gauß-Markow-Theorem) und stellt sicher, dass die nachfolgende

statistische Inferenz (Berechnung von $p$-Wert und CIs) im ungestörten Basis-Design ideal und erwartungstreu abläuft. So wird zweifelsfrei gewährleistet, dass später beobachtete Schätzfehler oder *power*-Verluste ausschließlich auf die induzierten geometrischen Orthogonalitätsabweichungen (Design-Penalties) zurückzuführen sind und nicht durch systematische, verteilungsbedingte Residuenfehler (wie beispielsweise durch Form- und Lageparameter der Weibull-Verteilung) verfälscht werden.

Die Default-Werte für die Koeffizienten sowie die vorgegebene Standardabweichung $\sigma_{\text{sim}}$, welche als Streuparameter für das stochastische Basis-Verhalten dient, sind in Tabelle 5.1 zusammengefasst.

Tabelle 5.1: Nominale Startwerte und Streuparameter des pseudo-physikalischen Simulationsmodells

| **Modellparameter** | **Default-Wert** |
|---|---|
| Regressionskonstante $\beta_0$ | 30 |
| Regressionskoeffizienten $\beta_j$ (für $j \in \{1, 2, 12, 11, 22\}$) | 10 |
| Standardabweichung der Systemantwort $\sigma_{\text{sim}}$ | 1 |

**Simulationsalgorithmus und Monte-Carlo-Ansatz**

Das Modell der *Ground Truth* wird zunächst mit den zu untersuchenden Versuchsplänen gekoppelt. Für jeden Stützpunkt des Versuchsplans (Versuchspunkte) werden die korrespondierenden Systemantworten simuliert. Anschließend erfolgt die Rückrechnung des Regressionsmodells mittels MLE, entsprechend der ausgeführten Methodik aus Abschnitt 2.1.4. Um statistisch belastbare Aussagen zu treffen und **epistemische Unsicherheiten** auf einen minimalen numerischen Approximationsfehler zu reduzieren, wird das Verfahren in eine MCS mit $n_{\text{MC}} = 1 \times 10^4$ Iterationen eingebettet - vergleiche Abschnitt 2.2.5 für entsprechende Hintergründe. Dieser Ansatz erlaubt die Bewertung zweier zentraler Kriterien:

1. **Präzision der Parameterschätzung:** Durch den (Mittelwert-) Vergleich der geschätzten Parameter $\hat{\boldsymbol{\beta}}$ mit den *wahren* Koeffizienten $\boldsymbol{\beta}_{\text{true}}$ lassen sich systematischer Schätzfehler (**Bias**) und Varianz (**MSE**) der Schätzung ermitteln.

2. **Bestimmung der Trennschärfe** *power***:** Für jeden Simulationslauf wird geprüft, ob die signifikanten Effekte korrekt erkannt wurden ($p$-Wert $< \alpha$). Das Verhält-

nis der Treffer zur Gesamtzahl der Simulationen ergibt die empirische *power* (vgl. Gleichung 2.57).

### 5.1.2 Sensitivitätsanalyse geometrischer und stochastischer Einflussgrößen

Um zunächst die Robustheit des methodischen Ansatzes gegenüber den eingangs erwähnten Einflussgrößen zu bewerten, wird eine Sensitivitätsanalyse durchgeführt, welche methodische einem **DoE on Experimental Design**-Ansatz folgt: Die Eigenschaften des Versuchsplans sowie die der *Ground Truth* werden als Faktoren eines übergeordneten Meta-Designs derart variiert, sodass deren Einfluss auf die Effektivität der Schätzung und damit insbesondere die Trennschärfe der Effekte im GLM quantifiziert werden kann [**Arndt.2023**]. Infrage kommt dabei eine aus praktischer Überlegung erfasste Auswahl an sowohl geometrische Manipulationen als auch stochastische Einflüsse sowie methodische Parameter und deren Interaktionen:

1. Manipulation von SPsn über deren axialen Abstand;
2. Manipulation von SPsn durch co-faktorielle Korrelation;
3. Variation der Anzahl der ZPs;
4. Variation der Anzahl der SPs;
5. Variation der Standardabweichung der Effektstärken (System-Rauschen, auch SNR);
6. Änderung des relativen Verhältnisses von Effektstärken untereinander;
7. Variation der Standardabweichung der Systemantwort (Mess-Rauschen);
8. Variation des Signifikanzniveaus.

Insbesondere die Berücksichtigung der Verhältnismäßigkeit von Effektstärken sowie der Rauschparameter ist von zentraler Bedeutung, da sie die SNR im Modell direkt beeinflussen und damit die Detektionswahrscheinlichkeit der Effekte maßgeblich steuern, gleichzeitig aber eine gegen unendlich tendierende Variationsmöglichkeit bieten, die in einem reinen Screening-Ansatz nicht abgedeckt werden könnte. Zur formalen Beschreibung des Untersuchungsraums werden diese acht Einflussgrößen im Vektor $\boldsymbol{\xi} = [\xi_a, \ldots, \xi_h]^\top$ zusammengefasst und in Tabelle 5.2 definiert. Die Integration dieser Faktoren in das Meta-Design erfolgt dabei methodisch differenziert: Während die kontinuierlichen Stör- und Geometrieparameter ($\xi_a, \xi_b, \xi_e, \xi_f, \xi_g, \xi_h$)

den Versuchsraum eines CCD aufspannen, um stetige Sensitivitäten (Regressionskoeffizienten) zu schätzen, werden die strukturellen Designgrößen der Stützstellenanzahl ($\xi_c$, $\xi_d$) als kategoriale Blockfaktoren über drei diskrete Stufen behandelt. Diese Trennung ist zwingend geboten, da Variationen in der Stützstellenanzahl die topologische Struktur der Design-Matrix $\mathbf{X}$ und deren Freiheitsgrade diskontinuierlich verändern. Ein rein kontinuierliches Meta-Modell würde hier zu unzulässigen Interpolationen über strukturelle Singularitäten hinweg führen - beispielsweise beim vollständigen Verlust der Schätzbarkeit quadratischer Terme bei extremer Ausdünnung. Folglich werden die kontinuierlichen Sensitivitäten der Rauschparameter stets *innerhalb* konsistenter topologischer Design-Strukturen ermittelt, während der Haupteffekt der Stützstellenreduktion separat über die diskreten Mittelwertverschiebungen (Level-Shifts) der *power* zwischen den Blöcken quantifiziert wird. Weiter erfüllt der DoE-Ansatz mittels CCD den Anspruch, für die Sensitivitätsanalyse eine effiziente und notwendige statistische Inferenz und Kausalität zu identifizieren, wohingegen alternative Ansätze wie die reine Korrelationsanalyse, *Space-Filling Designs* (wie *Latin Hypercube Sampling* oder *Sobol*-Sequenzen) oder die Anwendung von Machine Learning (ML)-Modellen zur Schätzung von Sensitivitäten darüber hinaus Assoziationen für explorative Prädiktionen liefern würden [**Zio.2013**, **Kleppmann.2020**].

Etwaige Ergänzungen wie die Variation der Anzahl der Faktoren, die Manipulation der faktoriellen Versuchspunkte oder die Einführung von Lebensdauermodellen werden dabei bewusst ausgeschlossen, um die Komplexität des Meta-Designs handhabbar zu halten und die Interpretation der Ergebnisse durch eine pragmatische Auswahl und im Fokus der in Kapitel 3 postulierten Zielsetzung zu erleichtern.

So werden schließlich Haupteffekte, Interaktionen sowie quadratische Effekte auf die Trennschärfe als wesentlicher Performance-KPI und damit Metrik zur Effektivität ermittelt.

### 5.1.3 Ergebnisse der Sensitivitätsanalyse und Quantifizierung der Trennschärfe

Die simulative Untersuchung der Trennschärfe (*power*) über den durch $\boldsymbol{\xi}$ definierten Untersuchungsraum offenbart eine signifikante Dichotomie der Einflussgrößen. Es muss zwischen **dispositiven Designfaktoren** (Geometrie $\xi_a$, Stützstellen $\xi_c$, $\xi_d$), die vom Versuchsplaner aktiv modifiziert werden können, und **externen Restriktio-**

Tabelle 5.2: Definition und Parametrisierung der Untersuchungsfaktoren für die Sensitivitätsanalyse

| | Beschreibung | Wertebereich | Charakteristik |
|---|---|---|---|
| $\xi_a$ | **SP-Abstand** ($\alpha_D$)<br>Variation des Abstands der SPs zum Zentrum (z.B. flächenzentriert, rotierbar und extendiert). | $[1,00;\ 2 \cdot \alpha_D]$ | Kont. (CCD) |
| $\xi_b$ | **SP-Shift**<br>Asymmetrische / Co-Faktorielle Verschiebung eines SPs zur Simulation geometrischer Verzerrungen und Faktoren-Korrelation. | $[0,10;\ \alpha_D]$ | Kont. (CCD) |
| $\xi_c$ | **ZPs** ($n_C$)<br>Variation der Anzahl der ZPs $n_C > 0$. | $[1,00;\ 8,00]$ | Diskret (Faktoriell) |
| $\xi_d$ | **SPs** ($n_S$)<br>Variation durch Entfall von maximal 50 % der SPs (z.B. durch Zensierung oder Funktionalitätsverlust). | $[2,00;\ 4,00]$ | Diskret (Faktoriell) |
| $\xi_e$ | **System-Rauschen** (SNR)<br>Verhältnis zwischen pseudo-physikalischem Modellkoeffizienten und Systemabweichung bzw. Effektstreuung $\beta_i/\sigma$. | $[0,80;\ 1,20]$ | Kont. (CCD) |
| $\xi_f$ | **Effekt-Verhältnis** ($\beta_1/\beta_2$)<br>Verhältnis zweier Haupteffekte zueinander: zwischen gleichwertiger Effektstärke oder einem Anteil von 10 %. | $[0,10;\ 1,00]$ | Kont. (CCD) |
| $\xi_g$ | **Mess-Rauschen** ($\epsilon$)<br>Verhältnis zwischen den Modellkoeffizienten und dem Wert des Streuparameters der Systemantwort. | $[0,80;\ 1,20]$ | Kont. (CCD) |
| $\xi_h$ | **Signifikanzniveau** ($\alpha$)<br>Das gewählte Signifikanzniveau. | $[0,02;\ 0,08]$ | Kont. (CCD) |

**nen** (Rauschen $\xi_e$, $\xi_g$, Signifikanzniveau $\xi_h$), die durch das physikalische Testsystem oder normative Vorgaben als unveränderlich zu betrachten sind, unterschieden werden.

Tabelle 5.3 zeigt dazu entsprechende Ergebnisse der Sensitivitätsanalyse aus Abschnitt 5.1.2 in Form von Mittelwerten, Wertebereichen sowie den dominanten Einflussfaktoren für die Trennschärfe der einzelnen Modellparameter. Die Werte wurden durch eine ANOVA des Meta-Designs ermittelt, wobei die Effektstärke $E$ als Maß für die Dominanz eines Faktors auf die Trennschärfe herangezogen wird, sofern dieser als signifikant identifiziert und der im Model geschätzte Zusammenhang der Daten entsprechend erfolgreich auf Plausibilität (Residuenanalyse, Bestimmtheitsmaß, etc.) geprüft wurde. Tabelle 5.3 bildet dabei eine zusammenfassende Übersicht über die Ergebnisse, wobei weiterführende Details zu den einzelnen Effekten und deren Interaktionen in Anhang **??** zu finden sind.

Betrachtet man zunächst die globale **Modell-Power** ($power_M$), so zeigt sich eine extrem hohe Robustheit gegenüber allen Variationen mit einem Mittelwert von $\overline{power} > 99,7\,\%$. Diese pauschale Metrik verdeckt jedoch, dass das Verhalten spezifischer Einzel-Effekte - insbesondere die Identifikation der für die Lebensdauerprognose kritischen quadratischen Terme - deutlich sensitiver ausfällt. Wie Tabelle 5.3 zeigt, liegt die mittlere Trennschärfe für quadratische Terme ($power_{\beta_{11}}$, $power_{\beta_{22}}$) nur noch im Bereich von 70 % bis 79 %.

Die entscheidende Erkenntnis liefert jedoch der Blick auf die **Sensitivitäts-Indizes** (Spalte „Dominante Sensitivität“). Für die Mehrheit der untersuchten Koeffizienten ($power_M$, $power_{\beta_1}$, $power_{\beta_{12}}$, $power_{\beta_{11}}$) ist nicht etwa eine Reduktion der Versuchspunkte der limitierende Faktor, sondern das **Messrauschen** ($\xi_g$). Mit einem Sensitivitätsindex von bis zu $E = 1,99$ (bei $power_{\beta_{11}}$) dominiert die Güte der Messtechnik die Erfolgswahrscheinlichkeit des Tests. Da das Rauschen ($\xi_g$, $\xi_e$) sowie das Signifikanzniveau ($\xi_h$) in der praktischen Anwendung bei EoL-Tests an bestehenden Prüfständen meist feste Randbedingungen darstellen, definieren sie eine natürliche Obergrenze der erreichbaren Trennschärfe, die auch durch maximale Versuchspläne nicht durchbrochen werden kann.

Dies birgt ein erhebliches ökonomisches Potenzial: Wenn die Trennschärfe ohnehin primär durch das System- und Messrauschen limitiert wird, ist zu prüfen, ob Design-Vereinfachungen (Reduktion von $\xi_c$ und $\xi_d$) überhaupt zu einer *signifikanten* Effektivitätsreduktion führen. Tabelle 5.4 quantifiziert diesen „*Design-Penalty*“:

Tabelle 5.3: Zusammenfassende Statistik der Trennschärfe und Identifikation der dominanten Einflussfaktoren. Die Ergebnisse demonstrieren, dass die Power maßgeblich durch unveränderliche Systemgrößen (Rauschen) und nur im Ausnahmefall durch modifizierbare Designgrößen limitiert wird.

| **Koeffizient** | **Mittelwert** | **Wertebereich** | **Dominante Sensitivität** | |
|---|---|---|---|---|
| | $\overline{power}$ | [min; max] % | **Einflussfaktor** $\xi_i$ **(Kategorie)** | $E$ |
| | | *Globale Modellgüte:* | | |
| $power_{\mathrm{M}}$ | 99,7 % | [94,5; 100,0] | $\xi_{\mathrm{g}}$ (System) | 0,10 |
| | | *Spezifische Modelleffekte:* | | |
| $power_{\beta_0}$ | 97,9 % | [76,9; 100,0] | $\xi_{\mathrm{e}}$ (System) | 0,52 |
| $power_{\beta_1}$ | 78,6 % | [60,0; 90,8] | $\xi_{\mathrm{g}}$ (System) | 1,50 |
| $power_{\beta_2}$ | 66,0 % | [37,3; 84,1] | $\xi_{\mathrm{f}}$ (System) | 2,53 |
| $power_{\beta_{12}}$ | 72,6 % | [52,5; 85,9] | $\xi_{\mathrm{g}}$ (System) | 1,93 |
| $power_{\beta_{11}}$ | 70,9 % | [32,6; 86,8] | $\xi_{\mathrm{g}}$ (System) | 1,99 |
| $power_{\beta_{22}}$ | 79,3 % | [33,4; 100,0] | $\xi_{\mathrm{a}}$ **(Design)** | 3,72 |

$E$: Absoluter Effekt des Faktors auf die Power (aus ANOVA zum Meta-Design).

Es zeigt sich, dass der Verzicht auf ZPs ($\xi_c$) und SPs ($\xi_d$) zwar die Trennschärfe reduziert (z.B. $\Delta power \approx -13\,\%$ für $power_{\beta_{11}}$), dieser Einfluss jedoch in der gleichen Größenordnung liegt wie die unvermeidbaren Rauscheffekte (*Noise*).

Tabelle 5.4: Systematischer Trennschärfe-Verlust ($\Delta power$) bei Reduktion der Versuchsstützpunkte. Während lineare Haupteffekte relativ robust gegenüber einer Design-Ausdünnung bleiben, zeigt sich der primäre *Design-Penalty* in der Schätzung der quadratischen Terme.

| **Koeffizient** | **Durchschnittlicher Trennschärfe-Verlust** ($\Delta power$) | |
|---|---|---|
| | **bei** $\xi_c$ ($n_C = 8 \rightarrow 1$) | **bei** $\xi_d$ ($n_S = 4 \rightarrow 2$) |
| | *Konstante, Haupt- und Interaktionseffekte* | |
| $power_{\beta_0}$ | $-4,5\,\%$ | $-0,3\,\%$ |
| $power_{\beta_1}$ | $-2,4\,\%$ | $-6,0\,\%$ |
| $power_{\beta_2}$ | $+1,1\,\%$* | $-8,0\,\%$ |
| $power_{\beta_{12}}$ | $-1,2\,\%$ | $-0,9\,\%$ |
| | *Quadratische Effekte* | |
| $power_{\beta_{11}}$ | $-13,9\,\%$ | $-12,8\,\%$ |
| $power_{\beta_{22}}$ | n. a.** | $-6,1\,\%$ |

* Positiver Wert resultiert aus Varianzverschiebungen bei instabilen Designs.

** Nicht auswertbar, da Singularität in quadratischem Term bei $n_C$.

Einzig der quadratische Koeffizient $power_{\beta_{22}}$ bildet eine Ausnahme: Hier ist der geometrische Abstand der SPs ($\xi_a$) mit einem extremen Index von 3,72 der dominierende Faktor (vgl. Tabelle 5.3). Für alle anderen Terme gilt: Da die *power* durch die physikalischen Randbedingungen ($\xi_e, \xi_g$) maßgeblich vorbestimmt ist, besteht Spielraum zur Anpassung der Faktoren $\xi_c$ und $\xi_d$ in Bereiche, die aus Aspekten der Versuchszeit und des Budgets attraktiv sein können - ohne die Effektivität des Tests unverhältnismäßig stärker zu kompromittieren, als es das Messsystem ohnehin schon tut.

### 5.1.4 Generische Auswirkungen relevanter Orthogonalitätsabweichungen

Die Ergebnisse der vorangegangenen Sensitivitätsanalyse (siehe Abschnitt 5.1.3) haben gezeigt, dass das CCD im Hinblick auf die statistische Trennschärfe ein robustes Verhalten gegenüber Modifikationen seiner Stützstellenanzahl aufweist, da im Regelfall das experimentelle System- und Messrauschen den limitierenden Faktor der Effektivität darstellt - vgl. Tabellen 5.3 und 5.4 sowie Abschnitt 2.2.3. Für die praktische EoL-Versuchsplanung greift dieser generalisierte, kombinatorische Ansatz jedoch noch zu kurz. In der Realität am Prüfstand treten Abweichungen von der idealen Design-Matrix technisch bedingt oft nicht als geplante, systematische Ausdünnung auf, sondern als unvorhergesehene, asymmetrische und isolierte Einzelphänomene, erzwungen durch physikalische oder normative Restriktionen [**Arndt.2022**, **Mell.2022**, **Box.1963**, **Ahn.2015**]. Gleichzeitig eröffnet das Bewusstsein über die erstaunlich geringen *Design-Penalties* aus Abschnitt 5.1.3 die Chance für eine gezielte adaptive Planung: Wenn Design-Modifikationen die Effektivität des Nachweises ohnehin nur moderat beeinträchtigen, ist zu prüfen, inwiefern geometrische Manipulationen zur Kostenoptimierung, Prüfzeitverkürzung oder zur Vermeidung irrelevanter Ausfallmechanismen nicht sogar bewusst (*on purpose*) induziert werden sollten.

Um diese singulären Praxisphänomene systematisch bewerten zu können, ist die kombinatorische Betrachtung des Meta-Designs aus dem vorherigen Abschnitt nicht mehr zielführend. Zwar ist der Parameterraum an denkbaren geometrischen Abweichungen und deren Kombinationen in der Realität nahezu unendlich und hochgradig abhängig von produktspezifischen, technologischen sowie modellspezifischen Randbedingungen. Ein allgemeingültiger, analytischer oder erschöpfend numerischer Beweis für sämtliche Permutationen ist folglich weder möglich noch methodisch erstrebenswert. Der wissenschaftliche Anspruch an dieser Stelle liegt vielmehr darin, anhand isolierter, archetypischer Störfälle die fundamentalen Wirkmechanismen zwischen den objektiven Design-Metriken (Optimalitäten) und der resultierenden Trennschärfe aufzudecken. Aus dem Verständnis dieser kausalen Zusammenhänge lassen sich schließlich generalisierbare, methodische Anreize für die *Entwicklung effizienter multivariater Lebensdauerversuche* ableiten. Dementsprechend werden basierend auf der Simulationsmethodik aus Abschnitt 5.1.1 vier spezifische,

voneinander isolierte Störszenarien definiert, welche typische Einzelrestriktionen in multivariaten Lebensdauerversuchen abbilden [**Arndt.2022**, **Mell.2022**]:

- **Fall I (Axialer Shift):** SPs ($n_S \geq 1$) können aufgrund von Anlagenrestriktionen nicht auf dem nominellen Abstand $\alpha_D$ gefahren werden oder würden einen durch ALT induzierten Wechsel des Ausfallmechanismus provozieren. Zur methodischen Einordnung wird dieser Fall in drei Stufen simuliert: eine axiale Stauchung auf 80 %, eine Streckung auf 120 % sowie der Rückzug auf die Nennlasten des rein faktoriellen Würfels (*Face Centered (FC)*, $\alpha_D = 1$).

- **Fall II (Co-faktorielle Korrelation):** Ein SP ist nicht mehr achsenrein isoliert realisierbar. Spezifische, physikalische Systemfunktionalitäten (beispielsweise kombinierte Einflüsse auf das System durch Faktoren wie die Temperatur zusammen mit einer mechanischen Kraft) könnten die simultane (parasitäre) Aussteuerung eines zweiten Faktors erzwingen, wodurch eine direkte aber asymmetrische geometrische Korrelation im ansonsten orthogonalen Raum entsteht. Dieser Fall wird in einer leichten und einer starken Ausprägung untersucht, indem der Sternpunkt der $x_1$-Achse durch einen parasitären Stellgrößenanteil von $x_2 = 0{,}1$ sowie $x_2 = 1{,}0$ überlagert wird.

- **Fall III (Stellgrößen-Scatter):** Die Aktorik des Prüfstands erlaubt keine exakte Ansteuerung der Zielkoordinaten, sodass die SPs einer unbeabsichtigten stochastischen Streuung (uniformes Rauschen von $\pm 10$ % auf der Eingangsvariablen $x_i$) unterliegen.

- **Fall IV (Früh-Ausfall / Zensierung):** Ein Versuchspunkt führt zu einem Frühausfall (ggf. konkurrierender Schadensmechanismus), einem irrelevanten Durchläufer oder kann aus Zeitgründen nicht abgeschlossen werden. Er entfällt somit vollständig aus der finalen Design-Matrix. Da die topologische Bedeutung der Punkte stark variiert, wird dieses Szenario zur methodischen Differenzierung in zwei Unterkategorien gespalten:
  - **Fall IV: ZP**: Eliminierung eines der geometrisch redundanten ZPs.
  - **Fall IV: SP**: Asymmetrische Eliminierung eines extremen SP - hier simuliert am nördlichen SP auf der Achse von Faktor $x_1$.

Daraus ergeben sich mit Berücksichtigung einer unveränderten, orthogonalen Planmatrix in einem *Default CCD* insgesamt **neun** Szenarien, welche die Auswirkungen der jeweiligen Praxisrestriktion auf die Trennschärfe der Effekte isoliert quantifizieren und vergleichbar machen. Während auch bei dieser isolierten Betrachtung der Erhalt der Trennschärfe (*power*) die übergeordnete Rolle spielt, rückt hier zusätzlich die Schätzgüte der Modellparameter in den Fokus. Es gilt zu quantifizieren, inwiefern der Verlust der Orthogonalität - messbar über den globalen $A_2$-Indikator - zu Multikollinearität und folglich zu einer schädlichen Varianzinflation (VIF beziehungsweise MSE) oder gar zu systematischen Verzerrungen der Koeffizientenschätzung (*Bias*) führt - vgl. Abschnitt 2.2.5. Die analytische Differenzierung dieser Fehlerarten ist von entscheidender Bedeutung, da insbesondere ein signifikanter Bias die Validität der gesamten Lebensdauerprognose unbemerkt kompromittieren würde, während eine reine Varianzinflation primär die Konfidenzintervalle aufweitet.

### Kalibrierung der Signal-to-Noise Ratio und analytische Justierung des Arbeitspunkts

Wie in der vorangegangenen Sensitivitätsanalyse (vgl. Abschnitt 5.1.3) dargelegt, konvergiert die Trennschärfe bei dominierenden physikalischen Effekten (hohes SNR $\gg 1$) in einen Sättigungsbereich nahe 100 %. Anmerkung zu Sensitivanalyse 0,8-1,2 Unter solchen Idealbedingungen ist das Regressionsmodell derart robust, dass selbst signifikante geometrische Verzerrungen des Versuchsplans den Nachweis eines Effekts $E$ kaum gefährden. In der Praxis der Lebensdauerprognose stellen diese dominanten Einflussgrößen jedoch selten die primäre Herausforderung dar. Vielmehr gilt es, subtile Effekte und schwache Degradationserscheinungen zu identifizieren, die sich nur knapp vom Systemrauschen abheben.

Um den isolierten Einfluss von Orthogonalitätsabweichungen - den spezifischen *Design-Penalty* - überhaupt quantifizierbar zu machen, muss die nachfolgende Simulation daher in einen kritischen Arbeitsbereich überführt werden. Hierfür wird das *Ground-Truth*-Modell gezielt kalibriert: Die Koeffizientenstärken der untersuchten Effekte werden auf $\beta_i = 10$ fixiert und mit einer erhöhten Standardabweichung der Systemantwort von $\sigma = 7{,}5$ beaufschlagt. Dies entspricht einem moderaten Signal-Rausch-Verhältnis von SNR $\approx 1{,}33$.

Diese Parametrisierung macht sich die mathematische Gesetzmäßigkeit zunutze, dass die Trennschärfe-Funktion - basierend auf den Nichtzentralitätsparametern $\delta_{\text{nc}}$ der zugrundeliegenden Prüfverteilungen - einen S-förmigen (sigmoidalen) Verlauf aufweist [**Cohen.1988**, **Montgomery.2020**]. Während die Kurve am unteren Rand für ein SNR $\approx 0$ gegen das gewählte Signifikanzniveau $\alpha$ (Erwartungswert des Fehlers 1. Art) und am oberen Rand asymptotisch gegen $power = 100\,\%$ strebt, besitzt sie in der Übergangszone ihre steilste Flanke. Die definierte Kalibrierung zwingt das ideale, orthogonale Referenz-Design exakt auf diesen Wendepunkt maximaler Sensitivität, in dem die Basis-Trennschärfe für die betrachteten Modelleffekte bei rund $power = 88\,\%$ liegt.

Dieser künstliche Arbeitspunkt fungiert folglich als analytische Lupe: Er eliminiert jeglichen Sättigungseffekt und stellt sicher, dass die infolge von Orthogonalitäts-Verlust und Multikollinearität auftretende Varianzinflation (VIF) unmittelbar als messbarer Trennschärfe-Verlust $\Delta power$ sichtbar wird. Um hierbei rein stochastische Schwankungen zwischen den verschiedenen Design-Szenarien auszuschließen und eine strikte **Reproduzierbarkeit** der Ergebnisse zu garantieren, wird der Monte-Carlo-Algorithmus deterministisch initialisiert (*Mersenne-Twister*-Generator mit *Seed*-Fixierung) [**Zio.2013**]. Nur durch dieses methodische Setup lässt sich valide bewerten, ab welchem Grad eine hypothetische Praxisrestriktion am Prüfstand bzw. generelle Orthogonalitätsabweichung gemäß *Fall I-IV* die statistische Integrität der Effekt-Identifikation real gefährdet.

### Quantitative Auswertung und explorative Optimalitäts-Analyse

Die Auswertung der definierten Praxis-Szenarien bei einem kritischen Signal-Rausch-Verhältnis (SNR $= 1{,}33$) offenbart eine differenzierte Reaktion der klassischen Design-Metriken (Tabelle 5.5) und der algorithmischen Schätzgüte. Zur detaillierten Evaluation wird diese Schätzgüte nachfolgend nach der kombinierten Schätzvarianz (*VIF* in Tabelle 5.5 bzw. *MSE* in Tabelle **??** und Abbildung 5.1), dem systematischen Schätzfehler (*Bias* in Tabelle 5.6) sowie dem resultierenden Trennschärfe-Verlust ($\Delta power$ in Tabelle 5.7) aufgeschlüsselt.

Ein erster Blick auf die topologischen und informationsbasierten Metriken aus Tabelle 5.5 offenbart physikalisch wie geometrisch plausible Muster:

- **Volumeneffekte und Prädiktionsgüte:** Kriterien wie die *I*- und *D-Effizienz* skalieren direkt mit der absoluten Ausdehnung des Versuchsraums. So erzielt der nach außen gestreckte Shift (*Fall I*, +20 %) Bestwerte in der integrierten Prädiktionsvarianz ($I_{\text{eff}} = 85{,}1\,\%$). Demgegenüber provozieren ungeplante Ausfälle naturgemäß einen Modellierungsverlust. Bemerkenswert ist hierbei jedoch die geometrische Sensitivität: Während der Ausfall eines redundant platzierten Zentralpunktes (*Fall IV: ZP*) die globale Prädiktionsgüte nur marginal dämpft ($I_{\text{eff}}$ sinkt von 81,2 % auf 79,8 %), provoziert der asymmetrische Entfall eines randlichen Sternpunktes (*Fall IV: SP*) den einschlägigsten Kollaps, was eine Reduktion der $I_{\text{eff}}$ auf 69,0 % erklärt.

- **Topologische Warnsignale und blinde Flecken:** Eine *starke Korrelation* (*Fall II*) erzeugt einen statistischen blinden Fleck. Obwohl das globale Design-Volumen nur marginal zunimmt ($D_{\text{eff}} = 50{,}0\,\% \rightarrow 51{,}3\,\%$), schießt der $A_2$-Indikator als Maß für die Nicht-Orthogonalität auf seinen Spitzenwert von 0,352. Die durch die parasitäre Abhängigkeit entstehenden Lücken im Parameterraum bestraft die an *Worst-Case*-Szenarien orientierte *G-Effizienz* mit einem drastischen Einbruch auf 13,9 %. Während die globale Modellsignifikanz ($F$-Test, ANOVA) über alle Szenarien hinweg stabil bei $\approx 100\,\%$ verbleibt (daher nicht in Tabelle 5.5 aufgeführt), entlädt sich der Informationsverlust ausschließlich term-spezifisch in der Identifikationsgüte einzelner Parameter.

- **Geometrische Selektivität der Varianzinflation:** Der VIF bildet den Orthogonalitätsverlust nicht global, sondern hochgradig term-spezifisch ab. Während der stochastische Scatter (*Fall III*) sowie der symmetrieneutrale Ausfall des Zentralpunktes (*Fall IV: ZP*) das VIF exakt bei 1,00 stagnieren lassen, schlägt sich eine starke Korrelation (*Fall II*) primär auf den Interaktionsterm nieder ($VIF_{\beta_{12}} = 1{,}23$). Beim asymmetrischen Sternpunkt-Ausfall (*Fall IV: SP*) greift die Mathematik der isolierten Achsen: Da der zensierte SP auf der $x_1$-Achse liegt, leiden ausschließlich der zugehörige Haupteffekt $\hat{\beta}_1$ sowie die Krümmung $\hat{\beta}_{11}$ (jeweils $VIF = 1{,}22$). Die orthogonal stehende $x_2$-Achse bleibt davon vollkommen isoliert und unbeschadet ($VIF_{\beta_2,\beta_{22}} = 1{,}00$). Global bemisst sich der VIF stets $< 5$, was die allgemeine Stabilität der Schätzung bestätigt, jedoch die term-spezifische Varianzinflation und damit die potenzielle Trennschärfe-Reduktion deutlich macht, vgl. Abschnitt 2.2.5.

Tabelle 5.5: Matrix-Eigenschaften und Effizienzen zu Optimalitätskriterien der simulierten Störszenarien. Der VIF wird für alle Haupt- und quadratischen Terme dargestellt ($\hat{\beta}_0$ entfällt theoriekonform).

| **Szenario (Störfall)** | $A_2$ | **Effizienzen [%]** | | | | | **VIF** | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| | | $A_{\text{eff}}$ | $D_{\text{eff}}$ | $G_{\text{eff}}$ | $I_{\text{eff}}$ | $V_{\text{eff}}$ | $\hat{\beta}_1$ | $\hat{\beta}_2$ | $\hat{\beta}_{12}$ | $\hat{\beta}_{11}$ | $\hat{\beta}_{22}$ |
| Referenz (Orthogonal) | 0,000 | 42,9 | 50,0 | 17,6 | 81,2 | 180,0 | 1,00 | 1,00 | 1,00 | 1,00 | 1,00 |
| Fall I: Shift (-20 %) | 0,037 | 40,3 | 47,0 | 15,9 | 76,0 | 181,7 | 1,04 | 1,00 | 1,00 | 1,04 | 1,00 |
| Fall I: Shift (+20 %) | 0,038 | 45,0 | 53,6 | 17,7 | 85,1 | 181,0 | 1,04 | 1,00 | 1,00 | 1,04 | 1,00 |
| Fall I: FC | 0,071 | 39,1 | 45,9 | 15,2 | 73,5 | 184,0 | 1,07 | 1,00 | 1,00 | 1,08 | 1,01 |
| Fall II: Korrelation (leicht) | 0,004 | 42,9 | 50,0 | 17,0 | 81,2 | 180,0 | 1,00 | 1,00 | 1,00 | 1,00 | 1,00 |
| Fall II: Korrelation (stark) | 0,352 | 42,5 | 51,3 | 13,9 | 80,3 | 183,5 | 1,16 | 1,07 | 1,23 | 1,18 | 1,07 |
| Fall III: Scatter (±10 %) | 0,007 | 43,8 | 51,5 | 16,6 | 83,0 | 180,2 | 1,00 | 1,00 | 1,00 | 1,00 | 1,00 |
| Fall IV: SP | 0,183 | 37,6 | 45,3 | 14,3 | 69,0 | 197,2 | 1,22 | 1,00 | 1,00 | 1,22 | 1,05 |
| Fall IV: ZP | 0,001 | 44,4 | 52,2 | 18,7 | 85,7 | 164,8 | 1,00 | 1,00 | 1,00 | 1,00 | 1,00 |

Der VIF schlägt die direkte Brücke zur absoluten Schätzvarianz, welche in Abbildung 5.1 über den MSE quantifiziert wird. Die Visualisierung zeigt das absolute, skalierte Ausmaß der Prognoseunsicherheit im Modell. Dabei fällt auf, dass der Wechselwirkungsterm $\hat{\beta}_{12}$ bereits im orthogonalen Basisdesign (Default CCD) eine strukturell extrem hohe Schätzvarianz aufweist ($MSE \approx 13{,}89$). Dies ist eine **topologische Eigenheit des CCD**: Da die SPs strikt auf den Koordinatenachsen liegen (wobei jeweils der andere Faktor exakt Null ist), tragen sie systembedingt keinerlei Information zur Schätzung der Interaktion $x_1 x_2$ bei. Diese stützt sich ausschließlich auf den faktoriellen Kern des Designs.

Die tatsächlichen, störungsinduzierten Ausreißer manifestieren sich jedoch exakt an den durch den VIF prognostizierten Schwachstellen der Designmatrix. Hierbei offenbart der direkte Vergleich der Ausfall-Szenarien ein für die Praxis essenzielles Bild: Während die Zensierung des Zentralpunktes (*Fall IV: ZP*) mangels Varianzerhöhung quasi unbemerkt verpufft (der MSE steigt bei $\hat{\beta}_{11}$ lediglich von 7,04 auf 7,40), treibt der asymmetrische Freiheitsgradverlust des Sternpunktes in *Fall IV: SP* den MSE für die betroffenen Terme $\hat{\beta}_1$ und $\hat{\beta}_{11}$ auf massive 11,91 respektive 12,29. Dies entspricht einem drastischen Anstieg der Schätzvarianz um über 70 % gegenüber dem fehlerfreien Referenz-Design ($MSE \approx 6{,}97$). Analog korrespondiert die starke Korrelation aus *Fall II* mit spürbaren Varianzaufweitungen bei $\hat{\beta}_1$ und $\hat{\beta}_{11}$ (auf

$MSE > 8{,}0$), was die extreme Sensitivität der OLS-Schätzung gegenüber parasitären geometrischen Abhängigkeiten visuell greifbar macht.

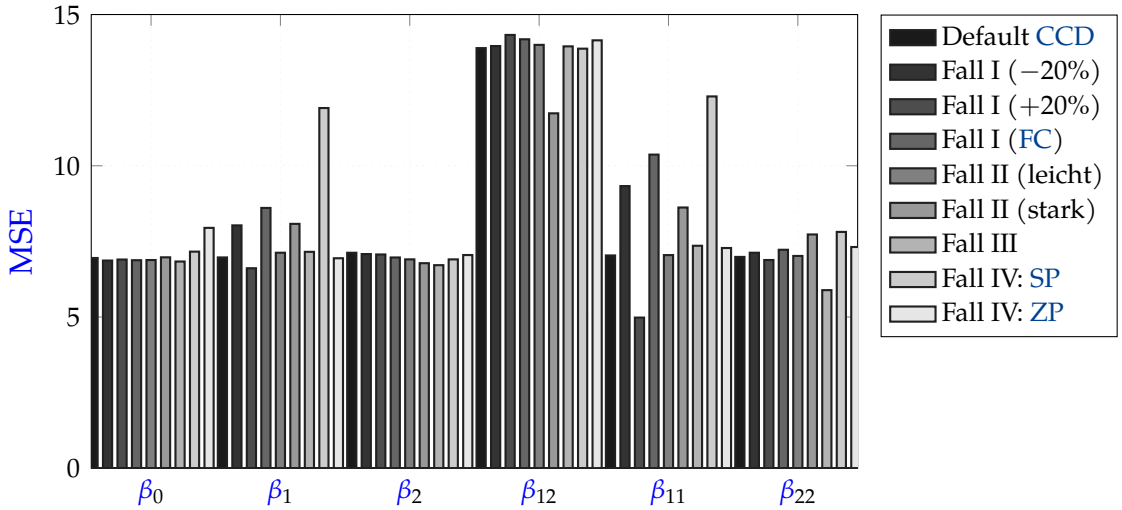


Abbildung 5.1: Güte der Schätzer (MSE). Geometrische Verzerrungen entladen sich primär in der Schätzvarianz, insbesondere beim Wegfall von Freiheitsgraden durch asymmetrische Ausfälle (***Fall IV: SP***).

Andererseits belegt die Auswertung die fundamentale Erwartungstreue des angewandten OLS-Schätzers: Trotz gravierender struktureller Abweichungen im Versuchsraum verharrt der systematische Schätzfehler (Bias) für alle Szenarien und über alle Koeffizienten hinweg zum gewählten SNR Arbeitspunkt im marginalen Promillebereich (Tabelle 5.6). Die Schätzungen der Modellkoeffizienten bleiben im Mittel folglich korrekt. Eine geometrische Verzerrung im CCD führt demnach nicht zwangsläufig zu einer inhärent falschen, verschobenen Effekterkennung, vgl. Abbildung 5.2.

Die hinreichende Dimensionierung von $n_{\mathrm{MC}} = 1 \times 10^4$ Simulationsläufen zur Eliminierung des stochastischen Approximationsrauschens und zur Gewährleistung einer strikt reproduzierbaren Konvergenz gegen diese wahren Parameter wird dabei exemplarisch für den im Störfall unbeschadeten, orthogonal isolierten Koeffizienten $\hat{\beta}_2$ in Abbildung 5.3 visuell belegt (die stark streuenden Konvergenzplots der gestörten Koeffizienten $\hat{\beta}_1$ und $\hat{\beta}_{11}$ finden sich im Anhang **??**).

Der resultierende **Einfluss auf die Trennschärfe** - in Tabelle 5.7 quantifiziert und in Abbildung 5.4 detailliert veranschaulicht - verhält sich in der Konsequenz wie folgt:

Tabelle 5.6: Simulationsergebnisse: Relativer systematischer Schätzfehler (Bias) der einzelnen Koeffizienten in Prozent bezogen auf ihren Nominalwert bei SNR = 1,33.

| **Szenario (Störfall)** | $\hat{\beta}_0$ | $\hat{\beta}_1$ | $\hat{\beta}_2$ | $\hat{\beta}_{12}$ | $\hat{\beta}_{11}$ | $\hat{\beta}_{22}$ |
|---|---|---|---|---|---|---|
| Referenz (Orthogonal) | +0,05 % | −0,02 % | −0,10 % | +0,41 % | −0,15 % | −0,05 % |
| Fall I: Shift (-20 %) | +0,05 % | −0,00 % | −0,17 % | +0,05 % | +0,02 % | −0,28 % |
| Fall I: Shift (+20 %) | +0,02 % | −0,19 % | +0,08 % | +0,22 % | −0,07 % | +0,00 % |
| Fall I: FC | +0,10 % | +0,23 % | −0,04 % | +0,22 % | −0,12 % | +0,11 % |
| Fall II: Korrelation (leicht) | −0,09 % | +0,23 % | +0,15 % | +0,17 % | +0,03 % | +0,21 % |
| Fall II: Korrelation (stark) | −0,10 % | +0,01 % | −0,49 % | −0,49 % | +0,64 % | −0,15 % |
| Fall III: Scatter (±10 %) | +0,02 % | +0,16 % | +0,35 % | −0,13 % | −0,09 % | −0,08 % |
| Fall IV: SP | −0,03 % | +0,26 % | +0,01 % | +0,50 % | +0,51 % | +0,07 % |
| Fall IV: ZP | −0,05 % | −0,24 % | −0,36 % | −0,01 % | −0,12 % | −0,06 % |

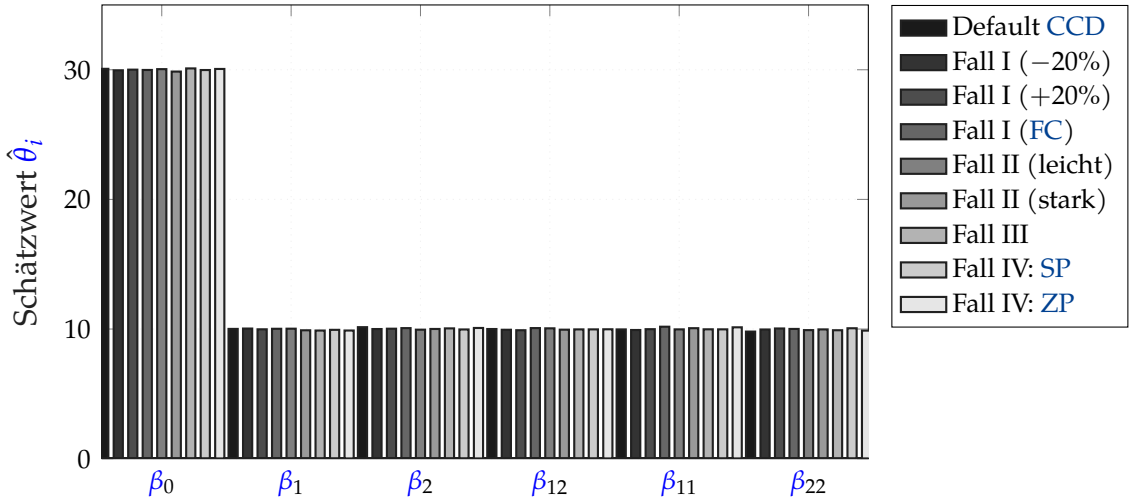


Abbildung 5.2: Absolute Schätzwerte der Modellkoeffizienten für den Arbeitspunkt SNR = 1,33.

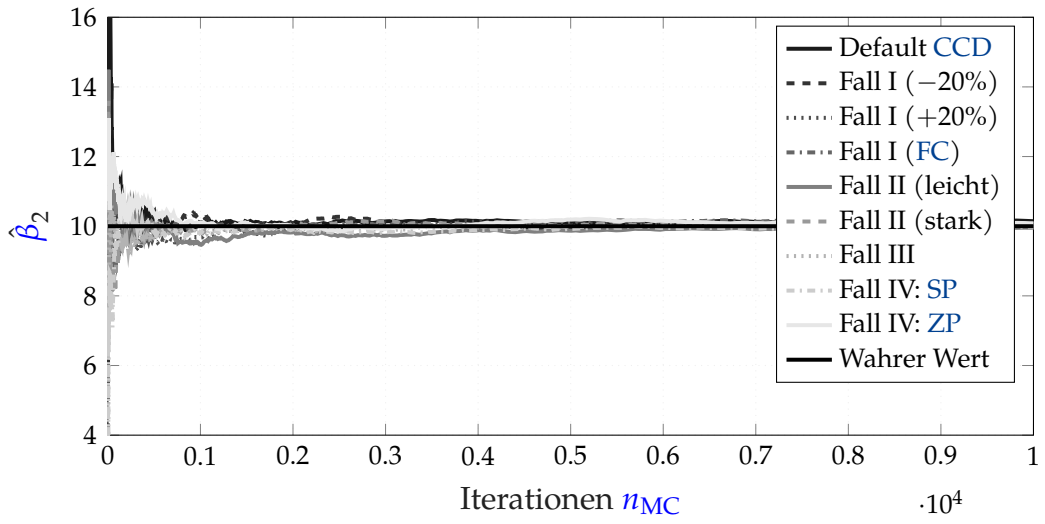


Abbildung 5.3: Numerische Konvergenz am Beispiel des Schätzwertes zu $\hat{\beta}_2$ über die MCS-Iterationen.

Tabelle 5.7: Simulationsergebnisse: Durchschnittlicher Trennschärfe-Verlust ($\Delta power$) der Koeffizienten bei SNR = 1,33. Ein negatives Vorzeichen indiziert einen Verlust, ein positives Vorzeichen einen Gewinn an Trennschärfe.

| **Szenario (Störfall)** | $power_{\beta_0}$ | $power_{\beta_1}$ | $power_{\beta_2}$ | $power_{\beta_{12}}$ | $power_{\beta_{11}}$ | $power_{\beta_{22}}$ |
|---|---|---|---|---|---|---|
| Referenz (Orthogonal) | – | – | – | – | – | – |
| Fall I: Shift (-20 %) | -0,0 % | -2,0 % | -0,1 % | +0,1 % | -4,3 % | -0,1 % |
| Fall I: Shift (+20 %) | ±0,0 % | +0,9 % | +0,0 % | -0,1 % | +4,6 % | -0,1 % |
| Fall I: FC | -0,0 % | -2,8 % | -0,1 % | +0,1 % | -6,2 % | +0,1 % |
| Fall II: Korrelation (leicht) | ±0,0 % | -0,0 % | +0,0 % | -0,0 % | +0,0 % | +0,1 % |
| Fall II: Korrelation (stark) | ±0,0 % | -2,4 % | +0,7 % | +3,9 % | -2,7 % | -1,3 % |
| Fall III: Scatter (±10 %) | +0,0 % | -0,3 % | +1,0 % | +0,2 % | -1,2 % | +3,0 % |
| Fall IV: SP | -0,0 % | -8,4 % | -0,4 % | -0,6 % | -10,5 % | -1,8 % |
| Fall IV: ZP | -0,1 % | -0,3 % | -0,3 % | -0,6 % | -0,8 % | -0,9 % |

1. **Gutmütige Restriktionen (Scatter, FC und ZPs):** Eine ungenaue, stochastisch verzerrte Ansteuerung der Nenn-Koordinaten (*Fall III*) sowie der ungeplante Entfall eines redundanten Zentralpunktes (*Fall IV:ZP*) erzeugen kaum messbare Auswirkungen. Ihr Trennschärfe-Verlust liegt de facto im Bereich des numerischen Rauschens ($\leq 1\,\%$). Selbst das bewusste Zurückziehen der SPs auf das strikte physikalische Randniveau der Faktoren (*FC*, *Fall I*) generiert lediglich einen absolut vertretbaren Detektionsverlust von 3,6 % in den quadratischen Termen.

2. **Kritische Restriktionen (Asymmetrischer Ausfall):** Der vollständige Entfall eines randlichen Sternpunktes (*Fall IV: SP*) schlägt sich im Kollaps nahezu aller globalen Optimalitäten nieder. Der asymmetrische Verlust von Freiheitsgraden an den Rändern des Parameterraums treibt das VIF auf über 1,2 und resultiert unmittelbar im stärksten Einbruch der Trennschärfe von fast 7 %.

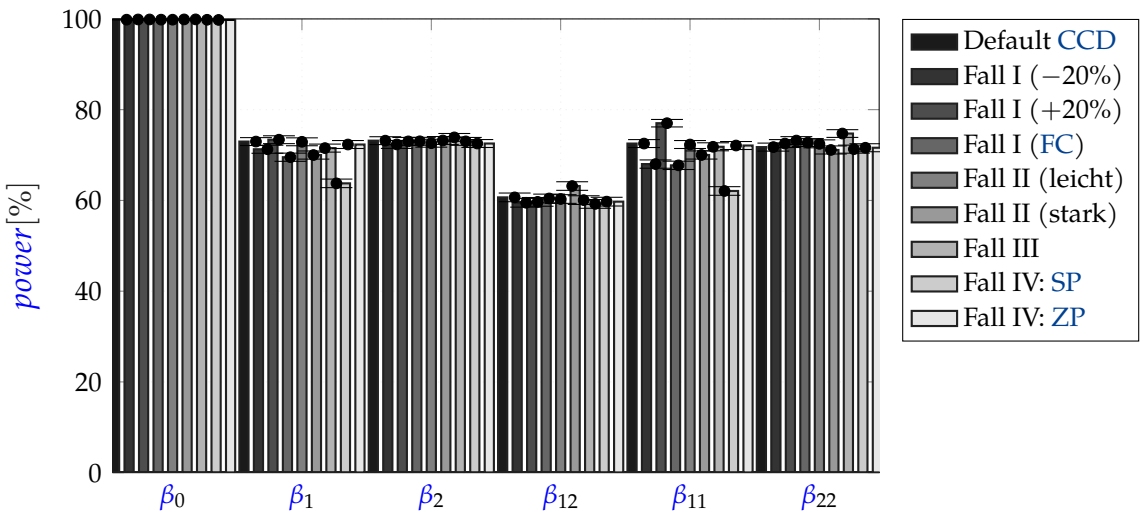


Abbildung 5.4: Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der Störszenarien. Trotz kritischer Parameterkonstellation (SNR = 1,33) bleiben die *power*-Verluste bei Erhalt der Symmetrie gering.

Zur Verifikation der methodischen Transparenz und Reproduzierbarkeit ist das numerische Konvergenzverhalten der empirischen Trennschärfe über die zunehmende Anzahl an MCS-Iterationen - ebenfalls exemplarisch für $\beta_2$ - in Abbildung 5.5 dokumentiert. Es zeigt, dass die angesetzte Iterationstiefe ausreicht, um den nu-

merischen Approximationsfehler zu minimieren und belastbare Power-Kennwerte abzuleiten.

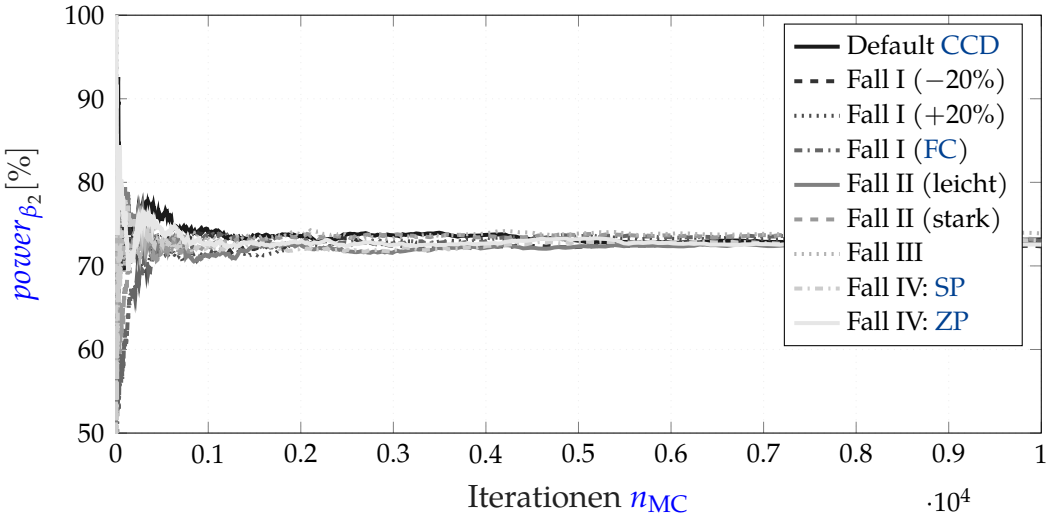


Abbildung 5.5: Numerische Konvergenz der Trennschärfe über die Simulationsläufe am Beispiel von $\beta_2$.

Flankierend sind die resultierenden Wahrscheinlichkeitsdichten der Signifikanztests ($p$-Wert) für alle Fälle in Abbildung 5.6 grafisch aufbereitet.

Weiterführende Sensitivitäts- und Strukturmatrizen sowie die Konvergenzplots der restlichen Koeffizienten können bei Bedarf im Anhang **??** eingesehen werden.

Die Gegenüberstellung der Resultate (vgl. Abbildung 5.7) erlaubt eine fundierte Neubewertung der etablierten Design-Metriken hinsichtlich ihrer Vorhersagekraft für die *power*:

- **Grenzen topologischer Indikatoren ($A_2$):** Der rein topologische $A_2$-Indikator weist ein geringes Bestimmtheitsmaß in Bezug auf den tatsächlichen Trennschärfe-Verlust auf ($R^2 \approx 0{,}12$). Da Trennschärfe-Verluste infolge von Multikollinearität (Klippeneffekt) oft sigmoidal und damit hochgradig nichtlinear verlaufen, eignet sich dieser Topologie-Indikator primär als Warnsystem für Singularitäten, nicht aber als präziser Prädiktor für die verbleibende *power*.

- **Die I-Effizienz als robustes, globales Maß:** Auf Ebene der theoretischen Optimalitätskriterien erweist sich die I-Effizienz ($I_{\text{eff}}$) als verlässlicher Indikator, der rund 81 % der Varianz des Trennschärfe-Verlusts erklärt ($R^2 \approx 0{,}81$). Da

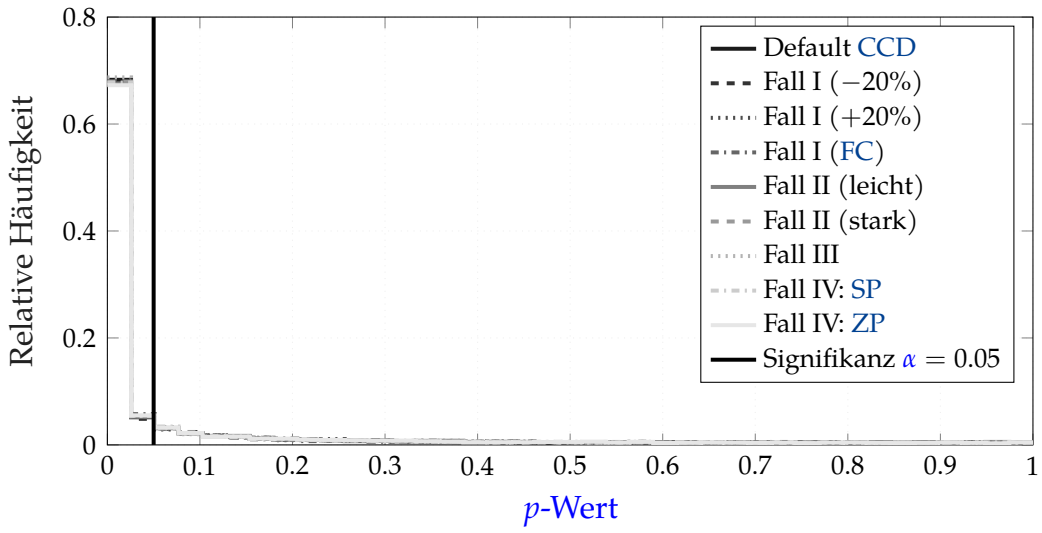


Abbildung 5.6: $p$-Wert Histogramm für den Signifikanztest am Beispiel von $\beta_2$. Die relative Häufigkeit der Werte unterhalb von $\alpha = 0{,}05$ entspricht der berechneten *power*.

sie die SPV über den gesamten Versuchsraum integriert, bewertet sie direkt die durchschnittliche Prognosegüte des Modells. Im Gegensatz zur rein volumenbasierten D-Effizienz erfasst die I-Effizienz die wahren Hebelwirkungen geometrischer Abweichungen realitätsnah. Dies prädestiniert die SPV als entscheidende Leitmetrik, sobald der Fokus von der reinen Parameteridentifikation auf die Prognosefähigkeit wechselt.

- **Der MSE als direkter Prädiktor der Teststatistik:** Die simulierte Schätzvarianz (MSE) fungiert als nahezu perfekter Prädiktor für den Trennschärfe-Erhalt ($R^2 \approx 1{,}00$ am Beispiel von $\hat{\beta}_{11}$). Dies folgt stringent aus der Prüfmathematik: Da die Teststatistik (z. B. der $F$-Wert) proportional zu $1/\sqrt{MSE}$ skaliert, verschiebt eine Varianzinflation den Nichtzentralitätsparameter unmittelbar. Der MSE übersetzt den geometrischen Fehler somit nahezu verlustfrei in die probabilistische Trennschärfe.

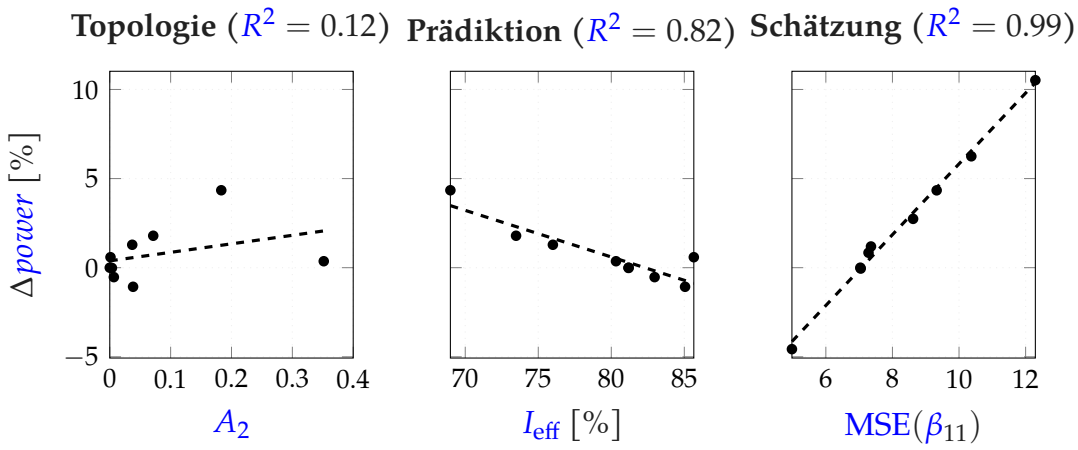


Abbildung 5.7: Korrelation zwischen Design-Metriken und dem resultierenden Trennschärfe-Verlust in den **simulierten Störszenarien**: *Fälle I-IV*.

### 5.1.5 Fazit: Statistische Effektivität und geometrisches Gestaltungsbudget

Die simulativen Analysen belegen die erstaunliche topologische Robustheit des CCD gegenüber geometrischen Modifikationen. Zwar manifestieren sich bei massiven strukturellen Eingriffen in den Versuchsraum definierte Ausreißer in der Schätzvarianz - etwa der sprunghafte Anstieg des MSE bei den Termen $\hat{\beta}_1$ und $\hat{\beta}_{11}$ (auf Werte $> 12$, vgl. Abbildung 5.1) infolge eines asymmetrischen Sternpunkt-Ausfalls (*Fall IV: SP*) oder die Varianzinflation des Interaktionsterms ($VIF_{\beta_{12}} \approx 1{,}23$, siehe Tabelle 5.5) bei starker Faktorkorrelation (*Fall II*). Setzt man diese Extremwerte jedoch in Relation zu kritischen statistischen *Red Flags* (Ausschlusskriterien wie einem $VIF > 5$ oder massiven Einbrüchen der Trennschärfe von $\Delta power > 10\,\%$ auf die wesentlichen Haupteffekte), erweisen sich selbst diese modifizierten Versuchspläne als funktionell. Der systematische Schätzfehler (*Bias*) bleibt ohnehin durchweg vernachlässigbar, vgl. Abbildung 5.2.

Darüber hinaus verursachen der Entfall redundanter Zentralpunkte (*Fall IV: ZP*) oder moderate axiale Verschiebungen (*Fall I*) lediglich marginale *Design-Penalties*. Diese nachgewiesene Fehlertoleranz der Planmatrix rechtfertigt einen radikalen Paradigmenwechsel für hochbeschleunigte Lebensdauertests: Der Verzicht auf Replikationen im Zentrum oder die bewusste Entschärfung extremer Prüfbedingungen an den hochbelasteten (nordöstlichen) Rändern des Parameterraums zerstören die sta-

tistische Validität des Modells nicht, flexibilisieren aber Prüfkapazitäten. Der Tausch einer in der Praxis ohnehin durch Rauschen limitierten, globalen Trennschärfe gegen signifikante Prüfzeitverkürzungen liefert dem Planer somit ein wertvolles **geometrisches Gestaltungsbudget**.

Um dieses Budget im weiteren Verlauf der Arbeit in eine holistische Effizienzbewertung (Informationsgewinn versus Prüfkosten) zu überführen, muss geklärt werden, wie die freigewordenen Versuchskapazitäten bestmöglich reinvestiert werden. Hierfür greift die Maximierung der reinen Erkennungswahrscheinlichkeit (*power*) zu kurz. Wie durch das Integral der I-Effizienz bereits mathematisch indiziert, rückt stattdessen die eigentliche Herausforderung der EoL-Erprobung in den Fokus: die gezielte Reduktion der Prognosevarianz SPV für die modellspezifische Extrapolationsabsicherung, wenn eine Garantie für die Identifikation von Effekten bereits zu akzeptabler Eintrittwahrscheinlichkeit gegeben ist.

## 5.2 Adaptive Versuchsplanung zur Extrapolationsabsicherung

In der Praxis beschleunigter Lebensdauertests (ALT) werden Versuchspläne naturgemäß in Bereiche hoher Belastungen verschoben - beispielsweise in den nordöstlichen Quadranten des Parameterraums - um Ausfälle in vertretbarer Prüfzeit zu erzwingen, sofern es der physikalisch sinnvolle Wertebereich der Faktoren zulässt. Das eigentliche Ziel der Modellbildung bleibt jedoch die verlässliche Prognose unter wesentlich moderateren Feldbedingungen: im Feldbereich des meist südwestlichen Quadranten.

Anstatt das in Abschnitt 5.1 erarbeitete geometrische Budget rein zur passiven Kostensenkung zu nutzen, drängt sich nun ein proaktiver Ansatz auf: Die durch die nachgewiesene Design-Robustheit freigewordenen Stützstellen - etwa substituierbare Zentralpunkte oder extreme, für den Schädigungsmechanismus gegebenenfalls irrelevante Sternpunkte - werden gezielt in Richtung des anvisierten Feldbereichs verlagert, während das verbleibende Basisdesign weiterhin die notwendige Trennschärfe für die Effektidentifikation gewährleistet. Dieser strategische *Brückenbau im Parameterraum* erzeugt asymmetrische Validierungspunkte, die das Regressionsmodell auf dem Extrapolationspfad verankern und empirisch absichern.

Um den Leistungsgewinn dieser gerichteten Design-Manipulationen objektiv bewerten zu können, wird die zuvor eingeführte SPV aus ihrer globalen Integralbetrachtung gelöst. Es bedarf nun ihrer isolierten Anwendung als exakte, lokale Maßzahl, die das Vertrauensintervall der Vorhersage punktgenau im kritischen Betriebspunkt des Feldes quantifiziert. Eine Bewertung nach etabliertem Vorgehen via Bias und *power* im Anschluss ist obligatorisch und folgt in Abschnitt 5.3.

### 5.2.1 Die Scaled Prediction Variance als Prognosemetrik

Während die vorangegangenen Analysen in Abschnitt 5.1.3 die Schätzbarkeit der zugrundeliegenden Modelleffekte (*power*, *Bias*) fokussierten, verlagert sich der Anspruch in der ALT-Lebensdauerprognose außerdem auf die Vorhersageunsicherheit des Zielwertes (vgl. Gleichung 2.32). Da der nominelle Feldbetrieb definitionsgemäß weit außerhalb der getesteten Hochlastgrenzen liegt, weitet sich jede Unsicherheit der Regressionskoeffizienten mit zunehmender geometrischer Distanz zum Design-Zentrum exponentiell aus. Zur Quantifizierung dieser ortsabhängigen Prognosegüte dient die SPV.

Um die Auswirkungen von Stützstellen-Modifikationen gezielt auf diese Extrapolationsfähigkeit zu bewerten, untersucht **Arndt.2024** die Varianztopologie modifizierter CCDs mittels Konturplots sowie Visualisierungen zur *Variance Dispersion* (VDG) und *Fraction of Design Space* (FDS). Durch eine Reduktion der Zentralpunkte (analog zum untersuchten *Fall IV: ZP*) erhöht sich demnach die SPV zwar im unmittelbaren interpolativen Kern des Versuchsplans leicht, sie wirkt sich jedoch de facto nicht auf die Peripherie und den fernen Extrapolationsraum aus. Dies untermauert die methodische These, dass redundante ZPs für extrapolierende EoL-Prognosen ein ineffizientes Investment darstellen können, sofern deren Umfang über die Grenzen der Modellstabilität hinausgeht und potenziell als Gestaltungsbudget freigegeben werden können.

Demgegenüber offenbart die SPV-Analyse den enormen geometrischen Hebel der Sternpunkte. Während ihr ersatzloser Entfall die Modellstabilität signifikant schädigt (die identifizierte statistische *Red Flag* aus *Fall IV: SP*), transformiert sich ihr Nutzen bei einer gezielten Verschiebung: Der Rückzug aus extremen Hochlastbereichen hin zu moderateren Lastniveaus führt zu einer gewollten, asymmetrischen Verformung der Varianzfunktion. Dies eröffnet das Potenzial, Mäßigung ungünsti-

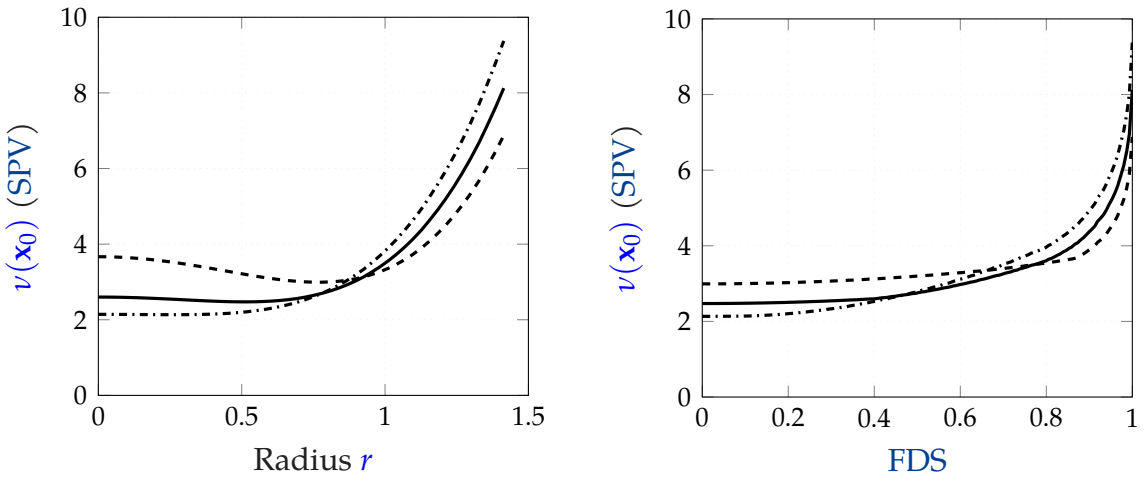


(a) Variance Dispersion Graph (VDG) (b) Fraction of Design Space (FDS)

Abbildung 5.8: Vorhersagegüte bei Variation der ZP-Anzahl $n_C$ für einen Ç mit $k = 2$ Faktoren.

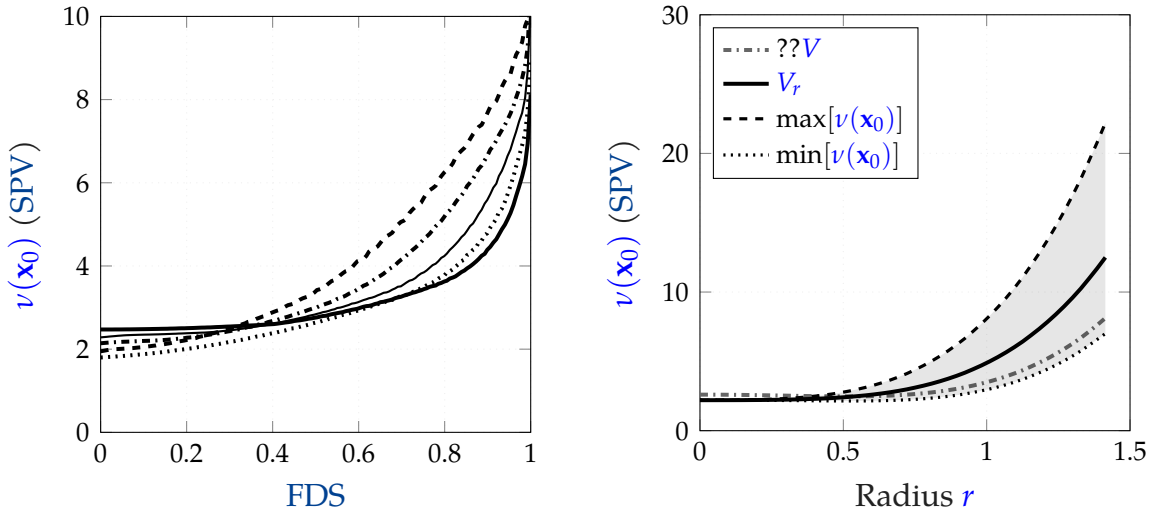


(a) FDS-Vergleich bei Ausfällen (b) VDG des manipulierten Designs

Abbildung 5.9: Auswirkung reduzierter Orthogonalität durch schrittweisen Entfall axialer Versuchspunkte auf die skalierte Prädiktionsvarianz .

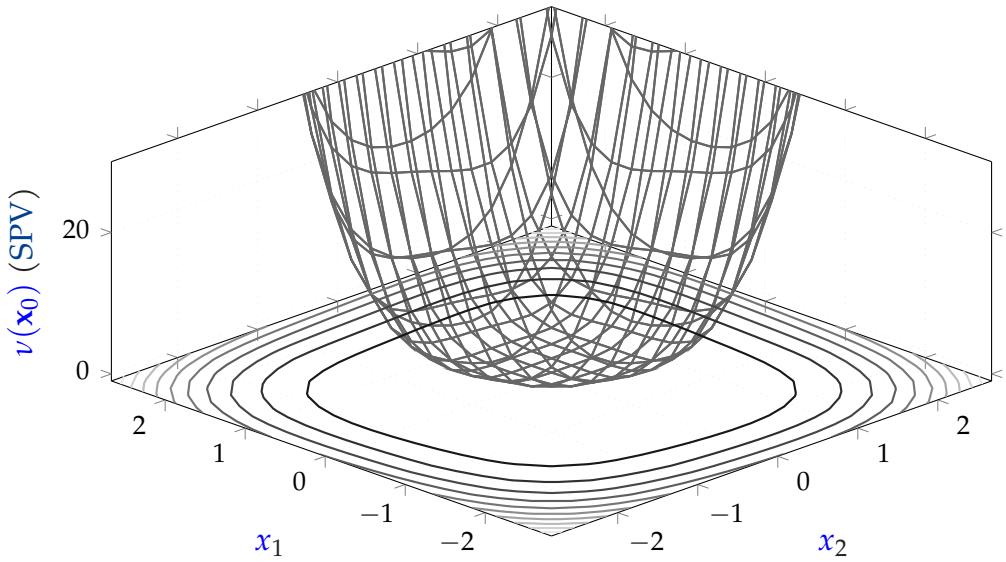


Abbildung 5.10: Dreidimensionale Darstellung der skalierten Prädiktionsvarianz und zugehöriger Konturverlauf für ein asymmetrisch manipuliertes Versuchsdesign.

ger Wertlagen der SPV durch Verschiebung der Sternpunkte in exakt jene Richtung zu erreichen *Brückenpunkt*.

Diese topologischen Gesetzmäßigkeiten verschmelzen die Ergebnisse der reinen Parameteridentifikation nahtlos mit dem Prognoseanspruch: Die durch reduzierte ZPs freigewordenen Ressourcen lassen sich investieren, um den geometrischen Extrapolationshebel in Richtung des Feld-Betriebspunktes abzustützen und die divergierende SPV-Funktion an einem kritischen Zwischenstopp zu erden. Zur Quantifizierung dieses spezifischen, richtungsabhängigen Informationsgewinns im multivariaten Raum stoßen klassische, meist rotationssymmetrisch auswertende Bewertungstools (wie der VDG) jedoch an ihre Grenzen.

### 5.2.2 Richtungsabhängige Bewertung: Der Extrapolation Variance Graph (EVG)

## 5.3 Übertragung auf multivariate Lebensdauermodelle

### 5.3.1 Transformation der Methodik auf lebensdauerverteilte Daten

### 5.3.2 Validierung der Trennschärfe bei zensierten Lebensdauerdaten

### 5.3.3 Prognosegüte und Konfidenzintervalle im Feldbetrieb

## 5.4 Ökonomische Bewertung: Das Effizienz-Kosten-Modell

### 5.4.1 Modellierung multivariater Prüfkosten

### 5.4.2 Der Trade-off: Testzeit versus Prognosegüte

### 5.4.3 Holistische Effizienz-Metrik für Lebensdauertests

# 6 Fallstudie

# 7 Zusammenfassung und Ausblick

## 7.1 Key Findings

## 7.2 Diskussion

## 7.3 Ausblick

# Anhang A Ableitungen zur Maximum-Likelihood-Schätzung

## A.1 Modell Daefinition (Modell zweiter Ordnung)

Für ein System mit $k = 2$ Einflussfaktoren $(x_1, x_2)$ basierend auf einem CCD ist der lineare Prädiktor $\eta_i$ definiert. Er beschreibt den Logarithmus der charakteristischen Lebensdauer wie folgt:

$$\eta_i = \ln(T_i) = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \beta_{12} x_{i,1} x_{i,2} + \beta_{11} x_{i,1}^2 + \beta_{22} x_{i,2}^2 \tag{.1}$$

Der zugehörige Parametervektor $\boldsymbol{\beta}$ und der Regressorvektor $x_i$ lauten:

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_{12} \\ \beta_{11} \\ \beta_{22} \end{bmatrix}, \quad x_i = \begin{bmatrix} 1 \\ x_{i,1} \\ x_{i,2} \\ x_{i,1} x_{i,2} \\ x_{i,1}^2 \\ x_{i,2}^2 \end{bmatrix} \tag{.2}$$

## A.2 Log-Likelihood-Funktion

Wir führen zunächst den Indikator $\delta_i$ ein ($\delta_i = 1$ für Ausfall, 0 für Zensierung). Zusätzlich definieren wir die Hilfsvariable $z_i$:

$$z_i = {t_i}^b \exp(-b\eta_i) \tag{.3}$$

Damit lautet die Log-Likelihood-Funktion $\Lambda$:

$$\Lambda = \sum_{i=1}^{n} \left[\delta_i \left(\ln(b) - b\eta_i + (b-1)\ln(t_i)\right) - z_i\right] \tag{.4}$$

## A.3 Score-Vektor (Erste Ableitungen)

Die partiellen Ableitungen (Gradient) dienen zur Maximierung der Funktion. Die Ableitung nach den Regressionskoeffizienten für $j \in \{0, 1, 2, 12, 11, 22\}$ lautet:

$$\frac{\partial \Lambda}{\partial \beta_j} = b \sum_{i=1}^{n} (z_i - \delta_i) x_{i,j} \tag{.5}$$

Die Ableitung nach dem Formparameter $b$ ergibt sich zu:

$$\frac{\partial \Lambda}{\partial b} = \sum_{i=1}^{n} \left[ \frac{\delta_i}{b} + (\delta_i - z_i)(\ln(t_i) - \eta_i) \right] \tag{.6}$$

## A.4 Hesse-Matrix (Zweite Ableitungen)

Die Elemente der Hesse-Matrix werden für die Fisher-Information und den Newton-Raphson-Algorithmus benötigt. Die zweite Ableitung nach den Koeffizienten $\boldsymbol{\beta}$ (für Indizes $j$ und $l$) ist:

$$\frac{\partial^2 \Lambda}{\partial \beta_j \partial \beta_l} = -b^2 \sum_{i=1}^{n} z_i x_{i,j} x_{i,l} \tag{.7}$$

Die zweite Ableitung nach dem Formparameter $b$ lautet:

$$\frac{\partial^2 \Lambda}{\partial b^2} = -\sum_{i=1}^{n} \left[ \frac{\delta_i}{b^2} + z_i (\ln(t_i) - \eta_i)^2 \right] \tag{.8}$$

Die gemischte Ableitung nach $\boldsymbol{\beta}$ und $b$ berechnet sich wie folgt:

$$\frac{\partial^2 \Lambda}{\partial \beta_j \partial b} = \sum_{i=1}^{n} x_{i,j} \left[ (z_i - \delta_i) + b z_i (\ln(t_i) - \eta_i) \right] \tag{.9}$$

# Anhang B Sensitivitätsanalyse

In diesem Anhang sind die detaillierten Ergebnisse der Sensitivitätsanalyse für die verschiedenen Parameterkombinationen tabellarisch zusammengefasst. Die Tabellen zeigen die Power des Tests in Abhängigkeit von den Störfaktoren $C$ (Zentrums-Läufe) und $D$ (Stern-Läufe).

Tabelle B1: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = +1$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9453 | 0.7362 | 0.6281 | 0.7168 | 0.5718 | - | 0.9935 |
| power max | 0.9905 | 0.8273 | 0.7994 | 0.8269 | 0.7495 | - | 1.0000 |
| power min | 0.7811 | 0.5999 | 0.3734 | 0.5517 | 0.3259 | - | 0.9451 |
| Power (+) | 0.9357 | 0.7304 | 0.6127 | 0.7163 | 0.5592 | - | 0.9949 |
| Power (-) | 0.9508 | 0.7353 | 0.6495 | 0.7148 | 0.5766 | - | 0.9909 |
| Power ($\alpha$) | 0.9058 | 0.7022 | 0.6006 | 0.7086 | 0.5164 | - | 0.9939 |
| Power (-$\alpha$) | 0.9485 | 0.7162 | 0.7044 | 0.7046 | 0.5656 | - | 0.9826 |
| a | 0.3958 | 0.0298 | 0.3543 | 0.1940 | 0.3241 | - | 0.2432 |
| b | 0.2848 | 0.0084 | 0.0789 | 0.3961 | 0.7657 | - | 0.0546 |
| e | 0.9380 | 0.1534 | 1.6411 | 0.2953 | 0.7639 | - | 0.0440 |
| f | 0.0115 | 0.0411 | 2.6158 | 0.0315 | 0.0551 | - | 0.0403 |
| g | 1.1583 | 1.8408 | 2.3250 | 1.9725 | 2.7091 | - | 0.2193 |
| h | 0.6492 | 0.6492 | 1.8966 | 1.5782 | 2.2201 | - | 0.1176 |
| aa | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0479 |
| bb | 0.0299 | 0.0299 | 0.0000 | 0.1089 | 0.0000 | - | 0.0000 |
| ee | 0.0988 | 0.0988 | 0.0797 | 0.0000 | 0.0000 | - | 0.0000 |
| ff | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 |
| gg | 0.1851 | 0.1851 | 0.0672 | 0.1405 | 0.2111 | - | 0.0398 |
| hh | 0.0913 | 0.0913 | 0.1066 | 0.0861 | 0.2561 | - | 0.0179 |
| ab | 0.0000 | 0.0000 | 0.1039 | 0.0647 | 0.2700 | - | 0.0162 |
| ae | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 |
| af | 0.0000 | 0.0000 | 0.0873 | 0.1034 | 0.0000 | - | 0.0197 |
| ah | 0.0375 | 0.0375 | 0.0000 | 0.0694 | 0.0000 | - | 0.0297 |
| ag | 0.1003 | 0.1003 | 0.0000 | 0.0000 | 0.0000 | - | 0.0625 |
| be | 0.0000 | 0.0000 | 0.0000 | 0.0850 | 0.0000 | - | 0.0284 |
| bf | 0.0000 | 0.0000 | 0.0948 | 0.0000 | 0.0000 | - | 0.0000 |
| bh | 0.0606 | 0.0606 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 |
| bg | 0.0434 | 0.0434 | 0.0000 | 0.0912 | 0.0934 | - | 0.0241 |
| ef | 0.0000 | 0.0000 | 0.3848 | 0.0000 | 0.0941 | - | 0.0000 |
| eh | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 |
| eg | 0.0916 | 0.0916 | 0.1936 | 0.0000 | 0.0203 | - | 0.0203 |
| fh | 0.0000 | 0.0000 | 0.1073 | 0.0000 | 0.0000 | - | 0.0000 |
| fg | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0287 | - | 0.0287 |
| gh | 0.1616 | 0.1616 | 0.0000 | 0.0822 | 0.0000 | - | 0.0000 |
| - | - | - | - | - | - | Lack of fit | - |

Tabelle B2: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = 0$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9518 | 0.7985 | 0.6387 | 0.7208 | 0.6531 | - | 0.9957 |
| power max | 0.9933 | 0.8573 | 0.8181 | 0.8411 | 0.7769 | - | 1.0000 |
| power min | 0.7685 | 0.6603 | 0.4066 | 0.5247 | 0.4672 | - | 0.9667 |
| Power (+) | 0.9444 | 0.7954 | 0.6178 | 0.7225 | 0.6561 | - | 0.9970 |
| Power (-) | 0.9556 | 0.7993 | 0.6589 | 0.7189 | 0.6485 | - | 0.9946 |
| Power ($\alpha$) | 0.9215 | 0.7834 | 0.5775 | 0.7248 | 0.6577 | - | 0.9995 |
| Power (-$\alpha$) | 0.9533 | 0.7944 | 0.6938 | 0.7146 | 0.6361 | - | 0.9929 |
| a | 0.5743 | 0.0539 | 0.4599 | 0.2257 | 0.1838 | - | 0.1461 |
| b | 0.2434 | 0.0624 | 0.1787 | 0.5291 | 0.1289 | - | 0.0400 |
| e | 0.9031 | 0.1628 | 1.5864 | 0.2921 | 0.4940 | - | 0.0366 |
| f | 0.0191 | 0.0288 | 2.6353 | 0.0388 | 0.0186 | - | 0.0286 |
| g | 1.0501 | 1.4474 | 2.1712 | 1.9654 | 2.3119 | - | 0.1445 |
| h | 0.5934 | 1.1095 | 1.8017 | 1.5105 | 1.8671 | - | 0.0673 |
| aa | 0.0000 | 0.0000 | 0.1083 | 0.0000 | 0.0000 | - | 0.0162 |
| bb | 0.0000 | 0.0000 | 0.0000 | 0.1100 | 0.1570 | - | 0.0119 |
| ee | 0.1020 | 0.0000 | 0.1373 | 0.0875 | 0.0000 | - | 0.0000 |
| ff | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 |
| gg | 0.1920 | 0.1289 | 0.1452 | 0.1150 | 0.1467 | - | 0.0312 |
| hh | 0.1089 | 0.2101 | 0.1396 | 0.1850 | 0.2392 | - | 0.0099 |
| ab | 0.0000 | 0.0972 | 0.1019 | 0.0906 | 0.0000 | - | 0.0267 |
| ae | 0.0000 | 0.0000 | 0.1122 | 0.0672 | 0.0000 | - | 0.0000 |
| af | 0.0000 | 0.0000 | 0.0000 | 0.0853 | 0.0000 | - | 0.0000 |
| ah | 0.0775 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0239 |
| ag | 0.1522 | 0.0000 | 0.0000 | 0.1053 | 0.0000 | - | 0.0286 |
| be | 0.0356 | 0.0000 | 0.0000 | 0.0591 | 0.0000 | - | 0.0000 |
| bf | 0.0000 | 0.0000 | 0.0000 | 0.0703 | 0.0000 | - | 0.0117 |
| bh | 0.0400 | 0.0000 | 0.0000 | 0.0000 | 0.0797 | - | 0.0111 |
| bg | 0.0622 | 0.0934 | 0.0000 | 0.0603 | 0.1091 | - | 0.0000 |
| ef | 0.0441 | 0.0806 | 0.3800 | 0.0888 | 0.0000 | - | 0.0311 |
| eh | 0.0791 | 0.0000 | 0.0747 | 0.0000 | 0.0000 | - | 0.0000 |
| eg | 0.0738 | 0.0000 | 0.0000 | 0.1994 | 0.0972 | - | 0.0000 |
| fh | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0152 |
| fg | 0.0000 | 0.0000 | 0.0775 | 0.0000 | 0.0000 | - | 0.0117 |
| gh | 0.1287 | 0.1422 | 0.0000 | 0.0906 | 0.0841 | - | 0.0164 |
| - | - | - | - | - | - | Lack of fit | - |

Tabelle B3: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = -1$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9540 | 0.7986 | 0.7074 | - | - | - | 0.9975 |
| power max | 0.9989 | 0.8729 | 0.8406 | - | - | - | 1.0030 |
| power min | 0.7860 | 0.6751 | 0.4696 | - | - | - | 0.9723 |
| Power (+) | 0.9487 | 0.7962 | 0.6911 | - | - | - | 0.9976 |
| Power (-) | 0.9545 | 0.7996 | 0.7428 | - | - | - | 0.9967 |
| Power ($\alpha$) | 0.9262 | 0.7884 | 0.7104 | - | - | - | 0.9956 |
| Power (-$\alpha$) | 0.9426 | 0.7981 | 0.8568 | - | - | - | 0.9930 |
| a | 0.7210 | 0.1280 | 0.4171 | - | - | - | 0.0960 |
| b | 0.3130 | 0.0177 | 0.7838 | - | - | - | 0.0204 |
| e | 0.8543 | 0.0783 | 1.3897 | - | - | - | 0.0216 |
| f | 0.0265 | 0.1084 | 2.2880 | - | - | - | 0.0300 |
| g | 0.9984 | 1.3910 | 1.8966 | - | - | - | 0.1050 |
| h | 0.5009 | 1.1444 | 1.4085 | - | - | - | 0.0433 |
| aa | 0.0000 | 0.0000 | 0.0000 | - | - | - | 0.0209 |
| bb | 0.0590 | 0.0823 | 0.0411 | - | - | - | 0.0000 |
| ee | 0.0766 | 0.0000 | 0.0514 | - | - | - | 0.0000 |
| ff | 0.0000 | 0.0000 | 0.2129 | - | - | - | 0.0000 |
| gg | 0.1704 | 0.0802 | 0.1430 | - | - | - | 0.0365 |
| hh | 0.1141 | 0.1227 | 0.1461 | - | - | - | 0.0000 |
| ab | 0.0742 | 0.0920 | 0.1405 | - | - | - | 0.0178 |
| ae | 0.0642 | 0.0000 | 0.1030 | - | - | - | 0.0000 |
| af | 0.0000 | 0.0000 | 0.0814 | - | - | - | 0.0125 |
| ah | 0.0739 | 0.0000 | 0.0545 | - | - | - | 0.0112 |
| ag | 0.1261 | 0.0000 | 0.0000 | - | - | - | 0.0366 |
| be | 0.0000 | 0.0000 | 0.0414 | - | - | - | 0.0000 |
| bf | 0.0000 | 0.0000 | 0.0483 | - | - | - | 0.0000 |
| bh | 0.0558 | 0.0000 | 0.0000 | - | - | - | 0.0000 |
| bg | 0.0000 | 0.0000 | 0.0530 | - | - | - | 0.0097 |
| ef | 0.0000 | 0.0820 | 0.4002 | - | - | - | 0.0131 |
| eh | 0.0000 | 0.0000 | 0.0000 | - | - | - | 0.0125 |
| eg | 0.0636 | 0.0000 | 0.0789 | - | - | - | 0.0000 |
| fh | 0.0000 | 0.0000 | 0.0911 | - | - | - | 0.0000 |
| fg | 0.0000 | 0.0830 | 0.0000 | - | - | - | 0.0231 |
| gh | 0.1339 | 0.1452 | 0.1148 | - | - | - | 0.0100 |
| - | - | - | - | Lack of fit | Lack of fit | Lack of fit | - |

Tabelle B4: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = +1$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9902 | 0.7454 | 0.6374 | 0.7229 | - | 0.7645 | 0.9968 |
| power max | 0.9981 | 0.8382 | 0.7916 | 0.8411 | - | 0.9125 | 1.0000 |
| power min | 0.9588 | 0.6174 | 0.3968 | 0.5881 | - | 0.3337 | 0.9794 |
| Power (+) | 0.9843 | 0.7426 | 0.6232 | 0.7237 | - | 0.7862 | 0.9970 |
| Power (-) | 0.9934 | 0.7447 | 0.6596 | 0.7238 | - | 0.7243 | 0.9958 |
| Power ($\alpha$) | 0.9668 | 0.7285 | 0.6175 | 0.7294 | - | 0.7777 | 0.9950 |
| Power (-$\alpha$) | 0.9924 | 0.7346 | 0.7206 | 0.7296 | - | 0.6029 | 0.9916 |
| a | 0.0155 | 0.0621 | 0.2866 | 0.2087 | - | 4.7500 | 0.0968 |
| b | 0.0000 | 0.0499 | 0.0228 | 0.4204 | - | 1.5342 | 0.0237 |
| e | 0.3993 | 0.2315 | 1.6512 | 0.2988 | - | 0.2277 | 0.0097 |
| f | 0.0000 | 0.0261 | 2.6397 | 0.0000 | - | 0.0597 | 0.0174 |
| g | 0.1461 | 1.6970 | 2.2654 | 1.9055 | - | 1.7045 | 0.0962 |
| h | 0.0774 | 1.3724 | 1.7403 | 1.3905 | - | 1.2919 | 0.0420 |
| aa | 0.0000 | 0.0819 | 0.0000 | 0.0000 | - | 0.5453 | 0.0177 |
| bb | 0.0000 | 0.1413 | 0.0635 | 0.1255 | - | 0.3322 | 0.0000 |
| ee | 0.0842 | 0.1212 | 0.0000 | 0.0986 | - | 0.1128 | 0.0000 |
| ff | 0.0000 | 0.0000 | 0.3990 | 0.0000 | - | 0.0000 | 0.0000 |
| gg | 0.0211 | 0.0681 | 0.1503 | 0.0726 | - | 0.0915 | 0.0089 |
| hh | 0.0000 | 0.0913 | 0.1597 | 0.1189 | - | 0.1559 | 0.0000 |
| ab | 0.0000 | 0.0000 | 0.0000 | 0.1508 | - | 0.0719 | 0.0125 |
| ae | 0.0175 | 0.0000 | 0.0000 | 0.0000 | - | 0.1094 | 0.0000 |
| af | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 |
| ah | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.1788 | 0.0116 |
| ag | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.3075 | 0.0219 |
| be | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0141 |
| bf | 0.0000 | 0.0884 | 0.0000 | 0.0000 | - | 0.0738 | 0.0000 |
| bh | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.1050 | 0.0000 |
| bg | 0.0000 | 0.0000 | 0.0000 | 0.1005 | - | 0.1244 | 0.0147 |
| ef | 0.0000 | 0.0000 | 0.3547 | 0.0000 | - | 0.0862 | 0.0000 |
| eh | 0.0000 | 0.0000 | 0.0841 | 0.0000 | - | 0.0000 | 0.0000 |
| eg | 0.0441 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 |
| fh | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 |
| fg | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - | 0.1187 | 0.0159 |
| gh | 0.0000 | 0.0000 | 0.0000 | 0.0995 | - | 0.0750 | 0.0000 |
| - | - | - | - | - | Lack of fit | - | - |

Tabelle B5: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = 0$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9905 | 0.8010 | 0.6464 | 0.7278 | 0.7582 | 0.7765 | 0.9980 |
| power max | 0.9986 | 0.8732 | 0.7996 | 0.8508 | 0.8625 | 0.9315 | 1.0000 |
| power min | 0.9552 | 0.6885 | 0.4066 | 0.5683 | 0.6378 | 0.5508 | 0.9853 |
| Power (+) | 0.9848 | 0.7978 | 0.6275 | 0.7258 | 0.7535 | 0.7942 | 0.9981 |
| Power (-) | 0.9941 | 0.8076 | 0.6660 | 0.7273 | 0.7674 | 0.7376 | 0.9974 |
| Power ($\alpha$) | 0.9694 | 0.8007 | 0.5947 | 0.7158 | 0.7564 | 0.7714 | 0.9970 |
| Power (-$\alpha$) | 0.9956 | 0.8282 | 0.7037 | 0.7199 | 0.7958 | 0.6113 | 0.9950 |
| a | 0.0027 | 0.1427 | 0.4640 | 0.2446 | 0.0495 | 4.0624 | 0.0608 |
| b | 0.0099 | 0.0559 | 0.0418 | 0.5323 | 0.3258 | 1.0318 | 0.0137 |
| e | 0.4114 | 0.0532 | 1.5052 | 0.2067 | 0.2528 | 0.1887 | 0.0100 |
| f | 0.0035 | 0.0072 | 2.5420 | 0.0221 | 0.0221 | 0.0399 | 0.0061 |
| g | 0.1383 | 1.4069 | 2.2154 | 1.9565 | 1.8537 | 1.5771 | 0.0754 |
| h | 0.0706 | 0.9461 | 1.7469 | 1.3671 | 1.2025 | 1.2268 | 0.0318 |
| aa | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.5061 | 0.0097 |
| bb | 0.0000 | 0.0000 | 0.0000 | 0.1137 | 0.0656 | 0.0787 | 0.0000 |
| ee | 0.0759 | 0.1234 | 0.1083 | 0.0887 | 0.1299 | 0.0926 | 0.0000 |
| ff | 0.0115 | 0.0000 | 0.0000 | 0.0513 | 0.0824 | 0.0000 | 0.0000 |
| gg | 0.0147 | 0.0860 | 0.0911 | 0.1219 | 0.1251 | 0.1168 | 0.0178 |
| hh | 0.0000 | 0.1129 | 0.1642 | 0.1101 | 0.0907 | 0.1474 | 0.0000 |
| ab | 0.0000 | 0.0000 | 0.0000 | 0.1018 | 0.0000 | 0.1845 | 0.0000 |
| ae | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.1461 | 0.0112 |
| af | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0823 | 0.0097 |
| ah | 0.0000 | 0.0000 | 0.0000 | 0.0967 | 0.0000 | 0.1739 | 0.0113 |
| ag | 0.0000 | 0.0000 | 0.0000 | 0.1195 | 0.0000 | 0.2064 | 0.0219 |
| be | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0693 | 0.0000 | 0.0000 |
| bf | 0.0000 | 0.0000 | 0.1167 | 0.0889 | 0.0000 | 0.0717 | 0.0000 |
| bh | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0929 | 0.0777 | 0.0000 |
| bg | 0.0000 | 0.1098 | 0.0000 | 0.0000 | 0.0000 | 0.0895 | 0.0000 |
| ef | 0.0000 | 0.0767 | 0.3902 | 0.0000 | 0.0000 | 0.0000 | 0.0000 |
| eh | 0.0187 | 0.0000 | 0.1736 | 0.0000 | 0.0000 | 0.0945 | 0.0000 |
| eg | 0.0553 | 0.0767 | 0.0000 | 0.0836 | 0.0000 | 0.0000 | 0.0000 |
| fh | 0.0000 | 0.0000 | 0.1789 | 0.0000 | 0.0000 | 0.0000 | 0.0000 |
| fg | 0.0178 | 0.0000 | 0.0964 | 0.1392 | 0.0000 | 0.0000 | 0.0000 |
| gh | 0.0216 | 0.1333 | 0.0000 | 0.1445 | 0.0000 | 0.1073 | 0.0125 |

Tabelle B6: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = -1$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9906 | 0.8001 | 0.7253 | 0.7307 | 0.7711 | 0.8209 | - |
| power max | 1.0000 | 0.8858 | 0.8277 | 0.8590 | 0.8612 | 0.9535 | - |
| power min | 0.9556 | 0.6939 | 0.4813 | 0.5676 | 0.6473 | 0.5788 | - |
| Power (+) | 0.9846 | 0.7993 | 0.7053 | 0.7301 | 0.7680 | 0.8377 | - |
| Power (-) | 0.9932 | 0.8053 | 0.7401 | 0.7247 | 0.7740 | 0.7956 | - |
| Power ($\alpha$) | 0.9653 | 0.8030 | 0.6554 | 0.7123 | 0.7620 | 0.8464 | - |
| Power (-$\alpha$) | 0.9897 | 0.8198 | 0.7537 | 0.6969 | 0.7791 | 0.7271 | - |
| a | 0.0314 | 0.1339 | 0.2048 | 0.2370 | 0.0789 | 2.8293 | - |
| b | 0.0083 | 0.0793 | 0.5931 | 0.6122 | 0.1142 | 0.6457 | - |
| e | 0.4076 | 0.1149 | 1.1845 | 0.2977 | 0.1985 | 0.1012 | - |
| f | 0.0045 | 0.0841 | 2.2052 | 0.0770 | 0.0359 | 0.0660 | - |
| g | 0.1364 | 1.4107 | 1.7065 | 1.8462 | 1.5774 | 1.2572 | - |
| h | 0.0775 | 0.9693 | 1.3760 | 1.3693 | 1.2351 | 1.0155 | - |
| aa | 0.0000 | 0.0057 | 0.2197 | 0.0000 | 0.0000 | 0.2441 | - |
| bb | 0.0000 | 0.0024 | 0.0834 | 0.0852 | 0.0000 | 0.0754 | - |
| ee | 0.0564 | 0.0680 | 0.0000 | 0.1171 | 0.0619 | 0.0659 | - |
| ff | 0.0000 | 0.0593 | 0.1670 | 0.0000 | 0.0000 | 0.0000 | - |
| gg | 0.0276 | 0.0926 | 0.1028 | 0.0635 | 0.1037 | 0.0591 | - |
| hh | 0.0239 | 0.0714 | 0.1634 | 0.1792 | 0.1168 | 0.1448 | - |
| ab | 0.0000 | 0.0000 | 0.0861 | 0.1619 | 0.0000 | 0.1661 | - |
| ae | 0.0000 | 0.0194 | 0.0000 | 0.0000 | 0.0555 | 0.0952 | - |
| af | 0.0000 | 0.0000 | 0.0614 | 0.0000 | 0.0000 | 0.0000 | - |
| ah | 0.0192 | 0.0641 | 0.0686 | 0.0000 | 0.0000 | 0.1520 | - |
| ag | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.1133 | - |
| be | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.0427 | 0.0000 | - |
| bf | 0.0158 | 0.0403 | 0.1277 | 0.0000 | 0.0000 | 0.0000 | - |
| bh | 0.0000 | 0.0000 | 0.0000 | 0.0000 | 0.1120 | 0.0000 | - |
| bg | 0.0000 | 0.0000 | 0.1030 | 0.1050 | 0.0000 | 0.0000 | - |
| ef | 0.0000 | 0.0000 | 0.3220 | 0.0000 | 0.0000 | 0.1180 | - |
| eh | 0.0208 | 0.0734 | 0.0000 | 0.1659 | 0.0702 | 0.0000 | - |
| eg | 0.0411 | 0.1172 | 0.0798 | 0.0000 | 0.0000 | 0.0808 | - |
| fh | 0.0000 | 0.0762 | 0.0780 | 0.0000 | 0.0000 | 0.0000 | - |
| fg | 0.0000 | 0.0000 | 0.1998 | 0.1400 | 0.0608 | 0.0000 | - |
| gh | 0.0000 | 0.0462 | 0.0000 | 0.0772 | 0.1202 | 0.1314 | - |
| - | - | - | - | - | - | - | Lack of fit |

Tabelle B7: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = +1$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9949 | - | 0.6450 | 0.7284 | 0.7145 | 0.7727 | - |
| power max | 1.0000 | - | 0.7837 | 0.8358 | 0.8097 | 1.0000 | - |
| power min | 0.9742 | - | 0.3734 | 0.5875 | 0.4275 | 0.9829 | - |
| Power (+) | 0.9909 | - | 0.6216 | 0.7277 | 0.7073 | 0.7909 | - |
| Power (-) | 0.9968 | - | 0.6612 | 0.7291 | 0.7158 | 0.7401 | - |
| Power ($\alpha$) | 0.9783 | - | 0.5599 | 0.7263 | 0.6791 | 0.7870 | - |
| Power (-$\alpha$) | 0.9948 | - | 0.6718 | 0.7303 | 0.7031 | 0.6435 | - |
| a | 0.0000 | - | 0.3510 | 0.1266 | 0.8831 | 4.5897 | - |
| b | 0.0013 | - | 0.0509 | 0.4785 | 1.0897 | 1.7627 | - |
| e | 0.2539 | - | 1.5429 | 0.2870 | 0.3910 | 0.2779 | - |
| f | 0.0013 | - | 2.5994 | 0.0812 | 0.0105 | 0.0011 | - |
| g | 0.0695 | - | 2.3087 | 1.9936 | 1.9692 | 1.7285 | - |
| h | 0.0302 | - | 1.6869 | 1.3665 | 1.3721 | 1.1623 | - |
| aa | 0.0000 | - | 0.0000 | 0.0000 | 0.1855 | 0.5719 | - |
| bb | 0.0000 | - | 0.0000 | 0.1214 | 0.2005 | 0.3038 | - |
| ee | 0.0476 | - | 0.0000 | 0.1196 | 0.1032 | 0.1125 | - |
| ff | 0.0000 | - | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - |
| gg | 0.0000 | - | 0.1937 | 0.1661 | 0.2318 | 0.1463 | - |
| hh | 0.0219 | - | 0.1743 | 0.1704 | 0.2036 | 0.0694 | - |
| ab | 0.0000 | - | 0.0000 | 0.0000 | 0.2447 | 0.2175 | - |
| ae | 0.0000 | - | 0.0000 | 0.0000 | 0.0000 | 0.2034 | - |
| af | 0.0000 | - | 0.0000 | 0.0000 | 0.1066 | 0.0000 | - |
| ah | 0.0000 | - | 0.0816 | 0.0000 | 0.0000 | 0.1350 | - |
| ag | 0.0000 | - | 0.0000 | 0.0000 | 0.0966 | 0.3544 | - |
| be | 0.0000 | - | 0.1275 | 0.0000 | 0.0000 | 0.0000 | - |
| bf | 0.0000 | - | 0.0000 | 0.0000 | 0.0000 | 0.1050 | - |
| bh | 0.0000 | - | 0.1672 | 0.0000 | 0.0000 | 0.0000 | - |
| bg | 0.0194 | - | 0.1172 | 0.0939 | 0.2109 | 0.0000 | - |
| ef | 0.0000 | - | 0.3784 | 0.0000 | 0.0631 | 0.0000 | - |
| eh | 0.0000 | - | 0.2038 | 0.0000 | 0.0000 | 0.0775 | - |
| eg | 0.0303 | - | 0.0000 | 0.0000 | 0.0000 | 0.0000 | - |
| fh | 0.0000 | - | 0.0000 | 0.0000 | 0.0634 | 0.0000 | - |
| fg | 0.0153 | - | 0.1762 | 0.0000 | 0.0000 | 0.0000 | - |
| gh | 0.0000 | - | 0.0000 | 0.0000 | 0.0628 | 0.0000 | - |
| - | - | Lack of fit | - | - | - | - | Lack of fit |

Tabelle B8: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = 0$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9949 | 0.8007 | 0.6497 | - | 0.7877 | 0.7861 | 0.9984 |
| power max | 1.0000 | 0.9077 | 0.8025 | - | 0.8681 | 0.9176 | 1.0000 |
| power min | 0.9771 | 0.7010 | 0.4032 | - | 0.6628 | 0.4751 | 0.9878 |
| Power (+) | 0.9912 | 0.7980 | 0.6315 | - | 0.7796 | 0.8027 | 0.9988 |
| Power (-) | 0.9968 | 0.8035 | 0.6766 | - | 0.7920 | 0.7578 | 0.9981 |
| Power ($\alpha$) | 0.9796 | 0.7937 | 0.6208 | - | 0.7546 | 0.8030 | 0.9999 |
| Power (-$\alpha$) | 0.9953 | 0.8091 | 0.7482 | - | 0.7896 | 0.6759 | 0.9978 |
| a | 0.0060 | 0.0652 | 0.4519 | - | 0.0098 | 3.6725 | 0.0433 |
| b | 0.0183 | 0.0519 | 0.0116 | - | 0.3922 | 1.2550 | 0.0097 |
| e | 0.2406 | 0.1823 | 1.5806 | - | 0.1582 | 0.1947 | 0.0090 |
| f | 0.0000 | 0.0559 | 2.7147 | - | 0.0286 | 0.0000 | 0.0080 |
| g | 0.0803 | 1.4901 | 2.3085 | - | 1.5045 | 1.4975 | 0.0557 |
| h | 0.0313 | 0.9934 | 1.6549 | - | 1.0501 | 1.1319 | 0.0213 |
| aa | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.3338 | 0.0000 |
| bb | 0.0000 | 0.0000 | 0.0686 | - | 0.0000 | 0.1913 | 0.0000 |
| ee | 0.0457 | 0.1627 | 0.1149 | - | 0.1524 | 0.1218 | 0.0050 |
| ff | 0.0000 | 0.0970 | 0.0000 | - | 0.0000 | 0.0000 | 0.0000 |
| gg | 0.0000 | 0.0000 | 0.1214 | - | 0.1445 | 0.0976 | 0.0082 |
| hh | 0.0000 | 0.0817 | 0.1258 | - | 0.0907 | 0.1776 | 0.0000 |
| ab | 0.0242 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 | 0.0131 |
| ae | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.1000 | 0.0000 |
| af | 0.0000 | 0.0000 | 0.0000 | - | 0.0998 | 0.0000 | 0.0056 |
| ah | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.1419 | 0.0084 |
| ag | 0.0000 | 0.0778 | 0.0000 | - | 0.0000 | 0.2569 | 0.0169 |
| be | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 | 0.0072 |
| bf | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 | 0.0000 |
| bh | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 | 0.0000 |
| bg | 0.0000 | 0.0772 | 0.0000 | - | 0.0842 | 0.0000 | 0.0000 |
| ef | 0.0000 | 0.1550 | 0.4475 | - | 0.0000 | 0.0000 | 0.0000 |
| eh | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0803 | 0.0000 |
| eg | 0.0236 | 0.0812 | 0.1231 | - | 0.0000 | 0.0000 | 0.0097 |
| fh | 0.0000 | 0.0000 | 0.0000 | - | 0.0000 | 0.0000 | 0.0000 |
| fg | 0.0000 | 0.0000 | 0.2075 | - | 0.0000 | 0.0000 | 0.0081 |
| gh | 0.0000 | 0.0600 | 0.1353 | - | 0.0711 | 0.0000 | 0.0084 |
| - | - | - | - | Lack of fit | - | - | - |

Tabelle B9: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = -1$

| **Metrik** | **Power $\beta_0$** | **Power $\beta_1$** | **Power $\beta_2$** | **Power $\beta_{12}$** | **Power $\beta_{11}$** | **Power $\beta_{22}$** | **Power Model** |
|---|---|---|---|---|---|---|---|
| power intercept value | 0.9949 | 0.8035 | - | 0.7330 | - | 0.8378 | 0.9990 |
| power max | 1.0000 | 0.8784 | - | 0.8544 | - | 0.9286 | 1.0000 |
| power min | 0.9753 | 0.7101 | - | 0.5842 | - | 0.6034 | 0.9953 |
| Power (+) | 0.9918 | 0.7998 | - | 0.7345 | - | 0.8424 | 0.9990 |
| Power (-) | 0.9967 | 0.8031 | - | 0.7286 | - | 0.8177 | 0.9990 |
| Power ($\alpha$) | 0.9828 | 0.7819 | - | 0.7297 | - | 0.8111 | 0.9989 |
| Power (-$\alpha$) | 0.9969 | 0.7912 | - | 0.7130 | - | 0.7411 | 0.9989 |
| a | 0.0010 | 0.0699 | - | 0.1136 | - | 2.4390 | 0.0192 |
| b | 0.0038 | 0.0659 | - | 0.7811 | - | 0.8272 | 0.0055 |
| e | 0.2297 | 0.1238 | - | 0.2768 | - | 0.0821 | 0.0063 |
| f | 0.0077 | 0.0349 | - | 0.0462 | - | 0.1113 | 0.0096 |
| g | 0.0584 | 1.2813 | - | 1.8702 | - | 1.2301 | 0.0336 |
| h | 0.0427 | 1.0310 | - | 1.2671 | - | 0.8845 | 0.0125 |
| aa | 0.0000 | 0.0000 | - | 0.0613 | - | 0.2086 | 0.0000 |
| bb | 0.0000 | 0.0000 | - | 0.1732 | - | 0.1142 | 0.0000 |
| ee | 0.0369 | 0.0706 | - | 0.0745 | - | 0.0000 | 0.0000 |
| ff | 0.0000 | 0.0000 | - | 0.0000 | - | 0.0000 | 0.0000 |
| gg | 0.0000 | 0.1056 | - | 0.1212 | - | 0.1036 | 0.0000 |
| hh | 0.0000 | 0.0931 | - | 0.1762 | - | 0.1711 | 0.0082 |
| ab | 0.0000 | 0.0000 | - | 0.0000 | - | 0.1048 | 0.0000 |
| ae | 0.0000 | 0.0000 | - | 0.0761 | - | 0.0000 | 0.0000 |
| af | 0.0000 | 0.0658 | - | 0.0000 | - | 0.0000 | 0.0000 |
| ah | 0.0123 | 0.0000 | - | 0.0000 | - | 0.1023 | 0.0000 |
| ag | 0.0000 | 0.0789 | - | 0.0000 | - | 0.1142 | 0.0000 |
| be | 0.0000 | 0.0000 | - | 0.0798 | - | 0.0000 | 0.0000 |
| bf | 0.0123 | 0.0000 | - | 0.0101 | - | 0.1023 | 0.0000 |
| bh | 0.0177 | 0.0000 | - | 0.0000 | - | 0.0000 | 0.0000 |
| bg | 0.0183 | 0.0000 | - | 0.0000 | - | 0.0983 | 0.0000 |
| ef | 0.0123 | 0.0000 | - | 0.0000 | - | 0.1023 | 0.0000 |
| eh | 0.0181 | 0.0123 | - | 0.0000 | - | 0.0000 | 0.0000 |
| eg | 0.0208 | 0.0000 | - | 0.0000 | - | 0.0000 | 0.0000 |
| fh | 0.0000 | 0.0000 | - | 0.0000 | - | 0.0000 | 0.0073 |
| fg | 0.0177 | 0.0714 | - | 0.1136 | - | 0.0670 | 0.0000 |
| gh | 0.0000 | 0.0000 | - | 0.1120 | - | 0.0848 | 0.0000 |
| - | - | - | Lack of fit | - | Lack of fit | - | - |

# Anhang C Stabilitäts- und Konvergenzanalysen der Design-Modifikationen

In diesem Anhang sind ergänzende statistische Visualisierungen zur Bewertung der geometrischen Design-Verzerrungen (vergleiche Abschnitt 5.3) aufgeführt.

Tabelle C1: Simulationsergebnisse: Schätzvarianz (MSE) der einzelnen Koeffizienten bei SNR = 1,33.

| **Szenario (Störfall)** | $\hat{\beta}_0$ | $\hat{\beta}_1$ | $\hat{\beta}_2$ | $\hat{\beta}_{12}$ | $\hat{\beta}_{11}$ | $\hat{\beta}_{22}$ |
|---|---|---|---|---|---|---|
| Referenz (Orthogonal) | 6,95 | 6,97 | 7,12 | 13,89 | 7,04 | 6,99 |
| Fall I: Shift (-20 %) | 6,87 | 8,03 | 7,08 | 13,96 | 9,33 | 7,13 |
| Fall I: Shift (+20 %) | 6,90 | 6,61 | 7,07 | 14,33 | 4,98 | 6,88 |
| Fall I: FC | 6,88 | 8,61 | 6,97 | 14,18 | 10,37 | 7,22 |
| Fall II: Korrelation (leicht) | 6,88 | 7,13 | 6,91 | 14,00 | 7,05 | 7,02 |
| Fall II: Korrelation (stark) | 6,97 | 8,08 | 6,78 | 11,73 | 8,62 | 7,73 |
| Fall III: Scatter (±10 %) | 6,84 | 7,15 | 6,71 | 13,95 | 7,36 | 5,89 |
| Fall IV: SP | 7,16 | 11,91 | 6,91 | 13,87 | 12,29 | 7,81 |
| Fall IV: ZP | 7,95 | 6,94 | 7,05 | 14,15 | 7,28 | 7,31 |

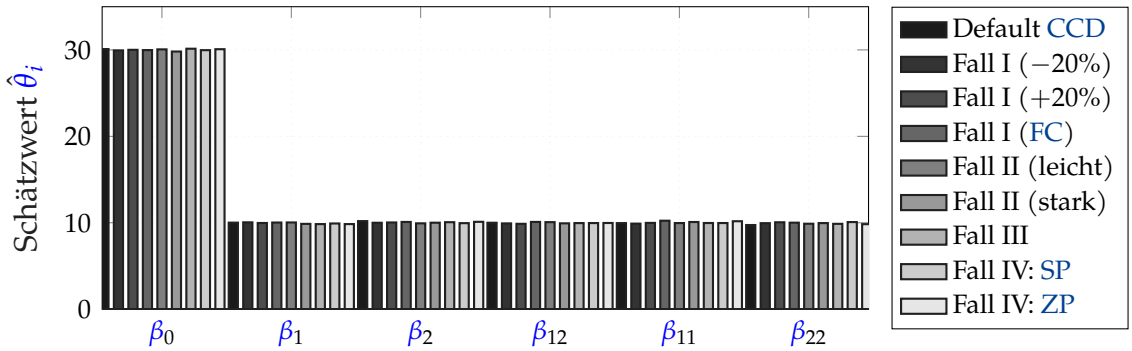


Abbildung C1: Absolute Schätzwerte der Modellkoeffizienten inklusive der 95 %-Konfidenzintervalle für SNR = 1.

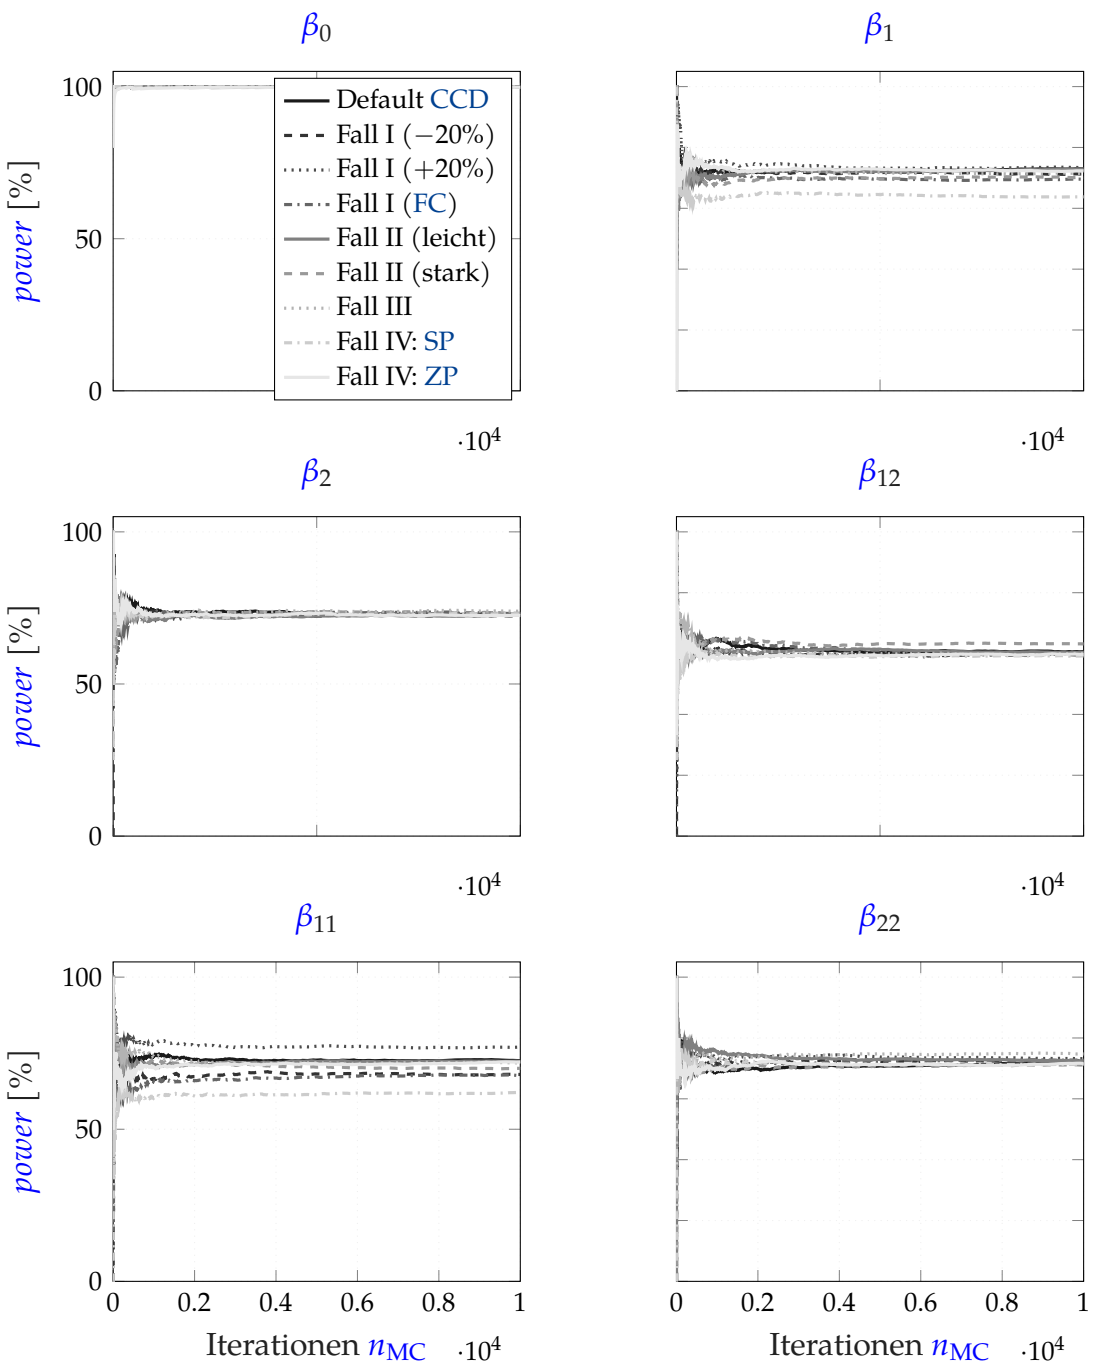


Abbildung C2: Laufende Konvergenz der Trennschärfe für alle Modellparameter. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar.

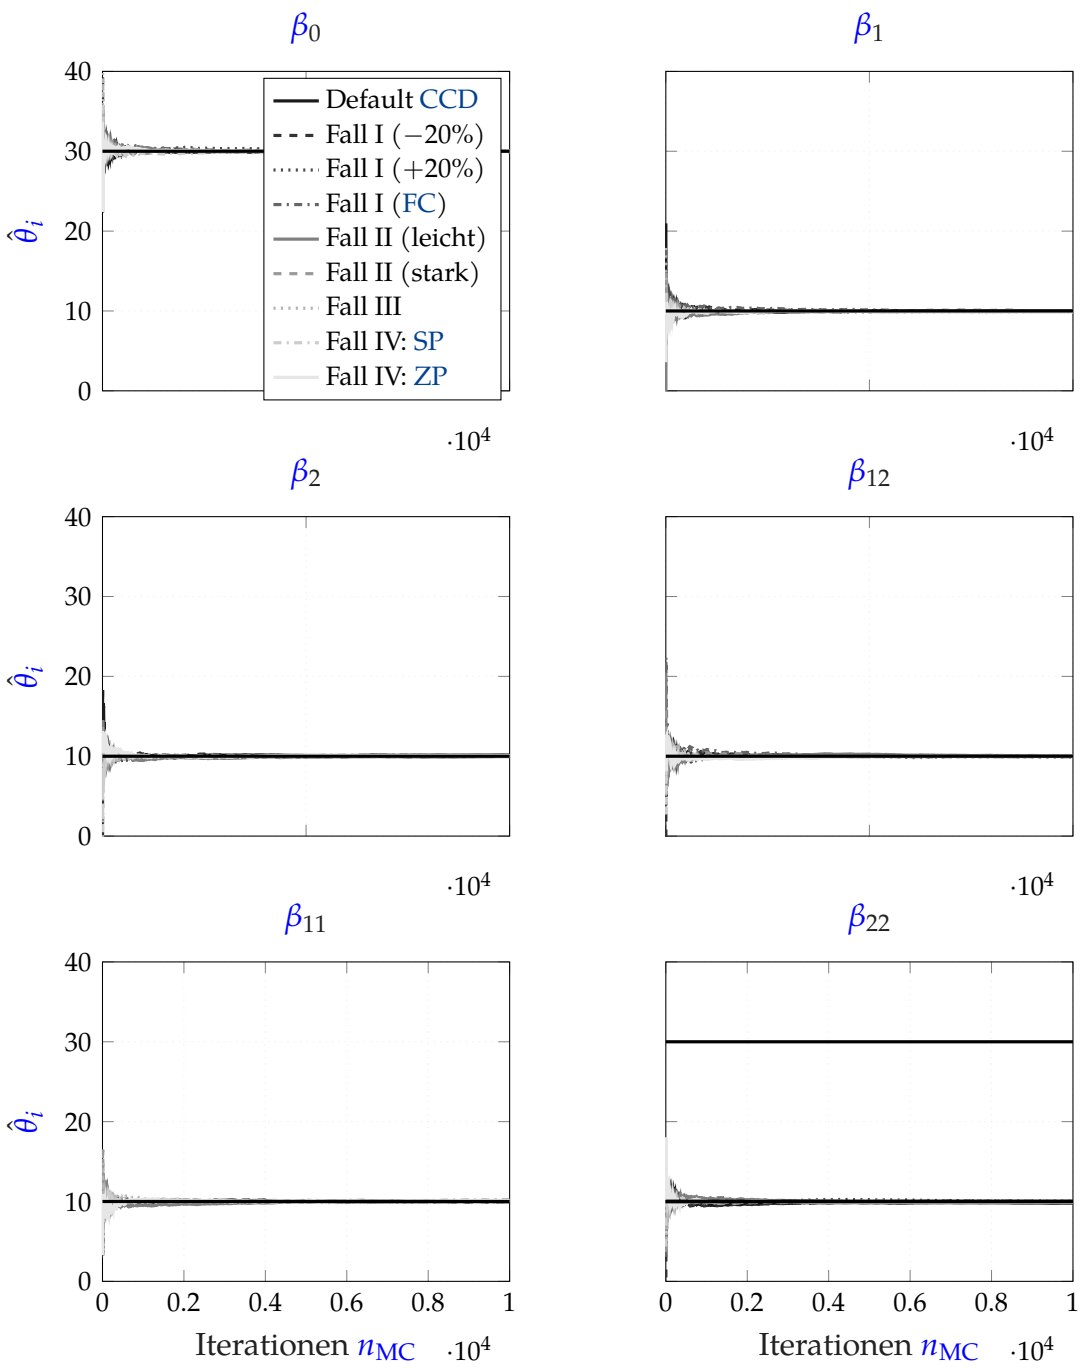


Abbildung C3: Konvergenz der OLS-Parameterschätzwerte ($\hat{\beta}_i$). Alle Modelle erweisen sich unabhängig von der geometrischen Verzerrung als erwartungstreu. Die Schätzungen stabilisieren sich bei der $n_{\mathrm{MC}} = 10^4$ reproduzierbar.

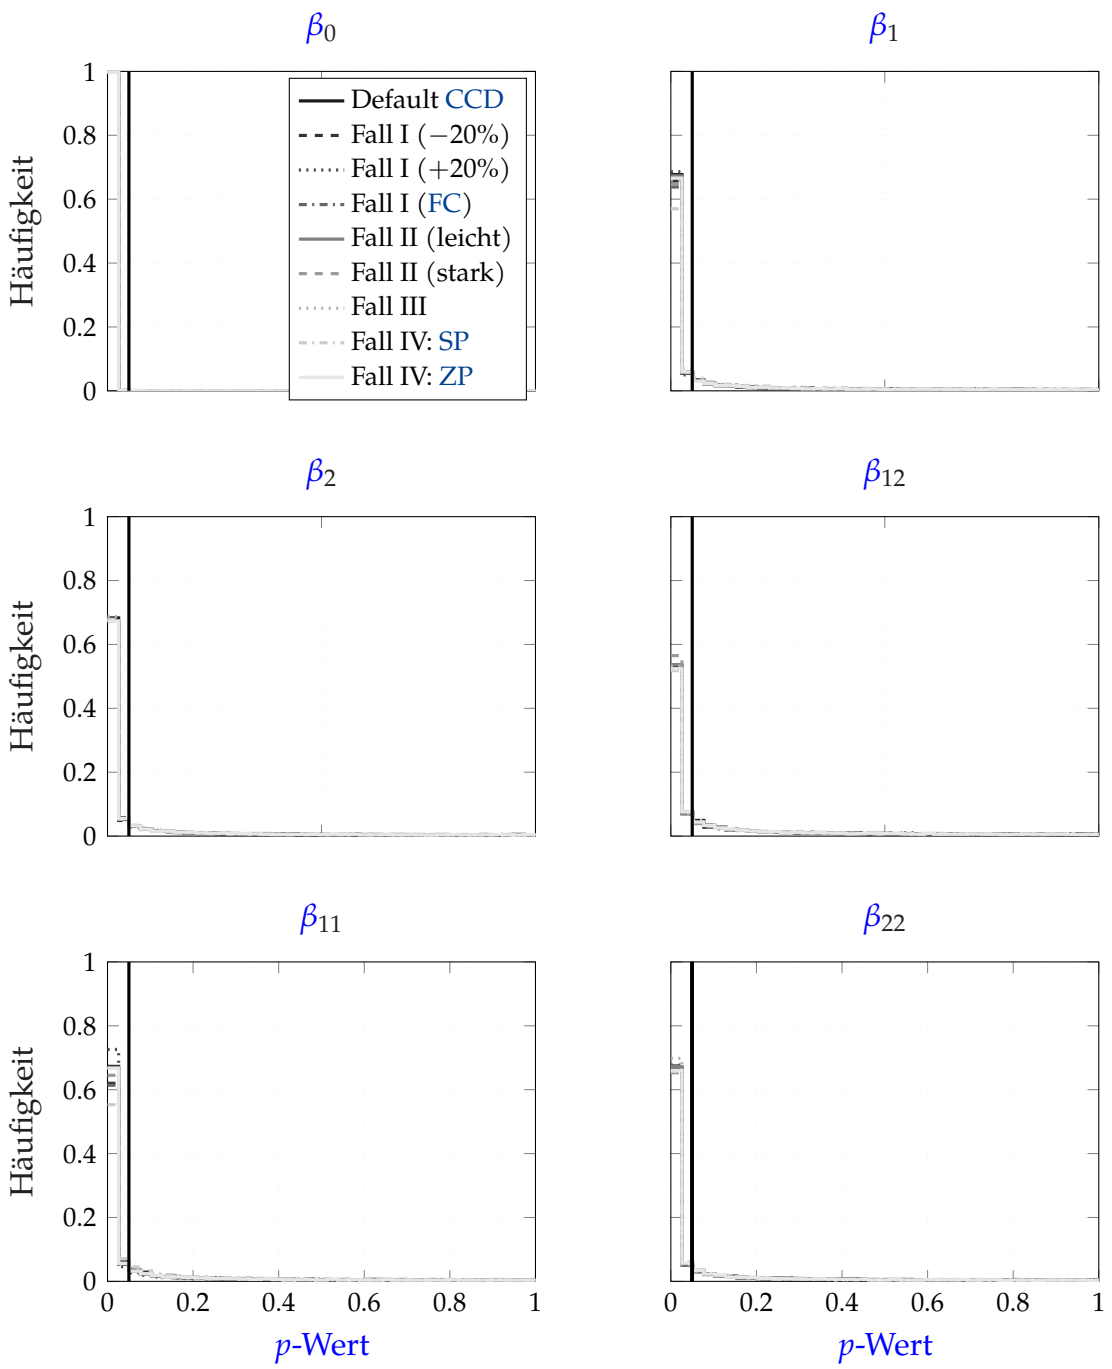


Abbildung C4: Relative Häufigkeiten der in der Simulation ermittelten $p$-Werte der Signifikanztests.

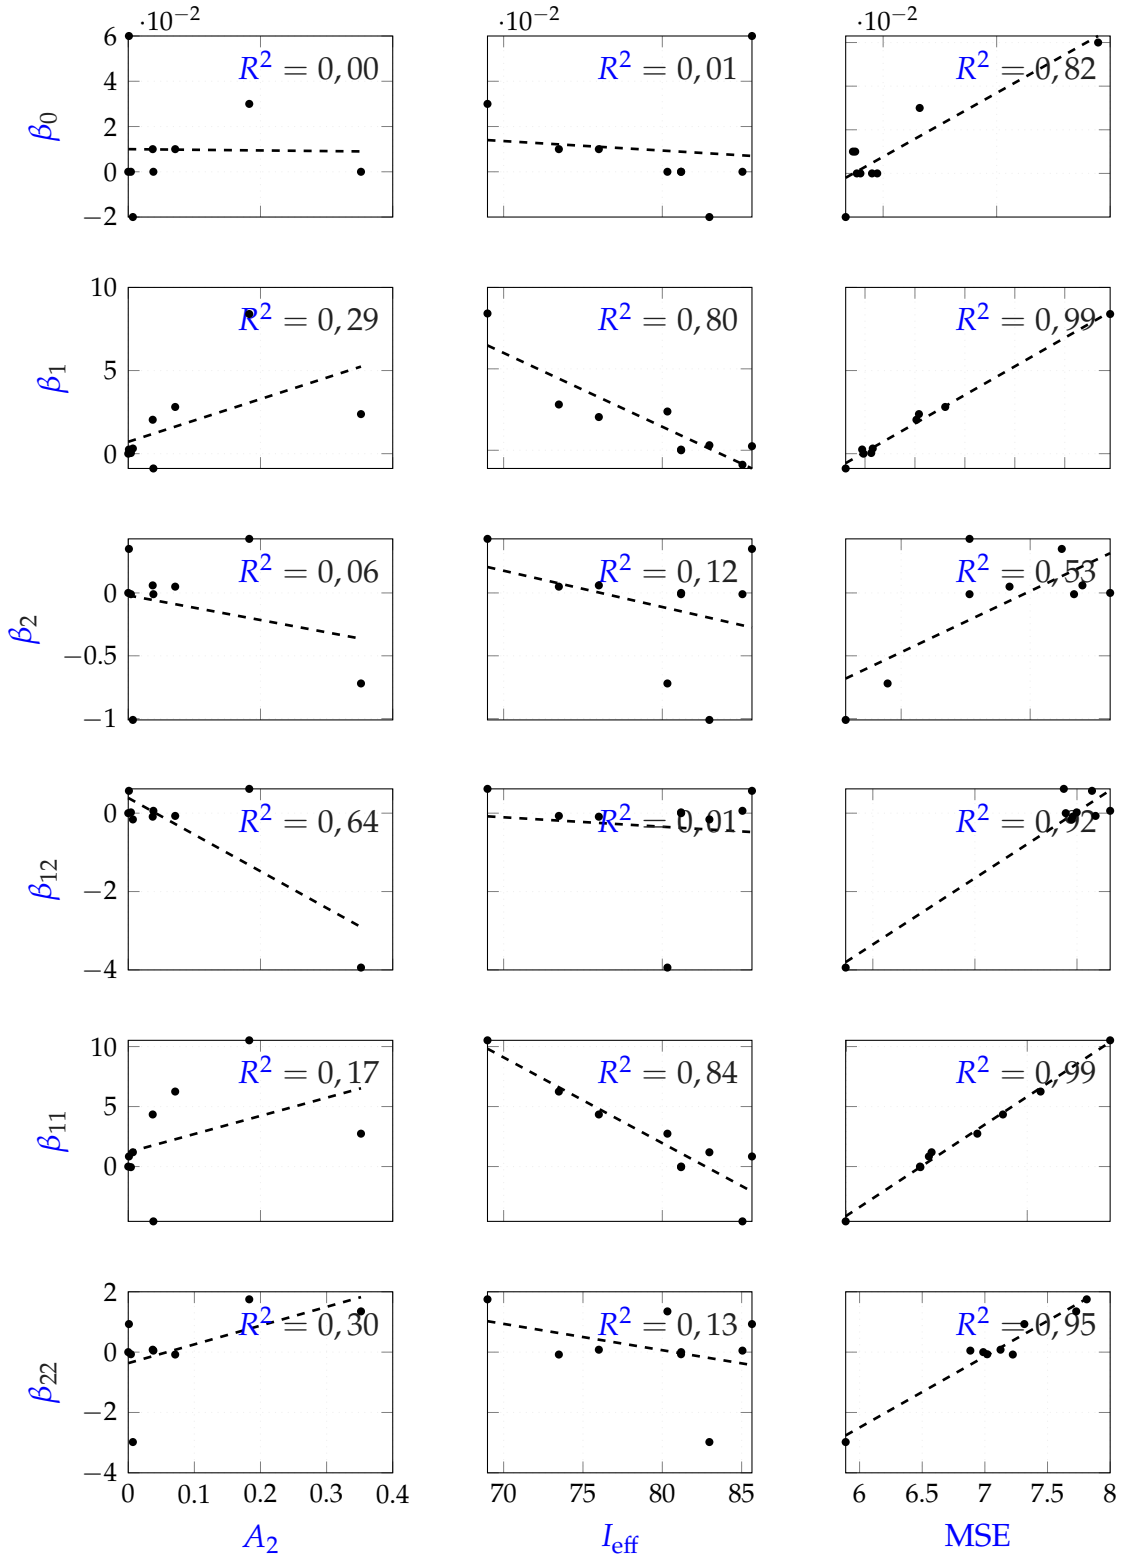


Abbildung C5: Korrelierende Metriken zur prozentualen Trennschärfe-Änderung ($\Delta power$ [%]) über alle Koeffizienten und Szenarien ergänzend zu Abbiildung 5.7.

## Anhang C.1 Szenarien bei Arbeitspunkt SNR= 1

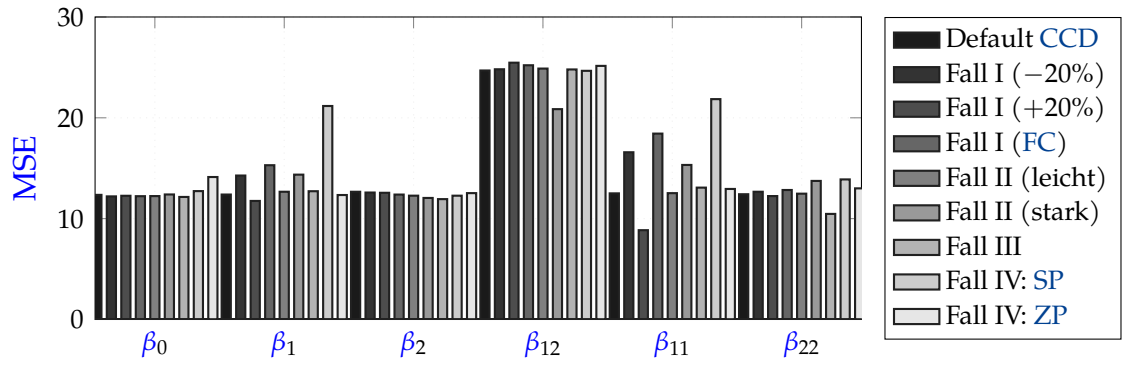


Abbildung C6: Güte der Schätzer (MSE) für SNR = 1.

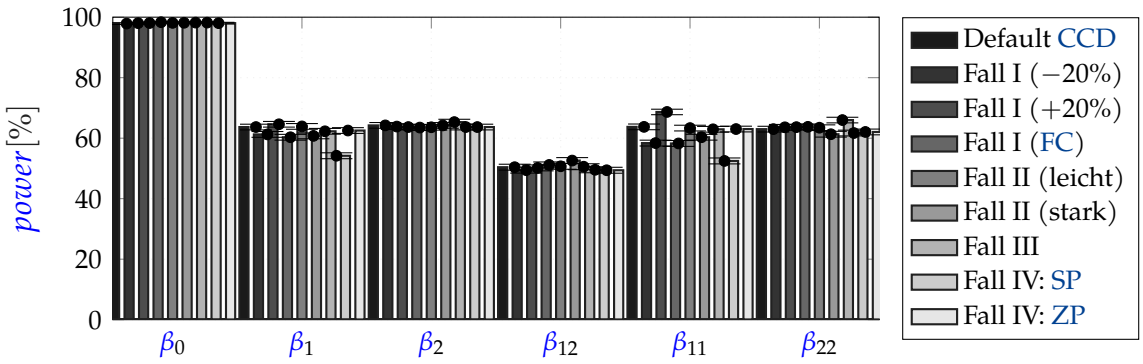


Abbildung C7: Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der Störszenarien für SNR = 1.