

Effiziente Multivariate Lebensdauertests

Efficient Multivariate Life Tests

Der Fakultät Konstruktions-, Produktions- und Fahrzeugtechnik
der Universität Stuttgart
zur Erlangung der Würde eines Doktor-Ingenieurs (Dr.-Ing.) vorgelegte Abhandlung

von
Marco Arndt, M.Sc.
aus Ravensburg

Hauptberichter: PD Dr.-Ing. habil. Martin Dazer
Mitberichter: Prof. Dr.-Ing. Michael Hanss

Tag der mündlichen Prüfung:

Institut für Maschinenelemente der Universität Stuttgart

2026

Vorwort

Die vorliegende Arbeit entstand während meiner Tätigkeit als akademischer Mitarbeiter am Institut für Maschinenelemente (IMA) der Universität Stuttgart.

Mein größter Dank gilt meinem Doktorvater und Mentor Herrn PD Dr.-Ing. habil. Martin Dazer. Als sein Stellvertreter im Fachbereich Zuverlässigkeitstechnik durfte ich neben seinem herausragenden Fachwissen eine außergewöhnliche Förderung erfahren. Seine stetige Unterstützung, die unzähligen Diskussionen und sein uneingeschränktes Vertrauen legten das absolute Fundament für diese Arbeit. Für dieses freundschaftliche Miteinander bin ich zutiefst dankbar.

Besonderer Dank gebührt Herrn Prof. Dr.-Ing. Bernd Bertsche, dem ehemaligen Leiter des Instituts für Maschinenelemente. Er prägte zu meinem Beginn am IMA eine einzigartige Institutskultur, die mir den kreativen und methodischen Freiraum für diese Forschungsarbeit überhaupt erst eröffnete.

Herzlich danke ich Herrn Prof. Dr.-Ing. Michael Hanss für die Übernahme des Mitberichts und die kritische Durchsicht meiner Arbeit, sowie Herrn Prof. Dr.-Ing. André Casal Kulzer für die Übernahme des Prüfungsvorsitzes.

Für die hervorragende Zusammenarbeit im Industrieprojekt danke ich Herrn Dr. sc. ETH Wolfram Raither. Unser freundschaftlicher Austausch und die fruchtbaren Gespräche waren stets eine wertvolle Inspirationsquelle.

Mein Dank gilt ebenso allen Mitarbeiterinnen und Mitarbeitern des IMA für das einzigartige Arbeitsklima. Allen voran danke ich Philipp Mell für den stets fachlich bereichernden und freundschaftlichen Austausch sowie für das akribische Korrekturlesen dieser Arbeit. Giuseppe Mannone, Kim Hintz, Dr.-Ing. Alexander Grundler und Erich Rittmaier danke ich für die wertvollen Diskussionen und die großartige gemeinsame Zeit am Institut. Ein besonderer Dank gilt Dr.-Ing. Kevin Lucan für das von ihm initiierte vertrauensvolle Umfeld und die gelebte unternehmerische Freiheit, die meinen Weg und den vieler ehemaliger Kollegen nachhaltig und mit großer Freude prägen. Gleichmaßen danke ich allen studentischen Hilfskräften und Verfassern von Abschlussarbeiten für ihre tatkräftige Unterstützung.

Der wichtigste Dank gebührt meiner Familie. Meiner Ehefrau Marei und meiner Tochter Karla danke ich von ganzem Herzen für den unermüdlichen Rückhalt und die grenzenlose Geduld in all den Phasen, in denen diese Arbeit meine Zeit beansprucht hat.

Ravensburg, im Oktober 2026

Marco Arndt

Kurzfassung

Die Zuverlässigkeitstechnik bedient sich beschleunigter Lebensdauererprobungen (*Accelerated Life Testing, ALT*), um Entwicklungszyklen zu reduzieren. Da das Ausfallverhalten technischer Systeme zumeist durch mehrere interagierende Belastungen determiniert wird, erfordert die zugehörige empirische Modellierung der Lebensdauer zwingend die multivariate statistische Versuchsplanung (*Design of Experiments, DoE*) mittels *Response Surface Methodology (RSM)*, wobei sich für technische Anwendungen das *Central Composite Design (CCD)* als Standard-Testplan etabliert hat. Dessen ungeprüfte Übertragung auf ALT birgt jedoch einen fundamentalen methodischen Konflikt: Während klassische Versuchspläne auf geometrische Symmetrie und Interpolation im Zentrum des Versuchsraums ausgelegt sind, erfordert die Lebensdauererprobung prinzipbedingt die Extrapolation von hohen Prüflasten auf moderate Feldbedingungen. Zudem verletzen Lebensdauerdaten durch asymmetrische Weibull-Verteilungen und Zensierungen die klassischen Prämissen normalverteilter Residuen.

Die vorliegende Dissertation adressiert diesen Konflikt durch ein ganzheitliches methodisches Framework zur Auslegung hocheffizienter Lebensdauertests. Im informationstheoretischen Kern der Arbeit wird per *Monte-Carlo-Simulation (MCS)* nachgewiesen, dass das CCD eine ausgeprägte topologische Resilienz gegenüber praxisinduzierten Orthogonalitätsabweichungen hinsichtlich der relevanten Metriken zur Bewertung der Modellierungsfähigkeit aufweist. Diese nachgewiesene Fehlertoleranz erschließt ein wertvolles geometrisches Gestaltungsbudget, welches den Übergang zur adaptiven Versuchsplanung legitimiert. Anstatt Versuchspunkte lediglich zur passiven Kostensenkung zu eliminieren, werden freigewordene Stützstellen proaktiv als Extrapolations-Ankerpunkte in Richtung des Feldbereichs verlagert. Dieser methodische Brückenbau - formalisiert im neu entwickelten *Extrapolation-Variance minimized Accelerated Lifetime Testing Design (EmALT)* - stützt das Regressionsmodell auf dem Extrapolationspfad empirisch ab. Zur richtungsabhängigen Quantifizierung der resultierenden Prognosevarianz wird der *Extrapolation Variance Graph (EVG)* eingeführt.

Dieser belegt formal, dass die Allokation der Ankerpunkte die Unsicherheit am anvisierten Feld-Betriebspunkt signifikant reduziert.

Den Abschluss bildet die Synthese mit einem Kostenmodell, welches den inhärenten Zielkonflikt der Lebensdauererprobung quantifiziert: Eine gesteigerte Prognosegüte im Feldbereich verursacht durch die reduzierte Stressbeschleunigung exponentiell höhere Prüfstandskosten. Die Arbeit etabliert hierfür den *Economic Extrapolation Power Index (EPI)* als integrale Bewertungsmetrik. Eine empirische Fallstudie an realen Prüfstandsdaten demonstriert die praktische Leistungsfähigkeit der Methodik abschließend anhand prädiktiver *Confirmation Experiments*. Die Dissertation weist somit nach, dass sich Effizienz in der Versuchsplanung nicht über die bedingungslose Minimierung von Prüfläufen definiert, sondern sich durch das ökonomische Optimum zwischen minimalem Ressourceneinsatz und der zwingenden Absicherung der statistischen Vorhersagegüte im Einsatzbereich manifestiert.

Abstract

Reliability engineering employs accelerated life testing (*Accelerated Life Testing, ALT*) to compress development cycles. Because the failure behavior of technical systems is typically governed by multiple interacting loads, the corresponding empirical modeling of lifetime strictly requires multivariate statistical design of experiments (*Design of Experiments, DoE*) utilizing *Response Surface Methodology (RSM)*. Within this context, the *Central Composite Design (CCD)* has emerged as the standard experimental design for technical applications. However, applying this design to ALT without scrutiny introduces a fundamental methodological conflict: While classical experimental designs are optimized for geometric symmetry and interpolation within the center of the design space, life testing inherently necessitates extrapolation from elevated test loads to moderate field conditions. Furthermore, lifetime data—characterized by asymmetric Weibull distributions and censoring—violate the classical premises of normally distributed residuals.

This dissertation addresses this conflict by introducing a comprehensive methodological framework for the design of highly efficient lifetime tests. In the information-theoretic core of the study, *Monte Carlo Simulation (MCS)* demonstrates that the CCD exhibits pronounced topological resilience against practice-induced deviations from orthogonality, as evaluated by relevant metrics for modeling capability. This proven fault tolerance unlocks a valuable geometric design budget, which legitimizes the transition toward adaptive experimental design. Rather than merely eliminating design points for passive cost reduction, available support points are proactively relocated as extrapolation anchor points toward the expected field operation domain. This methodological bridging—formalized in the newly developed *Extrapolation-Variance minimized Accelerated Lifetime Testing Design (EmALT)*—empirically anchors the regression model along the extrapolation path. To quantify the resulting prediction variance on a directional basis, the *Extrapolation Variance Graph (EVG)* is introduced. This metric formally substantiates that the allocation of anchor points significantly reduces uncertainty at the targeted field operating point. The framework concludes with a synthesis

incorporating a cost model that quantifies the inherent trade-off in life testing: Enhanced prediction accuracy in the field domain incurs exponentially higher test rig costs due to the reduced stress acceleration. To address this, the study establishes the *Economic Extrapolation Power Index (EPI)* as an integral evaluation metric. Finally, an empirical case study utilizing real test rig data demonstrates the practical capability of the methodology through predictive *Confirmation Experiments*.

Consequently, this dissertation demonstrates that efficiency in experimental design is not defined by the unconditional minimization of test runs, but rather manifests as the economic optimum between minimizing resource expenditure and rigorously ensuring statistical prediction quality within the intended application domain.

Inhaltsverzeichnis

Vorwort	iii
Kurzfassung	v
Abstract	vii
Nomenklatur	xiii
Abkürzungen	xiii
Indizes	xiv
Formelzeichen	xvi
1 Einleitung	1
1.1 Forschungsperspektive und Problembeschreibung	2
1.2 Beitrag dieser Arbeit	3
1.3 Aufbau der Arbeit	5
2 Stand der Technik und Forschung	7
2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie	7
2.1.1 Begriffe und Definitionen	8
2.1.2 Deskriptive Statistik für Lebensdauerdaten	9
2.1.3 Parametrische Lebensdauermodelle	10
2.1.4 Parameterschätzverfahren	12
2.2 Statistische Versuchsplanung und Modellbildung	14
2.2.1 Grundlagen zur statistischen Versuchsplanung	15
2.2.2 Parameter-Screening	16
2.2.3 Statistische Versuchsplanung zur Lebensdauererprobung	17
2.2.4 Strategische Vorgehensweisen	21
2.2.5 Bewertung und Optimierung von Versuchsplanung	22
2.2.6 Statistische Modellbildung	36

3	Testplanung für die multivariate Lebensdauererprobung	45
3.1	Bewertung des Forschungsstandes	45
3.1.1	Das methodische Paradoxon ALT-optimaler GLM-Designs	46
3.1.2	Diskrepanz zwischen geometrischer Optimalität und stochastischer Trennschärfe	47
3.1.3	Synthese des Forschungsstandes und Ableitung der Forschungslücke	49
3.2	Forschungsfragen und wissenschaftliche Zielsetzung	51
3.3	Methodische Forschungsarchitektur	53
4	Statistische Effektivität als Fundament effizienter Lebensdauertests	55
4.1	Methodische Simulationsarchitektur und pseudo-physikalisches Modell	56
4.1.1	Pseudo-physikalisches Ground-Truth-Modell	56
4.1.2	Simulationsarchitektur und Monte-Carlo-Inferenz	57
4.2	Effektivität von Versuchsplänen mit Orthogonalitätsabweichungen	60
4.2.1	Potenzialanalyse geometrischer und stochastischer Einflussgrößen	61
4.2.2	Ergebnisse der Potenzialanalyse und Quantifizierung der Trennschärfe	66
4.2.3	Generische Auswirkungen relevanter Orthogonalitätsabweichungen	68
4.2.4	Fazit: Statistische Effektivität als Basis der explorativen Versuchsplanung	79
4.3	Adaptive Versuchsplanung zur Extrapolationsabsicherung	80
4.3.1	Die Scaled Prediction Variance als Prognosemetrik	81
4.3.2	Richtungsabhängige Bewertung: Der Extrapolation Variance Graph (EVG)	85
4.4	Kostenstruktur der Lebensdauererprobung	90
4.5	Übertragung auf multivariate Lebensdauermodelle	94
4.5.1	Generische Auswirkungen asymmetrischer Versuchsplanung	98
4.5.2	Effizientes Lifetime Design of Experiments (L-DoE) und der Economic Extrapolation Power Index	102
4.6	Fazit	110

5 Empirische Anwendung der Extrapolationsabsicherung	113
5.1 Modellschätzung und Anpassungsgüte	114
5.1.1 Residuenanalyse und Verifikationsdiagnostik	117
5.2 Konsequenzen für die Zuverlässigkeitsmodellierung	119
5.2.1 Confirmation Experiments: Der statistische Härtetest	120
5.2.2 Ökonomische Schlussfolgerung und industrieller Business Case	121
6 Zusammenfassung und Ausblick	123
6.1 Diskussion	125
6.2 Ausblick	126
Literatur	127
Anhang	139
A Sensitivitätsanalyse	139
B Orthogonalitäts-Analysen der Design-Modifikationen	148
B.1 Orthogonalitäts-Analysen aus Abschnitt 4.2.3	148
B.2 Szenarien bei Arbeitspunkt SNR= 1	155
B.3 Effizienzanalysen aus Abschnitt 4.5.2	156

Nomenklatur

Abkürzungen

<i>cdf</i>	Cumulative Distribution Function
<i>pdf</i>	Probability Density Function
AFT	Accelerated Failure Time
ALT	Accelerated Lifetime Testing
ANOVA	Varianzanalyse, engl. Analysis of Variance
AP	Ankerpunkt
CCD	Central Composite Design
CI	Confidence Interval
CU	Currency Units (normierte Geldeinheiten)
DoE	Design of Experiments
DSD	Definitive Screening Design
DSM	Design-Structure-Matrix
EmALT	Extrapolationvariance minimized Accelerated Lifetime Testing
EoL	End-of-Life
EPI	Economic Extrapolation Power Index
EVG	Extrapolation Variance Graph
FC	Face Centered
FDS	Fraction of Design Space
GLL	Generalized Log-Linear
GLM	Generalized Linear Model
ILP	Integer Linear Programming

IMA	Institut für Maschinenelemente
IWLS	Iteratively Weighted Least Squares
KPI	Leistungsindikator, engl. Key Performance Indicator
L-DoE	Lifetime Design of Experiments
LR-Test	Likelihood-Ratio Test
MCS	Monte-Carlo-Simulation
MLE	Maximum Likelihood Estimation
MSE	Mean Squared Error
OLS	Ordinary Least Squares
OMARS	Orthogonal Minimally Aliased Response Surface
PH	Proportional Hazard
PI	Prediction Interval
RSD	Response Surface Design
RSM	Response Surface Methodology
SNR	Signal-zu-Rausch Verhältnis, engl. Signal-to-Noise Ratio
SP	Sternpunkt
SPV	Scaled Prediction Variance
UPV	Unscaled Prediction Variance
VDG	Variance Dispersion Graph
VIF	Varianz-Inflations-Faktor
ZP	Zentralpunkt

Indizes

0	Zeitpunkt $t = 0$ Regressionskonstante Position im Versuchsraum
Σ	Gesamtkosten

AP	Ankerpunkt
A	Umgebungskosten (Ambient Conditions)
BC	Box-Cox-Transformation
B	Basis-Prüfstandshardware
C	Steuerungstechnik (Control)
D	Sternpunktabstand CCD
E	Energiekosten
F	Faktorieller Punkt
H	Hilfs- und Betriebsstoffe
I	Messtechnik (Instrumentation)
L	Labor- und Infrastrukturkosten
MC	Monte-Carlo-Simulation
M	Instandhaltungskosten (Maintenance)
O	Personalkosten (Operator)
SP	Sternpunkt
S	Laufende Durchführungskosten (Size of Testing)
T	Prüfstandskosten (Test Equipment)
V	Transformation
ZP	Zentralpunkt
a	Simulationsfaktor: Sternpunkt-Abstand
b	Simulationsfaktor: Sternpunkt-Shift
c	Simulationsfaktor: Zentralpunkte
d	Simulationsfaktor: Sternpunkte
error	Fehler 2. Art (Wahrscheinlichkeit für ein falsch-negatives Ergebnis)
e	Simulationsfaktor: System-Rauschen
f	Simulationsfaktor: Effekt-Verhältnis
g	Simulationsfaktor: Mess-Rauschen

h	Simulationsfaktor: Signifikanzniveau
m	Modellbezogen
nc	Nichtzentral (non-central)
nom	Nominale Werte
ob	Beobachtet (Observed)
sim	Simulationsergebnisse
i	Laufvariable
j	Laufvariable
k	Laufvariable (für Faktor-Indizierung)
l	Laufvariable
o	Obere Grenze des Vertrauensbereichs
q	Quantilwert
u	Untere Grenze des Vertrauensbereichs
z	Zensierungsindikator

Formelzeichen

A_2	Nicht-Orthogonalitätsindikator (A_2 -Kriterium)
A_{opt}	A-Optimalitätskriterium (Spur-Minimierung)
α	Signifikanzniveau
	Abstand der Sternpunkte (Axial Points)
b	Weibull-Formparameter (Weibull-Modul)
β	Koeffizientenmatrix
β	Regressionskoeffizient, Modellparameter
	Fehler 2.Art
C	Kosten (allgemein)
Ω	Kandidatenmenge (Menge aller möglichen Faktorstufenkombinationen)

$\chi^2(\cdot)$	Chi-Quadrat-Verteilung
$\text{Cov}[\cdot]$	Covarianz-Operator
COVRATIO	Einflussstatistik auf Schätzwerte (Covariance Ratio)
D	Cook's Distanz
d_f	Anzahl der Freiheitsgrade
D_{opt}	D-Optimalitätskriterium (Determinanten-Maximierung)
γ	Binäre Entscheidungsvariable für die Design-Optimierung (1 = Versuchspunkt ausgewählt)
δ	Statusindikator (1=Ausfall, 0=Zensiert)
DFBETAS	Einflussstatistik auf Koeffizienten (Difference in Betas)
DFFITS	Einflussstatistik auf Prädiktionen (Difference in Fits)
$E(\cdot)$	Erwartungswert
$\vec{e}$	Richtungsvektor zur extrapolierten Prognose
E	Effekt
A_{eff}	A-Effizienz
D_{eff}	D-Effizienz (Normierte Determinante)
G_{eff}	G-Effizienz (Verhältnis Modellparameter zu max. Varianz)
I_{eff}	I-Effizienz
V_{eff}	V-Effizienz
λ	Eigenwert (einer Matrix)
	Transformationsparameter (Box-Cox)
η_{eco}	Economic Extrapolation Power Index
ϵ	Fehlerterm-Matrix
ϵ	Fehlerterm
$E(\cdot)$	Erwartungswert
$F(\cdot)$	Ausfallwahrscheinlichkeit, Verteilungsfunktion
$f(\cdot)$	Dichtefunktion
F	Fisher-Informationsmatrix

$G(\cdot)$	Verteilungsfunktion der kleinsten Extremwerte
G_{opt}	G-Optimalitätskriterium (Minimierung max. Prädiktionsvarianz)
$\Gamma(\cdot)$	Gamma-Funktion
$\mathbf{H}_f$	Hesse-Matrix (der Log-Likelihood-Funktion)
h	Eintrag von $\mathbf{H}$, Hebelwert
H_0	Nullhypothese
H_1	Alternativhypothese
$\mathbf{H}$	Orthogonale Projektionsmatrix, Prädiktionsmatrix, Hat-Matrix
I_{opt}	I-Optimalitätskriterium (Minimierung durchschn. Prädiktionsvarianz)
k	Anzahl der Modellparameter
$\mathcal{L}(\cdot)$	Likelihood-Funktion
$\Lambda(\cdot)$	Log-Likelihood-Funktion
$\lambda(t)$	Ausfallrate (zeitabhängig)
LR	Likelihood-Ratio
$\mathbf{M}$	Informationsmatrix $\mathbf{X}'\mathbf{X}$
m	Replikation
MSE	Mittlerer quadratischer Fehler (Mean Squared Error)
μ	Lageparameter
N	Versuchsanzahl
n	Stichprobenumfang
	Anzahlvariable
k_f	Anzahl der Faktoren (Dimension)
p	Anzahl der Regressionskoeffizienten
p -Wert	Überschreitungs-, Rest-Irrtumswahrscheinlichkeit
p_f	Fraktionsgrad
$power$	Trennschärfe, Power

$\Pr$	Wahrscheinlichkeit
$\nu(\mathbf{x}_0)$	Prädiktionsvarianz an der Stelle $\mathbf{x}_0$ (skaliert)
q	Quantilwert
R	Zuverlässigkeit
r	Paarweiser (Pearson-)Korrelationskoeffizient Radius im Versuchsraum (Euklidische Distanz) Studentisiertes Residuum
R^2	Bestimmtheitsmaß (Determinationskoeffizient)
r_{CS}	Cox-Snell-Residuum
r_{Dev}	Standardisiertes Devianz-Residuum
r	Standardisiertes Residuum (bezogen auf die SEV-Verteilung)
$\mathbb{R}$	Menge der reellen Zahlen
s	Empirische Standardabweichung (von x)
s^2	Empirische Varianz (von x)
$SEV(\cdot, \cdot)$	Verteilung der kleinsten Extremwerte, engl. Smallest Extreme Value
σ	Standardabweichung (theoretisch) Skalenparameter
σ^2	Varianz der Lebensdauer (theoretisch)
SNR	Signal-zu-Rausch Verhältnis (engl. Signal-to-Noise Ratio)
T	Charakteristische Lebensdauer (Skalenparameter)
t	Zeit, Lebensdauermerkmal Teststatistik in Bezug zur Signal-to-Noise Ratio
$\mathbf{t}$	Vektor der Ausfallzeiten
τ	kontinuierliche Zufallsvariable
θ	Modellparameter, Schätzung
$\boldsymbol{\theta}$	Vektor der Modellparameter
U_{opt}	U-Optimalitätskriterium (Minimierung der Prädiktionsvarianz am spezifischen Extrapolations- oder Betriebspunkt $\mathbf{x}_0$)

v	Integrationsvariable (Gamma-Funktion)
$\mathbf{V}$	Varianz-Kovarianz-Matrix
V_{opt}	V-Optimalitätskriterium (Punktuelle Varianz-Minimierung)
$\text{Var}[\cdot]$	Varianz-Operator
$\mathcal{W}(\cdot, \cdot)$	Weibull-Verteilung
w	Hilfsgröße zur Berechnung von Vertrauensbereichen (standardisierte Log-Lebensdauer)
$\mathbf{W}$	Gewichtsmatrix (Diagonalmatrix im angenommenen GLM)
$\mathbf{X}$	Versuchsplan-Matrix oder Modellmatrix
x	Messwert, Variable, Parameter
$\bar{x}$	Arithmetischer Mittelwert (empirisch)
$\mathcal{X}$	Anker-Exposition (zulässiges Toleranzfeld für Extrapolationsankerpunkte)
$\mathbf{x}$	Position im Parameterraum
ζ	Einflussfaktor im Meta-Design der Sensitivitätsanalyse
$\boldsymbol{\zeta}$	Vektor der Einflussfaktoren im Meta-Design der Sensitivitätsanalyse
$\mathbf{y}$	Antwortmatrix
y	Systemantwort, -variable
z	Quantil der Standardnormalverteilung
z_e	Standardisierte Variable der Kleinstwertverteilung (SEV); Hilfsgröße für Wald-Konfidenzintervalle (äquivalent zu w)

1 Einleitung

Die funktionale Absicherung technischer Produkte und Systeme über ihre gesamte Lebensdauer bildet das Fundament einer beherrschten industriellen Produktentwicklung. Motiviert durch zugesicherte Systemeigenschaften, die Wahrung der Markenintegrität sowie zunehmend restriktive und regulatorische Rahmenbedingungen ist ein proaktives Zuverlässigkeitsmanagement, innerhalb dessen die Lebensdauererprobung eine grundlegende Validierungsmethode darstellt, für Produkthersteller unerlässlich. Aus der Marktperspektive manifestiert sich dies in der Anforderung, dass komplexe technische Systeme - von automatisierten Fahrzeugarchitekturen über vernetzte mechatronische Subsysteme bis hin zu energie- und antriebstechnischen Anlagen - ihre spezifizierte Funktionalität über den definierten Einsatz- und Gewährleistungszeitraum erfüllen.

Die Zuverlässigkeitstechnik stellt die erforderlichen Methoden bereit, um das Produkt-Ausfallverhalten über die Einsatzdauer hinweg quantitativ zu beherrschen. Das Spektrum reicht von präventiven Methoden der funktionalen Sicherheit über die stochastische Analyse von Felddaten bis hin zu Verfahren der statistischen Versuchsplanung für die beschleunigte Lebensdauererprobung - engl. *Accelerated Lifetime Testing (ALT)*. Ein zentrales Ergebnis ist darauf aufbauend die probabilistische Modellierung der zeitabhängigen Überlebenswahrscheinlichkeit bzw. Zuverlässigkeit $R(t)$, welche die Wahrscheinlichkeit quantifiziert, dass ein System unter definierten Betriebs- und Umgebungsbedingungen bis zu einem Zeitpunkt t funktionsfähig bleibt [1]. Ungenügende Zuverlässigkeitsprognosen in der industriellen Praxis resultieren dabei nicht ausschließlich aus einem rein quantitativen Mangel an Prüfstandskapazitäten. Vielmehr begründen sich Fehleinschätzungen auch darin, dass im Betrieb simultan *mehrere* heterogene Stressoren als Einflussparameter auf das System einwirken. Auch können resultierenden Schädigungsmechanismen durch latente Wechselwirkungen getrieben werden, welche durch isolierte, univariate Versuchsstrategien methodisch schlichtweg nicht erfasst werden können [2, 3].

Die Beherrschung multivariater Beanspruchungskollektive erfordert folglich den Einsatz passender, statistischer Versuchsmethoden. Mit der fortschreitenden mechanischen Integration und Funktionsverdichtung gewinnt die multivariate Lebensdauererprobung damit eine existenzielle Bedeutung für die ressourceneffiziente Produktabsicherung.

1.1 Forschungsperspektive und Problembeschreibung

Werden multivariate Abhängigkeiten bei der Lebensdauerabsicherung methodisch unzureichend aufgelöst, ist in der industriellen Praxis das Ausweichen auf kostenintensive Kompensationsstrategien eine gängige aber unvorteilhafte Folge: Komponenten werden konservativ überdimensioniert, Austauschintervalle präventiv verkürzt oder unerkannte Wechselwirkungen provozieren fatale Feldausfälle mit unter Umständen kapitalen Gewährleistungs- und Reputationsfolgen. Um Lebensdauerdominierende Schädigungsmechanismen unter multivariaten Beanspruchungskollektiven empirisch und ausfallbasiert zu quantifizieren und gleichzeitig ressourcenintensive Prüfzeiten zu minimieren, ist die methodische Kopplung von statistischer Versuchsplanung - *Design of Experiments (DoE)* - mit der *End-of-Life (EoL)*-Erprobung durch ALT zwingend erforderlich.

An dieser methodischen Schnittstelle offenbart sich jedoch eine fundamentale Diskrepanz zwischen dem statistischen Werkzeug und der ingenieurtechnischen Zielsetzung: Klassische Konzepte der *Response Surface Methodology (RSM)* und etablierte Versuchsdesigns (wie das *Central Composite Design (CCD)*) sind stochastisch und topologisch strikt auf Interpolation ausgelegt [3, 4]. Ihre geometrische Struktur minimiert die Schätzvarianz exakt im Zentrum des experimentellen Versuchsraums. Die angewandte Zuverlässigkeitsmodellierung erfordert hingegen die Überbrückung zweier räumlich getrennter Domänen: Um physikalische Ausfälle innerhalb strenger ökonomischer Restriktionen zu provozieren, muss die ALT-Prüfung im Hochlastbereich erfolgen - im *Test-Parameterraum*. Die prädiktive Anwendung der erzeugten Modelle - die Absicherung der Systemlebensdauer - verlangt jedoch eine Prognose unter moderaten Feldbedingungen - im *Betriebs-Parameterraum*. Da der experimentelle Prüfraum und der reale Betriebsraum topologisch getrennt sind, wird das Regressionsmodell unweigerlich zur fernen Extrapolation gezwungen, vergleiche Abbildung 1.1.




Abbildung 1.1: Schematische Darstellung des Zusammenhangs von *Betriebs-Parameterraum* und *Test-Parameterraum* für die Anwendung von ALT in einem normalisierten Raum mit zwei Einflussparametern x_1 und x_2 .

Dieser strukturelle Widerspruch zwischen einem interpolationsoptimierten Versuchsentwurf und der extrapolationsbasierten Zuverlässigkeitsanwendung führt in der Prüfpraxis zu einer drastischen Fehlallokation experimenteller Ressourcen: Standard-DoEs konzentrieren ihre maximale Schätzpräzision im prädiktiv irrelevanten aber ökonomisch interessanten Test-Parameterraum des Hochlastbereichs, während die Vorhersagegüte entlang des kritischen Extrapolationspfads in Richtung der realen Einsatzbedingungen kollabiert und die Prädiktionsvarianz massiv divergiert. Die unmodifizierte Anwendung klassischer, zentrums-fokussierter Versuchspläne in der Lebensdauererprobung generiert demnach lediglich Scheingenauigkeiten im unmittelbaren Prüfraum, induziert am maßgeblichen Feld-Betriebspunkt jedoch unkontrollierbare stochastische Unsicherheiten.

1.2 Beitrag dieser Arbeit

Ausgehend von diesem mathematisch-topologischen Widerspruch formuliert die vorliegende Dissertation eine neuartige Systematik zur Auslegung hocheffizienter, multivariater Lebensdauertests. Liegt ein System vor, dessen Zuverlässigkeit unter Einwir-

kung mehrerer interagierender Stressfaktoren experimentell durch EoL abzusichern ist, stellt diese Arbeit die erforderlichen theoretischen, simulativen und empirischen Methoden zur Verfügung, um klassische Versuchspläne in extrapolations-optimierte Lebensdauerprüfungen zu transformieren. Der wissenschaftliche Kern der Arbeit besteht folglich in der gezielten topologischen Absicherung der Vorhersagegüte für Lebensdauern bzw. Zuverlässigkeiten im Parameterraum der Feldbetriebspunkte - die zwingende mathematische Voraussetzung, um ALT unter ökonomischen Restriktionen überhaupt stochastisch belastbar zu legitimieren.

Der wissenschaftliche Beitrag gliedert sich somit in drei zentrale Kernelemente:

- **Quantifizierung topologischer Resilienz:**

Systematischer, simulativer Nachweis mittels Monte-Carlo-Methoden, dass klassische Response Surface Designs (RSDs) eine signifikante Robustheit gegenüber praxisinduzierten, strukturellen Modifikationen aufweisen. Hieraus werden neben der methodischen Existenz eines nutzbaren geometrischen *Gestaltungsbudgets* auch die adäquaten Bewertungsmetriken für die Versuchsplaneignung abgeleitet.

- **Adaptive Versuchsplanung und richtungs-sensitive Varianzbewertung:**

Proaktive Umwidmung des identifizierten Gestaltungsbudgets zur gezielten Anpassung des Versuchsplans in Richtung des angestrebten Prognosebereichs im Feld-Parameterraum, formalisiert im adaptiven *Extrapolationvariance minimized Accelerated Lifetime Testing (EmALT)-Design*. Zur objektiven Quantifizierung des stochastischen Leistungsgewinns wird begleitend der *Extrapolation Variance Graph (EVG)* als neuartiges Bewertungswerkzeug eingeführt, welches die Prognoseunsicherheit zum Prädiktionspunkt gerichtet erfasst.

- **Ökonomische Synthese:**

Etablierung einer ganzheitlichen Bewertungsmetrik zur simultanen Bilanzierung von statistischer Trennschärfe, Extrapolationsunsicherheit und realen Prüfstandkosten.

1.3 Aufbau der Arbeit

Der strukturelle Aufbau der vorliegenden Arbeit orientiert sich an der methodischen Sequenz einer effizienten multivariaten Versuchskampagne (vgl. Abbildung 1.2).

Nach der in diesem Kapitel dargelegten Problemstellung widmet sich **Kapitel 2** dem aktuellen Stand der Forschung und Technik. Dort werden die mathematisch-statistischen Grundlagen der Zuverlässigkeits-Datenanalyse, der *Maximum Likelihood Estimation* (MLE), der statistischen Versuchsplanung (DoE) sowie der multivariaten Modellbildung im Rahmen von *Generalized Linear Models* (GLMs) systematisch aufbereitet. **Kapitel 3** synthetisiert diese Grundlagen, identifiziert die inhärenten Schwachstellen klassischer Optimalitätskriterien bei Lebensdauerprüfungen und leitet hieraus die zentralen Forschungsfragen der Dissertation ab.

Darauf aufbauend vollzieht zunächst **Kapitel 4** den methodischen Schritt zur quantitativen Versuchsplanung: Ausgehend von der quantifizierten strukturellen Robustheit klassischer Designs werden die Methodik der richtungssensitiven Varianzanalyse, das Konzept der asymmetrischen Extrapolationsabsicherung sowie die ökonomisch-statistische Effizienzbilanzierung hergeleitet und im Weibull-Kontext simulativ aufgezeigt.

In **Kapitel 5** erfolgt der Transfer in die industrielle Praxis. Anhand eines realen Datensatzes zur Lebensdauerprüfung von Lenksystem-Zahnriemen wird die Leistungsfähigkeit der entwickelten Methodik durch statistische Bestätigungsversuche empirisch verifiziert und der resultierende ökonomische Business Case dargelegt. Die Arbeit schließt in **Kapitel 6** mit einer Zusammenfassung der Kernergebnisse, einer kritischen Diskussion methodischer Anwendungsgrenzen sowie einem Ausblick auf weiterführende Forschungsfelder ab.




Abbildung 1.2: Aufbau der Arbeit.

2 Stand der Technik und Forschung

Dieses Kapitel stellt die für diese Arbeit erforderlichen technischen und methodischen Grundlagen bereit. Zunächst werden in Abschnitt 2.1 zentrale Begriffe und Konzepte der Zuverlässigkeitstechnik sowie das grundlegende statistische Verfahren zur Lebensdauer-Datenanalyse in Kombination mit Versuchsplänen erläutert. Darauf aufbauend folgen in Abschnitt 2.2 die Einführung und die Einordnung von DoE für Lebensdaueruntersuchungen sowie der multivariaten Lebensdauermodellierung aus dem Stand der Technik und der Wissenschaft, die beide für die Entwicklung effizienter Lebensdauerversuchspläne maßgeblich sind. Im Kontext der Lebensdauererprobung umfasst dies insbesondere typische, statistische Versuchspläne sowie Metriken und Indikatoren zur allgemeinen Bewertung der Versuchspläne.

2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie

Die Zuverlässigkeitstechnik befasst sich mit der probabilistischen Beschreibung der Lebensdauer technischer Produkte und Systeme sowie der strategischen und statistischen Planung von Lebensdauertests. Ziel ist die statistische Modellierung des Ausfallverhaltens unter Berücksichtigung der Funktionalität des Produkts bei relevanten Randbedingungen. Eine zentrale Aufgabe besteht somit in der statistischen Charakterisierung des Ausfallbegriffs mithilfe deskriptiver Statistik sowie in der Parametrisierung geeigneter Verteilungen zur Abbildung des Lebensdauerverhaltens. Die Modellierung kann - abhängig von den Randbedingungen - auf Basis *einer einzelnen* Belastungsgröße oder *mehrerer* Beanspruchungsparameter erfolgen, die gemeinsam den Produktausfall determinieren. Ein grundlegendes Verständnis des Umgangs mit zufallsverteilten Lebensdauerereignissen ist daher eine elementare Voraussetzung für die statistische Versuchsplanung im Rahmen der Zuverlässigkeitstechnik. Weiterführende Konzepte und vertiefte methodische Ansätze zur Zuverlässigkeitstechnik sowie

zur statistischen Testplanung sind allen voran in der Standardliteratur von Bertsche und Dazer [1] dargelegt, an deren Vorgehensweise sich die nachfolgende Übersicht orientiert.

2.1.1 Begriffe und Definitionen

Der *Ausfall* eines Produkts bezeichnet das Ende der Lebensdauer durch Verlust der geforderten Funktionalität. Maßgeblich hierfür sind für Ermüdungsausfälle von außen einwirkende *Belastungen* (*einzelne* oder *zeitgleich mehrere* Einflussparameter - Kräfte und Momente im mechanischen Kontext) sowie die daraus resultierenden inneren *Beanspruchungen* (innere Kräfte, Momente und lokale Spannungen). Die Ausfallzeit wird als kontinuierliche Zufallsvariable $\tau > 0$ verstanden, wobei $\tilde{t}$ als zugehörige zeitliche Integrationsvariable fungiert. Die fundamentalen Funktionen zur probabilistischen Beschreibung des Lebensdauerverhaltens sind gemeinsam mit deskriptiven Statistiken in Tabelle 2.1 zusammengefasst [1, 2, 5].

Tabelle 2.1: Mathematische Definitionen der Zuverlässigkeitsfunktionen

Wahrscheinlichkeitsdichte (*Probability Density Function (pdf)*):

Änderungsrate der Ausfallwahrscheinlichkeit.

$$f(t) = \frac{d}{dt}F(t) = \frac{d}{dt}\Pr(\tau \leq t), \quad t \geq 0. \quad (2.1)$$

Kumulative Ausfallwahrscheinlichkeit (*Cumulative Distribution Function (cdf)*):

Wahrscheinlichkeit eines Ausfalls bis zum Zeitpunkt t .

$$F(t) = \Pr(\tau \leq t) = \int_0^t f(\tilde{t}) d\tilde{t} \quad (2.2)$$

Tabelle 2.1 (*Fortsetzung*): Mathematische Definitionen

Zuverlässigkeit:

Überlebenswahrscheinlichkeit über den Zeitpunkt t hinaus.

$$R(t) = 1 - F(t) = \int_t^{\infty} f(\tilde{t}) d\tilde{t} \quad (2.3)$$

Ausfallrate (*Hazard-Function*):

Momentanes Ausfallrisiko, bedingt auf das Überleben bis t .

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t < \tau \leq t + \Delta t | \tau > t)}{\Delta t} = \frac{f(t)}{R(t)} \quad (2.4)$$

2.1.2 Deskriptive Statistik für Lebensdauerdaten

Um die theoretischen Parameter der Grundgesamtheit in der Praxis nutzbar zu machen, müssen diese auf Basis empirisch ermittelter Lebensdauerdaten (Stichprobe vom Umfang n mit den Ausfallzeiten $t_1, \dots, t_n$) approximiert werden. Die deskriptive Statistik liefert hierfür Methoden zur Berechnung von *Lageparametern* (Zentrum) und *Streuungsmaßen* (Breite). Tabelle 2.2 fasst die theoretischen Definitionen der Zufallsvariable τ sowie die grundlegenden Zuverlässigkeitsfunktionen und ihre korrespondierenden empirischen Schätzer kompakt zusammen.

Tabelle 2.2: Deskriptive Kennzahlen im Kontext der Lebensdaueranalyse

Erwartungswert und Mittelwert:

Erwartungswert μ des theoretischen Lageparameters der Grundgesamtheit. Der arithmetische Mittelwert $\bar{t}$ dient als üblicher, *empirischer Schätzer* für eine endliche Stichprobe.

$$\mu = E[\tau] = \int_0^{\infty} \tilde{t} \cdot f(\tilde{t}) d\tilde{t} \quad \text{geschätzt durch} \quad \bar{t} = \frac{1}{n} \sum_{i=1}^n t_i \quad (2.5)$$

Quantile und Median:

Das Quantil t_q definiert den Zeitpunkt, an dem die Verteilung $F(t)$ den Anteil $q \in [0, 1]$ erreicht. Der Median $t_{0.5}$ teilt die Fläche unter der *pdf* in zwei Hälften [6, 7].

$$F(t_q) = q \quad \text{bzw. für Median:} \quad F(t_{0.5}) = 0.5 \quad (2.6)$$

Varianz und Standardabweichung:

Die theoretische Varianz σ^2 (mittlere quadratische Abweichung) wird durch die erwartungstreue empirische Varianz s^2 geschätzt. Die empirische Standardabweichung folgt daraus zu $s = \sqrt{s^2}$.

$$\sigma^2 = E[(\tau - \mu)^2] \quad \approx \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (t_i - \bar{t})^2 \quad (2.7)$$

2.1.3 Parametrische Lebensdauermodelle

Während die deskriptiven Statistiken $\bar{x}$ und s^2 die zentrale Tendenz und die Streuung der vorliegenden Stichprobe quantifizieren, erlauben sie keine Extrapolation oder die Modellierung der zugrundeliegenden Funktionen $F(t)$ und $f(t)$ der Grundgesamtheit. Um eine prädiktive, mathematische Beschreibung des stochastischen Ausfallverhaltens zu erhalten, müssen die in Abschnitt 2.1.1 definierten Lebensdauerfunktionen durch geeignete parametrische Verteilungsmodelle approximiert werden. Andernfalls

können nur nichtparametrische Modellierungsansätze zur Schätzung der kumulierten Wahrscheinlichkeit in Überlebensfunktionen wie beispielsweise nach Kaplan und Meier [8] genutzt werden [2, 3]. Die Verteilungsmodelle hingegen bieten eine geschlossene mathematische Form für *cdf* und *pdf* und ermöglichen es, das komplexe Ausfallverhalten durch eine geringe Anzahl von Parametern zu charakterisieren.

Weibull-Verteilung

In der Zuverlässigkeitstechnik hat sich die *Weibull-Verteilung* aufgrund ihrer hohen Flexibilität als das am häufigsten verwendete Modell etabliert. Je nach zugrundeliegendem physikalischen Ausfallmechanismus finden jedoch auch andere statistische Verteilungen Anwendung, wie beispielsweise die *Lognormalverteilung* (häufig bei Ermüdungs-, Korrosions- oder Diffusionsprozessen) oder die *Exponentialverteilung* (zur Modellierung von Zufallsausfällen ohne Alterungseffekte) [5, 6]. Für weitere Ausführungen dazu sei an dieser Stelle jedoch auf bereits ausreichend diskutierte Aufbereitungen von Bertsche und Dazer [1], Rigdon et al. [3], Birolini [5], Yang [6] und Hedderich und Sachs [9] verwiesen.

Die (zweiparametrische) Weibull-Verteilung ist das Standardmodell zur Beschreibung der Lebensdauer von technischen Produkten ohne die Berücksichtigung eines möglichen dritten Parameters - der ausfallfreien Zeit t_0 . Sie wird durch den *Formparameter* $b > 0$ (Weibull-Modul) und die *charakteristische Lebensdauer* $T > 0$ (Skalenparameter), welche dem 63,2-ten Perzentil $t_{0,632}$ entspricht, beschrieben. Unabhängig von b gilt hier somit: $F(T) = 1 - e^{-1} \approx 63,2\%$. Folgt die Lebensdauer-Zufallsvariable τ dieser Verteilung, wird dies mathematisch als $\tau \sim \mathcal{W}(T, b)$ notiert. Damit ist sie in der Lage, alle drei Phasen der "Badewannenkurve" (Frühausfälle mit $b < 1$, Zufallsausfälle $b \approx 1$, Verschleißausfälle mit $b > 1$) durch die Wahl ihrer Parametrisierung abzubilden, vgl. Bertsche und Dazer [1]. Die Einheit des Skalenparameters T entspricht der des Messwertes. Die charakteristischen Funktionen und statistischen Momente der Weibull-Verteilung sind in Tabelle 2.3 zusammengefasst.

Tabelle 2.3: Funktionen und Kennzahlen der Weibull-Verteilung

Dichte- und Verteilungsfunktion (pdf & cdf):

$$f(t) = \frac{b}{T^b} t^{b-1} \exp \left[- \left(\frac{t}{T} \right)^b \right], \quad t > 0 \quad (2.8)$$

$$F(t) = 1 - \exp \left[- \left(\frac{t}{T} \right)^b \right], \quad t > 0 \quad (2.9)$$

Ausfallrate (Hazard-Funktion):

$$\lambda(t) = \frac{b}{T} \left(\frac{t}{T} \right)^{b-1}, \quad t > 0 \quad (2.10)$$

Momente und Gamma-Funktion:

Mit der Gamma-Funktion (2.11) $\Gamma(x) = \int_0^\infty v^{x-1} e^{-v} dv$ ergeben sich Erwartungswert μ (vgl. Gleichung (2.5)) und Varianz σ^2 (vgl. Gleichung (2.7)) der Weibull-verteilten Lebensdauer τ :


$$\mu = T \cdot \Gamma \left(1 + \frac{1}{b} \right) \quad (2.12)$$

$$\sigma^2 = T^2 \left[\Gamma \left(1 + \frac{2}{b} \right) - \Gamma^2 \left(1 + \frac{1}{b} \right) \right] \quad (2.13)$$

Die Flexibilität der Verteilung zeigt sich in den Spezialfällen des Formparameters: Für $b = 1$ geht sie in die Exponentialverteilung über ($\lambda(t) = \text{konst.}$), während sie sich für $b \approx 3,6$ einer Normalverteilung annähert (vgl. Abb. 2.1) [10, 11].

2.1.4 Parameterschätzverfahren

Soll eine geschlossene mathematische Beschreibung des stochastischen Ausfallverhaltens gefunden werden, ist nach Vorbild von Abschnitt 2.1.3 ein adäquates Verteilungsmodell zu parametrisieren. Die zentrale Problemstellung besteht darin, aus der



Abbildungung 2.1: Weibull $f(t)$ für ausgewählte Werte von T und b .

empirischen Stichprobe bestehend aus n Realisierungen der Zufallsvariable τ statistisch fundierte Schätzwerte für die wahren Parameter der Grundgesamtheit (z. B. $\hat{T}$ und $\hat{b}$ für $\tau = \mathcal{W}(b, T)$) zu extrahieren. Diese Parameteridentifikation ist die zwingende Voraussetzung, um prädiktive Aussagen zur Zuverlässigkeit $R(t)$ abzuleiten.

Während in der klassischen, normalverteilten Statistik häufig die *Methode der kleinsten Fehlerquadrate* (*Ordinary Least Squares* (OLS)) Anwendung findet, ist diese für die Lebensdauerdatenanalyse unzureichend. Wesentliche Hauptgründe hierfür sind das Auftreten unvollständiger (rechts-zensierter) Beobachtungen, sogenannter *Durchläufer*, sowie die möglicherweise nicht-normalverteilte Natur der Zufallsvariablen Lebensdauer τ . Zur simultanen und erwartungstreuen Abbildung von exakten Ausfällen und Zensierungen hat sich stattdessen die MLE als universeller Standard etabliert [2, 12].

Das Grundprinzip der MLE besteht darin, diejenigen Parameterwerte als Schätzwerte $\hat{\theta}$ zu identifizieren, welche die Wahrscheinlichkeit (Likelihood) maximieren, exakt die vorliegende empirische Stichprobe beobachtet zu haben. Formal wird die Stichprobe über Paare (t_i, δ_i) definiert, wobei t_i der Prüfzeit und δ_i einem Statusindikator (1 = Ausfall, 0 = Zensierung) entspricht [2, 13]. Unter der Annahme stochastisch unabhängiger Beobachtungen ergibt sich die Likelihood-Funktion $\mathcal{L}$ als Produkt aus

den Wahrscheinlichkeitsdichten $f(\cdot)$ der Ausfälle und den Zuverlässigkeiten $R(\cdot)$ der zensierten Einheiten:

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^n \left[f(t_i|\boldsymbol{\theta})^{\delta_i} \cdot R(t_i|\boldsymbol{\theta})^{1-\delta_i} \right]. \quad (2.14)$$

Zur algorithmischen Maximierung wird dieser Ausdruck durch Logarithmierung in die numerisch stabilere *Log-Likelihood-Funktion* Λ überführt:

$$\Lambda := \ln(\mathcal{L}(\mathbf{t}|\boldsymbol{\theta})) \propto \sum_{i=1}^n [\delta_i \cdot \ln f(t_i|\boldsymbol{\theta}) + (1 - \delta_i) \cdot \ln R(t_i|\boldsymbol{\theta})]. \quad (2.15)$$

Die Identifikation des Parametersatzes $\hat{\boldsymbol{\theta}}$, der $\Lambda(\boldsymbol{\theta})$ maximiert, erfolgt durch das Nullsetzen der partiellen Ableitungen ($\partial\Lambda/\partial\boldsymbol{\theta} \stackrel{!}{=} 0$). Da für die Weibull-Verteilung hierfür keine geschlossenen analytischen Lösungen existieren, werden in der Praxis iterative, numerische Optimierungsalgorithmen (wie das *Newton-Raphson-Verfahren* oder *Pattern-Search-Algorithmen*) angewandt [14, 15, 16]. Methodisch ist dabei zu beachten, dass die MLE zwar asymptotisch erwartungstreu ist, bei kleinen Stichprobenumfängen n jedoch systematische Verzerrungen (*Bias*) in $\hat{\boldsymbol{\theta}}$ aufweisen kann [17], welche sich bei Bedarf durch etablierte Korrekturverfahren kompensieren lassen (*Bias-Korrektur*) [18, 19].

Die MLE liefert jedoch nicht nur die Punktschätzer $\hat{\boldsymbol{\theta}}$, sondern bildet auch das stochastische Fundament zur Quantifizierung der Modellunsicherheiten und *Vertrauensbereiche* (*Confidence Intervals (CIs)*). Da diese Unsicherheitsquantifizierung insbesondere bei Vorliegen multivariater Beanspruchungen (GLMs) über die strukturelle Effizienz der Versuchsplanung entscheidet, wird die dafür erforderliche mathematische Herleitung der Informationsmatrizen geschlossen im multivariaten Kontext in Abschnitt 2.2.6 behandelt.

2.2 Statistische Versuchsplanung und Modellbildung

Multivariate Lebensdauertests erfordern definitionsgemäß die Variation mehrerer Einflussfaktoren ($k \geq 2$). Die systematische Planung derartiger experimenteller Untersuchungen erfolgt mittels Methoden von DoE, was im spezifischen Kontext der Zuverlässigkeitstechnik nach Kremer [4] auch unter dem Paradigma *L-DoE* zusam-

mengefasst wird. Während detaillierte historische Abrisse zur klassischen Versuchsplanung der einschlägigen Standardliteratur zu entnehmen sind [20, 21, 22], fokussiert dieser Abschnitt explizit auf die methodischen Anforderungen mehrdimensionaler Lebensdauertests um ferner deren Effizienz zu erörtern.

Der primäre Anspruch von DoE besteht in der ökonomisch effizienten Versuchsplanung sowie empirischen Modellierung einer Systemantwort in Abhängigkeit erklärender Variablen. In der Zuverlässigkeitstechnik zielt dies auf die parametrische Charakterisierung des multivariaten Ausfallverhaltens bzw. der Lebensdauer ab. Eine fundamentale methodische Herausforderung stellt hierbei jedoch die zwingende Integration der beschleunigten Lebensdauererprobung (ALT) dar: Um physikalische Ausfälle innerhalb vertretbarer Prüfzeiten zu provozieren, operieren die Versuchspläne gezwungenermaßen in einem hochbelasteten *Test-Parameterraum*. Die eigentliche Zielsetzung der Modellbildung - die prädiktive Absicherung der Zuverlässigkeit - verlangt jedoch verlässliche Vorhersagen im moderaten *Betriebs-Parameterraum*. Diese räumliche Diskrepanz erzwingt eine formale stochastische Extrapolation, welche grundlegend zum vorliegenden Stand der Technik bislang nicht formal in die Versuchsplanung integriert wurde und im Rahmen von L-DoE als methodische Lücke identifiziert werden kann. Bisherige Ansätze des L-DoE fokussieren primär auf die reine statistische Modellbildung und klammern diesen Beschleunigungs- und Extrapolationsaspekt weitgehend aus. Dadurch bleibt die tatsächliche prädiktive Vorhersagegüte und strategische Effizienz der Versuchspläne für den Feldbetrieb oft unberücksichtigt.

2.2.1 Grundlagen zur statistischen Versuchsplanung

Die methodische Grundlage der statistischen Versuchsplanung bildet die funktionale Abbildung einer Systemantwort y in Abhängigkeit gezielt variierten Einflussfaktoren - der *Steuergrößen* [22, 23]. Nicht kontrollierbare Einflüsse werden formal als *Störgrößen* abgebildet. Zur empirischen Modellierung werden die Faktoren im definierten *Test-Parameterraum* (*Design-Space*) auf diskreten, typischerweise kodierten *Faktorstufen* (z. B. -1 und $+1$) variiert. Die strukturierte Kombination dieser Stufen definiert die individuellen Versuchspunkte und konstituiert die *Versuchsplan-Matrix*.

Der kausale Einfluss der Faktoren auf die Systemantwort wird mathematisch durch Polynomfunktionen approximiert. Ein fundamentales Regressionsmodell erster Ord-

nung für $k = 2$ Faktoren erfasst neben der *Regressionskonstanten* β_0 die linearen *Haupteffekte* β_1, β_2 sowie deren *Wechselwirkung* β_{12} :

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \epsilon. \quad (2.16)$$

Sollen bei einer Lebensdauer- und Zuverlässigkeitsanalyse zudem signifikante Nichtlinearitäten quantifiziert werden, wird der Ansatz zu einem Modell *zweiter Ordnung* mit *quadratischen Termen* β_{11}, β_{22} erweitert:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \quad (2.17)$$

Für n Beobachtungen und p zu schätzende Modellparameter lässt sich dieses Gleichungssystem verallgemeinert in Matrixnotation formulieren:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad (2.18)$$

wobei $\boldsymbol{\beta}$ als $p \times 1$ Vektor der Regressionskoeffizienten ($p = k + 1$) durch den $n \times 1$ Vektor $\mathbf{y}$ aller Beobachtungen sowie durch die Versuchsplan-Matrix $\mathbf{X}$ ($n \times p$ Einträge) unter Zuhilfenahme eines geeigneten Schätzverfahrens (vgl. Abschnitt 2.1.4) zu ermittelten ist [6, 14]. Der Parametervektor $\boldsymbol{\beta}$ wird hierbei über etablierte stochastische Optimierungsverfahren (vgl. Abschnitt 2.1.4) geschätzt. Da die Komplexität dieser Modelle exponentiell mit der Anzahl der betrachteten Faktoren skaliert, wird der quantitativen Versuchsdurchführung in der Praxis ein heuristisches oder experimentelles Parameter-Screening vorgeschaltet, um die Dimension des Parameterraums a priori auf die maßgeblichen Einflussgrößen zu reduzieren [24].

2.2.2 Parameter-Screening

Im Hinblick auf die Realisierung eines unter Zeit- und Kostenrestriktionen hochgradig effizienten DoE ist die effiziente Ausgestaltung einer Screening-Strategie selbst schon von primärem Interesse. In traditionellen DoE-Ansätzen impliziert dies den Einsatz von *Kreativmethoden*, wie sie Standardliteratur [22] aufführt oder exemplarisch durch Kremer [4] und Gundlach [25] zusammengefasst werden. Hierbei ist ein Rückgriff auf Ergebnisse aus Experimenten, die explizit für das Forschungsziel ausgelegt wären, in dieser Phase unter Umständen noch nicht möglich. Es gilt damit zunächst,

qualitativ eine rein rational erlesene Sammlung an potenziellen Einflussparameter zu erstellen, um diese dann anhand ihrer geschätzten Einflüsse auf die Systemantwort zu priorisieren. Ansätze aus der Kreativmethodik können dazu genutzt werden und fundieren auf der technischen *Systemanalyse*, die sowohl mit als auch ohne spezifisches Vorwissen über das System erfolgen kann [1]. Hilfsmittel zur Priorisierung einer hier erstellten Parametersammlung können beispielsweise Entscheidungsfindungsprotokolle, wie die *Design-Structure-Matrix (DSM)*, und Methoden aus dem Komplexitätsmanagement, z.B. *Ishikawa-Diagramm*, sein - siehe hierzu auch weiterführende Werke von Mayers [26], Pahl et al. [27], Wu und Hamada [28], Daenzer und Haberfellner [29] sowie Lindemann et al. [30]. Das Screening liefert somit eine rational festgestellte Auswahl an möglichst wenigen Einflussparametern, die perspektivisch den entscheidenden Anteil an statistisch begründeter Manipulation der Systemantwort tragen und sich daher für eine Untersuchung in Versuchsplänen qualifizieren. Eine Abstimmung dieser heuristischen Herangehensweise im Screening insbesondere auf Lebensdaueruntersuchungen findet dabei unter Berücksichtigung der Wechselwirkungen zwischen Faktoren und den Randbedingungen des *Test-Parameterraums* in einem strategischen Ablauf nach [24] statt. Entsprechend ist daraufhin ein geeigneter Versuchsplan für die physischen Datenerhebungen zu wählen.

2.2.3 Statistische Versuchsplanung zur Lebensdauererprobung

Standardprotokolle aus dem DoE eignen sich grundsätzlich auch für Lebensdaueruntersuchungen, da statistische Effekte hierbei formal als Differenz der mittleren Systemantwort zwischen diskreten Einstellstufen berechnet werden. Etablierte Versuchspläne, wie sie in der einschlägigen Literatur [22, 31] beschrieben werden, können daher auch für die Lebensdauererprobung adaptiert werden und sind wie folgt zu klassifizieren:

Faktorielle Versuchspläne zur linearen Modellbildung

Um ein multivariates Parameterset systematisch zu untersuchen, etabliert der 2^k *voll-faktorielle Versuchsplan* die Basis der klassischen Testplanung. Durch die Kombination von k Faktoren auf jeweils zwei Einstellstufen ermöglicht er die Anpassung eines linearen

Modells erster Ordnung inklusive aller Wechselwirkungen. Bei einfacher Durchführung (Replikation $m = 1$) erfordert dieses Design exakt

$$n = 2^k \quad (2.19)$$

Versuche. Ein daraus resultierendes, gesättigtes Gleichungssystem erlaubt die eindeutige stochastische Bestimmung aller $n - 1$ Modellterme erster Ordnung. Entscheidend für die prädiktive Aussagekraft ist hierbei die Definition der Faktor-Umfänge: Schrittweite bzw. Stufenabstände. Die Stufenabstände sind einerseits ausreichend groß zu wählen, um signifikante Effekte vom experimentellen Versuchsrauschen zu isolieren - vgl. *Signal-zu-Rausch Verhältnis*, engl. *Signal-to-Noise Ratio (SNR)*. Andererseits dürfen die Intervalle nicht zu weit gefasst sein, um unerkannte Nichtlinearitäten innerhalb des Interpolationsraums zu vermeiden [28, 31, 32].

Übersteigt die Dimensionalität des Systems eine kritische Grenze (typischerweise $k > 5$), skaliert der Versuchsumfang exponentiell und wird für ressourcenintensive ALT-Kampagnen ökonomisch ineffizient. In diesen Fällen kann das physikalische Screening auf *teil-faktorielle Versuchspläne* reduziert werden, welche lediglich eine definierte Fraktion $n = 2^{k-p_f}$ der vollständigen Planmatrix abbilden [31, 33]. Dieser bewusste Informationsverzicht wird durch zwei empirische Postulate stochastisch legitimiert [3, 33]:

- **Effekthierarchie:** Haupteffekte besitzen in der Regel eine signifikant größere Amplitude als Effekte höherer Ordnung.
- **Effektvererbung:** Die Signifikanz von Wechselwirkungen setzt strukturell die Relevanz der zugehörigen Haupteffekte voraus.

Die systemimmanente Konsequenz dieser Reduktion ist die statistische Vermengung (*Aliasing*) von Haupteffekten und Wechselwirkungen. Für die industriennahe Lebensdauererprobung ist dieser Kompromiss jedoch dann zwingend erforderlich, wenn testintensive Ressourcen zu bündeln und ein faktorielles Screening-Design zu generieren ist, welches in nachfolgenden Entwicklungsphasen nahtlos *augmentiert* werden kann.

Wirkungsflächenversuchspläne zur quadratischen Modellbildung

In generalisierten Ansätzen zur GLM-Parametrisierung kann weiter entscheidend sein, wie die bestehende Datenbasis aus der faktoriellen Erprobung weitergenutzt und augmentiert werden kann, falls die Systemantwort signifikante *Krümmungen* aufweist und die quantitativen Beziehungen zwischen Faktoren und Zielgröße für eine Optimierung detaillierter beschrieben werden müssen.

Die RSM behandelt als Teildisziplin des DoE derartige Herangehensweisen und bietet hierfür spezielle *Wirkungsflächenversuchspläne* (RSDs) an. Der erste Schritt zur Detektion von Nichtlinearitäten besteht in der Integration von n_{ZP} sogenannten *Zentralpunkte* (ZPs) in den faktoriellen Basisplan. Hierbei werden alle Faktoren auf die kodierte Stufe 0 (die Mitte des Versuchsraums) gesetzt. Weicht der Mittelwert der Systemantwort in den ZPs signifikant vom Mittelwert über die faktoriellen Eckpunkte ab, deutet dies auf eine Krümmung der Antwortfläche hin [22].


Um diese quadratischen Zusammenhänge explizit zu bestimmen, gilt der *Zentral-Zusammengesetzte-Versuchsplan* (CCD) als etablierter Standard [3, 34]. Ein CCD entsteht durch die *Augmentierung* des ursprünglichen voll- (oder teil-)faktoriellen Plans (den n_{F} Eckpunkten), vgl. Abbildung 2.2, um:

- eine definierte Anzahl n_{ZP} an wiederholten ZPs (üblicherweise $3 \leq n_{\text{ZP}} \leq 5$ zur Abschätzung des reinen Fehlers) [33]; sowie
- $n_{\text{SP}} = 2 \cdot k$ zusätzliche *Sternpunkte* (SPs), die auf den Achsen des Koordinatensystems im Abstand $\pm\alpha_{\text{D}}$ vom Zentrum liegen.

Während die ZPs das Vorhandensein quadratischer Effekte validieren, ermöglichen die SPs deren Wertbestimmung. Die Wahl des Abstands α_{D} wird primär durch die Geometrie des relevanten *Test-Parameterraums* (*Region of Interest*) diktiert. Wird dieser Raum als *Sphäre* verstanden, ist die *Drehbarkeit* (*Rotierbarkeit*) ein wesentliches Qualitätsmerkmal. Sie stellt sicher, dass die Varianz der Vorhersage nur vom Abstand zum Zentrum abhängt und invariant gegenüber einer Rotation des Koordinatensystems ist. Um diese Eigenschaft zu gewährleisten, berechnet sich der Abstand α_{D} in Abhängigkeit der faktoriellen Versuchspunkte n_{F} zu [22, 35]:

$$\alpha_{\text{D}} = (n_{\text{F}})^{1/4}. \quad (2.20)$$

Alternativ kann für sphärische Räume auch $\alpha_D = \sqrt{k}$ gewählt werden (*Sphärisches CCD*), wodurch alle faktoriellen Punkte und SPs auf einer Kugeloberfläche liegen [36]. Ist der Versuchsraum hingegen durch harte physikalische Grenzen (z.B. maximale Temperatur) kubisch beschränkt, bietet sich der *flächenzentrierte CCD* (*Face Centered CCD*) an. Hierbei wird $\alpha_D = 1$ gesetzt, sodass die SPs direkt auf den Flächenmitten des Würfels liegen. Dies vereinfacht die Durchführung, da nur drei Faktorstufen ($-1, 0, +1$) benötigt werden, opfert jedoch die Eigenschaft der Rotierbarkeit. Eine effiziente



(a) Versuchsplan (CCD)

Versuchs- #	Faktorstufen		Punkt- Typ
	x_1	x_2	
1	-1	-1	n_F
2	+1	-1	
3	-1	+1	
4	+1	+1	
5	$-\alpha_D$	0	n_{SP}
6	$+\alpha_D$	0	
7	0	$-\alpha_D$	
8	0	$+\alpha_D$	
9	0	0	n_{ZP}
10	0	0	
11	0	0	
12	0	0	
13	0	0	

(b) Versuchsplanmatrix (Stufen) zu Abb. 2.2a

Abbildung 2.2: Zentral zusammengesetzter Versuchsplan (CCD) mit $k = 2$

Alternative zum CCD stellt das *Box-Behnken-Design* dar [37]. Dieses Design kombiniert 2^k -Faktorielle mit unvollständigen Blockplänen und platziert Versuchspunkte auf den Kantenmitten des Versuchsraums, vermeidet jedoch die extremen faktoriellen Versuchspunkte. Dies kann vorteilhaft für Lebensdauertests sein, bei denen extreme Ecken oft zu verfrühten Ausfällen führen können. Zudem ist es bei korrekter Wahl der ZPs alias-optimal gegenüber kubischen Modellen [38]. Stoßen Standard-Designs (CCD, Box-Behnken) aufgrund von Restriktionen im Versuchsraum, nicht-standardmäßigen Modellierungszielen oder ungewöhnlichen Stichprobenumfängen

an ihre Grenzen, empfiehlt sich der Einsatz von *Optimalen Versuchsplänen*, vergleiche Abschnitt 2.2.5. Diese computergenerierten Designs minimieren beispielsweise algorithmisch die durchschnittliche Vorhersagevarianz über den gesamten Designraum und können Standard-Designs in ihrer Prädiktionsgüte oft übertreffen [22, 39]. Gleichzeitig ist zu dieser Stelle festzuhalten, dass mit den Eigenschaften der Rotierbarkeit und der Orthogonalität zwei fundamentale Qualitätsmerkmale für CCDs existieren, die einen varianz-optimierten Versuchsplan charakterisieren.

2.2.4 Strategische Vorgehensweisen

In der versuchstechnischen Praxis entsteht ein CCD vorzugsweise im Rahmen einer *sequenziellen Versuchsstrategie*. Zeigt das initiale lineare Modell signifikante Anpassungsmängel (*Lack-of-Fit*), wird der bestehende faktorielle Basisplan um die SPs augmentiert, um ein Regressionsmodell zweiter Ordnung abzubilden [36]. In der Zuverlässigkeitstechnik ist diese Erweiterung essenziell: Primäres Ziel ist hierbei nicht die Suche nach lokalen Extrema, sondern die korrekte stochastische Erfassung nicht-linearer Schädigungsmechanismen unter multivariaten Belastungen [3, 40]. Prinzipielle Vorgehensweisen wie *Blockbildung* oder *Randomisierung* (vgl. [31, 32]), die ein erfolgreiches Umsetzen von DoE bzw. L-DoE begünstigen sollten, seien hier bereits vorausgesetzt. Abbildung 2.3 fasst eine derartige strategische Vorgehensweise zur Realisierung eines CCD zusammen, wie sie beispielsweise Box und Wilson [41], Box et al. [42] und Bisgaard [43] vorschlagen.




Abbildung 2.3: Strategischer Ansatz zur augmentierten Versuchsplanung für die Lebensdauererprobung nach [42, 43], beispielhaft im zweidimensionalen Fall ($k = 2$) dargestellt.

Da die zwingend erforderliche Anzahl an Versuchspunkten N direkt mit der Anzahl der zu schätzenden Parameter p [44] korrespondiert, kann die schrittweise Augmentierung das ökonomische Risiko der Lebensdauererprobung minimieren. Während lineare Effekte durch zwei Stützstellen auflösbar sind, erfordert die Modellierung quadratischer Terme im Gleichungssystem zwingend mindestens drei Faktorstufen. Anstatt ein ressourcenintensives CCD a priori vollständig aufzulegen, erlaubt eine theoretische *Sequenzierung* eine datengetriebene Entscheidungsfindung: Zunächst separiert ein faktorieller Plan (bei $k \geq 3$ ggf. teil-faktoriell) die signifikanten von den trivialen Faktoren. Anschließend detektieren ergänzte ZPs das Vorliegen globaler Krümmungen. Lediglich bei nachgewiesener Nichtlinearität oder bei einer geplanten, fernen Extrapolation in den Feldbereich erfolgt die finale Erweiterung durch SPs [45, 46]. Während eine Randomisierung jenseits dieser Sequenzierung durchgeführt werden kann, wird auf diese Weise die experimentelle Aufwand-Nutzen-Bilanz maximiert, da kostenintensive Prüfläufe ausschließlich zur fundierten Absicherung der Extrapolationsgüte allokiert werden [22, 36, 47].

2.2.5 Bewertung und Optimierung von Versuchsplanung

Wird maximale Flexibilität jenseits starrer Standard-Designs wie dem voll-faktoriellen Setup oder dem CCD verlangt, können *optimale Versuchspläne* einen leistungsfähigen, *effizienten* Lösungsansatz für *multivariate* Versuchsplanung bieten [22, 36, 48]. Diese verfolgen das Ziel, die Versuchspunkte algorithmisch so im Versuchsraum zu positionieren, dass spezifische Qualitätskriterien - allen voran die Verteilung der (um die Versuchsanzahl N skalierten) *Prädiktionsvarianz*, engl. *Scaled Prediction Variance* (SPV),

$$v(\mathbf{x}_0) = \frac{N \text{Var}[\hat{y}(\mathbf{x}_0)]}{\sigma^2} = \mathbf{x}_0' \left(\frac{\mathbf{M}}{N} \right)^{-1} \mathbf{x}_0 = N \mathbf{x}_0' \mathbf{M}^{-1} \mathbf{x}_0 \quad (2.21)$$

optimiert werden [22, 36]. Die Prädiktionsvarianz ist ein dimensionsloses Maß, das ausschließlich über die geometrische Anordnung der N Versuchspunkte (der Matrix $\mathbf{X}$) in der *Informationsmatrix* (auch *Momentenmatrix*)

$$\mathbf{M} \stackrel{m=1}{=} \mathbf{X}'\mathbf{X} \quad (2.22)$$

definiert und damit positionsabhängig von einer Referenz $\mathbf{x}_0' = [1, x_{01}, \dots, x_{0k}]$ im Parameterraum ist [36]. Sie ist damit unabhängig von der tatsächlichen Streuung der Messdaten (σ^2). Weiter wird sie über die Anzahl der Versuchspunkte N skaliert, um zwischen Versuchsplänen mit unterschiedlicher Stichprobengröße hinsichtlich des Gestaltungsbudgets und der geometrischen Effizienz zu vergleichen [36, 39]. Im Sinne der absoluten Schätzpräzision und direkt über die Breite der resultierenden Konfidenzintervalle kann sie im ingenieurwissenschaftlichen Blickwinkel aber auch unskaliert betrachtet werden: als *Unscaled Prediction Variance* (UPV)

$$v(\mathbf{x}_0)/N = \text{Var}[\hat{y}(\mathbf{x}_0)]/\sigma^2 = \mathbf{x}_0' \mathbf{M}^{-1} \mathbf{x}_0, \quad (2.23)$$

vgl. Montgomery [22] und Myers et al. [49]. Die strikte methodische Differenzierung dieser beiden Metriken ist für die Auslegung von Lebensdauertests essenziell: Während die UPV die *absolute, physikalische Schätzpräzision* repräsentiert - welche sich nach informationstheoretischen Grundsätzen mit jedem zusätzlichen Versuchspunkt zwingend verbessert oder zumindest stagniert -, fungiert die SPV als reines Maß der *geometrischen Design-Effizienz*. Sie bewertet den Informationsgewinn pro investiertem Versuchsaufwand N . Ein geometrisch ineffizient platzierter Versuchspunkt (etwa ein redundanter Zentralpunkt für eine ferne Extrapolation) kann zwar die absolute UPV marginal senken, jedoch die SPV verschlechtern, da die Aufwandserhöhung (Steigerung von N) den minimalen Informationsgewinn überkompensiert. Somit dient die SPV dem topologischen Strukturvergleich und der Budget-Allokation, während die UPV die Basis zur Berechnung realer Konfidenzintervalle für die tatsächliche Lebensdauerprognose im Feld bildet. Zusammen mit der Varianz des Versuchsfehlers σ^2 (vgl. Gleichung 2.26) erlaubt die Prädiktionsvarianz somit eine direkte Quantifizierung der *Unsicherheit in der Modellvorhersage* $\text{Var}[\hat{y}(\mathbf{x}_0)]$ an einer beliebigen Stelle $\mathbf{x}_0$ im Versuchsraum. Um sie über verschiedene Stellen im Parameterraum zu bewerten, konnten allen voran Zahran et al. [50] und Giovannitti-Jensen und Myers [51] mit dem *Variance Dispersion Graph* (VDG) oder *Fraction of Design Space* (FDS)-Plot Visualisierungsstrategien entwickeln. Diverse Anwendungen folgten daraufhin und festigten durch Arbeiten von Goldfarb et al. [52] und Ozol-Godfrey et al. [53] deren Relevanz bei der Untersuchung von Designtypen durch beispielsweise Borkowski et al. [54], Myers et al. [55] und Schoonees et al. [56] für verschiedenste Designmodifikationen oder -Störungen. Der FDS stellt dabei die kumulative Verteilung der Prädiktions-

varianz über den jeweiligen Anteil des Design-Space' entsprechend Abbildung 2.4a dar, während der VDG (neben den Extremwerten) die durchschnittliche, sphärische Prädiktionsvarianz als Funktion des Abstands r zum Zentrum des Versuchsraums visualisiert - vgl. Abbildung 2.4b. Eine effiziente Versuchsplanung für multivariate




Abbildung 2.4: FDS und VDG für einen CCD mit $k = 2$ Faktoren.

Lebensdaueruntersuchungen muss sich neben pragmatischen Beweggründen maßgeblich an der Prädiktionsvarianz orientieren, weshalb im Folgenden eine Übersicht der darauf basierenden, gängigen Metriken und Qualitätsmerkmale gegeben wird.

Orthogonalität, Ausgewogenheit und Multikollinearität

Der Einsatz optimaler Versuchspläne ist zunächst prädestiniert für Szenarien, in denen klassische Pläne an ihre Grenzen stoßen - sei es durch physikalische Randbedingungen, welche bestimmte Faktorstufenkombinationen ausschließen, oder durch strikte Limitierungen der verfügbaren Versuchskapazität [32, 39]. Derart klassische Versuchspläne wie der voll-faktorielle Versuchsplan sind aufgrund ihrer Versuchspunktanordnung stets *orthogonal* [3, 22]. Ein Versuchsplan wird als orthogonal bezeichnet, wenn keine Korrelation zwischen jeweils zwei Spalten der Versuchsplan-Matrix vorliegt - deren Skalarprodukte also jeweils null ergeben:

$$\langle x_i, x_j \rangle = 0 \quad \text{für alle } i \neq j. \quad (2.24)$$

Oder in anderen Worten: entspricht die Informationsmatrix $\mathbf{M}$ einer reinen Diagonalmatrix, ist der Versuchsplan orthogonal [3, 33]. So können Effekte eindeutig identifiziert werden - die Vektoren der Faktorstufenkombinationen sind linear unabhängig und Effekte lassen sich unverzerrt schätzen. Dies stellt einen Versuchsplan also zunächst einmal qualitativ günstig dar.

Um den Grad der Abweichung von diesem Idealzustand - etwa bei asymmetrisch ausgedünnten Designs oder durch praxisbedingte Modifikationen der Versuchsraumgeometrie - quantitativ bewerten zu können, hat sich in der Literatur der A_2 -Indikator als globales Maß für Nicht-Orthogonalität etabliert [57, 58]. Er berechnet sich als Summe der quadrierten Elemente abseits der Hauptdiagonalen der normierten Informationsmatrix $\mathbf{M}$:

$$A_2 = \sum_{i=1}^p \sum_{\substack{j=1 \\ j \neq i}}^p r_{ij}^2 \quad \text{mit} \quad r_{ij} = \frac{\mathbf{M}_{ij}}{\sqrt{\mathbf{M}_{ii}\mathbf{M}_{jj}}}, \quad (2.25)$$

wobei r_{ij} den paarweisen Korrelationskoeffizienten zwischen der i -ten und j -ten Spalte der Versuchsplan-Matrix repräsentiert. Folglich gilt für einen streng orthogonalen Plan $A_2 = 0$. Jeder Anstieg dieses Wertes signalisiert zunehmende Multikollinearität im Design, was das Risiko von Fehlschlüssen bei der Identifikation kausaler Haupteffekte und Interaktionen erhöht [28].

Zudem liegt *Ausgewogenheit* vor, sofern für einen jeweiligen Faktor alle anderen Faktoreinstellungen gleichmäßig aufgeteilt sind [31]. Damit wird Varianzhomogenität und Gleichbehandlung der Faktoren gewährleistet, sodass die Schätzung der Effekte unverzerrt erfolgt.

Mathematisch fundiert die Bewertung der Schätzgenauigkeit auf der Inversen der Informationsmatrix, welche als *Varianz-Kovarianz-Matrix* (oder *Dispersionsmatrix*) $(\mathbf{X}'\mathbf{X})^{-1}$ der Regressionskoeffizienten definiert ist:

$$\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}, \quad (2.26)$$

wobei wie gehabt σ^2 die Varianz des Versuchsfehlers darstellt.

Ein universelles Maß zur Beurteilung der Schätzgüte einzelner Parameter ist der *Mean Squared Error* (MSE). Er vereint die Varianz des Schätzers und dessen systematische Verzerrung (*Bias*) generell über alle Beobachtungen durch $1/n \sum_i^n (y_i - \hat{y}_i)^2$ in

einer Metrik und beschreibt für einen geschätzten Parameter $\hat{\beta}_j$ die erwartete quadratische Abweichung von dessen wahren Wert β_j :

$$\text{MSE}(\hat{\beta}_j) = E \left[(\hat{\beta}_j - \beta_j)^2 \right] = \text{Var}(\hat{\beta}_j) + \left(\text{Bias}(\hat{\beta}_j) \right)^2. \quad (2.27)$$

Da klassische Schätzverfahren (wie OLS oder MLE) unter regulären Bedingungen (hinreichend große Stichprobenumfänge, adäquate Modellannahmen) erwartungstreu sind ($\text{Bias} = 0$), entspricht der MSE in diesen Fällen exakt der Schätzvarianz $\text{Var}(\hat{\beta}_j)$ und skaliert folglich direkt mit den Diagonalelementen der inversen Informationsmatrix [9].

Während der A_2 -Indikator die Gesamtmatrix bewertet, stehen genau diese Diagonalelemente in direktem Zusammenhang mit dem *Varianz-Inflations-Faktor* (VIF) für die Evaluation einzelner Modellterme [31, 32]. Der VIF dient als Maßzahl für Multikollinearität und quantifiziert den Faktor, um den sich die Varianz (und damit der MSE) eines geschätzten Koeffizienten im Vergleich zu einem vollständig orthogonalen Design aufgrund von Korrelationen zwischen den Faktoren erhöht (vergleiche auch *Konditionszahl*) [9]. Während bei orthogonalen Plänen (Idealfall) ein $\text{VIF} = 1$ vorliegt, deuten hohe Werte (typischerweise > 5 oder > 10) auf eine instabile Modellschätzung hin [32, 33].

Zur lokalen Diagnose von Versuchspunkten und deren Auswirkung auf die Regressionsparameter existieren in der Fachliteratur etablierte Maßzahlen wie die Hebelwerte h_{ii} der Prädiktionsmatrix (*Hat-Matrix*) $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, die Cook-Distanz (D_i) sowie detaillierte Einflussstatistiken wie DFBETAS, DFFITS und COVRATIO - vergleiche Werke von Siebertz et al. [31], Montgomery et al. [33], Belsley [59] und Fahrmeir et al. [60]. Da es sich hierbei jedoch um rein retrospektive Diagnostikwerkzeuge handelt, die bereits vorliegende Versuchsergebnisse zwingend voraussetzen, finden sie im Rahmen der a priori Testplanung dieser Arbeit keine weitere Anwendung.

Optimalitätskriterien

Da in restriktiven Versuchsräumen Orthogonalität oft nicht erreichbar ist, zielen optimale Versuchspläne darauf ab, durch Minimierung spezifischer Eigenschaften der Dispersionsmatrix den Informationsgehalt der Versuchsmatrix algorithmisch zu maximieren. In klassischen, normalverteilten OLS-Modellen stützt sich diese Optimie-

rung ausschließlich auf die geometrischen Eigenschaften der Matrix $(\mathbf{X}'\mathbf{X})^{-1}$. Für die Auslegung multivariater Lebensdauertests (GLMs) muss diese klassische Momentenmatrix jedoch zwingend durch die parameterabhängige Fisher-Informationsmatrix substituiert werden. Mittels *Iteratively Weighted Least Squares* (IWLS) lässt sich diese Informationsmatrix $\mathbf{M}$ als gewichtetes Skalarprodukt ausdrücken [61]:

$$\mathbf{M} = \mathbf{X}'\mathbf{W}\mathbf{X}. \quad (2.28)$$

Die $n \times n$ Diagonalmatrix $\mathbf{W}$ enthält die Varianzen der Beobachtungen, welche wiederum direkte Funktionen der a priori unbekannten Modellparameter θ sind. Diese strukturelle Kopplung zwingt die Versuchsplanung bei Lebensdauerdaten zur Lösung eines streng lokalen Optimalitätsproblems, wofür zwingend theoretische Vorabannahmen (*Planning Values*) für θ getroffen werden müssen [62, 63]. Damit ist eine a-priori Grundkenntnis der zu erwartenden Lebensdauerverteilung und deren Parameter unabdingbar, um die geometrische Güte des Versuchsplans erfolgreich zu maximieren. Verfahren zur Bayesscher Optimierung der *Planning Values* erlauben die Reduktion etwaiger Unsicherheiten und werden von Monroe et al. [61] detailliert beschrieben.

Unter steter Berücksichtigung dieses fundamentalen stochastischen Vorbehalts fasst Tabelle 2.4 die etablierten Optimalitätskriterien zusammen, welche primär die geometrische Güte quantifizieren und den Vergleich zur Standard-Methodik ermöglichen [22, 39]. Sie bilden mitunter die Grundlage für diverse weitere Optimalitäten und hybride Ansätze und lassen sich prinzipiell in Modellierungskriterien (*A*-, *D*-Optimalität) und Prädiktionskriterien (*G*-, *I*-, *U*-, *V*-Optimalität) unterteilen [3, 36]. Während konventionelle Ansätze stets die Optimierung eines einzelnen Kriteriums anstreben, können in der Praxis auch mehrere Kriterien gleichzeitig berücksichtigt werden, um eine ausgewogene Optimierung zu erreichen [39, 64].

Tabelle 2.4: Übersicht, Zielsetzung und mathematische Definition verschiedener Optimalitätskriterien für Versuchspläne

Kriterium	Zielgröße, Beschreibung und Definition
A-Optimalität	Minimierung der Spur der inversen Informationsmatrix [3, 22, 32]. <i>Ziel: Maximale Präzision der einzelnen Parameter im Durchschnitt.</i> $A_{\text{opt}} = \min \left(\text{spur} \left(\mathbf{M}^{-1} \right) \right) = \min \left(\sum_{j=1}^k \text{Var} \left(\hat{\beta}_j \right) \right) \quad (2.29)$
D-Optimalität	Maximierung der Determinante der Informationsmatrix $\mathbf{M}$. Da das Volumen des Vertrauensellipsoids der Koeffizientenschätzwerte umgekehrt proportional zur Quadratwurzel der Determinante ($\sqrt{\det(\mathbf{M})}$) ist, minimiert dieses Kriterium das Unsicherheitsvolumen im Parameterraum [22, 32, 36, 65]. <i>Ziel: Minimierung des Volumens des gemeinsamen Vertrauensbereichs aller Modellparameter.</i> $D_{\text{opt}} = \max \left(\det(\mathbf{M}) \right) = \min \left(\det \left(\mathbf{M}^{-1} \right) \right) \quad (2.30)$
G-Optimalität	Minimierung der maximalen skalierten Prädiktionsvarianz $\nu(\mathbf{x}_0)$ im relevanten Parameterraum [22, 36, 44]. <i>Ziel: Qualität der Vorhersage an der ungünstigsten Stelle sichern.</i> $G_{\text{opt}} = \min \left(\max_{\mathbf{x}_0 \in \mathbb{R}^k} \nu(\mathbf{x}_0) \right) \quad (2.31)$

Fortsetzung auf der nächsten Seite...

Tabelle 2.4 (Fortsetzung): Übersicht der Optimalitätskriterien

Kriterium	Zielgröße, Beschreibung und Definition
I-Optimalität	Minimierung der durchschnittlichen (<i>integrierten</i>) Prädiktionsvarianz über den Parameterraum [3, 65]. <i>Ziel: Optimale Vorhersagegüte (SPV) im Mittel über den gesamten Raum - z.B. bei initialer Parametrisierung eines multivariaten Lebensdauermodells.</i> $I_{\text{opt}} = \min \left(\frac{N}{\int_{\mathbb{R}^k} dx} \int_{\mathbb{R}^k} v(\mathbf{x}_0) dx \right) \quad (2.32)$
U-Optimalität	Minimierung der Prädiktionsvarianz an einem spezifischen Betriebspunkt, der Standard-Nutzungsbedingung (<i>Use-Condition</i>). W bezeichnet die parameterabhängige Gewichtsmatrix des GLM (vgl. Abschnitt 2.2.6), deren Aufstellung initiale Vorabannahmen der Modellparameter voraussetzt. [3, 61, 62, 63]. <i>Ziel: Maximale Vorhersagegenauigkeit für extrapolierte Lebensdauern unter realen Feldbedingungen.</i> $U_{\text{opt}} = \min \left(\mathbf{x}_0' \cdot (\mathbf{X}'\mathbf{W}\mathbf{X})^{-1} \cdot \mathbf{x}_0 \right) \quad (2.33)$
V-Optimalität	Minimierung der durchschnittlichen Prädiktionsvarianz über ein diskretes Set von N Punkten [22, 39, 49]. <i>Ziel: Optimale Vorhersagegüte (SPV) an spezifischen i Stellen - z.B. bei L-DoE-Versuchspunkten oder spezifischen Nennlasten.</i> $V_{\text{opt}} = \min \left(\frac{1}{N} \sum_{i=1}^N v(x_i) \right) \quad (2.34)$

Zur vergleichbaren Bewertung unterschiedlicher Designs unabhängig von der Skalierung werden normierte *Effizienzen* herangezogen [22]. Aus Tabelle 2.4 lassen sich

die **A-Effizienz** A_{eff} , **D-Effizienz** D_{eff} , **G-Effizienz** G_{eff} , **I-Effizienz** I_{eff} und **V-Effizienz** V_{eff} ableiten, welche jeweils die Güte $[0, 1]$ eines Versuchsplans quantifizieren - vergleiche Tabelle 2.5.

Tabelle 2.5: Übersicht, Zielsetzung und mathematische Definition verschiedener Effizienzkriterien für Versuchspläne

Kriterium	Zielgröße, Beschreibung und Definition
A-Effizienz	Maß für die durchschnittliche Präzision der Regressionskoeffizienten. [36, 39]. $A_{\text{eff}} = 100 \cdot \frac{p}{\text{spur}(N \cdot \mathbf{M}^{-1})} \quad (2.35)$
D-Effizienz	Maß für den Informationsgehalt der Informationsmatrix $\mathbf{M}$, definiert über die Determinante, umgekehrt proportional zum Volumen des Vertrauensellipsoids der Parameterschätzwerte und durch die Potenzierung mit $1/p$ pro Schätzparameter normiert. [36, 39]. $D_{\text{eff}} = 100 \cdot \frac{\det(\mathbf{M})^{1/p}}{N} \quad (2.36)$
G-Effizienz	Maß für die Vorhersagegüte im ungünstigsten Fall innerhalb des Versuchsraums. Da für die maximale SPV die theoretische Untergrenze $\nu(\mathbf{x}_0)_{\max} \geq p$ gilt, beschreibt dieses Kriterium das Verhältnis zwischen idealer und realisierter maximaler Varianz [36]. $G_{\text{eff}} = 100 \cdot \frac{p}{\nu(\mathbf{x}_0)_{\max}} \quad (2.37)$

Fortsetzung auf der nächsten Seite...

Tabelle 2.5 (Fortsetzung): Übersicht der Effizienzkriterien

Kriterium	Zielgröße, Beschreibung und Definition
I-Effizienz	Maß für die durchschnittliche Vorhersagegüte über den gesamten Versuchsraum [36]. $I_{\text{eff}} = 100 \cdot \frac{p}{\frac{1}{\int_R dx} \int_R v(\mathbf{x}_0) dx} \quad (2.38)$
V-Effizienz	Maß für die durchschnittliche Vorhersagegüte über ein diskretes Set von N Punkten analog zu Gleichung 2.38 [36]. $V_{\text{eff}} = 100 \cdot \frac{1}{N} \sum_{i=1}^N \frac{p}{v(\mathbf{x}_0)(x_i)} \quad (2.39)$

Forschungsschwerpunkte in der RSM

Während die klassische sequentielle Strategie (Screening gefolgt von Augmentierung zum CCD oder Anpassung von Parameterräumen mit optimalen Versuchsplänen) die methodischen Risiken minimiert, erfordert sie oft einen hohen administrativen und zeitlichen Aufwand durch mehrere Versuchsphasen - insbesondere bei technischen Versuchsanlagen mit hohem Rüst-Aufwand. Als Antwort darauf entwickelten Jones und Nachtsheim [38] zunächst die Klasse der *Definitive Screening Designs* (DSDs), um auch bei größeren Faktorenzahlen (typisch $k \geq 4$) Haupteffekte von Effekten zweiter Ordnung (Zweifach-Wechselwirkungen und quadratische Terme) in einem Schritt zu separieren. Da DSDs jedoch eine starre Struktur aufweisen und oft nur eine geringe statistische Power zur Schätzung quadratischer Effekte bieten, etablierte sich in jüngster Forschung die umfassendere Klasse der *Orthogonal Minimally Aliased Response Surface* (OMARS)-*Designs*, zu der Goos [66] zuletzt eine detaillierte Übersichtsarbeit vorlegte. Núñez Ares und Goos [67] erarbeiteten hierfür einen Katalog verschiedener OMARS-Designs, die im Gegensatz zu klassischen Plänen eine flexible Wahl der Versuchsanzahl n ermöglichen. Diese Designs zielen spezifisch auf

den fließenden Übergang von Screening zu RSD in einem einzigen experimentellen Schritt ab (*One-Step Approach*). Dazu basieren sie auf der Variation aller quantitativen Faktoren auf drei Stufen $(-1, 0, +1)$, um quadratische Zusammenhänge prinzipiell abzubilden. Die statistische Konstruktion garantiert dabei zwei fundamentale Orthogonalitätseigenschaften, die sie von klassischen Optimal-Designs abgrenzen: Erstens sind alle Haupteffekte orthogonal zueinander, was eine unabhängige Schätzung der linearen Einflüsse sichert. Zweitens sind die Haupteffekte vollständig unkorreliert mit sämtlichen Effekten zweiter Ordnung (sowohl Zweifach-Wechselwirkungen als auch quadratische Terme). Das verbleibende Aliasing (Vermengung) beschränkt sich somit ausschließlich auf die Gruppe der Effekte zweiter Ordnung untereinander und wird algorithmisch minimiert (engl. *Minimally Aliased*). Dies erlaubt eine signifikante Flexibilisierung der Stichprobengröße im Vergleich zu starr definierten Plänen wie dem CCD, bei gleichzeitigem Erhalt der robusten Schätzbarkeit der primären Haupteffekte. Die Generierung eines solchen OMARS-Designs erfolgt dabei nicht über geometrische Konstruktionsvorschriften (wie beim CCD), sondern algorithmisch durch die Lösung eines ganzzahligen linearen Optimierungsproblems (engl. *Integer Linear Programming (ILP)*). Basierend auf der Kandidatenmenge Ω (üblicherweise entsprechend einem voll-faktoriellen 3^{k_f} Plan) wird ein Vektor binärer Entscheidungsvariablen $\gamma \in \{0, 1\}^{|\Omega|}$ gesucht, der folgende mathematische Restriktionen simultan erfüllt:

- **Einhaltung des Stichprobenumfangs:**

Die Summe der ausgewählten Versuchspunkte muss exakt der gewünschten Anzahl n entsprechen:

$$\sum_{i=1}^{|\Omega|} \gamma_i = n. \quad (2.40)$$

- **Orthogonalität der Haupteffekte:**

Jedes Paar von Haupteffekt-Spalten j und l muss unkorreliert sein. Für die kodierten Faktorstufen $x_{ij} \in \{-1, 0, +1\}$ des i -ten Kandidaten gilt:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot x_{il} = 0 \quad \forall 1 \leq j < l \leq k_f. \quad (2.41)$$

- **Orthogonalität Haupteffekt zu Effekten zweiter Ordnung:**

Dies ist das definierende Merkmal. Jeder Haupteffekt j muss orthogonal zu

jedem Effekt zweiter Ordnung (Interaktion $x_l x_k$ oder quadratischer Term x_l^2) sein:

$$\sum_{i=1}^{|\Omega|} \gamma_i \cdot x_{ij} \cdot (x_{il} \cdot x_{ik}) = 0 \quad \forall j, l, k \in \{1, \dots, k_f\}. \quad (2.42)$$

Unter Einhaltung dieser harten Nebenbedingungen wird anschließend jene Design-Variante ausgewählt, welche die Aliasing-Struktur der Effekte zweiter Ordnung untereinander minimiert (z. B. durch Maximierung von D_{opt} , vgl. Gleichung 2.30).

Signifikanz und Trennschärfe

Weiter muss sichergestellt werden, dass der Versuchsplan über eine ausreichende *Trennschärfe* (*power*) verfügt. Die Trennschärfe beschreibt als Metrik diejenige Wahrscheinlichkeit, mit der ein existierender Einfluss durch Faktoren vor dem Hintergrund des experimentellen Rauschens (vergleiche *t*-Statistik, SNR, *Signifikanztests* nach [22, 32, 39]) korrekt als *signifikanter* Effekt E identifiziert wird [31, 32]. Insofern ist ein Effekt in praktischem Umfeld natürlich problemabhängig (Streuungscharakteristik der Lebensdauer, realisierbare Stichprobengröße, etc.) und meist von Bedeutung für $E \geq 2\sigma$, wobei Trennschärfewerte $\geq 80\%$ als befriedigend gelten [3, 22]. Insbesondere bei reduzierten Versuchsplänen und unter dem Einfluss stochastischer Lebensdauerstreuung ist die *power*-Analyse jedoch essenziell, um das Risiko von falsch-negativen Schlussfolgerungen zu minimieren. Letztendlich kann die Trennschärfe somit als Garantimetrik verstanden werden, die sicherstellt, dass ein geplanter Versuchsaufbau in der Lage ist, Effekte von praktischer Relevanz zu detektieren [36, 68] - was vornehmlich in Bezug auf Lebensdauertests aufgrund genannter wirtschaftlicher Randbedingungen von hoher Bedeutung ist.

Formalisiert wird dies im Rahmen *statistischer Hypothesentests* [22, 32]. Die Zielsetzung besteht darin, den Nachweis zu erbringen, ob ein bestimmter Faktor x_j einen signifikanten Einfluss auf die Systemantwort y ausübt. Dazu werden zwei konkurrierende Hypothesen formuliert: Die *Nullhypothese* H_0 unterstellt, dass kein Zusammenhang besteht, der korrespondierende Regressionskoeffizient β_j (vgl. Abschnitt 2.2.6) also den Wert Null annimmt:

$$H_0 : \beta_j = 0 \quad \text{gegen} \quad H_1 : \beta_j \neq 0. \quad (2.43)$$

Die *Alternativhypothese* H_1 postuliert hingegen einen signifikanten Effekt ($\beta_j \neq 0$). Die Entscheidung über die Annahme oder Ablehnung von H_0 basiert auf dem p -Wert. Dieser quantifiziert die Wahrscheinlichkeit, unter der Annahme der Gültigkeit von H_0 die beobachteten Daten (oder extremere Ergebnisse) zu erhalten. Unterschreitet der p -Wert das a priori definierte *Signifikanzniveau* α (üblicherweise $\alpha = 0,05$), wird H_0 zugunsten der Alternativhypothese H_1 verworfen. Der Fehler, H_0 fälschlicherweise abzulehnen, obwohl kein Effekt vorliegt, wird als Fehler 1. Art bezeichnet; seine Wahrscheinlichkeit ist durch α begrenzt. Die *Trennschärfe* fokussiert hingegen auf den Fehler 2. Art (oft mit β_{error} notiert), welcher das Risiko beschreibt, einen tatsächlich vorhandenen Effekt nicht zu erkennen (falsch-negative Entscheidung). Die *power* ist folglich definiert als das Komplement dieses Fehlers ($1 - \beta_{\text{error}}$) und entspricht der Wahrscheinlichkeit, H_0 korrekterweise abzulehnen, wenn H_1 wahr ist:

$$\text{power} = \Pr(H_0 \text{ ablehnen} \mid H_1 \text{ ist wahr}) = 1 - \beta_{\text{error}}. \quad (2.44)$$

In idealisierten, orthogonalen Standard-Versuchsplänen unter der Annahme normalverteilter Residuen $\epsilon \sim \mathcal{N}(0, \sigma^2)$ lässt sich die Trennschärfe für klassische OLS-Regressionsmodelle exakt analytisch bestimmen. Die *power* berechnet sich hierbei aus der Wahrscheinlichkeit, dass die Teststatistik unter der Alternativhypothese H_1 den kritischen Wert einer nicht-zentralen Prüfverteilung überschreitet. Der Grad dieser Verschiebung wird durch den sogenannten *Nichtzentralitätsparameter* δ_{nc} quantifiziert [22, 69]. Für die Überprüfung eines individuellen Modellparameters β_j ist dieser definiert als:

$$\delta_{\text{nc}} = \frac{|\beta_j|}{\sigma \sqrt{(\mathbf{X}'\mathbf{X})_{jj}^{-1}}}, \quad (2.45)$$

wobei $|\beta_j|$ die zu detektierende wahre Effektstärke und σ die Standardabweichung des experimentellen Rauschens darstellt [36, 68]. Der funktionale Zusammenhang zwischen diesem Nichtzentralitätsparameter und der resultierenden Trennschärfe ist jedoch hochgradig nichtlinear: Die *power* folgt in Abhängigkeit von δ_{nc} - und damit vom Signal-Rausch-Verhältnis - dem Verlauf einer *sigmoidalen Sättigungsfunktion*, vergleiche Abbildung 2.5 [68]. In den asymptotischen Randbereichen (bei extrem schwachen oder hochgradig dominanten Effekten) reagiert die Trennschärfe nahezu unempfindlich auf topologische Änderungen im Design. Im Bereich des Wendepunkts - der *steilsten Flanke* dieser sigmoidalen Funktion - entfaltet die geometrische




Abbildung 2.5: Zusammenhang zwischen *power* und δ_{nc} .

Matrixstruktur $\mathbf{X}$ hingegen ihren maximalen Hebel auf die Prognosegüte. Anhand der analytischen OLS-Metrik in Gleichung 2.45 wird dieser Mechanismus unmittelbar ersichtlich: Sobald die topologische Orthogonalität verloren geht, entstehen signifikante Kovarianzen in der Informationsmatrix $\mathbf{M} = \mathbf{X}'\mathbf{X}$. Die Invertierung dieser Matrix erzwingt eine Inflation des Diagonalelements $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$, was den Wert von δ_{nc} mathematisch komprimiert und die Trennschärfe genau an der kritischen Flanke der Funktion drastisch einbrechen lässt. Für die multivariate Lebensdauererprobung verliert diese analytische Berechnung jedoch ihre methodische Anwendbarkeit. Aufgrund der asymmetrischen Verteilungsannahmen (Weibull) und dem Vorliegen zensierter Daten existieren im GLM-Framework keine geschlossenen analytischen Lösungen zur exakten Bestimmung der Trennschärfe. Die Signifikanz der Koeffizienten β_j muss hier vorzugsweise über numerische *Likelihood-Ratio Tests* (*LR-Tests*) oder approximativ über *Wald-Tests* ermittelt werden [2, 3, 70]. Die Quantifizierung der Trennschärfe erfordert in der modernen Zuverlässigkeitsplanung folglich zwingend *Monte-Carlo-Simulationen* (*MCSs*) [4, 71, 72]. Hierbei wird der geplante Versuchsplan unter Vorgabe eines definierten Effektmodells virtuell iteriert (n_{MC} Simulationsläufe), mit stochasti-

scher Streuung überlagert und zensiert, um den relativen Anteil korrekter Signifikanz-Entscheidungen ($p\text{-Wert} < \alpha$) als empirischen Schätzer der Test-Power zu extrahieren.

2.2.6 Statistische Modellbildung

Die statistische Modellbildung quantifiziert den funktionalen Zusammenhang zwischen den systematisch variierten Einflussfaktoren x_i und der beobachteten Systemlebensdauer. Aufgrund der in Abschnitt 2.1 dargelegten Eigenschaften empirischer Lebensdauerdaten mit inhärenter Nicht-Normalverteilung und rechts-zensierten Beobachtungen verletzt die klassische Methode entsprechend OLS fundamentale stochastische Regressionsprämissen und generiert systematisch verzerrte Schätzer. Zur methodisch belastbaren Modellierung kommt stattdessen das Framework der GLMs zur Anwendung, welches den linearen Prädiktor formal mit der zugrundeliegenden Verteilung verknüpft [2, 3, 6]. Hinsichtlich der Modellauswahl kann in klassischen Ansätzen der Versuchsplanung dabei oft auf Potenztransformationen der Antwortvariablen in Form $y^{(\lambda_{BC})}$ oder $\ln(y)$ (für $\lambda_{BC} = 0$ mit geometrischem Mittelwert der Beobachtung $\bar{y} = \exp[\frac{1}{n} \sum_{i=1}^n \ln(y_i)]$) zurückgegriffen werden - wie die *Box-Cox-Transformation* nach Montgomery et al. [33] und Box und Cox [73]. So wird die Varianzhomogenität und Normalverteilung approximiert zu [33]:

$$y_i^{(\lambda_{BC})} = \begin{cases} \frac{y_i^{\lambda_{BC}} - 1}{\lambda_{BC} \bar{y}^{\lambda_{BC} - 1}}, & \text{für } \lambda_{BC} \neq 0, \\ \bar{y} \ln(y_i), & \text{für } \lambda_{BC} = 0. \end{cases} \quad (2.46)$$

Im Kontext der expliziten Lebensdaueranalyse ist dieser generische Ansatz jedoch weniger gebräuchlich, da die physikalisch motivierte Verteilungsannahme (z.B. Weibull) bereits eine inhärente Transformation der Ausfallzeit impliziert - vgl. Abschnitt 2.1.3, Gleichung 2.8 sowie Yang [6] und Wu und Hamada [28]. Unter der Annahme Weibullverteilter Ausfallzeiten (Abschnitt 2.1.3) führen $j = 0, \dots, k$ betrachtete Parameter aus Gleichung 2.17 und n Beobachtungen entsprechend Gleichung 2.8 zum Erwartungswert der charakteristischen Lebensdauer als *Link-Funktion* der Einflussfaktoren x_i und des unbekannten Koeffizientenvektors $\hat{\beta}$ [6, 28, 74] über *Accelerated Failure Time (AFT)*-Modell:

$$E_{\theta_x}(\ln(T)) = y = \beta_0 + \sum_{j=1}^k \beta_j x_j + \dots + \epsilon. \quad (2.47)$$

In der Lebensdauer-Datenanalyse wird neben den GLM-Ansätzen insbesondere der *Proportional Hazard (PH)*-Modell-Ansatz verwendet. Die Stärke dieser PH-Modelle bildet dabei die Abbildung zeitabhängiger Kovariaten, weshalb sie vornehmlich in der Biostatistik verwendet werden [75, 76]:

$$f(t, \mathbf{X}) = \lambda(t)(t, \mathbf{X}) \cdot R(t, \mathbf{X}) = b \cdot t^{b-1} \cdot e^{[y - t^b e^y]}. \quad (2.48)$$

Weibull-GLM

Im ingenieurwissenschaftlichen Kontext - maßgeblich gestützt durch Ausführungen in Meeker et al. [2], Yang [6], Wu und Hamada [28], Myers et al. [49], Kremer et al. [76], Dobson und Barnett [77] und Stufken und Yang [78] - finden hingegen *Log-Location-Scale-Modelle*, also GLMs, überwiegend Anwendung. Obwohl für die Weibull-Verteilung eine mathematische Äquivalenz zwischen beiden Ansätzen besteht, sprechen drei fundamentale Gründe für deren Verwendung.

- **Physikalischer Bezug:**

Gängige physikalische Beschleunigungsmodelle (Arrhenius, Inverses Potenzgesetz) beschreiben die Änderung der *Zeit* bis zum Ausfall ($\ln(\hat{T})$) und nicht der Ausfallrate. Die Log-Linearisierung dieser Gesetze führt direkt auf die Regressionsgleichung der Location-Scale-Modelle.

- **Universalität der Auswertung:**

Das Modell bietet einen einheitlichen mathematischen Rahmen, der nicht nur für die Weibull-Verteilung, sondern identisch auch für die Lognormal-Verteilung und Normalverteilung gültig ist. Das PH-Modell hingegen ist für Lognormal-Verteilungen mathematisch nicht geschlossen anwendbar.

- **Fokus auf Lebensdauer-Quantile:**

In der Zuverlässigkeitstechnik liegt das Interesse primär auf der Prädiktion von Ausfallzeiten für geringe Ausfallanteile (z.B. t_{10}).

Diese Größen sind direkte Ergebnisse der Location-Scale-Gleichung, während sie im PH-Modell nur indirekt über die Invertierung der Hazard-Funktion zugänglich sind.

Folglich wird eine zufallsverteilte Lebensdauer τ für ein Weibull-GLM mit der Dichtefunktion

$$f(t, \mathbf{X}) = b \cdot t^{b-1} e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_j)} \cdot e^{-t^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_j)}}, \quad t > 0. \quad (2.49)$$

beschrieben und analog zu Gleichung 2.15 in die *Generalized Log-Linear (GLL)-Funktion* überführt [6, 44, 79]:

$$\begin{aligned} \Lambda &= \ln(\mathcal{L}(t_i; b, \beta_0, \dots, \beta_k)) \\ &\propto \sum_{i=1}^n \left[\ln(b) - b \left(\beta_0 + \sum_{j=1}^k \beta_j x_{ij} \right) + (b-1) \ln(t_i) - t_i^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})} \right]. \end{aligned} \quad (2.50)$$

Werden außerdem (rechts-) zensierte Daten berücksichtigt, so ergibt sich analog zu Gleichung 2.15 über Gleichung 2.50 die erweiterte GLL-Funktion [2, 6]:

$$\Lambda_z \propto \Lambda - (1 - \delta_i) \cdot t_i^b e^{-b(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})}. \quad (2.51)$$

Sollen über die rein empirische Datenauswertung hinaus bekannte physikalische Gesetzmäßigkeiten im Modell berücksichtigt werden, ist die lineare Struktur des Prädiktors entsprechend anzupassen. Dies erfolgt durch eine Transformation der physikalischen Beanspruchungsgrößen x in den Modellraum. Anstelle der direkten Verwendung des Einflussfaktors in der GLL-Beziehung (Gleichung 2.49) wird eine transformierte Größe x_V eingesetzt, welche die physikalische Natur des Schädigungsmechanismus abbildet. Gängige Transformationen umfassen hierbei die reziproke Anpassung für thermische Lasten (*Arrhenius*) oder logarithmische Ansätze für elektrische Potenzmodelle, vgl. Tabelle 2.6. Eine Übersicht verschiedener Modellierungsansätze (z.B.

Tabelle 2.6: Übersicht gängiger Transformationen der Belastungsgrößen zur Abbildung physikalischer Lebensdauermodelle

Art	Transformation	Lebensdauermodell	Anwendungsfall
Keine	$x_V = x$	Exponential / Wöhler	mechanisch
Reziprok	$x_V = 1/x$	Arrhenius	thermisch
Logarithmisch	$x_V = e^x$	Potenzmodell	elektrisch

Arrhenius-Modell, Inverses Potenzgesetz, Eyring, Coffin-Manson-Modell, etc.) und deren Einbindung in die GLM-Struktur findet sich in [2, 3, 75]. Die Schätzung der unbekannten Parameter $\hat{\beta}$ und $\hat{b}$ erfolgt mittels numerischer Maximierung der GLL-Funktion (Gleichung 2.51).

Signifikanzanalyse

Liegen die Parameterschätzungen $\hat{\theta}_i$ vor, erfolgt die Bewertung ihrer statistischen Relevanz mittels LR-Test. Dieses Verfahren stellt das methodische Äquivalent zur *Varianzanalyse, engl. Analysis of Variance (ANOVA)* bei normalverteilten Daten dar und prüft, ob die Aufnahme eines Parameters die Modellanpassung signifikant verbessert. Der Test basiert auf dem Vergleich der maximalen Likelihood des vollständigen Modells $\mathcal{L}(\hat{\theta}_i)$ gegenüber der eines reduzierten Modells $\mathcal{L}(\hat{\theta}_{-i})$, aus dem der zu untersuchende Parameter eliminiert wurde [4, 80]. Die Teststatistik LR quantifiziert den Informationsverlust durch die Modellreduktion und ist definiert als *Devianz-Funktion* [2, 81]:

$$LR = -2 \ln \left(\frac{\mathcal{L}(\hat{\theta}_{-i})}{\mathcal{L}(\hat{\theta}_i)} \right) = 2 \cdot [\ln(\mathcal{L}(\hat{\theta}_i)) - \ln(\mathcal{L}(\hat{\theta}_{-i}))]. \quad (2.52)$$

Unter der Nullhypothese H_0 , dass der ausgeschlossene Parameter keinen Einfluss hat, folgt LR asymptotisch einer χ^2 -Verteilung mit d_f Freiheitsgraden (Anzahl der ausgeschlossenen Parameter, hier meist $d_f = 1$). Die Signifikanzentscheidung erfolgt über den p -Wert, der die Wahrscheinlichkeit angibt, einen Testwert $\geq LR$ zu beobachten:

$$p\text{-Wert} = \Pr(\chi^2(d_f) \geq LR). \quad (2.53)$$

Ist dieser p -Wert kleiner als das definierte Signifikanzniveau $p\text{-Wert} < \alpha$, wird der Parameter als signifikant in das Modell aufgenommen.

Erwartungswerte und Konfidenzintervalle

Nach der Ermittlung der optimalen Modellparameter $\hat{\theta}$ ist die Quantifizierung der mit diesen Schätzungen verbundenen Unsicherheit essenziell. Analytisch erfolgt dies über die Betrachtung der Krümmung der Log-Likelihood-Funktion Λ im Maximum. Je stärker die Krümmung, desto präziser ist die Schätzung (geringere Varianz). Mathematisch erfordert dies die Auswertung der Hesse-Matrix $\mathbf{H}_f$, welche die zweiten

partiellen Ableitungen der Log-Likelihood-Funktion nach den Parametern θ_i (also β_j und b) enthält.

Da die theoretische (erwartete) Fisher-Informationsmatrix die Kenntnis der wahren Parameter θ erfordert, wird in der statistischen Praxis stattdessen die *beobachtete* Fisher-Informationsmatrix $\mathbf{F}_{\text{ob}}$ (engl. *Observed Fisher Information*) herangezogen [12, 82]. Diese ist definiert als die negative Hesse-Matrix, ausgewertet an der Stelle der MLE-Schätzwerte $\hat{\theta}$ [20, 83]:

$$\mathbf{F}_{\text{ob}} := -\mathbf{H}_{\mathbf{f}}(\hat{\theta}) = \begin{bmatrix} -\frac{\partial^2 \mathcal{L}}{\partial \theta_1^2} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_1 \partial \theta_k} \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2^2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_2 \partial \theta_k} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_1} & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k \partial \theta_2} & \cdots & -\frac{\partial^2 \mathcal{L}}{\partial \theta_k^2} \end{bmatrix}. \quad (2.54)$$

Die asymptotische Varianz-Kovarianz-Matrix $\hat{\mathbf{V}}$ der Parameterschätzer wird anschließend durch die Inversion der Fisher-Informationsmatrix für $\hat{\theta} = \theta$ approximiert [6, 83]:

$$\hat{\mathbf{V}} \approx \mathbf{F}_{\text{ob}}^{-1} = \begin{bmatrix} \hat{\text{Var}}(\hat{\theta}_1) & \hat{\text{Cov}}(\hat{\theta}_1, \hat{\theta}_2) & \cdots & \hat{\text{Cov}}(\hat{\theta}_1, \hat{\theta}_k) \\ \hat{\text{Cov}}(\hat{\theta}_2, \hat{\theta}_1) & \hat{\text{Var}}(\hat{\theta}_2) & \cdots & \hat{\text{Cov}}(\hat{\theta}_2, \hat{\theta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\text{Cov}}(\hat{\theta}_k, \hat{\theta}_1) & \hat{\text{Cov}}(\hat{\theta}_k, \hat{\theta}_2) & \cdots & \hat{\text{Var}}(\hat{\theta}_k) \end{bmatrix}. \quad (2.55)$$

Die Hauptdiagonalelemente dieser Matrix liefern die geschätzten Varianzen $\hat{\text{Var}}(\hat{\theta}_j)$ der einzelnen Modellparameter. Unter der Annahme der asymptotischen Normalverteilung der MLE beschreibt Yang [6] neben weiteren Alternativen aus Meeker et al. [2] und Kremer und Bertsche [80] die symmetrischen $(1 - \alpha)$ -Konfidenzintervalle (Wald-Intervalle) wie nachfolgend:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\text{Var}}(\hat{\theta}_j)} \quad \text{bzw.} \quad \cdots = \hat{\theta}_j \exp \left(\pm z_{1-\alpha/2} \cdot \frac{\sqrt{\hat{\mathbf{V}}_{jj}}}{\hat{\theta}_j} \right), \quad (2.56)$$

wobei $z_{1-\alpha/2}$ dem $(1 - \alpha/2)$ -Quantil der Standardnormalverteilung entspricht. Da Lebensdauerparameter (z. B. der Skalenparameter T) definitionsgemäß auf den positiven reellen Zahlenraum beschränkt sind, erfolgt die Berechnung der CIs standardmäßig über die im rechten Teil der Gleichung 2.56 aufgeführte Log-Transformation,

um physikalisch unmögliche, negative Intervallgrenzen mathematisch konsistent auszuschließen.

Vertrauensbereiche für Funktionswerte und Weibull-GLM

Oft ist nicht nur die Unsicherheit der Modellparameter selbst, sondern die der daraus abgeleiteten Funktionen - wie der Zuverlässigkeit $R(t)$ oder der Ausfallwahrscheinlichkeit $F(t)$ - von Interesse. Zur analytischen Ermittlung dieser sogenannten Fisher-Vertrauensbereiche führt Yang [6] zunächst eine Hilfsgröße w ein - vergleiche auch z_e nach Meeker et al. [2]. Diese normiert die logarithmische Abweichung der betrachteten Zeit t von der geschätzten charakteristischen Lebensdauer $\hat{T}$ mit dem Formparameter $\hat{b}$ (vergleiche auch Bain und Engelhardt [84] für weitere Abschätzungen):

$$\hat{w} = \hat{b} \cdot \ln \left(\frac{t}{\hat{T}} \right). \quad (2.57)$$

Die Varianz dieser transformierten Hilfsgröße lässt sich mittels der *Delta-Methode* (einer auf der Taylor-Reihenentwicklung basierenden, linearen Fehlerfortpflanzung) approximativ aus den Varianzen und Kovarianzen der Parameterschätzer bestimmen:

$$\hat{\text{Var}}(\hat{w}) = \left(\frac{\hat{b}}{\hat{T}} \right)^2 \hat{\text{Var}}(\hat{T}) + \left(\frac{\hat{w}}{\hat{b}} \right)^2 \hat{\text{Var}}(\hat{b}) - \frac{2\hat{w}}{\hat{T}} \hat{\text{Cov}}(\hat{T}, \hat{b}). \quad (2.58)$$

Basierend auf der asymptotischen Normalverteilung ergeben sich die Vertrauensgrenzen $[\hat{w}_u, \hat{w}_o]$ gemäß:

$$[\hat{w}_u, \hat{w}_o] = \hat{w} \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\text{Var}}(\hat{w})}. \quad (2.59)$$

Die Rücktransformation dieser Grenzen in den Wertebereich der Ausfallwahrscheinlichkeit erfolgt anschließend über die Verteilungsfunktion der kleinsten Extremwerte $G = 1 - \exp[-\exp(\hat{w})]$, woraus sich direkt die Konfidenzintervalle der Zuverlässigkeit ableiten lassen. Im Fall von GLM ist zu berücksichtigen, dass die geschätzte charakteristische Lebensdauer $\hat{T}$ keine unabhängige Konstante ist, sondern funktional entsprechend Gleichung 2.47 von den Kovariaten x und dem Parametervektor $\hat{\beta}$ abhängt. Die für Gleichung 2.58 benötigte Varianz $\hat{\text{Var}}(\hat{T})$ muss folglich unter Berücksichtigung der gesamten Kovarianzmatrix der Regressionskoeffizienten aus Gleichung

chung 2.55 berechnet werden. Dies erfolgt durch die allgemeine Fehlerfortpflanzung nach Gauß:

$$\hat{\text{Var}}(\hat{T}) \approx \sum_{i=1}^k \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i} \right)^2 \hat{\text{Var}}(\hat{\beta}_i) + \sum_{i=1}^k \sum_{\substack{j=1 \\ j \neq i}}^k \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_i} \right) \left(\frac{\partial \hat{T}}{\partial \hat{\beta}_j} \right) \hat{\text{Cov}}(\hat{\beta}_i, \hat{\beta}_j). \quad (2.60)$$

Modellgüte und Residuenanalyse

Die Validität eines parametrischen Lebensdauermodells (hier Weibull-GLM) beruht auf drei fundamentalen Annahmen, die es nach der Parameterschätzung zu verifizieren gilt: Erstens folgen die Lebensdauern der angenommenen Verteilung. Zweitens sind die Lebensdauern statistisch unabhängig. Drittens besteht ein log-linearer Zusammenhang zwischen dem Skalenparameter und den Einflussgrößen, wobei der Formparameter in einfachen Modellen als konstant über den gesamten Versuchsraum angenommen wird. Die Beurteilung dieser Modellgüte erfordert bei Lebensdauerdaten, bedingt durch Nicht-Normalverteilung und Zensierung, eine Anpassung klassischer Konzepte zur Residuenanalyse ($y - \hat{y}$) [31, 32]. Stattdessen werden transformierte Residuen betrachtet, die den Bezug zur Verteilung der kleinsten Extremwerte *SEV* herstellen, welcher der logarithmierten Weibull-Verteilung zugrunde liegt. Analog zur z-Transformation bei der Normalverteilung lassen sich für jede Beobachtung t_i standardisierte Residuen r_i berechnen. Dabei ersetzt der logarithmierte Schätzwert der charakteristischen Lebensdauer $\ln(\hat{T})$ (vgl. Gleichung 2.47) den Lageparameter μ und der Kehrwert des Formparameters $1/\hat{b}$ die Skalierung σ . Dies entspricht exakt der in diesem Abschnitt eingeführten Hilfsgröße w :

$$r_i = \frac{\ln(t_i) - \ln(\hat{T})}{1/\hat{b}} = \hat{b} \cdot \ln \left(\frac{t_i}{\hat{T}} \right). \quad (2.61)$$

Ist das Modell korrekt spezifiziert, müssen diese Residuen (unter Berücksichtigung der Zensierung) einer Verteilung der kleinsten Extremwerte *SEV* ($\mu = 0, \sigma = 1$) folgen. Eine allgemeinere Form der Validierung bieten die *Cox-Snell-Residuen* r_{CS} [2, 3]. Sie stellen eine Transformation der standardisierten Residuen dar und entsprechen

dem Wert der kumulativen Hazard-Funktion an der Stelle der Beobachtung. Für das Weibull-Modell gilt der Zusammenhang:

$$r_{CSi} = -\ln(\hat{R}(t_i)) = \exp(r_i) = \left(\frac{t_i}{\hat{T}}\right)^{\hat{b}}. \quad (2.62)$$

Folgt das angepasste Modell den Daten, so verhalten sich die Residuen r_{CS} wie eine Stichprobe aus einer Standard-Exponentialverteilung mit Mittelwert 1. Diese Eigenschaft erlaubt eine grafische Validierung mittels Probability-Plots: Liegen die geplotteten Residuen auf einer Geraden im Exponential-Wahrscheinlichkeitsnetz, kann von einer adäquaten Modellpassung ausgegangen werden. Zur Identifikation von Ausreißern oder einflussreichen Beobachtungen eignen sich hingegen standardisierte Devianz-Residuen r_{Dev} . Im Gegensatz zu den stets positiven Cox-Snell-Residuen sind diese symmetrischer um Null verteilt und folgen asymptotisch einer Standardnormalverteilung:

$$r_{Dev i} = \text{sgn}(r_{CSi} - 1) \cdot \sqrt{2[r_{CSi} - \delta_i - \delta_i \ln(r_{CSi})]}. \quad (2.63)$$

Neben der Verteilungsprüfung dienen Streudiagramme dieser Residuen zur Aufdeckung struktureller Modelldefizite. Dabei werden r_{CS} oder r_{Dev} gegen die prädizierten Werte oder gegen einzelne Einflussfaktoren aufgetragen und gegenüber Trendfreiheit und Varianzhomogenität bewertet. Besteht initiale Unsicherheit über die zugrundeliegende Physik, ermöglicht zudem der Vergleich der Wahrscheinlichkeitsnetze der Residuen eine empirische Selektion: Dasjenige Modell, dessen Punktegraphen eine geringere Krümmung aufweisen und besser der theoretischen Geraden folgen, ist statistisch zu bevorzugen.

3 Testplanung für die multivariate Lebensdauererprobung

3.1 Bewertung des Forschungsstandes

Der in Kapitel 2 dargelegte Stand der Forschung und Technik verdeutlicht, dass die Zuverlässigkeitstechnik und das DoE profunde Methodenrepertoires bereitstellen. Die methodische Schnittmenge beider Felder - die Planung effizienter multivariater Lebensdauererprobungen unter Berücksichtigung schiefer Verteilungen und Zensierungen im Rahmen von Weibull-GLMs - offenbart jedoch fundamentale Konflikte, welche den zwingenden Bedarf an weiterführender Forschung für die versuchstechnische Praxis beim Einsatz von multivariatem ALT begründen.

Zur systematischen Einordnung dieser Defizite bedarf es zunächst einer grundlegenden Definition der zentralen Bewertungsmetriken, wie sie aus ingenieurwissenschaftlicher Sicht für die Lebensdauererprobung relevant sind. Für die vorliegende Arbeit wird daher definiert, dass ein Versuchsplan nur dann als adäquat anwendbar gilt, wenn er die folgenden beiden Zielgrößen erfüllt:

- **Statistische Effektivität:** Die Fähigkeit eines Versuchsplans, eine physikalische Kausalität (entsprechend der Effekte, der Degradationen oder der Schädigungsmechanismen) hinsichtlich der Lebensdauer eines Produkts stochastisch verlässlich mit geforderter *power* sowie hinreichender Parameter-Schätzgüte zu approximieren. So soll die Lebensdauer über den relevanten Parameterraum hinweg unverzerrt prognostiziert werden können. Demzufolge werden hierbei eine effektive GLM-Parameterschätzung, die Trennschärfe sowie die Prognosefähigkeit bzw. die Prädiktionsvarianz als Maßstäbe herangezogen.
- **Ökonomische Effizienz:** Die Allokation minimaler Ressourcen (allen voran ein restriktiver Stichprobenumfang N und eine adäquate Erprobungsdauer) zur Erreichung dieser geforderten statistischen Effektivität.

Ein Lebensdauertest ist folglich nur dann praxistauglich, wenn er das Investitionsrisiko der physikalischen Erprobung minimiert, ohne die Garantie zur Effekterkennung, deren Approximation selbst sowie die Anwendbarkeit der Modellierung zu kompromittieren. Demnach qualifizieren sich diese Metriken sowohl für die Bestandsaufnahme im aktuellen Forschungsumfeld als auch für die unmittelbare Planung effizienter, multivariater Versuchspläne. Anhand dieses Anforderungsprofils werden die methodischen Defizite aktueller Forschungsansätze im Folgenden diskutiert. Dies untergliedert sich in die methodische Dekonstruktion der optimalen Versuchsplanung (Abschnitt 3.1.1), die Einordnung der beschränkten analytischen Quantifizierbarkeit stochastischer Trennschärfe als Optimierungsgröße (Abschnitt 3.1.2) sowie die finale Synthese, welche in die Ableitung der in dieser Arbeit adressierten Forschungslücke mündet (Abschnitt 3.1.3).

3.1.1 Das methodische Paradoxon ALT-optimaler GLM-Designs

Der Einsatz computergenerierter, algorithmisch optimaler Versuchspläne (*D*-, *I*- oder *U*-Optimalität) erscheint aus theoretischer Sicht zunächst als logische Konsequenz, um maßgeschneiderte, effiziente Designs für ALT zu entwerfen. Im Kontext der Lebensdauer-Datenanalyse führt dies jedoch in ein methodisches Paradoxon [39]. Khuri [72], Stufken und Yang [78] und Yang et al. [85] weisen darauf hin, dass insbesondere die *lokale Optimalität* dieser Pläne immer dann eine fundamentale Limitation darstellt, wenn die wahren Modellparameter θ (allen voran der Formparameter b) *a priori* nicht bekannt oder abschätzbar sind.

Forschungsarbeiten zu GLM-optimalen Designs für ALT von Monroe et al. [62] und Seo und Pan [63] adressieren dieselbe Problematik und belegen das fundamentale stochastische Hindernis: Im Gegensatz zu klassischen OLS-Modellen, deren Informationsmatrix alleinig von der Versuchspunktopologie $\mathbf{X}$ abhängt, weist die Fisher-Informationsmatrix bei Weibull-GLMs (gemäß Gleichung 2.28 und 2.54) eine zwingende Abhängigkeit von den wahren, aber vorab unbekannten Modellparametern θ auf. Die Versuchsplanung erfordert damit unweigerlich stochastisches Vorwissen, welches sich, etwa im Fall der *U*-Optimalität für Prognostik in relevanten Betriebsbereichen, in der Vorgabe theoretischer *Planning Values* für die Regressionskoeffizienten in β und den Formparameter b manifestiert. Monroe et al. [61] erweitern diesen Ansatz durch iteratives Aktualisieren mittels Bayes'scher *Updating*-Prozesse, um die lokale

Optimalität sukzessive an die physikalische Realität anzupassen und so Effektivität und Effizienz zu maximieren. In konservativer Annahme muss jedoch davon ausgegangen werden, dass dem pragmatisch handelnden Ingenieur im Maschinen- oder Fahrzeugbau im realen Projektumfeld a priori Kenntnisse dieses Detailgrads zumeist vollständig fehlen. Stimmen anfängliche Schätzungen nicht mit der physikalischen Realität überein, entartet das GLM-optimale Testdesign und verliert seine statistische Integrität („The designs may be poor if the choice of values is far from the true parameter values“ Stufken und Yang [78, S. 2]). Kompensationsstrategien entgegen dieser Design-Entartung werden in der Theorie so durch drastische Erhöhung des Stichprobenumfangs N oder durch signifikante Verlängerung etwaiger Zensierungszeiten adressiert [62], was die Methode für die industrielle Praxis jedoch wirtschaftlich unbrauchbar macht.

Auch die in Forschungsarbeiten von Núñez Ares und Goos [67] und Goos [66] favorisieren optimale Testplauungen durch OMARS-Designs. Aus ingenieurwissenschaftlicher Perspektive lösen jedoch auch diese Ansätze nicht das fundamentale Problem der inhärenten Parameterabhängigkeit. Sie zielen auf strukturelle Flexibilität und die orthogonale Schätzung von Haupteffekten in einem einzigen experimentellen Schritt (*One-Step Approach*) ab, erkaufen dies jedoch durch eine algorithmisch kontrollierte Vermengung von Wechselwirkungen. Vor allem aber adressieren sie nicht den fundamentalen ALT-Konflikt: Die Notwendigkeit einer über den Raffungsfaktor hinweg reichenden *Extrapolation* in den Feldbetrieb steht der inhärenten Optimierung dieser Pläne auf *Interpolation* im Zentrum des Versuchsraums diametral entgegen. Konservativ wird in der Testplanung angenommen, dass im Vorfeld zumeist unbekannt ist, wie viele Faktoren tatsächlich relevant sind und ob diese in erster oder zweiter Ordnung wirken. Schlussfolgernd beraubt ein OMARS-Design den Prüfenieur der essenziellen strategischen Rückfallebene, eine sequenzielle Erweiterung von in der Regel kostenintensiven Versuchspunkten durchzuführen (vgl. Abschnitt 2.2.4).

3.1.2 Diskrepanz zwischen geometrischer Optimalität und stochastischer Trennschärfe

Ein weiteres fundamentales Forschungsdefizit besteht in der Entkopplung von geometrischen Optimalitätskriterien und der tatsächlichen, probabilistischen Erfolgswahrscheinlichkeit eines Tests. Wie in Abschnitt 2.2.5 dargelegt, basieren klassische Metri-

ken auf der Minimierung der Prädiktionsvarianz. Die Varianz allein garantiert jedoch nicht, dass ein physikalischer Effekt überhaupt signifikant vom Rauschen getrennt werden kann.

Im klassischen OLS-Umfeld lässt sich dies noch über den Nichtzentralitätsparameter δ_{nc} analytisch korrelieren. Im Kontext der Lebensdauerdatenanalyse, bei der grundlegend mit asymmetrischen Datenverteilungen und Zensierung zu rechnen ist, lassen sich diese Wahrscheinlichkeiten folglich nicht mehr über klassische *t-Tests* ableiten. Ausgehend von den Arbeiten zu GLMs [86] wird die Signifikanz der Koeffizienten vorzugsweise über *LR-Tests* (oder approximativ über *Wald-Tests*) ermittelt [2, 3]. Da für diese komplexen Verteilungsmodelle - insbesondere unter dem Einfluss asymmetrischer Versuchsraumänderungen und kleiner Stichprobenumfänge N - keine geschlossenen analytischen Lösungen zur Berechnung der Trennschärfe existieren, muss entsprechend Kremer [4] die Untersuchung numerisch mittels *MCS* erfolgen [71]. Hierbei wird der geplante Versuchsplan iterativ unter Vorab-Annahmen eines vorliegenden Regressionsmodells simuliert, verrauscht und zensiert, um den Anteil korrekter Signifikanz-Entscheidungen ($p\text{-Wert} < \alpha$) bei virtueller Design-Anwendung als empirische *power* zu extrahieren. Die Forschungslücke manifestiert sich darin, dass die Auswirkungen asymmetrischer Versuchsplanmodifikationen auf diese Trennschärfe empirisch nicht hinreichend untersucht sind. Aus Praxisperspektive ist die *power* als quantitative Erfolgsmetrik für den *Return-on-Investment* eines Versuchs zu interpretieren, doch ihre Korrelation zu den reinen geometrischen Optimalitätskriterien am Extrapolationspunkt ist bei individuellen Designmodifikationen bislang unzureichend beleuchtet.

Darüber hinaus wird die in der klassischen Versuchsplanung oft rein geometrisch betrachtete Design-Güte im Kontext der Zuverlässigkeitstechnik durch eine zeitliche Dynamik überlagert. Da die Information in Lebensdauertests stochastisch über die Zeit generiert wird, skaliert die tatsächliche Schätzvarianz in der Praxis maßgeblich mit den realisierten Ausfallzeiten [14]. Ein Versuchsplan ist folglich nur dann im Sinne der ökonomischen Effizienz tragfähig, wenn er die exponentiell ansteigende Testdauer bei unbeeinträchtigter statistischer Effektivität minimiert. Dieser fundamentale Zielkonflikt zwischen geometrischem Informationsgewinn und realen zeitlichen Prüfkosten bleibt in gängigen statistischen Gütekriterien und Optimalitäten jedoch vollständig unberücksichtigt.

3.1.3 Synthese des Forschungsstandes und Ableitung der Forschungslücke

Aus der Diskrepanz zwischen dem theoretischen Anspruch streng *lokaler*, GLM-optimaler Designs und der strukturellen Starrheit einstufiger *One-Step*-Ansätze leitet sich für die versuchstechnische Praxis die Notwendigkeit einer global robusteren Vorgehensweise ab. Anstatt ein künstliches Optimum zu berechnen, das bei geringfügigen Parameterabweichungen (*Planning Values*) in seiner Modellbildung kollabiert, erweist sich eine perspektivische, gezielte Adaption bewährter, topologisch fehlertoleranter Standard-Designs als der methodisch zielführende Pfad.

Dabei dürfen isolierte Optimalitätskriterien jedoch nicht als pauschales Entwurfsziel fungieren. Um den eingangs definierten Leitgrößen der ingenieurwissenschaftlichen ALT-Praxis gerecht zu werden, muss das Anforderungsprofil an ein Testdesign in einen multidimensionalen Benchmark überführt werden, der vier Zieldimensionen abbildet:

- **Modellierungsgüte (A-, D-Kriterien):** Adressiert die geforderte *topologische Robustheit*. Sie sichert ab, dass die GLM-Parameterschätzung in $\hat{\theta}$ auch bei Modifikationen des Designs und fehlendem Vorwissen numerisch stabil bleibt [22].
- **Prognosefähigkeit (SPV, G-, I-, U-, V-Kriterien):** Quantifiziert die *Prognosefähigkeit im Prädiktionsraum*. In der Lebensdauererprobung besitzt diese absolute Priorität, da die präzise Vorhersage der Zuverlässigkeit $R(t)$ im zumeist abweichenden *Betriebs-Parameterraum* das eigentliche Versuchsziel darstellt [3, 36].
- **Testdauer und Ressourceneffizienz:** Gewährleistet die *ökonomische Effizienz* sowie die *strukturelle Flexibilität*. Sie limitiert die Versuchsplanung durch die harte Realität exponentiell ansteigender EoL-Prüfzeiten sowie Prüfstandskosten $E(C_{\Sigma})$ und bewertet die zeitliche Skalierung der Informationsgewinnung [87].
- **Trennschärfe (*power*):** Dient als *Garantie-Metrik* für einen erfolgreichen Testausgang. Ein theoretisch varianzminimales Design, das in der Praxis den Nachweis essenzieller physikalischer Effekte verfehlt, ist industriell wertlos (Anforderungshorizont: $power \geq 80\%$) [68, 88].

Diese vier Zieldimensionen verhalten sich in der realen Versuchspraxis zumeist gegensätzlich zueinander: Eine extreme Beschleunigung der Belastungen senkt zwar

die Testdauer, kompromittiert jedoch die Prognosegüte im Feld. Ein reiner Fokus auf lokale D -Optimalität maximiert zwar die Schätzpräzision für Effekt-Koeffizienten, ignoriert jedoch die asymmetrische Extrapolationsrichtung und die tatsächliche *power*. Die Ausrichtung auf U -Optimalität minimiert zwar theoretisch die Prädiktionsvarianz am fernen Betriebspunkt, erzwingt jedoch eine Konzentration der Versuchspunkte auf niedrige Stressniveaus; dies lässt die Erprobungsdauer massiv eskalieren und zieht bei fehlerhaften *Planning Values* unwirtschaftliche Kompensationsmaßnahmen in Form von erhöhtem N oder drastisch verlängerten Zensierungszeiten nach sich. Ebenso reduzieren moderne OMARS-Designs zwar den Stichprobenumfang durch einen einstufigen Versuchsaufbau (*One-Step*), erkaufen diese strukturelle Effizienz jedoch durch eine unvermeidbare Vermengung der Wechselwirkungen und limitieren die stochastische Modellbildung durch ihre systemimmanente Beschränkung auf den Hyperwürfel $[-1, 1]^k$ strikt auf die reine Interpolation. Eine effiziente Testplanung erfordert folglich zwingend einen strategischen Kompromiss.

Als methodisches Fundament für diesen Kompromiss zeichnet sich insbesondere das CCD aus, welches sich als robuster Standard - insbesondere für quadratische Ansätze der Lebensdauermodellierung - bewährt hat [3, 4, 32]. Gegenüber alternativen Designs garantiert es durch seine *Rotierbarkeit* sowie eine hohe D -Effizienz ein vorteilhaftes Verhältnis zwischen Modellierungsumfang und benötigter Stichprobengröße [3]. Zudem erlaubt es den strategisch starken, sequenziellen Aufbau - vom Screening über augmentierte ZPs hin zu ergänzten SPs [22, 43]. Basierend auf dem am Institut für Maschinenelemente (IMA) generierten Wissensstand [4] ist das CCD im Rahmen des L-DoE folglich gleichermaßen bekannt sowie geeignet, um erwartungstreue Schätzungen und Vertrauensbereiche zu generieren [16, 80].

Für die spezifischen Anforderungen der ALT-Erprobung erweist sich die starre geometrische Symmetrie des klassischen CCD jedoch als limitierend. Die erforderliche *Extrapolation* steht im direkten Konflikt mit der mathematischen Optimierung klassischer RSDs auf *Interpolation* im Zentrum des Versuchsraums [41]. Bestehende Ansätze zur Modifikation von CCDs [58, 89, 90] adressieren diese Diskrepanz nicht proaktiv für den fernen Extrapolationsraum, sondern fokussieren sich zumeist auf den Erhalt generischer Optimalitätskriterien bei Ausfällen [71, 88].

Genau an diesem Konfliktpunkt verankert sich der methodische Beitrag der vorliegenden Arbeit. Die inhärente strukturelle Überbestimmtheit des CCD (beispielsweise

durch mehrfache Zentralpunkt-Replikationen) birgt ein ungenutztes Potenzial, welches hier als geometrisches *Gestaltungsbudget* für die prädiktionsbasierte Designoptimierung definiert wird. Wird die geometrische Symmetrie des Plans kritisch hinterfragt, können zur Disposition stehende Versuchspunkte aus dem originären Plan hinsichtlich ihrer Position gezielt modifiziert werden. Die identifizierte Forschungslücke besteht somit darin, dieses Gestaltungsbudget nicht primär zur passiven Kostenreduktion zu streichen. Vielmehr sollen diese verfügbaren Stützstellen als dedizierte *Extrapolations-Ankerpunkte* exakt dorthin verlagert werden, wo der perspektivische Prognosepunkt im Feldbetrieb allokiert ist, um das Regressionsmodell auf dem Extrapolationspfad stochastisch abzustützen.

Dieser proaktive, methodische Schritt wird durch Erkenntnisse der Optimalitätsforschung theoretisch legitimiert: Seo und Pan [63] sowie Monroe et al. [62] belegen, dass algorithmisch auf eine Feldbetriebs-Prognose optimierte Designs (*U*-Optimalität) von Natur aus eine massive topologische Asymmetrie erzwingen, indem sie einen erheblichen Großteil der Versuchspunkte auf das niedrigste Stressniveau allokieren. Zudem beweisen Monroe und Pan [34], dass gezielt asymmetrische Designs in physikalisch restriktiven Versuchsräumen die Breite der Konfidenzintervalle für Parameterschätzungen im Vergleich zu konventionellen, starren Designs drastisch reduzieren können. Um diese mathematisch nachgewiesenen Effizienzsprünge der Asymmetrie zu nutzen, ohne die Ausfallrisiken lokaler Optimalpläne in Kauf zu nehmen, formuliert diese Arbeit einen methodischen Brückenschlag: Auf Basis des CCD entsteht ein adaptiver Versuchsplan, der eine hin zur Prädiktionsvarianz optimierte Informationsgewinnung in Extrapolationsrichtung sicherstellt, während die parallel quantifizierte *power* garantiert, dass der *Return-on-Investment* des Lebensdauertests gewahrt bleibt.

3.2 Forschungsfragen und wissenschaftliche Zielsetzung

Als methodisches Fundament für die multivariate Lebensdauererprobung dient in dieser Arbeit somit das CCD aus der Klasse der RSDs. Diese Wahl begründet sich zusammenfassend in fünf fundamentalen verfahrenstechnischen, physikalischen und statistischen Eigenschaften [2, 35, 36]:

1. **Sequenzielle Augmentierbarkeit:** Ermöglicht den stufenweisen Ausbau vom Screening zum vollwertigen quadratischen Modell und minimiert das ökonomische Fehlinvestitionsrisiko bei zeitintensiven Tests [1].
2. **Rotierbarkeit und Richtungsneutralität:** Bietet eine homogene Ausgangsbasis für die Prädiktionsgüte bei a priori unbekannter Lage des Zuverlässigkeitsoptimums [2].
3. **Modellierung nichtlinearer Schädigungskinetik:** Die Abtastung auf fünf Faktorstufen erlaubt die Validierung physikalischer Beschleunigungsmodelle und die Detektion von Linearitätsgrenzen [6, 75].
4. **Schätzung der reinen Systemstreuung:** Zentralpunkt-Replikationen ermöglichen die modellunabhängige Trennung von reinem Versuchsfehler (*Pure Error*) und Modellanpassungsfehlern (*Lack of Fit*) [2].
5. **Topologische Fehlertoleranz:** Die symmetrische Grundstruktur garantiert eine extrem hohe Robustheit gegenüber unvorhergesehenen Zensierungen (*Missing Data*) am Prüfstand [22].

Die vorliegende Arbeit verfolgt die wissenschaftliche Zielsetzung, diese für die Lebensdauererprobung überlegene Grundarchitektur nicht zu verwerfen, sondern den ihr zugrundeliegenden Ansatz zur Augmentierung konsequent auf den Extrapolationsraum auszuweiten. Die forschungsleitende Hypothese besteht darin, dass der Informationsgewinn für die Feldbetriebs-Prognose nicht durch eine kostenintensive Vergrößerung der Prüflingsanzahl erzwungen werden muss. Vielmehr wird postuliert, dass sich durch die Identifikation ungenutzter geometrischer Freiheitsgrade ein Gestaltungsbudget ableiten lässt, dessen strategische Reinvestition als Extrapolations-Ankerpunkte ein stochastisches Nullsummenspiel im Versuchsraum ermöglicht.

Um diese Hypothese zu überprüfen und den in Abschnitt 3.1 identifizierten Zielkonflikt aufzulösen, leitet sich die zentrale Hauptforschungsfrage dieser Arbeit wie folgt ab:

Hauptforschungsfrage

Wie kann die Architektur zentral zusammengesetzter Versuchspläne unter Beibehaltung oder Reduktion des Gesamtstichprobenumfangs asymmetrisch adaptiert werden, um beschleunigte Lebensdauerprüfungen für eine varianzminimierte Zuverlässigkeitsmodellierung im Extrapolationsraum des Feldbetriebs maximal effizient auszulegen?

Zur systematischen Beantwortung dieser übergeordneten Problemstellung werden drei spezifische Teilforschungsfragen definiert:

Teilforschungsfragen

- 1: Welches geometrische Gestaltungsbudget lässt sich aus der strukturellen Überbestimmtheit klassischer CCDs ableiten, ohne die grundlegende topologische Stabilität der multivariaten GLM-Parameterschätzung zu gefährden?
- 2: Wie lassen sich diese freigewordenen Versuchspunkte als richtungsspezifische Extrapolations-Ankerpunkte allokalieren, und mit welchen Metriken kann die Wahrung der statistischen Trennschärfe (*power*) hierbei quantitativ garantiert werden?
- 3: Wie lässt sich der fundamentale Zielkonflikt zwischen stochastischer Vorhersagegüte und exponentiell skalierenden Prüfstandskosten in einem ökonomischen Bewertungsmodell abbilden, um ein skalares Effizienzoptimum für die Testplanung zu ermitteln?

3.3 Methodische Forschungsarchitektur

Die Beantwortung der formulierten Forschungsfragen erfolgt entlang einer vierstufigen Methodenkette, welche das theoretische Konzept von der stochastischen Basisidentifikation bis hin zum industriellen Nutzennachweis führt:

- **Stufe 1: Quantifizierung der Resilienz & Gestaltungsbudget (Abschnitt 4.2):** Simulativer Nachweis der Fehlertoleranz des klassischen CCD gegenüber geometrischen Restriktionen und Ableitung des nutzbaren Gestaltungsbudgets für asymmetrische Modifikationen bei konstantem Stichprobenumfang N (Beantwortung Teilforschungsfrage 1). Hier wird eine Potenzialanalyse der asymmetrischen Designmodifikation durchgeführt, um die Auswirkungen auf die Trennschärfe als grundlegende Eigenschaft im Sinne einer Erfolgswahrscheinlichkeit für die Testplanung zu quantifizieren.
- **Stufe 2: Adaptive Testplanung & Extrapolations-Ankerpunkte (Abschnitt 4.3):** Methodische Weiterentwicklung des Augmentierungsprinzips durch die Allokation von Extrapolations-Ankerpunkten in modifizierten Designs auf Basis eines CCD innerhalb mathematisch definierter Toleranzbereiche (*Exposure Area*) sowie die richtungssensitive Analyse der Vorhersagevarianz unter Wahrung der Trennschärfe (Beantwortung Teilforschungsfrage 2).
- **Stufe 3: Stochastisch-ökonomische Bilanzierung (Abschnitte 4.4-4.5):** Koppung der MLE-basierten Weibull-AFT-Modellierung mit einem dynamischen Prüfstandskostenmodell und ökonomischer Bilanzierung zur Bestimmung des Pareto-Optimums aus Testdauer und Prognosegüte (Beantwortung Teilforschungsfrage 3).
- **Stufe 4: Empirische Verifikation (Kapitel 5):** Experimenteller Härte-test an realen Bauteilprüfungen (Lenksystem-Zahnriemen) mittels *Confirmation Experiments* (Abschnitt 5.2.1) und Prädiktionsintervallen zur Verifikation der entwickelten Methodik und der Validierung der in Stufe 3 ermittelten ökonomischen Effizienz (Beantwortung der Hauptforschungsfrage).

4 Statistische Effektivität als Fundament effizienter Lebensdauertests

Nach der methodischen Einordnung des Forschungsstandes und der Identifikation der wesentlichen Defizite in Kapitel 3 etabliert das vorliegende Kapitel die stochastische und topologische Basis für die Planung effizienter multivariater Lebensdauertests. Die wissenschaftliche Zielsetzung besteht darin, das Fundament zentral zusammengesetzter Versuchspläne (CCDs) gezielt an die asymmetrischen Anforderungen der Feldbetriebs-Extrapolation zu adaptieren. Um den Übergang von der klassischen *D*-Optimalität bzw. RSM hin zu einer Prädiktion-fokussierten Lebensdauererprobung nachvollziehbar zu segmentieren, gliedert sich der Untersuchungsansatz in eine fünfstufige Sequenz - ausgehend von einer isolierten Simulationsumgebung hin zur stochastisch-ökonomischen Synthese im AFT-Raum:

Zunächst etabliert **Abschnitt 4.1** die Simulations- und Auswertearchitektur auf Basis eines flexiblen *Ground-Truth*-Modells. Der Grundgedanke dieser Modellierung wird auch in weiteren Abschnitten aufgegriffen: Die statistische Effektivität der Versuchspläne wird in einer kontrollierten Umgebung quantifiziert, in welcher die wahren Systemparameter a priori bekannt sind und sich in Abhängigkeit der spezifischen Randbedingungen in den Untersuchungsschritten anpassen lassen. Darauf aufbauend quantifiziert **Abschnitt 4.2** die statistische Sensitivität klassischer Designs gegenüber geometrischen Praxisrestriktionen. Mittels MCS wird analysiert, in welchem Maße Orthogonalitätsabweichungen die Schätzpräzision und die statistische Trennschärfe (*power*) beeinflussen und welches topologische Gestaltungsbudget hieraus abgeleitet werden kann. Dieses Verständnis legitimiert in **Abschnitt 4.3** die adaptive Versuchsplanung, in welcher redundante Stützstellen als strategische Ankerpunkte (APs) allokiert werden. Deren richtungssensitive Wirkung entlang des Extrapolationspfads wird über den EVG visualisiert und ihre topologische Überlegenheit isoliert validiert. Den ökonomischen Rahmen definiert **Abschnitt 4.4** durch ein Kostenmodell, welches stochastische Testlaufzeiten über physikalische Beschleunigungsfaktoren in reale

Prüfstandsaufwände überführt. In **Abschnitt 4.5** erfolgt die Synthese für multivariate Lebensdauermodelle: Das asymmetrische EmALT-Konzept wird im Weibull-AFT-Raum über die Parameterschätzung unter realen Erprobungsbedingungen bewertet und über den Economic Extrapolation Power Index (EPI) im Pareto-Optimum aus Testaufwand und Prognosegüte bilanziert.

4.1 Methodische Simulationsarchitektur und pseudo-physikalisches Modell

Um die statistische Leistungsfähigkeit modifizierter Versuchspläne objektiv zu quantifizieren, bedarf es einer kontrollierten Untersuchungsumgebung, in welcher das wahre Systemverhalten *a priori* exakt definiert ist. Erst der systematische Abgleich der Modellierungs- und Schätzergebnisse mit einer deterministischen Referenz (*Ground Truth*) ermöglicht die Berechnung von Key Performance Indicators (KPIs) wie Schätzgüte, Varianzinflation und statistischer Trennschärfe (*power*). Zu diesem Zweck wird nachfolgend eine allgemeingültige, modulare Simulationsumgebung aufgebaut, welche als Auswertebasis für sämtliche Untersuchungen dieses Kapitels dient [91, 92].

4.1.1 Pseudo-physikalisches Ground-Truth-Modell

Das zugrundeliegende Systemverhalten wird durch ein polynomielles Regressionsmodell zweiter Ordnung approximiert. Dies entspricht der Modellstruktur, die als Ergebnis einer klassischen RSM-Auswertung (vgl. Gleichung (2.17)) resultiert und das Fundament für multivariate Lebensdauer- und Zuverlässigkeitsmodelle bildet. Zur Abbildung einer multivariaten Untersuchung ($k \geq 2$) wird im Basisszenario von zwei Einflussfaktoren (x_1, x_2) ausgegangen. Die Begrenzung auf $k = 2$ stellt methodisch eine konservative Betrachtung dar: Da sich die negativen Auswirkungen lokaler topologischer Störungen mit zunehmender Dimensionalität über eine größere Anzahl verbleibender orthogonaler Stützstellen verteilen, reagiert ein zweidimensionaler Versuchsraum statistisch am empfindlichsten auf geometrische Verzerrungen [71]. Das Modell berücksichtigt neben den Haupteffekten explizit Wechselwirkungen ersten Grades sowie quadratische Terme zur Erfassung der Krümmung der Systemantwort:

$$y_{\text{sim}} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \quad (4.1)$$

Unter Berücksichtigung von Gleichung 2.47 eignet sich diese Regressionsgleichung sowohl zur Abbildung repräsentativer Datenlagen aus der statistischen Versuchsplanung sowie der logarithmierten charakteristischen Lebensdauer T im AFT-Raum (vgl. Abschnitt 2.1.3).

4.1.2 Simulationsarchitektur und Monte-Carlo-Inferenz

Die definierte *Ground Truth* wird mit der jeweils zu untersuchenden Design-Matrix $\mathbf{X}$ entsprechend Gleichung 2.18 aufgelöst. Um epistemische Unsicherheiten zu minimieren und eine reproduzierbare numerische Konvergenz sicherzustellen, ist das Verfahren in eine MCS mit $n_{MC} = 1 \cdot 10^4$ Iterationen eingebettet. Hierbei kommt in der algorithmischen Umsetzung das Prinzip der *Seed-Fixierung* (*Common Random Numbers*) zum Einsatz: In die Prüfstandspraxis der Zuverlässigkeitstechnik übersetzt bedeutet dies, dass alle evaluierten Design-Varianten an exakt demselben Kollektiv virtueller Prüflinge mit identischer inhärenter Materialstreuung getestet werden, so dass resultierende Schätzabweichungen kausal auf die Topologie des Versuchsplans und nicht auf das Rauschen zufällig variierender Stichproben im MCS-Sampling zurückzuführen sind.

Ausgehend von der definierten *Ground Truth* und der Versuchsmatrix $\mathbf{X}$ werden in den MCS-Iterationen somit stochastische Systemantworten generiert. Die nachfolgende Parameterschätzung erfordert methodisch eine strikte Zweiteilung der Inferenzverfahren (OLS versus MLE), um topologische Design-Effekte von verteilungsspezifischen Schätzfehlern zu isolieren: Würde die Evaluierung asymmetrisch modifizierter Versuchspläne unmittelbar über eine MLE an zensierten, Weibull-verteilten Daten erfolgen, ließen sich Varianzerhöhungen und Trennschärfe-Verluste nicht mehr eindeutig zuordnen. Sie wären das ununterscheidbare Produkt aus der geometrischen Verzerrung der Design-Matrix $\mathbf{X}$ einerseits und dem stochastischen *Small-Sample Bias* der MLE andererseits. Aus diesem Grund erfolgt die Auswertung in entsprechender Abfolge:

- **Stufe 1 (Isolierter topologischer Fehler via OLS):** In den Abschnitten 4.2 und 4.3 operiert die Simulation unter den Prämissen der additiven Normalverteilung (Gauss-Markow-Theorem). Der OLS-Schätzer liefert hier die erwartungstreue Baseline. Jeder in dieser Phase messbare Verlust an statistischer Effektivität ist

ausschließlich auf die geometrische Modifikation des Versuchsplans zurückzuführen.

- **Stufe 2 (Stochastische Realität via MLE):** Nach dem Nachweis der Design-Integrität vollzieht Abschnitt 4.5 den Transfer auf das log-lineare AFT-Modell. Hier quantifiziert die MLE die Vorhersagegüte unter den Bedingungen rechtschiefer (und ggf. zensierter) Lebensdauerdaten.

Am Ausgang dieser Simulationsschleife werden die statistische Effektivität und die akkumulierten Prüfstandskosten simultan bereitgestellt. Dies erlaubt die Analyse der zwei elementaren Bewertungskriterien:

1. **Präzision der Parameterschätzung:** Durch den Erwartungswert-Vergleich der geschätzten Koeffizienten $\hat{\beta}$ mit den wahren Modellparametern β_{true} werden der systematische Schätzfehler (**Bias**) sowie die Schätzvarianz (**MSE**) quantifiziert.
2. **Empirische Trennschärfe (*power*):** Für jeden Simulationslauf wird über statistische Hypothesentests (ANOVA bzw. LR-Test) geprüft, ob signifikante Effekte vor dem Hintergrund des Rauschens korrekt identifiziert werden ($p\text{-Wert} < \alpha$). Der relative Anteil erfolgreicher Identifikationen definiert die empirische *power* (vgl. Gleichung (2.44), in Anlehnung an [4, 68, 92]).

Die systematische Kopplung dieser Inferenzschritte mit der topologischen Design-Auswahl und dem dynamischen Kostenmodell ist in Abbildung 4.1 zusammengefasst. Da diese Architektur als übergeordneter methodischer Fahrplan für die sukzessive Argumentationskette fungiert, integriert sie Parameter und Konzepte, deren formale Herleitung abschnittsspezifisch erfolgt. Der modulare Ablauf lässt sich entlang dreier Kernpfade strukturieren:

- **1. Kalibrierung des Pseudo-Physikalischen Modells (Linker Pfad im Schaubild):** Die Definition der wahren Systemantwort erfordert je nach Untersuchungsziel differenzierte SNR-Kalibrierungen. Für die grundlegende Analyse geometrischer Störungen operiert das Modell im Normalverteilungsraum (OLS). Für den Transfer in die Lebensdauererprobung erfolgt die Kalibrierung im log-linearen Weibull-Raum. Dies erfordert die spezifische Skalierung über die *SEV*-Streuung (σ_{SEV}), welche in Abschnitt 4.5 hergeleitet wird.




Abbildung 4.1: Methodische Architektur der Monte-Carlo-Simulationsumgebung.

- **2. Evolution der Versuchstopologie X (Rechter Pfad im Schaubild):** Ausgehend vom Basis-CCD bei konstantem Ressourcenaufwand von $N = 13$ Versuchspunkten (vier Randpunkte, vier Sternpunkte, fünf Zentralpunkte [3, 22]) werden zunächst in Abschnitt 4.2 systematische Variationen sowie isolierte Störfälle simuliert, um das Gestaltungsbudget des Plans zu quantifizieren. In Abschnitt 4.3 wird dieses Budget genutzt, um über die Definition eines statistischen Toleranzraums (*Exposure-Area*) die asymmetrischen Extrapolations-Ankerpunkte der modifizierten Topologie abzuleiten, welche für eine gezielte Reduktion der Prädiktionsvarianz zu präferieren sind.
- **3. Stochastisch-ökonomische Synthese (Unterer Pfad im Schaubild):** Am Ausgang der Simulationsschleife werden die ermittelte statistische Effektivität (geprägt durch *power*, MSE und die Positions-sensitive Prädiktionsvarianz) und der über das Kostenmodell (Abschnitt 4.4) ermittelte monetäre Erwartungswert $E(C_\Sigma)$ zusammengeführt. Diese kulminieren in Abschnitt 4.5 in der Effizienzbewertung, welcher die Relation aus Testaufwand zu Prognosegüte quantifiziert.

4.2 Effektivität von Versuchsplänen mit Orthogonalitätsabweichungen

In der industriellen Erprobungspraxis resultieren Abweichungen von der idealen Versuchsgeometrie häufig aus physikalischen Anlagenrestriktionen, Bauteilgrenzen oder der gezielten Lastanhebung im Rahmen von ALTs. Die Verschiebung von Versuchspunkten in Hochlastbereiche forciert den Ausfallmechanismus und verkürzt die Prüfzeit, während Stützstellen nahe dem Nennbetrieb bei üblicherweise ansteigender Prüfdauer die Extrapolationsunsicherheit dämpfen.

Modifikationen an RSDs wie dem CCD bergen das Risiko, die statistische Integrität des Versuchsplans zu schwächen. Im Idealfall sind die Spalten der Design-Matrix $\mathbf{X}$ eines CCD orthogonal zueinander, was die unkorrelierte Schätzung aller Modellparameter garantiert [22], vergleiche Abschnitt 2.2.5. Geometrische Verzerrungen heben diese Orthogonalität unweigerlich auf ($\langle x_i, x_j \rangle \neq 0$). Die Ausprägung der resultierenden Varianzinflation hängt dabei maßgeblich von der Topologie der Störung ab: Während Eingriffe im faktoriellen Kern die Schätzung der linearen Haupteffekte unmittelbar kompromittieren, entfalten die für ALTs typischen asymmetrischen Verschiebungen

an den absoluten Belastungsgrenzen ihre Konsequenzen für die Modellkrümmung zumeist erst bei der Erweiterung um periphere axiale SPs.

Wie in Kapitel 3 hergeleitet, erlauben rein algebraische Matrixmaße und Optimalitätskriterien hierbei keine verlässliche Aussage über die tatsächliche Schätzvarianz und die statistische Trennschärfe. Zur probabilistischen Quantifizierung dieser Praxisrestriktionen unter stochastischen Rauschbedingungen wird daher direkt auf die in Abschnitt 4.1 etablierte Simulationsarchitektur zurückgegriffen.

4.2.1 Potenzialanalyse geometrischer und stochastischer Einflussgrößen

Um die Robustheit klassischer CCDs fundiert zu bewerten, wird eine Potenzialanalyse durchgeführt. Diese folgt methodisch dem Prinzip eines "*Meta-DoE*": Die topologischen Eigenschaften des Versuchsplans sowie die stochastischen Randbedingungen werden als Faktoren eines übergeordneten Meta-Designs - wiederum ein CCD - derart variiert, dass deren funktionale Auswirkung auf die Schätzgüte - und hier insbesondere auf die statistische Trennschärfe - quantifiziert werden kann [91].

Hierfür wird ein Spektrum aus acht praxisrelevanten Geometrie-, Stör- und Inferenzparametern definiert. Zur formalen Beschreibung des Sensitivitätsraums werden diese Einflussgrößen im Parametervektor $\xi = [\xi_a, \dots, \xi_h]^\top$ zusammengefasst. Die Parametrisierung ist in Tabelle 4.1 deklariert und visuell in Abbildung 4.2 veranschaulicht:

1. Geometrischer SP-Abstand (α_D) zur Erfassung radialer Stauchungen oder Streckungen;
2. Asymmetrischer SP-Shift infolge parasitärer co-faktorieller Stellgrößenkopplung;
3. Diskrete Variation der Zentralpunktanzahl (n_{ZP});
4. Diskrete Variation der Sternpunktanzahl (n_{SP}) durch partiellen Stützstellenentfall;
5. Streuung der wahren Modellparameter (epistemisches Effekt-Rauschen);
6. Relatives Amplitudenverhältnis konkurrierender Haupteffekte (β_1 / β_2);
7. Standardabweichung des experimentellen Versuchsfehlers (System- und Messrauschen, SNR);
8. Vorgegebenes statistisches Signifikanzniveau (α).

Die Fokussierung der asymmetrischen Geometrievariationen (Faktor ζ_b) sowie potenzieller lokaler Zensierungen auf vornehmlich axiale SPs begründet sich unmittelbar aus der Erprobungspraxis: Im Rahmen von ALTs repräsentieren diese Stützstellen die schärfsten, uni-axialen Beanspruchungsbedingungen des Versuchsraums. An diesen physischen Systemgrenzen ist zunächst mit grundlegenden Restriktionen auf Basis von Randbedingungen der Prüfumgebung oder allgemein mit stochastischen Frühausfällen zu rechnen, unabhängig davon, ob sie geometrisch auf derselben Sphäre wie die faktoriellen Eckpunkte liegen. Die methodische Beschränkung auf nur einen




Abbildung 4.2: Variationen der Design-Matrix im Rahmen der Potenzialanalyse. Die Abbildung zeigt die geometrischen Modifikationen entsprechend Tabelle 4.1 für die gewählten Einflussgrößen.

vereinzelter SP - in Abbildung 4.2 exemplarisch visualisiert - vereinfacht dabei das Simulationslayout sowie die Interpretierbarkeit und ist analytisch hinreichend. Da das zugrundeliegende Basis-CCD a priori eine vollständige Achsensymmetrie aufweist, verhalten sich die Dimensionen des Parameterraums isotrop. Ein isolierter topologischer Eingriff entlang einer spezifischen Achse legt somit den reinen Wirkmecha-

nismus der Varianzinflation offen, welcher sich aufgrund der geometrischen Gleichwertigkeit direkt auf alle anderen Achsen projizieren lässt [32]. Würden stattdessen multiple asymmetrische Verschiebungen simultan induziert, resultierte dies in nicht-linearen Überlagerungen der Kovarianzen innerhalb der inversen Informationsmatrix $\mathbf{M}^{-1}$. Eine derartige untrennbare statistische Vermengung der Störeinflüsse würde die Identifikation isolierter Kausalitäten - das Kernziel der Potenzialanalyse - erschweren. Globale, symmetrische Skalierungen des gesamten Versuchsraums werden ohnehin entkoppelt über den Faktor ζ_a (Variation von α_D) erfasst. Um die stochastische Realität technischer Systeme im Rahmen dieser Potenzialanalyse abzubilden, werden die wahren Modellparameter β_j nicht starr fixiert. Ausgehend von kalibrierten nominalen Startwerten $\beta_{j,\text{nom}}$ (vgl. Tabelle 4.2) unterliegen die Koeffizienten in jedem Monte-Carlo-Lauf einer stochastischen Schwankung entsprechend *Random Effects* [22]. Zusätzlich wird die Systemantwort y_{sim} mit einem additiven Restfehler ϵ beaufschlagt, welcher die aleatorische Unsicherheit modelliert:

$$\epsilon \sim \mathcal{N}(0, \sigma_{\text{sim}}^2) \quad \text{und} \quad \beta_j \sim \mathcal{N}(\beta_{j,\text{nom}}, \sigma_{\text{sim}}^2). \quad (4.2)$$

Die Wahl der Normalverteilung ist dabei methodisch notwendig: Sie erfüllt die Prämissen des Gauß-Markow-Theorems und stellt sicher, dass die statistische Inferenz im ungestörten Basis-Design erwartungstreu operiert. Etwaige Schätzfehler lassen sich somit kausal auf induzierte *Orthogonalitätsabweichungen* durch Design-Modifikationen aus Tabelle 4.1 zurückführen, ohne durch verteilungsbedingte Asymmetrien überlagert zu werden [2]. Für die späteren, dedizierten Design-Modifikationen im weiteren Verlauf des Kapitels wird die stochastische Überlagerung der wahren Parameter (*Random Effects*) jedoch deaktiviert und das System deterministisch auf einen festen Arbeitspunkt aufbauend auf die Ergebnisse der vorliegenden *Potenzialanalyse* kalibriert, um weitere Effekte isoliert evaluieren zu können.

Die in Tabelle 4.2 definierten Startwerte der Modellparameter fungieren dazu als dimensionslose, generische Basisgrößen. Da die topologische Auswertung von RSDs maßstabs- und translationsinvariant ist - die *power* wird nicht durch absolute Werte, sondern durch die relativen Amplituden- und Rauschverhältnisse (SNR) in ξ determiniert, dienen diese Werte alleinig der Etablierung eines numerisch stabilen Referenzniveaus. Sie stellen über die vollständige Regressionsgleichung sicher, dass die berechnete Systemantwort über den gesamten Versuchsraum hinweg strikt positiv

Tabelle 4.1: Definition und Parametrisierung der Untersuchungsfaktoren für die Sensitivitätsanalyse

	Beschreibung	Wertebereich	Charakteristik	Kategorie
ζ_a	SP-Abstand (α_D) Variation des axialen Sternpunktabstands zum Zentrum.	$[1,00; 2 \cdot \alpha_D]$	Kontinuierlich	Design
ζ_b	SP-Shift Asymmetrische, co-faktorielle Verschiebung eines SP.	$[0,10; \alpha_D]$	Kontinuierlich	Design
ζ_c	ZPs (n_{ZP}) Diskrete Variation der Zentralpunktanzahl $n_{ZP} \in \{1, 5, 8\}$.	$[1,00; 8,00]$	Diskret (Blockfaktor)	Design
ζ_d	SPs (n_{SP}) Diskrete Variation der Sternpunktanzahl $n_{SP} \in \{2, 3, 4\}$.	$[2,00; 4,00]$	Diskret (Blockfaktor)	Design
ζ_e	Effekt-Rauschen Streuung der wahren Modellparameter (σ_{sim}/β).	$[0,80; 1,20]$	Kontinuierlich	System
ζ_f	Effekt-Verhältnis (β_1/β_2) Amplitudenverhältnis zweier Haupteffekte.	$[0,10; 1,00]$	Kontinuierlich	System
ζ_g	Mess-Rauschen (SNR: y/ϵ) Verhältnis zwischen mittlerer Effektamplitude und Fehler.	$[0,80; 1,20]$	Kontinuierlich	System
ζ_h	Signifikanzniveau (α) Vorgegebene Irrtumswahrscheinlichkeit.	$[0,02; 0,08]$	Kontinuierlich	System

Tabelle 4.2: Nominale Startwerte und Streuparameter des pseudo-physikalischen Simulationsmodells

Modellparameter	Default-Wert
Regressionskonstante β_0	30
Regressionskoeffizienten β_j (für $j \in \{1, 2, 12, 11, 22\}$)	10
Standardabweichung der Systemantwort σ_{sim}	1

bleibt und physikalisch möglicherweise unplausible (z.B. negative) Werte infolge der stochastischen Überlagerungen vermieden werden. Zur formalen Beschreibung des Sensitivitätsraums der Potenzialanalyse werden die acht Einflussgrößen im Parametervektor $\xi = [\xi_a, \dots, \xi_h]^\top$ zusammengefasst und gemäß Tabelle 4.1 parametrisiert. Die Einbindung in das Meta-Design erfolgt methodisch differenziert: Während die sechs kontinuierlichen Geometrie- und Rauschparameter den stetigen Parameterraum aufspannen, werden die strukturellen Stützstellenzahlen (ξ_c, ξ_d) als kategoriale Blockfaktoren über jeweils drei diskrete Stufen ($-1, 0, +1$) variiert. Diese Entkopplung ist notwendig: Eine Reduktion der Stützstellen verändert die Rang- und Freiheitsgradstruktur der Informationsmatrix diskontinuierlich. Ein kontinuierliches Meta-Modell würde unzulässig über diese strukturellen Singularitäten interpolieren (beispielsweise in Form unphysikalischer, fraktionaler Versuchspunkte). Die Kombination der beiden diskreten Blockfaktoren spannt folglich exakt $3 \times 3 = 9$ isolierte Basis-Topologien auf. Die kontinuierlichen Sensitivitäten werden isoliert innerhalb dieser neun diskreten Topologie-Blöcke ermittelt (dokumentiert im Anhang B). Im Fokus dieser Potenzialanalyse steht dabei exklusiv die statistische Trennschärfe (*power*). Für den Zuverlässigkeitsingenieur stellt sie die primäre quantitative Entscheidungsgröße dar: Sie definiert maßgeblich, ob ein ressourcenintensiver Test überhaupt die methodische Aussicht auf einen erfolgreichen Nachweis des physikalischen Effekts besitzt. Die exakte Ausprägung des Schätzwertes ordnet sich dieser grundlegenden Erfolgsgarantie im Rahmen eines Screenings unter, weshalb sie als entscheidende Kenngröße in der Potenzialanalyse betrachtet wird. Der makroskopische Effekt der Stützstellenreduktion selbst wird separat über die Niveauverschiebungen der *power* zwischen den neun Blöcken quantifiziert. Gegenüber alternativen Screening-Verfahren gewährleistet dieser hierarchische DoE-Ansatz eine formal abgesicherte Kausalitätsprüfung zur


Trennung von Haupteffekten, Interaktionen und Krümmungsanteilen auf die resultierende Trennschärfe [32, 93], wenngleich in den nachfolgenden Untersuchungen ergänzend weitere Metriken herangezogen werden.

4.2.2 Ergebnisse der Potenzialanalyse und Quantifizierung der Trennschärfe

Die Untersuchung der Trennschärfe im Meta-Design offenbart eine grundlegende Zweiteilung zwischen dispositiven Designfaktoren (Geometrie, Stützstellenanzahl) und externen Systemrestriktionen (Rauschen, Signifikanzniveau). Tabelle 4.3 fasst die Ergebnisse der ANOVA zusammen, wobei die signifikante Effektstärke E als Maß für die Dominanz eines Faktors dient: Sie erfasst hier, in welchem Maß die Variation eines der acht Einflussgrößen die Trennschärfe bei der Identifikation des jeweiligen Koeffizienten beeinflusst - und in welchem Umfang der resultierende *power*-Wert schlussfolgernd streut. Vereinfachend werden pro Koeffizient nur die jeweils dominierenden Einflussgrößen mit der höchsten Effektstärke ausgewiesen.

Wird die globale Modell-Power betrachtet, zeigt sich eine hohe Robustheit mit einer mittleren Trennschärfe von $\overline{power}_m > 99,7\%$. Diese globale Metrik verdeckt jedoch das hochsensitive Verhalten der isolierten Einzel-Effekte - insbesondere der quadratischen Terme ($power_{\beta_{11}}, power_{\beta_{22}}$), deren Trennschärfe in den Bereich von 70 % bis 79 % abfällt. Unterschiedliche Trennschärfen der quadratischen Terme trotz identischer nominaler Startkoeffizienten ergeben sich hierbei aufgrund der Konsequenz der zuvor etablierten asymmetrischen Stör-Topologie: Da der simulierte SP-Shift (Faktor ζ_b) auf der x_2 -Achse induziert wird, wird die Schätzung von β_{22} maßgeblich durch die physische Design-Geometrie (ζ_a) dominiert. Der Term β_{11} auf der ungestörten Achse wird hingegen primär durch die allgemeine Systemrestriktion des Messrauschens (ζ_g) limitiert, was die Effektstärke des Design-Faktors ζ_a auf $power_{\beta_{11}}$ zwar reduziert, für den Koeffizienten β_{22} jedoch als dominant herausstellt. Da das Rauschen in der Praxis zumeist eine unveränderliche Randbedingung darstellt, definiert es die natürliche Obergrenze der erreichbaren Trennschärfe. Aus der Systematik in Tabelle 4.3 kristallisiert sich der zentrale Umkehrschluss für die weitere Versuchsplanung heraus: Da die Nachweiswahrscheinlichkeit der linearen Haupteffekte nahezu exklusiv durch systemische Rauschfaktoren beschrieben wird, reagiert das Design gegenüber einer Reduktion seiner axialen und zentralen Stützstellen hochgradig robust. Weder die ZP- noch

Tabelle 4.3: Ausgewählte Statistik der Trennschärfe (Lage des Mittelwerts ($\circ$) innerhalb des resultierenden Wertebereichs ($[\min; \max]$) auf der Basislinie von 0 % bis 100 %) und Identifikation der jeweils dominierenden Einflussfaktoren mit Kategorien.

Koeffizient	Mittelwert	Empirische Streuung	Dominierende Sensitivität	
	$\overline{power}$	(Min – μ – Max)	Einflussfaktor (Kat.)	E
$power_m$	99,7 %		ξ_g (System)	0,10
$power_{\beta_0}$	97,9 %		ξ_e (System)	0,52
$power_{\beta_1}$	78,6 %		ξ_g (System)	1,50
$power_{\beta_2}$	66,0 %		ξ_f (System)	2,53
$power_{\beta_{12}}$	72,6 %		ξ_g (System)	1,93
$power_{\beta_{11}}$	70,9 %		ξ_g (System)	1,99
$power_{\beta_{22}}$	79,3 %		ξ_a (Design)	3,72

die SP-Anzahl (Faktoren ξ_c und ξ_d) treten als dominierende Limitierung in Erscheinung. Genau in dieser topologischen Unempfindlichkeit verbirgt sich das gesuchte geometrische Gestaltungspotenzial. Um zu verifizieren, ob eine gezielte Ausdünnung dieser unkritischen Punkte die statistische Aussagekraft tatsächlich nicht nennenswert kompromittiert, quantifiziert Tabelle 4.4 den topologisch induzierten Einfluss auf die $power$ als mittlere Trennschärfe-Änderung. Die numerische Bilanzierung belegt hier die Robustheit des CCD-Skeletts: Der Verzicht auf redundante Zentralpunkte oder die Ausdünnung der Sternpunkte zieht für die Haupteffekte lediglich einen untergeordneten Trennschärfe-Verlust nach sich. Der exklusive strukturelle Schwachpunkt dieser Reduktion isoliert sich auf die quadratischen Terme (bis zu $-13,9\%$ bei $power_{\beta_{11}}$).

Aus dieser Erkenntnis formt sich die übergeordnete Strategie der adaptiven Versuchsplanung: Die unkritische Reduktion klassischer Stützstellen gefährdet die Detektion von Haupteffekten kaum, was ein *geometrisches Gestaltungsbudget* freisetzt. Gleichzeitig belegt Tabelle 4.3, dass die periphere Design-Geometrie (Sternpunktabstand ξ_a) mit $E = 3,72$ den mit Abstand stärksten Hebel auf eben jene sensitiven quadratischen Terme besitzt. Die methodische Schlussfolgerung lautet daher: Das freigesetzte Gestaltungsbudget wird folglich nicht zur trivialen Kostensenkung gestrichen, sondern proaktiv in asymmetrische topologische Reallokationen investiert. Diese umgewidmeten Stützstellen stützen die Modellkrümmung ab und minimieren so systematisch die

Tabelle 4.4: Systematischer Trennschärfe-Verlust ($\Delta power$) bei Ausdünnung der Versuchsstützpunkte.

Koeffizient	Durchschnittlicher Trennschärfe-Verlust ($\Delta power$)	
	durch ξ_c (n_{ZP})	bei ξ_d (n_{SP})
$power_{\beta_0}$	−4,5 %	−0,3 %
$power_{\beta_1}$	−2,4 %	−6,0 %
$power_{\beta_2}$	+1,1 %*	−8,0 %
$power_{\beta_{12}}$	−1,2 %	−0,9 %
$power_{\beta_{11}}$	−13,9 %	−12,8 %
$power_{\beta_{22}}$	n. a.**	−6,1 %

* Resultiert aus Varianzverschiebungen bei instabilen Designs.

** Nicht auswertbar aufgrund von Singularität.

Extrapolationsvarianz für die Lebensdauerprognose im Feldbetrieb. Inwiefern diese Strategie in der Praxis tatsächlich die statistische Aussagekraft des Versuchsplans bewahrt, wird in Abschnitt 4.2.3 im Folgenden anhand von vier gewählten Störszenarien evaluiert.

4.2.3 Generische Auswirkungen relevanter Orthogonalitätsabweichungen

Die generalisierte, kombinatorische Betrachtung des Meta-Designs bedarf für die angewandte Versuchsplanung von ALTs einer topologischen Detaillierung. Wie die vorangegangene Potenzialanalyse belegt, tangieren Modifikationen der Design-Architektur die Trennschärfe der linearen Haupteffekte zumeist nur nachgelagert und entfalten ihre dominierende Hebelwirkung exakt bei den hochsensiblen quadratischen Modelltermen (beispielhaft identifiziert in Tabelle 4.3 durch ξ_a sowie Tabelle 4.4 durch ξ_c und ξ_d). Korrespondierend hierzu wird in der einschlägigen Literatur argumentiert, dass in der realen Prüfstandsumgebung selten systematische Matrix-Ausdünnungen, sondern vielmehr asymmetrische, isolierte Geometrieabweichungen durch physikalische oder normative Restriktionen erzwungen werden [58, 71, 94, 95].

Um diese Effekte zu evaluieren, wird im Folgenden bewusst auf eine erschöpfende kombinatorische Variation sämtlicher Versuchspunkte verzichtet - ein Vorgehen, das

methodisch ohnehin primär in globale Skalierungs- oder Sphärizitätseffekte des CCD übergehen würde. Stattdessen fokussiert sich die nachfolgende Analyse exemplarisch auf dedizierte Einzelmodifikationen der Kategorie *Design*. Diese gezielte Auswahl erhebt keinen Anspruch auf kombinatorische Vollständigkeit; sie dient vielmehr dem Zweck, die fundamentalen Auswirkungen des zuvor identifizierten topologischen Potenzials unter praxisnahen Randbedingungen trennscharf zu quantifizieren. Aus dem Verständnis dieser kausalen Zusammenhänge lassen sich generalisierbare, methodische Hebel für die Entwicklung effizienter multivariater Lebensdauerversuche ableiten.

Dementsprechend werden, basierend auf der Simulationsmethodik aus Abschnitt 4.1, vier spezifische Störszenarien definiert, welche typische Restriktionen der industriellen Erprobungspraxis abbilden [71, 94]:

- **Fall I (Asymmetrischer axialer Abstandsfehler):** Ein singulärer SP kann aufgrund lokaler Anlagenrestriktionen nicht auf dem nominellen Abstand α_D positioniert werden. Im Gegensatz zur symmetrischen Verschiebung aller SPs - die primär eine Skalierung des Versuchsraums oder einen Verlust der Rotierbarkeit repräsentiert - erzwingt erst dieser isolierte Fehler den kritischen asymmetrischen Orthogonalitätsbruch. Die Quantifizierung erfolgt methodisch über drei Stufen: eine axiale Stauchung auf 80 %, eine Streckung auf 120 % sowie der vollständige Rückzug auf das Nennlastniveau des faktoriellen Kerns (*Face Centered* (FC), $\alpha_D = 1$).
- **Fall II (Asymmetrische co-faktorielle Korrelation):** Ein singulärer SP ist nicht mehr achsenrein isoliert realisierbar. Spezifische physikalische Systemfunktionalitäten (beispielsweise kombinierte Einflüsse durch Temperatur und mechanische Kraft) erzwingen die parasitäre Aussteuerung eines zweiten Faktors, wodurch eine asymmetrische geometrische Korrelation im ansonsten orthogonalen Raum entsteht. Dieser Fall wird in einer leichten und einer starken Ausprägung untersucht, indem ausschließlich der Sternpunkt der x_1 -Achse durch einen parasitären Stellgrößenanteil von $x_2 = 0,1$ sowie $x_2 = 1,0$ überlagert wird.
- **Fall III (Stellgrößen-Scatter):** Die Aktorik des Prüfstands erlaubt keine exakte Ansteuerung der Zielkoordinaten in den extremsten Einstellungen, sodass

die nominellen SPs einer unbeabsichtigten stochastischen Streuung unterliegen (uniformes Rauschen von $\pm 10\%$ auf der Eingangsvariablen x_i).

- **Fall IV (Früh-Ausfall / Zensierung):** Ein Versuchspunkt führt zu einem Früh-ausfall, abweichendem Schädigungsmechanismus, wird als Durchläufer zensiert oder kann aus Zeitgründen nicht abgeschlossen werden. Der Versuch entfällt somit vollständig aus der finalen Design-Matrix. Der Ausfall faktorieller Eckpunkte wird hierbei bewusst exkludiert, da deren Verlust die orthogonale Basis der linearen Haupteffekte fundamental zerstört und zumeist einen analytischen Versuchsabbruch erzwingt. Stattdessen wird vereinfacht die Zensierung peripherer und zentraler Punkte in zwei Unterkategorien differenziert:
 - **Fall IV-ZP:** Eliminierung eines geometrisch redundanten ZP. Da diese Punkte räumlich deckungsgleich im Ursprung liegen, dient deren Wiederholung primär der Schätzung des reinen Versuchsfehlers. Ihr Wegfall reduziert folglich nicht die geometrische Aufspannung des Parameterraums.
 - **Fall IV-SP:** Asymmetrische Eliminierung extremer SPs - hier simuliert am isolierten Entfall des nördlichen SP auf der Achse von Faktor x_1 .

Wird als Referenzbasis zusätzlich zu den Design-Variationen der **Fälle I-IV** das ungestörte *Basis CCD* berücksichtigt, ergeben sich insgesamt neun zu evaluierende Szenarien. Für diese werden die Auswirkungen der jeweiligen Praxisrestriktion auf die Effektivität der Parameterschätzung und die *power* der Effekte isoliert quantifiziert. Es gilt zu ermitteln, inwiefern der Verlust der Orthogonalität - messbar über den globalen A_2 -Indikator - zu Multikollinearität und folglich zu einer schädlichen Varianzinflation (VIF beziehungsweise MSE) oder gar zu systematischen Verzerrungen der Koeffizientenschätzung (*Bias*) führt. Die analytische Differenzierung dieser Fehlerarten ist elementar, da ein signifikanter Bias die Validität der gesamten Lebensdauerprognose unbemerkt kompromittieren würde, während eine reine Varianzinflation primär die Konfidenzintervalle aufweitet.

Kalibrierung der Signal-to-Noise Ratio und analytische Justierung des Arbeitspunkts

Die vorausgegangene Potenzialanalyse (vgl. Abschnitt 4.2.2 und Tabelle 4.3) hat das SNR als dominierenden Begrenzungsfaktor der statistischen Trennschärfe identi-

ziert. Bei extrem starken physikalischen Effekten ($\text{SNR} \gg 1$) konvergiert die *power* in eine asymptotische Sättigung nahe 100 %, vergleiche Abbildung 2.5 [68]. In diesem Zustand operiert das Regressionsmodell derart fehlerverzeihend, dass selbst gravierende geometrische Verzerrungen des CCD durch das starke Signal maskiert werden und keinen messbaren Einbruch der Nachweiswahrscheinlichkeit (*power*) provozieren. Um die methodische Sensitivität für die Evaluation subtiler topologischer Schwachstellen zu maximieren, muss der stochastische Arbeitspunkt der Simulation daher kalibriert werden.

Hierfür wird das Basismodell am kritischen Punkt maximaler Empfindlichkeit verankert: Bei einer vorgegebenen Standardabweichung der Systemantwort von $\sigma = 5,0$ wird das SNR für die schätztechnisch sensitiven Terme zweiter Ordnung auf die obere Intervallgrenze von ξ_g mit $\text{SNR} = 1,20$ justiert: $|\beta_{11}| = |\beta_{22}| = |\beta_{12}| = 6,0$. Diese Parametrisierung zwingt das Referenz-Design für die quadratischen Effekte exakt auf die steilste Flanke der sigmoidalen Trennschärfe-Funktion (Basis-*power* von ca. 70 % bis 80 %) [22]. Nur an diesem Wendepunkt konvertiert eine geometrisch induzierte Varianzinflation in einen messbaren Effektivitätsverlust, der eine trennscharfe Quantifizierung topologischer Schwachstellen ermöglicht.

In strikter Übereinstimmung mit dem *Sparsity of Effects Principle* [22] - welches postuliert, dass technische Systeme primär durch Haupteffekte und erst nachgelagert durch Interaktionen niedriger Ordnung dominiert werden - fließen die linearen Terme proportional stärker mit $\beta_1 = \beta_2 = 12,0$ ($\text{SNR} = 2,40$) in das Modell ein (vgl. Tabelle 4.5). Zusammen mit der Konstanten $\beta_0 = 24,0$ hebt dies die Systemantworten in einen plausiblen, strikt positiven Bereich. Die gezielte Kombination aus positiven Haupteffekten und negativen quadratischen Termen emuliert dabei exakt das physikalische Verhalten eines durch Sättigungseffekte begrenzten Leistungsoptimums - entsprechend gängiger Zuverlässigkeitsmodellierungen, vergleiche später Abbildung 4.16.

Tabelle 4.5: Kalibrierte Startwerte und statistische Eigenschaften des Normalverteilungs-Basismodells

Koeffizient	β_0	β_1, β_2	β_{11}, β_{22}	β_{12}	σ
Wahrer Wert	24,0	12,0	-6,0	-6,0	5,0
SNR	-	2,40	1,20	1,20	-

Wie in Abschnitt 4.1.2 methodisch abgeleitet, wird zur fokussierten Evaluation dieser geometrischen Störszenarien die zusätzliche Überlagerung durch *Random Effects* deaktiviert. Ebenso greift an dieser Stelle die algorithmische Kontrollfunktion der *Common Random Numbers* (Seed-Fixierung) [93]: Da sämtliche zu evaluierenden Design-Derivate auf exakt identische stochastische Rauschvektoren angewendet werden, ist methodisch garantiert, dass jede resultierende Abweichung in Bias und MSE kausal und ausschließlich auf den induzierten Orthogonalitätsverlust der Matrix $\mathbf{X}$ zurückzuführen ist.

Quantitative Auswertung und explorative Optimalitäts-Analyse

Die Auswertung der definierten Praxis-Szenarien (**Fälle I-IV**) am kalibrierten, kritischen Arbeitspunkt ($\text{SNR} = 1,20$) offenbart eine hochgradig differenzierte Reaktion der klassischen Design-Metriken und der numerisch ermittelten Schätzgüte, vgl. Tabelle 4.6. Zur detaillierten Evaluation wird die Leistungsfähigkeit nachfolgend auf Basis der kombinierten Schätzvarianz (*VIF* in Tabelle 4.6 bzw. *MSE* in Abbildung 4.3), dem systematischen Schätzfehler (*Bias* in Abbildung 4.4) sowie der resultierenden Trennschärfe-Variation (Δpower in Abbildung 4.6) aufgeschlüsselt.

Die nachfolgende Auswertung der Design-Metriken aus Tabelle 4.6 fokussiert sich bewusst auf algebraische *a priori*-Kriterien. Da Metriken wie die *D*-, *I*- oder *G*-Effizienz im linearen Modell exklusiv auf der Informationsmatrix $\mathbf{X}'\mathbf{X}$ beruhen, isolieren sie den reinen geometrischen Design-Fehler. Parameterabhängige Gütemaße - wie beispielsweise die *U*-Optimalität - werden an dieser Stelle methodisch exkludiert, um die topologische Bewertung nicht unzulässig mit den stochastischen Annahmen der wahren Koeffizienten zu vermengen. Dabei manifestieren sich drei zentrale Gesetzmäßigkeiten:

- **Volumeneffekte und Prädiktionsgüte:** Kriterien wie die *I*- und *D*-Effizienz skalieren direkt mit dem geometrischen Trägheitsmoment (der räumlichen Ausdehnung) des Versuchsraums. So erzielt der nach außen gestreckte Shift eines extremen Sternpunktes (*Fall I*, +20 %) Bestwerte in der integrierten Prädiktionsvarianz mit $I_{\text{eff}} = 85,1 \%$. Demgegenüber erzeugen Ausfälle periphere Informationsverluste, deren topologische Sensitivität jedoch gravierend divergiert: Während der asymmetrische Entfall eines extremen Sternpunktes (*Fall IV-SP*) eine starke Reduktion der *I*-Effizienz auf $I_{\text{eff}} = 69,0 \%$ nach sich zieht, dämpft

der Ausfall eines Zentralpunktes (*Fall IV-ZP*) die Vorhersagegüte keineswegs. Vielmehr steigt die SPV-normierte I_{eff} aufgrund des reduzierten Stichprobenumfangs N rechnerisch sogar auf 85,7 %. Dies belegt die methodische Ineffizienz reiner Basis-ZPs für Extrapolationsvorhaben.

- **Topologische Singularitäten:** Eine starke *co-faktorielle Korrelation* (*Fall II, stark*) erzeugt ein signifikantes Informationsdefizit. Obwohl das globale Design-Volumen bei dieser Modifikation weitestgehend erhalten bleibt, konvergiert der A_2 -Indikator als Maß für die Nicht-Orthogonalität gegen sein absolutes Maximum von 0,352. Die durch die parasitäre Abhängigkeit entstehenden Lücken im Parameterraum bestraft die an *Worst-Case-Szenarien* orientierte *G-Effizienz* mit einem drastischen Einbruch, während sich der reale Informationsverlust in eine term-spezifische Varianzinflation verlagert.
- **Geometrische Selektivität der Varianzinflation:** Der VIF bildet den Orthogonalitätsverlust nicht global, sondern hochgradig isoliert ab. Beim asymmetrischen Sternpunkt-Ausfall (*Fall IV-SP*) greift die stringente Mathematik der entkoppelten Achsen: Da der entfallene SP exakt auf der x_1 -Achse liegt, leiden ausschließlich der zugehörige Haupteffekt $\hat{\beta}_1$ sowie der quadratische Term $\hat{\beta}_{11}$ unter spürbarer Varianzinflation. Die orthogonal dazu stehende x_2 -Achse bleibt von diesem topologischen Bruch vollkommen unbeschadet.

Diese geometrisch induzierten Varianzerhöhungen werden in Abbildung 4.3 über den MSE empirisch verifiziert. Eine besondere topologische Hebelwirkung zeigt sich beim Interaktionsterm β_{12} unter starker *co-faktorieller Korrelation* (*Fall II, stark*): Sein MSE sinkt im Vergleich zum Basis-Design. Durch das parasitäre Abdriften des Sternpunkts von $(\alpha_D, 0)$ auf $(\alpha_D, 1)$ vergrößert sich die Stützbasis für das Kreuzprodukt $x_1 x_2$ künstlich. Das Design gewinnt für exakt diesen Term an Hebelwirkung, was dessen isolierte Schätzvarianz senkt. Erkauft wird dieser lokale Gewinn jedoch durch die Zerstörung der Matrix-Orthogonalität gemessen durch A_2 und große Varianzerhöhungen in *VIF* der übrigen Parameter.

Gleichzeitig belegt die Auswertung der Fehlerstrukturen (vgl. Abbildung 4.4) die uneingeschränkte Erwartungstreue des OLS-Schätzers. Die empirische Ausweisung dieser Metrik erbringt den formalen Nachweis, dass geometrische Verzerrungen des Versuchsplans - solange das Auswertemodell korrekt spezifiziert bleibt - ausschließ-

Tabelle 4.6: Matriceigenschaften und Effizienzen zu Optimalitätskriterien der simulierten Störszenarien. Der VIF wird für alle Haupt- und quadratischen Terme dargestellt ($\hat{\beta}_0$ entfällt theoriekonform).

Szenario (Störfall)	A_2	Effizienzen [%]					VIF				
		A_{eff}	D_{eff}	G_{eff}	I_{eff}	V_{eff}	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	0,000	42,9	50,0	17,6	81,2	180,0	1,00	1,00	1,00	1,00	1,00
Fall I: Shift (−20 %)	0,037	40,3	47,0	15,9	76,0	181,7	1,04	1,00	1,00	1,04	1,00
Fall I: Shift (+20 %)	0,038	45,0	53,6	17,7	85,1	181,0	1,04	1,00	1,00	1,04	1,00
Fall I: FC	0,071	39,1	45,9	15,2	73,5	184,0	1,07	1,00	1,00	1,08	1,01
Fall II: Korrelation (leicht)	0,004	42,9	50,0	17,0	81,2	180,0	1,00	1,00	1,00	1,00	1,00
Fall II: Korrelation (stark)	0,352	42,5	51,3	13,9	80,3	183,5	1,16	1,07	1,23	1,18	1,07
Fall III: Scatter ($\pm 10\%$)	0,007	43,8	51,5	16,6	83,0	180,2	1,00	1,00	1,00	1,00	1,00
Fall IV: SP	0,183	37,6	45,3	14,3	69,0	197,2	1,22	1,00	1,00	1,22	1,05
Fall IV: ZP	0,001	44,4	52,2	18,7	85,7	164,8	1,00	1,00	1,00	1,00	1,00




Abbildung 4.3: Güte der Schätzer (MSE) am Arbeitspunkt $\text{SNR} = 1,20$. Geometrische Verzerrungen entladen sich primär in der Schätzvarianz (vgl. *Fall IV-SP*). Das Absinken des Fehlers für β_{12} in *Fall II* resultiert aus dem künstlich erhöhten Hebelarm für das Interaktions-Kreuzprodukt.

lich die Schätzvarianz anregen. Der systematische Schätzfehler in der Parameterschätzung (Bias) verharrt im Bereich des numerischen Rauschens und kompromittiert das Gauss-Markow-Fundament nicht.




Abbildung 4.4: Absolute Schätzwerte der Modellkoeffizienten für den Arbeitspunkt $\text{SNR} = 1,20$. Der systematische Schätzfehler (Bias) bleibt marginal, was die OLS-Erwartungstreue trotz topologischer Verzerrungen verifiziert.

Die hinreichende Dimensionierung von $n_{\text{MC}} = 1 \cdot 10^4$ Simulationsläufen zur Eliminierung des stochastischen Approximationsrauschens wird dabei exemplarisch für den im Störfall orthogonal isolierten Koeffizienten $\hat{\beta}_2$ in Abbildung 4.5 einmalig und visuell belegt. Eine weitere Auflistung der Konvergenzverläufe für die übrigen Parameter wird mit Verweis auf Anhang B an dieser Stelle aus Platzgründen unterdrückt, da diese in allen Szenarien identisch verlaufen.

Da die Erwartungstreue der Schätzer durch diese Auswertung bewertet ist, folgt nun die Analyse der resultierenden Trennschärfe (*power*) der Effekte. Der Einfluss der gewählten Fehlerarchitektur auf die Trennschärfe (vgl. Abbildung 4.6) summiert die Effekte probabilistisch auf und verdichtet sich zu folgender Erkenntnis:

1. **Subkritische Restriktionen:** Stochastisch verzerrte Ansteuerung (*Fall III*) und der Entfall eines ZP (*Fall IV-ZP*) induzieren lediglich marginale Einbußen der Entdeckungswahrscheinlichkeit - zumeist $< 1,3$ Prozentpunkte, entsprechend Abbildung 4.6.




Abbildung 4.5: Numerische Konvergenz am Beispiel des Schätzwertes zu $\hat{\beta}_2$ über die MCS-Iterationen.

2. Kritische Restriktionen für Terme höherer Ordnung: Sobald die periphere Geometrie kompromittiert wird, reduziert sich die Trennschärfe maßgeblich. Selbst das symmetrische Zurückziehen eines SP auf das physikalische Randniveau (FC, Fall I) generiert einen Verlust von 6,7 Prozentpunkten bei den quadratischen Termen. Der asymmetrische Entfall eines Sternpunktes (Fall IV-SP) führt zum signifikantesten Rückgang (bis zu 10,6 Prozentpunkte bei $power_{\beta_{11}}$).

Hierbei ist ergänzend und einmalig die numerische Konvergenz der empirischen Trennschärfe in Abbildung 4.7 beispielhaft für die Koeffizienten β_2 dokumentiert, während für weitere Auswertungen auf die vollständige Auflistung in Anhang B verwiesen wird. Diese legt jedoch dar, dass die Konvergenz der Trennschärfe in allen Szenarien identisch verläuft und die gewählte Anzahl an MCS-Iterationen von $n_{MC} = 1 \cdot 10^4$ ebenfalls als ausreichend zu bewerten ist, um das stochastische Approximationsrauschen zu eliminieren.

Nachdem die simulativen Trennschärfe-Verluste für die Praxis-Szenarien quantifiziert wurden, stellt sich für die operative Versuchsplanung die Frage, inwieweit klassische algebraische *a priori*-Metriken diesen Abfall prädictieren können, ohne iterativ auf rechenintensive Monte-Carlo-Simulationen angewiesen zu sein. Die abschließende Korrelationsanalyse zwischen diesen Design-Metriken und der simulativen




Abbildung 4.6: Trennschärfe mit 95%-Konfidenzintervallen in Abhängigkeit der simulierten Störszenarien.




Abbildung 4.7: Numerische Konvergenz der Trennschärfe über die Simulationsläufe am Beispiel von β_2 .

Trennschärfe-Änderung $\Delta power$ (Abbildung 4.8) beantwortet diese Fragestellung eindeutig am Beispiel des quadratischen Terms β_{11} : Der rein algebraische A_2 -Indikator zeigt hierbei mit einem Bestimmtheitsmaß von $R^2 = 0,13$ keine nutzbare Indikation. Die globale Metrik zur *topologischen* Abweichung von der Orthogonalität vermag nicht zu prognostizieren, welcher isolierte Term auf der nichtlinearen Sigmoidalkurve der Trennschärfe letztendlich maßgeblich an *power* verliert. Die I_{eff} (mittlerer Graph in Abbildung 4.8) erweist sich gemäß der starken Korrelation von $R^2 = 0,80$ hingegen als hochgradig verlässliches Makro-Maß zur Bewertung der globalen Prognosegüte. Im Gegensatz dazu offenbart das Diagonalelement der inversen Informationsmatrix $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ - abgebildet über den daraus abgeleiteten Term-spezifischen MSE - eine nahezu perfekte lineare Abhängigkeit ($R^2 = 0,99$). Da diese strukturelle *a priori*-Matrixgröße die theoretische Schätzvarianz exakt determiniert, antizipiert sie den empirisch wirksamen MSE und damit den Trennschärfe-Erhalt isolierter Koeffizienten deterministisch (korrespondierend zur Zielfunktion der *A*-Optimalität). Weitere klassische *a priori*-Gütemaße - wie die volumenbasierte *D*-Optimalität oder die Extremwertfokussierte *G*-Optimalität - werden aus dieser dedizierten Prädiktionsanalyse bewusst exkludiert: Erstere kaschiert interne Varianzverschiebungen infolge topologischer Hebelwirkungen, während Letztere empfindlich auf lokale Singularitäten reagiert und sich folglich nicht als robuster Prädiktor für isolierte Trennschärfe-Verluste eignet. Zusammenfassend lässt sich die Eignung konventioneller Design-Metriken wie folgt systematisieren: Die A_2 -Metrik fungiert ausschließlich als unspezifischer globaler Warnindikator für Orthogonalitätsverluste. Die I_{eff} dient als belastbares globales Maß für die Prädiktionsgüte, während das Term-spezifische Diagonalelement $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ den entscheidenden *a priori*-Indikator für den Erhalt der lokalen Trennschärfe darstellt. Aus dieser Gegenüberstellung leitet sich für die Versuchsplanung folgender Sachverhalt ab: Geht es primär um die sichere statistische Identifikation isolierter physikalischer Effekte (*Hypothesentests*), muss das Design konsequent auf die Minimierung der Term-spezifischen Schätzvarianz durch strukturelle Optimierung der Matrixdiagonale (assoziiert mit der *A*-Optimalität) ausgelegt werden. Ist das übergeordnete Ziel jedoch die Minimierung der globalen Prognoseunsicherheit im Raum, erweist sich die prädiktive I_{eff} (in enger Verwandtschaft zur *V*-Optimalität) als der maßgebliche Stellhebel.




Abbildung 4.8: Korrelation zwischen a priori Design-Metriken und dem resultierenden Trennschärfe-Verlust in den Störszenarien.

4.2.4 Fazit: Statistische Effektivität als Basis der explorativen Versuchsplanung

Die simulativen Analysen unterstreichen eine ausgeprägte und gemäß der Fallunterscheidung in der Designmodifikation term-spezifische Resilienz des CCD gegenüber geometrischen und anlagenbedingten Abweichungen. Während große topologische Brüche eine messbare Aufweitung der Schätzvarianz (MSE) provozieren, offenbart sich eine für die Versuchsplanung grundlegende Erkenntnis: Die Detektion der Haupteffekte β_1 und β_2 erweist sich gegenüber geometrischen Störungen als robust, wohingegen die für die Modellkrümmung essenziellen quadratischen Terme sensibel auf periphere Informationsverluste reagieren. Die bewusste Inkaufnahme moderater geometrischer Restriktionen gefährdet die grundlegende Identifikation der primären Einflüsse somit nicht und erfüllt die grundlegende Erwartungshaltung: zum Erhalt einer belastbaren Schätzgüte der quadratischen Terme sollte eine ausreichende Anzahl an Stützstellen in der Peripherie des Versuchsraums vorhanden sein, für Haupteffekte fungiert der vollfaktorielle Kern des CCD als Identifikationskern. Jedoch eröffnet die Auswertung ein wertvolles *geometrisches Gestaltungsbudget*: topologisch redundante Stützstellen sowie die Lage peripherer Versuchspunkte (SPs) eignen sich zunächst grundlegend dafür, zur operativen Optimierung freigegeben zu werden.

Ogleich die allgemeine Vorhersagegüte prinzipiell in jedem Regressionsmodell mit der Prädiktionsvarianz verknüpft ist, gewinnt dies im Kontext der beschleunigten Lebensdauererprobung (ALT) eine existenzielle Hebelwirkung: Da ALT-Modelle den getesteten *Design-Space* in den fernen *Use-Space* (Betriebs-Parameterraum) extrapolieren müssen, potenziert sich die im Versuchsraum vorliegende Varianz der Prädiktion - insbesondere getrieben durch unsichere Krümmungseffekte - auf dem Extrapolationspfad. Sobald durch die fundamentale Robustheit des Designs die grundlegende Identifikation der Haupteffekte gesichert ist, wird die zielgerichtete Kontrolle der SPV-Struktur folglich zum primären Stellhebel der Versuchsökonomie.

Die konsequente Minimierung dieser Prognoseunsicherheit auf dem Extrapolationspfad bildet die theoretische Kernprämisse für eine belastbare Lebensdauerprognose. Anstatt das theoretisch freigesetzte Gestaltungsbudget trivial zur Wiederherstellung der klassischen Orthogonalität zu verwenden (wie es die traditionelle RSM fordern würde), leitet diese Arbeit hieraus eine methodische Antithese ab: Das aus topologisch unkritischen Versuchspunkten gewonnene Budget wird genutzt, um Stützstellen nach dem Gedanken *U*-optimaler Designplanungen gezielt asymmetrisch in Richtung des anvisierten Feldbereichs zu verlagern. Diese Strategie stellt den Kernansatz des nachfolgenden Abschnitts 4.3 dar. Das planerische Ziel lautet dabei, die für den *Betriebs-Parameterraum* kritische Prädiktionsvarianz exakt entlang des Extrapolationspfads abzustützen, während die robuste Grundstruktur des CCD als Identifikationskern für eine belastbare Schätzung der wesentlichen kausalen Zusammenhänge erhalten bleibt. Der quantitative Nachweis, inwiefern sich diese geometrische Stabilität real auf die Fehlerquoten einer echten Lebensdauerberechnung überträgt, obliegt schließlich der stochastischen Synthese im AFT-Raum (später folgend in Abschnitt 4.5).

4.3 Adaptive Versuchsplanung zur Extrapolationsabsicherung

Anstatt das in Abschnitt 4.2 identifizierte geometrische Budget zur passiven Kostensenkung zu nutzen, wird es topologisch reinvestiert: Die aufgrund der Design-Robustheit zur Disposition stehenden Stützstellen - wie substituierbare ZPs oder unkritische Sternpunkte (SPs) - werden als asymmetrische APs gezielt in Richtung des anvisierten Feldbereichs verlagert. Diese gerichtete *Extrapolationsstützung* sichert das Regressions-

modell auf dem Prognosepfad empirisch ab, während der Gesamtversuchsumfang N des CCD unverändert bleibt [96, 97, 98]. Das RSD bleibt dabei als topologischer Kern erhalten und gewährleistet die Identifikationsgüte für die Haupteffekte und Interaktionen. In Anlehnung an die sequenzielle Versuchsplanung aus Abschnitt 2.2.4 erfolgt zudem eine iterative, varianzgetriebene Verfeinerung der Stützstellenpositionen, um die SPV im kritischen Extrapolationspfad sukzessive zu minimieren [98]. Um den Leistungsgewinn dieser gerichteten Design-Manipulationen objektiv bewerten zu können, wird die SPV aus ihrer globalen Integralbetrachtung gelöst. Es bedarf ihrer Anwendung als lokale Maßzahl, die die Vorhersageunsicherheit gemäß Gleichung 2.21 punktgenau im kritischen Betriebspunkt quantifiziert.

4.3.1 Die Scaled Prediction Variance als Prognosemetrik

Wie die vorherigen Auswertungen demonstrierten, bewahrt das Basis-Design die Identifikation von Haupteffekten sehr robust, während geometrische Restriktionen primär die Schätzvarianz (MSE) der Krümmungsterme vergrößern. Für die beschleunigte Lebensdauererprobung, welche naturgemäß eine weite Extrapolation in den *Field-Space* erzwingt, reicht diese isolierte Betrachtung der Koeffizientenvarianz jedoch nicht mehr aus. Das methodische Erkenntnisinteresse verschiebt sich auf die räumliche Ausbreitung dieser Unsicherheit. Die Metrik der Prädiktionsvarianz projiziert die koeffizientenspezifischen MSE-Werte über die inverse Informationsmatrix auf jeden beliebigen Punkt im Versuchsraum. Zur Quantifizierung dieser ortsabhängigen Prognosegüte dienen dabei sowohl die SPV für *effizienzbasierte* topologische Varianzbewertungen als auch die UPV für die Bestimmung der absoluten physikalischen Vorhersageunsicherheit. Da bei der hier angestrebten reinen geometrischen Umverteilung der Stützstellen der Gesamtaufwand (Stichprobenumfang N) konstant bleibt, verhalten sich SPV und UPV streng proportional zueinander. Eine topologische Optimierung der Effizienzmetrik SPV führt in diesem Szenario zwangsläufig zu einer formgleichen Minimierung der absoluten Vorhersagepräzision UPV.

Zur Bewertung der Extrapolationsfähigkeit asymmetrischer Design-Modifikationen erweisen sich klassische sphärische Metriken wie VDG und FDS jedoch als unzureichend. Dies verdeutlicht zunächst die Zentralpunkt-Reduktion (*Fall IV-ZP*): Werden die redundanten ZPs von $n_{ZP} = 5$ auf beispielsweise $n_{ZP} = 3$ reduziert, verzeichnet das Zentrum $(0;0)$ lediglich einen marginalen Varianzanstieg, ohne dass sich die Prä-

diktionsgüte in der Peripherie verschlechtert. Wie Abbildung 4.9 zeigt, bleibt die SPV im Vergleich zum Basis-CCD im Extrapolationsraum nahezu unverändert oder sinkt aufgrund der Normierung mit dem geringeren N sogar ab. In der äußeren Sphäre ($r = \sqrt{2}$) reduziert sich die SPV dadurch um rund 15 % von 8,125 auf 6,875. Entgegengesetzt dazu führt eine Erhöhung der ZPs ($n_{\text{ZP}} > 5$) zu einem unvorteilhaften Anstieg der skalierten Varianz in der Peripherie. Die Reduktion des Grenznutzens




Abbildung 4.9: Vorhersagegüte bei Variation der ZP-Anzahl n_{ZP} für einen CCD mit $k = 2$ Faktoren.

lässt sich anhand des Grenzwerts der SPV im Versuchszentrum ($x_0 = 0$) formal belegen. Unter der Prämisse, dass die Schätzvarianz im Ursprung orthogonaler Versuchspläne primär durch die mittlere Varianz der Zentralpunkte determiniert wird ($\text{Var}(\hat{y}) \approx \sigma^2 / n_{\text{ZP}}$), ergibt sich für ein zweidimensionales CCD mit einer Struktur aus $n_{\text{F}} + n_{\text{SP}} = 8$ Randpunkten und einer zunehmenden Anzahl an Zentralpunkten n_{ZP} :

$$\begin{aligned} \lim_{n_{\text{ZP}} \rightarrow \infty} \text{SPV}(0) &= \lim_{n_{\text{ZP}} \rightarrow \infty} \frac{N \cdot \text{Var}(\hat{y}(0))}{\sigma^2} = \lim_{n_{\text{ZP}} \rightarrow \infty} \frac{(8 + n_{\text{ZP}}) \cdot \frac{\sigma^2}{n_{\text{ZP}}}}{\sigma^2} \\ &= \lim_{n_{\text{ZP}} \rightarrow \infty} \left(\frac{8}{n_{\text{ZP}}} + 1 \right) = 1 \end{aligned} \quad (4.3)$$

Dieses asymptotische Konvergenzverhalten liefert den Nachweis, dass die SPV im Zentrum am absoluten Minimum von 1 stagniert. Eine Erhöhung der Zentralpunktanzahl

über $n_{\text{ZP}} \approx 3$ hinaus erweist sich als statistisch redundant für die globale Modellanpassung und insbesondere für die ferne Extrapolation. Folglich ist die Reallokation dieser Versuchsressourcen für das geometrische Gestaltungsbudget methodisch begründet.

Demgegenüber nehmen die Sternpunkte (*Fall IV: SP*) eine kritischere Rolle ein, da sie die Varianztopologie in der Peripherie dominieren. Wird ein Sternpunkt zensiert oder ausgelassen (hier exemplarisch im Hochlastbereich), wächst die SPV in dieser Region stark an. Infolgedessen wird ein wesentlicher Teil des Versuchsraums durch unverhältnismäßig große Varianzwerte dominiert (vgl. FDS in Abbildung 4.10a). Die-




Abbildung 4.10: Vorhersagegüte bei Variation der SP-Anzahl n_{SP} für einen CCD mit $k = 2$ Faktoren. SPV-Werte für verschiedene Varianten entfallener Sternpunkte. Abbildung 4.10b zeigt den Fall des vollständigen Entfalls der Sternpunkte $(\alpha_D; 0)$ und $(0; \alpha_D)$ im Hochlastbereich.

se asymmetrische Störung erzeugt jedoch eine komplexe, anisotrope Varianzstruktur, an der klassische Visualisierungswerkzeuge fundamental scheitern. Die FDS-Metrik (Abbildung 4.10a) integriert die Varianz über das gesamte Design-Volumen und verliert dadurch per Definition jegliche räumliche Auflösung der Störungsrichtung. Der VDG (Abbildung 4.10b) wiederum verdeutlicht zwar eine extreme radiale Aufweitung des Streubereichs in Form divergierender Minimum- und Maximum-Bänder. Da er die SPV jedoch rein sphärisch aggregiert, bleibt die exakte geometrische *Richtung* dieser fatalen Varianzspitzen vollständig verborgen. Die wahre Ausprägung dieser




Abbildung 4.11: Dreidimensionale Darstellung der SPV (links) und zugehöriger Konturverlauf (rechts) für ein beispielhaft asymmetrisch manipuliertes Versuchsdesign: es entfallen $(0; \alpha_D)$ und $(\alpha_D; 0)$ eines CCD mit $k = 2$ Faktoren.

Asymmetrie offenbart erst der dreidimensionale Konturverlauf in Abbildung 4.11. Aus ingenieurwissenschaftlicher Perspektive ist eine solche Richtungsabhängigkeit hochgradig kritisch, da sie die Vorhersagegüte entlang des maßgeblichen Extrapolationspfads unbemerkt zerstören kann. Für die Zuverlässigkeitsplanung resultieren hieraus drei methodische Konsequenzen:

1. Lokale Fehlstellen in der Versuchsmatrix induzieren stark divergierende Varianzspitzen (*Blind Spots*) exakt entlang des Richtungsvektors der fehlenden Stützstelle.
2. Die Prognosegüte im fernen Feldbereich verhält sich in asymmetrischen Designs hochgradig richtungssensitiv. Pauschale Rückschlüsse auf die radiale Extrapolationsfähigkeit mittels VDG oder FDS sind mathematisch unzulässig und führen in der Praxis zu trügerischen Sicherheitsannahmen.
3. Sphärisch mittelnde Visualisierungen maskieren diese prognoserelevante Richtungsabhängigkeit vollständig und indizieren lediglich global die Existenz lokaler Varianzstreuungen.

Für die effiziente Auslegung multivariater ALT-Szenarien erzwingt dieses Defizit die Entwicklung eines spezialisierten Bewertungswerkzeugs, welches die SPV exakt entlang des physikalischen Lastpfads quantifiziert.

4.3.2 Richtungsabhängige Bewertung: Der Extrapolation Variance Graph (EVG)

Durch asymmetrische Modifikationen (vgl. *Fall I*, *Fall IV-SP* und *ZP*) verliert die Varianztopologie ihre konzentrische Rotationssymmetrie. Die Prädiktionsvarianz divergiert folglich richtungsabhängig. Für die Extrapolation einer Zuverlässigkeitsprognose in den fernen *Field-Space* ist somit nicht die azimutale Durchschnittsvarianz entscheidend, sondern exakt der Gradient entlang des Vektors zwischen Design-Zentrum und Zielpunkt. Um diesen topologischen blinden Fleck in der Interpretationsfähigkeit der Prädiktionsvarianz aufzulösen und asymmetrische Anpassungen zielgerichtet quantifizieren zu können, entwickelten Arndt und Dazer [98] den EVG. Dieser transformiert die Fragestellung: Anstatt die SPV über alle Raumrichtungen konzentrisch zu mitteln, wird sie ausschließlich entlang eines spezifisch definierten Extrapolationspfads analysiert. Dieser Pfad wird durch den normierten Richtungsvektor $\vec{e}$ beschrieben, welcher sich algebraisch exakt aus der Vektorstrecke vom Zentrum des Versuchsplans (Ursprung) hin zu dem anvisierten Prognosepunkt (z. B. dem nominalen Feldbetriebspunkt im *Use-Space*) berechnet. In Abhängigkeit des radialen Abstands r auf diesem Vektor wird die richtungsabhängige Prädiktionsvarianz - im Folgenden als $v(r, \vec{e})$ bezeichnet - wie folgt definiert:

$$v(r, \vec{e}) = N \cdot [\mathbf{x}_0(r, \vec{e})]' \mathbf{M}^{-1} [\mathbf{x}_0(r, \vec{e})] \quad (4.4)$$

Die Auswertungsfunktion $\mathbf{x}_0(r, \vec{e})$ transformiert den abgetasteten Koordinatenpunkt $r \cdot \vec{e}$ in den korrespondierenden Modellvektor, welcher auf die Polynomstruktur der Informationsmatrix $\mathbf{M}$ expandiert wird. Dadurch wird die Varianz topologisch isoliert entlang der kritischen Extrapolationsachse hin zum Prognosepunkt auswertbar. Gleichzeitig bleibt die Methodik flexibel anwendbar für ingenieurstechnisch relevante Stellen im Parameterraum, etwa zur Untersuchung spezifischer Randbereiche des Betriebsraums. Der EVG liefert somit die analytische Grundlage, um asymmetrische Stützstellen (APs) zielgerichtet zur Varianzdämpfung auf diesem ermittelten Extrapo-




Abbildung 4.12: Versuchsraum-Topologie: Das Basis-Design (CCD) wird durch strategische Extrapolations-APs (innerhalb der *Exposure-Area*) in Richtung des fernen Feld-Betriebspunktes (Ziel-Vektor) erweitert.

lationspfad zu allokalieren. Soll die skalierte Vorhersagevarianz $v(r_{\text{fix}}, \vec{e})$ in einem spezifischen Prognosepunkt minimiert werden, lässt sich die Ermittlung der optimalen AP-Koordinaten algorithmisch als diskretes Suchproblem formulieren. Der zugrundeliegende Suchraum (Ω) wird hierbei durch den reellen, kontinuierlichen Parameterraum aufgespannt, welcher logisch lediglich durch die physikalisch-technischen Stellgrenzen der Prüfstandsanlage limitiert wird. Für eine vorgegebene variable Anzahl freier Stützstellen n_{AP} (generiert aus dem zuvor abgeleiteten Gestaltungsbudget) erweitert der Algorithmus iterativ die Designmatrix um potenzielle Koordinatenkombinationen aus Ω und berechnet jeweils die resultierende Varianzausprägung. Da anlagenbedingte Restriktionen eine punktgenaue Ansteuerung des absoluten theoretischen Optimums in der Praxis oftmals verhindern, identifiziert das Verfahren nicht nur einen singulären Punkt, sondern eine robuste Teilmenge des Parameterraums. Dieser Lösungsbereich umfasst alle Koordinatenkombinationen, deren Platzierung die resultierende Varianz unterhalb einer definierten Toleranzschranke hält. Gesteuert

wird dieser Bereich über eine relative Toleranzmarge q (beispielsweise ein Aufschlag von 5 % auf das identifizierte absolute Minimum, $q = 0,05$):

$$\mathcal{X} = \{x_{AP,i} \in \Omega \mid \nu(r_{\text{fix}}, \vec{e}) \leq \min(\nu) \cdot (1 + q)\} \quad (4.5)$$

Die Menge dieser zulässigen Koordinaten spannt die sogenannte **Anker-Exposition** (*Exposure-Area*) $\mathcal{X}$ auf. Jede physikalisch realisierbare Platzierung der APs innerhalb dieses Toleranzfeldes garantiert eine varianzoptimale Stützung des Regressionsmodells auf dem Extrapolationspfad. Gleichzeitig gewährt diese Bereichsdefinition die notwendige Flexibilität für die technische Umsetzung am Prüfstand. Abbildung 4.12 illustriert diese Methodik exemplarisch: Das unveränderte Basis-CCD wird um drei strategisch investierte Extrapolations-APs im südwestlichen Quadranten erweitert. Die grau hinterlegte Anker-Exposition markiert dabei exakt jenen Parameterbereich, in dem eine beliebige Platzierung dieser APs die Prädiktionsvarianz im anvisierten Prognosepunkt $(-0,7; -1,9)$ zuverlässig auf den definierten Schwellenwert limitiert. Der algorithmische Suchprozess kann ergänzend Anhang 4.2.3 entnommen werden. Werden, wie in diesem Beispiel, konkrete Ankerpunkte identifiziert und fixiert, lässt sich das resultierende asymmetrische Design zur Überprüfung in einem 3D-Konturplot visualisieren (vgl. Abbildung 4.13). Beispielhaft werden die APs an dieser Stelle sowie in den nachfolgenden Abschnitten auf die Koordinaten $(-0,85; -2,60)$, $(-1,10; -2,35)$ und $(-0,85; -2,35)$ fixiert. Hierbei wird deutlich, wie die gesetzten APs die Varianztopologie im Zielquadranten eindrücken und den divergierenden Anstieg der SPV gezielt dämpfen. Die Anordnung der APs in Richtungs-optimaler Lage zur Minimierung der SPV in einem extrapolierten Prognosepunkt in Kombination mit der verbleibenden orthogonalen Designstruktur des CCD wird damit fortan als **EmALT-Design** bezeichnet. Der quantitative Nutzen dieser gezielten topologischen Manipulation manifestiert sich abschließend in der direkten Gegenüberstellung des klassischen VDG mit dem neu eingeführten EVG (vgl. Abbildung 4.14). Wird das EmALT-Design konventionell über den VDG evaluiert, maskiert dessen sphärische Mittelung den lokalen Informationsgewinn nahezu vollständig; das Design erscheint hierdurch fälschlicherweise kaum vorteilhafter als der Standard. Der EVG quantifiziert hingegen den tatsächlichen, zielgerichteten Erfolg der Modifikation: Durch die explizite Auswertung exakt entlang des Extrapolationsvektors $\vec{e}$ wird die SPV deterministisch bis in den fernen Prognosepunkt aufgeschlüsselt. Dies löst die wesentliche stochastische Schwäche des




Abbildung 4.13: Dreidimensionale Darstellung der SPV und zugehöriger Konturverlauf für ein asymmetrisch manipuliertes Versuchsdesign: Das modifizierte CCD ($k = 2$) beinhaltet drei APs zur Stützung des südwestlichen Quadranten.

VDG auf: Fällt der Vektor des anvisierten Prognosepunkts zufällig mit der Richtung der geringsten Varianz zusammen, entspricht der EVG-Verlauf exakt dem unteren Minimum-Band des VDG. Liegt der Prognosepunkt jedoch geometrisch ungünstig im nicht-gestützten Raum, schnell die Varianz in Richtung des Maximum-Bandes empor. Der EVG eliminiert diese unzulässige Unschärfe der sphärischen Darstellung. Die Auswertung in Abbildung 4.14 demonstriert eindrucksvoll, wie die strategisch exakt auf der Extrapolationsachse platzierten APs ein markantes lokales Plateau im radialen Varianzanstieg erzwingen. Diese topologische Stützung reduziert die Vorhersageunsicherheit auf dem spezifischen Extrapolationspfad gegenüber dem starren Standard-Design substantiell.




Abbildung 4.14: Der klassische VDG verschleiert den lokalen Design-Nutzen des um APs modifizierten CCD durch radiale Mittelung. Der EVG belegt hingegen die signifikante SPV-Reduktion zielgerichtet entlang des Extrapolationsvektors zum Prognosepunkt.

Diese richtungsabhängige Varianzdämpfung erbringt den formalen Nachweis, dass eine gezielte Abkehr von strikter geometrischer Symmetrie im Kontext von Lebensdauerversuchen hochgradig effizient ist. Das durch topologische Ausdünnung gewonnene Gestaltungsbudget wird folglich nicht als passive Kosteneinsparung verbucht, sondern proaktiv zur Sicherstellung einer belastbaren Prognosegüte im Feldbereich reinvestiert.

4.4 Kostenstruktur der Lebensdauererprobung

Während die vorherigen Abschnitte das geometrische Gestaltungsbudget und dessen topologische Reinvestition zur Prädiktionsabsicherung behandelten, rückt nun die ökonomische Dimension in den Fokus. Die bisherige Evaluierung konzentrierte sich primär auf die *statistische Effektivität* der Versuchsdesigns - also auf deren fundamentale methodische Fähigkeit, die wahren physikalischen Zusammenhänge unverfälscht (Bias, MSE) und mit der geforderten *power* als Nachweissicherheit zu identifizieren. Statistische Effektivität bildet jedoch lediglich die Grundvoraussetzung für die industrielle EoL-Versuchsplanung. Ein effektiver Versuchsplan wird in der Praxis erst dann zu einem *effizienten* Design, wenn er die statistischen Zielvorgaben unter minimalem Ressourceneinsatz erreicht. Effizienz definiert sich folglich direkt über das Verhältnis zwischen der algorithmischen Leistungsfähigkeit (statistische KPIs) und den real verursachten experimentellen Aufwänden.

Um die ganzheitliche Leistungsfähigkeit adaptiver Versuchsplan-Modifikationen bewerten zu können, bedarf es einer komplementären ökonomischen Metrik. Zielsetzung des folgenden Kostenmodells ist dabei keine betriebswirtschaftlich absolute Prognose realer Unternehmensbilanzen, sondern die Etablierung einer quantitativen Vergleichsgröße auf Basis von Currency Units (normierte Geldeinheiten) (CU). Nur durch diese Überführung der Ressourcen in eine einheitliche, abstrakte Währungsmetrik lässt sich das übergeordnete Optimierungsproblem objektiv beantworten: Das quantitative Verhältnis aus Prädiktionsgüte und den dafür aufzuwendenden Prüfstandsressourcen zu maximieren.

Zu diesem Zweck wird nachfolgend die Struktur eines Modells eingeführt, welches die monetären Aufwände der experimentellen Durchführung im DoE systematisch erfasst und bilanziert. Die methodische Grundlage hierfür bildet das in Arndt und Dazer [98] publizierte Kostenmodell für multivariate Lebensdauertests. An dieser Stelle werden zunächst die zugrundeliegenden Kostenpositionen, deren funktionale Zuordnung sowie die strukturellen Interdependenzen des Modells grundlegend definiert. Die detaillierte quantitative Auswertung dieses Modells erfolgt im Rahmen der Gesamtbewertung in Abschnitt 4.5, sobald die stochastischen Eigenschaften realer Lebensdauerdaten in die Betrachtung integriert sind. Auch bei einer vorab fest definierten Anzahl an Versuchspunkten (N) und vorgegebenen Replikationen hängen die realen Versuchskosten maßgeblich von den individuellen Laufzeiten t_i der




Abbildung 4.15: Struktur des Kostenmodells zur Berechnung der Gesamtkosten C_Σ als Funktion der Versuchsplan-Implementierung, identifizierter Kostenfaktoren sowie zufallsbehafteter Versuchslaufzeiten t_i (in Anlehnung an [87]).

Prüflinge ab. Dies gilt insbesondere für EoL-Untersuchungen, bei denen Prüflinge oftmals sequenziell und bis zum Ausfallereignis unter stark variierenden Lastniveaus getestet werden. Um diese Aufwände generisch und unabhängig vom spezifischen Prüflingstyp bilanzieren zu können, werden die Gesamtkosten C_{Σ} in drei wesentliche Hauptdomänen unterteilt [98]:

1. **Umgebungskosten C_A (*Ambient Conditions*):** Diese statische Domäne bündelt die standort- und laborbezogenen Bereitstellungskosten C_L , wie beispielsweise allgemeine Aufwände für die Laborinfrastruktur, den Flächenbedarf oder die grundlegende Raumklimatisierung.
2. **Prüfstandskosten C_T (*Test Equipment*):** Hierunter fallen die anlagenspezifischen Ausrüstungs- und Investitionskosten. Diese setzen sich primär aus der grundlegenden Prüfstandshardware C_B sowie der geforderten Güte der eingesetzten Messtechnik C_I und Steuerungstechnik C_C zusammen. Ein strategisches Absenken der geforderten Ansteuergenauigkeit (und die damit verbundene Inkaufnahme von Orthogonalitätsabweichungen, vgl. in Abschnitt 4.2.3 Scatter-Effekte in Fall III) würde sich hier direkt in signifikant reduzierten Hardware- und Investitionskosten niederschlagen.
3. **Laufende Durchführungskosten C_S (*Size of Testing*):** Diese hochgradig variable Kostengruppe skaliert direkt mit der zeitlichen Dauer und dem physikalischen Umfang der Versuchsreihe. Sie umfasst die kontinuierlichen Personalkosten C_O , die Aufwände für Hilfs- und Betriebsstoffe C_H , den lastabhängigen Energieverbrauch C_E sowie die belastungs- und zeitproportionalen Instandhaltungskosten C_M .

Das zugrundeliegende strukturelle Wirknetz dieser Kostenpositionen ist in Abbildung 4.15 visualisiert. Es verdeutlicht die Interdependenzen der Domänen und zeigt auf, wie die einzelnen Faktoren methodisch aggregiert werden, um die designspezifischen Gesamtkosten C_{Σ} abzuleiten. Um die theoretischen Relationen dieser Kostendomänen in einen ingenieurspraktischen Kontext zu setzen, können für typische EoL-Prüfszenarien im Maschinen- und Automobilbau charakteristische Annahmen getroffen werden. Um die theoretischen Relationen dieser Kostendomänen für die Parametrierung der Monte-Carlo-Simulation zugänglich zu machen, müssen charakteristische Skalierungsfaktoren abgeleitet werden. Die Investitionskosten für derartige

Anlagen (C_T) belaufen sich branchenüblich auf sechsstellige Beträge, welche kalkulatorisch über eine Nutzungsdauer von sechs bis acht Jahren abgeschrieben werden [99]. Die explizite Nennung dieses Abschreibungshorizonts ist methodisch essenziell, da hieraus das fundamentale Skalierungsverhalten von Lebensdauererprobungstests resultiert: Durch die inhärente Auslegung auf Dauerlauf (oftmals im 24/7-Betrieb) relativiert sich der Anteil der reinen Anlagenabschreibung pro Betriebsstunde auf einen marginalen Bruchteil der Investitionssumme. Die tatsächliche Kostendynamik, welche die Effizienz unterschiedlicher Design-Topologien determiniert, wird stattdessen von den operativen Hebeln bestimmt.

Erstens skaliert der Energieverbrauch C_E proportional mit den Laufzeiten t_i . Insbesondere bei kombinierten Umwelt- und Lastkollektiven übersteigen die stündlichen Energiekosten die Anlagenabschreibung signifikant. Zweitens induzieren die Personalkosten C_O eine starke Asymmetrie: Während automatisierte Dauerläufe personell lediglich beim initialen Rüsten ins Gewicht fallen, treiben kurze, interaktionsintensive Versuchsläufe (z. B. an ZPs) den effektiven Stundensatz in die Höhe. Neben diesen primären Treibern vervollständigen Instandhaltungskosten (C_M) und Betriebsstoffe (C_H) das Modell [100, 101, 102].

Tabelle 4.7 aggregiert diese Größenordnungen. Sie dient an dieser Stelle nicht als betriebswirtschaftlicher Kostenkatalog, sondern definiert die unabdingbare Skalierungsmatrix für die stochastische Synthese: Nur durch die indikative Wichtung dieser Faktoren lässt sich evaluieren, wie stark stochastisch streuende Ausfallzeiten die ökonomische Effizienz des iterativen Versuchsplans im späteren AFT-Raum belasten.

Während die fixen Bereitstellungsblöcke für Labor (C_A) und Basis-Prüfstand (C_T) weitestgehend statisch und additiv in die Gesamtbilanz einfließen, verhalten sich die laufenden Durchführungskosten C_S extrem dynamisch. Da Lebensdauererprobungsversuche stochastischen Ausfallprozessen unterliegen und die asymmetrische Verteilung unterschiedlicher Belastungsstufen (Faktorkombinationen im DoE) zu stark variierenden Testdauern führt, determinieren erst die individuellen, zufallsbehafteten Versuchslaufzeiten t_i den tatsächlichen Ressourcenverbrauch (Personal, Energie, Material, Anlagenverschleiß).

Im Rahmen der späteren Modellierung müssen diese dynamischen Kostentreiber folglich in einem iterativen Prozess evaluiert werden. Die Einbettung in eine Monte-Carlo-Simulation erlaubt es, die Verteilung der stochastischen Ausfallzeiten zu ag-

Tabelle 4.7: Indikative Relationen der Kostenpositionen in Bezug auf die Gesamtinvestition C_T für beispielhafte, typische Komponentenprüfstände im Maschinenbau.

Kostendomäne	Kostenposition	Pos.	Relation zu C_T
Prüfstandskosten	Grundlegende Hardware (AfA) ^a	C_B	$\approx 12,5\% - 16,7\% \text{ p. a.}$
	Mess- und Steuerungstechnik	$C_{I,C}$	<i>in C_T inkludiert</i>
Umgebungskosten	Laborinfrastruktur ^b	C_L	$\approx 1,0\% - 3,0\% \text{ p. a.}$
Durchführung	Instandhaltung & Kalibrierung ^c	C_M	$\approx 3,0\% - 5,0\% \text{ p. a.}$
Durchführung	Maschinenstundensatz (rein) ^b	–	$\approx 0,01\% - 0,02\% \text{ p. Bh}$
Durchführung	Lastabhängige Energie ^b	C_E	$\approx 0,005\% - 0,02\% \text{ p. Bh}$
Durchführung	Hilfs- und Betriebsstoffe	C_H	$\ll 0,005\%$
Durchführung	Rüst- und Bedienpersonal	C_O	$\approx 0,015\% - 0,025\% \text{ p. Ah}$

^a bei 6-8 Jahren Nutzungsdauer [99]; ^b in Anlehnung an VDI 3258 [102]; ^c gem. VDI 2884 [100].

Anmerkung: Bh = Betriebsstunde (Anlage aktiv), Ah = Arbeitsstunde (Personal aktiv).

gregieren, um einen belastbaren Erwartungswert für die Durchführungskosten $\bar{C}_S$ zu ermitteln. In der Summe stellt dieses Kostenmodell ein unabdingbares Instrument dar, um topologischen und statistischen Modifikationen eines Versuchsplans ein direktes ökonomisches Preisschild zuzuordnen.

4.5 Übertragung auf multivariate Lebensdauermodelle

Die bisherigen Untersuchungen isolierten die fundamentale geometrische Robustheit asymmetrischer Versuchspläne bewusst unter den idealisierten Prämissen des Gauss-Markow-Theorems (additive Normalverteilung, OLS). Diese methodische Abstraktion ist erforderlich: Hätte die Analyse von Beginn an auf rechtsschiefen, zensierten Lebensdauerverteilungen (Weibull) basiert, wären topologisch induzierte Varianzinflationen untrennbar mit dem verteilungsspezifischen *Small-Sample-Bias* der MLE vermenget worden. Erst dieser formale Nachweis der geometrischen Integrität und die Identifikation des topologischen Gestaltungsbudgets legitimieren nun den Transfer in die stochastische Realität der Zuverlässigkeitstechnik.

Der vorliegende Abschnitt vollzieht diesen Transfer auf Lebensdauermodelle. Die Methodik der Extrapolationsabsicherung wird hierbei in die komplexe Datenlage

der industriellen EoL-Versuchsplanung (streng positive, rechtsschiefe und potenziell durch Prüfzeitverkürzungen zensierte Ausfallzeiten [2]) überführt. Dazu wird der in Abbildung 4.1 etablierte Gesamt-Simulationspfad vollumfänglich aktiviert: Die iterative Maximum-Likelihood-Schätzung der Ausfalldaten wird direkt mit dem dynamischen Kostenmodell aus Abschnitt 4.4 gekoppelt.

Um die geometrischen Eigenschaften der unter dem Begriff EmALT hier neue abgeleiteten Designs weiterhin kausal von den verteilungsspezifischen Eigenheiten der Weibull-Schätzung zu trennen, erfolgt die Synthese in einem methodisch zweistufigen Prozess: Zunächst wird die reine Prädiktionsvarianz des asymmetrischen Designs isoliert unter idealisierten OLS-Bedingungen evaluiert (Abschnitt 4.5.1), bevor in Abschnitt 4.5.2 die finale Validierung der Vorhersagegüte und Kosteneffizienz im log-linearen AFT-Raum stattfindet.

Um die ökonomische und statistische Effizienz dieser adaptiven Extrapolationsabsicherung abschließend zu quantifizieren, werden drei spezifische Design-Konfigurationen über das etablierte Kostenmodell gegeneinander evaluiert. Anstatt eines starren Ressourcenaufwands repräsentieren diese Konfigurationen gezielt unterschiedliche Stufen der Budgetauslastung:

1. **Basis CCD (Referenzbudget):** Der klassische rotationssymmetrische Versuchsplan ($N = 13$), bestehend aus dem faktoriellen Kern ($n_F = 4$), vier axialen SPs ($n_{SP} = 4$, mit $\alpha_D = \sqrt{2}$) sowie fünf redundanten ZPs ($n_{ZP} = 5$) [22].
2. **Passiv ausgedünntes Design (CCD_{-AP}, Budgeteinsparung):** Die aus Abschnitt 4.3.1 als extrapolations-ineffizient identifizierten Stützstellen entfallen ersatzlos ($N = 10$). Dies betrifft zu den Anschauungszwecken dieser Arbeit einen redundanten Zentralpunkt sowie die beiden für die Extrapolation unkritischen Sternpunkte im Bereich der höchsten Belastung ($(0; \alpha_D)$ und $(\alpha_D; 0)$). Dieses Design senkt die Prüfkosten künstlich ab und dient als methodische Baseline, um den isolierten Trennschärfe-Verlust dieser Fehlstellen im Lebensdauer-Raum zu messen.
3. **EmALT (Budget-Reinvestition):** Das erarbeitete geometrische Budget aus den drei freigewordenen Stützstellen erfährt eine gezielte Reinvestition ($N = 13$). Gemäß der in Abschnitt 4.3.2 beschriebenen *Exposure-Area*-Methode werden diese drei Versuchspunkte als asymmetrische Ankerpunkte (APs) in den süd-westlichen Quadranten versetzt, in welchem sich der reale Feldbetriebspunkt

als fiktiver Prognosepunkt $(-0,7; -1,9)$ befindet (vgl. Abbildung 4.12). Unter Berücksichtigung von Prüfstandsrestriktionen an den Belastungsgrenzen platziert dieses Layout die Anker beispielhaft bei $(-0,85; -2,60)$, $(-1,10; -2,35)$ und $(-0,85; -2,35)$, um die Prädiktionsvarianz exakt auf dem Extrapolationspfad zu minimieren.

Entsprechend der Vorgehensweise in Abschnitt 4.2.3 evaluiert die nachfolgende MCS die drei Design-Varianten auf Basis von $n_{MC} = 1 \cdot 10^4$ Iterationen.

Signal-Rausch-Kalibrierung unter dem Sparsity of Effects Principle

Um die in der methodischen Basisuntersuchung (Abschnitt 4.2) etablierte Vergleichbarkeit der Trennschärfe-Verluste aufrechtzuerhalten, wird das Referenz-Modell (*Ground-Truth*) für die spätere Weibull-Simulation analog zu Abschnitt 4.2.3 exakt auf denselben kritischen Arbeitspunkt $SNR = 1,20$ kalibriert. Da absolute Regressionskoeffizienten in β zwischen dem additiven Normalverteilungsraum und Lebensdauermodellen jedoch nicht unmittelbar übertragbar (nicht translationsinvariant) sind, erfordert dieser finale Transfer die explizite Berücksichtigung verteilungsspezifischer Skalierungsgesetze.

Beim Übergang zum AFT-Modell ändert sich die Interpretation des Modells grundlegend: Aufgrund der strengen Positivität und der ausgeprägten Wertebereichsdynamik realer Ausfallzeiten modelliert die Regression nicht die Lebensdauer t selbst, sondern deren natürlichen Logarithmus $\ln(t)$ als Zielgröße. Unterliegt die physikalische Lebensdauer t einer Weibull-Verteilung, folgt ihr logarithmierter Wert $\ln(t)$ axiomatisch einer *SEV* - in der Literatur äquivalent als Gumbel-Verteilung für Minima bezeichnet [2]. Das AFT-Modell formuliert sich in diesem logarithmischen Raum als lineares Regressionsmodell:

$$\ln(t) = x'\beta + \sigma_{SEV} \cdot \epsilon \quad \text{mit} \quad \epsilon \sim SEV(0,1) \quad (4.6)$$

Die für die *power* entscheidende Metrik zur Streuung (σ_{SEV}) stellt im Weibull-Fall jedoch keine unabhängig wählbare Variable dar. Sie entspricht exakt dem Skalenpara-

meter der SEV , welcher über das Inverse des Weibull-Formparameters b intrinsisch an die werkstoffphysikalische Ausfallcharakteristik gekoppelt ist [2]:

$$\sigma_{SEV} = \frac{1}{b} \quad (4.7)$$

Unter der werkstoffmechanisch plausiblen Annahme eines progressiven Verschleiß- oder Ermüdungsverhaltens wird dieser Formparameter für die simulativen Untersuchungen im Rahmen dieser Arbeit repräsentativ auf $b = 3,0$ fixiert [12]. Diese fallspezifische Definition beschränkt den Skalenparameter für die nachfolgende Auswertung deterministisch auf $\sigma_{SEV} = 1/3 \approx 0,33$.

Für die methodische Konsistenz bleibt zu betonen, dass σ_{SEV} den rein mathematischen Skalenparameter und nicht die tatsächliche Standardabweichung der rechtschiefen SEV abbildet (welche über die Eulersche Konstante skaliert und $\sigma_{total, SEV} \approx 1,28 \cdot \sigma_{SEV}$ beträgt). In der statistischen Zuverlässigkeitstechnik eignet es sich jedoch, das SNR invariant auf den Skalenparameter zu beziehen, da dieser als direkter Faktor in die Fisher-Informationsmatrix eingeht und somit die Asymptotik der Likelihood-basierten Schätzung unmittelbar bestimmt [2].

Während die methodische Basisuntersuchung das Streuungsniveau künstlich auf $\sigma = 5,0$ skalierte, fixiert der AFT-Ansatz das Systemrauschen folglich intrinsisch. Um den kritischen Arbeitspunkt von $SNR = 1,20$ in den Weibull-Raum zu überführen, kalibrieren sich die vorzugebenden Modellkoeffizienten in β exakt auf diese SEV -Streuung: $\beta = SNR \cdot \sigma_{SEV}$. Für die quadratischen Modellkomponenten resultiert daraus eine exakte Ziel-Effektstärke von $|\beta_{11}| = |\beta_{22}| = |\beta_{12}| = 1,20 \cdot 0,33 \approx 0,40$.

Um eine belastbare und deterministische Referenz (*Ground-Truth*) für die MCS zu erschaffen, müssen die absoluten Vorzeichen dieser Effekte physikalisch plausibel motiviert werden. Ein Anstieg des Stressniveaus (positive Faktorstufen) induziert im Erwartungsfall eine Beschleunigung der Schädigungsmechanismen und damit eine Reduktion der Lebensdauer. Die Modellstruktur bildet dies durch strikt *negative* Vorzeichen der Haupteffekte ab. Die relativen Effektstärken staffeln sich hierbei hierarchisch gemäß dem empirisch belegten *Sparsity of Effects Principle* [22]. Daraus leitet sich die finale Parametrisierung für das stochastische Modell ab:

- **Haupteffekte:** Entsprechend dem Sparsity-Prinzip fungieren sie als dominante, lebensdauerermindernde Stressoren und werden mit einer betragsmäßig doppelt

so hohen Effektamplitude parametrisiert: $\beta_1 = \beta_2 = -0,80$. Das korrespondierende SNR von 2,40 verleiht diesen Termen eine ausgeprägte statistische Detektionssicherheit. Im Kontext des multiplikativen AFT-Ansatzes impliziert dies eine drastische Verkürzung der zu erwartenden Lebensdauer um den konstanten Beschleunigungsfaktor $r = \exp(0,80) \approx 2,22$ pro normierter Stressestufe.

- **Interaktionen und quadratische Effekte:** Diese Terme determinieren die Krümmung der Antwortfläche (vgl. Abbildung 4.16) und werden betragsmäßig auf den sensitiven Schwellenwert von $|\beta_{ij}| = 0,40$ kalibriert. Um einen physikalisch plausiblen Verlauf der Lebensdauer-Antwortfläche zu generieren, werden die quadratischen Terme *negativ* definiert ($\beta_{11} = \beta_{22} = -0,40$). Dies moduliert eine nach unten geöffnete Krümmung im logarithmischen Raum, welche eine progressive Schadensbeschleunigung bei extremen Überlasten abbildet. Der Interaktionsterm wird hingegen *positiv* gewählt ($\beta_{12} = +0,40$), um im kombinierten Hochlastbereich (beide Faktoren maximal positiv) eine zu extreme, unrealistische Lebensdauer-Degradation durch die rein additiven negativen Haupteffekte leicht abzufedern (antagonistische Kompensation).
- **Intercept:** Die Regressionskonstante β_0 dimensioniert sich abschließend derart, dass die charakteristische Basislebensdauer T im Koordinatenursprung (Nennbetrieb) ein anwendungsnahes Referenzniveau von ca. 100.000 Lastwechseln abbildet ($\ln(10^5) \approx 11,51$).

Tabelle 4.8: Kalibrierte Startwerte und statistische Eigenschaften des log-linearen Weibull-Basismodells (AFT-Ansatz)

Koeffizient	β_0	β_1, β_2	β_{11}, β_{22}	β_{12}	σ_{SEV}
Wahrer Wert	11,51	-0,80	-0,40	0,40	0,33
SNR	–	2,40	1,20	1,20	–

4.5.1 Generische Auswirkungen asymmetrischer Versuchsplanung

Bevor das in Abschnitt 4.5 kalibrierte log-lineare Lebensdauermodell simuliert wird, bedarf die neuartige EmALT-Topologie einer isolierten geometrischen Zwischenvalidierung. Um den strukturellen Einfluss der asymmetrischen Ankerpunkt-Reallokation




Abbildung 4.16: Antwortfläche der charakteristischen Systemlebensdauer T in Abhängigkeit der Faktoren x_1 und x_2 . Die Projektion verdeutlicht die große Extrapolationsdistanz zwischen dem DoE-Zentrum und den geforderten Feld-Bedingungen.

Tabelle 4.9: Matrixeigenschaften und Effizienzen. Der VIF wird für alle Terme dargestellt ($\hat{\beta}_0$ entfällt).

Szenario	A_2	Effizienzen [%]					VIF				
		A_{eff}	D_{eff}	G_{eff}	I_{eff}	V_{eff}	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	0,017	46,7	56,9	21,0	95,5	134,2	1,00	1,00	1,00	1,02	1,02
CCD-AP	0,373	39,2	50,4	18,5	78,3	140,3	1,27	1,27	1,00	1,31	1,31
EmALT	2,596	39,1	68,9	15,5	73,1	136,3	1,45	3,84	3,18	1,32	5,91

von den stochastischen Nichtlinearitäten der Weibull-MLE abzugrenzen, operiert die nachfolgende Auswertung zunächst nochmals unter den kontrollierten Bedingungen der additiven Normalverteilungs-Baseline ($\text{SNR} = 1,20$, vgl. Tabelle 4.5). Dieser methodische Zwischenschritt stellt die direkte quantitative Vergleichbarkeit mit den in Abschnitt 4.2.3 evaluierten Praxisstörungen her: Jeder messbare Effekt in Schätzvarianz und Trennschärfe ist somit unmittelbar auf die Geometrie der Matrix $\mathbf{X}$ zurückzuführen.

Die algebraische Auswertung entlang Tabelle 4.9 quantifiziert das zugrundeliegende topologische Spannungsfeld: Die asymmetrische Reallokation der Stützstellen erzwingt einen Bruch der Rotationssymmetrie, was sich im Anstieg von A_2 sowie der moderaten Erhöhungen der maximalen VIF-Werte niederschlägt. Im entscheidenden Vergleich zum passiv ausgedünnten Design CCD_{AP} belegt die *I-Effizienz* jedoch den signifikanten funktionalen Mehrwert der EmALT-Strategie: Während die ersatzlose Streichung von Stützstellen zu einer starken Reduktion der Prädiktionsgüte führt, fängt die Reinvestition der Punkte in Form gerichteter APs die integrierte Vorhersagevarianz wirksam ab. Hierbei wird deutlich, dass das klassische Paradigma der vollständigen Dekorrelation einzelner Koeffizienten in der Extrapolationspraxis angepasst werden muss: Eine kontrollierte Multikollinearität ist der notwendige algebraische Preis, um die Prädiktionsvarianz entlang des maßgeblichen Lastpfads gezielt zu minimieren.

Die stochastische Auswertung validiert diese topologischen Indikatoren probabilistisch. Die fundamentale Erwartungstreue des OLS-Schätzers bleibt unter asymmetrischen Bedingungen unbeschadet gewahrt; der systematische Schätzfehler (*Bias*) verharret über alle Design-Varianten hinweg auf einem vernachlässigbaren Niveau marginal nahe Null: vgl. Abbildung 4.17.

Ergänzend zur Verteilungsprüfung der Teststatistiken bestätigt die Auswertung der standardisierten Residuen r_i , dass die asymmetrische Stützstellenallokation im EmALT-Design keine systematischen Strukturbrüche oder Heteroskedastizitäten induziert. Der geometrische Eingriff manifestiert sich ausschließlich in der Schätzvarianz (MSE, Tabelle 4.10). Der direkte Vergleich offenbart die Überlegenheit gegenüber der passiven Ausdünnung: Während CCD_{AP} über alle Koeffizienten hinweg große Varianzsteigerungen verzeichnet, fangen die reinvestierten APs diesen Verlust spürbar ab. Ein bemerkenswertes Resultat zeigt sich hierbei für die Krümmung $\hat{\beta}_{22}$: Der




Abbildung 4.17: Absolute Schätzwerte der Modellkoeffizienten für die asymmetrischen Designvarianten am Arbeitspunkt $\text{SNR} = 1,20$. Der Bias bleibt marginal; die Erwartungstreue des OLS-Schätzers ist gewahrt.

MSE sinkt im EmALT-Design auf einen Bestwert von 2,05 ab und unterbietet damit sogar die Schätzvarianz des idealen Basis-CCD (3,56) deutlich. Dieser Gewinn an Präzision ist eine direkte mathematische Konsequenz der Hebelarmgesetze: Da die APs im südwestlichen Quadranten mit stark negativen x_2 -Koordinaten platziert sind (bis zu $x_2 = -2,60$ im Vergleich zu $\alpha_D = \sqrt{2} \approx 1,41$ im Standard-Design), stützen sie die quadratische Modellkrümmung entlang dieser Achse stärker ab. Die induzierte Asymmetrie fungiert somit als zielgerichtetes mathematisches Werkzeug zur selektiven Versteifung der Informationsmatrix.

Tabelle 4.10: Schätzvarianz (MSE) der einzelnen Koeffizienten bei OLS-Baseline ($\text{SNR} = 1,2$).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	5,00	3,10	3,15	6,21	3,54	3,56
CCD-AP	6,30	5,61	5,42	6,36	7,25	7,57
EmALT	5,33	4,89	5,32	4,95	6,97	2,05

Diese selektive Varianzstabilisierung überträgt sich unmittelbar auf die statistische Trennschärfe (vgl. Abbildung 4.18). Während das passiv ausgedünnte Design einen

drastischen Einbruch der *power* bei den quadratischen Termen erleidet (beispielsweise Verlust von über 12 Prozentpunkten bei $power_{\beta_{11}}$), stellt das EmALT-Design das Detektionsniveau nahezu vollständig wieder her und schließt für $power_{\beta_{22}}$ dank des vergrößerten Hebelarms exakt zur ungestörten Basis auf.




Abbildung 4.18: Vergleichende Analyse der absoluten statistischen Trennschärfe. Die asymmetrische Extrapolationsabsicherung (EmALT) stellt die Detektionsrate im Vergleich zur reinen Ausdünnung nahezu vollständig wieder her.

Jegliche Variation der Modellgüte im additiven Normalverteilungsraum lässt sich somit deterministisch auf den variablen VIF der modifizierten Design-Topologie zurückführen. Alle im nachfolgenden Transfer auf Lebensdauermodelle auftretenden Effekte ordnen sich damit unmissverständlich der stochastischen Natur der Weibull-Verteilung und der iterativen MLE-Approximation zu.

4.5.2 Effizientes L-DoE und der Economic Extrapolation Power Index

Mit dem Übergang zur MLE rechtsschiefer Weibull-Ausfallzeiten $t \sim \mathcal{W}(T, b)$ vollzieht die Versuchsplanung den Schritt in die physikalisch-ökonomische Realität. Wie in Abschnitt 4.4 hergeleitet, fungiert in der Lebensdauererprobung die Zielgröße selbst - die Ausfallzeit t_i - als primärer Kostentreiber. Die Designmatrix $\mathbf{X}$ und die resultierenden Versuchskosten C_{Σ} sind somit stochastisch hart gekoppelt. Dies zwingt die Auslegung des EmALT-Designs in einen fundamentalen Zielkonflikt: Die Verlagerung von Extrapolations-APs in Richtung geringerer Stressniveaus stützt zwar die Prädik-

tionsvarianz im Feld, erzwingt jedoch exponentiell längere Testlaufzeiten, wodurch der Kostenerwartungswert $E(C_\Sigma)$ unweigerlich ansteigt.

Um diesen Trade-off zwischen statistischer Prädiktionssicherheit und realem Ressourcenverbrauch als objektives Optimierungsproblem zu formulieren, bedarf es einer aggregierenden Effizienz-Metrik. Da das Ziel beschleunigter Lebensdauerversuche nicht die pauschale Modellabsicherung im gesamten Raum (hierfür böte sich beispielsweise das geometrische Mittel oder das Produkt aller *power*-Werte an), sondern die belastbare Extrapolation in einen spezifischen Betriebspunkt ist, fokussiert diese Metrik auf die lokale Prognosegüte. Der relevante Informationsgehalt korrespondiert mit dem Kehrwert der prädiktiven Varianz am fernen Prognosepunkt ($1/\nu(\mathbf{x}_0)$). Unter Einbezug der koeffizientenspezifischen Detektionssicherheit wird dieser Ansatz zum EPI für einen beliebigen Regressionskoeffizienten $\hat{\beta}_i$ synthetisiert:

$$\eta_{\text{eco}} = \frac{\text{power}(\hat{\beta}_i)}{\nu(\mathbf{x}_0) \cdot E(C_\Sigma)} \times 10^3 \quad (4.8)$$

Der Skalierungsfaktor 10^3 überführt die Kennwerte in einen handhabbaren numerischen Bereich. Der EPI formuliert somit ein skalares Optimierungskriterium: Er skaliert proportional zur statistischen *power*, während die Extrapolationsvarianz und der monetäre Ressourceneinsatz das Ergebnis als Straf-Faktoren im Nenner mindern.

Um den Nachweis für die Notwendigkeit dieses Trade-offs zu erbringen, erweitert das MCS-Setup die Evaluierung um ein viertes Referenz-Design: das Feld-CCD. Diese Konfiguration überträgt die orthogonale Designmatrix unskaliert auf die Koordinaten des fernen Feldebereichs und fungiert methodisch als analytischer Grenzwert: varianzarme Interpolation unter Feldbedingungen mit Inkaufnahme der maximalen Prüfzeit im *Betriebs-Parameterraum*.

Die probabilistische Auswertung belegt beim Übergang zur MLE rechtsschiefer SEV-Residuen theoriekonform eine systematische Verzerrung infolge des geringen Stichprobenumfangs (*Small-Sample Bias*) [2]. Da auf numerische Bias-Korrekturen an dieser Stelle bewusst verzichtet wird, um die reine topologische Hebelwirkung auf den industriellen Standard-Schätzer offenzulegen, induziert der limitierte Prüfumfang von $N = 13$ eine merkliche Parameterverschiebung (Tabelle B4).

Die detaillierte Analyse dieses systematischen Schätzfehlers erfordert eine fundierte Einordnung: Erstens verharret die Schätzung der Regressionskonstante $\hat{\beta}_0$ über alle

Tabelle 4.11: Relativer systematischer Schätzfehler (Bias) in Prozent bei GLLW-Schätzung (Weibull-Modell).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	+0,15 %	−0,08 %	+0,10 %	−0,24 %	+13,73 %	+12,79 %
CCD _{−AP}	+0,24 %	+3,72 %	+3,39 %	+6,82 %	+23,17 %	+22,10 %
EmALT	−0,00 %	+19,55 %	−39,14 %	−47,84 %	+46,51 %	−53,26 %

Szenarien hinweg auf einem Niveau exzellenter Erwartungstreue. Die absolute Lage der Basislebensdauer im Versuchsraum bleibt somit perfekt zentriert, womit der grundlegende Ankerpunkt des Modells fehlerfrei determiniert ist. Zweitens entlädt sich die in Abschnitt 4.5.1 identifizierte Multikollinearität des EmALT-Designs im Zusammenspiel mit der iterativen MLE in stärkeren Einzelabweichungen der Terme höherer Ordnung (bis zu −53,26 % bei $\hat{\beta}_{22}$). Diese ausgeprägten Verzerrungen isolierter Parameter untergraben die Methodik jedoch nicht, sondern sind der mathematische Preis der topologischen Asymmetrie: Die Methodik opfert bewusst die Korrelationsfreiheit und Erwartungstreue einzelner Parameter, um starke Kovarianzen aufzubauen. Dementsprechend werden auch unter den Maßnahmen zur Designoptimierung im EmALT-Ansatz die Terme höherer Ordnung nicht exakt rekonstruiert, sondern lediglich in ihrer gemeinsamen Wirkung auf die Prädiktionsvarianz am fernen Prognosepunkt stabilisiert und weiter mit korrektem Vorzeichen in ihrer physikalischen Wirkung auf die Lebensdauer-Antwortfläche abgebildet.

Ein ergänzender methodischer Vorteil des EmALT-Designs offenbart sich bei der Identifikation des Weibull-Formparameters $\hat{b}$ (wahrer Wert $b = 3,00$). Da die Lage ($\hat{\beta}_0$) präzise fixiert ist, würde eine Fehlschätzung des Formparameters die resultierende Ausfallwahrscheinlichkeit massiv verfälschen. Klassische, eng konzentrierte Hochlast-Versuchspläne überschätzen diesen Parameter bei kleinen Stichproben ($\hat{b} = 4,97$ im Basis-CCD bzw. $\hat{b} = 5,91$ im CCD_{−AP}), was zu einer Unterschätzung der realen Bauteilstreuung führt. Das EmALT-Design stützt durch die weit in den Niedrigstressbereich ausgreifenden Ankerpunkte den stochastischen Hebelarm der Likelihood-Funktion und rekonstruiert die auf den simulierten Schädigungsmechanismus zurückzuführende Ausfallstreuung mit $\hat{b} = 3,37$ deutlich belastbarer.

Hinsichtlich der statistischen Trennschärfe (*power*) stabilisiert die Reallokation der Stützstellen den ungestörten quadratischen Haupteffekt $\hat{\beta}_{11}$ mit *power* = 99,01 % auf




Abbildung 4.19: Absolute Schätzwerte der MLE-Koeffizienten im Weibull-Modell ($\text{SNR} = 1,20$). Der Schätzwert der Basislebensdauer $\hat{\beta}_0$ bleibt exakt; die Terme höherer Ordnung spiegeln die durch die Multikollinearität induzierte Varianzumverteilung wider.

einem Niveau, welches das Basis-CCD (98,33 %) sogar leicht übertrifft. Zwar erfährt der quadratische Term der modifizierten Achse ($\hat{\beta}_{22}$) infolge der Asymmetrie einen Rückgang auf 75,04 %, verbleibt damit jedoch im Bereich gesunder Trennschärfe-Werte. Der Interaktionsterm $\hat{\beta}_{12}$ unterschreitet mit 64,53 % zwar diese Grenze. Die reduzierte Trennschärfe dieses Terms stellt jedoch den Kompromiss der EmALT-Topologie dar, welcher im Kontext der Reduktion der Prädiktionsvarianz $\nu(\mathbf{x}_0)$ im Extrapolationsbereich tolerierbar ist. Die finale Entscheidungsoberfläche der Versuchsplanauswahl manifestiert sich in der ökonomischen Synthese (Tabelle 4.12 sowie Abbildung 4.21). Hierbei verdichtet sich die Gegenüberstellung von statistischer Effektivität und ökonomischer Effizienz objektiv: Der linke Teilplot in Abbildung 4.21 veranschaulicht diese Kopplung: Das orthogonale Basis-CCD, sollte es so vollumfänglich im beschleunigten *Test-Parameterbereich* umgesetzt sein, charakterisiert sich durch minimale Prüfkosten zu 74,4 kCU, disqualifiziert sich jedoch durch eine stochastisch inakzeptable Prädiktionsunsicherheit im Feldbereich ($\nu(\mathbf{x}_0) = 30,02$, vgl. Tabelle 4.12). Das theoretische Feld-CCD markiert das konträre Extremum: Es generiert absolute Prädiktionsgüte ($\nu(\mathbf{x}_0) \approx 2,60$), provoziert durch unbeschleunigte Prüfzeiten jedoch prohibitive Erwartungskosten von $E(C_\Sigma) = 128,7$ kCU (Faktor 1,59 gegenüber dem EmALT-Design). Das EmALT-Design positioniert sich als das maßgebliche Optimum: Es realisiert na-




Abbildung 4.20: Vergleichende Analyse der MLE-*power*. Ergänzende Auswertung in Anhang B.3

hezu die ungestörte Prädiktionsschärfe des Feld-Designs ($\nu(\mathbf{x}_0) = 2,39$), unterbietet dessen Ressourcenaufwand durch die ALT-Beschleunigung jedoch massiv.

Dieser Befund belegt die Schwäche klassischer DoE-Metriken im Rahmen der Zuverlässigkeitstechnik (Abbildung 4.21, rechts). Die Gegenüberstellung der *D*-Optimalität und des EPI offenbart eine strikt inverse Kausalität: Ungeachtet der durch die Asymmetrie geometrisch kompromittierten *D*-Optimalität dominiert das EmALT-Design die tatsächliche wirtschaftliche Effizienz (EPI) signifikant. Ein rein durch algebraische Optimalitätskriterien motiviertes Festhalten an orthogonalen Versuchsplänen erweist sich in der Lebensdauererprobung somit als ineffizient: Die vordergründig eingesparten Prüfstandsressourcen induzieren unweigerlich eine massive Varianzinflation auf dem Extrapolationspfad. Welche konkreten physikalischen und sicherheitstechnischen Konsequenzen diese abstrakte Skalargröße der Prädiktionsvarianz ($\nu(\mathbf{x}_0)$) für die tatsächliche industrielle Auslegung besitzt, wird im nachfolgenden Schritt anhand der resultierenden Zuverlässigkeitsmodelle quantifiziert.

Konsequenzen für die Prognoseunsicherheit im Feldbetrieb

Die abstrakte Minimierung der Prädiktionsvarianz erfüllt in der ingenieurwissenschaftlichen Lebensdauererprobung keinen Selbstzweck, sondern dient der Zielsetzung: der Konstruktion belastbarer, eng tolerierter Zuverlässigkeitsprognosen im realen Feldeinsatz. Der ökonomische Mehrwert des EmALT-Designs - quantifiziert durch

Tabelle 4.12: Ganzheitliche ökonomisch-statistische Gegenüberstellung aller Modellkoeffizienten. Der Index η_{eco} quantifiziert die prädiktive Effizienz unter Berücksichtigung der Erwartungskosten $E(C_{\Sigma})$.

Szenario / Ressourcen	Metrik	β_1	β_2	β_{12}	β_{11}	β_{22}
Basis CCD	$\Delta power$	—	—	—	—	—
$E(C_{\Sigma})$: 54,2 kCU	rel. Bias	−0,1 %	+0,1 %	−0,2 %	+13,7 %	+12,8 %
SPV: 30,02	η_{eco}	0,62	0,62	0,50	0,60	0,61
CCD_{AP}	$\Delta power$	−0,1 %	−0,0 %	+6,1 %	−4,5 %	−4,7 %
$E(C_{\Sigma})$: 48,2 kCU	rel. Bias	+3,7 %	+3,4 %	+6,8 %	+23,2 %	+22,1 %
SPV: 30,12	η_{eco}	0,69	0,69	0,60	0,65	0,65
EmALT	$\Delta power$	−0,2 %	−5,7 %	−16,9 %	+0,7 %	−23,6 %
$E(C_{\Sigma})$: 81,0 kCU	rel. Bias	+19,5 %	−39,1 %	−47,8 %	+46,5 %	−53,3 %
SPV: 2,39	η_{eco}	5,15	4,86	3,33	5,11	3,87




Abbildung 4.21: Links: Exponentieller Zielkonflikt aus Prädiktionsvarianz und Erwartungskosten mit dem EmALT-Design als ökonomischem Optimum. Rechts: Inverse Kausalität zwischen klassischer D -Effizienz und EPI am Beispiel von β_{22} (vollständige Evaluation in Anhang B.3).

den EPI - verbleibt somit nicht als rein algebraische Kennzahl, sondern übersetzt sich in der industriellen Praxis direkt in eine höhere statistische Präzision dieser Vorhersagemodelle. Wie flankierende Untersuchungen zu CIs in optimierten Versuchsplänen belegen [98], korreliert die topologische Kontrolle der SPV unmittelbar mit präziseren Schätzungen der Vertrauensbereiche für die prognostizierten Ausfallwahrscheinlichkeiten.

Um diesen methodischen Transfer aufzuzeigen - also wie aus den ermittelten Regressionsparametern in $\hat{\theta}$ ein finales Zuverlässigkeitsmodell generiert wird - visualisiert Abbildung 4.22 den simulativen Verlauf der Überlebenswahrscheinlichkeit $R(t)$ exakt am anvisierten Extrapolationspunkt $(-0,7; -1,9)$ im Feldbereich. Dargestellt sind die Zuverlässigkeitsfunktionen auf Grundlage der Gleichungen (2.3), (2.47) und (2.60) sowie das korrespondierende 90 %-CIs. Letzteres resultiert aus der Invertierung der F_{ob} der jeweiligen MLE-Modellierung. Als objektive Referenz dient hierbei die Kurve des wahren Systemverhaltens (*Ground-Truth*) nach bekannter Vorgabe aus Tabelle 4.8 mit $b = 3,0$.

Während die mittleren $R(t)$ -Prognosen (Punktschätzer) beider Designs den wahren physikalischen Degradationsverlauf valide approximieren, manifestieren sich im direkten Vergleich der Konfidenzbänder prägnante topologische Divergenzen. Bedingt durch die große Extrapolationsdistanz unterliegen naturgemäß beide Versuchspläne einer substanziellen Prognosevarianz, sodass ihre absoluten Streuungsamplituden auf einem vergleichbaren Grundniveau verharren. Dennoch induziert das voll-orthogonale Basis-CCD die massivste Aufweitung der Vertrauensgrenzen und überschätzt R bei hohen Zuverlässigkeitswerten, vgl. Abbildung 4.22. Demgegenüber gelingt es dem EmALT-Design, diesen Unsicherheitsbereich durch die strategische Varianzdämpfung seiner Ankerpunkte sowohl kosteneffizienter zu erheben, als auch messbar zu verdichten. Die Ausprägung der simulierten Vertrauensgrenzen $[\hat{R}(t)_u, \hat{R}(t)_o]$ resultiert dabei aus dem multidimensionalen Regressionsmodell der Faktoren in Kombination mit der empirischen Extraktion der Schranken mittels der Kovarianzmatrix $\hat{V}$.

In der industriellen Praxis und vor dem Kontext eines Prüflingsumfangs von $N = 13$ sind selbst derartige moderate Reduktionen der Vertrauensbereiche von Bedeutung, da normative Sicherheitsnachweise und Wartungsintervalle zumeist auf der unteren Vertrauensgrenze einer definierten $R(t)$ basieren [1, 2].




Abbildung 4.22: Vergleich der prognostizierten Überlebenswahrscheinlichkeit $R(t)$ am Feldbetriebspunkt inklusive 90 %-CI. Aufgrund der Distanz weisen beide Designs hohe Prognoseunschärfen auf, das EmALT-Design (schwarz) reproduziert das wahre Zuverlässigkeitsmodell jedoch mit stellenweise geringerer Varianz als das Basis-CCD (grau).

4.6 Fazit

Das vorliegende Kapitel erbringt damit den theoretischen und simulativen Nachweis, dass klassische Prinzipien der statistischen Versuchsplanung zwar ein methodisch robustes Fundament für die Lebensdauererprobung bilden, in ihrer starren Ausprägung jedoch nicht nur ökonomisch ineffizient sind, sondern im Zuge ferner Feldprognosen auch eine grundlegende Extrapolationsproblematik aufspannen. Die vollzogene Synthese liefert dabei drei zentrale Erkenntnisse für die Zuverlässigkeitstechnik:

1. **Topologische Resilienz:** RSDs wie das CCD reagieren auf periphere Modifikationen und Ausdünnungen erstaunlich robust, solange die Identifikation der Haupteffekte gesichert ist. Dies legitimiert die Abkehr vom Dogma der strengen Orthogonalität und eröffnet ein wertvolles geometrisches Gestaltungsbudget.
2. **Extrapolationsabsicherung:** Die SPV verhält sich in gestörten Designs hochgradig richtungssensitiv. Die entwickelte EmALT-Positionierung nutzt das freigewordene Gestaltungsbudget proaktiv, um über asymmetrische APs die Prognoseunsicherheit zielgerichtet entlang des Extrapolationsvektors zum fernen Feldbetriebspunkt zu minimieren. Der EVG dient hierbei als analytisches Instrumentarium, um die topologische Sensitivität von $\nu(\mathbf{x}_0)$ zu quantifizieren und die Ankerpunktpositionierung systematisch zu optimieren.
3. **Ökonomische Effizienz:** Die strenge Entkopplung von Design-Optimalität und Versuchsdauer verliert in der Lebensdauererprobung ihre Gültigkeit. Der neu eingeführte EPI (η_{eco}) weist nach, dass sich das EmALT-Design im Zielkonflikt zwischen stochastischer Prädiktionsgüte und exponentiell skalierenden Prüfkosten als das überlegene physikalisch-ökonomische Optimum positioniert und klassisch D -optimale Pläne signifikant dominiert. Dieser Befund wird durch Forschungsarbeiten zur statistischen Trennschärfe computergenerierter Optimalpläne gestützt: Wie Rittmaier et al. [88] durch simulative Analysen belegen, bieten algorithmisch optimierte Designs unter Ressourcenrestriktionen zwar prinzipielle Vorteile gegenüber starren Standard-Versuchsplänen, weisen jedoch in Abhängigkeit des gewählten Optimalitätskriteriums (A -, D - oder V -Optimalität) stark divergierende Detektionsraten für spezifische Modelleffekte auf. Die in dieser Arbeit vollzogene Abkehr von einer pauschalen D -Optimalität hin zu einer

asymmetrischen, prädiktionszentrierten Zielfunktion (SPV) ist folglich der logische methodische Schritt, um das geometrische Gestaltungsbudget ökonomisch zielführend für die Lebensdauererprobung zu erschließen.

Trotz dieser Befunde erfordert die methodische Einordnung der Ergebnisse eine stringente Diskussion der Modellrestriktionen: Die numerische Evaluation basiert zunächst auf der Prämisse eines strukturell korrekten, stetigen log-linearen AFT-Modells sowie eines konstanten Ausfallmechanismus über den gesamten Versuchsraum. Treten in der physikalischen Realität abrupte Wechsel der Schädigungsmechanismen zwischen Hochlast- (ALT) und Feldbereich auf, geraten rein modellbasierte Extrapolationen unweigerlich an ihre methodischen Grenzen - sowohl bei univariaten Lastfällen als auch bei mehrdimensionalen Lastvektoren. Gerade vor diesem Hintergrund entfaltet das EmALT-Design jedoch einen weiteren, entscheidenden Praxisvorteil: Durch die strategische Verortung der Ankerpunkte nahe dem realen Einsatzniveau fungieren diese Stützstellen nicht nur als stochastische Varianzdämpfer, sondern zugleich als physikalische Frühwarnsensoren. Im Rahmen der post-experimentellen Datenanalyse lassen sich diese Ankerpunkte analog zu *Confirmation Experiments* [103] auswerten. Entsprechende Metriken, wie etwa die *Probability of Agreement*, können hierbei herangezogen werden, um empirisch zu validieren, ob die am Hochlastprüfstand extrahierten Degradationsgesetze im moderaten *Use-Space* weiterhin Gültigkeit besitzen - eine Detektionsmöglichkeit, die durch reine Hochlastprüfungen vollständig verwehrt bliebe.

Während die durchgeführten Sensitivitätsanalysen und MCSs die theoretischen Gesetzmäßigkeiten des EmALT-Designs unter kontrollierten stochastischen Randbedingungen verifiziert haben, erfordert der Transfer in die Zuverlässigkeitspraxis einen finalen empirischen Härtetest. Im nachfolgenden Kapitel 5 wird das hergeleitete Design daher auf eine physische Fallstudie übertragen. Anhand der realen multivariaten Lebensdauererprobung von Lenksystem-Zahnriemen wird das klassische Basis-Modell mittels *Confirmation Experiments* gezielt herausgefordert. Es wird empirisch verifiziert, dass die theoriebasierte Extrapolationsabsicherung durch das EmALT-Konzept weit mehr als eine effiziente Varianzdämpfung ist: Sie erweist sich als methodische Notwendigkeit, um das Zuverlässigkeitsmodell im realen Feldbetrieb vor fatalen, sicherheitskritischen Überschätzungen zu bewahren.

5 Empirische Anwendung der Extrapolationsabsicherung

Für den Transfer der in Kapitel 4 entwickelten EmALT-Planung in die industrielle Zuverlässigkeitstechnik dient das vorliegende Kapitel der empirischen Anwendung. Anhand einer Fallstudie zu einem real vermessenen Hardwaredatensatz von Lenksystem-Zahnriemen [104] wird die praktische Leistungsfähigkeit asymmetrischer Versuchsplanung demonstriert. Vorausgesetzt sei hier, dass im Rahmen einer effizienten Versuchsplanung bereits die grundlegende Parameterauswahl auf Basis von heuristischen oder experimentellen Vorversuchen erfolgt ist [24].

Dieser methodische Übergang von der theoretischen Simulation zur physischen Erprobung erzwingt eine Konfrontation mit der industriellen Messrealität: Die idealisierte Gesetzmäßigkeit der MCS mit vollumfänglicher Kenntnis der wahren Parameter weicht der limitierten Schätzpräzision eines realen, zweifach replizierten Datensatzes ($N = 26$). Zudem unterliegen experimentelle EoL-Versuche physikalischen und normativen Restriktionen an den Belastungsgrenzen. Anstatt diese Limitierungen als methodischen Makel zu betrachten, generieren sie aus Sicht der adaptiven Versuchsplanung das **geometrische Gestaltungsbudget** für den EmALT-Ansatz (vgl. Abschnitt 4.3). Hier speist sich dieses Budget abweichend von der theoriegeleiteten Zentralpunkt-Reduktion aus dem zwingenden Entfall zweier Hochlast-SPs - $(0; \alpha_D)$ und $(\alpha_D; 0)$ - sowie des faktoriellen Eckpunktes $(1; -1)$. Diese topologische Restriktion ist physikalisch durch die Versuchsträger determiniert: In diesem spezifischen Höchstlastbereich kann für diesen beispielhaften Datensatz ein Wechsel des Ausfallmechanismus resultieren [105, 106] und durch Befundung charakterisiert werden, wodurch die erhobenen Lebensdauerdaten ihre regressionsanalytische Validität für den Feldbetrieb verliert.

Um die Leistungsfähigkeit der EmALT-Strategie am Realdatensatz zu evaluieren, wird das durch den Entfall der Hochlast-Punkte theoretisch freigewordene Budget proaktiv umgewidmet. Die experimentellen Aufwände werden algorithmisch als asym-

metrische APs in die Peripherie des anvisierten Feldbetriebspunktes $(-1,50; -1,80)$ realloziert. Da der originäre Datensatz nach Arndt et al. [104] diese entschärften Stressniveaus nicht abdeckt, werden reale Prüfläufe aus flankierenden Versuchsträgern des Erprobungsprojekts für die AP-Koordinaten integriert. Diese methodische Synthese eines kohärenten Datensatzes dient dem ingenieurwissenschaftlichen Zweck, das Wirkprinzip der Extrapolationsabsicherung unter realem stochastischem Materialrauschen zu verifizieren. Tabelle 5.1 fasst die empirischen Ausfallzeiten für die vergleichende Modellierung zusammen. Da die APs im Gegensatz zur theoretischen Simulation nun mit realen Ausfallzeiten unterlegt sind, ermöglicht dieser Datensatz einen einzigartigen, zweiseitigen Modellvergleich: Die Parameterschätzung und Lebensdauerprognose erfolgen separat für das klassische Basis-CCD (ohne APs, isoliert aus den Untersuchungen von Arndt et al. [104]) sowie für das reallozierte EmALT-Design inklusive der Ankerpunkte. Dies erlaubt nicht nur die finale Evaluation der realen Modellanpassung, der SPV sowie der verursachten Versuchskosten, sondern rückt vor allem einen fundamentalen Validierungs-Aspekt in den Fokus: Die nachfolgende Analyse liefert den empirischen Nachweis, in welchem Maße reale Degradationsdaten auf dem Extrapolationspfad das ungestützte Basis-Modell vor fatalen Fehlprädiktionen schützen und zu einer signifikant geschärften Lebensdauerprognose führen.

5.1 Modellschätzung und Anpassungsgüte

Die MLE-basierte Auswertung der Modellparameter nach Gleichung (2.50) offenbart für beide Design-Varianten zunächst messbare Diskrepanzen in der Ausprägung der Schätzwerte zu physikalischen Effekten. Abbildung 5.1 veranschaulicht die Gegenüberstellung der geschätzten Regressionskoeffizienten in $\hat{\beta}$ sowie des korrespondierenden Weibull-Formparameters $\hat{b}$.

Die Integration der Ankerpunkte modifiziert das Regressionsmodell messbar und offenbart eine wertvolle Anreicherung des ungestützten Extrapolationsmodells. Während die Konstante $\hat{\beta}_0$ sowie die Effekte $\hat{\beta}_2$ und $\hat{\beta}_{22}$ eine hohe Konsistenz aufzeigen, erzwingen die APs bei den übrigen Termen eine signifikante Neukalibrierung. So wird der Haupteffekt $\hat{\beta}_1$ drastisch gedämpft (ca. -54%), während sich der quadratische Term $\hat{\beta}_{11}$ mehr als verdoppelt (ca. $+148\%$). Besonders prägnant ist die vollständige Vorzeichenumkehr der Faktoren-Interaktion $\hat{\beta}_{12}$ ($0,60 \rightarrow -0,37$). Da bei empirischen

Tabelle 5.1: Gegenüberstellung der Versuchspläne und realisierten Ausfallzeiten t_i für das Basis-CCD und das EmALT-Design ($N = 26$) auf Basis der Datenlage aus [104] und begleitenden Prüfläufen (APs).

Run	Basis-CCD			EmALT		
	x_1	x_2	t_i [h]	x_1	x_2	t_i [h]
<i>Replikation 1</i>						
1	1,00	1,00	314144	1,00	1,00	314144
2	1,00	-1,00	1440	-2,42	-2,17	1850000
3	-1,00	1,00	625776	-1,00	1,00	625776
4	-1,00	-1,00	4760	-1,00	-1,00	4760
5	α_D	0,00	2904	-3,15	-2,56	4200000
6	$-\alpha_D$	0,00	800000	$-\alpha_D$	0,00	800000
7	0,00	α_D	78368	-3,15	-2,56	3950000
8	0,00	$-\alpha_D$	32072	0,00	$-\alpha_D$	32072
9	0,00	0,00	43472	0,00	0,00	43472
10	0,00	0,00	40144	0,00	0,00	40144
11	0,00	0,00	70440	0,00	0,00	70440
12	0,00	0,00	45296	0,00	0,00	45296
13	0,00	0,00	44560	0,00	0,00	44560
<i>Replikation 2</i>						
14	1,00	1,00	210584	1,00	1,00	210584
15	1,00	-1,00	7656	-2,42	-2,17	1910000
16	-1,00	1,00	752936	-1,00	1,00	752936
17	-1,00	-1,00	5264	-1,00	-1,00	5264
18	α_D	0,00	1440	-3,15	-2,56	4120000
19	$-\alpha_D$	0,00	709336	$-\alpha_D$	0,00	709336
20	0,00	α_D	48840	-3,15	-2,56	4300000
21	0,00	$-\alpha_D$	42728	0,00	$-\alpha_D$	42728
22	0,00	0,00	20936	0,00	0,00	20936
23	0,00	0,00	71744	0,00	0,00	71744
24	0,00	0,00	57960	0,00	0,00	57960
25	0,00	0,00	22432	0,00	0,00	22432
26	0,00	0,00	65816	0,00	0,00	65816




Abbildung 5.1: Vergleich der MLE-Parameterschätzungen für das klassische Basis-CCD und das EmALT-Design am realen Datensatz. Die Integration der Ankerpunkte führt zu einer elementaren Neukalibrierung ausgewählter Haupteffekte, Wechselwirkungen und der Streuung (Formparameter $\hat{b}$).

Daten keine absolute *Ground-Truth* vorliegt, belegen diese Verschiebungen primär die immense strukturelle Instabilität des reinen CCD-Modells: Ohne die Stützung durch APs kippt die Parameterkonstellation auf dem Extrapolationspfad erheblich.

Flankierend induzieren die Realdaten einen datensatzspezifischen Effekt bezüglich des Weibull-Formparameters $\hat{b}$. Das eng im Hochlastzentrum konzentrierte Basis-CCD schätzt mit $\hat{b} = 1,25$ eine hohe Varianz der Lebensdauern, was auf eine starke stochastische Bauteilstreuung unter Extrembelastung hindeutet. Die Einbindung der feldnahen Ankerpunkte stabilisiert diesen Wert auf $\hat{b} = 1,66$. Diese deterministischere Schädigungskinetik im moderaten Stressbereich korrespondiert mit der werkstoffphysikalischen Erwartungshaltung, dass tribologische Verschleißmechanismen fernab der makroskopischen Belastungsgrenzen eine reduzierte Ausfallstreuung aufweisen.

Diese Neukalibrierung manifestiert sich visuell prägnant in der Antwortfläche (Abbildung 5.2). Das ungestützte Basis-CCD extrapoliert den steilen Gradienten des Hochlastzentrums starr und linear in den fernen *Use-Space*, was zu einer potenziell fatalen Überschätzung der zu erwartenden Systemlebensdauer im Feld führt. Das EmALT-Design registriert durch seine APs physikalisch korrekt, dass die Lebensdauer bei moderateren Lasten nicht im gleichen Maße ansteigt, wie es die initiale

Hochlast-Extrapolation suggeriert. Die Response Surface erfährt durch die APs somit eine empirisch gestützte Dämpfung in Richtung konservativerer Lebensdauern.




Abbildung 5.2: Modellanpassung im Parameterraum (logarithmische Darstellung): Beide Regressionsflächen im direkten visuellen Vergleich. Das Basis-CCD extrapoliert starr aus dem Hochlastzentrum. Das EmALT-Design wird durch die APs im südwestlichen Parameterbereich gestützt und erfährt eine merkliche Dämpfung der prognostizierten Lebensdauer.

5.1.1 Residuenanalyse und Verifikationsdiagnostik

Die fundamentale Neukalibrierung der Modellparameter – insbesondere die Dämpfung des Haupteffekts $\hat{\beta}_1$ sowie die Vorzeichenumkehr der Interaktion $\hat{\beta}_{12}$ – wirft die methodische Frage auf, ob das EmALT-Design die physikalische Realität adäquat abbildet oder Schätzartefakte induziert. Zur Beantwortung dieser Fragestellung wird die Residuenstruktur beider Regressionsmodelle anhand der in Abschnitt 2.2.6 hergeleiteten diagnostischen Metriken überprüft - vgl. Abbildung 5.3.

Die Analyse der standardisierten Devianz-Residuen r_{Dev} - siehe Gleichung (2.63) - über der logarithmierten charakteristischen Lebensdauer $\ln(\hat{T})$ in Abbildung 5.3 (links) bestätigt die Homoskedastizität beider Modelle: Die Residuen streuen symmetrisch um den Nullpunkt und verharren mit Ausnahme singulärer Randbeobachtungen innerhalb der statistischen Toleranzschranken von $\pm 2\sigma$. Das EmALT-Design




Abbildung 5.3: Residuenanalyse der Modellpassung für das Basis-CCD und das EmALT-Design am realen Prüfstandsdatensatz ($N = 26$): Standardisierte Devianz-Residuen über $\ln(\hat{T})$ (links) sowie Cox-Snell-Residuen (rechts).

weist über den gesamten Prädiktionsbereich von $\ln(\hat{T}) = 10,4$ bis $16,0$ (entsprechend einer Lebensdauer bis über 10^6 h) eine homogene, trendfreie Verteilung auf.

Flankierend liefert die Auswertung der Cox-Snell-Residuen r_{CS} (Gleichung (2.62)) in Abbildung 5.3 (rechts) den empirischen Nachweis der überlegenen Modellanpassung: Während die Residuen des Basis-CCD im oberen Wertebereich ($r_{CSi} > 2,0$) eine systematische Krümmung und Abweichung von den theoretischen Quantilen $-\ln(1-F)$ aufweisen, folgen die Residuen des EmALT-Designs bis zu Werten von $r_{CSi} \approx 3,5$ nahezu ideal der theoretischen Winkelhalbierenden. Dies belegt, dass die Integration der Ankerpunkte einen möglichen Lack-of-Fit im Niedriglastbereich eliminiert. Damit ist formal nachgewiesen, dass die signifikante Verschiebung der Modellparameter in $\hat{\beta}$ keine statistische Verzerrung darstellt, sondern das reale tribologische Verschleißverhalten des Zahnriemens mathematisch konsistent und frei von systematischen Anpassungsmängeln abbildet. Dieses empirische Ergebnis bestätigt die simulationsbasierten Erkenntnisse aus Kapitel 4: Die durch das EmALT-Design induzierte Umverteilung der Schätzvarianz bewahrt die statistische Signifikanz der Modelleffekte (vgl. Tabelle 4.12) und führt am realen Prüfstand zu einer signifikant überlegenen, physikalisch fundierten Modellgüte.

5.2 Konsequenzen für die Zuverlässigkeitsmodellierung

Die Korrektur der Antwortfläche wirkt sich unmittelbar auf die statistische Feldabsicherung am anvisierten Prognosepunkt $(-1,50; -1,80)$ aus. Abbildung 5.4 projiziert die parametrisierten Modelle auf den Verlauf der Überlebenswahrscheinlichkeit $\hat{R}(t)$. Dargestellt sind die Zuverlässigkeitsfunktionen auf Grundlage der Gleichungen (2.3), (2.47) und (2.60) sowie die korrespondierenden 90 %-CIs, ermittelt über die Delta-Methode auf Basis der invertierten beobachteten Fisher-Informationsmatrix F_{ob} .




Abbildung 5.4: Empirische Lebensdauerprognose am Feldpunkt. Das EmALT-Design liefert eine radikal verkleinerte Prädiktionsvarianz (schmales Konfidenzband). Sein Median verbleibt kohärent innerhalb des weiten Vertrauensbereichs des Basis-CCD, zeichnet jedoch ein realitätsnäheres und konservativeres Ausfallverhalten.

Die Auswertung bestätigt zunächst die theoriegeleitete Erwartung zur Varianzreduktion aus Kapitel 4: Das Basis-CCD weist aufgrund der ungestützten Extrapolationsdistanz eine stark ausgeprägte Prädiktionsvarianz von $SPV = 55,04$ im Prognosepunkt auf. Dies führt zu einem extrem breiten Konfidenzband für die Prognose im Feldbetriebspunkt, das bei einer beispielhaften Laufzeit von 5×10^5 h eine maximale Unschärfe von 98,2 % aufspannt. Das EmALT-Design hingegen reduziert die Varianz durch die implementierten APs massiv: Die SPV reduziert sich durch die

Ankerpunkte auf 4,86, wodurch sich die Breite des CI am Referenzpunkt auf 7,4 % verdichtet. Die formale Extrapolationsunsicherheit wird somit um den Faktor 11,3 gedämpft. In der industriellen Auslegungspraxis bedeutet dies: Das Basis-CCD liefert im Feldbereich eine stochastisch derart unscharfe Prognose, dass das Modell für normative Zulassungsprozesse faktisch unnutzbar bleibt. Erst die topologische Stützung durch die Ankerpunkte überführt die Extrapolation in ein belastbares, normativ verwertbares Zuverlässigkeitsmodell. Die mediane Prognose des EmALT-Designs steht dabei nicht im fundamentalen Widerspruch zur Basis-Approximation, sondern reicht diese stochastisch an: Der konservativere Erwartungswert der angepassten Modellierung verbleibt über weite Strecken tief im massiven Streuband der ungestützten CCD-Prognose.

5.2.1 Confirmation Experiments: Der statistische Härtetest

Um die Belastbarkeit der reinen Hochlast-Extrapolation (Basis-CCD) formell zu prüfen, werden die am Prüfstand ermittelten Ausfallzeiten der Ankerpunkte als *Confirmation Runs* nach Stevens und Anderson-Cook [103] ausgewertet. Die Prüflogik lautet: Bildet das extrapolierende Hochlastmodell die physikalische Realität valide ab, müssen die neuen, empirischen Ausfallzeiten zwingend innerhalb der Prädiktionsintervalle (Prediction Intervals (PIs)) des Modells am jeweiligen Lastpunkt liegen. Da die Richtung einer potenziellen Fehlprädiktion (*a priori* unbekannte Über- oder Unterschätzung der Lebensdauer) offen ist, wird hierbei methodisch zwingend ein zweiseitiges PI konstruiert. Dieses definiert sich über das 5 %- und 95 %-Quantil der prognostizierten Weibull-Verteilung, wobei die epistemische Parameterunsicherheit additiv über die Δ -Methode der Fisher-Informationsmatrix (**F**) integriert wird.

Die quantitative Auswertung liefert ein paradox anmutendes stochastisches Resultat: Die empirischen Ausfallzeiten der Replikationen an beiden peripheren Ankerpunkten (etwa $3,95$ bis $4,30 \times 10^6$ h sowie $1,85$ bis $1,91 \times 10^6$ h) liegen **vollständig innerhalb** der durch das Basis-CCD berechneten 90 %-PIs. Das ungestützte Basis-Modell besteht diesen formalen statistischen Test auf 90 % *Coverage* und wird folglich nicht falsifiziert. Eine ingenieurwissenschaftliche Betrachtung der Intervallgrenzen entlarvt jedoch die methodische Schwäche des reinen Hochlast-Versuchsplans: Bedingt durch die extreme Prädiktionsvarianz spannt das Basis-CCD an diesen Koordinaten PIs von physikalisch nicht verwertbarer Größenordnung auf - von minimal

$3,63 \times 10^5$ h bis hin zu $8,23 \times 10^{12}$ h am ersten AP sowie $7,11 \times 10^4$ h bis $1,51 \times 10^{10}$ h am zweiten. Das Modell passiert den statistischen Konfirmationstest somit ausschließlich aufgrund seiner eigenen, ungebremsen Varianzinflation, die ein Streuband über mehrere Zehnerpotenzen erzeugt. Für normative Garantieentscheidungen verliert die Extrapolation dadurch jegliche Trennschärfe, was die proaktive Varianzdämpfung durch EmALT aus der empirischen Praxis heraus als zwingende Notwendigkeit legitimiert.

5.2.2 Ökonomische Schlussfolgerung und industrieller Business Case

Die Validierung am extremen Randbereich durch die *Confirmation Runs* liefert den abschließenden, formellen Beleg für die Natur der EoL-Kostengleichung. Vordergründig suggeriert der rein monetäre Vergleich eine Ineffizienz des EmALT-Designs: Einem ressourcenschonenden Basis-CCD mit Gesamtkosten von lediglich 68,3 kCU steht im EmALT-Design ein geforderter Prüfstandsaufwand von 371,2 kCU gegenüber. Werden diese Versuchspläne jedoch der industriellen Realität der Zuverlässigkeitsfreigabe unterzogen, entlarvt sich die reine ALT-Kostenreduktion des Basis-Designs als irreführende Investition.

Der entscheidende Maßstab für die Testeffizienz ist in der industriellen Realität nicht die isolierte Minimierung der nominalen Prüfkosten, sondern die Beherrschung von Garantierisiken bei gleichzeitiger Sicherstellung der *Time-to-Market*. Das Basis-CCD erkaufte sich seinen monetären Kostenvorteil durch Konfidenzbänder, die am Prognosepunkt eine rechnerische Überlebenswahrscheinlichkeit zwischen 0 % und 100 % aufspannen, was eine belastbare Systemfreigabe unmöglich macht.

Ein alternativer, rein auf den Prognosepunkt zentrierter Feld-Versuchsplan würde diese Unschärfe zwar eliminieren, erforderte aufgrund unbeschleunigter Laufzeiten jedoch exorbitante Prüfkosten von analytisch 22 152,0 kCU, was jegliche Entwicklungszeitpläne sprengen würde. Vor diesem Hintergrund transformiert sich der nominale Prüfstands-Mehraufwand des EmALT-Designs (Differenz ca. 300 kCU zum Basis-CCD) in ein hochprofitables Re-Investment: Das Design komprimiert die Prognoseunschärfe im Feld-Betriebspunkt auf präzise 7,4 %. Es realisiert somit die stochastische Präzision eines echten Feldtests für einen Bruchteil von dessen Kosten (ca. 1,68 %), während der entscheidende Beschleunigungsvorteil der ALT-Methodik vollständig gewahrt bleibt. Die adaptive EmALT-Strategie etabliert sich folglich als ein hocheffekti-

ves methodisches Steuerungswerkzeug, um hochbeschleunigte Lebensdauerversuche ökonomisch effizient und sicherheitstechnisch belastbar auszurichten und schließt damit die informationstheoretische Lücke zwischen statistischer Optimalität und industrieller Feldbewährung.

6 Zusammenfassung und Ausblick

Die vorliegende Arbeit löst den fundamentalen methodischen Konflikt auf, der einer effizienten, multivariaten Zuverlässigkeitsmodellierung bislang im Wege steht. Sie beantwortet die zentrale Forschungsfrage, wie klassische RSDs für die spezifischen Zwecke des ALT effizient geplant und individuell adaptiert werden können. Der erarbeitete Paradigmenwechsel - weg von der starren Maximierung klassischer Optimalitätskriterien hin zu einer stochastisch und ökonomisch ausbalancierten Extrapolationsabsicherung unter Beibehaltung des Prüfumfangs N - beantwortet die in Kapitel 3 formulierte Hauptforschungsfrage sowie die zugehörigen Teilforschungsfragen abschließend. Dieser Erkenntnisgewinn manifestiert sich in vier zentralen wissenschaftlichen Säulen:

1. Limitierung klassischer Optimalitätskriterien:

Die methodische Untersuchung beweist, dass volumenbasierte Optimalitätsmaße (insbesondere die als Standard verbreitete klassische D -Effizienz) für EoL-Versuche systematisch ineffizient sind. Da der Fokus beschleunigter Prüfungen nicht auf der Interpolation, sondern auf der weiten Extrapolation in den Feldbereich liegt, führt ein rein orthogonal ausgerichtetes Design zu einer unzulässig hohen skalierten Prädiktionsvarianz (SPV) am fernen Prognosepunkt.

2. Adaptionsstrategie mittels topologischer Resilienz (Teilforschungsfrage 1):

Umfangreiche Sensitivitätsanalysen decken auf, dass etablierte Standard-Versuchspläne wie das CCD eine unerwartet hohe topologische Resilienz aufweisen. Der asymmetrische Entfall unkritischer Stützstellen bewirkt tolerierbare Einbußen in der statistischen Trennschärfe (*power*) der Haupteffekte. Diese Erkenntnis legitimiert den bewussten Verzicht auf strikte Orthogonalität und eröffnet dem Versuchsplaner ein wertvolles **geometrisches Gestaltungsbudget**, um den klassischen Augmentierungs-Gedanken isometrisch ($N_{\text{adaptiv}} \leq N_{\text{CCD}}$) durch gezielte Stützstellen-Reallokation fortzuführen.

3. Bewertungsmethodik und physikalisch-ökonomisches Optimum (Teilforschungsfrage 2):

Die proaktive Umwidmung des Gestaltungsbudgets in asymmetrische Ankerpunkte (APs) nahe dem Feldbereich (EmALT-Methodik) minimiert die Extrapolationsvarianz zielgerichtet. Um die Auswirkungen dieser Orthogonalitätsmanipulationen quantitativ zu bewerten, dient der richtungssensitive EVG als geometrischer Indikator. Flankierend überführt der Economic Extrapolation Power Index (EPI) die reine statistische *Effektivität* (Trennschärfe und Prädiktionsvarianz) unter Berücksichtigung exponentiell skalierender Prüflaufzeiten in eine ganzheitliche ökonomische *Effizienz*. Die Bilanzierung weist nach, dass das EmALT-Design das globale Pareto-Optimum aus reduzierter Prognoseunsicherheit und vertretbaren Prüfstandskosten bzw. Versuchsdauern darstellt.

4. Empirische Anwendung und methodische Notwendigkeit (Teilforschungsfrage 3):

Die industrielle Fallstudie demonstriert anhand realer Prüfstandsdaten die praktische Leistungsfähigkeit der Extrapolationsabsicherung. Zwar wurden der EmALT-Methodik hierbei zu Illustrationszwecken zwei extreme – und für die industrielle Praxis letztlich untaugliche – Alternativen (reines Hochlast-CCD und unbeschleunigtes Feld-Design) gegenübergestellt, doch entlarvt gerade diese Kontrastierung eine hochrelevante ingenieurwissenschaftliche Realität: Die massiven Unzulänglichkeiten klassischer Orthogonalpläne auf dem Extrapolationspfad sind kein konstruiertes theoretisches Artefakt, sondern ein reales industrielles Risiko. Prädiktionsintervall-basierte Konfirmationstests belegen, dass die Allokation von Ankerpunkten dieses Risiko wirksam bannt und sicherheitskritische Überschätzungen im Feldbetrieb verhindert – eine Systematik, deren Robustheit sich nahtlos auch auf weniger extreme Datensätze und moderatere Versuchsplan-Alternativen übertragen lässt.

Zusammenfassend lässt sich konstatieren, dass die entwickelte Methodik weit über den Rahmen der hier betrachteten Referenzdesigns und spezifischen Arbeitspunkte hinausreicht. Abseits der sorgfältigen numerischen Beweisführung etabliert die vorliegende Arbeit einen **allgemeingültigen Analyse-Leitpfad**. Das geschaffene Instrumentarium – bestehend aus richtungssensitiver Varianzbewertung (EVG), stochastisch-ökonomischer Bilanzierung (EPI) und prädiktiver Validierung (*Confirmation Experi-*

ments) - dient künftig als universelles Leitgerüst. Es befähigt den Versuchsplaner, prinzipiell beliebige Modifikationen an multivariaten Testdesigns quantitativ zu charakterisieren, objektiv zu bewerten und effiziente Lebensdauerversuche in unterschiedlichsten industriellen Kontexten systematisch abzusichern.

6.1 Diskussion

Die entwickelte Methodik bietet ein weitreichendes Instrumentarium zur Steigerung der Modelleffizienz, bedarf jedoch hinsichtlich ihrer Anwendbarkeit und algorithmischen Skalierbarkeit einer kritischen ingenieurwissenschaftlichen Einordnung.

Die fundamentale Prämisse der Extrapolationsabsicherung durch EmALT beruht auf der Annahme einer stetigen Degradationskinetik. Das log-lineare AFT-Modell setzt zwingend einen einheitlichen Ausfallmechanismus über den gesamten abgetasteten Parameterraum voraus. Die Ankerpunkte verschieben die empirische Absicherung zwar signifikant näher an den Feldbereich und reduzieren das Risiko unerkannter Nichtlinearitäten im direkten Vergleich zur klassischen Hochlast-Prüfung massiv. Abrupte physikalische Mechanismenwechsel, die erst bei noch geringeren Lasten (zwischen den APs und dem nominellen Feld-Niveau) auftreten, kann jedoch auch dieses Design rein datenbasiert nicht *a priori* präzisieren. Das Modell verbleibt folglich eine stochastische Approximation der Realität, die final stets durch physikalisches Domänenwissen plausibilisiert werden muss.

Eine zentrale methodische Randbedingung der adaptiven Versuchsplanung liegt zudem in ihrer inhärenten Kopplung an das verfügbare *A-priori*-Wissen [72]. Die optimale Platzierung der Ankerpunkte innerhalb der *Exposure-Area* (gestützt durch den EVG) sowie die Vorabkalkulation des EPI erfordern initiale Annahmen über die zugrundeliegenden Weibull-Parameter und das Kostengefüge. Entspricht die frühe Schätzung der Effektgrößen nicht der wahren Systemkinetik, verschiebt sich die topologische Effizienz des konzipierten Versuchsplans. Die Methodik ist somit untrennbar an die Qualität der vorangegangenen Screening-Phase gebunden.

Hinsichtlich der algorithmischen Skalierbarkeit konzentrieren sich die grafischen und analytischen Nachweise im Rahmen dieser Arbeit auf den zweidimensionalen Versuchsraum ($k = 2$). Während die Berechnungen der Informationsmatrix, der SPV sowie der Trennschärfe mathematisch dimensionsunabhängig operieren, steigt die

Komplexität der Identifikation und Visualisierung vorteilhafter APs in höherdimensionalen Parameterräumen drastisch an. Die Verortung von Ankerpunkten auf Basis rasterartiger Auswertungen stößt bei multivariaten Problemen mit drei oder mehr interagierenden Stressfaktoren unweigerlich an rechnerische und geometrisch-visuelle Grenzen.

6.2 Ausblick

Aus den identifizierten Restriktionen leiten sich direkte Impulse für die weiterführende wissenschaftliche Forschung im Schnittpunkt von Zuverlässigkeitstechnik und statistischer Versuchsplanung ab. Zur Adressierung des dimensional Skalierungsproblems empfiehlt sich die Entwicklung automatisierter Optimierungsalgorithmen. Die Überführung der EmALT-Positionierung in ein deterministisches *Constrained Optimization Problem* - bei welchem Algorithmen die Ankerpunkte unter Einhaltung numerischer SPV-Schranken und anlagenspezifischer Parametergrenzen selbstständig in mehrdimensionalen Räumen allokalieren - beschleunigt den industriellen Planungsprozess und macht ihn unabhängig von manuellen, visuellen EVG-Auswertungen. Um die Abhängigkeit von *A-priori*-Wissen zu reduzieren, bietet die Integration der EmALT-Methodik in sequenzielle oder Bayes'sche Versuchsplanungsstrategien ein herausragendes Potenzial [3, 72, 107]. Ein dynamisches DoE, welches erste Ausfallereignisse aus dem faktoriellen Hochlast-Kern in Echtzeit auswertet, um die Koordinaten der nachgelagerten Ankerpunkte laufend zu aktualisieren und an das sich abzeichnende Ausfallverhalten anzupassen, maximiert die Effizienz der experimentellen Ressourcenallokation. Schließlich erfordert die Generalisierung des Ansatzes eine systematische Ausweitung jenseits des hier fokussierten AFT-Modells für isolierte Totalausfälle. Die Übertragung der gerichteten Extrapolationsabsicherung auf Modelle mit konkurrierenden Ausfallmechanismen (*Competing Risks*) oder auf Degradationsmodelle, bei denen der kontinuierliche Verschleißverlauf als stochastische Zielgröße dient, stellt den logischen nächsten Paradigmenwechsel dar. Dies erweitert den Anwendungsbereich der EmALT-Strategie von der klassischen Lebensdauerprüfung auf die proaktive Zustandsüberwachung (*Condition Monitoring*) und zukunftsweisende *Predictive-Maintenance*-Architekturen.

Literatur

- [1] B. Bertsche und M. Dazer. *Zuverlässigkeit im Fahrzeug- und Maschinenbau: Ermittlung von Bauteil- und System-Zuverlässigkeiten*. 4. Auflage. Berlin und Heidelberg: Springer Vieweg, 2022. ISBN: 978-3-662-65023-3. DOI: 10.1007/978-3-662-65024-0.
- [2] W. Q. Meeker, L. A. Escobar und F. G. Pascual. *Statistical methods for reliability data*. Second edition. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2022. ISBN: 978-1-118-11545-9.
- [3] S. E. Rigdon, R. Pan, D. C. Montgomery und L. J. Freeman. *Design of experiments for reliability achievement*. Hoboken, NJ: Wiley, 2022. ISBN: 9781119237693. DOI: 10.1002/9781119237754.
- [4] A. Kremer. „Statistische Versuchsplanung in der Lebensdauererprobung mit Vertrauensintervallen“. Diss. 2021. DOI: 10.18419/OPUS-11728.
- [5] A. Birolini. *Reliability Engineering*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2017. ISBN: 978-3-662-54208-8. DOI: 10.1007/978-3-662-54209-5.
- [6] G. Yang. *Life cycle reliability engineering*. Hoboken, N.J.: Wiley, 2007. ISBN: 9780471715290. URL: <http://www.loc.gov/catdir/enhancements/fy0740/2006019150-b.html>.
- [7] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot und G. Tutz. *Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2016. ISBN: 978-3-662-50371-3. DOI: 10.1007/978-3-662-50372-0.
- [8] E. L. Kaplan und P. Meier. „Nonparametric Estimation from Incomplete Observations“. In: *Journal of the American Statistical Association* 53.282 (1958), S. 457. ISSN: 01621459. DOI: 10.2307/2281868.
- [9] J. Hedderich und L. Sachs. *Angewandte Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2020. ISBN: 978-3-662-62293-3. DOI: 10.1007/978-3-662-62294-0.

- [10] H. Rinne. *The Weibull Distribution: A Handbook*. 1st ed. London: CRC Press LLC, 2008. ISBN: 978-1-4200-8743-7. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=1633687>.
- [11] D. Kececioglu. *Reliability & life testing handbook*. Lancaster, PA: DEStech Publications, 2002. ISBN: 1-932078-03-7.
- [12] W. Nelson. *Accelerated Testing: Statistical Models, Test Plans, and Data Analysis*. 1st ed. Bd. v.344. Wiley Series in Probability and Statistics Series. Newark: John Wiley & Sons Incorporated, 1990. ISBN: 978-0471697367. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=469757>.
- [13] J. D. Kalbfleisch. *The statistical analysis of failure time data*. 2nd ed. Wiley series in probability and statistics. Hoboken, N.J.: J. Wiley, 2002. ISBN: 047136357X. DOI: 10.1002/9781118032985.
- [14] W. Nelson. *Applied Life Data Analysis*. Bd. v.577. Wiley series in probability and statistics. Hoboken: John Wiley & Sons Inc, 2005. ISBN: 9780471644620. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226561>.
- [15] H. Qiao und C. P. Tsokos. „Parameter estimation of the Weibull probability distribution“. In: *Mathematics and Computers in Simulation* 37.1 (1994), S. 47–55. ISSN: 0378-4754. DOI: 10.1016/0378-4754(94)90058-2.
- [16] A. Kremer und B. Bertsche. „A New Approach for Parametrizing Multidimensional Lifetime Models“. In: *Proceedings of the 29th European Safety and Reliability Conference (ESREL)*. Hrsg. von M. Beer und E. Zio. Europe und Singapore: European Safety and Reliability Association und Research Publishing Services, 2019, S. 715–722. ISBN: 978-981-11-2724-3. DOI: 10.3850/978-981-11-2724-3{\textunderscore}0443-cd.
- [17] R. B. Abernethy. *The new Weibull handbook: Reliability & statistical analysis for predicting life, safety, risk, support costs, failures, and forecasting warranty claims, substantiation and accelerated testing, using Weibull, log normal, Crow-AMSAA, Probit, and Kaplan-meier Models*. 5. ed. North Palm Beach, Fla.: R.B. Abernethy, 2006. ISBN: 0965306232.

-
- [18] H. Hirose. „Bias correction for the maximum likelihood estimates in the two-parameter Weibull distribution“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 6.1 (1999), S. 66–68. ISSN: 10709878. DOI: 10.1109/94.752011.
- [19] R. Ross. „Bias and standard deviation due to Weibull parameter estimation for small data sets“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 3.1 (1996), S. 28–42. ISSN: 10709878. DOI: 10.1109/94.485512.
- [20] R. A. Fisher. *The Design of Experiments*. Edinburgh: Oliver & Boyd, 1935.
- [21] G. E. P. Box, W. G. Hunter und J. S. Hunter. *Statistics for experimenters: An introduction to design, data analysis, and model building*. Wiley series in probability and mathematical statistics. New York: Wiley, 1978. ISBN: 0471093157. URL: <http://www.loc.gov/catdir/description/wiley033/77015087.html>.
- [22] D. C. Montgomery. *Design and Analysis of Experiments*. 10th. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2020. ISBN: 9781119722106.
- [23] D. E. Coleman und D. C. Montgomery. „A Systematic Approach to Planning for a Designed Industrial Experiment“. In: *Technometrics* 35.1 (1993), S. 1. ISSN: 0040-1706. DOI: 10.2307/1269280.
- [24] M. Arndt, M. Dazer, W. Raither und B. Bertsche. „Parameter assessment for reliability modeling of machine components using heuristic screening“. In: *Forschung im Ingenieurwesen* 87.4 (2023), S. 1347–1370. ISSN: 0015-7899. DOI: 10.1007/s10010-023-00711-5.
- [25] C. Gundlach. „Entwicklung eines ganzheitlichen Vorgehensmodells zur problemorientierten Anwendung des statistischen Versuchsplanung“. Zugl.: Kassel, Univ., Diss, 2004. Kassel. URL: <http://d-nb.info/971843546/34>.
- [26] B. Mayers. *Prozeß- und Produktoptimierung mit Hilfe der statistischen Versuchsmethodik: Zugl.: Aachen, Techn. Hochsch., Diss., 1997*. Als Ms. gedr. Bd. 97,9. Berichte aus der Produktionstechnik. Aachen: Shaker, 1997. ISBN: 3826524977.
- [27] G. Pahl, W. Beitz, J. Feldhusen und K.-H. Grote. *Engineering design: A systematic approach*. 3. ed. London: Springer, 2007. ISBN: 978-1-84628-318-5. DOI: 10.1007/978-1-84628-319-2.

- [28] C.-F. Wu und M. Hamada. *Experiments: Planning, analysis and optimization*. Third edition. Wiley series in probability and statistics. Hoboken, NJ, USA: Wiley, 2021. ISBN: 9781119470106. URL: <https://zbmath.org/?q=an%3A1460.62003>.
- [29] W. F. Daenzer und R. Haberfellner, Hrsg. *Systems Engineering: Methodik und Praxis*. 11., durchges. Aufl. Zürich: Verl. Industrielle Organisation, 2002. ISBN: 385743998X.
- [30] U. Lindemann, M. Maurer und T. Braun. *Structural Complexity Management: An Approach for the Field of Product Design*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008. ISBN: 978-3-540-87888-9. DOI: 10.1007/978-3-540-87889-6.
- [31] K. Siebertz, D. van Bebbber und T. Hochkirchen. *Statistische Versuchsplanung: Design of Experiments (DoE)*. 3. Auflage. VDI-Buch. Berlin und Heidelberg: Springer Vieweg, 2026. ISBN: 978-3-662-73090-4.
- [32] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 10., überarbeitete Auflage. Praxisreihe Qualität. München: Hanser, 2020. ISBN: 978-3-446-46397-4.
- [33] D. C. Montgomery, E. A. Peck und G. G. Vining. *Introduction to linear regression analysis*. Sixth edition. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2021. ISBN: 978-1-119-57872-7.
- [34] E. M. Monroe und R. Pan. „Experimental Design Considerations for Accelerated Life Tests with Nonlinear Constraints and Censoring“. In: *Journal of Quality Technology* 40.4 (2008), S. 355–367. ISSN: 0022-4065. DOI: 10.1080/00224065.2008.11917742.
- [35] G. E. P. Box und J. S. Hunter. „Multi-Factor Experimental Designs for Exploring Response Surfaces“. In: *The Annals of Mathematical Statistics* 28.1 (1957), S. 195–241.
- [36] R. H. Myers, D. C. Montgomery und C. M. Anderson-Cook. *Response Surface Methodology: Process and Product Optimization Using Designed Experiments*. 4. Aufl. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2016. ISBN: 978-1-118-91601-8.

-
- [37] G. E. P. Box und D. W. Behnken. „Some New Three Level Designs for the Study of Quantitative Variables“. In: *Technometrics* 2 (1960), S. 455–475. ISSN: 0040-1706.
- [38] B. Jones und C. J. Nachtsheim. „Efficient Designs With Minimal Aliasing“. In: *Technometrics* 53.1 (2011), S. 62–71. ISSN: 0040-1706. DOI: 10.1198/TECH.2010.09113.
- [39] P. Goos und B. A. Jones. *Optimal Design of Experiments: A Case Study Approach*. 1st. Hoboken, NJ: John Wiley & Sons, Inc, 2011. ISBN: 9780470744611.
- [40] A. M. Dean, D. Voss und D. Draguljić. *Design and analysis of experiments*. Second edition. Springer texts in statistics. Cham: Springer, 2017. ISBN: 978-3-319-52248-7. DOI: 10.1007/978-3-319-52250-0.
- [41] G. E. P. Box und K. B. Wilson. „On the Experimental Attainment of Optimum Conditions“. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 13.1 (1951), S. 1–45. ISSN: 00359246. URL: <http://www.jstor.org/stable/2983966> (besucht am 23.03.2023).
- [42] G. E. P. Box, S. Bisgaard und C. Fung. „An explanation and critique of taguchi’s contributions to quality engineering“. In: *Quality and Reliability Engineering International* 4.2 (1988), S. 123–131. ISSN: 0748-8017. DOI: 10.1002/qre.4680040207.
- [43] S. Bisgaard. „A Conceptual Framework for the use of Quality Concepts and Statistical Methods in Product Design“. In: *Journal of Engineering Design* 3.1 (1992), S. 31–47. ISSN: 0954-4828. DOI: 10.1080/09544829208914746.
- [44] K. G. Russell. *Design of experiments for generalized linear models*. Chapman and Hall/CRC Interdisciplinary Statistics Ser. Boca Raton, London und New York: CRC Press Taylor & Francis Group, 2019. ISBN: 9780429057489. DOI: 10.1201/9780429057489.
- [45] I. Paschal und I. Fortune. „Performance Evaluation of Custom A-, D-, and I-Optimal Designs for Non-Standard Second-Order Models“. In: *American Journal of Theoretical and Applied Statistics* 13.5 (2024), S. 92–114. ISSN: 2326-8999. DOI: 10.11648/j.ajtas.20241305.11.

- [46] F. Pukelsheim. *Optimal design of experiments: Originally published: New York : J. Wiley, 1993. Classic ed. Bd. 50. Classics in applied mathematics. Philadelphia, Pa.: Society for Industrial and Applied Mathematics (SIAM 3600 Market Street Floor 6 Philadelphia PA 19104), 2006. ISBN: 9780898716047. DOI: 10.1137/1.9780898719109.*
- [47] M. Risberg Ellekjær und S. Bisgaard. „The use of experimental design in the development of new products“. In: *International Journal of Quality Science* 3.3 (1998), S. 254–274. ISSN: 1359-8538. DOI: 10.1108/13598539810229230.
- [48] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 9., überarbeitete Auflage. Hanser eLibrary. München: Hanser, 2016. ISBN: 978-3-446-44716-5. DOI: 10.3139/9783446447172?locatt=mode:legacy.
- [49] R. H. Myers, D. C. Montgomery, G. G. Vining und T. J. Robinson. *Generalized linear models: With applications in engineering and the sciences*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2010. ISBN: 9780470454633. DOI: 10.1002/9780470556986.
- [50] A. Zahran, C. M. Anderson-Cook und R. H. Myers. „Fraction of Design Space to Assess Prediction Capability of Response Surface Designs“. In: *Journal of Quality Technology* 35.4 (2003), S. 377–386. ISSN: 0022-4065.
- [51] A. Giovannitti-Jensen und R. H. Myers. „Graphical Assessment of the Prediction Capability of Response Surface Designs“. In: *Technometrics* 31.2 (1989), S. 159–171. ISSN: 0040-1706.
- [52] H. B. Goldfarb, C. M. Borror, D. C. Montgomery und C. M. Anderson-Cook. „Three-Dimensional Variance Dispersion Graphs for Mixture-Process Experiments“. In: *Journal of Quality Technology* 36.1 (2004), S. 109–124. ISSN: 0022-4065. DOI: 10.1080/00224065.2004.11980255.
- [53] A. Ozol-Godfrey, C. M. Anderson-Cook und D. C. Montgomery. „Fraction of Design Space Plots for Examining Model Robustness“. In: *Journal of Quality Technology* 37.3 (2005), S. 223–235. ISSN: 0022-4065. DOI: 10.1080/00224065.2005.11980323.
- [54] J. J. Borkowski, W. Limmun und B. Chomtee. „Factorwise variance dispersion graphs“. In: *Communications in Statistics - Theory and Methods* 51.23 (2022), S. 8427–8445. ISSN: 0361-0926. DOI: 10.1080/03610926.2021.1897144.

-
- [55] R. H. Myers, G. G. Vining, A. Giovannitti-Jensen und S. L. Myers. „Variance Dispersion Properties of Second-Order Response Surface Designs“. In: *Journal of Quality Technology* 24.1 (1992), S. 1–11. ISSN: 0022-4065. DOI: 10.1080/00224065.1992.11979368.
- [56] P. Schoonees, N. Le Roux und R. Coetzer. „Flexible Graphical Assessment of Experimental Designs in R : The vdg Package“. In: *Journal of Statistical Software* 74.3 (2016). DOI: 10.18637/jss.v074.i03.
- [57] G. E. P. Box und N. R. Draper. *Response surfaces, mixtures, and ridge analyses*. 2. ed. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2007. ISBN: 9780470053577. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2006043975-b.html>.
- [58] H. Ahn. „Central Composite Design for the Experiments with Replicate Runs at Factorial and Axial Points“. In: *Industrial Engineering* 349 (2015), S. 969–979.
- [59] D. A. Belsley. *Regression diagnostics: Identifying influential data and sources of collinearity*. Wiley series in probability and statistics. New York: Wiley, 2004. ISBN: 9780471725145. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226535>.
- [60] L. Fahrmeir, T. Kneib und S. Lang. *Regression: Modelle, Methoden und Anwendungen*. 2. Auflage. Statistik und ihre Anwendungen. Heidelberg und Berlin: Springer, 2009. ISBN: 978-3-642-01836-7. DOI: 10.1007/978-3-642-01837-4.
- [61] E. M. Monroe, R. Pan, C. M. Anderson-Cook, D. C. Montgomery und C. M. Borrór. „A generalized linear model approach to designing accelerated life test experiments“. In: *Quality and Reliability Engineering International* 27.4 (2011), S. 595–607. ISSN: 0748-8017. DOI: 10.1002/qre.1143.
- [62] E. M. Monroe, R. Pan, C. M. Anderson-Cook, D. C. Montgomery und C. M. Borrór. „Sensitivity Analysis of Optimal Designs for Accelerated Life Testing“. In: *Journal of Quality Technology* 42.2 (2010), S. 121–135. ISSN: 0022-4065. DOI: 10.1080/00224065.2010.11917811.
- [63] K. Seo und R. Pan. „ALTopt: An R Package for Optimal Experimental Design of Accelerated Life Testing“. In: *The R Journal* 7.2 (2015), S. 177. DOI: 10.32614/RJ-2015-029.

- [64] S. J. Walsh, L. Lu und C. M. Anderson-Cook. „I -optimal or G -optimal: Do we have to choose?“ In: *Quality Engineering* 36.2 (2024), S. 227–248. ISSN: 0898-2112. DOI: 10.1080/08982112.2023.2194963.
- [65] A. C. Atkinson, A. N. Donev und R. D. Tobias. *Optimum Experimental Designs, with SAS*. 1st. New York: Oxford University Press Inc, 2007. ISBN: 9780199296590.
- [66] P. Goos. „OMARS Designs for Factor Screening and Response Surface Experimentation in One Step: A Review“. In: *WIREs Computational Statistics* 17.2 (2025). ISSN: 1939-5108. DOI: 10.1002/wics.70018.
- [67] J. Núñez Ares und P. Goos. „Enumeration and Multicriteria Selection of Orthogonal Minimally Aliased Response Surface Designs“. In: *Technometrics* 62.1 (2020), S. 21–36. ISSN: 0040-1706. DOI: 10.1080/00401706.2018.1549103.
- [68] J. Cohen. *Statistical power analysis for the behavioral sciences*. Second edition. Hillsdale, NJ: Lawrence Erlbaum Associates Publishers, 1988. ISBN: 9781134742707. DOI: 10.4324/9780203771587.
- [69] M. H. Kutner, C. J. Nachtsheim, J. Neter und W. Li. *Applied Linear Statistical Models*. 5. ed. McGraw-Hill/Irwin series Operations and decision sciences. Boston, Mass.: McGraw-Hill Irwin, 2005. ISBN: 0072386886. URL: <http://www.loc.gov/catdir/bios/mh042/2004052447.html>.
- [70] C. E. McCulloch und S. R. Searle. *Generalized, linear, and mixed models*. A Wiley-Interscience publication. New York und Weinheim: Wiley, 2001. ISBN: 9780471193647. DOI: 59430.
- [71] M. Arndt, P. Mell und M. Dazer. „Generic effects of deviations from test design orthogonality on test power and regression modelling of Central-Composite Designs“. In: *Proceedings of the 16th International Probabilistic Safety Assessment and Management Conference (PSAM16)*. Bd. PSAM 16. Honolulu, HI, USA, 2022.
- [72] A. Khuri. *Response Surface Methodology and Related Topics*. 1st. World Scientific Publishing Co Pte Ltd, 2006. ISBN: 9789812564580.
- [73] G. E. P. Box und D. R. Cox. „An Analysis of Transformations“. In: *Journal of the Royal Statistical Society Series B: Statistical Methodology* 26.2 (1964), S. 211–243. ISSN: 1369-7412. DOI: 10.1111/j.2517-6161.1964.tb00553.x.

-
- [74] M. V. Wüthrich und M. Merz. *Statistical Foundations of Actuarial Learning and its Applications*. Cham: Springer International Publishing, 2023. ISBN: 978-3-031-12408-2. DOI: 10.1007/978-3-031-12409-9.
- [75] M. Modarres, M. Nuri-Amiri und C. Jackson. *Probabilistic physics of failure approach to reliability: Modeling, accelerated testing, prognosis and reliability assessment*. Performability engineering series. Beverly, MA und Hoboken, NJ: Scrivener Publishing und John Wiley & Sons Inc, 2017. ISBN: 9781119388630.
- [76] A. Kremer, L. Dücsö und B. Bertsche. „Reliability Prediction using Design of Experiments“. In: *Proceedings of the 30th European Safety and Reliability Conference and 15th Probabilistic Safety Assessment and Management Conference*. Hrsg. von P. Baraldi, F. Di Maio und E. Zio. Singapore: Research Publishing Services, 2020, S. 1501–1507. ISBN: 978-981-14-8593-0. DOI: 10.3850/978-981-14-8593-0{\textunderscore}3538-cd.
- [77] A. J. Dobson und A. G. Barnett. *An Introduction to Generalized Linear Models*. Fourth edition. Texts in statistical science. Boca Raton, FL: CRC Press, 2018. ISBN: 9781315182780. DOI: 10.1201/9781315182780.
- [78] J. Stufken und M. Yang. „Optimal Designs for Generalized Linear Models“. In: *Design and analysis of experiments*. Hrsg. von K. Hinkelmann. Bd. 3. Wiley series in probability and statistics. Hoboken, NJ: Wiley-Interscience, 2012, S. 137–164. ISBN: 9780470530689. DOI: 10.1002/9781118147634.ch4.
- [79] M. Aitkin und D. Clayton. „The Fitting of Exponential, Weibull and Extreme Value Distributions to Complex Censored Survival Data Using GLIM“. In: *Journal of the Royal Statistical Society Series C: Applied Statistics* 29.2 (1980), S. 156. ISSN: 0035-9254. DOI: 10.2307/2986301.
- [80] A. Kremer und B. Bertsche. „A Methodology for Consideration of Uncertainty in Lifetime Design of Experiments“. In: *2019 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2019, S. 1–6. ISBN: 978-1-5386-6554-1. DOI: 10.1109/RAMS.2019.8768906.
- [81] A. C. Rencher und G. B. Schaalje. *Linear models in statistics*. 2. ed. Hoboken, NJ: Wiley-Interscience, 2008. ISBN: 9780471754985. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2007024268-b.html>.

- [82] J. F. Lawless. *Statistical models and methods for lifetime data*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley-Interscience, 2003. ISBN: 0471372153. URL: <http://www.loc.gov/catdir/bios/wiley044/2002151805.html>.
- [83] D. Rasch und D. Schott. *Mathematical statistics*. Hoboken, NJ: John Wiley & Sons Inc, 2018. ISBN: 9781119385288.
- [84] L. J. Bain und M. Engelhardt. *Statistical Analysis of Reliability and Life-Testing Models*. Routledge, 2017. ISBN: 9780203738733. DOI: 10.1201/9780203738733.
- [85] M. Yang, B. Zhang und S. Huang. „Optimal designs for generalized linear models with multiple design variables“. In: *Statistica Sinica* 21.3 (2011), S. 1415–1430. ISSN: 10170405. DOI: 10.5705/ss.2009.115.
- [86] J. A. Nelder und R. W. M. Wedderburn. „Generalized Linear Models“. In: *Journal of the Royal Statistical Society. Series A (General)* 135.3 (1972), S. 370. ISSN: 00359238. DOI: 10.2307/2344614.
- [87] M. Arndt und M. Dazer. „Analysis of Efficiency in Response Surface Designs Considering Orthogonality Deviations and Cost Models“. In: *European Conference on Safety and Reliability (ESREL), 3rd September - 7th September 2023*. Hrsg. von M. P. Brito, T. Aven, P. Baraldi, M. Čepin und E. Zio. Singapore: Research Publishing Services, 2023, S. 1167–1174. ISBN: 978-981-18-8071-1. DOI: 10.3850/978-981-18-8071-1{\textunderscore}P160-cd.
- [88] E. Rittmaier, M. Arndt und M. Dazer. „Simulative Analysis of Statistical Power of Optimal Test Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–7. ISBN: 979-8-3503-6774-4. DOI: 10.1109/RAMS48127.2025.10935086.
- [89] A. N. Donev. „Design of experiments in the presence of errors in factor levels“. In: *Statistical Planning and Inference* 126.2 (2004), S. 569–585.
- [90] M. K. Ardakani, D. Das, S. S. Wulf und T. J. Robinson. „Estimation in Second-Order Models with Errors in the Factor Levels“. In: *Commun. in Statistics* 40.9 (2011), S. 1573–1590. DOI: 10.1080/03610921003637421.

-
- [91] M. Arndt und M. Dazer. *Power and Accuracy Characterization of Regression Models in The Presence of Orthogonality Deviations in CCDs*. In: *6th International Conference on Design of Experiments (ICODOE 2022)*. 2023. URL: <https://www.memphis.edu/msci/icodoe22/index.php>.
- [92] M. Arndt, P. Mell und M. Dazer. „Generic effects of deviations from test design orthogonality on test power and regression modelling of Central-Composite Designs“. In: *Probabilistic Safety Assessment and Management PSAM 16, June 26-July 1, 2022, Honolulu, Hawaii*. URL: <https://www.iapsam.org/PSAM16/papers/MA19-PSAM16.pdf>.
- [93] E. Zio. *The Monte Carlo simulation method for system reliability and risk analysis*. Springer series in reliability engineering. London: Springer, 2013. ISBN: 978-1-4471-4587-5. DOI: 10.1007/978-1-4471-4588-2.
- [94] P. Mell, M. Arndt und M. Dazer. „Non-orthogonality in test design: practical relevance of the theoretical concept in terms of regression quality and test plan efficiency“. In: *Proceedings of the Probabilistic Safety Assessment and Management Conference 2022 PSAM 16 (2022)*. URL: <https://www.iapsam.org/PSAM16/paper.php?ID=PH20>.
- [95] G. E. P. Box. „The Effects of Errors in the Factor Levels and Experimental Design“. In: *Technometrics* 5.2 (1963), S. 247–262. ISSN: 0040-1706. URL: <https://doi.org/10.2307/1266066>.
- [96] M. Arndt und M. Dazer. „Investigating Practical Orthogonality Deviations in RSM for Optimized Predictive Reliability Modeling“. In: *2024 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2024, S. 1–6. ISBN: 979-8-3503-0769-6. DOI: 10.1109/RAMS51492.2024.10457825.
- [97] M. Arndt, E. Rittmaier und M. Dazer. „Assessing the Extrapolation Variance of Non-Orthogonal Response Surface Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–6. ISBN: 979-8-3503-6774-4. DOI: 10.1109/RAMS48127.2025.10935022.
- [98] M. Arndt und M. Dazer. „Confidence Intervals in Optimized Response Surface Designs for Accelerated Lifetime Testing“. In: *35th European Safety and Reliability*, S. 867–874. DOI: 10.3850/978-981-94-3281-3\textunderscore ESREL-SRA-E2025-P2042-cd.

- [99] Bundesministerium der Finanzen. *AfA-Tabelle für die allgemein verwendbaren Anlagegüter (AfA-Tabelle AV): § 193ff AO , § 7 Abs 1 EStG.*
- [100] VDI-Gesellschaft Produkt- und Prozessgestaltung. *Beschaffung, Betrieb und Instandhaltung von Produktionsmitteln unter Anwendung von Life Cycle Costing (LCC): VDI 2884:2005-12.* 2005.
- [101] K. Ehrlenspiel und H. Meerkamm. *Integrierte Produktentwicklung: Denkabläufe, Methodeneinsatz, Zusammenarbeit.* 6., überarbeitete und erweiterte Auflage. Hanser eLibrary. München: Carl Hanser Verlag, 2017. ISBN: 9783446449084. DOI: 10.3139/9783446449084.
- [102] VDI-Gesellschaft Produkt- und Prozessgestaltung. *Kostenrechnung mit Maschinenstundensätzen; Begriffe, Bezeichnungen, Zusammenhänge: VDI 3258 Blatt 1:1962-10.* 1962.
- [103] N. T. Stevens und C. M. Anderson-Cook. „Design and analysis of confirmation experiments“. In: *Journal of Quality Technology* 51.2 (2019), S. 109–124. ISSN: 0022-4065. DOI: 10.1080/00224065.2019.1571344.
- [104] M. Arndt, W. Raither und M. Dazer. „Multivariate Damage-based Reliability Assessment of Toothed Belts for Vehicle Steering Systems“. In: *IEEE Transactions on Reliability* (2026), S. 1–13. DOI: 10.1109/TR.2026.3713009.
- [105] R. Perneder. *Handbuch Zahnriementchnik: Grundlagen, Berechnung, Anwendungen.* Berlin und Heidelberg: Springer, 2009. ISBN: 978-3-540-89321-9.
- [106] T. Nagel. *Zahnriemengetriebe: Eigenschaften, Normung, Berechnung, Gestaltung.* 1. Aufl. München und Wien: Hanser, 2008. ISBN: 978-3-446-41380-1.
- [107] B. R. Englert, S. E. Rigdon, C. M. Borror, D. C. Montgomery und R. Pan. „Optimal Design for Multifactor Life Testing Experiments for Exponentially Distributed Lifetimes“. In: *Frontiers in Statistical Quality Control* 10. Hrsg. von H.-J. Lenz, W. Schmid und P.-T. Wilrich. SpringerLink Bücher. Heidelberg und s.l.: Physica-Verlag HD und Imprint Physica, 2012, S. 303–317. ISBN: 978-3-7908-2845-0. DOI: 10.1007/978-3-7908-2846-7{\textunderscore}20.

Anhang A Sensitivitätsanalyse

In diesem Anhang sind die detaillierten Ergebnisse der Sensitivitätsanalyse für die verschiedenen Parameterkombinationen tabellarisch zusammengefasst. Die Tabellen zeigen die Power des Tests in Abhängigkeit von den Störfaktoren C (Zentrums-Läufe) und D (Stern-Läufe).

Tabelle A1: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9453	0.7362	0.6281	0.7168	0.5718	-	0.9935
power max	0.9905	0.8273	0.7994	0.8269	0.7495	-	1.0000
power min	0.7811	0.5999	0.3734	0.5517	0.3259	-	0.9451
Power (+)	0.9357	0.7304	0.6127	0.7163	0.5592	-	0.9949
Power (-)	0.9508	0.7353	0.6495	0.7148	0.5766	-	0.9909
Power (α)	0.9058	0.7022	0.6006	0.7086	0.5164	-	0.9939
Power ($-\alpha$)	0.9485	0.7162	0.7044	0.7046	0.5656	-	0.9826
a	0.3958	0.0298	0.3543	0.1940	0.3241	-	0.2432
b	0.2848	0.0084	0.0789	0.3961	0.7657	-	0.0546
e	0.9380	0.1534	1.6411	0.2953	0.7639	-	0.0440
f	0.0115	0.0411	2.6158	0.0315	0.0551	-	0.0403
g	1.1583	1.8408	2.3250	1.9725	2.7091	-	0.2193
h	0.6492	0.6492	1.8966	1.5782	2.2201	-	0.1176
aa	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0479
bb	0.0299	0.0299	0.0000	0.1089	0.0000	-	0.0000
ee	0.0988	0.0988	0.0797	0.0000	0.0000	-	0.0000
ff	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
gg	0.1851	0.1851	0.0672	0.1405	0.2111	-	0.0398
hh	0.0913	0.0913	0.1066	0.0861	0.2561	-	0.0179
ab	0.0000	0.0000	0.1039	0.0647	0.2700	-	0.0162
ae	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
af	0.0000	0.0000	0.0873	0.1034	0.0000	-	0.0197
ah	0.0375	0.0375	0.0000	0.0694	0.0000	-	0.0297
ag	0.1003	0.1003	0.0000	0.0000	0.0000	-	0.0625
be	0.0000	0.0000	0.0000	0.0850	0.0000	-	0.0284
bf	0.0000	0.0000	0.0948	0.0000	0.0000	-	0.0000
bh	0.0606	0.0606	0.0000	0.0000	0.0000	-	0.0000
bg	0.0434	0.0434	0.0000	0.0912	0.0934	-	0.0241
ef	0.0000	0.0000	0.3848	0.0000	0.0941	-	0.0000
eh	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
eg	0.0916	0.0916	0.1936	0.0000	0.0203	-	0.0203
fh	0.0000	0.0000	0.1073	0.0000	0.0000	-	0.0000
fg	0.0000	0.0000	0.0000	0.0000	0.0287	-	0.0287
gh	0.1616	0.1616	0.0000	0.0822	0.0000	-	0.0000
-	-	-	-	-	-	Lack of fit	-

Tabelle A2: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9518	0.7985	0.6387	0.7208	0.6531	-	0.9957
power max	0.9933	0.8573	0.8181	0.8411	0.7769	-	1.0000
power min	0.7685	0.6603	0.4066	0.5247	0.4672	-	0.9667
Power (+)	0.9444	0.7954	0.6178	0.7225	0.6561	-	0.9970
Power (-)	0.9556	0.7993	0.6589	0.7189	0.6485	-	0.9946
Power (α)	0.9215	0.7834	0.5775	0.7248	0.6577	-	0.9995
Power ($-\alpha$)	0.9533	0.7944	0.6938	0.7146	0.6361	-	0.9929
a	0.5743	0.0539	0.4599	0.2257	0.1838	-	0.1461
b	0.2434	0.0624	0.1787	0.5291	0.1289	-	0.0400
e	0.9031	0.1628	1.5864	0.2921	0.4940	-	0.0366
f	0.0191	0.0288	2.6353	0.0388	0.0186	-	0.0286
g	1.0501	1.4474	2.1712	1.9654	2.3119	-	0.1445
h	0.5934	1.1095	1.8017	1.5105	1.8671	-	0.0673
aa	0.0000	0.0000	0.1083	0.0000	0.0000	-	0.0162
bb	0.0000	0.0000	0.0000	0.1100	0.1570	-	0.0119
ee	0.1020	0.0000	0.1373	0.0875	0.0000	-	0.0000
ff	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0000
gg	0.1920	0.1289	0.1452	0.1150	0.1467	-	0.0312
hh	0.1089	0.2101	0.1396	0.1850	0.2392	-	0.0099
ab	0.0000	0.0972	0.1019	0.0906	0.0000	-	0.0267
ae	0.0000	0.0000	0.1122	0.0672	0.0000	-	0.0000
af	0.0000	0.0000	0.0000	0.0853	0.0000	-	0.0000
ah	0.0775	0.0000	0.0000	0.0000	0.0000	-	0.0239
ag	0.1522	0.0000	0.0000	0.1053	0.0000	-	0.0286
be	0.0356	0.0000	0.0000	0.0591	0.0000	-	0.0000
bf	0.0000	0.0000	0.0000	0.0703	0.0000	-	0.0117
bh	0.0400	0.0000	0.0000	0.0000	0.0797	-	0.0111
bg	0.0622	0.0934	0.0000	0.0603	0.1091	-	0.0000
ef	0.0441	0.0806	0.3800	0.0888	0.0000	-	0.0311
eh	0.0791	0.0000	0.0747	0.0000	0.0000	-	0.0000
eg	0.0738	0.0000	0.0000	0.1994	0.0972	-	0.0000
fh	0.0000	0.0000	0.0000	0.0000	0.0000	-	0.0152
fg	0.0000	0.0000	0.0775	0.0000	0.0000	-	0.0117
gh	0.1287	0.1422	0.0000	0.0906	0.0841	-	0.0164
-	-	-	-	-	-	Lack of fit	-

Tabelle A3: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = +1, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9540	0.7986	0.7074	-	-	-	0.9975
power max	0.9989	0.8729	0.8406	-	-	-	1.0030
power min	0.7860	0.6751	0.4696	-	-	-	0.9723
Power (+)	0.9487	0.7962	0.6911	-	-	-	0.9976
Power (-)	0.9545	0.7996	0.7428	-	-	-	0.9967
Power (α)	0.9262	0.7884	0.7104	-	-	-	0.9956
Power ($-\alpha$)	0.9426	0.7981	0.8568	-	-	-	0.9930
a	0.7210	0.1280	0.4171	-	-	-	0.0960
b	0.3130	0.0177	0.7838	-	-	-	0.0204
e	0.8543	0.0783	1.3897	-	-	-	0.0216
f	0.0265	0.1084	2.2880	-	-	-	0.0300
g	0.9984	1.3910	1.8966	-	-	-	0.1050
h	0.5009	1.1444	1.4085	-	-	-	0.0433
aa	0.0000	0.0000	0.0000	-	-	-	0.0209
bb	0.0590	0.0823	0.0411	-	-	-	0.0000
ee	0.0766	0.0000	0.0514	-	-	-	0.0000
ff	0.0000	0.0000	0.2129	-	-	-	0.0000
gg	0.1704	0.0802	0.1430	-	-	-	0.0365
hh	0.1141	0.1227	0.1461	-	-	-	0.0000
ab	0.0742	0.0920	0.1405	-	-	-	0.0178
ae	0.0642	0.0000	0.1030	-	-	-	0.0000
af	0.0000	0.0000	0.0814	-	-	-	0.0125
ah	0.0739	0.0000	0.0545	-	-	-	0.0112
ag	0.1261	0.0000	0.0000	-	-	-	0.0366
be	0.0000	0.0000	0.0414	-	-	-	0.0000
bf	0.0000	0.0000	0.0483	-	-	-	0.0000
bh	0.0558	0.0000	0.0000	-	-	-	0.0000
bg	0.0000	0.0000	0.0530	-	-	-	0.0097
ef	0.0000	0.0820	0.4002	-	-	-	0.0131
eh	0.0000	0.0000	0.0000	-	-	-	0.0125
eg	0.0636	0.0000	0.0789	-	-	-	0.0000
fh	0.0000	0.0000	0.0911	-	-	-	0.0000
fg	0.0000	0.0830	0.0000	-	-	-	0.0231
gh	0.1339	0.1452	0.1148	-	-	-	0.0100
-	-	-	-	Lack of fit	Lack of fit	Lack of fit	-

Tabelle A4: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9902	0.7454	0.6374	0.7229	-	0.7645	0.9968
power max	0.9981	0.8382	0.7916	0.8411	-	0.9125	1.0000
power min	0.9588	0.6174	0.3968	0.5881	-	0.3337	0.9794
Power (+)	0.9843	0.7426	0.6232	0.7237	-	0.7862	0.9970
Power (-)	0.9934	0.7447	0.6596	0.7238	-	0.7243	0.9958
Power (α)	0.9668	0.7285	0.6175	0.7294	-	0.7777	0.9950
Power ($-\alpha$)	0.9924	0.7346	0.7206	0.7296	-	0.6029	0.9916
a	0.0155	0.0621	0.2866	0.2087	-	4.7500	0.0968
b	0.0000	0.0499	0.0228	0.4204	-	1.5342	0.0237
e	0.3993	0.2315	1.6512	0.2988	-	0.2277	0.0097
f	0.0000	0.0261	2.6397	0.0000	-	0.0597	0.0174
g	0.1461	1.6970	2.2654	1.9055	-	1.7045	0.0962
h	0.0774	1.3724	1.7403	1.3905	-	1.2919	0.0420
aa	0.0000	0.0819	0.0000	0.0000	-	0.5453	0.0177
bb	0.0000	0.1413	0.0635	0.1255	-	0.3322	0.0000
ee	0.0842	0.1212	0.0000	0.0986	-	0.1128	0.0000
ff	0.0000	0.0000	0.3990	0.0000	-	0.0000	0.0000
gg	0.0211	0.0681	0.1503	0.0726	-	0.0915	0.0089
hh	0.0000	0.0913	0.1597	0.1189	-	0.1559	0.0000
ab	0.0000	0.0000	0.0000	0.1508	-	0.0719	0.0125
ae	0.0175	0.0000	0.0000	0.0000	-	0.1094	0.0000
af	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0000
ah	0.0000	0.0000	0.0000	0.0000	-	0.1788	0.0116
ag	0.0000	0.0000	0.0000	0.0000	-	0.3075	0.0219
be	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0141
bf	0.0000	0.0884	0.0000	0.0000	-	0.0738	0.0000
bh	0.0000	0.0000	0.0000	0.0000	-	0.1050	0.0000
bg	0.0000	0.0000	0.0000	0.1005	-	0.1244	0.0147
ef	0.0000	0.0000	0.3547	0.0000	-	0.0862	0.0000
eh	0.0000	0.0000	0.0841	0.0000	-	0.0000	0.0000
eg	0.0441	0.0000	0.0000	0.0000	-	0.0000	0.0000
fh	0.0000	0.0000	0.0000	0.0000	-	0.0000	0.0000
fg	0.0000	0.0000	0.0000	0.0000	-	0.1187	0.0159
gh	0.0000	0.0000	0.0000	0.0995	-	0.0750	0.0000
-	-	-	-	-	Lack of fit	-	-

Tabelle A5: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9905	0.8010	0.6464	0.7278	0.7582	0.7765	0.9980
power max	0.9986	0.8732	0.7996	0.8508	0.8625	0.9315	1.0000
power min	0.9552	0.6885	0.4066	0.5683	0.6378	0.5508	0.9853
Power (+)	0.9848	0.7978	0.6275	0.7258	0.7535	0.7942	0.9981
Power (-)	0.9941	0.8076	0.6660	0.7273	0.7674	0.7376	0.9974
Power (α)	0.9694	0.8007	0.5947	0.7158	0.7564	0.7714	0.9970
Power ($-\alpha$)	0.9956	0.8282	0.7037	0.7199	0.7958	0.6113	0.9950
a	0.0027	0.1427	0.4640	0.2446	0.0495	4.0624	0.0608
b	0.0099	0.0559	0.0418	0.5323	0.3258	1.0318	0.0137
e	0.4114	0.0532	1.5052	0.2067	0.2528	0.1887	0.0100
f	0.0035	0.0072	2.5420	0.0221	0.0221	0.0399	0.0061
g	0.1383	1.4069	2.2154	1.9565	1.8537	1.5771	0.0754
h	0.0706	0.9461	1.7469	1.3671	1.2025	1.2268	0.0318
aa	0.0000	0.0000	0.0000	0.0000	0.0000	0.5061	0.0097
bb	0.0000	0.0000	0.0000	0.1137	0.0656	0.0787	0.0000
ee	0.0759	0.1234	0.1083	0.0887	0.1299	0.0926	0.0000
ff	0.0115	0.0000	0.0000	0.0513	0.0824	0.0000	0.0000
gg	0.0147	0.0860	0.0911	0.1219	0.1251	0.1168	0.0178
hh	0.0000	0.1129	0.1642	0.1101	0.0907	0.1474	0.0000
ab	0.0000	0.0000	0.0000	0.1018	0.0000	0.1845	0.0000
ae	0.0000	0.0000	0.0000	0.0000	0.0000	0.1461	0.0112
af	0.0000	0.0000	0.0000	0.0000	0.0000	0.0823	0.0097
ah	0.0000	0.0000	0.0000	0.0967	0.0000	0.1739	0.0113
ag	0.0000	0.0000	0.0000	0.1195	0.0000	0.2064	0.0219
be	0.0000	0.0000	0.0000	0.0000	0.0693	0.0000	0.0000
bf	0.0000	0.0000	0.1167	0.0889	0.0000	0.0717	0.0000
bh	0.0000	0.0000	0.0000	0.0000	0.0929	0.0777	0.0000
bg	0.0000	0.1098	0.0000	0.0000	0.0000	0.0895	0.0000
ef	0.0000	0.0767	0.3902	0.0000	0.0000	0.0000	0.0000
eh	0.0187	0.0000	0.1736	0.0000	0.0000	0.0945	0.0000
eg	0.0553	0.0767	0.0000	0.0836	0.0000	0.0000	0.0000
fh	0.0000	0.0000	0.1789	0.0000	0.0000	0.0000	0.0000
fg	0.0178	0.0000	0.0964	0.1392	0.0000	0.0000	0.0000
gh	0.0216	0.1333	0.0000	0.1445	0.0000	0.1073	0.0125

Tabelle A6: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = 0, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9906	0.8001	0.7253	0.7307	0.7711	0.8209	-
power max	1.0000	0.8858	0.8277	0.8590	0.8612	0.9535	-
power min	0.9556	0.6939	0.4813	0.5676	0.6473	0.5788	-
Power (+)	0.9846	0.7993	0.7053	0.7301	0.7680	0.8377	-
Power (-)	0.9932	0.8053	0.7401	0.7247	0.7740	0.7956	-
Power (α)	0.9653	0.8030	0.6554	0.7123	0.7620	0.8464	-
Power ($-\alpha$)	0.9897	0.8198	0.7537	0.6969	0.7791	0.7271	-
a	0.0314	0.1339	0.2048	0.2370	0.0789	2.8293	-
b	0.0083	0.0793	0.5931	0.6122	0.1142	0.6457	-
e	0.4076	0.1149	1.1845	0.2977	0.1985	0.1012	-
f	0.0045	0.0841	2.2052	0.0770	0.0359	0.0660	-
g	0.1364	1.4107	1.7065	1.8462	1.5774	1.2572	-
h	0.0775	0.9693	1.3760	1.3693	1.2351	1.0155	-
aa	0.0000	0.0057	0.2197	0.0000	0.0000	0.2441	-
bb	0.0000	0.0024	0.0834	0.0852	0.0000	0.0754	-
ee	0.0564	0.0680	0.0000	0.1171	0.0619	0.0659	-
ff	0.0000	0.0593	0.1670	0.0000	0.0000	0.0000	-
gg	0.0276	0.0926	0.1028	0.0635	0.1037	0.0591	-
hh	0.0239	0.0714	0.1634	0.1792	0.1168	0.1448	-
ab	0.0000	0.0000	0.0861	0.1619	0.0000	0.1661	-
ae	0.0000	0.0194	0.0000	0.0000	0.0555	0.0952	-
af	0.0000	0.0000	0.0614	0.0000	0.0000	0.0000	-
ah	0.0192	0.0641	0.0686	0.0000	0.0000	0.1520	-
ag	0.0000	0.0000	0.0000	0.0000	0.0000	0.1133	-
be	0.0000	0.0000	0.0000	0.0000	0.0427	0.0000	-
bf	0.0158	0.0403	0.1277	0.0000	0.0000	0.0000	-
bh	0.0000	0.0000	0.0000	0.0000	0.1120	0.0000	-
bg	0.0000	0.0000	0.1030	0.1050	0.0000	0.0000	-
ef	0.0000	0.0000	0.3220	0.0000	0.0000	0.1180	-
eh	0.0208	0.0734	0.0000	0.1659	0.0702	0.0000	-
eg	0.0411	0.1172	0.0798	0.0000	0.0000	0.0808	-
fh	0.0000	0.0762	0.0780	0.0000	0.0000	0.0000	-
fg	0.0000	0.0000	0.1998	0.1400	0.0608	0.0000	-
gh	0.0000	0.0462	0.0000	0.0772	0.1202	0.1314	-
-	-	-	-	-	-	-	Lack of fit

Tabelle A7: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = +1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	-	0.6450	0.7284	0.7145	0.7727	-
power max	1.0000	-	0.7837	0.8358	0.8097	1.0000	-
power min	0.9742	-	0.3734	0.5875	0.4275	0.9829	-
Power (+)	0.9909	-	0.6216	0.7277	0.7073	0.7909	-
Power (-)	0.9968	-	0.6612	0.7291	0.7158	0.7401	-
Power (α)	0.9783	-	0.5599	0.7263	0.6791	0.7870	-
Power ($-\alpha$)	0.9948	-	0.6718	0.7303	0.7031	0.6435	-
a	0.0000	-	0.3510	0.1266	0.8831	4.5897	-
b	0.0013	-	0.0509	0.4785	1.0897	1.7627	-
e	0.2539	-	1.5429	0.2870	0.3910	0.2779	-
f	0.0013	-	2.5994	0.0812	0.0105	0.0011	-
g	0.0695	-	2.3087	1.9936	1.9692	1.7285	-
h	0.0302	-	1.6869	1.3665	1.3721	1.1623	-
aa	0.0000	-	0.0000	0.0000	0.1855	0.5719	-
bb	0.0000	-	0.0000	0.1214	0.2005	0.3038	-
ee	0.0476	-	0.0000	0.1196	0.1032	0.1125	-
ff	0.0000	-	0.0000	0.0000	0.0000	0.0000	-
gg	0.0000	-	0.1937	0.1661	0.2318	0.1463	-
hh	0.0219	-	0.1743	0.1704	0.2036	0.0694	-
ab	0.0000	-	0.0000	0.0000	0.2447	0.2175	-
ae	0.0000	-	0.0000	0.0000	0.0000	0.2034	-
af	0.0000	-	0.0000	0.0000	0.1066	0.0000	-
ah	0.0000	-	0.0816	0.0000	0.0000	0.1350	-
ag	0.0000	-	0.0000	0.0000	0.0966	0.3544	-
be	0.0000	-	0.1275	0.0000	0.0000	0.0000	-
bf	0.0000	-	0.0000	0.0000	0.0000	0.1050	-
bh	0.0000	-	0.1672	0.0000	0.0000	0.0000	-
bg	0.0194	-	0.1172	0.0939	0.2109	0.0000	-
ef	0.0000	-	0.3784	0.0000	0.0631	0.0000	-
eh	0.0000	-	0.2038	0.0000	0.0000	0.0775	-
eg	0.0303	-	0.0000	0.0000	0.0000	0.0000	-
fh	0.0000	-	0.0000	0.0000	0.0634	0.0000	-
fg	0.0153	-	0.1762	0.0000	0.0000	0.0000	-
gh	0.0000	-	0.0000	0.0000	0.0628	0.0000	-
-	-	Lack of fit	-	-	-	-	Lack of fit

Tabelle A8: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = 0$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	0.8007	0.6497	-	0.7877	0.7861	0.9984
power max	1.0000	0.9077	0.8025	-	0.8681	0.9176	1.0000
power min	0.9771	0.7010	0.4032	-	0.6628	0.4751	0.9878
Power (+)	0.9912	0.7980	0.6315	-	0.7796	0.8027	0.9988
Power (-)	0.9968	0.8035	0.6766	-	0.7920	0.7578	0.9981
Power (α)	0.9796	0.7937	0.6208	-	0.7546	0.8030	0.9999
Power ($-\alpha$)	0.9953	0.8091	0.7482	-	0.7896	0.6759	0.9978
a	0.0060	0.0652	0.4519	-	0.0098	3.6725	0.0433
b	0.0183	0.0519	0.0116	-	0.3922	1.2550	0.0097
e	0.2406	0.1823	1.5806	-	0.1582	0.1947	0.0090
f	0.0000	0.0559	2.7147	-	0.0286	0.0000	0.0080
g	0.0803	1.4901	2.3085	-	1.5045	1.4975	0.0557
h	0.0313	0.9934	1.6549	-	1.0501	1.1319	0.0213
aa	0.0000	0.0000	0.0000	-	0.0000	0.3338	0.0000
bb	0.0000	0.0000	0.0686	-	0.0000	0.1913	0.0000
ee	0.0457	0.1627	0.1149	-	0.1524	0.1218	0.0050
ff	0.0000	0.0970	0.0000	-	0.0000	0.0000	0.0000
gg	0.0000	0.0000	0.1214	-	0.1445	0.0976	0.0082
hh	0.0000	0.0817	0.1258	-	0.0907	0.1776	0.0000
ab	0.0242	0.0000	0.0000	-	0.0000	0.0000	0.0131
ae	0.0000	0.0000	0.0000	-	0.0000	0.1000	0.0000
af	0.0000	0.0000	0.0000	-	0.0998	0.0000	0.0056
ah	0.0000	0.0000	0.0000	-	0.0000	0.1419	0.0084
ag	0.0000	0.0778	0.0000	-	0.0000	0.2569	0.0169
be	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0072
bf	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
bh	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
bg	0.0000	0.0772	0.0000	-	0.0842	0.0000	0.0000
ef	0.0000	0.1550	0.4475	-	0.0000	0.0000	0.0000
eh	0.0000	0.0000	0.0000	-	0.0000	0.0803	0.0000
eg	0.0236	0.0812	0.1231	-	0.0000	0.0000	0.0097
fh	0.0000	0.0000	0.0000	-	0.0000	0.0000	0.0000
fg	0.0000	0.0000	0.2075	-	0.0000	0.0000	0.0081
gh	0.0000	0.0600	0.1353	-	0.0711	0.0000	0.0084
-	-	-	-	Lack of fit	-	-	-

Tabelle A9: Ergebnisse der Sensitivitätsanalyse für Konfiguration $C = -1, D = -1$

Metrik	Power β_0	Power β_1	Power β_2	Power β_{12}	Power β_{11}	Power β_{22}	Power Model
power intercept value	0.9949	0.8035	-	0.7330	-	0.8378	0.9990
power max	1.0000	0.8784	-	0.8544	-	0.9286	1.0000
power min	0.9753	0.7101	-	0.5842	-	0.6034	0.9953
Power (+)	0.9918	0.7998	-	0.7345	-	0.8424	0.9990
Power (-)	0.9967	0.8031	-	0.7286	-	0.8177	0.9990
Power (α)	0.9828	0.7819	-	0.7297	-	0.8111	0.9989
Power ($-\alpha$)	0.9969	0.7912	-	0.7130	-	0.7411	0.9989
a	0.0010	0.0699	-	0.1136	-	2.4390	0.0192
b	0.0038	0.0659	-	0.7811	-	0.8272	0.0055
e	0.2297	0.1238	-	0.2768	-	0.0821	0.0063
f	0.0077	0.0349	-	0.0462	-	0.1113	0.0096
g	0.0584	1.2813	-	1.8702	-	1.2301	0.0336
h	0.0427	1.0310	-	1.2671	-	0.8845	0.0125
aa	0.0000	0.0000	-	0.0613	-	0.2086	0.0000
bb	0.0000	0.0000	-	0.1732	-	0.1142	0.0000
ee	0.0369	0.0706	-	0.0745	-	0.0000	0.0000
ff	0.0000	0.0000	-	0.0000	-	0.0000	0.0000
gg	0.0000	0.1056	-	0.1212	-	0.1036	0.0000
hh	0.0000	0.0931	-	0.1762	-	0.1711	0.0082
ab	0.0000	0.0000	-	0.0000	-	0.1048	0.0000
ae	0.0000	0.0000	-	0.0761	-	0.0000	0.0000
af	0.0000	0.0658	-	0.0000	-	0.0000	0.0000
ah	0.0123	0.0000	-	0.0000	-	0.1023	0.0000
ag	0.0000	0.0789	-	0.0000	-	0.1142	0.0000
be	0.0000	0.0000	-	0.0798	-	0.0000	0.0000
bf	0.0123	0.0000	-	0.0101	-	0.1023	0.0000
bh	0.0177	0.0000	-	0.0000	-	0.0000	0.0000
bg	0.0183	0.0000	-	0.0000	-	0.0983	0.0000
ef	0.0123	0.0000	-	0.0000	-	0.1023	0.0000
eh	0.0181	0.0123	-	0.0000	-	0.0000	0.0000
eg	0.0208	0.0000	-	0.0000	-	0.0000	0.0000
fh	0.0000	0.0000	-	0.0000	-	0.0000	0.0073
fg	0.0177	0.0714	-	0.1136	-	0.0670	0.0000
gh	0.0000	0.0000	-	0.1120	-	0.0848	0.0000
-	-	-	Lack of fit	-	Lack of fit	-	-

Anhang B Orthogonalitäts-Analysen der Design-Modifikationen

In diesem Anhang sind ergänzende Visualisierungen und Analysen zur Bewertung der geometrischen Design-Modifikationen bzw. Orthogonalitäts-Abweichungen aufgeführt.

Anhang B.1 Orthogonalitäts-Analysen aus Abschnitt 4.2.3

Tabelle B1: Simulationsergebnisse: Schätzvarianz (MSE) der einzelnen Koeffizienten bei $\text{SNR} = 2,4$.

Szenario (Störfall)	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	3,09	3,10	3,17	6,17	3,13	3,11
Fall I: Shift (−20 %)	3,05	3,57	3,15	6,20	4,15	3,17
Fall I: Shift (+20 %)	3,07	2,94	3,14	6,37	2,21	3,06
Fall I: FC	3,06	3,82	3,10	6,30	4,61	3,21
Fall II: Korrelation (leicht)	3,06	3,17	3,07	6,22	3,13	3,12
Fall II: Korrelation (stark)	3,10	3,59	3,01	5,21	3,83	3,44
Fall III: Scatter (± 10 %)	3,04	3,18	2,98	6,20	3,27	2,62
Fall IV: SP	3,18	5,29	3,07	6,17	5,46	3,47
Fall IV: ZP	3,53	3,09	3,13	6,29	3,24	3,25

Algorithmus zur Berechnung der Exposure-Area

Tabelle B2: Simulationsergebnisse: Durchschnittliche Trennschärfe-Änderung ($\Delta power$) der Koeffizienten. Ein negatives Vorzeichen indiziert einen Verlust, ein positives Vorzeichen einen Gewinn an $power$ verglichen zur Referenz (Basis CCD)

Szenario (Störfall)	$power_{\beta_0}$	$power_{\beta_1}$	$power_{\beta_2}$	$power_{\beta_{12}}$	$power_{\beta_{11}}$	$power_{\beta_{22}}$
Referenz (Orthogonal)	—	—	—	—	—	—
Fall I: Shift (−20 %)	±0,0 %	−0,9 %	−0,0 %	±0,0 %	−4,5 %	−0,1 %
Fall I: Shift (+20 %)	−0,0 %	+0,3 %	−0,0 %	−0,0 %	+4,6 %	−0,1 %
Fall I: FC	±0,0 %	−1,4 %	−0,1 %	+0,1 %	−6,7 %	−0,2 %
Fall II: Korrelation (leicht)	±0,0 %	−0,1 %	−0,0 %	+0,1 %	+0,1 %	−0,0 %
Fall II: Korrelation (stark)	±0,0 %	−1,2 %	+0,3 %	+3,3 %	−3,1 %	−1,5 %
Fall III: Scatter (±10 %)	±0,0 %	−0,1 %	+0,4 %	+0,2 %	−1,2 %	+2,8 %
Fall IV: SP	±0,0 %	−4,4 %	−0,1 %	−0,3 %	−10,6 %	−1,5 %
Fall IV: ZP	−0,0 %	−0,3 %	−0,2 %	−0,8 %	−1,3 %	−0,9 %

Tabelle B3: Simulationsergebnisse: Relativer systematischer Schätzfehler (Bias) der einzelnen Koeffizienten in Prozent bezogen auf ihren Nominalwert bei $SNR = 2,4$.

Szenario (Störfall)	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Referenz (Orthogonal)	+0,05 %	−0,01 %	−0,06 %	−0,45 %	+0,17 %	+0,05 %
Fall I: Shift (−20 %)	+0,04 %	−0,00 %	−0,09 %	−0,06 %	−0,02 %	+0,31 %
Fall I: Shift (+20 %)	+0,01 %	−0,11 %	+0,05 %	−0,24 %	+0,08 %	−0,00 %
Fall I: FC	+0,08 %	+0,13 %	−0,02 %	−0,25 %	+0,13 %	−0,13 %
Fall II: Korrelation (leicht)	−0,08 %	+0,13 %	+0,08 %	−0,19 %	−0,03 %	−0,23 %
Fall II: Korrelation (stark)	−0,08 %	+0,01 %	−0,27 %	+0,55 %	−0,71 %	+0,17 %
Fall III: Scatter (±10 %)	+0,02 %	+0,09 %	+0,19 %	+0,14 %	+0,10 %	+0,09 %
Fall IV: SP	−0,03 %	+0,14 %	+0,01 %	−0,56 %	−0,57 %	−0,07 %
Fall IV: ZP	−0,05 %	−0,13 %	−0,20 %	+0,01 %	+0,13 %	+0,07 %

Algorithm 1 Algorithmische Identifikation der Anker-Exposition (*Exposure-Area*)

Require: Basis-Design $\mathbf{X}_{\text{base}}$, polynomialer Prognosevektor $f(x_{\text{pr}})$, diskreter Suchraum $\mathcal{X}$, Anzahl umzuwidmender APs n_{AP} , relative Toleranzmarge q

- 1: $\nu_{\min} \leftarrow \infty$ ▷ Initialisierung der minimalen Prädiktionsvarianz
- 2: $\mathcal{C} \leftarrow \text{Kombinationen}(\mathcal{X}, n_{\text{AP}})$ ▷ Menge aller möglichen AP-Kombinationen
- 3: $\mathbf{V} \leftarrow$ Array der Länge $|\mathcal{C}|$ zur Speicherung der Varianzen
- // Phase 1: Exhaustive Evaluierung der SPV im Prognosepunkt
- 4: **for each** $C_i \in \mathcal{C}$ **do**
- 5: $\mathbf{X}_{\text{aug}} \leftarrow \mathbf{X}_{\text{base}} \cup C_i$ ▷ Augmentierung des Designs
- 6: $\mathbf{M}_i \leftarrow \mathbf{X}_{\text{aug}}^\top \mathbf{X}_{\text{aug}}$ ▷ Informationsmatrix
- 7: $\nu_i \leftarrow N \cdot f(x_{\text{pr}})^\top \mathbf{M}_i^{-1} f(x_{\text{pr}})$ ▷ Berechnung der SPV gem. Gl. X.X
- 8: $\mathbf{V}[i] \leftarrow \nu_i$
- 9: **if** $\nu_i < \nu_{\min}$ **then**
- 10: $\nu_{\min} \leftarrow \nu_i$ ▷ Registrierung des absoluten Minimums
- 11: **end if**
- 12: **end for**
- // Phase 2: Filterung und Konstruktion des Toleranzraums
- 13: $\nu_{\text{thresh}} \leftarrow \nu_{\min} \cdot (1 + q)$ ▷ Definition der oberen Toleranzschranke
- 14: $\mathcal{X}_{\text{exposure}} \leftarrow \emptyset$
- 15: **for each** $C_i \in \mathcal{C}$ **do**
- 16: **if** $\mathbf{V}[i] \leq \nu_{\text{thresh}}$ **then**
- 17: $\mathcal{X}_{\text{exposure}} \leftarrow \mathcal{X}_{\text{exposure}} \cup C_i$ ▷ Akkumulation valider Stützstellen
- 18: **end if**
- 19: **end for**

Ensure: Toleranzraum $\mathcal{X}_{\text{exposure}}$ (Menge aller zulässigen geometrischen Verortungen)




Abbildung B1: Laufende Konvergenz der Trennschärfe für alle Modellparameter. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar.




Abbildung B2: Konvergenz der OLS-Parameterschätzwerte ($\hat{\beta}_i$). Alle Modelle erweisen sich unabhängig von der geometrischen Verzerrung als erwartungstreu. Die Schätzungen stabilisieren sich bei der $n_{MC} = 10^4$ reproduzierbar.




Abbildung B3: Relative Häufigkeiten der in der Simulation ermittelten p -Werte der Signifikanztests.




Abbildung B4: Korrelierende Metriken zur prozentualen Trennschärfe-Änderung ($\Delta power$ [%]) über alle Koeffizienten und Szenarien ergänzend zu Abbildung 4.8.

Anhang B.2 Szenarien bei Arbeitspunkt SNR= 1




Abbildung B5: Güte der Schätzer (MSE) für SNR = 1.




Abbildung B6: Trennschärfe mit 95 %-Konfidenzintervallen in Abhängigkeit der Stör-szenarien für SNR = 1.

Anhang B.3 Effizienzanalysen aus Abschnitt 4.5.2

Tabelle B4: Relativer systematischer Schätzfehler (Bias) in Prozent bei GLLW-Schätzung (Weibull-Modell).

Szenario	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_{12}$	$\hat{\beta}_{11}$	$\hat{\beta}_{22}$
Basis CCD	+0,15 %	−0,08 %	+0,10 %	−0,24 %	+13,73 %	+12,79 %
CCD _{−AP}	+0,24 %	+3,72 %	+3,39 %	+6,82 %	+23,17 %	+22,10 %
EmALT	−0,00 %	+19,55 %	−39,14 %	−47,84 %	+46,51 %	−53,26 %




Abbildung B7: KPI ggü. D -Effizienz aller Koeffizienten.




Abbildung B8: Aggregierte p -Wert Histogramme der MLE-Signifikanztests. Die stochastische Auswertung liefert artefaktfreie Verteilungen.