

# **Entwicklung Effizienter Multivariater Lebensdauertests**

Efficient Multivariate Lifetime Testing

Der Fakultät Konstruktions-, Produktions- und Fahrzeugtechnik  
der Universität Stuttgart  
zur Erlangung der Würde eines Doktor-Ingenieurs (Dr.-Ing.) vorgelegte  
Abhandlung

von  
**Marco Arndt, M.Sc.**  
aus Ravensburg

Hauptberichter: PD Dr.-Ing. habil. Martin Dazer  
Mitberichter: Univ.-Prof. Dr.-Ing. Mit Berichter

Tag der mündlichen Prüfung:

Institut für Maschinenelemente der Universität Stuttgart

2026



# **Vorwort**

Thanks for your service.



# Kurzfassung/Abstract

-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-

TODO:

- 
- Abstract / Kurzfassung / Danksagung
- Bilder prüfen
- "mark changes after your Oral presentation for review"
- "textcolor blue in definitions ändern
- "Print"Funktion aktivieren
- "nocite"Funktion deaktivieren in main Z.269

-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-TODO-



# Inhaltsverzeichnis

<b>Vorwort</b> . . . . .	<b>iii</b>
<b>Kurzfassung/Abstract</b> . . . . .	<b>v</b>
<b>Nomenklatur</b> . . . . .	<b>ix</b>
Abkürzungen . . . . .	ix
Indizes . . . . .	x
Formelzeichen . . . . .	x
<b>Abbildungsverzeichnis</b> . . . . .	<b>xv</b>
<b>Tabellenverzeichnis</b> . . . . .	<b>xvii</b>
<b>1 Einleitung</b> . . . . .	<b>1</b>
1.1 Forschungsperspektive und Problembeschreibung . . . . .	2
1.2 Beitrag dieser Arbeit . . . . .	3
1.3 Aufbau der Arbeit . . . . .	4
<b>2 Stand der Forschung und Technik</b> . . . . .	<b>7</b>
2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie . . . . .	7
2.1.1 Begriffe und Definitionen . . . . .	8
2.1.2 Deskriptive Statistik für Lebensdauerdaten . . . . .	9
2.1.3 Parametrische Lebensdauermodelle . . . . .	11
2.1.4 Parameterschätzverfahren . . . . .	13
2.2 Statistische Versuchsplanung und Modellbildung . . . . .	18
2.2.1 Grundlagen zur statistischen Versuchsplanung . . . . .	19
2.2.2 Statistische Versuchsplanung zur Lebensdauererprobung . . . . .	24
2.2.3 Statistische Modellbildung . . . . .	39

<b>3</b>	<b>Ansätze zur Effizienzsteigerung in der Planung von ausfallbasierten Lebensdauertests mit mehreren Faktoren . . . . .</b>	<b>41</b>
3.1	Bewertung des Standes der Forschung und Technik . . . . .	41
3.2	Forschungsfragen und Aufbau der Arbeit . . . . .	42
<b>4</b>	<b>Parameter-Screening für multifaktorielle Lebensdauertests . . . . .</b>	<b>43</b>
4.1	Identifikation potenzieller Einflussgrößen . . . . .	43
4.2	Kreativmethoden zum Auswahlprozesse im Parameter-Screening . . . . .	43
4.3	Randbedingungen in der Parameterauswahl für die Zuverlässigkeitsmodellierung . . . . .	43
4.4	Vorgehen zum heuristische Screening für die Zuverlässigkeitsmodellierung . . . . .	43
4.5	Zusammenfassung . . . . .	43
<b>5</b>	<b>Effiziente multivariate Versuchspläne für Lebensdaueruntersuchungen . . . . .</b>	<b>45</b>
<b>6</b>	<b>Fallstudie . . . . .</b>	<b>47</b>
<b>7</b>	<b>Zusammenfassung und Ausblick . . . . .</b>	<b>49</b>
7.1	Key Findings . . . . .	49
7.2	Diskussion . . . . .	49
7.3	Ausblick . . . . .	49
	<b>Literatur . . . . .</b>	<b>51</b>
	<b>Anhang . . . . .</b>	<b>67</b>
A	Ein Anhang . . . . .	67
A.1	Unteranhang 1 . . . . .	67



# Nomenklatur

## Abkürzungen

<i>cdf</i>	Cumulative Distribution Function
<i>pdf</i>	Probability Density Function
ALT	Accelerated Lifetime Testing
ANOVA	Varianzanalyse, engl. Analysis of Variance
BEV	Battery Electric Vehicle
CCD	Central Composite Design
CI	Confidence Interval
CP	Center Point
DfR	Design for Reliability
DoE	Design of Experiments
DSM	Design-Structure-Matrix
ECU	Electronic Control Unit
EoL	End-of-Life
GLM	Generalized Linear Model
IMA	Institut für Maschinenelemente
L-DoE	Lifetime Design of Experiments
MLE	Maximum-Likelihood-Estimation
MMR	Median-Rank-Regression-Methode
OFAT	One Factor At Time
OLS	Ordinary Least Squares

<b>RSD</b>	Response Surface Design
<b>RSM</b>	Response Surface Methodology
<b>SPV</b>	Scaled Prediction Variance
<b>VIF</b>	Varianz-Inflations-Faktor

## Indizes

0	Zeitpunkt $t = 0$ Zentralpunkt Regressionskonstante Position im Versuchsraum
C	Zentralpunkt
D	Sternpunktabstand CCD
F	Faktorieller Punkt
MC	Monte-Carlo-Simulation
O	Beobachtet (Observed)
S	Sternpunkt
error	Fehler 2. Art (Wahrscheinlichkeit für ein falsch-negatives Ergebnis)
$i$	Laufvariable
$j$	Laufvariable
$l$	Laufvariable
$o$	Obere Grenze des Vertrauensbereichs
$q$	Quantilwert
$u$	Untere Grenze des Vertrauensbereichs

## Formelzeichen

$A_{\text{opt}}$	A-Optimalitätskriterium (Spur-Minimierung)
$\alpha$	Signifikanzniveau
	Abstand der Sternpunkte (Axial Points)
$b$	Weibull-Formparameter (Weibull-Modul)
$\beta$	Koeffizientenmatrix
$\beta$	Regressionskoeffizient, Modellparameter
	Fehler 2.Art
$\kappa$	Konditionszahl der Informationsmatrix
$\text{Cov}[\cdot]$	Covarianz-Operator
COVRATIO	Einflussstatistik auf Schätzwerte (Covariance Ratio)
$D$	Cook's Distanz
$D_{\text{opt}}$	D-Optimalitätskriterium (Determinanten-Maximierung)
$\delta$	Statusindikator (1=Ausfall, 0=Zensiert)
$\det(\cdot)$	Determinante einer Matrix
DFBETAS	Einflussstatistik auf Koeffizienten (Difference in Betas)
DFFITS	Einflussstatistik auf Prädiktionen (Difference in Fits)
$E(\cdot)$	Erwartungswert
$E_{\text{opt}}$	E-Optimalitätskriterium (Eigenwert-Minimierung)
$E$	Effekt
$D_{\text{eff}}$	D-Effizienz (Normierte Determinante)
$G_{\text{eff}}$	G-Effizienz (Verhältnis Modellparameter zu max. Varianz)
$\lambda$	Eigenwert (einer Matrix)
$\mathbf{v}$	Eigenvektor
$\epsilon$	Fehlerterm-Matrix
$\epsilon$	Fehlerterm
$F(\cdot)$	Ausfallwahrscheinlichkeit, Verteilungsfunktion
$f(\cdot)$	Dichtefunktion
$\mathbf{F}$	Fisher-Informationsmatrix

$g(\cdot)$	Abgeleitete Funktion (für Delta-Methode)
$\mathbf{g}'$	Gradientenvektor der Funktion $g$
$G_{\text{opt}}$	G-Optimalitätskriterium (Minimierung max. Prädiktionsvarianz)
$\Gamma(\cdot)$	Gamma-Funktion
$\mathbf{H}_{\mathbf{f}}$	Hessian-Matrix (der Log-Likelihood-Funktion)
$h$	Eintrag von $\mathbf{H}$ , Hebelwert
$H_0$	Nullhypothese
$H_1$	Alternativhypothese
$\mathbf{H}$	Orthogonale Projektionsmatrix, Prädiktionsmatrix, Hat-Matrix
$I_{\text{opt}}$	I-Optimalitätskriterium (Minimierung durchschn. Prädiktionsvarianz)
$k$	Anzahl der Modellparameter
$\mathcal{L}(\cdot)$	Likelihood-Funktion
$\Lambda(\cdot)$	Log-Likelihood-Funktion
$\lambda(t)$	Ausfallrate (zeitabhängig)
$\mathbf{M}$	Informationsmatrix $\mathbf{X}'\mathbf{X}$
$m$	Replikation
$\mu$	Erwartungswert der Lebensdauer (theoretisch)
$N$	Versuchsanzahl
$n$	Stichprobenumfang / Anzahlvariable
$p$	Anzahl der Regressionskoeffizienten
$p$ -Wert	Überschreitungs- / Rest-Irrtumswahrscheinlichkeit
$p_{\mathbf{f}}$	Fraktionsgrad
$power$	Trennschärfe, Power
$\text{Pr}$	Wahrscheinlichkeit
$v(\mathbf{x}_0)$	Prädiktionsvarianz an der Stelle $\mathbf{x}_0$ (skaliert)

$\pi(\cdot)$	A-Priori-Information/Verteilung
$q$	Quantilwert
$R$	Zuverlässigkeit
$r$	Studentisiertes Residuum
$\mathbb{R}$	Menge der reellen Zahlen
$s$	Empirische Standardabweichung (von $x$ )
$S_{\text{opt}}$	S-Optimalitätskriterium (Abstands-Maximierung)
$s^2$	Empirische Varianz (von $x$ )
$se$	Standardfehler (Standard Error)
$\sigma$	Standardabweichung (theoretisch)
$\sigma^2$	Varianz der Lebensdauer (theoretisch)
$T$	Charakteristische Lebensdauer (Skalenparameter)
$t$	Zeit, Lebensdauermerimal
$\mathbf{t}$	Vektor der Ausfallzeiten
$\tau$	kontinuierliche Zufallsvariable
$\boldsymbol{\theta}$	Vektor der Modellparameter
$U_{\text{Copt}}$	U-Optimalitätskriterium (Minimierung Prädiktionsvarianz)
$v$	Integrationsvariable (Gamma-Funktion)
$\mathbf{V}$	Varianz-Kovarianz-Matrix
$V_{\text{opt}}$	V-Optimalitätskriterium (Punktuelle Varianz-Minimierung)
$\text{Var}[\cdot]$	Varianz-Operator
$\mathcal{W}(\cdot, \cdot)$	Weibull-Verteilung (Notation)
$\mathbf{X}$	Versuchsplan-Matrix oder Modellmatrix
$x$	Messwert, Variable, Parameter
$\bar{x}$	Arithmetischer Mittelwert (empirisch)
$\mathbf{x}$	Postion im Parameterraum
$\mathbf{y}$	Antwortmatrix

$y$	Systemantwort, -variable
$z$	Quantil der Standardnormalverteilung

# Abbildungsverzeichnis

2.1	Weibull $f(t)$ für ausgewählte Werte von $T$ und $b$ . . . . .	13
2.2	Design of Experiments (DoE) Steps gemäß [39] . . . . .	20
2.3	Parameter-Diagramm (P-Diagramm) . . . . .	21
2.4	Schematische Darstellung der Effekte: (a) positiver Haupteffekt von Faktor $x_1$ , (b) Wechselwirkungseffekte zwischen $x_1$ und $x_2$ . . . . .	22
2.5	Standard voll-faktorieller Versuchsplan . . . . .	25
2.6	Einfluss der Schrittweite auf die Approximation des Effekts $E$ . . . . .	25
2.7	Zentral zusammengesetzter Versuchsplan (CCD) mit $k = 2$ . . . . .	29
2.8	Strategischer Ansatz zu augmentierter Versuchsplanung für die Lebensdauererprobung nach [48] . . . . .	30





# Tabellenverzeichnis

2.1	Übersicht, Zielsetzung und mathematische Definition verschiedener Optimalitätskriterien für Versuchspläne [ <a href="#">7</a> , <a href="#">29</a> , <a href="#">32</a> , <a href="#">34</a> ] . . . . .	35
-----	--	----



# 1 Einleitung

Die Absicherung technischer Produkte und Systeme hinsichtlich ihrer Funktionalität bildet einen zentralen Bestandteil der ingenieurwissenschaftlichen Verantwortlichkeiten im Produktentwicklungsprozess. Motiviert durch Produktversprechen gegenüber der potenziellen Käuferschaft sowie bestehender Kunden, zur Wahrung des Selbstverständnisses einer Marke oder rein aufgrund regulatorischer Vorgaben soll hier im Kontext des vorgesehenen Einsatzzweckes Zuverlässigkeitsmanagement betrieben werden. So wird insbesondere aus Marktperspektive erwartet, dass ein (technisches) Produkt - ein Fahrzeug, ein Smartphone, eine Photovoltaikanlage - seine Funktionalität mindestens zum Gewährleistungs- oder Garantiezeitraum uneingeschränkt erfüllt.

Über den gesamten Produktlebenszyklus hinweg unterstützen Methoden der Zuverlässigkeitstechnik dabei, diese Anforderungen systematisch zu erfüllen. Verfahren aus dem Bereich „Safety“, explorative Datenanalysen zur Untersuchung der Produktperformance im Betrieb oder Test, effiziente Versuchsplanung zur Analyse oder zum Nachweis der Lebensdauer am Design, Methoden der beschleunigten Versuchsplanung, engl. [Accelerated Lifetime Testing \(ALT\)](#), der Aufbau probabilistischer Lebensdauermodelle sowie das Risikomanagement im Allgemeinen eignen sich für diese Herausforderung. Das zentrale Ergebnis liegt in der Ermittlung der Ausfallwahrscheinlichkeit als Komplement zur Zuverlässigkeit - also der Wahrscheinlichkeit, dass ein Produkt unter den definierten Randbedingungen eine vorgegebene Zeitdauer ohne funktionskritischen Ausfall übersteht [1]. Üblicherweise soll so nachgewiesen werden, dass das Erzeugnis dem Einfluss einer bestimmten Belastung - beispielsweise einer physikalischen oder elektrischen Kraft, einem Wärmeeintrag oder der Exposition gegenüber einer chemischen Beanspruchung - standhält. Gelingt in der Praxis keine hinreichend genaue Quantifizierung dieser probabilistischen Metrik, so liegen die Ursachen jedoch nicht zwangsläufig allein in ökonomischen Einschränkungen wie dem Zeit- und Kostenbudget für ein erforder-

liches Testing oder einem fehlenden methodischen Know-how - vielmehr könnten *mehrere* Einflussfaktoren auf die Zuverlässigkeit einwirken und sogar Wechselwirkungen ausprägen, ohne dass dies adäquat wahrgenommen oder antizipiert wird.

Moderne Produkte können schlichtweg durch multivariat bedingte Fehlermechanismen ausfallen. Die wirtschaftliche Tragweite dieser Erkenntnis wurde bereits 1996 im renommierten *Forbes Magazine* thematisiert, welches die einschlägigen Erfolge multivariabler Testmethoden in der industriellen Praxis hervorhob [2].

### 1.1 Forschungsperspektive und Problembeschreibung

Da trotz genannter Umstände die Kundenanforderungen und Garantiebedingungen üblicherweise als unveränderlich, teils sogar als zunehmend anspruchsvoller zu verstehen sind, werden Unsicherheiten in der Lebensdauerabsicherung dann meist nur durch präventive Wartungsstrategien, durch Tolerierung von Restrisiken oder durch die Inkaufnahme nachträglicher Schadensbegrenzung behandelt. Der zugrunde liegende Gedanke: ehe ein Produkt, dessen Lebensdauerverhalten nicht quantifizierbar verstanden ist, einen kritischen Verschleißzustand erreicht, wird es im Rahmen eines festgelegten Wartungsintervalls vorsorglich ersetzt. Dabei könnte zugrunde liegen, dass schlichtweg kein physikalisches Modell oder eine ausreichend ausgeprägte empirische Datengrundlage vorhanden ist. Führt auch diese Vorsorge zu erheblichen Regress- oder Kulanzkosten, müssen ausfallschutzorientierte Maßnahmen - bis hin zu Rückrufaktionen - frühzeitig eingeplant und umgesetzt werden, um Image- und Kostenrisiken (wenn auch selten nachhaltig) zu minimieren. Um jenes zu vermeiden, muss also bereits im Vorfeld den verschiedensten Randbedingungen mithilfe der Zuverlässigkeitstechnik begegnet werden. Besonders komplexe Randbedingungen lassen sich beispielsweise durch eine hochgradige Integration von Elektrifizierung und Digitalisierung, verkürzte Entwicklungszyklen, verschärfter Kostendruck, sich per se verändernde Prioritäten aus Marktperspektive, wandelnde Materialauswahl und -komposition, leistungsoptimierte Belastungsszenarien, intensivierte Einsatzbedingungen und nicht zuletzt eine effiziente Ressourcennutzung innerhalb eines Produkts beschreiben - um nur einige zu nennen. Ein einfaches Beispiel verdeutlicht dies: Der komfortable sowie ausfallfreie Betrieb eines Fahr-

zeugs soll einerseits gegenüber verschiedensten Schadensursachen gewährleistet werden; andererseits hängt er maßgeblich vom Funktionserhalt einer inzwischen bis zu dreistelligen Anzahl an [Electronic Control Units \(ECUs\)](#) ab - während in der jüngeren Vergangenheit noch eine geringe bis mittlere zweistellige Anzahl mit nur begrenztem Funktionsumfang üblich war [3]. Oder aber der störungsfreie Betrieb digitaler Services im [Battery Electric Vehicle \(BEV\)](#) setzt bei Zentralisierung von [ECU](#)-Funktionen die stetige Funktionsfähigkeit der Traktionsbatterie voraus, durch deren chemische Alterung, verschiedenst beeinflusst, sich jedoch zeitgleich wiederum weitere Unsicherheiten aus verschiedenen Einflüssen eingliedern können. Ein damit betrachtetes System bildet somit ein vielfältig komplexeres Netzwerk aus teils wechselwirkenden oder direkten Eigenschaften, die zu einem Versagen führen könnten.

Damit kann festgehalten werden: Produktdesigns werden angesichts steigender Kundenanforderungen zunehmend raffinierter und im Sinne des Effizienzgedankens optimiert (z.B. durch mehr Sensorik, Rechenleistung und fortschrittliche Assistenzsysteme), gleichzeitig wird jedoch die Art und Weise eines möglichen Funktionsverlustes zunehmend komplexer. Somit rückt die Fähigkeit, Prognosen über die Lebensdauer und Ausfallwahrscheinlichkeit in Abhängigkeit von mehreren Einflussgrößen treffen zu können, zunehmend in den unternehmerischen Fokus. Über die klassische Testplanung im Rahmen der Zuverlässigkeitstechnik hinaus erfordert dies also Methoden der statistischen Versuchsplanung bei gleichzeitiger Berücksichtigung *mehrerer* Einflussfaktoren auf die Lebensdauer. Methoden wie [ALT](#) und die Lebensdauermodellbildung behalten dabei weiterhin ihre Relevanz und bilden einen unverzichtbaren Bestandteil einer fundierten Teststrategie.

## 1.2 Beitrag dieser Arbeit

Ausgehend von der beschriebenen Problemstellung lässt sich der übergeordnete Beitrag dieser Arbeit wie folgt formulieren: Liegt ein komplexes technisches System vor und soll dieses hinsichtlich seiner Lebensdauer empirisch untersucht werden, um fundierte Prognosen über die Funktionalität im Betrieb treffen zu können, so müssen mehrdimensionale Lebensdaueruntersuchungen nach dem Prinzip des [DoE](#)

geplant werden. Neben der bloßen Implementierung von mehrdimensionale Tests für die Lebensdauererprobung berücksichtigt dieser Ansatz damit:

- eine effiziente Methodik zur gezielten Vorauswahl relevanter Faktoren aus der Gesamtheit potenzieller Systemparameter - mit dem Ziel, deren signifikanten Einfluss auf die Lebensdauer zu untersuchen;
- die Auswahl geeigneter Strategien und passender Testpläne zur statistisch abgesicherten Quantifizierung von Einflüssen auf die Lebensdauer, in Kombination mit konventionellen Zuverlässigkeitsmethoden wie beispielsweise ALT;
- eine präzise Parameterschätzung zur mathematischen Beschreibung der Effekte auf Basis der als signifikant identifizierten Einflussgrößen;
- die Bilanzierung geeigneter Testpläne im Vergleich zu etablierten, in der Literatur bereits umfangreich diskutierten Versuchsplänen, insbesondere hinsichtlich potenzieller Abweichungen bei nicht-normalverteilten Daten.

### 1.3 Aufbau der Arbeit

Der allgemeine inhaltliche Aufbau der vorliegenden Arbeit kann **Abb. 1** entnommen werden. So folgt auf die in diesem Abschnitt beschriebene Problemstellung sowie Ausführung über den generellen Beitrag der Arbeit weiter in Kapitel 2 der relevante Stand aus aktueller Forschung und Literatur. Kapitel 3 fasst schließlich den Forschungsbedarf zusammen und stellt das Ziel der Arbeit, aus der sich die relevanten Forschungsfragen ergeben, konkret heraus. Kapitel 4 beinhaltet die Vorstellung zu effizienten, qualitativen Screening-Methoden. Hier werden die herausgearbeiteten Vorschläge zu einer Auswahl an heuristischen Methoden für die Selektion der perspektivisch wenig relevanten Faktoren beschrieben, die für die Umsetzung in der experimentellen statistischen Datenerhebung für maßgeblich erachtet werden. Weiter werden in Kapitel 5 darauf die Rahmenbedingungen für die zur statistischen Versuchsplanung neu herausgearbeiteten Versuchsplankonfigurationen für effiziente Lebensdauertests abgeglichen und schließlich bewertet. Als Ergebnis sind neben neuen, effizienten Versuchsplänen auch die relevanten Merkmale beschrieben, die es bedarf, um Versuchspläne im Kontext von Lebensdauertests zu bewerten. **Kapitel 6**.

Abschließend stellt Kapitel 7 eine Zusammenfassung über die methodische Herangehensweise und die erreichten Ergebnisse der Arbeit zusammen und ordnet diese für künftige Forschungsbestrebungen im Bereich der multivariaten Lebensdauer-Versuchsplanung ein.





## 2 Stand der Forschung und Technik

Dieses Kapitel stellt die für diese Arbeit erforderlichen technischen und methodischen Grundlagen bereit. Zunächst werde in Abschnitt 2.1 zentrale Begriffe und Konzepte der Zuverlässigkeitstechnik sowie das grundlegende statistische Verfahren zur Lebensdauer-Datenanalyse in Kombination mit Versuchsplänen erläutert. Darauf aufbauend folgen in Abschnitt 2.2 die Einführung und die Einordnung von DoE für Lebensdaueruntersuchungen sowie der multivariaten Lebensdauermodellierung aus dem Stand der Technik und der Wissenschaft, die beide für die Entwicklung effizienter Lebensdauerversuchspläne maßgeblich sind. Im Kontext der Lebensdauererprobung umfasst dies insbesondere typische, statistische Versuchspläne sowie Metriken und Indikatoren zur allgemeinen Bewertung der Versuchspläne.

### 2.1 Zuverlässigkeitstechnik und Wahrscheinlichkeitstheorie

Die Zuverlässigkeitstechnik befasst sich mit der probabilistischen Beschreibung der Lebensdauer technischer Produkte und Systeme sowie der strategischen und statistischen Planung von Lebensdauertests. Ziel ist die statistische Modellierung des Ausfallverhaltens unter Berücksichtigung der Funktionalität des Produkts bei relevanten Randbedingungen. Eine zentrale Aufgabe besteht somit in der statistischen Charakterisierung des Ausfallbegriffs mithilfe deskriptiver Statistik sowie in der Parametrisierung geeigneter Verteilungen zur Abbildung des Lebensdauerverhaltens. Die Modellierung kann - abhängig von den Randbedingungen - auf Basis *einer einzelnen* Belastungsgröße oder *mehrerer* Beanspruchungsparameter erfolgen, die gemeinsam den Produktausfall determinieren. Ein grundlegendes Verständnis des Umgangs mit zufallsverteilten Lebensdauerereignissen ist daher eine elementare Voraussetzung für die statistische Versuchsplanung im Rahmen der Zuverlässigkeitstechnik. Weiterführende Konzepte und vertiefte methodische Ansätze zur Zu-

verlässigkeitstechnik sowie zur statistischen Testplanung sind allen voran in der Standardliteratur von Bertsche und Dazer [1] dargelegt, an deren Vorgehensweise sich die nachfolgenden Ausführungen orientieren.

### 2.1.1 Begriffe und Definitionen

Der **Ausfall** eines technischen Produkts bezeichnet den Zeitpunkt innerhalb seiner Lebensdauer, zu dem die geforderte Funktionalität unter definierten Umgebungs- und Randbedingungen nicht mehr erfüllt ist - also das Lebensdauerende - engl. **End-of-Life (EoL)**. Als **Belastung** werden die von außen auf ein Produkt einwirkenden Einflussparameter - Kräfte und Momente im mechanischen Kontext - bezeichnet. *Einzelne* oder zeitgleich *mehrere* Einflussparameter induzieren infolge der Produktgestalt daraus **Beanspruchungen**: innere Kräfte, Momente und lokale Spannungen. Belastung und Beanspruchung sind die maßgeblichen Faktoren, welche die Lebensdauer determinieren. Die **Ausfallzeit**, welche diese Zustandsänderung zeitlich definiert, wird im Allgemeinen als kontinuierliche Zufallsvariable  $\tau > 0$  aufgefasst. So ergibt sich die Wahrscheinlichkeit, dass ein Produkt im Zeitraum bis  $t$  einen Funktionsverlust erleidet, zu

$$F(t) = \Pr(\tau \leq t) = \int_0^t f(t) dt. \quad (2.1)$$

Diese Funktion beschreibt die **Ausfallwahrscheinlichkeit**. Sie definiert damit die Verteilungsfunktion - engl. **Cumulative Distribution Function (cdf)** - für stochastische **EoL**-Events, während die **Zuverlässigkeit**

$$R(t) = \Pr(\tau > t) = 1 - F(t) = \int_t^\infty f(t) dt, \quad t \geq 0. \quad (2.2)$$

komplementär diejenige Wahrscheinlichkeit  $R(t) : \mathbb{R}_{\geq 0} \rightarrow [0, 1] \subset \mathbb{R}$  quantifiziert, zu der das nicht reparierbare Produkt die realisierte Zeit  $t$  überlebt: also frei von Funktionsverlust bleibt und funktionsfähig ist [1, 4, 5]. Damit ist die Zuverlässigkeit mathematisch als reellwertige, monoton fallende und stetige Funktion definiert. Gleichwohl ist  $R(t)$  keine universelle Eigenschaft, sondern vielmehr eine Funktion der Betriebsbedingungen. Diese Bedingungen umfassen unter anderem eine oder mehrere Belastungsarten und deren Niveaus, Nutzungsverhalten sowie spezifische

Betriebsprofile. Mechanische, elektrische und thermische Belastungen treten dabei am häufigsten auf [6]. Die **Wahrscheinlichkeitsdichtefunktion** - engl. **Probability Density Function (pdf)** -  $f(t)$  der Ausfallzeit beschreibt, wie sich die Wahrscheinlichkeiten der Ausfälle über der Zeit verteilen. Sie folgt somit der Ableitung der *cdf*:

$$f(t) = \frac{d}{dt}F(t) = \frac{d}{dt}\Pr(\tau \leq t), \quad t \geq 0. \quad (2.3)$$

Damit repräsentiert  $f(t)$  die Ausfallintensität pro Zeiteinheit und ist proportional zur lokalen Änderungsrate der Ausfallwahrscheinlichkeit. Als vierte fundamentale Größe der Zuverlässigkeitsanalyse wird außerdem die **Ausfallrate** (auch Hazard-Funktion)  $\lambda(t)(t)$  eingeführt. Sie quantifiziert das momentane Ausfallrisiko eines Produkts zum Zeitpunkt  $t$ , bedingt dadurch, dass es bis zu diesem Zeitpunkt überlebt hat ( $R(t) > 0$ ). Mathematisch ist sie als das Verhältnis der *pdf* zur Zuverlässigkeitsfunktion  $R(t)$  definiert:

$$\lambda(t)(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t < \tau \leq t + \Delta t | \tau > t)}{\Delta t} = \frac{1}{R(t)} \left[ -\frac{dR(t)}{dt} \right] = \frac{f(t)}{R(t)}. \quad (2.4)$$

Die Ausfallrate  $\lambda(t)(t)$  ist von zentraler Bedeutung, da ihr zeitlicher Verlauf (z.B. konstant, steigend, fallend) direkte Rückschlüsse auf zugrundeliegende Ausfallmechanismen wie Frühausfälle, Zufallsausfälle oder Verschleiß (vgl. "Badewannenkurve") zulässt [1, 6, 7].

### 2.1.2 Deskriptive Statistik für Lebensdauerdaten

Die im vorherigen Abschnitt definierten Funktionen  $F(t)$ ,  $R(t)$ ,  $f(t)$  und  $\lambda(t)(t)$  beschreiben das stochastische Ausfallverhalten eines Produktes auf einer theoretischen Populationsebene. Für die praktische Anwendung im Engineering müssen diese Funktionen, respektive die Parameter der ihnen zugrundeliegenden Verteilungsmodelle, auf Basis von empirisch ermittelten Lebensdauerdaten jedoch approximiert werden.

Die deskriptive Statistik stellt die notwendigen Methoden zur initialen Charakterisierung, Quantifizierung und Aufbereitung dieser Stichprobendaten bereit. Zur Beschreibung der Lebensdauerverteilungen sind **Lageparameter** und **Streuungs-**

**maße** notwendig, die zunächst theoretisch (für die Grundgesamtheit) definiert und anschließend aus der Stichprobe berechnet werden.

Der primäre Lageparameter ist der **Erwartungswert**  $\mu$  der Zufallsvariable  $\tau$ . Er repräsentiert den Schwerpunkt von  $f(t)$  und wird für kontinuierliche Lebensdauerdaten berechnet als:

$$\mu = E[\tau] = \int_0^{\infty} t \cdot f(t) dt. \quad (2.5)$$

Ein weiterer Lageparameter ist das **Quantil**  $t_q$  der Lebensdauer. Es definiert den Zeitpunkt, zu dem  $F(t)$  den Anteil  $q$  (respektive das **Perzentil** in Prozentpunkten) erreicht:

$$F(t_q) = q, \quad q \in [0, 1]. \quad (2.6)$$

Damit gibt das  $q$  - Quantil denjenigen Lebensdauerwert an, unterhalb dessen der Anteil  $q$  aller betrachteten Produkte ausgefallen ist. Ein spezieller Fall ist der **Median**  $t_{0.5}$ , bei dem die Ausfallwahrscheinlichkeit 50% beträgt:

$$F(t_{0.5}) = 0.5. \quad (2.7)$$

Der Median beschreibt somit den Zeitpunkt, zu dem die Hälfte aller Produkte ausgefallen ist. Damit teilt er die Fläche 1 unter der  $pdf$  in zwei gleich große Teilflächen [6, 8].

Das primäre Streuungsmaß ist die **theoretische Varianz**  $\sigma^2$ , welche die mittlere quadratische Abweichung vom Erwartungswert beschreibt:

$$\sigma^2 = \text{Var}[\tau] = E[(\tau - \mu)^2] = \int_0^{\infty} (t - \mu)^2 \cdot f(t) dt. \quad (2.8)$$

Da  $\mu$  und  $\sigma^2$  als theoretische Parameter üblicherweise unbekannt sind, werden auch sie durch empirische Statistiken approximiert, die aus einer Stichprobe vom Umfang  $n$  (bestehend aus den Messwerten  $x_1, \dots, x_n$ ) berechnet werden. Diese werden wiederum als Realisierungen der Zufallsvariable  $\tau$  aufgefasst.

Das gängige empirische Äquivalent für den Erwartungswert  $\mu$  ist der **arithmetische Mittelwert**  $\bar{x}$ :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i. \quad (2.9)$$

Analog wird die theoretische Varianz  $\sigma^2$  durch die **empirische Varianz**  $s^2$  (eine erwartungstreue Kenngröße) approximiert:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (2.10)$$

Die **empirische Standardabweichung**  $s = \sqrt{s^2}$  dient entsprechend als Näherung für die theoretische Standardabweichung  $\sqrt{\sigma^2}$ .

### 2.1.3 Parametrische Lebensdauermodelle

Während die deskriptiven Statistiken  $\bar{x}$  und  $s^2$  die zentrale Tendenz und die Streuung der vorliegenden Stichprobe quantifizieren, erlauben sie keine Extrapolation oder die Modellierung der zugrundeliegenden Funktionen  $F(t)$  und  $f(t)$  der Grundgesamtheit. Um eine prädiktive, mathematische Beschreibung des stochastischen Ausfallverhaltens zu erhalten, müssen die in Abschnitt 2.1.1 definierten Lebensdauerfunktionen durch geeignete parametrische Verteilungsmodelle approximiert werden. Andernfalls können nur nichtparametrische Modellierungsansätze zur Schätzung der kumulierten Wahrscheinlichkeit in Überlebensfunktionen wie beispielsweise nach Kaplan und Meier [9] genutzt werden [5, 7]. Die Verteilungsmodelle hingegen bieten eine geschlossene mathematische Form für *cdf* und *pdf* und ermöglichen es, das komplexe Ausfallverhalten durch eine geringe Anzahl von Parametern zu charakterisieren.

#### Weibull-Verteilung

In der Zuverlässigkeitstechnik hat sich die **Weibull-Verteilung** aufgrund ihrer hohen Flexibilität als das am häufigsten verwendete Modell etabliert. Je nach zugrundeliegendem physikalischen Ausfallmechanismus finden jedoch auch andere statistische Verteilungen Anwendung, wie beispielsweise die **Lognormal-Verteilung** (häufig bei Ermüdungs-, Korrosions- oder Diffusionsprozessen), die **Exponentialverteilung** (zur Modellierung von Zufallsausfällen ohne Alterungseffekte) oder die **Beta-Verteilung** (allgemein zur formenreichen Modellierung von  $R$  über dem festen Intervall  $[0, 1]$ ). Für weitere Ausführungen dazu sei an dieser Stelle jedoch auf

bereits ausreichend diskutierte Aufbereitungen von Bertsche und Dazer [1], Birolini [4], Yang [6], Rigdon et al. [7] und Hedderich und Sachs [10] verwiesen.

Die (zweiparametrische) Weibull-Verteilung ist das Standardmodell zur Beschreibung der Lebensdauer von technischen Produkten ohne die Berücksichtigung eines möglichen dritten Parameters - der ausfallfreien Zeit  $t_0$ . Sie wird durch den **Formparameter**  $b > 0$  (Weibull-Modul) und die **charakteristische Lebensdauer**  $T > 0$  (Skalenparameter), welche dem 63,2-ten Perzentil  $t_{0,632}$  entspricht, beschrieben. Unabhängig von  $b$  gilt hier:  $F(T) = 1 - e^{-1} \approx 63,2\%$ . Folgt die Lebensdauer-Zufallsvariable  $\tau$  dieser Verteilung, wird dies mathematisch als  $\tau \sim \mathcal{W}(T, b)$  notiert. Damit ist sie in der Lage, alle drei Phasen der "Badewannenkurve" (Frühausfälle mit  $b < 1$ , Zufallsausfälle  $b \approx 1$ , Verschleißausfälle mit  $b > 1$ ) durch die Wahl ihrer Parametrisierung abzubilden, vgl. Bertsche und Dazer [1].

Die Einheit des Skalenparameters  $T$  entspricht der Einheit des Messwertes ( $t$  in Stunden, Überrollungen, Kilometer, etc.). Die *pdf* der Weibull-Verteilung ist damit definiert als:

$$f(t) = \frac{b}{T^b} t^{b-1} \exp \left[ - \left( \frac{t}{T} \right)^b \right], \quad t > 0. \quad (2.11)$$

Die *cdf* ergibt sich durch Integration der *pdf* zu:

$$F(t) = 1 - \exp \left[ - \left( \frac{t}{T} \right)^b \right], \quad t > 0. \quad (2.12)$$

Aus  $f(t)$  und  $R(t) = 1 - F(t)$  leitet sich die **Ausfallrate**  $\lambda(t)(t)$  der Weibull-Verteilung ab:

$$\lambda(t)(t) = \frac{b}{T} \left( \frac{t}{T} \right)^{b-1}, \quad t > 0. \quad (2.13)$$

Der Erwartungswert  $\mu$  (vgl. Gleichung (2.5)) und die Varianz  $\sigma^2$  (vgl. Gleichung (2.8)) der Weibull-Verteilung lassen sich ebenfalls in geschlossener Form ausdrücken. Sie sind von der **Gamma-Funktion**  $\Gamma(\cdot)$  abhängig, welche für  $x > 0$  definiert ist als:

$$\Gamma(x) = \int_0^\infty v^{x-1} \exp(-v) dv. \quad (2.14)$$

Der Erwartungswert  $\mu$  der Weibull-verteilten Lebensdauer  $\tau$  ergibt sich zu:

$$\mu = E[\tau] = T \cdot \Gamma\left(1 + \frac{1}{b}\right). \quad (2.15)$$

Die Varianz  $\sigma^2$  ist gegeben durch:

$$\sigma^2 = \text{Var}[\tau] = T^2 \left[ \Gamma\left(1 + \frac{2}{b}\right) - \Gamma^2\left(1 + \frac{1}{b}\right) \right]. \quad (2.16)$$

Die Ausprägung der erwähnten Flexibilität der Weibull-Verteilung ist durch Abbildung 2.1 nachvollziehbar. Ein Spezialfall tritt ein für  $b = 1$ , da sich in diesem Fall die Weibull-Verteilung zur Exponentialverteilung mit dem Ausfallraten-Parameter  $\lambda(t) = 1/T$  und dem Erwartungswert  $\mu = T$  reduziert. Für  $b = 3,6$  wird die Schiefe der *pdf* annähernd eliminiert, sodass sich die Weibull-Verteilung einer Normalverteilung annähert [11, 12].




Abbildung 2.1: Weibull  $f(t)$  für ausgewählte Werte von  $T$  und  $b$ .

## 2.1.4 Parameterschätzverfahren

Soll eine geschlossene mathematische Beschreibung des stochastischen Ausfallverhaltens eines Produktes gefunden werden, ist das im vorherigen Abschnitt 2.1.2

definierte parametrische Verteilungsmodell  $\tau \sim \mathcal{W}(T, b)$  zu schätzen. Die Modellparameter der Grundgesamtheit sind in der praktischen Anwendung jedoch unbekannt. Die zentrale Problemstellung der **Parameterschätzung** besteht somit darin, aus der empirischen Stichprobe bestehend aus  $n$  Realisierungen  $t_1, \dots, t_n$  der Zufallsvariable  $\tau$  statistisch fundierte Schätzwerte  $\hat{T}$  und  $\hat{b}$  zu gewinnen. Diese sind Voraussetzung, um das Lebensdauermodell (z.B. Gleichung (2.12)) zu quantifizieren und prädiktive Aussagen zu Quantilen oder der Zuverlässigkeit  $R(t)$  zu ermöglichen. Eine wesentliche Komplikation hierbei sind jedoch das mögliche Auftreten von unvollständigen bzw. **zensierten** Daten sowie *multivariate* Abhängigkeiten der Belastungen zur Messgröße. Während für die Schätzung von Verteilungsparametern einfache Verfahren, wie die **Momentenmethode** oder die **Methode der kleinsten Fehlerquadrate** - engl. **Ordinary Least Squares (OLS)**, die beispielsweise bei der **Median-Rank-Regression-Methode (MMR)** im Wahrscheinlichkeitsnetz Anwendung findet, existieren, sind diese für die umfassende Analyse vielschichtiger Lebensdauerdaten in der Regel unzureichend und hier nur der Vollständigkeit wegen erwähnt - vgl. [1, 13]. Das universell anwendbare und robuste Verfahren, das Herausforderungen wie zensierte Daten und multivariate Modelle inhärent behandelt, ist die **Maximum-Likelihood-Estimation (MLE)** [5, 14].

### Maximum-Likelihood-Estimation

Das Grundprinzip der **MLE** besteht darin, diejenigen Parameterwerte (z.B.  $\hat{T}, \hat{b}$ ) als Schätzwerte auszuwählen, welche die Wahrscheinlichkeit (engl. Likelihood) maximieren, die empirisch beobachtete Stichprobe (bestehend aus unabhängigen Ausfällen und Zensierungen) zu erhalten. Mathematisch wird die Wahrscheinlichkeit der Realisierung von  $\mathbf{t} = (t_1, \dots, t_n)$  einer Stichprobe durch die **Likelihood-Funktion**  $\mathcal{L}$  bestimmt. Diese ist eine Funktion des unbekannten Parametervektors  $\boldsymbol{\theta}$ , der  $k$  zu schätzende Parameter enthält (z.B.  $\boldsymbol{\theta} = (T, b)$  mit  $k = 2$ ).

Für den vereinfachten Fall, dass die Stichprobe ausschließlich aus  $n$  exakten Ausfallereignissen (vollständige Daten) besteht, ist die Likelihood-Funktion  $\mathcal{L}$  das Produkt der einzelnen Wahrscheinlichkeitsdichten  $f(\cdot)$ :

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^n f(t_i|\boldsymbol{\theta}). \quad (2.17)$$



Zur Vereinfachung der numerischen Berechnung wird in der Anwendung die **Log-Likelihood-Funktion**  $\Lambda$  verwendet. Durch die Logarithmierung wird das Produkt (Gleichung (2.17)) in eine äquivalente, leichter zu maximierende Summe überführt:

$$\Lambda := \ln(\mathcal{L}(\boldsymbol{\theta})) \propto \sum_{i=1}^n \ln[f(t_i|\boldsymbol{\theta})]. \quad (2.18)$$

Wie zuvor dargelegt, ist dieser vereinfachte Ansatz für Lebensdauerdaten jedoch oft unzureichend, da er das Auftreten von zensierten Daten vernachlässigt. Für die praktische Anwendung existiert jedoch die entsprechende Erweiterung der Likelihood-Funktion um die Differenzierung etwaiger Testausgänge als *Durchläufer*. Dazu wird die Stichprobe als Paarung von  $t_i, \delta_i$  für  $\mathbf{t}$  definiert, wobei  $t_i$  der beobachteten Zeit und  $\delta_i$  einem Statusindikator ( $\delta_i = 1$  für einen exakten Ausfall;  $\delta_i = 0$  für eine Rechts-Zensierung) entspricht [5, 15].  $\mathcal{L}$  für rechts-zensierte Lebensdauerdaten lautet somit:

$$\mathcal{L}(\mathbf{t}|\boldsymbol{\theta}) \propto \prod_{i=1}^n [f(t_i|\boldsymbol{\theta})^{\delta_i} \cdot R(t_i|\boldsymbol{\theta})^{1-\delta_i}] \quad (2.19)$$

und definiert die Log-Likelihood Funktion als:

$$\Lambda := \ln(\mathcal{L}(\mathbf{t}|\boldsymbol{\theta})) \propto \sum_{i=1}^n [\delta_i \cdot \ln f(t_i|\boldsymbol{\theta}) + (1 - \delta_i) \cdot \ln R(t_i|\boldsymbol{\theta})]. \quad (2.20)$$

Der Parametervektor  $\hat{\boldsymbol{\theta}}$ , der den Wert von  $\Lambda(\boldsymbol{\theta})$  maximiert, liefert die MLE-Werte. Die Schätzwerte repräsentieren die (asymptotisch) effizientesten Schätzwerte für die Parameter der Grundgesamtheit. Dies erfolgt mathematisch durch Nullsetzen  $k$  partieller Ableitungen von  $\Lambda$ , sofern mathematisch entsprechende Schätzwerte in geschlossener Form durch  $\partial\Lambda/\partial\boldsymbol{\theta} \stackrel{!}{=} 0$  identifiziert werden können [11, 16]. Andernfalls werden numerische Optimierungsalgorithmen, vgl. Newton-Raphson-Verfahren, Patternsearch und vergleichbare, dafür herangezogen - siehe weiterführend [16, 17] sowie detaillierte Untersuchungen von Kremer und Bertsche [18]. An dieser Stelle sei erwähnt, dass systematische Verzerrungen (engl. **Bias**) in  $\hat{\boldsymbol{\theta}}$  aufgrund kleiner Stichprobenumfänge auftreten können [19] - jedoch auch korrigierbar sind, vgl. Arbeiten von Hirose [20] und Ross [21].

Die Qualität der Parameterschätzung beeinflusst daraus nicht nur die Prädiktionsgüte zur Schätzung der Lebensdauer oder Zuverlässigkeit - sie bedingt schließlich

auch die Effizienz des Schätzverfahrens. Wird im Sinne eines effizienten Verfahrens zur multivariaten Lebensdauermodellbildung eine Methodik gesucht, ist auch die Qualität der Parameterschätzung damit entscheidend. Vertrauensbereiche, oder engl. **Confidence Intervals (CIs)**, können eine Metrik für die Qualität der Modellierung einnehmen, da sie die Unsicherheit oder *Unschärfe* in der Prädiktion bemessen.

Die **MLE** liefert nicht nur die Punktschätzer  $\hat{\theta}$ , sondern auch die Quantifizierung von deren statistischer Unsicherheit (Präzision). Obwohl verschiedene Ansätze, wie die numerisch anspruchsvolleren Berechnungen nach Likelihood-Ratio-Methode, Bootstrap-Perzentil-Methode oder Monte-Carlo-Approximation existieren, ist das gängigste Verfahren zur Berechnung von **CIs** die Approximation mittels asymptotischer Normalverteilung der **MLE**-Schätzer  $\hat{\theta}$  [1, 14]. Dies erfolgt über die **Fisher-Informationmatrix**  $\mathbf{F}$ , welche die Information der Stichprobe über die Parameter  $\theta$  gemäß Kremer und Bertsche [22] bezüglich des Rechenaufwands und resultierender Modellqualität vergleichsweise effizient quantifiziert. So wird diese Methodik auch in gängiger Applikationen als Standard angewandt, vgl. [6, 14, 16]. In der praktischen Anwendung wird die Fisher-Informationmatrix auf Basis der resultierenden Schätzwerte  $\hat{\theta} = \theta$  so als Schätzung zur Beobachtung nach  $\mathbf{F}_O$  verwendet [14, 23]. Diese ist definiert als die negative **Hesse-Matrix**  $\mathbf{H}_f$  der Log-Likelihood-Funktion, ausgewertet an der Stelle der **MLE**-Schätzwerte  $\hat{\theta}$ :

$$\mathbf{F}_O := -\mathbf{H}_f(\hat{\theta}) = - \left[ \frac{\partial^2 \Lambda(\theta)}{\partial \theta_j \partial \theta_l} \right]_{\theta=\hat{\theta}}. \quad (2.21)$$

Die Matrix  $\mathbf{H}_f$  entspricht der  $(k \times k)$ -Matrix der  $k$  zweiten partiellen Ableitungen von  $\Lambda$  (vgl. Gl. (2.20)). Eine Invertierung  $\hat{\mathbf{F}}_O^{-1}$  ergibt die geschätzte **Varianz-Kovarianz-Matrix**  $\hat{\mathbf{V}}$ :

$$\hat{\mathbf{V}} \approx \hat{\mathbf{F}}_O^{-1}. \quad (2.22)$$

Die Diagonalelemente dieser Matrix  $\hat{\mathbf{V}}_{jj}$  entsprechen den Varianzen  $\text{Var}(\hat{\theta}_j)$  der einzelnen Parameterschätzwerte [14]. Die Nicht-Diagonalelemente  $\hat{\mathbf{V}}_{jl}$  (für  $j \neq l$ ) repräsentieren die **Kovarianzen**  $\text{Cov}(\hat{\theta}_j, \hat{\theta}_l)$  [6, 14]. Diese Kovarianzen sind von entscheidender Bedeutung, da sie die statistische Abhängigkeit zwischen den Schätzwerten (z.B. zwischen  $\hat{T}$  und  $\hat{b}$ ) quantifizieren, welche für die Berechnung der **CIs** von abgeleiteten Funktionen wie  $\hat{R}(t)$  erforderlich sind [5]. Basierend auf der An-

nahme der asymptotischen Normalität der Schätzer wird ein zweiseitiges  $(1 - \alpha)$ -CI für einen einzelnen Parameter  $\hat{\theta}_j$  direkt aus dessen Varianz approximiert durch:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \pm z_{1-\alpha/2} \cdot \sqrt{\hat{\mathbf{V}}_{jj}}, \quad (2.23)$$

wobei  $z_{1-\alpha/2}$  dem  $(1 - \alpha/2)$ -Quantil der Standardnormalverteilung entspricht. Da Lebensdauerparameter (z.B.  $T, b$ ) üblicherweise auf  $\mathbb{R}_{>0}$  beschränkt sind, werden CIs robust über eine Log-Transformation der Parameter berechnet, um physikalisch unmögliche (negative) Intervallgrenzen zu vermeiden [5, 6, 14]:

$$[\theta_{j,u}, \theta_{j,o}] = \hat{\theta}_j \exp \left( \pm z_{1-\alpha/2} \cdot \frac{\sqrt{\hat{\mathbf{V}}_{jj}}}{\hat{\theta}_j} \right). \quad (2.24)$$

Die Berechnung dieser CIs für Schätzwerte  $g(\hat{\theta})$  zu Größen wie  $\hat{R}(t)$  oder  $\hat{t}_q$  erfolgt mittels **Delta-Methode** [5, 14]. Dieses auf einer Taylor-Reihenentwicklung basierende Verfahren (Gauß'sche Fehlerfortpflanzung) approximiert die Varianz der Funktion  $\hat{g} = g(\hat{\theta})$  unter Einbeziehung der gesamten Varianz-Kovarianz-Matrix. Dazu wird der **Gradientenvektor**  $\mathbf{g}'$  der Funktion  $g$  (z.B.  $g = R(t)$ ) bezüglich des  $k$ -dimensionalen Parametervektors  $\theta$  gebildet:

$$\mathbf{g}' := \left[ \frac{\partial g(\theta)}{\partial \theta_1}, \dots, \frac{\partial g(\theta)}{\partial \theta_k} \right]_{\theta=\hat{\theta}}^T. \quad (2.25)$$

Die approximierte Varianz  $\text{Var}(\hat{g})$  der Funktion ergibt sich dann aus:

$$\text{Var}(\hat{g}) \approx \mathbf{g}'^T \hat{\mathbf{V}} \mathbf{g}'. \quad (2.26)$$

Das Vertrauensintervall für die Funktion  $\hat{g}$  wird anschließend unter Verwendung dieser Varianz (bzw. des Standardfehlers  $\sqrt{\text{Var}(\hat{g})}$ ) analog zu Gleichung (2.23) berechnet [6, 14, 24]:

$$[g_u, g_o] = \hat{g} \pm z_{1-\alpha/2} \sqrt{\text{Var}(\hat{g})}. \quad (2.27)$$

Sollen auch hier nur positive Werte für  $g$  berücksichtigt werden, kann eine Logarithmierung in der Berechnung der Vertrauensbereiche analog zu Gl. 2.24 erfolgen [6].

## 2.2 Statistische Versuchsplanung und Modellbildung

Multivariate Lebensdauertests erfordern definitionsgemäß die Betrachtung mehrerer  $k \geq 2$  Einflussfaktoren als Versuchsparameter. Dementsprechend entscheidend ist das Verständnis der wesentlichen Grundlagen im Umgang mit statistischer Versuchsplanung (DoE) für Lebensdauerdaten - auch unter dem Begriff **Lifetime Design of Experiments (L-DoE)** zusammengefasst - sowie der darauffolgenden Lebensdauermodellbildung. Während detaillierte Übersichten zur Historie von DoE von anfänglichen einschlägigen Beschreibungen durch Fisher [25], außerdem maßgebliche Weiterentwicklungen durch Box et al. [26] oder evolutionäre Schritte durch Taguchi [27] ausgiebig in Werken von Rigdon et al. [7], Kleppmann [28] und Montgomery [29] beschrieben sind, wird im Folgenden auf die wesentlichen Inhalte für die Forschungsschwerpunkte eingegangen.

Der primäre Anspruch von DoE besteht in der effizienten Planung empirischer Datenerhebungen, um Zielgrößen in Abhängigkeit erklärender Variablen zunächst robust zu modellieren und schließlich zu optimieren. Dieses Paradigma lässt sich auch unter der Begrifflichkeit **Design for Reliability (DfR)** unmittelbar wiedererkennen und so auf die Analyse von Lebensdauer und Zuverlässigkeit übertragen [6, 30]. Da das lokale oder globale Optimum der Lebensdauer- bzw. Zuverlässigkeitsfunktion eines Produktes a priori meist unbekannt ist, erfordert dessen Identifikation eine systematische Exploration des Parameterraumes. Eine besondere Herausforderung stellt hierbei zusätzlich die Integration von ALT dar: Die Diskrepanz zwischen dem hochbelasteten Testraum (engl. **Design Space**) und dem regulären **Prädiktionsraum** (engl. Use Space oder **Field Space**) kann eine **Extrapolation** erforderlich machen, welche die Anforderungen an die Daten- und somit auch an die Designqualität deutlich verschärft. Das Unwissen zur tatsächlichen Lage optimaler Antwortwerte und die Möglichkeit, per se einen systematischen Offset zwischen Design- und Field-Space durch ALT vorzufinden, stellen Teststrategien nach Best-Guess Ansätzen nachteilig. Hier wird in der industriellen Praxis häufig fälschlicherweise ein **One Factor At Time (OFAT)**-Testing Ansatz gewählt - unabhängig, ob vom Vorhandensein von Lebensdauer- oder anderen Daten, welcher schlichtweg die Wahrscheinlichkeit, Optimalstellen im Parameterraum systematisch zu treffen, senkt und somit gegenüber L-DoE nachteilig ist, vgl. [29, 31]. Da nun die geometrische Struktur eines Versuchsplans die erreichbare Modellierungsqualität deterministisch begrenzt, ist

eine präzise Bewertung der Plangüte anhand genau dieser Eigenschaft im Vorfeld unerlässlich. Hierfür können objektive **Performance-Indikatoren** sowie mathematische **Optimalitätskriterien** dienen, vgl. [29, 32]. Ergänzend zu rationalen Metriken wie der statistischen **Trennschärfe** (engl. **Power**) und dem Schätzergebnis einer **Koeffizienten-** bzw. Parameterschätzung sind diese Größen damit bestimmend für effiziente multivariate Lebensdauertests.

Vor diesem Hintergrund fokussiert sich dieser Abschnitt auf eine gezielte Auswahl an Grundbegriffen und Metriken für multivariate Testpläne im Kontext von **L-DoE** sowie auf eine Übersicht der für Lebensdauertests geeigneten Versuchspläne, bevor abschließend die statistische Modellbildung beleuchtet wird.

Für eine grundsätzlichere Auseinandersetzung mit konventionellen Methoden und Werkzeugen von **DoE** sei, mit Blick auf den Fokus der vorliegenden Arbeit, hingegen auf die einschlägige Literatur von Kleppmann [28], Siebertz et al. [31], Hinkelmann [33] sowie vornehmlich Montgomery [29] und Myers et al. [34] verwiesen. Diese Werke behandeln intensiv die Inhalte grundsätzlicher statistischer Versuchsplanung, welche um Perspektiven zu **L-DoE** bereits durch am **Institut für Maschinenelemente (IMA)** entstandene Dissertationen von Dazer [35], Herzig [36], Grundler [37] und maßgeblich durch Kremer [38] fortschreitend ergänzt wurden. Konsequenterweise werden Hintergründe zum Umgang mit normalverteilten Daten oder Abweichungen davon im Rahmen des **DoE**, die Diskussion zu einschlägigen Vor- und Nachteilen auch unter Abgrenzung zu Alternativen wie **OFAT**, die Regressionsmodellierung auf Basis der **Varianzanalyse, engl. Analysis of Variance (ANOVA)**, konventionelle Hypothesentests sowie fundamentale Ausführungen zu **ALT** in den nachfolgenden Ausführungen nicht explizit betrachtet, sondern als bekannt vorausgesetzt.

### 2.2.1 Grundlagen zur statistischen Versuchsplanung

Die Anwendung von **DoE** versteht sich grundsätzlich als Verfahrenskette entlang mehrerer Prozessschritte [29, 39], die beginnend von einer spezifischen Aufgabendeinition in einer statistisch abgesicherten Testentscheidung und Datenmodellierung mündet, vgl. Abbildung 2.2. Das erklärte Ziel ist es, den kausalen Zusammenhang zwischen Einflussfaktoren und Systemantwort funktional abzubilden. Darin abgebildete Einflussfaktoren sollen also per se **statistisch signifikant** und somit relevant


- 
- ① Definition des Untersuchungsziels
  - ② Identifizierung von Einflussparametern und Systemantwort
  - ③ Auswahl von Faktoren, Stufen und Parameterbereich
  - ④ Auswahl des Versuchsplans
  - ⑤ Durchführung der Versuchsreihe gemäß Versuchsplan
  - ⑥ Statistische Datenanalyse
  - ⑦ Schlussfolgerungen und Empfehlungen/Optimierung

Abbildung 2.2: DoE Steps gemäß [39]

für das Systemverhalten sein. So kann beispielsweise die zufallsverteilte Lebensdauer  $\tau$  in Abhängigkeit von  $k \geq 2$  technischen Beanspruchungen zunächst empirisch untersucht und anschließend modelliert sowie optimiert werden (*Schritt 1* in Abbildung 2.2).

Im Zentrum der Betrachtung steht damit generell ein technisches **System**, welches abstrakt als Produkt oder Prozess verstanden wird und den Zustand der Ausgangsgröße in Abhängigkeit der **Faktoren** definiert. Die zu untersuchende oder zu optimierende Ausgangsgröße wird als **Systemantwort**  $y$  (engl. **Response**) bezeichnet. Die gezielt kontrollierbaren und variierten Eingangsgrößen sind **Faktoren** (**Steuergrößen**), während nicht kontrollierbare oder unbekannte Einflüsse als **Störgrößen** (engl. **Noise**) klassifiziert werden (*Schritt 2*, vgl. [28]). Eine visuelle Aufstellung des genannten Zusammenspiels der Parameter kann dem Parameterdiagramm, kurz **P-Diagramm**, in Abbildung 2.3 entnommen werden [29]. Um das Systemverhalten zu charakterisieren, werden die Faktoren als kategoriale oder kontinuierliche Parameter im Versuch auf diskreten Werten, den sogenannten **Faktorstufen** (engl. **Level**), variiert (*Schritt 3*). Dies erfolgt in aller Regel in kodierter Darstellung, so entsprechen gemäß der gängigsten Konvention die Stufe  $-1$  der niedrigen und  $+1$  der hohen Einstellstufe. Die planerische Kombination verschiedener Faktorstufen äußert sich in spezifischen **Versuchspunkten** innerhalb des Parameterraums und entspricht der Versuchsplan-Matrix [28, 31]. Der **Versuchsraum** (engl. **Design Space**) wird hierbei durch die Gesamtheit der technisch realisierbaren und im Versuch einstellbaren Parameterkombinationen aufgespannt. Die Auswahl geeigneter statistischer Versuchspläne (*Schritt 4*) für die Durchführung (*Schritt 5*) wird in Abschnitt 2.2.2 detailliert behandelt.




Abbildung 2.3: Parameter-Diagramm (P-Diagramm)

Die aus der Variation resultierende Änderung der Systemantwort quantifiziert den Einfluss des Faktors, der statistisch als **Effekt**  $E$  bezeichnet wird und den Mittelwertunterschiede zweier Faktorstufen beschreibt (Schritte 6-7). Mittels **Kontrastmethode** wird also die Änderung der Systemantwort über alle durchgeführten Versuche mit jeweiligen Faktorstufen registriert [28, 29]:

$$E = \frac{1}{n|_{+1}} \sum y|_{+1} - \frac{1}{n|_{-1}} \sum y|_{-1} \quad (2.28)$$

So können mittels **DoE** strukturiert, effizient und verbindlich Informationen gewonnen werden, die über die direkten Effekte hinausgehen und differenziert Aufschluss über **Haupteffekte** sowie etwaige **Wechselwirkungen** der Faktoren auf die Antwort des Systems geben - vergleiche Abb. 2.4 sowie Kleppmann [28], Montgomery [29], Siebertz et al. [31] und Kremer [38]. Abbildung 2.4 visualisiert derartige Effekte. So gibt die Darstellung eines Haupteffekts in Abhängigkeit des Vorzeichens und der Steigung (**positiver** oder **negativer** Haupteffekt) sozusagen die Einflussstärke und -richtung wieder, während bei Wechselwirkung der Effekt in Abhängigkeit der Einstellung eines **Co-Faktors** dargestellt wird. Diese Zusammenhänge können mathematisch positiv oder negativ beschrieben sowie durch Polynomfunktionen höherer Ordnung approximiert werden, um zusätzlich beispielsweise **quadratische**



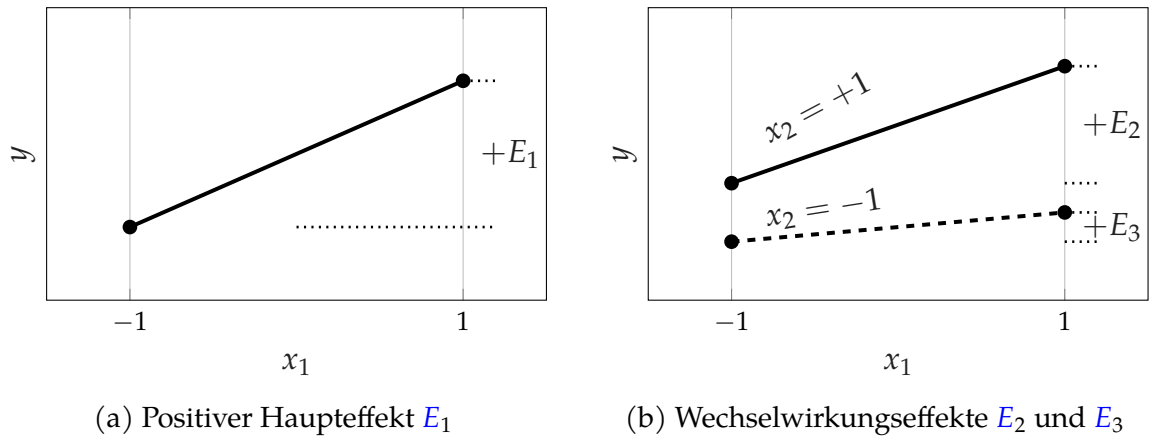


Abbildung 2.4: Schematische Darstellung der Effekte: (a) positiver Haupteffekt von Faktor  $x_1$ , (b) Wechselwirkungseffekte zwischen  $x_1$  und  $x_2$ .

**Effekte oder Mehrfachwechselwirkungen** abzubilden. In einem einfachen Fall wird für die lineare Beschreibung des Einflusses von Faktoren auf eine Antwortvariable ein durchschnittlicher Effekt durch eine Regressionskonstante  $\beta_0$  sowie Haupteffekte durch die Regressionskoeffizienten  $\beta_j, j = 0, 1, \dots, k$  zu einem Regressionsmodell erster Ordnung geschätzt. Falls relevant, erfolgt die Ergänzung um die jeweilige Wechselwirkung und einen Fehlerterm  $\epsilon$  als Zufallsvariable für Abweichungen durch Mess- und Streufehler [7, 29, 34]. Beispielhaft  $k = 2$  Faktoren resultiert daraus:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \epsilon. \quad (2.29)$$

Ein Modell zweiter Ordnung enthält zudem quadratische Terme, welche üblicherweise in Optimierungsaufgaben - so auch in der Lebensdauer- und Zuverlässigkeitsanalyse - relevant werden können:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \epsilon. \quad (2.30)$$

Die Gleichung der Modellierung kann so zur einfacheren Handhabung auch in Matrixnotation notiert werden und resultiert in:

$$y = \mathbf{X}\boldsymbol{\beta} + \epsilon, \quad (2.31)$$



wobei  $\beta$  als  $p \times 1$  Vektor der Regressionskoeffizienten ( $p = k + 1$ ) durch den  $n \times 1$  Vektor  $y$  aller Beobachtungen sowie durch die Versuchsplan-Matrix  $X$  ( $n \times p$  Einträge) unter Zuhilfenahme eines geeigneten Schätzverfahrens (vgl. Abschnitt 2.1.4) zu ermitteln ist [6, 16]. Sollen zunächst perspektivisch relevante Faktoren für eine versuchstechnische Untersuchung identifiziert werden, kann ein **Parameter-Screening** durchgeführt werden. Dessen Durchführung kann sowohl heuristisch als auch versuchstechnisch erfolgen.

### Parameter-Screening

Angesichts der potenziell hohen Komplexität durch Wechselwirkungen und Nicht-linearitäten sind die in Abbildung 2.2 beschriebenen *Schritte 2-3* als propädeutische Arbeiten für ein effizientes Testdesign zu interpretieren. Methodisch lassen sich diese unter dem Terminus **Screening** subsumieren. Screening-Schritte sind zwischen der Definition des Untersuchungsziels und der Durchführung der physischen Screening-Experimente angeordnet (vgl. *Schritt 3* in Abbildung 2.2 sowie Abschnitt 2.2.2). Daraus folgend dienen Screening-Methoden und -Versuchspläne dem Ziel, Informationsverluste bei einer minimalen Anzahl an Versuchsläufen zu begrenzen und die vitalen (*Steuergrößen*) von den trivialen (*Störgrößen*) Faktoren zu separieren, vgl. Abbildung 2.3.

Im Hinblick auf die Realisierung eines unter Zeit- und Kostenrestriktionen hochgradig effizienten DoE ist die effiziente Ausgestaltung der Screening-Strategie selbst schon von primärem Interesse. In traditionellen DoE-Ansätzen impliziert dies den Einsatz von **Kreativmethoden**, wie sie Standardliteratur von Montgomery [29] aufführen oder exemplarisch durch Kremer [38] und Gundlach [40] zusammengefasst werden. Hierbei ist ein Rückgriff auf Ergebnisse aus Experimenten, die explizit für das Forschungsziel ausgelegt wären, in dieser Phase unter Umständen noch nicht möglich. Es gilt damit zunächst, qualitativ eine rein rational erlesene Sammlung an potenziellen Einflussparameter zu erstellen, um diese dann anhand ihrer geschätzten Einflüsse auf die Systemantwort zu priorisieren. Ansätze aus der Kreativmethodik können dazu genutzt werden und fundieren auf der technischen **Systemanalyse**, die sowohl mit als auch ohne spezifisches Vorwissen über das System erfolgen kann [1]. Hilfsmittel zur Priorisierung einer hier erstellten Parametersammlung können beispielsweise Entscheidungsfindungsprotokolle, wie die **Design-Structure-**

**Matrix (DSM)**, und Methoden aus dem Komplexitätsmanagement, z.B. **Ishikawa-Diagramm**, sein - siehe hierzu auch weiterführende Werke von Mayers [41], Pahl et al. [42], Wu und Hamada [30] und Daenzer und Haberfellner [43] sowie Lindemann et al. [44]. Das Screening liefert somit eine rational festgestellte Auswahl an möglichst wenigen Einflussparametern, die mutmaßlich den entscheidenden Anteil an statistisch begründeter Manipulation der Systemantwort tragen und sich daher für eine Untersuchung in Versuchsplänen qualifizieren. Entsprechend ist daraufhin ein geeigneter Versuchsplan für die physischen Datenerhebungen zu wählen.

### 2.2.2 Statistische Versuchsplanung zur Lebensdauererprobung


Standardprotokolle aus dem DoE wie der  $2^k$  **voll-faktorielle Versuchsplan** eignen sich grundsätzlich auch für Lebensdaueruntersuchungen, da sich hier analog zu vergleichbar statistisch verteilter Datenlage Effekte stets als (Mittelwert-) Unterschiede in der Beobachtung der Systemantwort aus dem Vergleich zweier Einstellstufen eines oder mehrerer Faktoren ergeben [28].

#### $2^k$ Faktorielle Versuchspläne

Demzufolge kann auch ein Lebensdauer-beeinflussendes Parameterset - beispielhaft  $(x_1, x_2)$  - voll-faktoriell auf zwei Stufen variiert und vollständig kombiniert werden, vgl. Abbildung 2.5. Ein derartiges Setup erlaubt es, die perspektivische Differenz erreichbarer EoL-Werte durch tiefe und hohe Beanspruchungswerte der Faktoren zu beobachten [5, 6]. Der voll-faktorielle Versuchsplan bildet somit den Standard-Versuchsplan im DoE und fordert bei einmaliger Durchführung (**Replikation**  $m = 1$ )

$$n = 2^k \quad (2.32)$$

Versuche. Dieser Stichprobenumfang stellt sicher, dass das resultierende Gleichungssystem **gesättigt** ist: Mit  $n$  Versuchen lassen sich  $n - 1$  Effekte für Hauptfaktoren und Wechselwirkungen eindeutig bestimmen. Von entscheidender Bedeutung für die Aussagekraft des Versuchsplans ist die Wahl der Faktorstufen (vgl. Abbildung 2.6). Die Differenz der gewählten Level muss bereits im Vorfeld definiert werden, sodass signifikante Effekte sicher detektiert werden („**Signal-to-Noise**“), wobei gleichzeitig zu geringe Abstände (Rauschen) sowie zu große Intervalle (Gefahr unerkannter




(a) Versuchsplan

Faktorstufen- Kombination	Faktoren und Wechselwirkung		
	#	$x_1$	$x_2$
1	1	-1	-1
2	2	+1	-1
3	3	-1	+1
4	4	+1	+1

(b) Versuchsplanmatrix zu Abb. 2.5a

Abbildung 2.5: Standard voll-faktorieller Versuchsplan

Nichtlinearitäten) zu vermeiden sind - vgl. Abbildung 2.6 sowie Kleppmann [28], Wu und Hamada [30] und Siebertz et al. [31]. Auf Basis eines solchen zweistufigen


Abbildung 2.6: Einfluss der Schrittweite auf die Approximation des Effekts  $E$ 

Setups lässt sich der Zusammenhang zwischen Einflussgrößen und Lebensdauer interpolieren und in einem linearen Modell abbilden, welches zudem die Schätzung von Wechselwirkungen erlaubt. Werden davon abweichende Modellterme zur Abbildung der Systemantwort erwartet, berücksichtigen alternative Versuchspläne typischerweise drei bis fünf Faktorstufen. Der voll-faktorielle Versuchsplan nimmt dabei eine entscheidende Schlüsselrolle in der strategischen Modellbildung ein - insbesondere im Hinblick auf Lebensdauerdaten und Zuverlässigkeitstechnik.

Darin aufgeführte Versuchspunkte können auf Basis der Struktur ihrer Zuordnung üblicherweise ideal aus Voruntersuchungen übernommen oder durch weiterführende Untersuchungen nachfolgend erweitert werden. Ausgehend vom qualitativen Parameter-Screening (vgl. Abschnitt 2.2.1) ist ohne initiale Experimente oft unklar, welche Faktoren die Antwortvariable, also beispielsweise die Lebensdauer eines Systems, nun tatsächlich signifikant beeinflussen. Folglich ist es essenziell, diese Fragestellung vor der eigentlichen Versuchsplanumsetzung effizient zu klären.

### $2^{k-p_f}$ Fraktionell Faktorielle Versuchspläne

Sind nach Anwendung der Kreativmethoden (qualitatives Screening) weiterhin so viele Einflussfaktoren als relevant eingestuft, dass ein voll-faktorieller Ansatz gemäß Gleichung 2.32 zu einem wirtschaftlich nicht vertretbaren Versuchsumfang führen würde, muss die Strategie hin zu physikalischen Screening-Tests verschärft werden. Dies empfiehlt sich insbesondere für Systeme mit  $k > 5$  Faktoren, um die experimentelle Effizienz zu gewährleisten. Zur Veranschaulichung der Notwendigkeit: Bereits eine einzelne Replikation eines voll-faktoriellen Experiments mit  $k = 8$  Faktoren würde  $2^8 = 256$  Versuchsdurchläufe erfordern, was in der Lebensdauererprobung meist illusorisch ist.

Für derartige Selektionsaufgaben eignen sich daher **Screening-Versuchspläne**, wie der **teil-faktorielle Versuchsplan** (Fractional Factorial Design) oder alternativ der **Plackett-Burman-Plan** [28, 29, 31]. Bei diesem Ansatz wird lediglich eine selektive Teilmenge (Fraktion) der voll-faktoriellen Versuchsagenda umgesetzt, um mit minimalem Informationsverlust die für den Anwendungsfall signifikanten Effekte zu beschreiben. Mathematisch wird die Anzahl der Versuche dabei auf

$$n = 2^{k-p_f} \quad (2.33)$$

reduziert, wobei  $p_f$  den Grad der Fraktionierung (die Anzahl der Generatoren) angibt. Die Validität dieses Vorgehens stützt sich auf zwei fundamentale empirische Postulate [7, 13]:

- Die **Effekthierarchie** besagt, dass Effekte niedrigerer Ordnung – primär Haupteffekte – in der Regel eine größere Amplitude aufweisen und mit höherer Wahrscheinlichkeit signifikant sind als Effekte höherer Ordnung.

- Die **Effektvererbung** impliziert, dass das Auftreten signifikanter Wechselwirkungen oder quadratischer Terme strukturell an die Signifikanz ihrer korrespondierenden Haupteffekte gekoppelt ist.

Eine direkte Konsequenz dieser Reduktion („Der Preis der Einsparung“) ist jedoch, dass sich in teil-faktoriellen Versuchsplänen bestimmte Effekte nicht mehr isoliert betrachten lassen (vgl. Abbildung 2.5a für den Fall einer Fraktionierung). So sind beispielsweise Haupteffekte unter Umständen nicht mehr zweifelsfrei von Wechselwirkungen höherer Ordnung zu unterscheiden. Da sich diese Effekte statistisch überlagern, spricht man von einer **Vermengung** (engl. **Aliasing**). Die Schwere dieser Vermengung wird dabei über die **Auflösung** (engl. Resolution) des Versuchsplans klassifiziert (z. B. Auflösung III, IV oder V). Wird dieser Informationsverlust jedoch bewusst in Kauf genommen und ingenieurwissenschaftlich bewertet, ermöglicht dies eine signifikante Reduktion des Versuchsumfangs, um effizient die dominanten Faktoren aus der initialen Parametermenge zu isolieren. Diese Vorgehensweise ist von hoher Relevanz, da Lebensdauertests – ob als beschleunigte Prüfung mittels **ALT** oder unter Feldbedingungen – durch die inhärente Zeitabhängigkeit der Systemantwort erhebliche Kapazitäten binden und Ergebnisse nicht ad hoc verfügbar sind. Im Sinne einer ressourceneffizienten Gesamtstrategie sollten die Screening-Versuche daher idealerweise so konzipiert sein, dass sie nahtlos in einen nachfolgenden, höher aufgelösten Versuchsplan integriert (**augmentiert**) werden können.

### Wirkungsflächenversuchspläne

Die bisher diskutierten Versuchspläne beschränken sich auf die Untersuchung von Faktoren auf jeweils zwei Stufen ( $\pm 1$ ). Dies ermöglicht zwar eine effiziente Darstellung linearer Beziehungen und Interaktionen, jedoch ist die Modellierung komplexerer, nicht-linearer Effekte aufgrund fehlender Stützstellen im Versuchsraum damit physikalisch nicht möglich. Perspektivisch ist daher entscheidend, wie die bestehende Datenbasis weitergenutzt und augmentiert werden kann, falls die Systemantwort signifikante **Krümmungen** (engl. **Curvature**) aufweist und die quantitativen Beziehungen zwischen Faktoren und Zielgröße für eine Optimierung detaillierter beschrieben werden müssen.

Die **Response Surface Methodology (RSM)** behandelt als Teildisziplin des **DoE** derartige Herangehensweisen und bietet hierfür spezielle **Wirkungsflächenversuch-**

**spläne** - engl. **Response Surface Designs (RSDs)** - an. Der erste Schritt zur Detektion von Nichtlinearitäten besteht in der Integration von  $n_C$  sogenannten **Zentralpunkten**, engl. **Center Points (CPs)**, in den faktoriellen Basisplan. Hierbei werden alle Faktoren auf die kodierte Stufe 0 (die Mitte des Versuchsraums) gesetzt. Weicht der Mittelwert der Systemantwort in den Zentralpunkten signifikant vom Mittelwert über die faktoriellen Eckpunkte ab, deutet dies auf eine Krümmung der Antwortfläche hin [29].

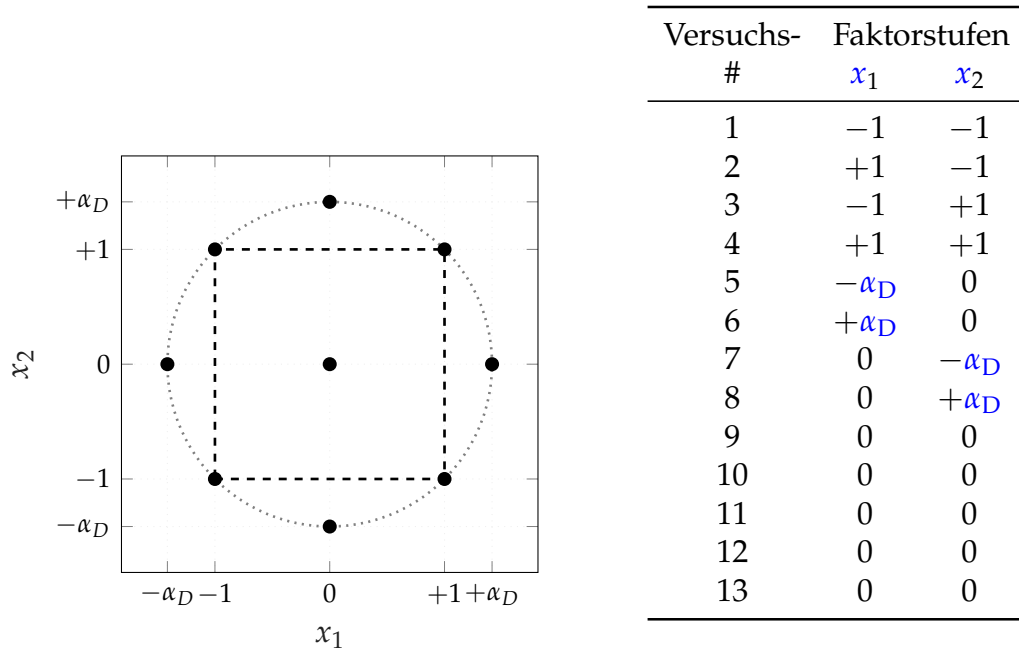
Um diese quadratischen Zusammenhänge explizit zu bestimmen, gilt der **Zentral-Zusammengesetzte-Versuchsplan**, engl. **Central Composite Design (CCD)**, als etablierter Standard. Ein **CCD** entsteht durch die Augmentierung des ursprünglichen voll- (oder teil-)faktoriellen Plans (den  $n_F$  Eckpunkten), vgl. Abbildung 2.7, um:

- eine definierte Anzahl  $n_C$  an wiederholten Zentralpunkten (üblicherweise  $3 \leq n_C \leq 5$  zur Abschätzung des reinen Fehlers) sowie
- $n_S = 2 \cdot k$  zusätzliche **Sternpunkte** (engl. **Axial Points** oder **Star Points**), die auf den Achsen des Koordinatensystems im Abstand  $\pm\alpha_D$  vom Zentrum liegen.

Während die Zentralpunkte das Vorhandensein quadratischer Effekte validieren, ermöglichen die Sternpunkte deren Wertbestimmung. Die Wahl des Abstands  $\alpha_D$  wird primär durch die Geometrie des interessierenden Versuchsraums (**Region of Interest**) diktiert. Betrachtet man diesen Raum als Kugel (**sphärisch**), ist die **Drehbarkeit** (engl. **Rotatability**) ein wesentliches Qualitätsmerkmal. Sie stellt sicher, dass die Varianz der Vorhersage nur vom Abstand zum Zentrum abhängt und invariant gegenüber einer Rotation des Koordinatensystems ist. Um diese Eigenschaft zu gewährleisten, berechnet sich der Abstand  $\alpha_D$  in Abhängigkeit der faktoriellen Versuchspunkte  $n_F$  zu [29, 45]:

$$\alpha_D = (n_F)^{1/4}. \quad (2.34)$$

Alternativ kann für sphärische Räume auch  $\alpha_D = \sqrt{k}$  gewählt werden (**Sphärisches CCD**), wodurch alle Versuchs- und Sternpunkte auf einer Kugeloberfläche liegen [34]. Ist der Versuchsraum hingegen durch harte physikalische Grenzen (z.B. maximale Temperatur) kubisch beschränkt, bietet sich der **flächenzentrierte CCD** (**Face**



(a) Versuchsplan (CCD)

(b) Versuchsplanmatrix (Stufen) zu Abb. 2.7a

Abbildung 2.7: Zentral zusammengesetzter Versuchsplan (CCD) mit  $k = 2$ 

**Centered CCD**) an. Hierbei wird  $\alpha_D = 1$  gesetzt, sodass die Sternpunkte direkt auf den Flächenmitten des Würfels liegen. Dies vereinfacht die Durchführung, da nur drei Faktorstufen ( $-1, 0, +1$ ) benötigt werden, opfert jedoch die Eigenschaft der Rotierbarkeit. Eine effiziente Alternative zum CCD stellt das **Box-Behnken-Design** dar [46]. Dieses Design kombiniert  $2^k$ -Faktorielle mit unvollständigen Blockplänen und platziert Versuchspunkte auf den Kantenmitten des Versuchsraums, vermeidet jedoch die extremen faktoriellen Versuchspunkte. Dies kann vorteilhaft für Lebensdauertests sein, bei denen extreme Ecken oft zu verfrühten Ausfällen führen können. Zudem ist es bei korrekter Wahl der Zentralpunkte alias-optimal gegenüber kubischen Modellen [47]. Stoßen Standard-Designs (CCD, Box-Behnken) aufgrund von Restriktionen im Versuchsraum (**Constraints**), nicht-standardmäßigen Modellierungszielen oder ungewöhnlichen Stichprobenumfängen an ihre Grenzen, empfiehlt sich der Einsatz von **Optimalen Versuchsplänen**, vergleiche übernächsten Abschnitt. Diese computergenerierten Designs minimieren algorithmisch die durchschnittliche Vorhersagevarianz über den gesamten Designraum und können Standard-Designs in ihrer Prädiktionsgüte oft übertreffen [29, 32].



## Strategische Vorgehensweisen

In der Praxis entsteht ein **CCD** häufig im Rahmen einer **sequenziellen Versuchsstrategie**: Zeigt das initiale lineare Modell Anpassungsmängel (**Lack-of-Fit**), wird der bestehende faktorielle Plan um die Sternpunkte augmentiert, um ein Modell zweiter Ordnung zu fitten [34]. Modelle zweiter Ordnung sind insbesondere in der Lebensdauer- und Zuverlässigkeitstechnik vermehrt von Bedeutung, da sie die Existenz von lokalen Extrema (Minima oder Maxima) der Systemantwort im Versuchsraum abbilden können [7]. Prinzipielle Vorgehensweisen, die ein erfolgreiches umsetzen von **DoE** begünstigen sollten, wie **Blockbildung** oder **Randomisierung** (vgl. [28, 31]) seien hier vorausgesetzt. Abbildung 2.8 fasst eine derartige strategische Vorgehensweise zur Realisierung eines **CCD** zusammen, wie sie Box et al. [48] vorschlagen.




Abbildung 2.8: Strategischer Ansatz zu augmentierter Versuchsplanung für die Lebensdauererprobung nach [48]

Demnach wird zunächst ein **teil-faktorieller Versuchsplan** zur Identifikation signifikanter Faktoren durchgeführt. Anschließend wird der Plan zu einem **voll-faktoriellen Versuchsplan** erweitert, um alle Haupteffekte und Wechselwirkungen erster Ordnung zu schätzen. Daraufhin werden **Zentralpunkte** ergänzt, um das Vorhandensein von Krümmungen zu validieren. Abschließend werden bei Bedarf die **Sternpunkte** hinzugefügt, um ein vollständiges **CCD** zu realisieren. Insbesondere in der Lebensdauererprobung ist eine derartige schrittweise Vorgehensweise sinnvoll, um den Versuchsumfang zu minimieren und dennoch eine fundierte Modellierung der Systemantwort zu gewährleisten. Gleichzeitig erlaubt diese Strategie eine flexible Anpassung an unerwartete Ergebnisse in den einzelnen Phasen der Untersuchung, während lokale Optima von Zuverlässigkeiten im Sinne von **DfR** im Vorfeld



ohnehin nicht bekannt sind. So kann beispielsweise auf Basis der Ergebnisse des teil-faktoriellen Plans entschieden werden, ob eine Erweiterung zum voll-faktoriellen Plan überhaupt notwendig ist, oder ob direkt zu den Zentralpunkten übergegangen wird. Genauso kann die Anzahl der Zentralpunkte an die beobachtete Streuung der Lebensdauerdaten angepasst werden, um eine robuste Schätzung des Fehlers zu gewährleisten. Ist dann eine Extrapolation in Richtung a-priori unbekannter Beanspruchungsniveaus geplant, verfügt der CCD über die notwendigen Stützstellen, um eine adäquate Exploration des Versuchsraums zu ermöglichen.

### Metriken zur optimalen Versuchsplanung

Wird maximale Flexibilität jenseits starrer Standard-Designs wie dem voll-faktoriellen Setup oder dem CCD verlangt, bieten **optimale Versuchspläne** einen leistungsfähigen Lösungsansatz. Diese verfolgen das Ziel, die Versuchspunkte algorithmisch so im Versuchsraum zu positionieren, dass spezifische Qualitätskriterien - allen voran die Verteilung der (um die Versuchsanzahl  $N$  skalierten) **Prädiktionsvarianz**, engl. **Scaled Prediction Variance (SPV)**,

$$v(\mathbf{x}_0) = \frac{N \text{Var}[\hat{y}(\mathbf{x}_0)]}{\sigma^2} = \mathbf{x}_0' \left( \frac{\mathbf{M}}{N} \right)^{-1} \mathbf{x}_0 = N \mathbf{x}_0' \mathbf{M}^{-1} \mathbf{x}_0 \quad (2.35)$$

optimiert werden [29, 34]. Die Prädiktionsvarianz ist ein dimensionsloses Maß, das ausschließlich von der geometrischen Anordnung der  $N$  Versuchspunkte (der Matrix  $\mathbf{X}$ ) und damit positionsabhängig von einer Referenz  $\mathbf{x}_0' = [1, x_{01}, \dots, x_{0k}]$  im Parameterraum ist. Sie ist damit unabhängig von der tatsächlichen Streuung der Messdaten ( $\sigma^2$ ). Eine effiziente Versuchsplanung für multivariate Lebensdaueruntersuchungen muss sich neben pragmatischen Beweggründen maßgeblich an diesen Größen orientieren, weshalb im Folgenden eine Übersicht der gängigen Metriken und Qualitätsmerkmale gegeben wird.

Der Einsatz optimaler Versuchspläne ist zunächst prädestiniert für Szenarien, in denen klassische Pläne an ihre Grenzen stoßen - sei es durch physikalische Randbedingungen welche bestimmte Faktorstufenkombinationen ausschließen, oder durch strikte Limitierungen der verfügbaren Versuchskapazität [28, 32]. Derart klassische Versuchspläne wie der voll-faktorielle Versuchsplan sind aufgrund ihrer Versuchspunktanordnung stets **orthogonal** [7, 29]. Ein Versuchsplan wird als orthogonal

bezeichnet, wenn keine Korrelation zwischen jeweils zwei Spalten der Versuchsplan-Matrix vorliegt - deren Skalarprodukte also jeweils null ergeben:

$$\langle x_i, x_j \rangle = 0 \quad \text{für alle } i \neq j. \quad (2.36)$$

Oder in anderen Worten: entspricht die **Informationsmatrix**

$$\mathbf{M} \stackrel{m=1}{=} \mathbf{X}'\mathbf{X} \quad (2.37)$$

einer Diagonalmatrix, ist der Versuchsplan orthogonal [7, 13]. So können Effekte eindeutig identifiziert werden - die Vektoren der Faktorstufenkombinationen sind linear unabhängig und Effekte lassen sich unverzerrt schätzen. Dies stellt einen Versuchsplan also zunächst einmal qualitativ günstig dar.

Zudem liegt **Ausgewogenheit** vor, sofern für einen jeweiligen Faktor alle anderen Faktoreinstellungen gleichmäßig aufgeteilt sind [31]. Damit wird Varianzhomogenität und Gleichbehandlung der Faktoren gewährleistet, sodass die Schätzung der Effekte unverzerrt erfolgt.

Mathematisch fundiert die Bewertung der Schätzgenauigkeit auf der Inversen der Informationsmatrix, welche als **Varianz-Kovarianz-Matrix** (oder **Dispersionsmatrix**)  $(\mathbf{X}'\mathbf{X})^{-1}$  der Regressionskoeffizienten definiert ist:

$$\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}, \quad (2.38)$$

wobei wie gehabt  $\sigma^2$  die Varianz des Versuchsfehlers darstellt. Die Diagonalelemente der Matrix  $(\mathbf{X}'\mathbf{X})^{-1}$  stehen hierbei in direktem Zusammenhang mit dem **Varianz-Inflations-Faktor (VIF)** [28, 31]. Der **VIF** dient als Maßzahl für Multikollinearität und quantifiziert den Faktor, um den sich die Varianz eines geschätzten Koeffizienten im Vergleich zu einem vollständig orthogonalen Design aufgrund von Korrelationen zwischen den Faktoren erhöht (vergleiche auch **Konditionszahl**) [10]. Während bei orthogonalen Plänen (Idealfall) ein **VIF** = 1 vorliegt, deuten hohe Werte (typischerweise > 5 oder > 10) auf eine instabile Modellschätzung hin [13, 28].

Ergänzend zur globalen Bewertung der Multikollinearität durch den **VIF** erlaubt die Betrachtung der sogenannten **Prädiktionsmatrix** (engl. auch **Hat-Matrix**)

$$\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \quad (2.39)$$

eine lokale Diagnose der Versuchspunkte. Die Diagonalelemente  $h_{ii} \in \left[\frac{1}{n}, 1\right]$  dieser Projektionsmatrix, bezeichnet als **Hebelwerte** (engl. **Leverage**), quantifizieren den Einfluss eines einzelnen Versuchslaufs auf die Modellvorhersage. Punkte mit hohen Hebelwerten (typischerweise  $h_{ii} > 2p/n$ ) befinden sich geometrisch weit vom Zentrum des Versuchsraums entfernt und dominieren die Regression, was den Plan anfällig für Ausreißer in diesen spezifischen Einstellungen macht [13, 31].

Während Hebelwerte jedoch lediglich das *Potenzial* einer Beobachtung zur Modellbeeinflussung aufgrund ihrer geometrischen Exponiertheit indizieren, quantifizieren Einflussstatistiken die *tatsächliche* Auswirkung auf die Regressionsparameter und die Vorhersagegüte. Die Identifikation solcher Beobachtungen erfolgt methodisch durch den iterativen Ausschluss des  $i$ -ten Datensatzes (*Leave-One-Out-Methodik*) und den Vergleich der resultierenden Modellstatistiken mit dem ursprünglichen Modell basierend auf  $n$  Beobachtungen [13, 49]. Als globales Maß für den Einfluss der  $i$ -ten Beobachtung auf den Vektor aller geschätzten Regressionskoeffizienten  $\hat{\beta}$  dient die **Cook-Distanz** ( $D_i$ ). Sie verknüpft die Information des intern studentisierten Residuums  $r_i$  mit dem Hebelwert  $h_{ii}$ :

$$D_i = \frac{r_i^2}{p} \cdot \frac{h_{ii}}{1 - h_{ii}}. \quad (2.40)$$

Ein hoher Wert (typischerweise  $D_i > 1$  oder  $D_i > 4/n$ ) signalisiert, dass das Entfernen der Beobachtung zu einer signifikanten Verschiebung der Modellparameter führen würde, da der Punkt sowohl weit vom Zentrum liegt als auch einen großen Fehler aufweist [49, 50].

Für eine differenzierte Analyse auf Ebene der einzelnen Modellterme wird die Metrik **DFBETAS** (Difference in Betas, Standardized) herangezogen. Sie misst die standardisierte Änderung eines spezifischen Regressionskoeffizienten  $\beta_j$  bei Ausschluss der  $i$ -ten Beobachtung:

$$\text{DFBETAS}_{j,i} = \frac{\hat{\beta}_j - \hat{\beta}_{j(-i)}}{\sqrt{\hat{\sigma}_{(-i)}^2 (\mathbf{X}'\mathbf{X})_{jj}^{-1}}}, \quad (2.41)$$

wobei  $\hat{\beta}_{j(-i)}$  den Koeffizienten ohne die  $i$ -te Beobachtung und  $\hat{\sigma}_{(-i)}^2$  die entsprechende Fehlerquadratschätzung darstellt. Hiermit lässt sich prüfen, ob einzelne Versuche

die Schätzung eines Effekt-Terms verzerren (kritischer Schwellenwert oft  $> 2/\sqrt{n}$ ) [13, 49].

Ergänzend beschreibt **DIFFITS** (Difference in Fits) die Änderung des Vorhersagewertes an der Stelle  $i$  selbst, normiert auf die Standardabweichung der Anpassung:

$$\text{DIFFITS}_i = \frac{\hat{y}_i - \hat{y}_{i(-i)}}{\sqrt{\hat{\sigma}_{(-i)}^2 h_{ii}}}. \quad (2.42)$$

Abschließend bewertet die **COVRATIO** den Einfluss auf die Präzision der Schätzung. Sie setzt die Determinante der Varianz-Kovarianz-Matrix ohne die  $i$ -te Beobachtung ins Verhältnis zur ursprünglichen Matrix:

$$\text{COVRATIO}_i = \frac{\det((\mathbf{X}'_{(-i)} \mathbf{X}_{(-i)})^{-1})}{\det((\mathbf{X}' \mathbf{X})^{-1})}. \quad (2.43)$$

Werte, die signifikant von 1 abweichen (Grenzen  $1 \pm 3p/n$ ), zeigen an, dass die Beobachtung die Konfidenzbereiche der Koeffizienten unverhältnismäßig beeinflusst [49].

Da in restriktiven Versuchsräumen Orthogonalität oft nicht erreichbar ist, zielen optimale Versuchspläne darauf ab, durch Minimierung spezifischer Eigenschaften der Dispersionsmatrix  $(\mathbf{X}' \mathbf{X})^{-1}$  den Informationsgehalt trotz Korrelationen zu maximieren. Die Generierung solcher maßgeschneiderten Pläne erfolgt algorithmisch unter Maximierung spezifischer statistischer Gütekriterien. Eine Übersicht der einschlägigsten **Optimalitätskriterien** - oder einfach **Optimalitäten** - welche den quantitativen Vergleich zur Standard-Methodik ermöglichen, ist in Tabelle 2.1 zusammengefasst [29, 32]. Sie bilden mitunter die Grundlage für diverse weitere Optimalitäten und hybride Ansätze [7, 34].

Tabelle 2.1: Übersicht, Zielsetzung und mathematische Definition verschiedener Optimalitätskriterien für Versuchspläne [7, 29, 32, 34]

Kriterium	Zielgröße, Beschreibung und Definition
<b>A-Optimalität</b>	<p>Minimierung der Spur der inversen Informationsmatrix [7, 28, 29].</p> <p>Ziel: Maximale Präzision der einzelnen Parameter im Durchschnitt.</p> $A_{\text{opt}} = \min \left( \text{spur}(\mathbf{M}^{-1}) \right) = \min \left( \sum_{j=1}^k \text{Var}(\hat{\beta}_j) \right) \quad (2.44)$
<b>D-Optimalität</b>	<p>Maximierung der Determinante der Informationsmatrix <math>\mathbf{M}</math> [7, 28, 29].</p> <p>Ziel: Beste Gesamtschätzung; minimiert das Volumen des Vertrauensellipsoids.</p> $D_{\text{opt}} = \max (\det(\mathbf{M})) \Leftrightarrow \min (\det(\mathbf{M}^{-1})) \quad (2.45)$
<b>E-Optimalität</b>	<p>Minimierung des maximalen Eigenwerts <math>\lambda_{\max}</math> der inversen Informationsmatrix [28, Erich-&gt;Boyd].</p> <p>Ziel: Worst-Case-Absicherung für den am schlechtesten geschätzten Parameter.</p> $E_{\text{opt}} = \min \left( \lambda_{\max}(\mathbf{M}^{-1}) \right) \quad (2.46)$
<b>G-Optimalität</b>	<p>Minimierung der maximalen skalierten Prädiktionsvarianz <math>v(\mathbf{x}_0)</math> im relevanten Parameterraum [29, 34].</p> <p>Ziel: Qualität der Vorhersage an der ungünstigsten Stelle sichern.</p> $G_{\text{opt}} = \min \left( \max_{\mathbf{x}_0 \in \mathbb{R}^k} v(\mathbf{x}_0) \right) \quad (2.47)$

Fortsetzung auf der nächsten Seite...

**Tabelle 2.1 (Fortsetzung):** Übersicht der Optimalitätskriterien

Kriterium	Zielgröße, Beschreibung und Definition
<b>I-Optimalität</b>	<p>Minimierung der durchschnittlichen (<i>integrierten</i>) Prädiktionsvarianz über den Parameterraum - auch <b>U-Optimalität</b> im ingenieurwissenschaftlich-statistischen Sinn: (<i>uniforme</i> Prädiktionsvarianz) [7, Monroe].</p> <p><i>Ziel: Optimale Vorhersagegüte im Mittel über den gesamten Raum.</i></p> $I_{\text{opt}} = \min \left( \frac{N}{\int_{\mathbb{R}^k} dx} \int_{\mathbb{R}^k} v(\mathbf{x}_0) dx \right) \quad (2.48)$
<b>S-Optimalität</b>	<p>Maximierung des minimalen euklidischen Abstandes zwischen zwei Versuchspunkten.</p> <p><i>Ziel: Gleichmäßige Raumfüllung (Space-Filling).</i></p> $S_{\text{opt}} = \max \left( \min_{i \neq j} \ x_i - x_j\  \right) \quad (2.49)$
<b>V-Optimalität</b>	<p>Minimierung der durchschnittlichen Prädiktionsvarianz über ein diskretes Set von <math>N</math> Punkten - z.B. die L-DoE-Versuchspunkte oder spezifische Nennlasten [29, 32, 51].</p> <p><i>Ziel: Optimale Vorhersagegüte an spezifischen Stellen.</i></p> $V_{\text{opt}} = \min \left( \frac{1}{N} \sum_{i=1}^N v(x_i) \right) \quad (2.50)$

Zur vergleichbaren Bewertung unterschiedlicher Designs unabhängig von der Skalierung werden normierte **Effizienzen** herangezogen [29]. Die **D-Effizienz**  $D_{\text{eff}}$  beschreibt die Güte der Parameterschätzung im Vergleich zu einem idealen ortho-

gonalen Design gleicher Größe. Hohe Werte (nahe 100 %) stehen für eine effiziente Ausnutzung der Versuche:

$$D_{\text{eff}} = \left( \frac{\det(\mathbf{M})}{n^p} \right)^{\frac{1}{p}} = \frac{D_{\text{opt}}^{\frac{1}{p}}}{n}. \quad (2.51)$$

Die **G-Effizienz**  $G_{\text{eff}}$  bewertet die Robustheit der Vorhersage. Sie setzt die theoretisch minimal erreichbare Prädiktionsvarianz ( $p/n$ ) ins Verhältnis zum tatsächlichen Worst-Case-Wert  $G_{\text{opt}}$  des Designs:

$$G_{\text{eff}} = \frac{p}{\max \frac{n \text{Var}[\hat{y}(x)]}{\sigma^2}} \quad (2.52)$$

Zuletzt muss sichergestellt werden, dass der Versuchsplan über eine ausreichende **Trennschärfe** (engl. **Power**) verfügt. Die Trennschärfe beschreibt als Metrik diejenige Wahrscheinlichkeit, mit der ein existierender Einfluss durch Faktoren vor dem Hintergrund des experimentellen Rauschens korrekt als **signifikanter** Effekt  $E$  identifiziert wird [28, 31]. Insofern ist ein Effekt in praktischem Umfeld natürlich problemabhängig (Streuungscharakteristik der Lebensdauer, realisierbare Stichprobengröße, etc.) und meist von Bedeutung für  $E \geq 2\sigma$ , wobei Trennschärfewerte  $\geq 80\%$  als befriedigend gelten [7, 29]. Insbesondere bei reduzierten Versuchsplänen und unter dem Einfluss stochastischer Lebensdauerstreuung ist die Power-Analyse jedoch essenziell, um das Risiko von falsch-negativen Schlussfolgerungen zu minimieren. Letztendlich kann die Trennschärfe somit als Garantimetrik verstanden werden, die sicherstellt, dass ein geplanter Versuchsaufbau in der Lage ist, Effekte von praktischer Relevanz zu detektieren [Cohen.1988, 34] - was insbesondere in Bezug auf Lebensdauertests aufgrund genannter wirtschaftlicher Randbedingungen von hoher Bedeutung ist. Formalisiert wird dies im Rahmen **statistischer Hypothesentests** [28, 29]. Die Zielsetzung besteht darin, den Nachweis zu erbringen, ob ein bestimmter Faktor  $x_j$  einen signifikanten Einfluss auf die Systemantwort  $y$  ausübt. Dazu werden zwei konkurrierende Hypothesen formuliert: Die **Nullhypothese**  $H_0$  unterstellt, dass kein Zusammenhang besteht, der korrespondierende Regressionskoeffizient  $\beta_j$  (vgl. Abschnitt 2.2.3) also den Wert Null annimmt:

$$H_0 : \beta_j = 0 \quad \text{gegen} \quad H_1 : \beta_j \neq 0. \quad (2.53)$$

Die **Alternativhypothese**  $H_1$  postuliert hingegen einen signifikanten Effekt ( $\beta_j \neq 0$ ). Die Entscheidung über die Annahme oder Ablehnung von  $H_0$  basiert auf dem **p-Wert**. Dieser quantifiziert die Wahrscheinlichkeit, unter der Annahme der Gültigkeit von  $H_0$  die beobachteten Daten (oder extremere Ergebnisse) zu erhalten. Unterschreitet der **p-Wert** das a priori definierte **Signifikanzniveau**  $\alpha$  (üblicherweise  $\alpha = 0,05$ ), wird  $H_0$  zugunsten der Alternativhypothese  $H_1$  verworfen. Der Fehler,  $H_0$  fälschlicherweise abzulehnen, obwohl kein Effekt vorliegt, wird als Fehler 1. Art bezeichnet; seine Wahrscheinlichkeit ist durch  $\alpha$  begrenzt. Die **Trennschärfe** fokussiert hingegen auf den Fehler 2. Art (oft mit  $\beta_{\text{error}}$  notiert), welcher das Risiko beschreibt, einen tatsächlich vorhandenen Effekt nicht zu erkennen (falsch-negative Entscheidung). Die Power folglich ist definiert als das Komplement dieses Fehlers ( $1 - \beta_{\text{error}}$ ) und entspricht somit der Wahrscheinlichkeit,  $H_0$  korrekterweise abzulehnen, wenn  $H_1$  wahr ist:

$$\text{power} = \Pr(H_0 \text{ ablehnen} \mid H_1 \text{ ist wahr}) = 1 - \beta_{\text{error}}. \quad (2.54)$$

Im Kontext der Lebensdauerdatenanalyse, bei der nicht-normalverteilte und zensierte Daten vorliegen, lassen sich diese Wahrscheinlichkeiten nicht über klassische **t-Tests** berechnen. Stattdessen kommen Verfahren für **Generalisierte Lineare Modelle**, engl. **Generalized Linear Model (GLM)** zum Einsatz, bei denen die Signifikanz der Koeffizienten  $\beta_j$  vorzugsweise über **Likelihood-Ratio-Tests** (oder approximativ über Wald-Tests, vergleiche hierzu Arbeiten von Meeker et al. [5], Rigdon et al. [7] und Montgomery [29]) ermittelt wird. Da für diese komplexen Verteilungsmodelle bei kleinen Stichprobenumfängen  $n$  keine geschlossenen analytischen Lösungen zur Berechnung der Trennschärfe existieren, erfolgt die Untersuchung gerne numerisch mittels **Monte-Carlo-Simulation** [38, 52, 53]. Hierbei wird der geplante Versuchsplan virtuell vielfach durchlaufen (z. B.  $n_{\text{MC}} = 10^4$  Simulationsläufe). Für jeden Lauf werden basierend auf einem angenommenen Modell Ausfallzeiten generiert, verrauscht bzw. mit Streuung überlagert und/oder zensiert. Anschließend erfolgt die Modellbildung und Hypothesenprüfung. Der Anteil der Simulationsläufe, in denen der definierte Effekt korrekt als signifikant (p-Wert  $< \alpha$ ) erkannt wird, entspricht der geschätzten **power** des Designs.



### 2.2.3 Statistische Modellbildung

- -> todo next:  
<https://www.researchgate.net/profile/Steven-Rigdon/research>  
<https://www.researchgate.net/profile/Rong-Pan-7/research>  
<https://www.researchgate.net/scientific-contributions/Eric-M-Monroe-70325879>  
[7, S.314]: UC Optimal Test Designs
- GLL-Weibull
- LR-Ratio
- Varianzen
- Modellaufbau
- Extrapolation: bedarf in der Praxis / oder sind doch dann mal VPs verfügbar und das modell wird einfach erweitert
- Optimalitäten
- Residuen (Cox-Snell [7])
- wu
- wütherich
- yang p282 erster abschnitt
- russell doe for glm kap1.4 p12

[7, 25, 28, 29, 30, 31, 32, 33, 34, 48, 51, 53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65, 66, 67, 68, 69, 70, 71, 72, 73, 74]



### **3 Ansätze zur Effizienzsteigerung in der Planung von ausfallbasierten Lebensdauertests mit mehreren Faktoren**

#### **3.1 Bewertung des Standes der Forschung und Technik**

- [34, Kap. 9.1.4]
- [34, Kap. 9.2.1]
- Khuri - 2006 - Design Issues for Generalized Linear Models A Review
- Yang - 2011 - OPTIMAL DESIGNS FOR GENERALIZED LINEAR MODELS WITH MULTIPLE DESIGN VARIABLES
- [7, Seite 314]
- Monroe, E.M., Pan, R., Anderson-Cook, C. et al. (2011). A generalized linear model approach to designing accelerated life test experiments. Quality and Reliability Engineering International 27: 595-607.

#### **Besonderheiten der Effizienz in der Lebensdauerprüfung**

Der Begriff der Effizienz erfährt im Kontext der Planung multivariater Lebensdauertests ([ALT](#) oder Reliability Demonstration Tests) eine signifikante Erweiterung gegenüber der klassischen linearen Versuchsplanung. Während Standard-Designs

primär die Varianz der Parameterschätzer minimieren, unterliegen Lebensdauertests der zusätzlichen Restriktion, dass die Information (der Ausfall eines Bauteils) stochastisch über die Zeit generiert wird und oft durch **Zensierung** limitiert ist.

Eine zentrale Herausforderung besteht in der **Modellabhängigkeit** (engl. Model Dependence) der Informationsmatrix. Bei nicht-linearen Modellen, wie der in der Zuverlässigkeitstechnik omnipräsenten Weibull- oder Lognormal-Regression, ist die Fisher-Informationsmatrix  $\mathbf{F}$  nicht mehr allein von der Versuchsplanmatrix  $\mathbf{X}$  abhängig, sondern auch von den wahren, aber unbekannten Verteilungsparametern  $\boldsymbol{\theta}$  (z. B. Formparameter  $b$ ):

$$\mathbf{M}(\mathbf{X}, \boldsymbol{\theta}) = E \left[ -\frac{\partial^2 \mathcal{L}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^2} \right]. \quad (3.1)$$

Daraus resultiert das Paradoxon, dass zur Konstruktion eines optimalen Plans bereits Kenntnisse über die zu ermittelnden Parameter vorliegen müssen. Klassische Optimalitätskriterien (D-, A-Optimalität) wandeln sich daher zu **lokalen Optimalitäten**, die nur für einen spezifischen Parametervektor  $\boldsymbol{\theta}_0$  („Best Guess“) gültig sind. Um Robustheit gegenüber Fehlannahmen dieser Startwerte zu gewährleisten, werden in der Entwicklung effizienter Lebensdauertests häufig **Bayes-Optimale Versuchspläne** eingesetzt, welche die Effizienz über eine A-Priori-Verteilung der Parameter maximieren [5, 32].

Zudem muss die **zeitliche Effizienz** berücksichtigt werden. Ein Versuchsplan gilt im Kontext der Lebensdaueranalyse nur dann als effizient, wenn er unter Berücksichtigung der Zensierungsmechanismen (Typ-I oder Typ-II) die erwartete Anzahl an Ausfällen maximiert oder die **erwartete Testdauer** (Expected Test Duration, ETD) bei gegebener Präzision minimiert. Die Varianz der Schätzung wird hierbei maßgeblich durch die Anzahl der ausgefallenen Einheiten getrieben, nicht allein durch die Stichprobengröße  $n$  [16].

## 3.2 Forschungsfragen und Aufbau der Arbeit

## **4 Parameter-Screening für multifaktorielle Lebensdauertests**

### **4.1 Identifikation potenzieller Einflussgrößen**

### **4.2 Kreativmethoden zum Auswahlprozesse im Parameter-Screening**

### **4.3 Randbedingungen in der Parameterauswahl für die Zuverlässigkeitsmodellierung**

### **4.4 Vorgehen zum heuristische Screening für die Zuverlässigkeitsmodellierung**

### **4.5 Zusammenfassung**



## **5 Effiziente multivariate Versuchspläne für Lebensdaueruntersuchungen**





## **6 Fallstudie**



## **7 Zusammenfassung und Ausblick**

### **7.1 Key Findings**

### **7.2 Diskussion**

### **7.3 Ausblick**



# Literatur

- [1] B. Bertsche und M. Dazer. *Zuverlässigkeit im Fahrzeug- und Maschinenbau: Ermittlung von Bauteil- und System-Zuverlässigkeiten*. 4. Auflage. Lehrbuch. Berlin und Heidelberg: Springer Vieweg, 2022. ISBN: 978-3-662-65023-3. URL: <http://www.springer.com/>.
- [2] R. Koselka. „The New Mantra: MVT“. In: *Forbes* (11.03.1996), S. 114–118.
- [3] *DAT Report 2025: Kurzbericht*. Ostfildern, Deutschland, Februar 2025. URL: [https://www.dat.de/fileadmin/protected/DAT\\_Report/2025/DAT-Report-2025-Kurzbericht.pdf](https://www.dat.de/fileadmin/protected/DAT_Report/2025/DAT-Report-2025-Kurzbericht.pdf).
- [4] A. Birolini. *Reliability Engineering*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2017. ISBN: 978-3-662-54208-8. DOI: [10.1007/978-3-662-54209-5](https://doi.org/10.1007/978-3-662-54209-5).
- [5] W. Q. Meeker, L. A. Escobar und F. G. Pascual. *Statistical methods for reliability data*. Second edition. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2022. ISBN: 978-1-118-11545-9.
- [6] G. Yang. *Life cycle reliability engineering*. Hoboken, N.J.: Wiley, 2007. ISBN: 9780471715290. URL: <http://www.loc.gov/catdir/enhancements/fy0740/2006019150-b.html>.
- [7] S. E. Rigdon, R. Pan, D. C. Montgomery und L. J. Freeman. *Design of experiments for reliability achievement*. Hoboken, NJ: Wiley, 2022. ISBN: 9781119237693. DOI: [10.1002/9781119237754](https://doi.org/10.1002/9781119237754).
- [8] L. Fahrmeir, C. Heumann, R. Künstler, I. Pigeot und G. Tutz. *Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2016. ISBN: 978-3-662-50371-3. DOI: [10.1007/978-3-662-50372-0](https://doi.org/10.1007/978-3-662-50372-0).
- [9] E. L. Kaplan und P. Meier. „Nonparametric Estimation from Incomplete Observations“. In: *Journal of the American Statistical Association* 53.282 (1958), S. 457. ISSN: 01621459. DOI: [10.2307/2281868](https://doi.org/10.2307/2281868).

- [10] J. Hedderich und L. Sachs. *Angewandte Statistik*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2020. ISBN: 978-3-662-62293-3. DOI: [10.1007/978-3-662-62294-0](https://doi.org/10.1007/978-3-662-62294-0).
- [11] H. Rinne. *The Weibull Distribution: A Handbook*. 1st ed. London: CRC Press LLC, 2008. ISBN: 978-1-4200-8743-7. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=1633687>.
- [12] D. Kececioglu. *Reliability & life testing handbook*. Lancaster, PA: DEStech Publications, 2002. ISBN: 1-932078-03-7.
- [13] D. C. Montgomery, E. A. Peck und G. G. Vining. *Introduction to linear regression analysis*. Sixth edition. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2021. ISBN: 978-1-119-57872-7.
- [14] W. Nelson. *Accelerated Testing: Statistical Models, Test Plans, and Data Analysis*. 1st ed. Bd. v.344. Wiley Series in Probability and Statistics Series. Newark: John Wiley & Sons Incorporated, 1990. ISBN: 978-0471697367. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=469757>.
- [15] J. D. Kalbfleisch. *The statistical analysis of failure time data*. 2nd ed. Wiley series in probability and statistics. Hoboken, N.J.: J. Wiley, 2002. ISBN: 047136357X. DOI: [10.1002/9781118032985](https://doi.org/10.1002/9781118032985).
- [16] W. Nelson. *Applied Life Data Analysis*. Bd. v.577. Wiley series in probability and statistics. Hoboken: John Wiley & Sons Inc, 2005. ISBN: 9780471644620. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226561>.
- [17] H. Qiao und C. P. Tsokos. „Parameter estimation of the Weibull probability distribution“. In: *Mathematics and Computers in Simulation* 37.1 (1994), S. 47–55. ISSN: 0378-4754. DOI: [10.1016/0378-4754\(94\)90058-2](https://doi.org/10.1016/0378-4754(94)90058-2).
- [18] A. Kremer und B. Bertsche. „A New Approach for Parametrizing Multidimensional Lifetime Models“. In: *Proceedings of the 29th European Safety and Reliability Conference (ESREL)*. Hrsg. von M. Beer und E. Zio. Europe und Singapore: European Safety and Reliability Association und Research Publishing Services, 2019, S. 715–722. ISBN: 978-981-11-2724-3. DOI: [10.3850/978-981-11-2724-3\textunderscore0443-cd](https://doi.org/10.3850/978-981-11-2724-3\textunderscore0443-cd).

- 
- [19] R. B. Abernethy. *The new Weibull handbook: Reliability & statistical analysis for predicting life, safety, risk, support costs, failures, and forecasting warranty claims, substantiation and accelerated testing, using Weibull, log normal, Crow-AMSAA, Probit, and Kaplan- meier Models*. 5. ed. North Palm Beach, Fla.: R.B. Abernethy, 2006. ISBN: 0965306232.
- [20] H. Hirose. „Bias correction for the maximum likelihood estimates in the two-parameter Weibull distribution“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 6.1 (1999), S. 66–68. ISSN: 10709878. DOI: [10.1109/94.752011](https://doi.org/10.1109/94.752011).
- [21] R. Ross. „Bias and standard deviation due to Weibull parameter estimation for small data sets“. In: *IEEE Transactions on Dielectrics and Electrical Insulation* 3.1 (1996), S. 28–42. ISSN: 10709878. DOI: [10.1109/94.485512](https://doi.org/10.1109/94.485512).
- [22] A. Kremer und B. Bertsche. „A Methodology for Consideration of Uncertainty in Lifetime Design of Experiments“. In: *2019 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2019, S. 1–6. ISBN: 978-1-5386-6554-1. DOI: [10.1109/RAMS.2019.8768906](https://doi.org/10.1109/RAMS.2019.8768906).
- [23] J. F. Lawless. *Statistical models and methods for lifetime data*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley-Interscience, 2003. ISBN: 0471372153. URL: <http://www.loc.gov/catdir/bios/wiley044/2002151805.html>.
- [24] L. J. Bain und M. Engelhardt. *Statistical Analysis of Reliability and Life-Testing Models*. Routledge, 2017. ISBN: 9780203738733. DOI: [10.1201/9780203738733](https://doi.org/10.1201/9780203738733).
- [25] R. A. Fisher. *The Design of Experiments*. Edinburgh: Oliver & Boyd, 1935.
- [26] G. E. P. Box, W. G. Hunter und J. S. Hunter. *Statistics for experimenters: An introduction to design, data analysis, and model building*. Wiley series in probability and mathematical statistics. New York: Wiley, 1978. ISBN: 0471093157. URL: <http://www.loc.gov/catdir/description/wiley033/77015087.html>.
- [27] G. Taguchi. *Taguchi's quality engineering handbook*. Hoboken, NJ: Wiley, 2005. ISBN: 9780471413349. DOI: [10.1002/9780470258354](https://doi.org/10.1002/9780470258354).
- [28] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 10., überarbeitete Auflage. Praxisreihe Qualität. München: Hanser, 2020. ISBN: 978-3-446-46397-4.

- [29] D. C. Montgomery. *Design and Analysis of Experiments*. 10th. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2020. ISBN: 9781119722106.
- [30] C.-F. Wu und M. Hamada. *Experiments: Planning, analysis and optimization*. Third edition. Wiley series in probability and statistics. Hoboken, NJ, USA: Wiley, 2021. ISBN: 9781119470106. URL: <https://zbmath.org/?q=an%3A1460.62003>.
- [31] K. Siebertz, D. van Bebbber und T. Hochkirchen. *Statistische Versuchsplanung: Design of Experiments (DoE)*. 2. Auflage. VDI-Buch. Berlin und Heidelberg: Springer Vieweg, 2017. ISBN: 978-3-662-55742-6.
- [32] P. Goos und B. A. Jones. *Optimal Design of Experiments: A Case Study Approach*. 1st. Hoboken, NJ: John Wiley & Sons, Inc, 2011. ISBN: 9780470744611.
- [33] K. Hinkelmann. *Design and Analysis of Experiments - Volume 3: Special Designs and Applications*. 1st. John Wiley & Sons, Inc, 2012. ISBN: 978-0470-53068-9.
- [34] R. H. Myers, D. C. Montgomery und C. M. Anderson-Cook. *Response Surface Methodology: Process and Product Optimization Using Designed Experiments*. 4. Aufl. Hoboken, NJ, USA: John Wiley & Sons, Inc, 2016. ISBN: 978-1-118-91601-8.
- [35] M. Dazer. *Zuverlässigkeitstestplanung mit Berücksichtigung von Vorwissen aus stochastischen Lebensdauerberechnungen*. 2019. DOI: [10.18419/OPUS-10501](https://doi.org/10.18419/OPUS-10501).
- [36] T. Herzig. *Anforderungsgerechte Produktauslegung durch Planung effizienter beschleunigter Zuverlässigkeitstests*. 2021. DOI: [10.18419/OPUS-12001](https://doi.org/10.18419/OPUS-12001).
- [37] A. Grundler. *Zuverlässigkeitsnachweis von Systemen durch Komponenten- und Systemtests unter Berücksichtigung von Vorkenntnissen*. 2024. DOI: [10.18419/OPUS-14393](https://doi.org/10.18419/OPUS-14393).
- [38] A. Kremer. „Statistische Versuchsplanung in der Lebensdauererprobung mit Vertrauensintervallen“. Diss. 2021. DOI: [10.18419/OPUS-11728](https://doi.org/10.18419/OPUS-11728).
- [39] D. E. Coleman und D. C. Montgomery. „A Systematic Approach to Planning for a Designed Industrial Experiment“. In: *Technometrics* 35.1 (1993), S. 1. ISSN: 0040-1706. DOI: [10.2307/1269280](https://doi.org/10.2307/1269280).



- 
- [40] C. Gundlach. „Entwicklung eines ganzheitlichen Vorgehensmodells zur problemorientierten Anwendung des statistischen Versuchsplanung“. Zugl.: Kassel, Univ., Diss, 2004. Kassel. URL: <http://d-nb.info/971843546/34>.
- [41] B. Mayers. *Prozeß- und Produktoptimierung mit Hilfe der statistischen Versuchsmethodik: Zugl.: Aachen, Techn. Hochsch., Diss., 1997*. Als Ms. gedr. Bd. 97,9. Berichte aus der Produktionstechnik. Aachen: Shaker, 1997. ISBN: 3826524977.
- [42] G. Pahl, W. Beitz, J. Feldhusen und K.-H. Grote. *Engineering design: A systematic approach*. 3. ed. London: Springer, 2007. ISBN: 978-1-84628-318-5. DOI: [10.1007/978-1-84628-319-2](https://doi.org/10.1007/978-1-84628-319-2).
- [43] W. F. Daenzer und R. Habermellner, Hrsg. *Systems Engineering: Methodik und Praxis*. 11., durchges. Aufl. Zürich: Verl. Industrielle Organisation, 2002. ISBN: 385743998X.
- [44] U. Lindemann, M. Maurer und T. Braun. *Structural Complexity Management: An Approach for the Field of Product Design*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008. ISBN: 978-3-540-87888-9. DOI: [10.1007/978-3-540-87889-6](https://doi.org/10.1007/978-3-540-87889-6).
- [45] G. E. P. Box und J. S. Hunter. „Multi-Factor Experimental Designs for Exploring Response Surfaces“. In: *The Annals of Mathematical Statistics* 28.1 (1957), S. 195–241.
- [46] G. E. P. Box und D. W. Behnken. „Some New Three Level Designs for the Study of Quantitative Variables“. In: *Technometrics* 2 (1960), S. 455–475. ISSN: 0040-1706.
- [47] B. Jones und C. J. Nachtsheim. „Efficient Designs With Minimal Aliasing“. In: *Technometrics* 53.1 (2011), S. 62–71. ISSN: 0040-1706. DOI: [10.1198/TECH.2010.09113](https://doi.org/10.1198/TECH.2010.09113).
- [48] G. Box, S. Bisgaard und C. Fung. „An explanation and critique of taguchi’s contributions to quality engineering“. In: *Quality and Reliability Engineering International* 4.2 (1988), S. 123–131. ISSN: 0748-8017. DOI: [10.1002/qre.4680040207](https://doi.org/10.1002/qre.4680040207).

- [49] D. A. Belsley. *Regression diagnostics: Identifying influential data and sources of collinearity*. Wiley series in probability and statistics. New York: Wiley, 2004. ISBN: 9780471725145. URL: <https://ebookcentral.proquest.com/lib/kxp/detail.action?docID=226535>.
- [50] L. Fahrmeir, T. Kneib und S. Lang. *Regression: Modelle, Methoden und Anwendungen*. 2. Auflage. Statistik und ihre Anwendungen. Heidelberg und Berlin: Springer, 2009. ISBN: 978-3-642-01836-7. DOI: [10.1007/978-3-642-01837-4](https://doi.org/10.1007/978-3-642-01837-4).
- [51] R. H. Myers, D. C. Montgomery, G. G. Vining und T. J. Robinson. *Generalized linear models: With applications in engineering and the sciences*. 2. ed. Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2010. ISBN: 9780470454633. DOI: [10.1002/9780470556986](https://doi.org/10.1002/9780470556986).
- [52] M. Arndt, P. Mell und M. Dazer. „Generic effects of deviations from test design orthogonality on test power and regression modelling of Central-Composite Designs“. In: *Proceedings of the 16th International Probabilistic Safety Assessment and Management Conference (PSAM16)*. Bd. PSAM 16. Honolulu, HI, USA, 2022.
- [53] A. Khuri. *Response Surface Methodology and Related Topics*. 1st. World Scientific Publishing Co Pte Ltd, 2006. ISBN: 9789812564580.
- [54] M. Risberg Ellekjær und S. Bisgaard. „The use of experimental design in the development of new products“. In: *International Journal of Quality Science* 3.3 (1998), S. 254–274. ISSN: 1359-8538. DOI: [10.1108/13598539810229230](https://doi.org/10.1108/13598539810229230).
- [55] S. Bisgaard. „A Conceptual Framework for the use of Quality Concepts and Statistical Methods in Product Design“. In: *Journal of Engineering Design* 3.1 (1992), S. 31–47. ISSN: 0954-4828. DOI: [10.1080/09544829208914746](https://doi.org/10.1080/09544829208914746).
- [56] S. Bisgaard. *Time series analysis and forecasting by example*. Wiley series in probability and statistics. Hoboken, N.J: Wiley, 2011. ISBN: 1118056949. DOI: [10.1002/9781118056943](https://doi.org/10.1002/9781118056943).
- [57] A. Zahran, C. M. Anderson-Cook und R. H. Myers. „Fraction of Design Space to Assess Prediction Capability of Response Surface Designs“. In: *Journal of Quality Technology* 35.4 (2003), S. 377–386. ISSN: 0022-4065.

- 
- [58] A. Giovannitti-Jensen und R. H. Myers. „Graphical Assessment of the Prediction Capability of Response Surface Designs“. In: *Technometrics* 31.2 (1989), S. 159–171. ISSN: 0040-1706.
- [59] E. Rittmaier, M. Arndt und M. Dazer. „Simulative Analysis of Statistical Power of Optimal Test Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–7. ISBN: 979-8-3503-6774-4. DOI: [10.1109/RAMS48127.2025.10935086](https://doi.org/10.1109/RAMS48127.2025.10935086).
- [60] R. T. Johnson, D. C. Montgomery und B. A. Jones. „An Expository Paper on Optimal Design“. In: *Quality Engineering* 23.3 (2011), S. 287–301. ISSN: 0898-2112. DOI: [10.1080/08982112.2011.576203](https://doi.org/10.1080/08982112.2011.576203).
- [61] A. N. Donev. „Design of experiments in the presence of errors in factor levels“. In: *Statistical Planning and Inference* 126.2 (2004), S. 569–585.
- [62] G. E. P. Box und K. B. Wilson. „On the Experimental Attainment of Optimum Conditions“. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 13.1 (1951), S. 1–45. ISSN: 00359246. URL: <http://www.jstor.org/stable/2983966> (besucht am 23. 03. 2023).
- [63] M. K. Ardakani, D. Das, S. S. Wulf und T. J. Robinson. „Estimation in Second-Order Models with Errors in the Factor Levels“. In: *Commun. in Statistics* 40.9 (2011), S. 1573–1590. DOI: [10.1080/03610921003637421](https://doi.org/10.1080/03610921003637421).
- [64] B. A. Jones und P. Goos. „I-Optimal Versus D-Optimal Split-Plot Response Surface Designs“. In: *Journal of Quality Technology* 44.2 (2012), S. 85–101. ISSN: 0022-4065.
- [65] B. A. Jones, K. Allen-Moyer und P. Goos. „A-optimal versus D-optimal design of screening experiments“. In: *Journal of Quality Technology* 53.4 (2021), S. 411–427. ISSN: 0022-4065.
- [66] L. A. Escobar und W. Q. Meeker. „Planning Accelerated Life Tests with Two or More Experimental Factors“. In: *Technometrics* 37.4 (1995), S. 411–427. ISSN: 0040-1706.
- [67] M. Modarres, M. Nuri-Amiri und C. Jackson. *Probabilistic physics of failure approach to reliability: Modeling, accelerated testing, prognosis and reliability assessment*. Performability engineering series. Beverly, MA und Hoboken, NJ: Scrivener Publishing und John Wiley & Sons Inc, 2017. ISBN: 9781119388630.

- [68] H. Ahn. „Central Composite Design for the Experiments with Replicate Runs at Factorial and Axial Points“. In: *Industrial Engineering* 349 (2015), S. 969–979.
- [69] D. Rasch und D. Schott. *Mathematical statistics*. Hoboken, NJ: John Wiley & Sons Inc, 2018. ISBN: 9781119385288.
- [70] H. Xu. „An Algorithm for Constructing Orthogonal and Nearly-Orthogonal Arrays with Mixed Levels and Small Runs“. In: *Technometrics* 44.4 (2002), S. 356–368. ISSN: 0040-1706.
- [71] A. Wald. „On the Efficient Design of Statistical Investigations“. In: *The Annals of Mathematical Statistics* 14.2 (1943), S. 134–140.
- [72] A. C. Rencher und G. B. Schaalje. *Linear models in statistics*. 2. ed. Hoboken, NJ: Wiley-Interscience, 2008. ISBN: 9780471754985. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2007024268-b.html>.
- [73] G. E. P. Box und N. R. Draper. *Response surfaces, mixtures, and ridge analyses*. 2. ed. Wiley series in probability and statistics. Hoboken, New Jersey: Wiley, 2007. ISBN: 9780470053577. URL: <http://www.loc.gov/catdir/enhancements/fy0826/2006043975-b.html>.
- [74] S. Bisgaard. „Designing Experiments for Tolerancing Assembled Products“. In: *Technometrics* 39.2 (1997), S. 142–152. ISSN: 0040-1706. DOI: [10.1080/00401706.1997.10485079](https://doi.org/10.1080/00401706.1997.10485079).
- [75] *Introduction to off-line quality control*. 1985.
- [76] *VDI Richtlinie Riemengetriebe*.
- [77] *Generalized linear models: With applications in engineering and the sciences*. 2nd ed (Online-Ausg.) Wiley series in probability and statistics. Hoboken, N.J: Wiley, 2010. ISBN: 9780470556979. URL: <http://site.ebrary.com/lib/alltitles/Doc?id=10529319>.
- [78] *Synchronous belts: Calculation of power rating and drive centre distance*.
- [79] *Proceedings of the 29th European Safety and Reliability Conference (ESREL 2019)*. Hannover, 2019.
- [80] *2019 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2019. ISBN: 978-1-5386-6554-1.

- [81] *Proceedings of the 16th International Probabilistic Safety Assessment and Management Conference (PSAM16)*. Honolulu, HI, USA, 2022.
- [82] *2022 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2022. ISBN: 978-1-6654-2432-5.
- [83] *Proceedings of the 33rd European Safety and Reliability Conference (ESREL 2023)*. Southampton, UK, 2023.
- [84] *Proceedings of the Probabilistic Safety Assessment and Management & Asian Symposium on Risk Assessment and Management (PSAM17 & ASRAM2024)*. Sendai, Japan, 2024.
- [85] *2024 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2024. ISBN: 979-8-3503-0769-6.
- [86] *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025. ISBN: 979-8-3503-6774-4.
- [87] S. Albers. *Handbuch Technologie- und Innovationsmanagement: Strategie — Umsetzung — Controlling*. SpringerLink Bücher. Wiesbaden und s.l.: Gabler Verlag, 2005. ISBN: 978-3-322-90787-5. DOI: [10.1007/978-3-322-90786-8](https://doi.org/10.1007/978-3-322-90786-8).
- [88] J. Antony. *Design of experiments for engineers and scientists*. Repr. Amsterdam: Butterworth-Heinemann, 2010. ISBN: 9780750647090. DOI: [10.1016/B978-0-7506-4709-0.X5000-5](https://doi.org/10.1016/B978-0-7506-4709-0.X5000-5).
- [89] M. Arndt, M. Dazer, J. Rötting und B. Bertsche. „Probabilistic Reliability Analysis of Screw Connections in Cast Aluminum Housings“. In: *Proceedings of the 31st European Safety and Reliability Conference (ESREL 2021)*. Hrsg. von B. Castanier. Chennai: Research Publishing Services, 2021, S. 2791–2798. ISBN: 978-981-18-2016-8. DOI: [10.3850/978-981-18-2016-8\textunderscore318-cd](https://doi.org/10.3850/978-981-18-2016-8\textunderscore318-cd).
- [90] M. Arndt, M. Dazer und B. Bertsche. „Reliability-Based Decision Methodology for Stress-Strength Optimization of Machine Components“. In: *2022 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2022, S. 1–6. ISBN: 978-1-6654-2432-5. DOI: [10.1109/RAMS51457.2022.9894019](https://doi.org/10.1109/RAMS51457.2022.9894019).

- [91] M. Arndt und M. Dazer. „Analysis of Efficiency in Response Surface Designs Considering Orthogonality Deviations and Cost Models“. In: *Proceedings of the 33rd European Safety and Reliability Conference (ESREL 2023)*. Southampton, UK, 2023.
- [92] M. Arndt und I. M. Dazer. „Analysis of Efficiency in Response Surface Designs Considering Orthogonality Deviations and Cost Models“. In: *European Conference on Safety and Reliability (ESREL), 3rd September - 7th September 2023*. Hrsg. von M. P. Brito, T. Aven, P. Baraldi, M. Čepin und E. Zio. Singapore: Research Publishing Services, 2023, S. 1167–1174. ISBN: 978-981-18-8071-1. DOI: [10.3850/978-981-18-8071-1\textunderscoreP160-cd](https://doi.org/10.3850/978-981-18-8071-1\textunderscoreP160-cd).
- [93] M. Arndt, M. Dazer, W. Raither und B. Bertsche. „Parameter assessment for reliability modeling of machine components using heuristic screening“. In: *Forschung im Ingenieurwesen* 87.4 (2023), S. 1347–1370. ISSN: 0015-7899. DOI: [10.1007/s10010-023-00711-5](https://doi.org/10.1007/s10010-023-00711-5).
- [94] M. Arndt und M. Dazer. „Investigating Practical Orthogonality Deviations in RSM for Optimized Predictive Reliability Modeling“. In: *2024 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2024, S. 1–6. ISBN: 979-8-3503-0769-6. DOI: [10.1109/RAMS51492.2024.10457825](https://doi.org/10.1109/RAMS51492.2024.10457825).
- [95] M. Arndt und M. Dazer. „Characteristics of Extrapolation-Optimized Response Surface Designs for Multivariate Reliability Modelling and Lifetime Prediction“. In: *Proceedings of the 17th International Conference on Probabilistic Safety Assessment and Management & Asian Symposium on Risk Assessment and Management PSAM17 & ASRAM2024* (2024).
- [96] M. Arndt und M. Dazer. „Investigating Practical Orthogonality Deviations in RSM for Improved Predictive Reliability Modeling“. In: *2024 Annual Reliability and Maintainability Symposium (RAMS)*. Bd. RAMS 2024. IEEE, 2024. ISBN: 979-8-3503-0769-6.
- [97] M. Arndt, E. Rittmaier und M. Dazer. „Assessing the Extrapolation Variance of Non-Orthogonal Response Surface Designs“. In: *2025 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2025, S. 1–6. ISBN: 979-8-3503-6774-4. DOI: [10.1109/RAMS48127.2025.10935022](https://doi.org/10.1109/RAMS48127.2025.10935022).



- 
- [98] A. C. Atkinson, A. N. Donev und R. D. Tobias. *Optimum Experimental Designs, with SAS*. 1st. New York: Oxford University Press Inc, 2007. ISBN: 9780199296590.
- [99] L. Bain. *Statistical Analysis of Reliability and Life-Testing Models : Theory and Methods, Second Edition / Lee Bain*. New edition 2. London: Taylor and Francis, 2017. ISBN: 9780203738733.
- [100] M. Beer und E. Zio, Hrsg. *Proceedings of the 29th European Safety and Reliability Conference (ESREL): 22-26 September 2019, Hannover, Germany*. Europe und Singapore: European Safety and Reliability Association und Research Publishing Services, 2019. ISBN: 978-981-11-2724-3. DOI: [10.3850/978-981-11-2724-3](https://doi.org/10.3850/978-981-11-2724-3).
- [101] B. Bertsche. *Reliability in automotive and mechanical engineering: Determination of component and system reliability*. Berlin und Heidelberg: Springer, 2008. ISBN: 978-3-540-33969-4. DOI: [10.1007/978-3-540-34282-3](https://doi.org/10.1007/978-3-540-34282-3).
- [102] A. Breiing und R. Knosala. *Bewerten technischer Systeme: Theoretische und methodische Grundlagen bewertungstechnischer Entscheidungshilfen*. Berlin und Heidelberg: Springer, 1997. ISBN: 978-3-642-63908-1. DOI: [10.1007/978-3-642-59229-4](https://doi.org/10.1007/978-3-642-59229-4).
- [103] M. P. Brito, T. Aven, P. Baraldi, M. Čepin und E. Zio, Hrsg. *European Conference on Safety and Reliability (ESREL), 3rd September - 7th September 2023: The topic of ESREL 2023 is "The Future of Safety in a Reconnected World".; We are delighted to announce ESREL2023, the 33rd European Safety and Reliability Conference. The conference will be held at the University of Southampton, United Kingdom, on 3-7 September 2023*. Singapore: Research Publishing Services, 2023. ISBN: 978-981-18-8071-1. DOI: [10.3850/978-981-18-8071-1-4procd](https://doi.org/10.3850/978-981-18-8071-1-4procd).
- [104] C. Brückner. *Qualitätsmanagement: Das Praxishandbuch für die Automobilindustrie*. 2., vollständig überarbeitete und erweiterte Auflage. München: Hanser, 2019. ISBN: 978-3-446-45575-7. DOI: [10.3139/9783446459724](https://doi.org/10.3139/9783446459724).
- [105] T. Buzan und B. Buzan. *The mind map book: Unlock your creativity, boost your memory, change your life*. 1. publ. Harlow u.a.: Pearson, BBC Active, 2010. ISBN: 9781406647167. URL: <https://permalink.obvsg.at/AC11808619>.

- [106] R. J. Carrol, D. Ruppert, L. A. Stefanski und C. M. Crainiceanu. *Measurement Error in Nonlinear Models: A Modern Perspective*. 2nd. Chapman & Hall/CRC, 2006. ISBN: 9780429139635.
- [107] B. Castanier, Hrsg. *Proceedings of the 31st European Safety and Reliability Conference (ESREL 2021): 19-23 September 2021, Angers, France*. Chennai: Research Publishing Services, 2021. ISBN: 978-981-18-2016-8. DOI: [10.3850/978-981-18-2016-8](https://doi.org/10.3850/978-981-18-2016-8).
- [108] H. Colsman. *Qualitätstechniken: Werkzeuge zur Problemlösung und ständigen Verbesserung*. 5. Auflage. Pocket Power. München: Hanser Verlag, 2013. ISBN: 9783446437425. DOI: [10.3139/9783446437425](https://doi.org/10.3139/9783446437425).
- [109] M. Dazer, M. Stohrer, S. Kemmler und B. Bertsche. „Planning of reliability life tests within the accuracy, time and cost triangle“. In: *2016 IEEE Accelerated Stress Testing & Reliability Conference (ASTR)*. Piscataway, NJ: IEEE, 2016, S. 1–9. ISBN: 978-1-5090-1880-2. DOI: [10.1109/ASTR.2016.7762270](https://doi.org/10.1109/ASTR.2016.7762270).
- [110] M. Dazer, A. Grundler, A. Benz, M. Arndt und P. Mell. „Pitfalls of Zero Failure Testing for Reliability Demonstration“. In: *Proceedings of the 32st European Safety and Reliability Conference (ESREL 2021)*. Hrsg. von M. C. Leva, L. Podofillini, E. Patelli und S. Wilson. Chennai: Research Publishing Singapore, 2022, S. 1639–1646. ISBN: 978-981-18-5183-4. DOI: [10.3850/978-981-18-5183-4](https://doi.org/10.3850/978-981-18-5183-4).
- [111] S. D. Eppinger. *Design structure matrix methods and applications*. Engineering systems. Cambridge, Mass.: MIT Press, 2012. ISBN: 9780262301428. DOI: [10.7551/mitpress/8896.001.0001?locatt=mode:legacy](https://doi.org/10.7551/mitpress/8896.001.0001?locatt=mode:legacy).
- [112] G. E. P. Box. „The Effects of Errors in the Factor Levels and Experimental Design“. In: *Technometrics* 5.2 (1963), S. 247–262. ISSN: 0040-1706. URL: <http://www.jstor.org/stable/1266066> (besucht am 23.03.2023).
- [113] J. Gharajedaghi. *Systems thinking: Managing chaos and complexity : a platform for designing business architecture*. 3rd ed. Burlington, MA: Morgan Kaufmann/Elsevier, 2011. ISBN: 9780123859150. DOI: [10.1016/C2010-0-66301-2](https://doi.org/10.1016/C2010-0-66301-2).
- [114] A. Grundler, M. Dazer und T. Herzig. *Statistical power analysis in reliability demonstration testing : the probability of test success*. 2022. DOI: [10.18419/OPUS-12638](https://doi.org/10.18419/OPUS-12638).



- 
- [115] J. Hirtz, R. B. Stone, D. A. McAdams, S. Szykman und K. L. Wood. „A functional basis for engineering design: Reconciling and evolving previous efforts“. In: *Research in Engineering Design* 13.2 (2002), S. 65–82. ISSN: 0934-9839. DOI: [10.1007/s00163-001-0008-3](https://doi.org/10.1007/s00163-001-0008-3).
- [116] 2016 IEEE Accelerated Stress Testing & Reliability Conference (ASTR): 28-30 Sept. 2016. Piscataway, NJ: IEEE, 2016. ISBN: 978-1-5090-1880-2.
- [117] B. Klein. *Versuchsplanung - DoE: Einführung in die Taguchi/Shainin-Methodik*. 3rd ed. München: De Gruyter, 2011. ISBN: 978-3-486-71136-3. DOI: [10.1524/9783486711363](https://doi.org/10.1524/9783486711363).
- [118] W. Kleppmann. *Versuchsplanung: Produkte und Prozesse optimieren*. 9., überarbeitete Auflage. Hanser eLibrary. München: Hanser, 2016. ISBN: 978-3-446-44716-5. DOI: [10.3139/9783446447172?locatt=mode:legacy](https://doi.org/10.3139/9783446447172?locatt=mode:legacy).
- [119] H. Krallmann, A. Bobrik und O. Levina. *Systemanalyse im Unternehmen: Prozessorientierte Methoden der Wirtschaftsinformatik*. 6., überarb. und erw. Aufl. München: Oldenbourg-Verl., 2013. ISBN: 978-3-486-72982-5. DOI: [10.1524/9783486729825](https://doi.org/10.1524/9783486729825).
- [120] A. Kremer und B. Bertsche. „Methodik zur Prognose der Lebensdauer von Zahnriemengetrieben“. In:
- [121] A. Kremer und B. Bertsche. „A New Approach for Parametrizing Multidimensional Lifetime Models“. In: *Proceedings of the 29th European Safety and Reliability Conference (ESREL 2019)*. Hannover, 2019.
- [122] M. C. Leva, L. Podofillini, E. Patelli und S. Wilson, Hrsg. *Proceedings of the 32st European Safety and Reliability Conference (ESREL 2021): Will be held in Dublin, Ireland from 28th August - 1st September 2022*. Chennai: Research Publishing Singapore, 2022. ISBN: 978-981-18-5183-4. DOI: [10.3850/9789811851834procd](https://doi.org/10.3850/9789811851834procd).
- [123] P. Mell, M. Arndt und M. Dazer. „Non-orthogonality in test design: practical relevance of the theoretical concept in terms of regression quality and test plan efficiency“. In: *Proceedings of the Probabilistic Safety Assessment and Management Conference 2022 PSAM 16* (2022).

- [124] P. Mell und M. Dazer. „Estimating the Duration of Failure-Based Reliability Demonstration Tests“. In: *2024 Annual Reliability and Maintainability Symposium (RAMS)*. IEEE, 2024, S. 1–7. ISBN: 979-8-3503-0769-6. DOI: [10.1109/RAMS51492.2024.10457820](https://doi.org/10.1109/RAMS51492.2024.10457820).
- [125] P. Mell und M. Dazer. „Analytic Evaluation of the Statistical Power of Accelerated Reliability Demonstration Tests“. In: *IEEE Access* 13 (2025), S. 99892–99910. DOI: [10.1109/ACCESS.2025.3577366](https://doi.org/10.1109/ACCESS.2025.3577366).
- [126] D. C. Montgomery. *Introduction to statistical quality control*. Eighth edition, EMEA edition. Hoboken, NJ: Wiley, 2020. ISBN: 9781119657118.
- [127] T. Nagel. *Zahnriemengetriebe: Eigenschaften, Normung, Berechnung, Gestaltung*. 1. Aufl. München und Wien: Hanser, 2008. ISBN: 978-3-446-41380-1.
- [128] R. Perneder. *Handbuch Zahnriementchnik: Grundlagen, Berechnung, Anwendungen*. Berlin und Heidelberg: Springer, 2009. ISBN: 978-3-540-89321-9.
- [129] H. Pham. *Springer Handbook of Engineering Statistics*. London: Springer London, 2023. ISBN: 978-1-4471-7502-5. DOI: [10.1007/978-1-4471-7503-2](https://doi.org/10.1007/978-1-4471-7503-2).
- [130] R. L. Plackett und J. P. Burman. „The Design of Optimum Multifactorial Experiments“. In: *Biometrika* 33 (1946), S. 305–325.
- [131] G. J. B. Probst und P. Gomez. *Vernetztes Denken: Ganzheitliches Führen in der Praxis*. 2., erweiterte Auflage. Wiesbaden: Gabler, 1991. ISBN: 978-3-322-89073-3. DOI: [10.1007/978-3-322-89072-6](https://doi.org/10.1007/978-3-322-89072-6).
- [132] D. G. Raheja. „Accelerated Testing: Statistical Models, Test Plans, and Data Analysis, Wayne Nelson. Wiley, New York, 1989. Price: £69.95“. In: *Quality and Reliability Engineering International* 6.2 (1990), S. 160. ISSN: 0748-8017. DOI: [10.1002/qre.4680060214](https://doi.org/10.1002/qre.4680060214).
- [133] C. Spura, B. Fleischer, H. Wittel, D. Jannasch, H. Roloff und W. Matek. *Roloff/Matek Maschinenelemente*. 26. Auflage. Wiesbaden: Springer Vieweg, 2023. ISBN: 978-3-658-40913-5. URL: <https://link.springer.com/978-3-658-40913-5>.
- [134] G. Taguchi. *Introduction to quality engineering: Designing quality into products and processes*. 6. print. Tokyo: Asian Productivity Organization, 1989. ISBN: 9283310837.

- [135] P. Tittmann. *Graphentheorie: Eine anwendungsorientierte Einführung : mit 115 Bildern, zahlreichen Beispielen und 92 Aufgaben*. 3., aktualisierte Auflage. Mathematik-Studienhilfen. München: Hanser, 2019. ISBN: 978-3-446-46052-2. DOI: [10 . 3139/9783446465039](https://doi.org/10.3139/9783446465039).
- [136] R. E. Trueman. *An introduction to quantitative methods for decision making*. 2. ed. Series in quantitative methods for decision making. New York: Holt Rinehart and Winston, 1977. ISBN: 003018391X.
- [137] VDA. *Zuverlässigkeitssicherung bei Automobilherstellern und Lieferanten. Zuverlässigkeits-Methoden und Hilfsmittel*.
- [138] K. Wallace, G. Pahl, W. Beitz, J. Feldhusen, K.-H. Grote und L. T. M. Blessing, Hrsg. *Engineering design: A systematic approach*. 3. ed. London: Springer, 2007. ISBN: 1846283183. URL: <http://site.ebrary.com/lib/librarytitles/docDetail.action?docID=10230457>.



## **Anhang A   Ein Anhang**

### **Anhang A.1   Unteranhang 1**